

Exercices 3 : Le Tidyverse II et les statistiques uni- et bi-variées

Essayez de faire ces exercices de manière indépendante. Inscrivez vos réponses dans un fichier script R (avec l'extension ".r" ou ".R") en essayant de bien structurer (et dans l'idéal commenter) votre code.

1 Préparation des données : `pragmatique.xlsx`

- Chargez les bibliothèques `tidyverse`, `readxl` et `DescTools`.
- Chargez le jeu de données `pragmatique.xlsx`.
- Observez les modalités de la variable `Lemme`. On voit qu'il y a un espace de trop après la modalité "EVIDEMMENT".
- Utilisez les fonctions `mutate()` et `str_squish()` (voir l'aide si besoin) pour transformer cette variable. Enregistrez la modification et vérifiez que les modalités ont été modifiées.
- Créez une variable `n_syllabes` qui est égale au nombre de syllabes de `Lemme`. Utilisez pour cela `case_when()` et assignez manuellement un nombre de syllabes à chaque modalité de `Lemme`.
- Créez une nouvelle variable dans `pragmatique_df` appelée `Durée` qui correspond à `Timing fin - Timing début`.

2 Statistiques uni- et bi-variées

- Avec `summarize()`, créez un tableau de données contenant la moyenne, la médiane et l'écart-type du nombre de syllabes.
- Utilisez `reframe()` pour créer un tableau contenant les quantiles-25%, 50% et 75% de `Durée`.
- Avec `reframe()`, créez une table contenant deux colonnes. La première colonne doit contenir le nom des différentes modalités de POS-TAG et la deuxième leur fréquence.
- Utilisez `summarize()` pour créer un tableau contenant le nombre de catégories, l'entropie et la variété effective de POS-TAG.
- Créez un tableau contenant la covariance et la corrélation entre `Durée` et `n_syllabes`.
- Donnez la table de contingence `Lemme` vs POS-TAG (sans le tidyverse).

3 Statistiques sur des groupes

- Créez des groupes avec POS-TAG et `Lemme` (dans cet ordre) et effectuez un `summarize()` contenant la moyenne de `Durée` sur ces groupes. Sauvegardez le tableau final dans une variable. S'agit-il des moyennes de `Durée` pour chaque `Lemme` ?
- En utilisant le tableau précédant, calculez la moyenne de `Durée` par POS-TAG.
- Calculez la moyenne de `n_syllabes` par `Lemme`.