

Exercices 5 : Tests statistiques

Essayez de faire ces exercices de manière indépendante. Inscrivez vos réponses dans un fichier script R (avec l'extension ".r" ou ".R") en essayant de bien structurer (et dans l'idéal commenter) votre code.

1 Préparation des données : sociolinguistique.xlsx

- Chargez les bibliothèques `tidyverse` et `readxl`.
- Chargez le jeu de données `sociolinguistique.xlsx`.
- Renommez les variables suivantes avec la fonction `rename`, (les éléments entre <> sont à remplacer adéquatement) :

```
<nouveau jeu de données> = <ancien jeu de données> %>%  
  rename(annee=<nom de la variable année de naissance>,  
         genre=<nom de la variable du genre>,  
         q1_cat='«?Les anglicismes enrichissent la langue française?»',  
         q2_cat='«?Les anglicismes constituent une menace pour la langue française?»')
```
- Créez des variables numériques `q1` et `q2`, contenant les réponses aux questions recodées selon le modèle :

```
<nouveau jeu de données> = <ancien jeu de données> %>%  
  mutate(q1=case_when(q1_cat=="En désaccord total" ~ -2,  
                      q1_cat=="Plutôt en désaccord" ~ -1,  
                      q1_cat=="Neutre" ~ 0,  
                      q1_cat=="Plutôt d'accord" ~ 1,  
                      q1_cat=="Tout à fait d'accord" ~ 2))
```
- Créez la variable `generation` avec :

```
<nouveau jeu de données> = <ancien jeu de données> %>%  
  mutate(generation=case_when(annee %in% 0:1983 ~ "X",  
                              annee %in% 1984:1995 ~ "Y",  
                              annee %in% 1996:2000 ~ "Z"))
```

2 Tests de moyenne groupes non-appariés

- Extrayez les vecteurs `q1_f` et `q1_h`, i.e. les réponses numériques à la question 1 pour les femmes et les hommes.
- Effectuez un test de moyenne entre ces deux vecteurs.
- Refaites cette procédure pour la question 2.
- Est-ce que les résultats sont significatifs au seuil $\alpha = 5\%$? Et au seuil $\alpha = 10\%$? Comment peuvent-ils s'interpréter (sens de l'effet)?

3 Tests bi-variés

- Effectuez un test de corrélation entre les réponses numériques à la question 1 et la question 2. Interprétez brièvement.
- Effectuez un test du F-ratio entre les réponses numériques à la question 1 et les générations. Refaites le même test pour la question 2 et les générations.

- Pour vous aider à interpréter les résultats précédants, faites des boxplots multiples entre génération et réponses numériques aux questions. Interprétez les résultats des tests et les boxplots.
- Créez une table de contingence entre les réponses catégorielles de la question 1 et les générations. Effectuez un test du χ^2 sur cette table de contingence. Est-ce que les résultats diffèrent par rapport au test du F-ratio ? Expliquez brièvement.