


TP : Introduction à l'analyse de données en SHS

Rappel théorique sur les tests statistiques

Guillaume Guex guillaume.guex@unil.ch


Statistique descriptive vs Statistique inférentielle

La **statistique descriptive** s'occupe de la construction de mesures, statistiques et graphiques pour décrire au mieux un échantillon.



Statistique descriptive vs Statistique inférentielle


La **statistique inférentielle** va essayer de confronter des **modèles théoriques** et des **hypothèses** aux mesures obtenues sur un échantillon.



Les **tests statistiques** sont une part importante de la statistique inférentielle.



Exemple : le nombre d'adjectifs

Exemple de **modèle** ou d'**hypothèse** : en français, dans un texte de 5000 mots, on compte en moyenne 300 adjectifs (avec écart-type de 20 adjectifs). En statistique, on modélise cela avec un **Loi normale** ou **Gaussienne** :



Exemple : le nombre d'adjectifs

Les **données de l'échantillon** vont ensuite nous permettre de voir si le modèle ou l'hypothèse semble valable ou non :



Les tests statistiques : tester un paramètre

En réalité, les tests ne vont pas s'effectuer sur le modèle complet, mais sur la **valeur d'un paramètre théorique dans la population**. Les hypothèses des tests prennent généralement les formes suivantes :

1. La **moyenne** du nombre d'adjectifs (sur 5000 mots) est de 300.
2. La **moyenne** du nombre d'adjectifs (sur 5000 mots) est égale en français et en anglais.
3. La **corrélation** entre le nombre d'adjectifs et la nombre de verbes est nulle.
4. Le **lien** (mesuré via le χ^2) entre le type de texte et le support de publication est inexistant.

À chaque fois, l'hypothèse suppose que le paramètre étudié possède une « vraie valeur » dans la population, et le test cherche à confronter cette hypothèse avec ce que l'on trouve dans l'échantillon (on restreint l'enjeu).

La logique est similaire à chaque fois, donc illustrons les tests avec le **test de la moyenne** (point 1).

Les hypothèses H_0 et H_1

Dans un test de moyenne (simple), on note la **moyenne théorique** avec μ . On pose ensuite l'**hypothèse H_0** et une **hypothèse alternative H_1** . Dans notre exemple :

$$\begin{cases} H_0 : \mu = 300 \\ H_1 : \mu \neq 300 \end{cases}$$


Le test consiste à mesurer la **moyenne empirique** sur un échantillon tiré de taille n , notée $\bar{x}$, et de voir si elle s'écarte « **beaucoup** » de la valeur théorique de 300.

Le problème est de définir ce « beaucoup ».

Supposer que H_0 est vraie

Pour quantifier l'écart en 300 et la moyenne empirique, on commence par **supposer que H_0 est vraie**.



Dans ce cadre, on sait (mathématiquement) que la moyenne d'un échantillon de taille n suit (à peu près) une **loi normale de moyenne 300 et d'écart-type $\frac{s_x}{\sqrt{n}}$** (où s_x est l'écart-type mesuré sur l'échantillon) :



(la courbe va se resserrer en fonction de n)

Où est $\bar{x}$ si H_0 est vraie ?



On regarde ensuite où se situe la moyenne calculée sur l'échantillon $\bar{x}$ par rapport à cette courbe :



La p-valeur

Pour quantifier la position de $\bar{x}$ par rapport à la courbe H_0 , on va utiliser le concept de **valeur p** ou **p-valeur** :

p-valeur = « probabilité d'obtenir des valeurs plus extrêmes que $\bar{x}$ si H_0 est vraie »



On va généralement poser un **seuil de tolérance**, noté α (souvent 5%) pour la p-valeur. Ce seuil détermine si on rejette H_0 :

- Si p-valeur $< \alpha$: **On rejette H_0 .**
- Si p-valeur $> \alpha$: **On ne rejette par H_0 .**

On dit que le test est **significatif** si p-valeur $< \alpha$ et que l'on rejette H_0 .

Le fait de poser le seuil α permet de contrôler l'**erreur de la première espèce** :

Erreur de la 1ère espèce = « Probabilité de rejeter H_0 alors que H_0 est vrai »

Avec un seuil de $\alpha = 5\%$, on va rejeter l'hypothèse H_0 à tort 1 fois sur 20.

Les autres tests se basent sur le même principe, mais la **statistique calculée** et la **courbe théorique pour H_0** ne sont pas les mêmes :

Test	Hypothèse H_0	Statistique ($\sim$)	Loi
Moyenne entre 2 groupes	$\mu_x = \mu_y$	$ \bar{x} - \bar{y} $	Loi de Student
Moyenne entre 2 groupes (appariés)	$\mu_x = \mu_y$	$\overline{(x_i - y_i)}$	Loi de Student
Corrélation (num - num)	$\text{cor}(X, Y) = 0$	ρ_{xy}	Loi de Student
F-ratio (num - cat)	$\mu_1 = \mu_2 = \dots = \mu_m$	F-ratio	Loi de Fisher
Chi-carré (cat - cat)	X et Y sont indépendantes	chi2	Loi du Chi2

Mais dans tous les cas, les **tests nous donnent une p-valeur qu'il faut comparer avec un seuil α** .