

Exercices 6 : Traitement des données textuelles

Essayez de faire ces exercices de manière indépendante. Inscrivez vos réponses dans un fichier script R (avec l'extension ".r" ou ".R") en essayant de bien structurer (et dans l'idéal commenter) votre code.

1 Chargement et traitement d'un document

- Chargez les librairies `tidyverse`, `readtext`, `quanteda` et `quanteda.textstats`.
- Chargez le fichier `data/20min.txt` dans une chaîne de caractères.
- Le fichier contient 5 articles différents. Les titres des articles sont sur une seule ligne et sont de la forme `A<numéro article> <titre de l'article>` (allez voir les données). Construisez une expression régulière pour capturer les numéros d'article (`A1`), (`A2`), (`A3`), ...).
Indication : il s'agit d'un "A", suivi d'un ou plusieurs "digits", puis d'une parenthèse fermante.
- Segmentez le texte par article avec l'expression régulière construite.
- Éliminez les éléments vides (ce qu'il y a avant `A1`) et vérifiez la longueur du vecteur résultant, elle doit être de 5.
- Utilisez `str_squish()` pour éliminer tous les espaces, tabulations et retours à la ligne superflus.
- À l'aide d'une boucle `for`, sauvegardez les articles dans le dossier `data/20min/` avec chacun un nom de la forme `20min_<numero>.txt`.

2 Quanteda

- Chargez tous le corpus contenu dans le dossier `"data/20min/"` à l'aide de la fonction `readtext()`.
- A partir des textes, créez un objet de type "corpus" de `quanteda`.
- Donnez les statistiques simples (`summary()`) et étendues (`textstat_summary()`) du corpus.
- A partir de l'objet de type "corpus", créez un objet de type "tokens" pour les mots. Supprimez la ponctuation, les symboles, les nombres, les url, séparez les traits d'union et mettez tous les caractères en minuscules.
- Supprimez les stopwords des tokens à partir de la liste donnée sous `"data/frenchST.txt"`.
- Créez un objet de type "dfm" à partir des tokens.
- Donnez les 20 mots les plus fréquents par document.