

Exercices 7 : Annotations

Essayez de faire ces exercices de manière indépendante. Inscrivez vos réponses dans un fichier script R (avec l'extension ".r" ou ".R") en essayant de bien structurer (et dans l'idéal commenter) votre code.

1 Chargement de documents XML

- Chargez les librairies `tidyverse`, `udpipe`, `xml2` et `xmlconvert`.
- Stockez le chemin d'accès (relatif) du dossier du corpus Nicolas_Boileau (contenant des fichiers XML extrait de *FranTEXT*) dans la variable `corpus_folder`.
- Listez (avec la fonction `list.files(<dossier>)`) et stockez les fichiers contenus dans ce dossier dans la variable `corpus_file_names`.
- Créez le tibble vide `corpus_token_df`, avec colonnes : `document` (caractères), `word` (caractères), `pos` (caractères), et `lemma` (caractères).
- Effectuez une boucle `for(file_name in corpus_file_names)`, qui boucle sur tous les fichiers du dossier. Dans la boucle :
 1. Créez le chemin d'accès au fichier avec la fonction `paste0()`.
 2. Chargez le document XML dans une dataframe avec `xml_to_df()` (avec les mêmes options que dans le cours).
 3. Transformez la dataframe en tibble (`as_tibble()`) et ajoutez une colonne `document` contenant le nom du fichier.
 4. Ajoutez le tibble du document au tibble du corpus avec la fonction `add_row()`.
- Affichez le tibble `corpus_token_df` dans un onglet de RStudio.
- À partir de ce tibble, donnez le nombre de tokens, types et lemmes pour chaque document.

2 Annotations automatiques

- Extrayez les textes du corpus dans un vecteur `texts`, à partir de `corpus_token_df`. Pour cela, groupez par document, puis effectuez un `summarise(text=str_c(word, collapse=" "))`. Les textes bruts seront alors contenu dans la colonne `text`.
- Affichez les 100 premiers caractères de chaque document avec `str_sub()`.
- Chargez le modèle `french-gsd-ud-2.5-191206.udpipe` (dans le dossier `models`), avec `udpipe_load_model()`.
- Annotez le corpus contenu dans `texts` avec `udpipe_annotate()`.
- Transformez le résultat donné par `udpipe_annotate()` en tibble et stockez le dans la variable `corpus_token_df2`.
- Affichez `corpus_token_df2` et comparez le à `corpus_token_df` du point 1. Commentez brièvement.