

Exercices 8 : Analyses de données textuelles

Essayez de faire ces exercices de manière indépendante. Inscrivez vos réponses dans un fichier script R (avec l'extension ".r" ou ".R") en essayant de bien structurer (et dans l'idéal commenter) votre code.

1 Chargement, création des objets quanteda, indices

- Chargez les librairies `tidyverse`, `readtext`, `quanteda`, `quanteda.textstats` et `quanteda.textplots`.
- Chargez les fichiers contenus dans le dossier "`exercices_data/20min/`" dans un dataframe.
- Créez un objet de type `corpus` et un objet de type `tokens` à partir de ce dataframe.
- Créez une table contenant l'indice de diversité lexicale `MATTR` et classez les documents par ordre croissant selon cet indice.
- Créez une table contenant les indices de lisibilité `meanSentenceLength` et `meanWordSyllables`, puis classez les documents par ordre croissant selon `meanSentenceLength`.

2 Collocations et Concordance

- Créez une table contenant les collocations d'ordre 2, et classez-les par ordre décroissant selon la fréquence.
- Créez un concordancier sur la séquence "le président", et affichez le dans un onglet.
- Affichez le graphique montrant les apparitions de la séquence "de la" à l'intérieur de vos documents.

3 Matrice documents-termes et spécificités

- A partir de l'objet `corpus`, construisez un objet `quanteda` de type `tokens` en enlevant tous les éléments « non-alphabétiques ».
- Séparez vos tokens via les apostrophes et retirez les *stopwords* à partir de la liste contenue dans "`exercices_data/stopwords/frenchST.txt`".
- Construisez la matrice documents-termes à partir du nouvel objet `tokens` obtenu.
- Affichez le graphique des spécificités pour les documents 3, 5, 8, et 20.
- Créez un *wordcloud* pour tout le corpus, avec tous les mots apparaissant minimum 10 fois.

4 Co-occurrences

- Construisez un nouvel objet `tokens`, à partir de celui obtenu à la section précédente, en mettant tous les tokens en minuscules.
- Construisez la matrice de co-occurrences, selon une fenêtre coulissante de ± 5 tokens.
- Créez une liste des 100 types les plus fréquents dans le corpus. Affichez cette liste.
- Créez le graphe de co-occurrences entre ces 100 types, en ne gardant qu'un certain nombre de co-occurrences pour avoir un affichage informatif mais non surchargé.