

Exercices 9 : Analyse factorielle des correspondances

Essayez de faire ces exercices de manière indépendante. Inscrivez vos réponses dans un fichier script R (avec l'extension ".r" ou ".R") en essayant de bien structurer (et dans l'idéal commenter) votre code.

1 Pré-traitements

- Chargez `tidyverse`, `readtext`, `quanteda`, `FactoMineR` et `factoextra`.
- Chargez les fichiers contenus dans le dossier "exercices_data/20min/" dans un dataframe.
- A partir de ce dataframe, construisez un objet `quanteda` de type `tokens`, en enlevant tous les éléments « non-alphabétiques ».
- Séparez vos tokens via les apostrophes et retirez les *stopwords* à partir de la liste contenue dans "exercices_data/stopwords/frenchST.txt".

2 Création de matrices termes-documents

- Construisez la matrice documents-termes à partir du nouvel objet `tokens` obtenu. N'oubliez pas de convertir l'objet "dfm" en dataframe, et de convertir la colonne `doc_id` en nom des lignes.
- Construisez une matrice documents-termes binaire (présence ou non du terme dans le document).
- En utilisant la marge des colonnes (`colSums()`) de la matrice binaire, extraire les indices des mots qui apparaissent dans un seul document (utilisez `which()`).
- Construisez un vecteur contenant les indices des articles sur le foot et sur le "fils lutteur" (ces derniers sont très différents des autres).

3 l'AFC

- Faites une AFC sur la matrice documents-termes (non-binaire) en lui ajoutant une quantité infime. Mettez comme lignes et colonnes supplémentaires les vecteurs construits à la section précédente.
- Affichez l'inertie sur toutes les dimensions. Quel pourcentage cumulé est exprimé sur les 4 premières ?
- Avec `factoextra`, faites un biplot des deux premières dimensions, en affichant uniquement les 80 mots avec la plus forte contribution.
- Avec `factoextra`, faites un biplot des dimensions 3 et 4, en affichant uniquement les 80 mots avec la plus forte contribution.
- Donnez la liste des 10 mots donnant le plus de contribution sur les axes 1 et 2.
- Commentez le résultat précédent.