

TP : Introduction à l'analyse de données en SHS

Introduction à l'AFC

Guillaume Guex guillaume.guex@unil.ch

La matrice documents-termes

À partir d'un corpus, la **matrice document-terme** se présente de la manière suivante :

doc_id	emmanuel	macron	président	retrouver	esprit	conquête	bâtir	france	ni
1 en_marche_2017.txt	1	1	3	2	4	2	2	21	
2 europe_ecologie_les_verts_2017.txt	0	0	0	1	0	0	0	38	
3 france_insoumise_2017.txt	0	2	6	2	5	0	1	64	
4 front_national_2017.txt	0	0	0	2	1	0	1	36	
5 mouvement_democratique_2017.txt	0	0	4	2	1	0	4	35	
6 parti_communiste_francais_2017.txt	0	1	1	0	0	0	0	0	
7 parti_radical_de_gauche_2017.txt	0	0	6	0	0	2	0	21	
8 parti_socialiste_2017.txt	0	0	0	0	0	0	0	7	
9 udi_republicains_2017.txt	2	2	2	1	2	0	0	35	

Les cases contiennent la **fréquence (absolue) des termes dans les documents**.

Il s'agit d'une **table de contingence** (croisement des modalités de deux variables catégorielles).

Cette table définit deux types de profils :

- les **profils des documents (lignes)**, par leur utilisation relative des différents mots.
- les **profils des termes (colonnes)**, par leur répartition relative à l'intérieur des documents.

Comment illustrer aux mieux ces deux types de profils ?

La méthode la plus adaptée est l'**Analyse Factorielle des Correspondances (AFC)**.

L'**Analyse Factorielle des Correspondances (AFC)** fait partie de la famille des **méthodes factorielles**. Cette méthode permet :

- D'analyser une **table de contingence** de manière **exploratoire**.
- De **compresser l'« information »** contenue dans des données, pour la représenter au mieux dans un nombre réduit de dimensions (souvent 2, i.e. un graphique dans le plan).
- De **comparer les profils des lignes** entre eux.
- De **comparer les profils des colonnes** entre eux.
- De comprendre les **attractions et répulsions entre lignes et colonnes**.

Les deux sorties principales d'une AFC sont le **screeplot** et le **biplot**.


La table de contenance : exemple

Exemple : flux migratoires entre des pays européens du sud vers des pays européens du nord en 1965

$Y = \text{origine } k \rightarrow$	Grèce	Turquie	Yougoslavie	Portugal	Espagne	Italie	total
$X = \text{destination } i \downarrow$							
Allemagne	187	133	65	14	183	372	954
France	5	8	20	103	346	340	822
Suisse	7	4	4	1	79	500	595
Pays-Bas	2	6	1	1	6	8	24
Belgique+Luxembourg	8	7	0	2	32	95	144
Autriche	2	5	19	0	2	3	31
Suède	0	0	5	0	0	5	10
total	211	163	114	121	648	1323	2580


Le screeplot : exemple

Le **screeplot** permet de voir la répartition de l'information :



Le biplot : exemple

Le **biplot** permet de comprendre les profils des lignes, des colonnes, et les attractions/répulsions entre lignes et colonnes :




Le biplot : clés d'interprétation

L'interprétation du biplot se fait de la manière suivante :

- Le **profil moyen** est représenté à l'origine.
- La distance (au carrée) à l'origine est d'autant plus grand que la catégorie est **atypique**.
- Deux lignes (ou deux colonnes) dont les coordonnées sont proches ont des **profils similaires**.
- L'**attraction ou répulsion** entre une ligne et une colonne k est proportionnelle au produit scalaire ($= \|a\| \|b\| \cos(a, b)$) entre leurs coordonnées, non pas à la proximité.

Attraction et répulsion entre ligne et colonne



- (I) Forte attractivité entre j et k .
- (II) Attractivité encore plus forte : le produit scalaire a augmenté.
- (III) Neutralité mutuelle.
- (IV) Forte répulsivité mutuelle.

Deux autres quantités (sur les lignes et colonnes) sont utiles pour l'interprétation :

- Les **contributions** permettent de comprendre comment sont constitués les axes.
- Les **cos2** représentent la qualité de la représentation des lignes (ou colonnes) sur chaque axes.

Contributions

	Dim 1	Dim 2	Dim 3	Dim 4	Dim 5
Grèce	31	0	22	38	1
Turquie	24	0	8	61	1
Yougoslavie	23	9	63	1	0
Portugal	8	29	1	0	58
Espagne	7	26	3	0	38
Italie	7	36	4	0	2

Cos2

	Dim 1	Dim 2	Dim 3	Dim 4	Dim 5
Grèce	78	0	20	1	0
Turquie	87	0	10	3	0
Yougoslavie	46	10	44	0	0
Portugal	32	67	1	0	0
Espagne	29	66	5	0	0
Italie	24	71	5	0	0