

Exercices 10 : Régression linéaire

Essayez de faire ces exercices de manière indépendante. Inscrivez vos réponses dans un fichier script R (avec l'extension ".r" ou ".R") en essayant de bien structurer (et dans l'idéal commenter) votre code.

1 Pré-traitements

- Chargez `tidyverse` et `leaps`.
- Chargez le fichier `"data/sociolinguistique_v2.csv"`.
- Construisez la table réduite ne contenant que la variable `annee`, ainsi que toutes la variables d'utilisation d'un anglicisme (variable de `Hashtag` à `Craft`)

2 Régressions linaires

- Faites le modèle linéaire complet pour prédire `annee` et affichez-le avec `summary()`.
- A quel mot correspond le coefficient de régression le plus significatif?
- Quelles sont les valeurs du R^2 et du R^2 ajusté?
- Faites une étude de modèles avec la fonction `regsubsets()` du package `leaps`.
- Affichez le graphique montrant les variables à retenir en fonction du BIC.
- Quelles sont les variables à retenir pour optimiser le BIC?
- Faites le modèle optimal avec les variables retenues. Quelles sont les nouvelles valeurs du R^2 et du R^2 ajusté?
- D'après le modèle, les utilisations de quels mots augmentent l'âge prédit.
- Affichez le diagramme des résidus. Est-ce que ce diagramme présente une structure particulière?
- Construisez un tableau de données pour deux individus, l'un utilisant "Hashtag", "Cool" et "Chill", et une autre utilisant "Tea-room" et "Re-dingote".
- Faites des prédictions sur les âges de ces personnes.