

TP : Introduction à l'analyse de données en SHS

Introduction à la régression linéaire



Guillaume Guex guillaume.guex@unil.ch

Parties déterministe et aléatoire

L'allure générale d'un diagramme de dispersion associé à deux variables x et y peut suggérer une relation du type

$$y_i = \underbrace{f(x_i)}_{\text{partie déterministe}} + \underbrace{e_i}_{\text{partie aléatoire}} \quad \text{où}$$

- $f(x)$ est une **fonction déterministe** donnant l'allure générale du nuage de points, ou tendance.
- e_i est le **résidu** ou **bruit**, purement aléatoire. C'est la partie de y inexpliquée par x .






Relations linéaires

La forme la plus simple d'une relation entre x et y est donnée par la **relation linéaire** $f(x) = ax + b$:

$$y_i = \underbrace{ax_i + b}_{\text{valeur prédite } y_i^*} + \underbrace{e_i}_{\text{résidu}} = y_i^* + e_i$$

- les y_i sont les **valeurs observées**.
- les y_i^* sont les **valeurs prédites**.




La droite de régression

L'objectif de la **régression simple** consiste à trouver le **coefficients de régression**, qui sont :

- le **pente** de la droite a .
- l'**ordonnée à l'origine** de la droite b .

tel que les $y_i^* = ax_i + b$ soient les **meilleurs prédictions** des y_i .






Les moindres carrés

On va chercher a et b afin que les prédictions $y_i^* = ax_i + b$ donnent une **somme des carrés des résidus** minimale :

$$\text{SSE} = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - y_i^*)^2 = \sum_{i=1}^n (y_i - ax_i - b)^2$$

C'est le **critère des moindres carrés**.



Régression multiple

français	géographie	physique	chimie	histoire	maths	philosophie	allemand
7	6	5	6	2	7	9	2
5	5	3	7	4	4	6	6
5	7	8	9	5	6	5	9
5	4	5	3	5	5	5	6
6	5	3	7	2	6	4	4
7	8	4	5	5	7	8	6
4	5	3	5	1	5	4	3
5	5	6	6	4	7	5	4
3	6	3	3	2	4	5	2
7	6	5	7	4	7	6	4
5	7	5	7	5	8	10	4
8	7	7	9	7	10	8	7
9	8	4	8	7	7	9	7
5	7	4	6	8	6	5	8
4	8	10	10	10	10	6	5
3	4	6	5	1	5	4	3
3	7	4	4	4	7	5	3
4	4	7	6	3	4	5	7
9	5	5	8	10	7	6	7
6	3	3	3	3	8	6	2
4	6	5	5	7	4	5	6
7	4	4	4	1	8	8	2
6	7	4	6	5	7	5	6
4	6	6	7	6	7	7	5
6	7	7	6	5	9	8	7
8	5	6	6	5	8	5	9
5	8	4	6	4	8	9	5
5	4	5	6	5	4	7	4
4	3	6	6	7	5	8	3
5	2	4	6	3	5	9	4
5	6	7	7	5	8	7	5
3	2	2	3	1	6	4	3
7	5	7	7	10	7	5	8
5	9	6	8	4	8	5	8
3	2	3	4	3	6	5	3
6	7	4	7	6	5	7	8
6	5	3	4	4	4	8	1
5	8	5	6	7	7	4	7
5	10	8	9	7	10	8	9
6	7	7	7	4	9	7	8
5	7	3	3	7	4	7	2
3	5	2	2	2	4	4	3
7	5	5	3	2	6	8	1
3	6	5	5	3	7	5	5
8	6	7	7	4	9	4	7
4	6	4	7	2	9	6	1
4	6	3	5	3	6	5	5
8	6	6	7	6	8	7	7
6	10	4	8	8	9	7	7
8	8	7	8	8	7	8	8

Le cadre de la **régression multiple** est lorsque l'on a **plusieurs variables explicatives** x_j pour tenter d'expliquer la **variable dépendante** y .


Par exemple : en se basant sur ce tableau, si l'on possède toutes les notes d'un nouvel élève sauf celle de géographie, peut-on la prédire ?

Régression multiple : hyperplan

Le principe reste ici le même, on va essayer de prédire y_i avec :

$$y_i^* := b_0 + b_1x_{i1} + \dots + b_px_{ip}$$

Il s'agit de l'équation d'un **hyperplan** :



Régression multiple : solution

Encore une fois, on trouve les **coefficients de régression** $b_0, b_1, \dots, b_p$ qui minimisent la **somme des carrés des résidus** $\sum_{i=1}^n (y_i - y_i^*)^2$.

Par exemple, dans notre tableau de notes, prédire la note de géographie avec les autres notes nous donne les coefficients suivants :

	B
(Constante)	1,239
français	-,247
physique	-,283
chimie	,189
histoire	,169
mathématiques	,405
philosophie	,210
allemand	,286

Le score prédit en géographie de quelqu'un qui aurait 8 en français et en histoire, et 7 partout ailleurs serait de

$$y^* = 1.239 - 0.247 \cdot 8 - 0.283 \cdot 7 + 0.189 \cdot 7 + 0.169 \cdot 8 + 0.405 \cdot 7 + 0.21 \cdot 7 + 0.286 \cdot 7 = 6.26$$

On peut voir qu'avoir une bonne note en français et physique diminue le score prédit de géographie, alors qu'il augmente pour les autres branches.