

Exercices 12 : Clustering

Essayez de faire ces exercices de manière indépendante. Inscrivez vos réponses dans un fichier script R (avec l'extension ".r" ou ".R") en essayant de bien structurer (et dans l'idéal commenter) votre code.

1 Pré-traitements

- Chargez `tidyverse`, `readxl`, `FactoMineR`, `factoextra`, `aricode`, et `dendextend`.
- Chargez le fichier `"exercices_data/phonétique.xlsx"`.
- Construisez une nouvelle table contenant les locuteurs et les durées moyennes des voyelles "i" et "i:". Pour cela, faites les opérations suivantes :
 1. Filtrez par `Opposition=="i(:)"`.
 2. Groupez par `Locuteur` et `Voyelle`.
 3. Faites un `summarise()` en calculant la moyenne de la durée de la voyelle et le maximum de la région.
 4. Faites un `pivot_wider()` avec les nouveaux noms de colonnes tirés de `Voyelle`, et les valeurs tirées de `Durée`.
 5. Dégrouppez le jeu de données (`ungroup()`).
- A partir du tableau précédant, construisez une table numérique en ne gardant que les durées des voyelles, normalisez, et retransformez la résultat en tibble.
- Sauvegardez dans un vecteur `region` les regions de chaque locuteur.

2 Classification ascendante hiérarchique

- A partir du tableau de données numérique, construisez :
 1. La matrice des distances euclidiennes.
 2. Une classification ascendante hiérarchique avec méthode `"ward.D2"`.
 3. Le dendrogramme résultant de la classification.
- Affichez le dendrogramme, en coloriant les 5 branches principales de l'arbre.
- Sauvegardez, dans un vecteur `groups`, la partition des locuteurs en 5 groupes issue de cette CAH.

3 Comparaison

- Construisez la table de contingence `region × groups` et affichez la.
- Faites un test du chi2 sur cette table et calculez le NMI.
- Avec `FactoMiner`, faites une analyse en composantes principales sur le tableau des données numériques, tout en ajoutant comme variables qualitatives supplémentaires `region` et `groups`.
- Avec `fviz_pca_ind()`, affichez le résultat de l'ACP, avec comme `habillage` les deux variables qualitatives supplémentaires.