

Introduction aux bases de données

Guillaume Guex guillaume.guex@unil.ch

Les systèmes de gestion de base de données (SGBD)

Les données (tentative de définition)

Les **données** sont des éléments factuels, bruts, issus d'observations dans un contexte donné. Elles sont souvent constituées de **nombres** (données quantitatives) mais peuvent aussi contenir du textes, des images, ou d'autres formats.

Les données sont souvent opposées à l'**information**, qui peut se définir comme la connaissance extraite à partir de données.


Donnée : {type="cliente", nom="Maria", age=52, ville="Lausanne" }

Information : "Il existe une cliente nommée Maria, qui a 52 ans et qui habite Lausanne".

Les bases de données

Une **base de données (BD)**, au sens large, est un ensemble de données portant généralement sur un domaine ou un thème spécifique.

Aujourd'hui, les bases de données sont généralement stockées sur un **ordinateur** et peuvent être plus ou moins **structurées**.



Avant les années 1960, les bases de données étaient organisées selon un **système de fichiers** : chaque programme ou utilisateur stockait des fichiers de données selon sa propre logique. Cela soulevait beaucoup de problèmes :


- Redondance.
- Partage difficile.
- Incohérences fréquentes.
- Faible sécurité.
- Problèmes de concurrence.
- Dépendance à des scripts particuliers.

Il existe plusieurs **types de fichiers** qui sont spécialisés pour contenir des données. Actuellement, les principaux types de fichiers sont :

- Les **tableurs Excel** (.xlsx).
- Les **fichiers CSV** "Comma-separated values" (.csv).
- Les **fichiers XML** "Extensible Markup Language" (.xml).
- Les **fichiers JSON** "JavaScript Object Notation" (.json).

Les système de gestion de base de données

Durant les années 1960 et 1970, des logiciels particuliers font leur apparition : les **systèmes de gestion de base de données (SGBD)**. Ces derniers se placent **entre la base de données et les différents utilisateurs**.



Source : datascientest.com/sghd-tout-savoir

Les SGBD assurent plusieurs caractéristiques désirables :

- **Structure** et **cohérence** des données.
- **Gestion des accès** et de la **sécurité**.
- **Partage** aisé des données.
- Gestion de la **concurrency**.
- **Optimisation** du stockage et des opérations.

Les bases de données relationnelles

Durant les années 1960, les travaux du mathématicien et informaticien **Edgar Frank Codd** posent les bases théoriques de ce qui va devenir un système de gestion de base de données particulier : les **systèmes de gestion de base de données relationnelle (SGBDR)**.

Ce sont les systèmes de bases de données **dominants** (mais moins depuis quelques années).

Organisation en tables (relations)

Les données dans les bases relationnelles sont organisées dans plusieurs **tables** ou tableaux, nommés **relations** (d'où "relationnelle") :

ModelNumber	ProductName	ProductPrice	UnitCost
1111	Chair	\$129.99	\$65.00
1112	Desk	\$599.99	\$325.00
1113	Table	\$299.99	\$100.00
1114	File Cabinet	\$159.99	\$80.00

Source : [codecademy.com/resources/docs/general/database/relational-database](https://www.codecademy.com/resources/docs/general/database/relational-database)

Les lignes s'appellent les **engistements** ou **tuples**, les colonnes les **attributs**. Chaque tuple doit être **unique**.


Les attributs possèdent des **types de données** définis en amont :

Product		
123	ModelNumber	int(11)
A-Z	ProductName	varchar(100)
123	ProductPrice	float
123	UnitCost	float


Les types de données les plus fréquents sont les **nombres entiers**, les **nombre à virgules**, les **chaînes de caractères** et les **date**.

Relations entre les tables (relationships)

Les tables sont reliées entre elles par de **relations (relationships)** :




Source : [codecademy.com/resources/docs/general/database/relational-database](https://www.codecademy.com/resources/docs/general/database/relational-database)



Schéma

La structure complète de la base de données s'appelle son **schéma**, qui est construit en amont :



Les opérations sur la base de donnée se font via des **transactions**, qui respectent les contraintes suivantes :

- **A**tomicté : chaque transaction réussit ou échoue complètement.
- **C**ohérence : chaque transaction respecte la cohérence de la base de données.
- **I**solation : les transactions simultanées laisse la base dans le même état que si elles avaient été effectuées séquentiellement.
- **D**urabilité : l'état de la base de données est garanti après une transaction validée, même en cas de défaillance.

Les opérations sur la base de données se font via un langage appelé **Structured Query Language (SQL)** :

```
SELECT ProductName, ProductPrice FROM Product  
WHERE UnitCost > 1000  
ORDER BY ProductPrice;
```

Ce langage se base sur une **algèbre relationnelle**, qui permet de créer l'union, l'intersection, la différence et le produit cartésien de différentes tables.

Les SGBDR, de part leur robustesse, maturité et flexibilité, sont devenus le **standard** pour gérer les bases de données. Les principaux SGBDR sont :

- MySQL
- PostgreSQL
- Oracle Database
- SQL Server
- SQLite
- MariaDB

D'autres types de SGBD existent, on parle parfois de SGBD **NoSQL** (qui peut vouloir dire "Not only SQL"). Quelques exemples :

- Systèmes de documents
- Systèmes hiérarchiques.
- Systèmes en graphes.
- Systèmes clé-valeur.
- Systèmes mixtes.

Ces dernières années, de part l'**explosion dans la récolte des données**, les systèmes NoSQL prennent de l'importance.