

# Recherche de données

---

Guillaume Guex [guillaume.guex@unil.ch](mailto:guillaume.guex@unil.ch)

# Les formats de données

---

De nombreux **formats de données** existent sur internet. Les plus fréquents sont :

- Les fichiers CSV
- Les classeurs Excel
- Les fichiers JSON
- Les fichiers XML
- Les fichiers HTML

Nous allons voir dans ce cours comment se les procurer et comment les traiter afin de pouvoir les utiliser dans une base de données SQL.

# Les fichiers CSV

Les **fichiers CSV** (*Comma-Separated Values*) sont des fichiers texte portant l'extension **.csv**.

Les données sont structurées sous forme **tabulaire** : les colonnes sont séparées par des virgules et les lignes par un retour à la ligne (la première ligne contient parfois le nom des colonnes).

```
id,nom,population,superficie  
1,Suisse,9.0,41291  
2,Allemagne,84.7,357588  
3,France,68.3,672051
```

C'est le **format privilégié pour peupler une base de données**.  
Nous allons voir comment convertir les autres types de fichiers en CSV.

# Les fichiers CSV

Les fichiers CSV sont **légers** et **faciles à utiliser**, d'où leur popularité.

Par abus de langage, on appelle parfois tous les **fichiers DSV** (*Delimiter-Separated Values*), c'est-à-dire avec un séparateur défini (";", "|", tabulation), des fichiers CSV. Par exemple, dans le monde francophone, les données dans un fichier CSV sont généralement séparées par le point-virgule ";".

Parfois, certaines données peuvent être **entourées par des guillemets**, afin de pouvoir contenir un séparateur :

```
id,nom,adresse
1,Jean,"28, blvd de Fleurs"
2,Frida,"7, av. de la Colline"
3,Kim,"15, rue du Lac"
```

Les **classeurs Excel** sont des fichiers portant l'extension **.xlsx** ou **.xls**, contenant des données **tabulaires**.

Ils peuvent contenir de nombreuses feuilles, des formules, des graphiques et même du code écrit en langage Visual Basic.

**Convertir des fichiers Excel en CSV et très facile** : Excel permet directement la sauvegarde de ses classeurs en CSV.

**ATTENTION** : Excel a tendance à changer automatiquement le format des données selon la localisation. P.ex., les nombres à virgule anglais "34.4" sont automatiquement convertis en version francophone "34,4".

Les **fichiers JSON** (*JavaScript Object Notation*) sont des fichiers texte portant l'extension **.json**.

Initialement créé pour stocker des **objets JavaScript**, ils peuvent être maintenant pris en charge par de nombreux langages de programmation.

C'est le format de données privilégié pour **communiquer entre les différents services du Web** (p.ex. serveur-application).

La plupart des SGBDR permettent de **stocker des fichiers JSON dans des attributs**.

# Les fichiers JSON

La structure d'un JSON est composée des éléments suivants :

- Des ensemble de **clé-valeur** : {"nom": "Kim", "age": 34}.
- Des **Arrays**. ["a", "b", "c", "d"].

Ces différents éléments peuvent être **emboîtés**.

```
{
  "id": 1,
  "name": "Switzerland",
  "population": 8600000,
  "mainCities": [
    {
      "name": "Zurich",
      "population": 415000
    },
    {
      "name": "Geneva",
      "population": 200000
    }
  ],
  "languages": [
    "German",
    "French",
    "Italian",
    "Romansh"
  ]
}
```

# Les fichiers JSON

On peut transformer les fichiers JSON en fichiers CSV en les **applatissant** (à l'aide du script `flatten_json.py`).

```
[
  {
    "id": 1,
    "name": "Switzerland",
    "population": 8600000,
    "mainCities": [
      {
        "name": "Zurich",
        "population": 415000
      },
      {
        "name": "Geneva",
        "population": 200000
      }
    ],
    "languages": ["German", "French", "Italian", "Romansh"]
  },
  {
    "id": 2,
    "name": "France",
    "population": 67000000,
    "mainCities": [
      {
        "name": "Paris",
        "population": 2140000
      },
      {
        "name": "Marseille",
        "population": 861000
      }
    ],
    "languages": ["French", "Breton", "Catalan", "Occitan", "Provençal", "Picard", "Normand", "Flandrois", "Wallon", "Lorrain", "Champenois", "Alsacien", "Léonais", "Breton", "Catalan", "Occitan", "Provençal", "Picard", "Normand", "Flandrois", "Wallon", "Lorrain", "Champenois", "Alsacien", "Léonais"]
  }
]
```

| id | name        | population | mainCities_0_name | mainCities_0_population | mainCities_1_name | mainCities_1_population | languages_0 | languages_1 | languages_2 | languages_3 |
|----|-------------|------------|-------------------|-------------------------|-------------------|-------------------------|-------------|-------------|-------------|-------------|
| 1  | Switzerland | 8600000    | Zurich            | 415000                  | Geneva            | 200000                  | German      | French      | Italian     | Romansh     |
| 2  | France      | 67000000   | Paris             | 2140000                 | Marseille         | 861000                  | French      |             |             |             |
| 3  | Germany     | 83000000   | Berlin            | 3645000                 | Hamburg           | 1841000                 | German      |             |             |             |
| 4  | Italy       | 60000000   | Rome              | 2873000                 | Milan             | 1366000                 | Italian     |             |             |             |

# Les fichiers XML

Les **fichiers XML** sont des fichiers texte, avec l'extension **.xml**, qui contiennent de l'**eXtensible Markup Language**. C'est un langage de **balisage**, **extensible** (pas de balises prédéfinies), qui permet de stocker de nombreuses structures de données.

```
<?xml version="1.0" encoding="UTF-8" ?>
<Countries>
  <Country id="1" name="Switzerland" population="8600000">
    <mainCities>
      <City name="Zurich" population="415000" />
      <City name="Geneva" population="200000" />
    </mainCities>
    <languages>
      <language>German</language>
      <language>French</language>
      <language>Italian</language>
      <language>Romansh</language>
    </languages>
  </Country>
  <Country id="2" name="France" population="67000000">
    <mainCities>
      <City name="Paris" population="2148000" />
      <City name="Marseille" population="861000" />
    </mainCities>
    <languages>
      <language>French</language>
    </languages>
  </Country>
  <Country id="3" name="Germany" population="83000000">
    <mainCities>
      <City name="Berlin" population="3645000" />
      <City name="Hamburg" population="1841000" />
    </mainCities>
    <languages>

```

Traiter le XML nécessite des scripts spécialisés (pas vu ici).

# Les fichiers HTML

Toutes les pages Web sont constituée de Les **fichiers HTML**, c'est-à-dire des fichiers texte avec l'extension **.html**, qui contiennent de l'**HyperText Markup Language**.

```
<!DOCTYPE html>
<html lang="en">
<head>
  <meta charset="UTF-8">
  <meta name="viewport" content="width=device-width, initial-scale=1.0">
  <title>Basic HTML Page</title>
  <link rel="stylesheet" href="styles.css">
</head>
<body>
  <header>
    <h1>Welcome to My Website</h1>
  </header>
  <nav>
    <ul>
      <li><a href="#home">Home</a></li>
      <li><a href="#about">About</a></li>
      <li><a href="#contact">Contact</a></li>
    </ul>
  </nav>
  <main>
    <section id="home">
```

Il existe plusieurs outils pour extraire les données d'un document HTML, on nomme cela le **Web Scrapping** (pas vu ici).

## Sites de données

---

Il existe de nombreux **sites** donnant des données. Voici quelques exemples de sites généralistes :

- Kaggle : <https://www.kaggle.com/datasets>
- UCI Machine Learning Repository :  
<https://archive.ics.uci.edu/datasets>
- IEEEDataport : <https://ieee-dataport.org/datasets>
- Webz.io : <https://webz.io/free-datasets/>
- OpendataSoft :  
<https://data.opendatasoft.com/pages/home/>
- Yahoo Datasets : <https://webscope.sandbox.yahoo.com/>
- Recherche de données avec Google :  
<https://datasetsearch.research.google.com/>

Pour des donnée socio-économiques :

- US gov data : <https://data.gov/>
- OCDE data : <https://data-explorer.oecd.org/>
- OFS : <https://www.bfs.admin.ch/bfs/fr/home/statistiques.html>
- Opendata swiss : <https://opendata.swiss/fr>

Finalement, une page GitHub recensant de nombreuses autres sources :

- Awesome-public-datasets : <https://github.com/awesomedata/awesome-public-datasets>


# Les API REST

---

# Les API

Une **API (Application Programming Interface)** est un ensemble de règles et de protocoles qui permet à des logiciels de communiquer entre eux.

Dans le cadre du Web, une API est généralement un **point d'entrée à un serveur Web**, que plusieurs applications Web peuvent utiliser.




Source : <https://medium.com/@perrysetgo/what-exactly-is-an-api-69f36968a41f>

# Les API REST

Une **API REST (ou RESTful)** (REpresentational State Transfer) est une API qui respecte une certaine architecture. C'est le type d'API majoritaire sur le Web.

Le plus souvent, elle reçoit une **requête HTTP** et envoie une réponse contenant des données sous format **JSON** (mais pas que).

## WHAT IS A REST API?



mannhowie.com

# Les requêtes HTTP

Une **requête HTTP** est émise par un client à destination d'un serveur :



Source : <https://medium.com/@gwenilorac/http-requests-and-responses-cc989147fd8c>

Les éléments les plus importants sont la **méthode** (que faire) et le **chemin** (où faire). Les méthodes les plus utilisées sont :

- GET : obtenir des données.
- POST : créer des données.
- PUT : mettre à jour des données.
- DELETE : supprimer des données.

# Les réponses HTTP

Une requête donne une **réponse** de la part du serveur




Source : <https://medium.com/@gwenilorac/http-requests-and-responses-cc989147fd8c>

C'est dans le **corps de la réponse** qu'on trouve les données, qui peuvent être des fichiers HTML, JSON ou XML.

# API REST - database

Les API REST peuvent servir d'**accès direct à des bases de données** stockées à distance.



Source : <https://datasciencedojo.com/blog/understanding-rest-api/>

On peut s'en servir pour construire des applications Web sans se préoccuper de la gestion des données.

Pour une liste (non-exhaustive) des API que l'on peut trouver, voir : <https://github.com/public-apis/public-apis>.

# API REST démo

Rest Countries : <https://restcountries.com/>

API Parlement suisse : <https://ws-old.parlament.ch/>