

Peuplement d'une base de données

Guillaume Guex guillaume.guex@unil.ch

L'opération de **peuplement** d'une base de données est une opération complexe, qui n'existe pas forcément dans tous les cas (parfois, on entre les données en cours d'utilisation). Ce processus peut être divisé en trois grandes étapes :

- Chargement des données.
- Manipulations et peuplement des tables.
- Nettoyage.

Le **chargement des données** consiste à entrer nos données brutes dans des tables SQL. On va utiliser ici l'outil Import Data de DBeaver.

Durant cette étape, il faut faire attention à certaines choses :

- Les noms des variables.
- Les type des variables.
- Si elle n'existe pas, l'ajout d'une clé aux données brutes.

L'étape suivante consiste en la **manipulation des données** afin de **peupler les différentes tables**.

On procède une table après l'autre, **en commençant par les tables sans clés étrangères**. Une table qui possède des clés étrangères se peuplent toujours après les tables qu'elle référence.

Manipulations et peuplement des tables

Le **processus de peuplement** d'une table peut grandement varier en fonction de cette dernière et des données brutes. On peut néanmoins tenter de le résumer de la sorte :

1. Isoler les attributs pertinents des données brutes.
2. Manipuler les données. Cela peut consister en :
 - Création de tables temporaires.
 - Jointures.
 - Suppressions de lignes.
 - Modifications des données et des types.
 - Extractions de valeurs distinctes.
 - Appels à des procédures (e.g. `UNPIVOT()`).
3. Ajouter une clé à notre dernière table temporaire ou ajouter une auto-incrémentation à l'identifiant de la table à remplir.
4. Remplir la table.

Notez que les trois premières étapes sont parfois facultatives.

La dernière étape consiste à **nettoyer** la base de données, c'est-à-dire à supprimer les tables contenant les données brutes et les tables temporaires.

Pour finir, 2 conseils fondamentaux à garder en tête :

- **Documentez toutes les étapes dans un script de peuplement.** En cas d'erreur, vous pourrez rapidement effacer toutes la base de données relancer le processus.
- Si nécessaire, **mettez à jour le script du schéma.** Les étapes de peuplement doivent se baser sur un schéma adéquat.

Démo : peuplement de europe_countries