

# Vues et Statistiques

---

Guillaume Guex [guillaume.guex@unil.ch](mailto:guillaume.guex@unil.ch)


# Les vues et tables temporaires

---

# Les vues

Les **vues** sont des tables créées à partir d'autres tables avec un **SELECT**.

Une vue est persistante, mais les données qui y sont contenues ne sont pas recréées. En modifiant les tables ayant servi à construire la vue, on modifie cette dernière.




Source : <https://medium.com/javarevisited/views-in-sql-create-update-and-drop-8d5ec53daaa4>

# Les vues : un exemple

Avec la BD video\_games, en exécutant la commande :

```
CREATE VIEW game_extended AS
SELECT g.game_id, g.name,
       ge.name AS genre,
       MIN(gp.release_date) AS first_release,
       ROUND(AVG(critic_score / 10), 1) AS critic_score,
       SUM(critic_count) AS critic_count,
       ROUND(AVG(user_score), 1) AS user_score,
       SUM(user_count) AS user_count,
       MAX(rating) AS rating
FROM game g
JOIN game_platform gp ON g.game_id = gp.game_id
JOIN genre ge ON g.genre_id = ge.genre_id
GROUP BY g.game_id;
```

On trouve alors cette nouvelle vue sous :



Une vue ne peut pas être modifiée une fois créée, car cette dernière est associée à une requête. On peut cependant écraser une vue existante avec `ALTER VIEW`.

Pour **voir la requête** qui a servi à créer la vue, on utilise :

```
SHOW CREATE VIEW game_extended;
```

Finalement, pour **supprimer** une vue :

```
DROP VIEW game_extended;
```

# Les tables temporaires

Les **tables temporaires** sont, comme leur nom l'indique, des tables qui n'existent que lors de la session courante. Elles sont effacées une fois que l'on ferme la session. On les crée avec :

```
CREATE TEMPORARY TABLE nb_games_per_platform
SELECT p.name, COUNT(*) FROM game_platform gp
JOIN platform p ON gp.platform_id = p.platform_id
GROUP BY gp.platform_id;
```

Attention, ces dernières n'apparaissent pas dans la liste des tables de DBeaver, il faut lancer un **SELECT** pour la voir :

```
SELECT * FROM nb_games_per_platform;
```

# Les statistiques

---

MariaDB n'est pas un programme de statistiques, et ses possibilités sont limitées. Cependant, il est possible d'obtenir certains **indicateurs statistiques** (ou **statistiques** tout court).

Concernant ces statistiques, on peut faire la typologie suivante :

- Les statistiques uni-variées :
  - Sur une variable numérique.
  - Sur une variable catégorielle.
- Les statistiques bi-variées :
  - Sur 2 variables numérique-numérique.
  - Sur 2 variables numérique-catégorielle.
  - Sur 2 variables catégorielle-catégorielle.
- Les statistiques multi-variées.

# Statistiques uni-variées : variable numérique

Les deux **indicateurs uni-variés** les plus connus pour une **variable numérique** sont :

- La **moyenne** : indicateur de tendance centrale.
- La **variance** ou l'**écart-type** : indicateurs de dispersion.

On les obtiens avec :

```
SELECT AVG(critic_score),  
       VARIANCE(critic_score),  
       STD(critic_score)  
FROM game_extended;
```

|   | 123 AVG(critic_score) ▾ | 123 VARIANCE(critic_score) ▾ | 123 STD(critic_score) ▾ |
|---|-------------------------|------------------------------|-------------------------|
| 1 | 6.83624                 | 1.9625                       | 1.40089                 |

# Statistiques uni-variées : variable numérique

D'autres statistiques uni-variées très utilisées sur une variable numérique sont les **quantiles**. Ces derniers dépendent d'un pourcentage  $p$ , et départagent le jeu de données tel qu'il y a  $p$  pourcents d'observations en dessous de cette valeur.

Le plus connu des quantiles est certainement la **médiane**, qui est le quantile pour  $p = 50\%$ . La syntaxe est assez particulière pour l'obtenir :

```
SELECT PERCENTILE_CONT(0.5) WITHIN GROUP (ORDER BY critic_score) OVER () AS Mediane  
FROM game_extended;
```

|   |               |
|---|---------------|
|   | 123 Mediane ▼ |
| 1 | 7             |
| 2 | 7             |
| 3 | 7             |
| 4 | 7             |

De manière similaire, on peut aussi construire le premier et le troisième **quartiles** (le deuxième quartile est la médiane) :

```
SELECT  
PERCENTILE_CONT(0.25) WITHIN GROUP (ORDER BY critic_score) OVER () AS Q1  
PERCENTILE_CONT(0.75) WITHIN GROUP (ORDER BY critic_score) OVER () AS Q3  
FROM game_extended;
```

|   | 123 Q1 ▼ | 123 Q3 ▼ |
|---|----------|----------|
| 1 | 6        | 7.9      |
| 2 | 6        | 7.9      |
| 3 | 6        | 7.9      |
| 4 | 6        | 7.9      |
| 5 | 6        | 7.9      |

# Statistiques uni-variées : variable catégorielle

Lorsque l'on a une variable catégorielle, il n'y a pas beaucoup d'indicateurs disponibles. On peut observer sa **distribution** :

```
SELECT ge.name AS genre,  
       COUNT(*) AS freq,  
       COUNT(*) / (SELECT COUNT(*) FROM game) AS relative_freq  
FROM game g JOIN genre ge ON g.genre_id = ge.genre_id  
GROUP BY ge.genre_id;
```

|   | A-z genre ▼  | 123 freq ▼ | 123 relative_freq ▼ |
|---|--------------|------------|---------------------|
| 1 | Sports       | 1,379      | 0.1193              |
| 2 | Platform     | 588        | 0.0509              |
| 3 | Racing       | 772        | 0.0668              |
| 4 | Role-Playing | 1,227      | 0.1061              |
| 5 | Puzzle       | 498        | 0.0431              |
| 6 | Misc         | 1,330      | 0.115               |
| 7 | Shooter      | 825        | 0.0714              |

# Statistiques uni-variées : variable catégorielle

Deux indicateurs sur la distribution d'une variable catégorielle sont l'**entropie** et la **variété effective**. Ces derniers permettent de voir si la distribution est relativement uniforme ou non.

```
-- Vue préalable avec la distribution
SELECT ge.name AS genre,
       COUNT(*) AS freq,
       COUNT(*) / (SELECT COUNT(*) FROM game) AS relative_freq
FROM game g JOIN genre ge ON g.genre_id = ge.genre_id
GROUP BY ge.genre_id;

-- Entropie et variété effective
SELECT SUM(-LOG(relative_freq) * relative_freq) AS entropy,
       EXP(SUM(-LOG(relative_freq) * relative_freq)) AS var_eff
FROM genre_freq;
```

|   | 123 entropy ▼ | 123 var_eff ▼ |
|---|---------------|---------------|
| 1 | 2.3971044886  | 10.9913048121 |

Il existe de nombreux **indicateurs bi-variés**, couvrant toutes les possibilités de paires de variables. Ici, nous n'allons voir que la **corrélation**, qui permet de mesurer le lien entre deux variables numériques (prend des valeurs entre -1 et 1) :

```
SELECT (AVG(critic_score*user_score)-AVG(critic_score)*AVG(user_score)) /  
        (STD(critic_score)*STD(user_score)) AS correlation  
FROM game_platform  
WHERE critic_score IS NOT NULL  
AND user_score IS NOT NULL;
```

|   |                   |
|---|-------------------|
|   | 123 correlation ▼ |
| 1 | 0.5808778289      |