

Machine Learning :

Présentation du cours

Guillaume Guex guillaume.guex@unil.ch

- **Quand** : Les lundis, 10h15-12h00.
- **Où** : Anthropole 5183.
- **Moodle** : Clé = ml25
<https://moodle.unil.ch/course/view.php?id=34339>
- **Github** :
https://github.com/gguex/ISH_ressources_cours_ML
- **Enseignant** :
Guillaume Guex
guillaume.guex@unil.ch
ANT 3132

Le but de ce cours est d'avoir un aperçu des usages et pratiques dans le monde du **Machine Learning**. Il s'agira de :

- Comprendre **plusieurs méthodes et algorithmes de ML**.
- Savoir trouver et utiliser des **jeux de données**.
- Implémenter des méthodes dans des **notebooks** en **Python**.
- Acquérir les **principes généraux** du domaine.
- **Démystifier et comprendre** le fonctionnement (d'une partie) des méthodes d'intelligence artificielle.

Il y aura plusieurs **échéances** durant le semestre.

- **lundi 20 octobre** : Avoir trouvé et décrire au minimum 2 jeux de données sur lesquels travailler.
(non noté)
- **dimanche 16 novembre** : Premier rendu, applications et interprétations d'algorithmes « classiques » sur les données.
(1/2 de la note finale)
- **dimanche 11 janvier** : Deuxième rendu, applications et interprétations d'algorithmes « avancés » sur les données.
(1/2 de la note finale)

Calendrier (provisoire)

	Date	Contenu	Remarques
Semaine 1	15 septembre	Introduction au Machine Learning	
Semaine 2	22 septembre	CONGÉ	
Semaine 3	29 septembre	Modèles Linéaires I	
Semaine 4	6 octobre	Modèles Linéaires II	
Semaine 5	13 octobre	Support Vector Machine, Noyaux, kNN	
Semaine 6	20 octobre	Clustering	20 octobre : DONNÉES
Semaine 7	27 octobre	Réduction de la dimensionnalité	
Semaine 8	3 novembre	CONGÉ	
Semaine 9	10 novembre	Arbres de décision/régression et dérivés	16 novembre : RENDU 1
Semaine 10	17 novembre	Réseaux de neurones	
Semaine 11	24 novembre	Deep learning et réseaux à convolution	
Semaine 12	1 décembre	Analyses de données textuelles	
Semaine 13	8 décembre	Réseaux de neurones récurrents	
Semaine 14	15 décembre	Les transformeurs	11 janvier : RENDU 2

Consignes pour les données

Essayez de trouver des données au format **csv** ou **xlsx**. Il faut au minimum **2 jeux de données**. Vous devez **renvoyer un résumé de vos données**, qui doit contenir :

- Un nom pour chaque jeu de données.
- Une potentielle problématique (une question) pour chacun d'entre eux.
- Le nombre n (min 1000) d'individus et le nombre p (min 2 catégorielles et 5 numériques) de variables.
- Les noms et les descriptions de chaque variable (numérique, catégorielle, modalités, recodage).
- La ou les sources de vos données.

Dernier délai : le **20 octobre**, à guillaume.guex@unil.ch

Généraliste :

- Kaggle : <https://www.kaggle.com/datasets>
- UCI Machine Learning Repository : <https://archive.ics.uci.edu/datasets>
- IEEEDataport : <https://ieee-dataport.org/datasets>
- Webz.io : <https://webz.io/free-datasets/>
- OpendataSoft : <https://data.opendatasoft.com/pages/home/>
- Yahoo Datasets : <https://webscope.sandbox.yahoo.com/>
- Recherche de données avec Google :
<https://datasetsearch.research.google.com/>

Sources de données

Données socio-économiques :

- US gov data : <https://data.gov/>
- OFS : <https://www.bfs.admin.ch/bfs/fr/home/statistiques.html>
- Opendata swiss : <https://opendata.swiss/fr>

Images :

- Paperswithcode : <https://paperswithcode.com/datasets>
- ImageNet : <https://image-net.org/index.php>
- COCO Dataset : <https://cocodataset.org/>
- CIFAR-10 : <https://www.cs.toronto.edu/~kriz/cifar.html>

Données textuelles :

- Projet Gutenberg : <https://www.gutenberg.org/>
- Large Movie Review Dataset :
<https://ai.stanford.edu/~amaas/data/sentiment/>
- Movie Review Data
<http://www.cs.cornell.edu/people/pabo/movie-review-data/>
- WordNet : <https://wordnet.princeton.edu/>
- Liste de corpora : https://en.wikipedia.org/wiki/List_of_text_corpora

Dans ce cours, nous utiliserons des **notebooks**, écrit en **Python**. Il est possible de les faire tourner en **local** (sur votre machine personnelle) mais également d'utiliser des **serveurs** :

- Google Colab : <https://colab.research.google.com/>
- Paperspace Gradient : <https://www.paperspace.com/gradient>
- Kaggle : <https://www.kaggle.com/>
- Amazon SageMaker : <https://aws.amazon.com/fr/sagemaker/>

De nombreuses **ressources pédagogiques** peuvent être trouvées sur internet :

- Google AI blog : <https://ai.googleblog.com/>
- OpenAI news : <https://openai.com/news/>
- Machine Learning is Fun ! : <https://www.machinelearningisfun.com/>
- Jay Alammar blog : <https://jalammar.github.io/>
- Machine Learning @ BERKELEY : <https://ml.berkeley.edu/blog/>
- Machine Learning Mastery : <https://machinelearningmastery.com/blog/>
- Towards data science : <https://towardsdatascience.com/>
- NLP-progress : <http://nlpprogress.com/>
- Cours fast-ai : <https://course.fast.ai/>
- Cours Andrew Ng : <https://www.coursera.org/learn/machine-learning>

Mais pour aller plus loin, des livres sont souvent nécessaires :

Théoriques :

- Bishop, C. M. (2016). *Pattern Recognition and Machine Learning*. Springer New York.
- Bishop, C. M., & Bishop, H. (2023). *Deep learning : Foundations and concepts*. Springer Nature.
- Hastie, T., Tibshirani, R., & Friedman, J. H. (2009). *The elements of statistical learning : Data mining, inference, and prediction* (2nd ed). Springer.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. The MIT Press.
- Izenman, A. J. (2008). *Modern multivariate statistical techniques : Regression, classification, and manifold learning*. Springer.

Pratiques :

- Géron, A. (2019). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow : Concepts, tools, and techniques to build intelligent systems* (Second edition). O'Reilly Media, Inc.
- Stevens, E., Antiga, L., & Viehmann, T. (2020). *Deep learning with PyTorch*. Manning Publications Co.
- Howard, J., & Gugger, S. (2020). *Deep learning for coders with fastai and PyTorch : AI applications without a PhD* (First edition). O'Reilly.
- Chollet, F. (2020). *L'apprentissage profond avec Python*. machinelearning.fr.