

I: Introduction au Machine Learning

Guillaume Guex guillaume.guex@unil.ch

Le Machine Learning

Le **Machine Learning**, ou **Apprentissage Automatique** en français, est un domaine à mi-chemin entre la statistique et l'informatique.

Par rapport à la statistique, ce domaine met plus d'emphasis sur l'ordinateur pour approximer des fonctions complexes, et moins d'emphasis sur des démonstrations pour construire des intervalles de confiance ou des tests.

Pour [Mitchell, T. (1997). Machine Learning. McGraw Hill. p. 2] :

« A computer program is said to learn from **experience E** with respect to some class of **tasks T** and **performance measure P** if its **performance at tasks in T, as measured by P, improves with experience E.** »

« Dessine
une maison »



Données



Entrainement

« Dessine
une maison »



Exemples d'applications : génération d'images


DALL-E 3 : <https://openai.com/index/dall-e-3/>

Midjourney : <https://www.midjourney.com/>

Stable Diffusion : <https://www.diffus.me/>

Microsoft Copilot Designer :

<https://copilot.microsoft.com/images/create>



Exemples d'applications : génération de textes


ChatGPT : <https://openai.com/chatgpt/>

Microsoft Copilot : <https://copilot.microsoft.com/>

Github Copilot : <https://github.com/features/copilot>

Claude AI : <https://claude.ai/>

Perplexity : <https://www.perplexity.ai/>



Exemples d'applications : systèmes de recommandation



YouTube

NETFLIX



Attention ! Ce cours permet d'avoir des **clés de lecture** aidant à creuser plus loin, nous n'allons pas créer des modèles très avancés.

Entraîner de très grands modèles est parfois **inaccessible** au grand public, car ils nécessitent de **très nombreuses données** et une **grande puissance de calcul**.

Mais le ML reste utile à petite échelle !

Les algorithmes de ML sont **omniprésents** dans le monde actuel. Même si on ne compte pas les utiliser activement, **il est important de les comprendre** (un minimum).

Les données

Les données

La plupart des **données** utilisées dans les algorithmes de ML suivent le schéma classique **individus** × **variables**, avec un tableau de taille $(n \times p)$:

	year	month	day	dep_time	sched_dep_time	dep_delay	arr_time	sched_arr_time	arr_delay	carrier	flight	tailnum	origin	dest
1	2013	1	1	517	515	2	830	819	11	UA	1545	N14228	EWB	IAH
2	2013	1	1	533	529	4	850	830	20	UA	1714	N24211	LGA	IAH
3	2013	1	1	542	540	2	923	850	33	AA	1141	N619AA	JFK	MIA
4	2013	1	1	544	545	-1	1004	1022	-18	B6	725	N804JB	JFK	BQN
5	2013	1	1	554	600	-6	812	837	-25	DL	461	N668DN	LGA	ATL
6	2013	1	1	554	558	-4	740	728	12	UA	1696	N39463	EWB	ORD
7	2013	1	1	555	600	-5	913	854	19	B6	507	N516JB	EWB	FLL
8	2013	1	1	557	600	-3	709	723	-14	EV	5708	N829AS	LGA	IAD
9	2013	1	1	557	600	-3	838	846	-8	B6	79	N593JB	JFK	MCO
10	2013	1	1	558	600	-2	753	745	8	AA	301	N3ALAA	LGA	ORD
11	2013	1	1	558	600	-2	849	851	-2	B6	49	N793JB	JFK	PBI
12	2013	1	1	558	600	-2	853	856	-3	B6	71	N657JB	JFK	TPA
13	2013	1	1	558	600	-2	924	917	7	UA	194	N29129	JFK	LAX
14	2013	1	1	558	600	-2	923	937	-14	UA	1124	N53441	EWB	SFO
15	2013	1	1	559	600	-1	941	910	31	AA	707	N3DUAA	LGA	DFW
16	2013	1	1	559	559	0	702	706	-4	B6	1806	N708JB	JFK	BOS
17	2013	1	1	559	600	-1	854	902	-8	UA	1187	N76515	EWB	LAS
18	2013	1	1	600	600	0	851	858	-7	B6	371	N595JB	LGA	FLL

Source : <https://github.com/tidyverse/nycflights13>

Les données sont souvent sous **format CSV** (texte).


Encodage numérique

Toutes les méthodes de ML utilisent des **valeurs numériques**, il s'agit donc dans un premier temps de savoir comment **représenter nos données** sous cette forme :

Réponse	encodage one-hot →		
petit	0	1	0
moyen	1	0	0
grand			

« Mon chat aime jouer » id numériques →

mot1	mot2	mot3	mot4
1535	495	53	987





matrice d'entiers →

0	0	0	0	0	0	0	0
0	0	255	0	0	0	255	0
0	0	255	0	0	0	255	0
0	0	0	0	0	0	0	0
0	0	0	120	0	0	0	0
0	120	0	0	0	0	120	0
0	0	180	0	0	0	180	0
0	0	0	180	180	180	0	0
0	0	0	0	0	0	0	0

Un encodage numérique permet une représentation des n individus comme n points dans un espace à p dimensions :



Les Iris de Fisher



Les données

Une idée sous-jacente des méthodes de ML est de trouver des **patterns (motifs)** dans les données.

Les Iris de Fisher, les 3 espèces



Souvent, on cherche à **prédire une variable en fonction des autres.**

Les méthodes

Nous avons vu que les méthodes de ML vont s'améliorer dans leur **Tâche T**, en fonction de l'**expérience E (les données)**, selon une **mesure de performance P**. Les **tâches** peuvent être variées :

- Classification
- Traduction
- Représentation
- Création de résumés
- etc.

Il s'agit de définir une **mesure de performance P** dans la tâche, afin de **voir si la méthode s'améliore avec l'expérience E**.


Dans le cadre d'une classification, cela peut-être tout simplement le **pourcentage d'objets correctement classés** (p.ex. vs une annotation humaine), que l'on nomme **exactitude (accuracy)**.

Parfois, cette mesure P peut-être plus compliquée à construire, comme lors d'une traduction automatique.

Les **méthodes** de ML font partie de 2 groupes principaux :

- Les méthodes **supervisées** cherchent à prédire une (des) variable(s) existante(s) dans les données. On peut donc baser l'entraînement sur la **justesse des prédictions**.
- Les méthodes **non-supervisées** peuvent être prédictives (ou non), mais n'ont pas accès à la variable à prédire dans les données. Elles utilisent alors les **structures** présentes dans les données pour l'entraînement.

Méthodes supervisées et non-supervisées




Il existe également d'autres types de méthodes :

- Les méthodes **semi-supervisées** ont accès à la variable à prédire sur **certaines données seulement**. Elles sont à mi-chemin entre les méthodes supervisées et non-supervisées.
- Les méthodes d'**apprentissage par renforcement** sont particulières, dans le sens qu'il n'y a pas réellement de jeu de données et que l'entraînement se base sur **la réponse donnée par un environnement relativement à la sortie de la méthode** (p.ex. IA de jeux vidéo).

Lors d'un apprentissage supervisé, les méthodes se divisent encore en deux catégories :

- Lorsque la variable à prédire est **catégorielle**, on parle de **classification**
- Lorsque la variable à prédire est **numérique**, on parle de **régression**.

Classification vs Régression



Un des grands enjeux du Machine Learning est de pouvoir **généraliser** au delà du jeu de données utilisé pour l'entraînement.

Un problème récurrent est le **sur-apprentissage**, c'est-à-dire que la méthode a trouvé des « règles » pour sa tâche qui n'existent que par hasard dans le jeu d'entraînement (échantillon non-représentatif).

Plus la méthode est **complexe**, plus le risque de sur-apprentissage est **important**.

Les méthodes que nous allons voir

- Régression linéaire
- Régression logistique
- Support Vector Machine, Noyaux
- kNN : k plus-proches voisins
- k-Moyennes, Mixture Models
- PCA, t-SNE
- Arbres de Décision, Forêts Aléatoires
- Gradient Boosting
- Réseaux de Neurones
- Topic Modeling
- Word Embeddings