

V: Le clustering


Guillaume Guex guillaume.guex@unil.ch

Les méthodes de clustering

Le Clustering


Lorsque l'on a une tâche de **classification non-supervisée**, on parle en anglais de **clustering** (pas de mot français équivalent).

Pour rappel, il s'agit de prédire une **variable catégorielle sans utiliser les « vraies réponses »** sur les points à classer. On va donc utiliser la **structure** trouvée dans nos données.



Les méthodes

Il existe de **nombreuses méthodes** de clustering, qui fonctionnent plus ou moins bien selon la structure



Dans ce cours, nous allons voir trois méthodes :

- Les **k-moyennes (k-means)**
- Le **clustering hiérarchique agglomératif (HAC)**
- Le **modèle de mélanges gaussiens (GMM)**

Nous allons également voir comment **évaluer** ces méthodes.

Avant de parler du modèle de mélanges gaussiens, nous ferons une petite digression pour parler des **approches bayésiennes** en analyse de données.

Les k-moyennes

Les k-moyennes

Les **k-moyennes** est certainement la méthode la plus connue et la plus utilisée lorsqu'il s'agit d'effectuer un clustering.


Elle fonctionne bien lorsque les individus dans chaque groupe sont regroupés autour d'un **centre de masse**, appelé aussi **centroïde**. Elle utilise une **distance** entre les individus.

Elle possède un seul **hyperparamètre k** , qui correspond au nombre de groupes que nous souhaitons trouver.

C'est un **algorithme itératif**, qui contient à chaque itération **deux étapes**. Il fait partie des algorithmes de type **Expectation - Maximization (EM)**.

k-moyennes : initialisation


On commence par poser **aléatoirement** (vers le centre) un nombre de points k qui vont nous servir de **centroïdes initiaux**.



Ce tirage aléatoire peut être **amélioré** (e.g. k-means++).


k-moyennes : étape 1

Dans l'**étape 1**, on assigne chaque individu au groupe du **centroïde le plus proche**




k-moyennes : étape 2

Dans l'**étape 2**, on **calcule à nouveau les centroïdes** en fonction des points de chaque groupe



k-moyennes : convergence

En enchainant les étapes 1 et 2, l'algorithme finit par **converger**



Évaluation d'une méthode de clustering

Comment **évaluer** si le résultat d'un clustering est satisfaisant ? Il existe 2 types de mesures :

- Les mesures **intrinsèques**, qui ne nécessitent pas de données externes pour être évaluées.
- Les mesures **extrinsèques**, qui ont besoin des véritables labels pour être calculées.


De nombreuses mesures intrinsèques se basent sur l'**inertie intra-groupes**.

L'inertie intra et inter-groupes

L'**inertie totale** se décompose en **inertie intra et inter-groupes** :

$$\Delta = \frac{1}{2} \sum_{ij} d_{ij}^2 = \sum_g \rho_g d_{g0}^2 + \sum_g \rho_g \Delta_g = \Delta_B + \Delta_W$$


où ρ_g , d_{g0} et Δ_g sont respectivement le poids, la distance au centre et l'inertie du groupe g .




Minimisation de l'inertie intra-groupes

Un « bon » clustering devra donc généralement **minimiser l'inertie intra-groupes** :

Grande Δ_W :




Petite Δ_W :



Cette mesure a cependant des **limitations**, p.ex. si les vrais groupes ont des formes allongées ou irrégulières.

Trouver k

Trouver un nombre de groupes k idéal n'est pas facile, car l'inertie intra-groupe ne fait que baisser selon le nombre de groupes. Une des stratégies peut être d'utiliser le **critère du coude** :



Il existe de nombreuses autres mesures ou études intrinsèques :

- L'indice de **Calinski-Harabasz** (à maximiser)
- L'indice de **Davies-Bouldin** (à minimiser)
- L'étude par le coefficient de **Silhouette** (étude détaillée).

Pour plus d'information, voir, e.g.,

<https://scikit-learn.org/stable/modules/clustering.html#clustering-performance-evaluation>

Même si l'on dispose de **vrais labels**, évaluer notre résultat n'est pas si aisé car les **clusters trouvés sont anonymes**. Une matrice de confusion sera de la forme :

	Vrai 1	Vrai 2	Vrai 3	Vrai 4
Cluster 1	34	1512	23	14
Cluster 2	2593	31	53	64
Cluster 3	75	324	235	3425
Cluster 4	14	1835	1641	42

Trouver la « bonne » permutation des clusters peut-être très compliqué.

De plus, il est bien d'avoir un score lorsque le **nombre de clusters diffère du nombre de vraies classes**.

Il existe plusieurs **mesures extrinsèques** qui permettent d'y remédier :

- **Indice de Rand.**
- Mesures basées sur l'**homogénéité**.
- Mesures basées sur la **complétude**.
- Mesures basées sur l'**information mutuelle**.

Pour plus d'information, voir, e.g.,

<https://scikit-learn.org/stable/modules/clustering.html#clustering-performance-evaluation>

Le clustering hiérarchique agglomératif (HAC)

Il existe deux groupes de méthodes de **clustering hiérarchique** :

- les méthodes **divisives**, ou **descendantes**, partent d'une classe contenant tous les points, puis, à chaque étape, divisent les classes en plusieurs sous-classes.
- les méthodes **agglomératives**, ou **ascendantes**, partent de la situation où il y a un point par classe, puis, à chaque étape, cherchent à les agglomérer pour obtenir des classes de plus en plus grandes.

Dans les deux cas, il en résulte une structure hiérarchique, représentée par un **dendrogramme**.

Clustering hiérarchique agglomératif

Le clustering hiérarchique **agglomératif** ou **ascendant** (HAC) est le plus fréquemment utilisé.

Une **distance** d_{ij} entre les individus est nécessaire. L'algorithme est itératif et contient deux étapes :


1. On **agrège les deux individus (ou groupes) qui sont les plus proches** selon la distance.
2. On **recalcule les distances** selon une méthode.

Il existe plusieurs méthodes pour recalculer les distances :

- Le **saut minimal**.
- Le **saut maximal**.
- Le **saut moyen**.
- La méthode de **Ward**.

Dendrogramme

Le résultat d'une HAC est un **dendrogramme** que l'on peut **couper** où l'on veut pour obtenir un nombre k de groupes.



Intermède bayésien

Le bayésianisme

Le **bayésianisme** est une théorie de la connaissance qui consiste à utiliser les **probabilités** pour appréhender nos **croyances**.

La **probabilité d'une théorie T** , notée $\mathbb{P}(T)$, peut être interprété dans ce cadre comme la **degré de croyance** ou **plausibilité** de cette théorie.

En statistiques, on l'oppose au **fréquentisme**, qui considère qu'une probabilité reflètent uniquement la **fréquence d'un évènement** lorsque la situation est répétée à l'infini.

Les **approches bayésiennes** prennent de plus en plus d'importance dans le domaine de l'intelligence artificielle.

La formule de Bayes

Les approches bayésiennes mettent en relation les **théories** T et les **données** D à travers la **formule de Bayes**

$$\mathbb{P}(T|D) = \frac{\mathbb{P}(D|T)\mathbb{P}(T)}{\mathbb{P}(D|T)\mathbb{P}(T) + \sum_{\hat{T} \neq T} \mathbb{P}(D|\hat{T})\mathbb{P}(\hat{T})}$$

$\mathbb{P}(T|D)$ = Le degré de croyance en T sachant D (posterior)

$\mathbb{P}(D|T)$ = La probabilité d'observer D sachant T (vraisemblance)

$\mathbb{P}(T)$ = Le degré de croyance *à priori* en T (prior)

$\hat{T}$ = Les théories alternatives à T

Le dénominateur de la formule de Bayes est souvent **incalculable** (mais on peut en faire des approximations).

Exemple simple

Le bayésianisme a été critiquée pour son utilisation du **degré de croyance à priori** $\mathbb{P}(T)$. Pourtant, la formule de Bayes est un outil puissant pour **mettre à jour ses croyances**.

Une personne n'a jamais vu de corbeau et hésite entre 2 théories :

- T = « Tous les corbeaux sont noirs »
- $\bar{T}$ = « Un corbeau sur deux est noir »

N'ayant aucune donnée, elle pose au début $\mathbb{P}(T) = 1/2$, $\mathbb{P}(\bar{T}) = 1/2$.

Un jour, elle aperçoit un corbeau noir. elle va donc mettre ses croyances à jour avec :

$$\begin{aligned}\mathbb{P}(T|\text{un corbeau noir}) &= \frac{\mathbb{P}(\text{un corbeau noir}|T)P(T)}{\mathbb{P}(\text{un corbeau noir}|T)P(T) + \mathbb{P}(\text{un corbeau noir}|\bar{T})P(\bar{T})} = \\ &= \frac{1 \cdot 1/2}{1 \cdot 1/2 + 1/2 \cdot 1/2} \\ &= \frac{2}{3}\end{aligned}$$

La degré de croyance en T passe donc de 0.5 à 0.67 avec une observation, celui de $\bar{T}$ passe de 0.5 à 0.33.

Autre exemple (véridique)

Sally Clark fut condamnée par la justice britannique en 1999 pour les meurtres de ses 2 nourrissons. L'argument de l'accusation était :
« comme il n'y a que 1 chance sur 73M ($= 8500^2$) que 2 morts de nourrissons se produisent pour deux enfants particuliers, elle doit donc être coupable. »

Ce raisonnement est faux ! Une **raisonnement bayésien** aurait donné :

$$\begin{aligned}\mathbb{P}(2 \text{ meurtres} | 2 \text{ morts}) &= \frac{\mathbb{P}(2 \text{ morts} | 2 \text{ meurtres}) \mathbb{P}(2 \text{ meurtres})}{\mathbb{P}(2 \text{ morts} | 2 \text{ meurtres}) \mathbb{P}(2 \text{ meurtres}) + \mathbb{P}(2 \text{ morts} | 2 \text{ accidents}) \mathbb{P}(2 \text{ accidents})} \\ &= \frac{1 \cdot 1/500'000'000}{1 \cdot 1/500'000'000 + 1 \cdot 1/73'000'000} \\ &\simeq 12.7\%\end{aligned}$$

On doit mettre la chance de deux accidents ($1 / 73\text{M}$) en perspective par rapport à la chance de commettre deux meurtres de ce type ($1 / 500\text{M}$).

La **régression linéaire**, comme de nombreuses méthodes de ML, peut être traitée de manière bayésienne. L'idée est de considérer les paramètres $w_0, \dots, w_1$ comme des **variables aléatoires** avec initialement :


$$\mathbb{P}(w_i) \sim \mathcal{N}(0, \sigma^2)$$

où $\mathcal{N}(0, \sigma^2)$ est une loi normale centrée avec variance σ^2 . Puis de **mettre à jour la distribution des paramètres en fonction des données** :

$$\mathbb{P}(w_i|D) \sim \mathbb{P}(D|w_i)\mathbb{P}(w_i)$$

La mises à jour peut se faire de manière **séquentielle**.



Application à la régression



Le modèle de mélanges gaussiens (GMM)

Mélanges de distributions

Certaines distributions de points s'explique mieux avec un modèle de **mélange de entre plusieurs distributions** :




Source : C.M. Bishop (2006) *Pattern Recognition and Machine Learning*

Mélanges de gaussiennes

La loi d'une variable X suivant un **mélange de k gaussiennes** s'écrit :

$$\mathbb{P}(X = \mathbf{x}) = \sum_{h=1}^k \pi_h \mathcal{N}(\mathbf{x} | \mu_h, \Sigma_h)$$

où $\mathcal{N}(\mathbf{x} | \mu_h, \Sigma_h)$ est la probabilité du loi **Normale** (multinomiale) et π_h qui vérifie, $\pi_h \geq 0$, $\sum_h \pi_h = 1$, que l'on peut voir comme la probabilité de **choisir une des lois normales**.



Source : C.M. Bishop (2006) *Pattern Recognition and Machine Learning*

On peut voir aussi π_h comme la probabilité de k **variables latentes** binaire $Z_1, \dots, Z_k$ d'être positif, i.e. :

$$\mathbb{P}(Z_h = 1) = \pi_h$$

où la variables Z_h dénote l'appartenance de X à la distribution h .

Si l'on suppose que nos données suivent un mélange de gaussiennes, on peut être intéressé, pour un point donné $\mathbf{x}$, de calculer **la probabilité d'être dans le groupe h sachant $\mathbf{x}$** , i.e. :

$$\mathbb{P}(Z_h = 1 | X = \mathbf{x}) = \frac{\mathcal{N}(\mathbf{x} | \mu_h, \Sigma_h) \pi_h}{\sum_j \mathcal{N}(\mathbf{x} | \mu_j, \Sigma_j) \pi_j}$$

L'algorithme EM


Seulement, nous n'avons pas accès à π_h , μ_h et Σ_h . On utilise alors un algorithme de type **Expectation-Maximization (EM)** de la façon suivante :

- Initialisation : On pose π_h , μ_h et Σ_h aléatoirement.
- On itère avec :
 1. **Étape E** : On calcule $\mathbb{P}(Z_h = 1|X = \mathbf{x})$ pour tous les points $\mathbf{x}$ et les groupe h .
 2. **Étape M** : On réestime π_h , μ_h et Σ_h en fonction de $\mathbb{P}(Z_h = 1|X = \mathbf{x})$.

L'algorithme s'arrête dès qu'un critère de convergence est atteint.

Cet algorithme peut-être vu comme un **k-moyennes flou** (et non isotrope).

L'algorithme EM



Source : C.M. Bishop (2006) *Pattern Recognition and Machine Learning*