


VI: Réduction de la dimensionnalité

Guillaume Guex guillaume.guex@unil.ch

Les variétés

Données de haute dimensionnalité


En ML, on travaille souvent avec des données qui ont une **haute dimensionnalité**. Par exemple, les images tirées du jeu de données **MNIST** (<http://yann.lecun.com/exdb/mnist/>), de taille 28×28 ,




Source : Baldominos et al. (2019) *A Survey of Handwritten Character Recognition with MNIST and EMNIST*

peuvent être **encodées** avec des vecteurs dans un espace à $28 \cdot 28 = 784$ dimensions (niveau de gris sur chaque pixel).

Pourtant, l'**immense majorité** des images dans cet espace de dimension 784 n'ont aucune signification pour nous :



Très fréquent




Très rare

Les vecteurs de MNIST se situent donc dans une **région particulière** de cet espace.

Les variétés


Les données de MNIST se situent approximativement sur des **variétés** (**manifolds**) de dimensionnalité bien inférieure (en l'occurrence $d \simeq 10$) :



« Swiss roll »





Hélice toroïdale



Sphère perforée

Source : Clark et al. (2017) *Nonlinear manifold representation in natural systems : The SOMersault*

On peut donc les **représenter dans un espace de dimensionnalité inférieure**, en conservant les particularités des individus :



Source : Burgoyne et Mcadams (2007) *Non-linear scaling techniques for uncovering the perceptual dimensions of timbre*

Réduction de la dimensionnalité

Les objectifs de la **réduction de la dimensionnalité** peuvent être multiples :

- **Représenter les données en 2D ou 3D.**
- **Compresser l'information.**
- **Réduire le bruit.**
- **Extraire des caractéristiques (features) pertinentes.**

Nous allons voir trois différentes méthodes dans ce cours :


- **L'analyse en composantes principales (PCA).**
- **L'analyse discriminante linéaire de Fisher (LFDA).**
- **Le t-Stochastic Neighbor Embedding (t-SNE).**

L'analyse en composantes principales (PCA)

L'analyse en composantes principales

L'**analyse en composantes principales (PCA)** est une méthode **linéaire** de réduction de dimensionnalité issue de la statistique multivariée. Avec n individus et p variables, le but est de trouver p axes ordonnés, les **composantes principales**, qui doivent

- Être **orthogonaux**.
- **Représenter** l'information de manière décroissante.
- **Compresser** au mieux l'information sur les premiers axes.




Premier axe principal : projection

On peut chercher ces axes principaux de manière **itérative**. Soient $\mathbf{x}_1, \dots, \mathbf{x}_n$ les vecteurs de nos **individus centrés**, chercher une représentation dans le premier axe revient à chercher $y_1, \dots, y_n$, définis par

$$y_i := \mathbf{w}_1^\top \mathbf{x}_i$$

où $\mathbf{w}_1$ est un vecteur de **projection orthogonale**, i.e. qui vérifie $\mathbf{w}_1^\top \mathbf{w}_1 = 1$.




Premier axe principal : le problème


Le but de cette première projection est de **maximiser la variance** (et donc l'information) sur les $y_1, \dots, y_n$, i.e., résoudre

$$\begin{aligned} \operatorname{argmax}_{\mathbf{w}_1} \quad & \operatorname{var}(y_1, \dots, y_n) = \mathbf{w}_1^\top \mathbf{C} \mathbf{w}_1 \\ \text{s.c.} \quad & \mathbf{w}_1^\top \mathbf{w}_1 = 1 \end{aligned}$$

où $\mathbf{C} = \frac{1}{N} \sum_i \mathbf{x}_i \mathbf{x}_i^\top$ est la **matrice de covariance** des données.



Faible variance $\rightarrow$ mauvais axe



Forte variance $\rightarrow$ bon axe

Axe principaux : solution

En résolvant ce problème, on trouve alors que le vecteur $\mathbf{w}_1$ doit être le **premier vecteur propre de la matrice de covariance $\mathbf{C}$** .

On trouve aussi que

$$\text{var}(y_1, \dots, y_n) = \mathbf{w}_1^\top \mathbf{C} \mathbf{w}_1 = \lambda_1$$

Pour les autres axes, on opère par récursion et on trouve

$$\mathbf{w}_1 = \mathbf{v}_1, \quad \text{var}(\text{axe}_1) = \lambda_1$$

$$\mathbf{w}_2 = \mathbf{v}_2, \quad \text{var}(\text{axe}_2) = \lambda_2$$

$$\vdots \quad \quad \quad \vdots$$

$$\mathbf{w}_p = \mathbf{v}_p \quad \text{var}(\text{axe}_p) = \lambda_p$$


où $\mathbf{v}_\alpha$ et λ_α sont respectivement les α -ièmes **vecteur propre** et **valeur propre** de $\mathbf{C}$.

Réduction de dimensionnalité avec la PCA

La **réduction de la dimensionnalité** s'opère lorsque l'on retient uniquement les $\alpha < p$ premières coordonnées principales.

- La PCA donne une **projection orthogonale** des données.
- Le **maximum d'inertie** est conservé.
- Les axes principaux peuvent être **interprétés**.
- On peut l'utiliser avec des **fonctions de kernel**.

Sans kernel, elle ne marche pas très bien avec certaines variétés :





Source : Wang et al. (2020) *Locality adaptive preserving projections for linear dimensionality reduction*

L'analyse discriminante linéaire de Fisher (LFDA)

Représenter différentes classes

Parfois, les individus que l'on cherche à représenter possèdent des **classes**. La représentation trouvée par PCA n'est alors pas forcément idéale pour les représenter.




Peut-on trouver une représentation qui **discrimine** fortement les classes ?

Variance intra et inter-groupes

Pour une représentation $y_1, \dots, y_n$, la **variance totale** se décompose en **variance intra et inter-groupe** :

$$\text{Var}(y_1, \dots, y_n) = \text{Var}_B(y_1, \dots, y_n) + \text{Var}_W(y_1, \dots, y_n)$$



L'idéal serait donc de **minimiser la variance intra-groupe** et **maximiser la variance inter-groupe**, i.e. maximiser $\frac{\text{Var}_B(y_1, \dots, y_n)}{\text{Var}_W(y_1, \dots, y_n)}$

L'analyse discriminante linéaire de Fisher (LFDA)

C'est l'objectif de l'**analyse discriminante linéaire de Fisher (LFDA)**. Encore une fois, on trouve la solution avec un **problème de valeurs/vecteurs propres généralisé** :

$$\mathbf{C}_B \mathbf{w} = \lambda \mathbf{C}_W \mathbf{w}$$



où

$$\mathbf{C}_B = \sum_g n_g \mathbf{x}_g \mathbf{x}_g^\top \quad \mathbf{C}_W = \sum_g \sum_{i \in g} (\mathbf{x}_i - \mathbf{x}_g)(\mathbf{x}_i - \mathbf{x}_g)^\top$$

avec $\mathbf{x}_i$ les données centrées, $\mathbf{x}_g$ le centre du groupe g , et n_g le nombre d'individus dans g .

Les vecteurs propres associées aux valeurs propres les plus grandes auront la meilleure représentation.

L'analyse discriminante linéaire de Fisher (LFDA)



On peut aussi s'en servir pour faire de la **classification**.

Le t-Stochastic Neighbor Embedding (t-SNE)

Le t-Stochastic Neighbor Embedding (t-SNE)

Le **t-Stochastic Neighbor Embedding (t-SNE)** est une méthode de réduction de dimensionnalité développée par van der Maaten et Hinton en 2008. Elle est une amélioration du **SNE**.

- Contrairement à la PCA et LFDA, cette méthode est **non-linéaire**.
- Elle marche bien lorsque les individus sont sur **plusieurs variétés apparentées**.
- Elle est **stochastique** (solution non-déterministe).
- On doit **donner la dimensionnalité résultante** à la méthode.
- Elle possède plusieurs **hyperparamètres**, dont un particulièrement important : la **perplexité**.

Le t-SNE est populaire dans le monde du ML, et similaire à une autre méthode en vogue : **UMAP** (pas vu ici).

On a nos individus $\mathbf{x}_1, \dots, \mathbf{x}_n$ (vecteurs de taille p) et on recherche des vecteurs $\mathbf{y}_1, \dots, \mathbf{y}_n$ de taille $d < p$.

Le principe du **SNE** est de poser des **distributions de probabilité** sur les points de départ et d'arrivée :


$$p_{j|i} = \frac{\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|^2 / 2\sigma^2)}{\sum_{k \neq i} \exp(-\|\mathbf{x}_i - \mathbf{x}_k\|^2 / 2\sigma^2)} \quad q_{j|i} = \frac{\exp(-\|\mathbf{y}_i - \mathbf{y}_j\|^2)}{\sum_{k \neq i} \exp(-\|\mathbf{y}_i - \mathbf{y}_k\|^2)}$$

On peut voir ces distributions comme

$p_{j|i}$: « La probabilité que i choisisse j comme voisin. »

Le $\sigma > 0$ est un **hyperparamètre** qui détermine à quel point on doit « regarder loin ».

SNE : principes



Source : <https://towardsdatascience.com/t-sne-clearly-explained-d84c537f53a>

On veut que les distributions $p_{\cdot|i}$ et $q_{\cdot|i}$ soient similaires pour tous les i . On va donc **minimiser les sommes des divergences de Kullback-Leibler** :

$$C(\mathbf{y}_1, \dots, \mathbf{y}_n) = \sum_i \text{KL}(p_{\cdot|i} || q_{\cdot|i}) = \sum_i \sum_j p_{j|i} \log \left(\frac{p_{j|i}}{q_{j|i}} \right)$$

On peut résoudre cela grâce à une descente du gradient.

Notez que l'hyperparamètre σ n'est pas défini directement. On préfère poser la **perplexité** des distributions $p_{\cdot|i}$:

$$\text{Perp}(p_{\cdot|i}) = 2^{(-\sum_j p_{j|i} \log_2 p_{j|i})}$$

Elle détermine σ , mais est plus interprétable : on peut la voir comme « **le nombre effectif de voisins à considérer** ».

Le SNE a deux problèmes :

- C est **difficile à minimiser**.
- Les points sont fréquemment « **entassés** ».

Le **t-SNE** améliore l'algorithme en modifiant deux points :

- Les distributions sont **symétrisées** $p_{ij} = (p_{j|i} + p_{i|j})/2$.
- Dans l'espace d'arrivée, on utilise plutôt une **loi de Student** avec 1 degré de liberté :

$$q_{ij} = \frac{(1 + \|\mathbf{y}_i - \mathbf{y}_j\|^2)^{-1}}{\sum_{k \neq i} (1 + \|\mathbf{y}_i - \mathbf{y}_k\|^2)^{-1}}$$

Il est intéressant de voir que les composants du gradient pour le t-SNE s'écrivent :

$$\frac{\partial C}{\partial \mathbf{y}_i} = 4 \sum_j (p_{ij} - q_{ij})(\mathbf{y}_i - \mathbf{y}_j)$$

ce qui peut s'interpréter comme des **forces dues à un réseau de ressorts**.

Demos :

- t-SNE <https://distill.pub/2016/misread-tsne/>
- UMAP <https://pair-code.github.io/understanding-umap/>