

Méthodes Quantitatives I :

3. Données, variables, visualisations et indicateurs

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 17 - 30


Exercices : 2.1, 2.2, 2.3.1, 2.3.3, 2.5

Les données et les variables

Population et échantillon

En statistiques, si l'on étudie des objets de même nature, on considère deux ensembles distincts :


- La **population** représente l'entière des objets considérés. Celle-ci peut être finie ou infinie. Nous n'y avons pas accès.
- L'**échantillon** est une partie finie de la population dont on a accès. C'est lui qui constitue nos **données**.



Statistique descriptive et inférentielle

La statistique se divise en deux branches majeures :

- La **statistique descriptive** regroupe les méthodes qui servent à décrire, résumer et analyser l'échantillon.
- La **statistique inférentielle** tente d'induire les caractéristiques de la population à partir de l'échantillon.



La tableau des données

Généralement, l'échantillon est représenté par un **tableau de données** qui a la forme suivante :

	Variable 1	Variable 2	...	Variable $p - 1$	Variable p
Individu 1					
Individu 2					
$\vdots$					
Individu $n - 1$					
Individu n					

Par convention, on place :

- Les n objets étudiés, nommés **individus**, sur les lignes.
- Leurs p caractéristiques, nommées **variables**, sur les colonnes.

À l'intersection de la ligne i et de la colonne j , on trouve le **score** de l'individu i pour la variable j .

La tableau des données : exemples

Des tableaux génériques (si double indice : « ligne-colonne ») :

	x_1	x_2	x_3
$i = 1$	x_{11}	x_{12}	x_{13}
$i = 2$	x_{21}	x_{22}	x_{23}
$i = 3$	x_{31}	x_{32}	x_{33}
$i = 4$	x_{41}	x_{42}	x_{43}
$i = 5$	x_{51}	x_{52}	x_{53}

	x	y	z
$i = 1$	x_1	y_1	z_1
$i = 2$	x_1	y_1	z_1
$i = 3$	x_1	y_1	z_1
$i = 4$	x_1	y_1	z_1
$i = 5$	x_1	y_1	z_1

Participant·e·s à un cours de master :

	genre	âge	nationalité	commune	« J'apprécie les maths »	« Mes motivations »
1	F	24	suisse	Lausanne	énormément	...
2	F	31	iranienne	Ecublens	beaucoup	...
3	M	23	suisse	Sion	beaucoup	...
4	NB	32	suisse	Lutry	plutôt oui	...
5	M	45	russe	Lausanne	plutôt non	...
6	F	25	française	Echandens	pas du tout	...
7	F	24	suisse	Lausanne	plutôt oui	...
8	NB	26	suisse	Renens	pas du tout	...
9	M	23	congolais	Lausanne	énormément	...
10	F	29	belge	Renens	plutôt non	...

Les variables mesurant les caractéristiques des individus ne sont pas de même nature. Il existe deux types principaux de variables :

- Les variables **numériques** ou **quantitatives** : les scores possèdent un caractère numérique qui peut être manipulé arithmétiquement.

Exemples : âge, taille, revenu, surface, population.

- Les variable **catégorielles** ou **nominales** : les scores dénotent l'appartenance à une catégorie ou à un groupe, sans avoir de caractère numérique.

Exemples : nationalité, commune, état civil, « J'apprécie les maths ».

L'échelle des variables numériques

Deux observateurs distincts, recensant une **variable numérique** sur plusieurs individus, peuvent noter des scores différents : tout dépend de l'**échelle** utilisée.

La nature de la variable va définir le **type d'échelle** utilisée.

Choisir un type d'échelle définit les **transformations admissibles** que l'on peut effectuer sur la variable sans changer l'information recensée.

L'échelle de quotient

Lorsque la variable possède un **référentiel absolu** et une **unité est relative**, on parle d'une **échelle de quotient**.

Les transformations de type **dilatation** : $\mathbf{v}' = a\mathbf{v}$ sont admissibles.

Le **rapport** de deux scores suivant une échelle du quotient ne dépend pas de l'unité choisie.

Exemples : l'âge, le poids, la taille, la distance entre deux points.




L'échelle relative

Lorsque la variable possède un **référentiel relatif** et une **unité absolue**, on parle d'une **échelle relative**.

Les transformations de type **translation** : $\mathbf{v}' = \mathbf{v} + b$ sont admissibles.

Exemples : l'année solaire, i.e. le nombre de rotations autour du soleil.




L'échelle d'intervalle

Lorsque la variable possède un **référentiel relatif** et une **unité relative**, on parle d'une **échelle d'intervalle**.

Les transformations de type **linéaire (affine)** : $\mathbf{v}' = a\mathbf{v} + b$ sont admissibles.

Exemples : la température ordinaire, le temps, la position, l'*utilité* en économie.



Finalement, lorsque la variable possède un **référentiel absolu et une unité absolue**, on parle d'une **échelle absolue**.

Aucune transformation n'est autorisée.

Exemples : ces échelles s'utilisent fréquemment pour les **effectifs**, c'est-à-dire des décomptes d'éléments (e.g. la population d'un pays).

Au-delà des transformations de type $\mathbf{v}' = a\mathbf{v} + b$, on peut considérer des échelles qui sont des **transformations non-linéaires** d'autres échelles. Quelques exemples :

- L'**échelle de Beaufort** (1805) quantifie la vitesse du vent sur 13 degrés, avec $\mathbf{v}' \simeq \sqrt[3]{\mathbf{v}^2/9}$.
- L'**échelle de Richter** (1935) utilise le logarithme (en base 10) de l'amplitude (maximale) de l'onde d'un séisme.
- Le **décibel** (1923) est une mesure logarithmique (en base 10) du rapport de deux puissances acoustiques ou électromagnétiques (multipliée par 10).

Les variables catégorielles

Le score d'une **variable catégorielle** n'est pas numérique, mais prend une valeur parmi un nombre fini de **modalités** (e.g. « grand », « petit », « moyen »).

Une variable catégorielle définit une **partition** de l'ensemble des individus : chaque individu possède au moins une modalité (exhaustivité) et une seule (exclusivité).

À l'instar des partitions, une variable catégorielle peut être **plus fine ou plus grossière** qu'une autre.

Exemple : la variable « commune de domicile » est plus fine que « canton de domicile ».

Les variables bimodales

Une variable catégorielle avec uniquement deux modalités s'appelle une **variable bimodale ou binaire**.

Cette variable sert généralement à séparer les individus entre **ceux qui possèdent une caractéristique et ceux qui ne l'ont pas**.

Les scores d'une variable bimodale peuvent être encodés grâce à la **fonction indicatrice** :

$$z_i = I(i \in A) = \begin{cases} 1 & \text{si } i \in A \\ 0 & \text{sinon} \end{cases}$$

Exemple : la variable « test positif » sur un échantillon de patients testés peut prendre les modalités « oui » ou « non ».

Une variable catégorielle est une **variable ordinale** si ses modalités possèdent une **relation d'ordre** entre elles : on peut classer ses modalités par ordre croissant ou décroissant.

Elles sont traitées de manière différente que les variables catégorielles sans ordre.

Exemples :

- **Fréquence d'utilisation** : *toujours* > *souvent* > *rarement* > *jamais*.
- **Classe socio-économique** : *classe aisée* > *classe moyenne* > *classe populaire*

Les variables ouvertes

Les **variables ouvertes** désignent des caractéristiques qui n'ont pas encore été catégorisées ni quantifiées.

Les **questions ouvertes** d'un questionnaire sont des exemples courants de variables ouvertes.

L'analyse statistique des variables ouvertes nécessite des stratégies particulières, par exemple :

- Faire un « **post-codage** » : plusieurs variables catégorielles sont créées pour encoder le texte de la réponse.
- Utiliser des méthodes de **traitement du langage naturel (NLP)** : la statistique textuelle et des méthodes d'IA permettent de transformer un texte donné en variables.

Variables catégorielles : encodage numérique

Si nécessaire, il est possible d'effectuer un **encodage numérique des variables catégorielles**.

- Les **variables bimodales** peuvent être encodées grâce à la fonction indicatrice :

Test positif	encodage	Variable encodée
oui	→	1
non		0

- Les **variables ordinales** peuvent être encodées grâce à des nombres entiers :

« J'apprécie les maths »	encodage	Variable encodée
pas du tout	→	0
plutôt non		1
plutôt oui		2
énormément		3

Variables catégorielles : encodage numérique (suite)

Pour les **variables catégorielles (non-ordinales)** avec m **modalités**, on va d'abord les transformer en m variables bimodales puis en scores binaires.

Couleur		est_rouge	est_vert	est_bleu		est_rouge	est_vert	est_bleu
rouge	bimodales →	oui	non	non	encodage →	1	0	0
vert		non	oui	non		0	1	0
bleu		non	non	oui		0	0	1

Cette manière de procéder crée une colonne de trop en terme de redondance de l'information. Dans certaines méthodes statistiques, on doit supprimer l'une d'elles.

Variables : résumé

Variable	Scores possibles	Recodage numérique	Exemples
Numérique	nombre	déjà numérique	âge, taille, revenu
Ordinale	m modalités ordonnées	m nombres entiers	accord, classe sociale
Bimodale	2 modalités	1 ou 0	a la caractéristique, résultat d'un test binaire
Catégorielle	m modalités non-ordonnées	m variables binaires	commune, espèce, marque
Ouverte	texte	difficile	question ouverte, remarque

Les visualisations et indicateurs uni-variés

Il est difficile d'appréhender les **caractéristiques d'un échantillon** de n individus et p variables d'un seul coup d'oeil. On aimerait par exemple savoir :

- Quelle est l'allure générale de la distribution des valeurs ?
- Y a-t-il des relations entre des variables ?
- Peut-on résumer une variable en quelques nombres ?

La **statistique descriptive** nous donne deux outils pour y arriver :

- Les **visualisations**.
- Les **indicateurs**.

Les visualisations et les indicateurs que l'on peut utiliser vont dépendre :

- Du **nombre de variables** et
- Du **type des variables**

que l'on souhaite observer.

Les visualisations et indicateurs sur une seule variable sont appelés **uni-variés**, et ceux sur plusieurs variables **bi-, tri-, ou multi-variés**.

L'histogramme

L'**histogramme** est une visualisation **uni-variée d'une variable numérique** qui se construit de la manière suivante.

Soit n scores $\{x_1, \dots, x_n\}$. On **partitionne** ces scores dans m intervalles de la forme $]a_j, a_{j+1}]$ et on compte l'**effectif** de chaque intervalle avec :


$$n_j = \sum_{i=1}^n I(a_j < x_i < a_{j+1})$$

L'histogramme consiste en **une série de rectangles, dont les bases sont les intervalles et la hauteur leur effectif**.

Il arrive parfois qu'on utilise une hauteur relative $h_j = n_j/n$, représentant alors la **proportion d'observations** dans l'intervalle.


L'histogramme : exemple

Un questionnaire électronique portant sur la Chamberonne a été envoyé en décembre 2016 aux $\sim 15'000$ membres de l'UNIL. Parmi les répondant.e.s, $n = 1365$ ont indiqué leur âge, que l'on peut observer avec l'histogramme suivant (intervalles sur les demi-entiers, de la forme $]20.5, 21.5]$) :



L'histogramme : largeur des intervalles

Choisir une **largeur des intervalles** adéquate est important pour avoir une bonne visualisation de la distribution.



Source : <https://www.atlassian.com/data/charts/histogram-complete-guide>

La fonction de répartition

La **fonction de répartition** ou **fonction de distribution cumulée** est également une **visualisation uni-variée d'une variable numérique**.

Définition

Soit les n scores $\{x_1, \dots, x_n\}$. La **fonction de répartition empirique** **$F(y)$** est la proportion de scores de l'échantillon inférieurs ou égaux à y :

$$F(y) := \frac{\text{nombre de scores inférieurs ou égaux à } y}{\text{nombre total de scores}} = \frac{|\{x_i | x_i \leq y\}|}{n}$$


Pour la construire on procède de la manière suivante :

- On ordonne nos scores $\{x_1, \dots, x_n\}$ de manière croissante.
- On trace un escalier qui commence à 0 vers $-\infty$, qui termine 1 vers ∞ et qui monte de $\frac{1}{n}$ à chaque x_i (où de $\frac{n_i}{n}$ si il y a n_i scores égaux).

La fonction de répartition : exemple

Soient les scores ordonnés suivants

1.0	1.3	1.4	1.7	1.7	2.2	2.3	2.7	3.0	3.2
3.9	4.3	4.6	4.7	5.9	6.5	7.4	7.7	8.4	8.5



La fonction de répartition est liée à une gamme d'indicateurs uni-variés nommés les **quantiles**

Définition

Soit les n scores $\{x_1, \dots, x_n\}$. Le quantile **quantile d'ordre α** ($0 < \alpha < 1$), noté x_α , est la (une des)* valeur telle qu'il y a une proportion α de scores inférieurs ou égaux à cette dernière. On a donc :


$$F(x_\alpha) = \alpha$$

Le quantile le plus connu est certainement la **médiane**, $x_{0.5}$: c'est la valeur pour laquelle 50% des scores de l'échantillon sont inférieurs (et donc 50% sont supérieurs).

* En réalité, il peut avoir plusieurs valeurs qui correspondent à ce critère. Nous verrons comment gérer ce cas.

Les quantiles : fonction de répartition

Comme $F(x_\alpha) = \alpha$, on pourrait poser $x_\alpha = F^{-1}(\alpha)$. Seulement certaines valeurs de α donnent plusieurs possibilités pour x_α . On prend alors la **valeur à mi-chemin** entre les deux scores de l'échantillon.



Pour les mêmes scores ordonnés :

1.0	1.3	1.4	1.7	1.7	2.2	2.3	2.7	3.0	3.2
3.9	4.3	4.6	4.7	5.9	6.5	7.4	7.7	8.4	8.5



- $x_{0.1} = 1.35$
- $x_{0.2} = 1.7$
- $x_{0.25} = 1.95$
- $x_{0.5} = 3.55$
- $x_{0.9} = 8.05$

Certains quantiles particuliers portent des **noms** :

- La **médiane** divise les scores en 2 partie égales.
- Les **quartiles** divisent les scores en tranches de 25%.
- Les **quintiles** divisent les scores en tranches de 20%.
- Les **déciles** divisent les scores en tranches de 10%.
- Les **centiles** divisent les scores en tranches de 1%.

Fonction de répartition et quantiles : exemple


Le nombre d'enfants vivant dans $n=12$ ménages est $\{0, 0, 0, 0, 0, 1, 1, 1, 2, 3, 3, 5\}$. On a alors :



La médiane vaut $x_{0.5} = 1$, le troisième quartile $x_{0.75} = 2.5$, et le 95^{ème} centile $x_{0.95} = 5$.

Fonction de répartition : effectifs dans des intervalles

On a parfois pas accès à l'échantillon initial, mais uniquement aux **effectifs dans des intervalles** (e.g. histogramme). Dans ce cas, la fonction de répartition monte linéairement entre chaque borne des intervalles :



Les quantiles s'obtiennent alors de manière univoque avec $x_\alpha = F^{-1}(\alpha)$.

Le **boxplot** ou **boîte à moustache** est une autre visualisation **uni-variée d'une variable numérique**. Il y a plusieurs éléments affichés :

- Le trait à l'intérieur de la boîte indique la **médiane** $x_{0.5}$.
- Les limites de la boîte indiquent le **premier quartile** $x_{0.25}$ et le **troisième quartile** $x_{0.75}$.
- La région couverte par les « moustaches » délimite **l'étendue des scores typiques**. Cette définition varie d'un logiciel à l'autre :
 - Cela peut être $x_{0.25} - 1.5(x_{0.75} - x_{0.25})$ et $x_{0.75} + 1.5(x_{0.75} - x_{0.25})$ sans dépasser le score minimal ou maximal.
 - Cela peut être l'intervalle $[x_{0.05}, x_{0.95}]$ ou $[x_{0.01}, x_{0.99}]$.
- Les scores hors des « moustaches » sont annotés, ce sont les **scores extrêmes**.

Le boxplot : exemples

A gauche : notes aux 4 épreuves de méthodes quantitatives

A droite : âges des répondants selon leur statut

