

Méthodes Quantitatives I :

4. Visualisations et indicateurs (suite)

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 30 - 38

Exercices : toute la série 2 + 3.1

Indicateurs uni-variés

Les indicateurs de tendance centrale

Soit l'échantillon de la variable « Temps hebdomadaire (hors cours) en heures consacré aux études » :

1.4	1.7	3.0	1.0	3.2	7.7	7.4	5.9	8.4	4.6
2.2	4.7	8.5	3.9	2.7	6.5	1.7	1.3	4.3	2.3

Comment pourrait-on résumer cette variable en **une seule valeur représentative** ?

C'est le but d'un **indicateur de tendance centrale**. Plusieurs choix sont possibles.

Définitions

Soit un échantillon de scores numériques $\{x_1, \dots, x_n\}$.

La **moyenne empirique**, notée $\bar{x}$, est définie par

$$\bar{x} := \frac{1}{n} \sum_{i=1}^n x_i$$

La **médiane**, notée $x_{0.5}$, représente la valeur telle qu'il y a 50% des scores en dessous et 50% de scores en dessus.

Dans le cas de données en classe (histogramme), le(s) **mode(s)** représente le milieu de la (des) classe(s) avec le plus grand effectif.

Dans notre exemple, on a $\bar{x} = 4.12$ et $x_{0.5} = 3.55$.



Bien que la moyenne soit très souvent utilisée comme indicateur de tendance centrale (meilleures propriétés mathématiques et plus facilement calculable), dans certains cas, l'utilisation de la médiane est plus judicieuse.

En effet, la médiane est **plus robuste**, c'est-à-dire qu'elle est **moins sensible aux valeurs extrêmes**.

Le mode n'est que très rarement utilisé.

Moyenne vs médiane


Exemple : Revenu net (CHF / mois) dans le canton de Vaud en 2017, $\bar{x} = 6133$ (en rouge) et $x_{0.5} = 4930$ (en vert).



Indicateurs de dispersion

S'il fallait un **deuxième nombre** pour résumer un échantillon de scores numériques $\{x_1, \dots, x_n\}$, on va généralement s'intéresser à un **indicateur de dispersion**.

Ce dernier devrait être **élevé si les valeurs sont dispersées** (autour de l'indicateur des tendances centrales)



Définition

Soit un échantillon $\{x_1, x_2, \dots, x_n\}$. La **variance empirique** de cet échantillon, notée **var(x)**, est :

$$\text{var}(x) := \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2$$

Si la barre « $\bar{}$ » dénote la moyenne d'une variable, on peut réécrire les formules suivantes comme :


$$\text{var}(x) := \overline{(x - \bar{x})^2} = \overline{x^2} - \bar{x}^2$$

La variance : exemple

1.4	1.7	3.0	1.0	3.2	7.7	7.4	5.9	8.4	4.6
2.2	4.7	8.5	3.9	2.7	6.5	1.7	1.3	4.3	2.3

$$\bar{x} = 4.12 \quad \overline{x^2} = 22.898$$

$$\text{var}(x) = \overline{x^2} - \bar{x}^2 = 22.898 - 16.9744 = 5.9236$$



Définition

Soit un échantillon numérique $\{x_1, x_2, \dots, x_n\}$. L'**écart-type** de cet échantillon, noté s_x , est :

$$s_x = \sqrt{\text{var}(x)}$$

En référence à la notation de l'écart-type, on note parfois la variance avec s_x^2 .

Contrairement à la variance, **l'écart-type s'écrit dans la même unité de mesure que la variable.**

Exemple (suite) : $s_x = \sqrt{5.9236} \approx 2.4338$ heures.

Définition

Soit un échantillon numérique $\{x_1, x_2, \dots, x_n\}$. L'**estimateur non-biaisé de la variance**, notée $\hat{s}_x^2$, se calcule avec :

$$\hat{s}_x^2 = \frac{n}{n-1} s_x^2$$

Cette variance non-biaisée diffère de la première seulement si l'échantillon est petit.

Exemple (suite) : $\hat{s}_x^2 = 6.2354$ et $s_x^2 = 5.9236$.

Définition

Soit un échantillon $\{x_1, x_2, \dots, x_n\}$. L'**écart interquartile**, noté **El(x)**, est :

$$El(x) = x_{0.75} - x_{0.25}$$

Comme la médiane par rapport à la moyenne, cette mesure est **plus robuste** que la variance.

On utilise aussi parfois l'**empan** ou **étendue** des valeurs, qui est égal à $x_{\max} - x_{\min}$.

Exemple (suite) : $x_{0.75} = 6.2$, $x_{0.25} = 1.95$, $El(x) = 4.25$.

Pondération et standardisation

Pondération : les poids relatifs

Lorsque que plusieurs individus ont des valeurs similaires, par exemple :

1	5	2	3	5	2	3	2	6	1
4	5	4	3	2	2	5	3	4	1

Il est possible de **regrouper les valeurs identiques** pour faire la moyenne, i.e.

$$\bar{x} = \frac{1}{20}(3 \cdot 1 + 5 \cdot 2 + 4 \cdot 3 + 3 \cdot 4 + 4 \cdot 5 + 1 \cdot 6) = 3.15$$

et en distribuant $\frac{1}{20}$:

$$\bar{x} = 0.15 \cdot 1 + 0.25 \cdot 2 + 0.20 \cdot 3 + 0.15 \cdot 4 + 0.20 \cdot 5 + 0.05 \cdot 6 = 3.15$$

Pondération : les poids relatifs

Ce tableau de données pourrait aussi s'écrire comme :

x	effectif	poids relatif
1	3	0.15
2	5	0.25
3	4	0.20
4	3	0.15
5	4	0.20
6	1	0.05

Les **poids relatifs** des observations sont l'effectif de chaque groupe divisé par le nombre total.

Définition

Soit un échantillon $\{x_1, x_2, \dots, x_n\}$. Si ces scores possèdent des **poids relatifs** $\{f_1, f_2, \dots, f_n\}$ qui vérifient :

$$\sum_{i=1}^n f_i = 1$$
$$f_i \geq 0$$

ces scores sont dit **pondérés**. Les objets sur lesquels sont mesurés ces scores peuvent être considérés comme des **agrégats**.

Jusqu'à maintenant, on travaillait avec des **scores non-pondérés**, ce qui revient à poser des **poids uniformes, i.e.,** $f_i = \frac{1}{n}$.

Définition

Soit un échantillon $\{x_1, x_2, \dots, x_n\}$ avec poids relatifs $\{f_1, f_2, \dots, f_n\}$. Alors :

La **moyenne pondérée**, notée $\bar{x}$, est :

$$\bar{x} = \sum_{i=1}^n f_i x_i$$

La **variance pondérée**, notée $\text{var}(x)$, est :

$$\text{var}(x) := \sum_{i=1}^n f_i (x_i - \bar{x})^2 = \left(\sum_{i=1}^n f_i x_i^2 \right) - \left(\sum_{i=1}^n f_i x_i \right)^2$$

Soit un groupe de 60 personnes, 40 femmes et 20 hommes. La taille moyenne des femmes vaut $\bar{x}_f = 168\text{cm}$, et celle des hommes vaut $\bar{x}_h = 175\text{cm}$.


Si l'on désire la taille moyenne de la totalité du groupe, on peut considérer notre échantillon comme deux agrégats avec scores $\{168, 175\}$ et poids relatifs $\{\frac{40}{60}, \frac{20}{60}\}$. On a alors :

$$\bar{x} = \frac{40}{60} \cdot 168 + \frac{20}{60} \cdot 175 = 170.33$$

La standardisation : un échantillon

Reprenons notre exemple :

1.4	1.7	3.0	1.0	3.2	7.7	7.4	5.9	8.4	4.6
2.2	4.7	8.5	3.9	2.7	6.5	1.7	1.3	4.3	2.3



Dans certains cas, p.ex. lors de comparaisons avec d'autres variables, il peut être intéressant de ne considérer que les **intervalles relatifs** entre les différentes mesures. La moyenne et la variance peuvent alors être « soustraites » du jeu de données.

Définition


Soit un échantillon $\{x_1, x_2, \dots, x_n\}$ de moyenne $\bar{x}$ et de variance s_x^2 .

- **Centrer** l'échantillon, revient à soustraire aux scores la moyenne : $x_i^c = x_i - \bar{x}$.
- **Réduire** l'échantillon, revient à diviser les scores par l'écart-type : $x_i^r = \frac{x_i}{s_x}$.
- **Standardiser l'échantillon**, revient à le centrer puis le réduire : $x_i^s = \frac{x_i - \bar{x}}{s_x}$

L'échantillon après standardisation aura une **moyenne nulle** et une **variance de 1**.

La standardisation : exemple

x	1.4	1.7	3.0	1.0	3.2	7.7	7.4	5.9	8.4	4.6
	2.2	4.7	8.5	3.9	2.7	6.5	1.7	1.3	4.3	2.3
x^c	-2.72	-2.42	-1.12	-3.12	-0.92	3.58	3.28	1.78	4.28	0.48
	-1.92	0.58	4.38	-0.22	-1.42	2.38	-2.42	-2.82	0.18	-1.82
x^s	-1.12	-0.99	-0.46	-1.28	-0.38	1.47	1.35	0.73	1.76	0.20
	-0.79	0.24	1.80	-0.09	-0.58	0.98	-0.99	-1.16	0.07	-0.75






Visualisations catégorielles et bi-variées

Visualisations catégorielles : le barplot

Pour une variable catégorielle x à m modalités, le **diagramme en bâtonnets** ou **barplot** consiste à placer sur l'axe horizontal les m catégories, et sur l'axe vertical des bâtonnets de hauteur





- n_j , l'effectif de la modalité $j = 1, \dots, m$, ou
- $f_j = n_j/n$, l'effectif relatif ou proportion de la modalité j .

Exemple : 3 variantes du barplot des $m = 6$ statuts du questionnaire « Chamberonne » ($n=1365$).



Visualisations catégorielles : le camembert

Le **camembert** ou **pie chart** est une alternative au barplot. Il est adoré par les amateurs d'esthétisme mais exécréé par les puristes.





Visualisations bi-variées : le diagramme de dispersion

Soit **deux variables quantitatives** $\{x_1, \dots, x_n\}$ et $\{y_1, \dots, y_n\}$ mesurées sur les mêmes n individus.

Le **diagramme de dispersion** ou **scatterplot** est la représentation de chaque individu i par un point de coordonnées (x_i, y_i) dans un repère cartésien.

Ce dernier permet de voir si **ces variables sont liées l'une à l'autre**.



Deux variables catégorielles : la table de contingence

La représentation simultanée de **2 variables catégorielles** x et y , avec respectivement m_1 et m_2 modalités, se base généralement sur un tableau intermédiaire que l'on nomme **table de contingence** ou **table croisée**.

Cette table possède m_1 lignes et m_2 colonnes, et les cases contiennent les **effectifs croisés** n_{jk} :

$n_{jk} := \ll \text{nombre d'individus de modalité } j \text{ pour } x \text{ et de modalité } k \text{ pour } y. \gg$

On complète la table par :

- Les **marge des lignes** : $n_{k\bullet} = \sum_{j=1}^{m_2} n_{jk}$
- Les **marge des colonnes** : $n_{\bullet j} = \sum_{k=1}^{m_2} n_{jk}$
- L'**effectif total** : $n_{\bullet\bullet} = \sum_{k=1}^{m_2} \sum_{j=1}^{m_2} n_{jk}$

Deux variables catégorielles : la table de contingence

$\begin{array}{c} y \rightarrow \\ x \downarrow \end{array}$	$k = 1$	$k = 2$	$\dots$	k	$\dots$	$k = m_2$	marge en ligne
$j = 1$	n_{11}	n_{12}	$\dots$	n_{1k}	$\dots$	n_{1m_2}	$n_{1\bullet}$
$j = 2$	n_{21}	n_{22}	$\dots$	n_{2k}	$\dots$	n_{2m_2}	$n_{2\bullet}$
$j = 3$	n_{31}	n_{32}	$\dots$	n_{3k}	$\dots$	n_{3m_2}	$n_{3\bullet}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
j	n_{j1}	n_{j2}	$\dots$	n_{jk}	$\dots$	n_{jm_2}	$n_{j\bullet}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
$j = m_1$	$n_{m_1 1}$	$n_{m_1 2}$	$\dots$	$n_{m_1 k}$	$\dots$	$n_{m_1 m_2}$	$n_{m_1 \bullet}$
marge en colonne	$n_{\bullet 1}$	$n_{\bullet 2}$	$\dots$	$n_{\bullet k}$	$\dots$	$n_{\bullet m_2}$	$n_{\bullet \bullet} = n$



Table de contingence : exemple

Pour les données de la « Chamberonne » : la table de contingence
« statut » × « faculté » avec les marges

	FTSR	Droit	Lettres	SSP	HEC	FBM	GSE	SerC	IBGA	Autre	Total
Etu	15	81	140	207	72	102	111	0	0	0	728
ProfMer	4	16	47	25	8	14	21	0	0	0	135
PostDoc	1	2	12	15	2	14	7	0	0	1	54
Ass	4	27	31	36	7	23	29	0	0	0	157
PAT	4	16	22	29	20	43	16	126	30	10	316
Autre	1	4	4	7	1	2	3	0	19	4	45
Total	29	146	256	319	110	198	187	126	49	15	1365



Visualisations bi-variées : le diagramme en bâtonnets groupés

À partir de cette table de contingence, plusieurs visualisations existent. Pour commencer, le **diagramme en bâtonnets groupé** :



Visualisations bi-variées : le diagramme en bâtonnets empilé et mosaïque

Le **diagramme en bâtonnets empilé** et le **diagramme en mosaïque** :



Visualisations bi-variées : numérique vs catégorielle

Une **visualisation d'une variable numérique vs catégorielle** consiste généralement une **visualisation uni-variée numérique pour chaque catégorie** :

