

Méthodes Quantitatives I :

5. Liens entre deux variables

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 39 - 46

Exercices : 3.2 - 3.4

Dépendance et lien entre deux variables

Lorsque l'on **étudie simultanément 2 variables** $x = \{x_1, \dots, x_n\}$ et $y = \{y_1, \dots, y_n\}$, la question fondamentale que l'on doit se poser est :

« Est-ce qu'il existe un **lien** entre la variable x et la variable y ? »

Exemples :

- « Existe-t-il un lien entre taille d'un individu et son poids ? »
- « Existe-t-il un lien entre consommation de chocolat et nombre de prix Nobel ? »
- « Existe-t-il un lien entre taux d'endettement d'un pays et croissance ? »

Des variables sans lien sont dites **indépendantes**.

Dépendance théorique vs dépendance empirique

Il faut distinguer :

- Le concept de **dépendance théorique** entre les variables de la population, et donc de notre **modèle**.
- Le concept de **dépendance empirique**, appelée **lien** ou **liaison**, pour les variables mesurées dans l'échantillon.

Population : X, Y

Échantillon : x, y

Les variables théorique sont notées avec des majuscules : X et Y .

Les variables mesurées dans l'échantillon sont en minuscule

$x = \{x_1, \dots, x_n\}$ et $y = \{y_1, \dots, y_n\}$

Dépendance théorique vs dépendance empirique

Par exemple, on peut définir l'indépendance au niveau théorique.

Définition

Deux variables X et Y sont **indépendantes** si et seulement si :

$$P(X \in A \text{ et } Y \in B) = P(X \in A)P(X \in B)$$

Pour n'importe quels ensembles de scores A et B .

Mais cette égalité ne sera (presque) **jamais vérifiée empiriquement**.

Dans l'échantillon, on utilisera une **mesure de la force du lien** pour voir si l'indépendance est probable ou non.

Intérêt de la notion de dépendance

Le cas de l'indépendance n'est pas très intéressant. En revanche, si deux variables sont **dépendantes**, plusieurs questions peuvent se poser :

- Dépendance forte ou faible ?
- Dépendance significative (voir tests) ou non ?
- Quelle est la nature de la dépendance ?
- Comment modéliser la dépendance ?

Aussi, plusieurs méthodes de statistiques se basent sur la dépendance. En effet, sachant la dépendance :

- On peut tenter de **prédire** la valeur de certaines variables à partir de la connaissance des valeurs d'autres variables (e.g. régression).
- On peut tenter d'**extraire** les variables explicatives sous-jacentes des données (e.g. méthodes factorielles).
- On peut tenter de **compresser** l'information contenu dans le jeu de données (e.g. théorie de l'information).

Pour le moment, nous restons dans le domaine de la **statistique descriptive** : Il s'agira de montrer comment **mesurer le lien entre deux variables empirique**.

La mesure de lien va dépendre de la nature des variables :

- Lorsque x et y sont catégorielles, on utilise le **chi-carré**.
- Lorsque x et y sont numériques, on utilise la **corrélation**.
- Lorsque x est numérique et y est catégorielle (ou l'inverse), on utilise le **F-ratio**.

Le chi-carré

La table de contingence

On se souvient que deux variables catégorielles x et y , de modalités m_1 et m_2 , peuvent être représentées par une **table de contingence** ($m_1 \times m_2$)

	FTSR	Droit	Lettres	SSP	HEC	FBM	GSE	SerC	IBGA	Autre	Total
Etu	15	81	140	207	72	102	111	0	0	0	728
ProfMer	4	16	47	25	8	14	21	0	0	0	135
PostDoc	1	2	12	15	2	14	7	0	0	1	54
Ass	4	27	31	36	7	23	29	0	0	0	157
PAT	4	16	22	29	20	43	16	126	30	10	316
Autre	1	4	4	7	1	2	3	0	19	4	45
Total	29	146	256	319	110	198	187	126	49	15	1365

Les composantes se notent n_{ij} , les marges sur les lignes $n_{i\bullet}$, les marges sur les colonnes $n_{\bullet j}$ et le total $n = n_{\bullet\bullet}$.

Hypothèse d'indépendance

Supposons l'indépendance. Les **variables théoriques** X et Y , dont sont issus x et y , devraient alors vérifier :

$$P(X = j \text{ et } Y = k) = P(X = j)P(Y = k)$$

La « traduction empirique » de se ces quantités est la suivante :

$$\begin{aligned} P(X = j \text{ et } Y = k) &\longrightarrow p_{jk} := \frac{n_{jk}}{n} \\ P(X = j) &\longrightarrow f_j := \frac{n_{j\bullet}}{n} \\ P(Y = i) &\longrightarrow \rho_k := \frac{n_{\bullet k}}{n} \end{aligned}$$

On appelle p_{jk} la **fréquence jointe** et f_j et ρ_j les **fréquences uni-variées ou marginales**.

Hypothèse d'indépendance : les effectifs théoriques

Sous hypothèse d'indépendance, on devrait donc trouver dans notre échantillon la **condition de non-liaison** suivante :

$$p_{jk} = \frac{n_{jk}}{n} \simeq \frac{n_{j\bullet}}{n} \frac{n_{\bullet k}}{n} = f_j \rho_k \quad \Rightarrow \quad n_{jk} \simeq \frac{n_{j\bullet} n_{\bullet k}}{n}$$

Définition

Soient une table de contingence avec les effectifs n_{jk} . On appelle **effectifs attendus ou théoriques sous indépendance**, notés n_{jk}^{th} , la quantité

$$n_{jk}^{\text{th}} := \frac{n_{j\bullet} n_{\bullet k}}{n}$$

Dans un échantillon, l'égalité $n_{jk} = n_{jk}^{\text{th}}$ est très improbable. On va plutôt s'intéresser à l'**écart qui existe entre n_{jk} et n_{jk}^{th}** .

Hypothèse d'indépendance : les effectifs théoriques

Les effectifs observés n_{jk}

	FTSR	Droit	Lettres	SSP	HEC	FBM	GSE	SerC	IBGA	Autre	Total
Etu	15	81	140	207	72	102	111	0	0	0	728
ProfMer	4	16	47	25	8	14	21	0	0	0	135
PostDoc	1	2	12	15	2	14	7	0	0	1	54
Ass	4	27	31	36	7	23	29	0	0	0	157
PAT	4	16	22	29	20	43	16	126	30	10	316
Autre	1	4	4	7	1	2	3	0	19	4	45
Total	29	146	256	319	110	198	187	126	49	15	1365

Les effectifs théoriques n_{jk}^{th}

	FTSR	Droit	Lettres	SSP	HEC	FBM	GSE	SerC	IBGA	Autre	Total
Etu	14.71	74.07	129.87	161.83	55.80	100.45	94.87	63.92	24.86	7.61	728
ProfMer	2.73	13.74	24.08	30.01	10.35	18.63	17.59	11.85	4.61	1.41	135
PostDoc	1.09	5.49	9.63	12.00	4.14	7.45	7.04	4.74	1.84	0.56	54
Ass	3.17	15.97	28.01	34.90	12.03	21.66	20.46	13.79	5.36	1.64	157
PAT	6.39	32.15	56.37	70.25	24.22	43.60	41.18	27.75	10.79	3.30	316
Autre	0.91	4.58	8.03	10.00	3.45	6.21	5.86	3.95	1.54	0.47	45
Total	29	146	256	319	110	198	187	126	49	15	1365

Les marges sont identiques dans les tables : $n_{j\bullet}^{\text{th}} = n_{j\bullet}$ et $n_{\bullet k}^{\text{th}} = n_{\bullet k}$

Définition

Soit une table de contingence avec les effectifs n_{jk} . On appelle **le coefficient du chi-carré**, noté **chi2**, la quantité

$$\text{chi2} := \sum_{j=1}^{m_1} \sum_{k=1}^{m_2} \frac{(n_{jk} - n_{jk}^{\text{th}})^2}{n_{jk}^{\text{th}}} = \sum_{j=1}^{m_1} \sum_{k=1}^{m_2} \frac{(n_{jk} - \frac{n_{j\bullet} n_{\bullet k}}{n})^2}{\frac{n_{j\bullet} n_{\bullet k}}{n}}$$

Le chi-carré mesure l'écart entre les données de l'échantillon et les effectifs attendus sous hypothèse d'indépendance. Un chi-carré élevé dénote donc une forte liaison entre les variables x et y .

On a aussi : $\text{chi2} = n \left(\left(\sum_{j=1}^{m_1} \sum_{k=1}^{m_2} \frac{n_{ij}^2}{n_{i\bullet} n_{\bullet j}} \right) - 1 \right)$, qui peut être plus pratique pour des calculs.

Le coefficient du chi-carré

Si l'on écrit le χ^2 en **termes de fréquences**, on a

$$\chi^2 = n \cdot \sum_{j=1}^{m_1} \sum_{k=1}^{m_2} \frac{(p_{jk} - f_j \rho_k)^2}{f_j \rho_k}$$

Il dépend donc de la taille de l'échantillon.

Définition

Le **phi-carré**, noté **phi2**, se définit avec

$$\text{phi2} := \frac{\chi^2}{n}$$

Il ne dépend que des fréquences relatives, mais pas de l'effectif n .

Dans notre exemple, on a $\chi^2 = 917.73$ et $\text{phi2} = \frac{917.73}{1365} = 0.672$.

Les quotients d'indépendance

Pour comparer un effectif observé n_{jk} avec son effectif théorique n_{jk}^{th} , il nous faut un indice qui ne dépend pas de la taille de l'effectif.

Définition

Les **quotients d'indépendance**, notés q_{jk} , se définissent comme

$$q_{jk} := \frac{n_{jk}}{n_{jk}^{\text{th}}} = \frac{p_{jk}}{f_i \rho_k}$$

- Les modalités j et k sont **conjointement sur-représentées** ou en **attraction** ssi $q_{jk} > 1$ ssi $n_{jk} > n_{jk}^{\text{th}}$.
- Les modalités j et k sont **conjointement sous-représentées** ou en **répulsion** ssi $q_{jk} < 1$ ssi $n_{jk} < n_{jk}^{\text{th}}$.
- Les modalités j et k sont **en relation de neutralité** ssi $q_{jk} = 1$ ssi $n_{jk} = n_{jk}^{\text{th}}$.

Les quotients d'indépendance : exemple

Les quotients d'indépendance dans notre exemple sont

	FTSR	Droit	Lettres	SSP	HEC	FBM	GSE	SerC	IBGA	Autre	
Etu	1.02	1.09	1.08	1.28	1.29	1.02	1.17	0	0	0	1
ProfMer	1.47	1.16	1.95	0.83	0.77	0.75	1.19	0	0	0	1
PostDoc	0.92	0.36	1.25	1.25	0.48	1.88	0.99	0	0	1.77	1
Ass	1.26	1.69	1.11	1.03	0.58	1.06	1.42	0	0	0	1
PAT	0.63	0.50	0.39	0.41	0.83	0.99	0.39	4.54	2.78	3.03	1
Autre	1.10	0.87	0.50	0.70	0.29	0.32	0.51	0	12.37	8.50	1
	1	1	1	1	1	1	1	1	1	1	

La plus grande sur-représentation est entre *Autre* avec *IBGA* : il y a 12.37 fois plus d'« Autre » dans « IBGA » qu'attendu sous indépendance.

Les quotients d'indépendance : propriétés

Par calcul, on trouve

$$\sum_{j=1}^{m_1} f_j q_{jk} = 1 \quad \sum_{k=1}^{m_2} \rho_k q_{jk} = 1$$

Ce qui veut dire que les **moyennes pondérées** (par les poids des lignes ou colonnes) des quotients sur les lignes, ou les colonnes, vaut 1.

Les coefficients du chi-carré et du phi-carré s'écrivent aussi comme

$$\text{phi}^2 = \frac{\text{chi}^2}{n} = \sum_{j=1}^{m_1} \sum_{k=1}^{m_2} f_j \rho_k (q_{jk} - 1)^2$$

C'est à dire comme une **moyenne pondérée du carré des écarts des quotients**.

L'indépendance revient à :

$$\text{chi}^2 = 0 \quad \Leftrightarrow \quad q_{jk} = 1 \text{ partout} \quad \Leftrightarrow \quad n_{jk} = n_{jk}^{\text{th}} \text{ partout}$$

Dépendance fonctionnelle

On peut montrer que la **valeur maximale que peut atteindre le χ^2** est

$$n \cdot \min(m_1 - 1, m_2 - 1)$$

Cette valeur est atteinte dans le cas de la **dépendance fonctionnelle**, lorsque la variable ayant le plus de modalités détermine entièrement l'autre variable.

	FTSR	Droit	Lettres	SSP	HEC	FBM	GSE	SerC	IBGA	Autre	Total
Etu	-	-	256	-	110	198	187	-	-	-	751
ProfMer	-	-	-	-	-	-	-	126	-	-	135
PostDoc	-	-	-	-	-	-	-	-	49	-	54
Ass	-	146	-	-	-	-	-	-	-	-	157
PAT	-	-	-	319	-	-	-	-	-	-	316
Autre	29	-	-	-	-	-	-	-	-	15	45
Total	29	146	256	319	110	198	187	126	49	15	1365

Ici, la **faculté** détermine entièrement le **statut**. La valeur de $\chi^2 = 1365 \cdot \min(6 - 1, 10 - 1) = 1365 \cdot 5 = 7175$ est atteinte.

On peut donc construire une mesure qui est plus facile à interpréter

Définition

Le **V de Cramer**, noté **V**, se définit comme

$$V := \sqrt{\frac{\text{chi2}}{n \min(m_1 - 1, m_2 - 1)}}$$

Il est compris dans $[0, 1]$.

Dans notre exemple, on a $V = \sqrt{\frac{917.73}{7175}} = 0.36$.


La covariance et la corrélation

Lien entre deux variables numériques

Il s'agit ici de définir une **mesure de dépendance entre deux variables numériques**.

Exemple, notes dans deux branches :

math	physique
5.5	5.5
5.0	3.5
4.5	4.0
1.5	3.0
6.0	6.0
4.5	5.0
3.0	2.0
3.5	2.5
5.0	5.0
4.0	5.5



Dans le diagramme de dispersion, **math** et **physique** semblent liées : un score élevé (resp. bas) en math implique en moyenne un score élevé (resp. bas) en physique, et vice-versa.

Définition

Soient deux variables numériques x et y . La **covariance**, notée **cov**(x, y) ou **s_{xy}**, se définit comme la **moyenne du produit des écarts à la moyenne**, i.e.

$$\text{cov}(x, y) := \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n} \left(\sum_{i=1}^n x_i y_i \right) - \bar{x} \bar{y}$$

On peut noter : $\text{cov}(x, y) = \overline{(x - \bar{x})(y - \bar{y})} = \overline{xy} - \bar{x} \bar{y}$.

On a : $\text{cov}(x, x) = \text{var}(x)$

- $(x_i - \bar{x})(y_i - \bar{y}) > 0$ s'il y a un écart positif à la moyenne pour x_i et pour y_i (ou un écart négatif pour les deux).
- $(x_i - \bar{x})(y_i - \bar{y}) < 0$ s'il y a un écart positif à la moyenne pour x_i mais négatif pour y_i (ou l'inverse).

La covariance est donc **positive pour une liaison positive** (les deux variables vont dans le même sens) et **négative pour une liaison négative** (les variables évoluent dans des directions opposées).

La covariance : sensibilité à l'échelle

On peut calculer que

$$\text{cov}(a \cdot x, b \cdot y) = a \cdot b \cdot \text{cov}(x, y)$$

La **covariance dépend du système d'unités choisies**.

Par exemple, la covariance entre **âge** et **revenu** deviendrait 12 fois plus grande si l'âge était mesuré en mois plutôt qu'en années.

Pour corriger ce défaut, on peut **standardiser les variables avec leur écart-types s_x et s_y** , ce qui revient à calculer le coefficient suivant.

Définition

Le **coefficient de corrélation** de x et y , noté $\text{corr}(x, y)$ ou r_{xy} , correspond à la **covariance entre les variables standardisées**, i.e. :

$$\text{corr}(x, y) := \text{cov}(x^s, y^s) = \frac{\text{cov}(x, y)}{s_x s_y}$$


On a $-1 \leq \text{corr}(x, y) \leq 1$.

On peut montrer que :


- $\text{corr}(x, y) = 1$ ssi $y_i = ax_i + b$ avec $a > 0$
- $\text{corr}(x, y) = -1$ ssi $y_i = ax_i + b$ avec $a < 0$

La corrélation : exemple


$$\text{corr}(x, y) = 0.69$$




$$\text{corr}(x, y) = -0.74$$



$$\text{corr}(x, y) = 1$$



$$\text{corr}(x, y) = -1$$





Corrélation nulle

On a l'implication suivante :

$$x \text{ et } y \text{ ne sont pas liés} \Rightarrow \text{corr}(x, y) \simeq 0$$

En revanche, **la réciproque est généralement fausse.**

Les variables peuvent avoir un lien **non-linéaire** et avoir une corrélation nulle.



En résumé :

$$x \text{ et } y \text{ ne sont pas liées} \implies \text{corr}(x, y) \simeq 0$$

$$\text{corr}(x, y) = \pm 1 \implies y = ax + b$$

Alors que pour des variables catégorielles x et y :


$$x \text{ et } y \text{ ne sont pas liées} \iff \text{chi}^2 = 0$$

Même si l'on arrive à trouver un lien entre deux variables, il est vital de garder en tête :

Lien entre x et $y \neq$ Causalité entre x et y


Découvrir la nature du lien entre les deux variables est généralement **difficile**.

$\text{corr}(\text{Consommation de chocolat}, \text{Nombre de prix Nobel}) = 0.791$




Source : Franz H. Messerli (2012) « Chocolate Consumption, Cognitive Function, and Nobel Laureates »

Il s'agit ici certainement le cas d'une **variable latente** agissant sur ces deux autres :



On peut trouver un lien négatif entre **Taux d'endettement** et **Taux de croissance du PIB**.



Source : G. Guex et S. Guex (2018) « Debt, economic growth, and interest rates : an empirical study of the Swiss case, presenting a new long-term dataset : 1894–2014 »

Cependant, la **causalité** est inversée :

