

Méthodes Quantitatives I :

6. Liens entre deux variables (suite)

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 46 - 53

Exercices : toute la série 3



La régression linéaire simple

Parties déterministe et aléatoire

L'allure générale d'un diagramme de dispersion associé à deux variables x et y peut suggérer une relation du type

$$y_i = \underbrace{f(x_i)}_{\text{partie déterministe}} + \underbrace{e_i}_{\text{partie aléatoire}} \quad \text{où}$$

- $f(x)$ est une **fonction déterministe** donnant l'allure générale du nuage de points, ou tendance.
- e_i est le **résidu** ou **bruit**, purement aléatoire. C'est la partie de y inexpliquée par x .






Relations linéaires

La forme la plus simple d'une relation entre x et y est donnée par la **relation linéaire** $f(x) = ax + b$:

$$y_i = \underbrace{ax_i + b}_{\text{valeur prédite } y_i^*} + \underbrace{e_i}_{\text{résidu}} = y_i^* + e_i$$

- les y_i sont les **valeurs observées**.
- les y_i^* sont les **valeurs prédites**.




La droite de régression

L'objectif de la **régression simple** consiste à trouver

- le **pente** de la droite a .
- l'**ordonnée à l'origine** de la droite b .

tel que les $y_i^* = ax_i + b$ soient les **meilleurs prédictions** des y_i .






Les moindres carrés

On va chercher a et b afin que les prédictions $y_i^* = ax_i + b$ donnent une **somme des carrés des résidus** minimale :

$$\text{SSE} = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - y_i^*)^2 = \sum_{i=1}^n (y_i - ax_i - b)^2$$

C'est le **critère des moindres carrés**.



La solution

Avec ce critère, on trouve la **solution à la régression simple** suivante

$$a = \frac{s_{xy}}{s_x^2} = r_{xy} \frac{s_y}{s_x}$$

$$b = \bar{y} - a\bar{x}$$

Exemple :

x : math	y : physique
5.5	5.5
5.0	3.5
4.5	4.0
1.5	3.0
6.0	6.0
4.5	5.0
3.0	2.0
3.5	2.5
5.0	5.0
4.0	5.5


$$\bar{x} = 4.25, s_x = 1.25$$

$$\bar{y} = 4.2, s_y = 1.33$$

$$r_{xy} = 0.72$$

$$a = 0.72 \cdot \frac{1.33}{1.25} = 0.768$$

$$b = 4.2 - 0.768 \cdot 4.25 = 0.936$$



Conséquences

- La moyenne empirique des résidus est nulle : $\bar{e} = 0$.
- La droite de régression passe par le point $(\bar{x}, \bar{y})$.
- La **variance totale de y se décompose** comme

$$\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n} \sum_{i=1}^n (y_i^* - \bar{y})^2 + \frac{1}{n} \sum_{i=1}^n (y_i - y_i^*)^2$$
$$\underbrace{\text{var}(y)}_{\text{variance totale}} = \underbrace{\text{var}(y^*)}_{\text{variance expliquée}} + \underbrace{\text{var}(e)}_{\text{variance résiduelle}}$$

- $\text{var}(e) = (1 - r^2)\text{var}(y)$, ce qui implique que

$$r^2 = \frac{\text{var}(y) - \text{var}(e)}{\text{var}(y)} = \frac{\text{var}(y^*)}{\text{var}(y)} = \frac{\text{variance expliquée}}{\text{variance totale}}$$

Le **carré de la corrélation**, appelé aussi **coefficient de détermination**, mesure la **proportion de variance de y expliquée par x**.

Le F-ratio


Variable numérique et catégorielle

On va maintenant s'intéresser à notre dernière mesure de lien, le **F-ratio**, qui mesure le lien entre une **variable numérique x et catégorielle y à m modalités**.

La variable y permet de **définir m groupes au sein des individus**.
On va indiquer ces groupes avec la lettre $j = 1, \dots, m$.

Exemple :


x	0.19	1.19	2.74	3.53	4.11	4.42	5.26	6.57	6.63	6.92	7.81	10.01
y	A	A	B	B	B	C	A	C	C	B	C	C



Lien entre variable numérique et catégorielle : intuition

Comment se présentent ces groupes dans le cas de lien ou de non-lien entre x et y ?

S'il y a un **lien**, les scores x_i seront **proches à l'intérieur de chaque groupe**, c'est-à-dire qu'il y aura une **faible variance à l'intérieur des groupes**.



À l'inverse, s'il n'y a **pas de lien**, les scores x_i seront **différents à l'intérieur de chaque groupe**, c'est-à-dire qu'il y aura une **forte variance à l'intérieur des groupes**.





Variance totale et variance des groupes

Dans tout l'échantillon de n individus, la **variance totale** est :

$$s^2 = \text{var}(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \quad \text{avec moyenne : } \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Si maintenant, on suppose que ces n individus sont répartis en m groupes, la **variance du groupe j** , d'**effectif n_j** s'exprimera comme :

$$s_j^2 = \text{var}_j(x) := \frac{1}{n_j} \sum_{i=1}^{n_j} (x_i - \bar{x}_j)^2 \quad \text{avec moyenne : } \bar{x}_j := \frac{1}{n_j} \sum_{i=1}^{n_j} x_i$$



Que se passe-t-il si l'on fait la **moyenne pondérée (par la taille des groupes) de toutes les variances des groupes**, que l'on nomme la **variance intragroupe**, i.e.

$$\text{var}_W(x) := \sum_{j=1}^m \frac{n_j}{n} \text{var}_j(x)$$

est-elle égale à la variance totale ? Non, elle est inférieure :


$$\text{var}_W(x) < \text{var}(x)$$

En fait, il nous manque la **variance entre les groupes** ou **variance intergroupe**.

Variance intergroupe

La **variance intergroupe** se calcule comme si l'on considérait chaque groupe comme **un seul individu**, résumé par sa moyenne $\bar{x}_j$ et de poids relatif n_j/n :

$$\text{var}_B(x) := \sum_{j=1}^m \frac{n_j}{n} (\bar{x}_j - \bar{x})^2$$



La décomposition de la variance

Théorème

Soit $x_1, \dots, x_n$ des scores répartis dans m groupes de tailles $n_1, \dots, n_m$.

La **variance totale** se décompose alors comme :

$$\text{var}(x) = \text{var}_B(x) + \text{var}_W(x)$$

où **$\text{var}_B(x)$** est la **variance intergroupe (between)** :


$$\text{var}_B(x) := \sum_{j=1}^m \frac{n_j}{n} (\bar{x}_j - \bar{x})^2$$

et **$\text{var}_W(x)$** est la **variance intragroupe (within)** :

$$\text{var}_W(x) := \sum_{j=1}^m \frac{n_j}{n} \text{var}_j(x)$$


avec $\bar{x}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} x_i$ et $\text{var}_j(x) = \frac{1}{n_j} \sum_{i=1}^{n_j} (x_i - \bar{x}_j)^2$ la moyenne et la variance du groupe j .

La décomposition de la variance




Comparaison entre $\text{var}_B(x)$ et $\text{var}_W(x)$

Quand les groupes sont **facilement discernables**, $\text{var}_B(x)$ est grande et $\text{var}_W(x)$ est petite :



À l'inverse, quand ils sont **peu discernables** : $\text{var}_B(x)$ est petite et $\text{var}_W(x)$ est grande :



Définition

Soit x une variable numérique répartis dans m groupes de tailles $n_1, \dots, n_m$ définis par une variable catégorielle y . Le **F-ratio** entre ces deux variables est :

$$F := \frac{\frac{\text{var}_B(x)}{m-1}}{\frac{\text{var}_W(x)}{n-m}}$$

où $\text{var}_B(x)$ est la **variance intergroupe** et $\text{var}_W(x)$ la **variance intragroupe**.

Les dénominateurs $m - 1$ et $n - m$ sont utilisées car on considère les *degrés de liberté*, ou le *nombre d'écarts*, entre les « points » qui sont utilisés dans le calcul des variances.

Le F-ratio a les propriétés suivantes :

- $F \geq 0$.
- $F = 0$ ssi $\text{var}_B(x) = 0$ ssi toutes les moyennes des groupes $\bar{x}_1, \dots, \bar{x}_m$ coïncident. Les groupes ont le **même centre**.
- $F = \infty$ ssi $\text{var}_W(x) = 0$ ssi tous les scores de chaque groupe coïncident. les groupes sont **complètement homogènes**.
- x et y non liés $\iff F = 0$

La valeur du F-ratio est **difficile à interpréter**, ce qui n'est pas le cas de la mesure suivante


Définition

Soit x une variable numérique répartis dans m groupes de tailles $n_1, \dots, n_m$ définis par une variable catégorielle y . Le **éta-carré** ou **rapport de corrélation** entre ces deux variables est :

$$\eta^2 := \frac{\text{var}_B(x)}{\text{var}(x)} = \frac{\text{var}_B(x)}{\text{var}_B(x) + \text{var}_W(x)}$$

Le éta-carré, de la même manière que r_{xy}^2 , représente la **proportion de variance x expliquée par y** .

Le F-ratio : exemple



statut	effectif n_j	moyenne $\bar{x}_j$	variance s_j^2	écart-type s_j
Etu	728	23.0	22.9	4.8
ProfMer	135	51.5	99.2	10.0
PostDoc	54	37.5	39.6	6.3
Ass	157	29.7	18.5	4.3
PAT	316	42.4	101.6	10.1
Autre	45	43.0	215.9	14.7
total	1365	31.8	159.9	12.6

On trouve ici :

$$\begin{aligned} \text{var}_B(x) &= 106.4 & \text{var}_W(x) &= 53.6 \\ F &= \frac{\frac{106.4}{6-1}}{\frac{53.6}{1365-6}} = 539.6 & \eta^2 &= \frac{106.4}{106.4 + 53.6} = 0.665 \end{aligned}$$

Le statut explique 2/3 de la variabilité de l'âge.