

Méthodes Quantitatives I :

7. Modèles et variables aléatoires

Guillaume Guex guillaume.guex@unil.ch


Pages du polycopié : 56 - 63

Exercices : 4.1, 4.2, 4.8

Les modèles

L'échantillon

Pour l'instant, nous avons uniquement travaillé avec des **échantillons** et avec les quantités que nous pouvions calculer à partir de ceux-ci.




Cette branche des statistiques s'appelle la **statistique descriptive**.

Maintenant, qu'en est-il de la **population** ?

La population

Personne n'a réellement accès à la **population**, on ne peut qu'en faire des **modèles**.



Le processus de création de modèles, ou de confrontation des modèles aux observations est le domaine de la **statistique inférentielle**.

Pour le moment, nous n'allons pas nous intéresser au processus d'inférence statistique, mais nous allons nous concentrer sur la manière dont **les modèles sont construits en statistique**.

Une modèle est une **idée** de la réalité, ou plutôt une **formalisation de cette idée**. Cette formalisation doit répondre à deux exigences :

- Être suffisamment **souple** pour pouvoir généraliser et rendre compte d'idées élaborées.
- Être suffisamment **précise** pour être confrontée avec les observations.

Les **modèles probabilistes** répondent à cette double exigence et se sont imposés presque partout en science (naturelle ou humaine et sociale).

Un modèle probabiliste dit que telle chose, tel état du monde, telle configuration, se produit avec une certaine probabilité.

Si une seule configuration est possible, on parle alors de **modèle déterministe**.

Si le modèle décrit une tendance, mais laisse place à de l'incertitude, il s'agit alors d'un **modèle aléatoire**.

Les familles de modèles probabilistes

En probabilité, nous disposons de plusieurs **familles de modèles probabilistes**, qui permettent de rendre compte de plusieurs réalités différentes. Par exemple :

- Les modèles **gaussiens** peuvent décrire la distribution des erreurs de localisation en astronomie, la taille des spécimens d'une espèce ou la position d'une particule dans l'espace.
- Les modèles **poissoniens** peuvent décrire le nombre de personnes connues rencontrées lors d'un événement, le nombre de glissements de terrains en une année ou le nombre de mails échangés en un jour.

On peut aussi **combiner les modèles** pour rendre compte d'idées plus complexes.

A partir de maintenant, dans ce cours, il faudra bien distinguer entre les objets qui se rapportent à :

- L'échantillon (données, observations), on parlera alors d'objets **empiriques**, qui relèvent du cas **particulier** (les notations sont en minuscules).
- La population (modèles, théories, hypothèses), on parlera alors d'objets **théoriques**, qui ont alors plutôt un caractère **universel** (les notations sont en majuscules).

Les variables aléatoires

Variables aléatoires

Prenons deux exemples de variables mesurées sur un échantillon :

- Soit $\{4, 3, 5, 2\}$ les résultats de 4 lancés de dés.
- Soit $\{169.1, 183.2, 171.6, 179.5, 191.5\}$ les tailles de 5 hommes en cm.


On peut modéliser ces valeurs comme le résultat de **réalisations** d'objets abstraits nommés **variables aléatoires**.

- Dans le premier cas, la variable aléatoire peut prendre les valeurs $\{1, 2, 3, 4, 5, 6\}$.
- Dans le deuxième cas, la variable aléatoire peut prendre des valeurs entre 54 à 272 (selon le livres de records).

Une variable aléatoire peut être vue comme un **générateur de valeurs**.

Variables aléatoires : notation

On va noter les **variables aléatoires** avec une majuscule X , alors que ses **réalisations** seront notées avec des minuscules indicées $x_1, \dots, x_n$.



Un échantillon de taille n , $x_1, \dots, x_n$, est le résultat de n réalisations ou générations de la variable X

Définitions

Les valeurs que peuvent prendre une variable aléatoire sont appelées son **support**. Ce dernier définit le type de variable aléatoire :

- Une variable aléatoire est **discrète** si elle prend des valeurs (finies ou infinies) **dénombrables** (face d'un dés, nombre de mails reçus, genre, etc.)
- Une variable aléatoire est **continue** si elle peut prendre des valeurs dans un **continuum** (taille d'une personne, temps d'attente, distance, etc.)
- Une variable aléatoire discrète peut être **quantitative, ordinale ou catégorielle**.
- Une variable aléatoire continue est (presque) exclusivement **numérique**.

Exemples de variables discrètes :

- Le nombre sur la face d'un dé.
- Le nombre d'accidents de voiture en Suisse en une année.
- Le niveau d'étude d'un individu.
- La profession d'un individu.

Exemples de variables continues :

- La taille d'une personne.
- Le temps d'arrivée à une course.
- La distance d'une boule de pétanque au cochonnet.

Variable aléatoire discrète : la distribution

Pour décrire une variable aléatoire, on a besoin de son **support** mais également des **probabilités que vont prendre les différentes valeurs**.

Définition

Soit une variable aléatoire discrète X , avec comme support $x_1, \dots, x_m$ (m fini ou infini). Sa **distribution** p_j se définit alors comme :

$$p_j := P(X = x_j)$$

On doit avoir :

$$p_j \geq 0 \quad \sum_{j=1}^m p_j = 1$$

La distribution : exemple

Soit $X = \ll \text{valeur d'une carte de jass} \gg$ On a :


- Les 6, 7, 8, 9 (sauf Nell) : 0 points
- Les 10 : 10 points
- Les Valais (sauf Bourg) : 2 points
- Les Dames : 3 points
- Les Rois : 4 points
- Les As : 11 points
- Le Nell (9 d'atout) : 14 points
- Le Bourg (V d'atout) : 20 points

On aura donc :

Support	Probabilité
0	$\frac{15}{36} = 41.7\%$
2	$\frac{3}{36} = 8.3\%$
3	$\frac{4}{36} = 11.1\%$
4	$\frac{4}{36} = 11.1\%$
10	$\frac{4}{36} = 11.1\%$
11	$\frac{4}{36} = 11.1\%$
14	$\frac{1}{36} = 2.8\%$
20	$\frac{1}{36} = 2.8\%$

La distribution : graphique

On peut représenter cette distribution sous forme **graphique** :



Variable aléatoire continue : la densité

Si l'on a une **variable aléatoire continue**, la situation est plus compliquée **car** $P(X = x) = 0$ **pour tout** x .

On va préféré définir les probabilité de X selon des **intervalles** :

$$P(X \in [a, b]) \quad \text{ou} \quad P(X \in (a, b))$$

Exemple : La probabilité qu'une pomme d'une espèce donnée pèse entre 100 et 150 grammes est a priori non nulle, mais la probabilité pour que cette dernière pèse par ex. exactement 152.000... grammes (avec une précision infinie) est nulle.

Définitions

Soit une variable aléatoire continue X , avec comme support $\mathbb{R}$.

Sa **densité** $f(x)$ se définit alors comme :


$$\int_a^b f(x)dx := P(X \in [a, b])$$

On doit avoir :

$$f(x) \geq 0 \quad \int_{-\infty}^{\infty} f(x)dx = 1$$

La densité : graphique


Le **graphique** de cette densité $f(x)$ est alors essentiel :



La probabilité que X soit entre 1 et 2 correspond à l'**aire** en rouge (c'est un nombre entre 0 et 1).

La densité : exemple


Soit un $X = \ll \text{distance d'une boule (tirée par un joueur très moyen) au cochonnet} \gg$, qui pourrait être modélisée avec la densité suivante (terrain de 10m) :



La probabilité d'être entre 4 et 7 mètres est donc de

$$P(X \in [4, 7]) = 3 \cdot 1/10 = 30\%$$

En réalité, la densité de la distance avec un joueur relativement bon risque d'être de la forme suivante :



Définitions

On appelle **fonction de répartition** ou **distribution cumulée** de la variable aléatoire quantitative X , la fonction $F(x)$ définie par :

$$F(x) := P(X \leq x)$$

De la même manière que les quantiles empiriques, le **quantile théorique** x_α se définit comme :



$$F(x_\alpha) = P(X \leq x_\alpha) = \alpha$$

On a :

- $F(x) = \sum_{x_j \leq x} p_j$ pour le cas discret.
- $F(x) = \int_{-\infty}^x p(t)dt$ pour le cas continu.



La fonction de répartition : cas discret

La fonction de répartition associée à une distribution numérique **discrète** est discontinue, et prend la forme d'un escalier.







La fonction de répartition : cas continu

À l'inverse, la fonction de répartition d'une variable **continue** est continue.



Les quantiles s'obtiennent alors en faisant $F^{-1}(\alpha) = x_\alpha$

Densité vs Fonction de répartition




La fonction de répartition : pourquoi ?

Dans les cas continus, il est parfois difficile de calculer l'intégrale de la densité, c'est pourquoi on préfère faire :

$$P(X \in [a, b]) = P(X \leq b) - P(X \leq a) = F(b) - F(a)$$

Pour certaines densités connues, on donne **un tableau des valeurs de la fonction de répartition**.



$$P(X \in [1, 3]) = F(3) - F(1)$$

On a également : $P(X \geq a) = 1 - P(X \leq a) = 1 - F(a)$

Définition

On appelle l'**espérance** ou **moyenne théorique** de la variable aléatoire quantitative X , la quantité $E(X)$ définie par :

$$E(X) := \sum_{i=j}^m p_j \cdot x_j \quad (\text{cas discret})$$

$$E(X) := \int_{-\infty}^{\infty} f(x) \cdot x \, dx \quad (\text{cas continu})$$

On utilise souvent la notation μ ou μ_X pour l'espérance $E(X)$ d'une variable aléatoire X .

Définition

On appelle la **variance théorique** de la variable aléatoire quantitative X , la quantité **Var(X)** définie par :

$$\text{Var}(X) := E((X - E(X))^2) = E(X^2) - E^2(X)$$

où

$$E(X^2) := \sum_{j=1}^m p_j \cdot x_j^2 \quad (\text{cas discret})$$

$$E(X^2) := \int_{-\infty}^{\infty} f(x) \cdot x^2 dx \quad (\text{cas continu})$$

On utilise souvent la notation σ^2 ou σ_X^2 pour la variance $\text{Var}(X)$ d'une variable aléatoire X .

L'**écart-type théorique** vaut $\sqrt{\text{Var}(X)}$ et se note généralement σ ou σ_X .

L'espérance et la variance : exemple discret

Reprenons notre exemple avec $X = \ll \text{valeur d'une carte de jass} \gg$:

Support	0	2	3	4	10	11	14	20
Probabilité	$\frac{15}{36}$	$\frac{3}{36}$	$\frac{4}{36}$	$\frac{4}{36}$	$\frac{4}{36}$	$\frac{4}{36}$	$\frac{1}{36}$	$\frac{1}{36}$

$$\begin{aligned}E(X) &= p_1 \cdot x_1 + \dots + p_m \cdot x_m \\&= \frac{15}{36} \cdot 0 + \frac{3}{36} \cdot 2 + \frac{4}{36} \cdot 3 + \frac{4}{36} \cdot 4 + \frac{4}{36} \cdot 10 + \frac{4}{36} \cdot 11 + \frac{1}{36} \cdot 14 + \frac{1}{36} \cdot 20 \\&= 4.22\end{aligned}$$


$$\begin{aligned}E(X^2) &= p_1 \cdot x_1^2 + \dots + p_m \cdot x_m^2 \\&= \frac{15}{36} \cdot 0^2 + \frac{3}{36} \cdot 2^2 + \frac{4}{36} \cdot 3^2 + \frac{4}{36} \cdot 4^2 + \frac{4}{36} \cdot 10^2 + \frac{4}{36} \cdot 11^2 + \frac{1}{36} \cdot 14^2 + \frac{1}{36} \cdot 20^2 \\&= 44.22\end{aligned}$$

$$\text{Var}(X) = E(X^2) - E(X)^2 = 44.22 - 4.22^2 = 26.4$$

$$\sigma_X = \sqrt{26.4} = 5.14$$

L'espérance et la variance : exemple continu

Soit $X = \ll \text{distance d'une boule au cochonnet} \gg$ donnée par la densité suivante :



$$E(X) = \int_0^{10} \frac{1}{10} \cdot x \, dx = \left(\frac{1}{10} \frac{x^2}{2} \Big|_0^{10} \right) = \frac{1}{10} \frac{10^2}{2} - \frac{1}{10} \frac{0^2}{2}$$
$$= 5$$

$$E(X^2) = \int_0^{10} \frac{1}{10} \cdot x^2 \, dx = \left(\frac{1}{10} \frac{x^3}{3} \Big|_0^{10} \right) = \frac{1}{10} \frac{10^3}{3} - \frac{1}{10} \frac{0^3}{3}$$
$$= \frac{100}{3}$$

$$\text{Var}(X) = E(X^2) - E(X)^2 = \frac{100}{3} - 5^2 = \frac{25}{3} = 8.33$$

$$\sigma_X = \sqrt{8.33} = 2.89$$

La standardisation

Toute variable quantitative X de moyenne μ et variance σ^2 peut être **centrée**, **réduite** ou **standardisée** :

$$X^c := X - \mu \quad X^r := \frac{X - \mu}{\sigma} \quad X^s := \frac{X - \mu}{\sigma}$$

Ce sont des **nouvelles variables aléatoires**, qui, par construction, vérifieront :

- $E(X^c) = 0$
- $\text{Var}(X^r) = 1$
- $E(X^s) = 0$ et $\text{Var}(X^s) = 1$

Il est facile de montrer que, pour toutes constantes a et b , on a

$$E(aX + b) = aE(X) + b \quad \text{Var}(aX + b) = a^2\text{Var}(X)$$

Distribution et densité bivariées

Définition

Soit X et Y deux variables **discrètes**, avec valeurs $x_1, \dots, x_{m_1}$ et $y_1, \dots, y_{m_2}$. Leur **distribution bivariée ou jointe**, donnée par p_{jk} , se définit comme :

$$p_{jk} := P(X = x_j \text{ et } Y = y_k)$$

Elle doit vérifier :

$$p_{jk} \geq 0 \quad \sum_{j=1}^{m_1} \sum_{k=1}^{m_2} p_{jk} = 1$$

On peut en déduire les **distributions marginales** :

$$P(X = x_j) = \sum_k P(X = x_j \text{ et } Y = y_k) = \sum_k p_{jk} = p_{j\bullet}$$

$$P(Y = y_k) = \sum_j P(X = x_j \text{ et } Y = y_k) = \sum_j p_{jk} = p_{\bullet k}$$

Distribution bivariée : exemple

Imaginons le lancé de deux dés équilibrés à 3 faces. On définit : $X =$ « score du plus petit dé » et $Y =$ « score du plus grand dé ». On va alors avoir la distribution bivariée suivante :

$X \backslash Y$	1	2	3
1	$\frac{1}{9}$	$\frac{2}{9}$	$\frac{2}{9}$
2	0	$\frac{1}{9}$	$\frac{2}{9}$
3	0	0	$\frac{1}{9}$

Les distributions marginales de X seront alors :

$$P(X = 1) = p_{11} + p_{12} + p_{13} = \frac{1}{9} + \frac{2}{9} + \frac{2}{9} = \frac{5}{9}$$

$$P(X = 2) = p_{21} + p_{22} + p_{23} = 0 + \frac{1}{9} + \frac{2}{9} = \frac{3}{9}$$

$$P(X = 3) = p_{31} + p_{32} + p_{33} = 0 + 0 + \frac{1}{9} = \frac{1}{9}$$

Pour Y , ce sera $P(Y = 1) = \frac{1}{9}$, $P(Y = 2) = \frac{3}{9}$ et $P(Y = 3) = \frac{5}{9}$.

Définition

Soit X et Y deux variables **continues**, avec valeurs dans $\mathbb{R}$. Leur **densité bvariée ou jointe**, donnée par $f_{XY}(x, y)$, se définit comme :

$$\int_a^b \int_c^d f_{XY}(x, y) \, dx dy := P(X \in [a, b] \text{ et } Y \in [c, d])$$

Elle doit vérifier :

$$f_{XY}(x, y) \geq 0 \quad \int_{-\infty}^{\infty} \sum_{-\infty}^{\infty} f_{XY}(x, y) = 1$$


On peut en déduire les **densité marginales** :

$$f_X(x) = \int_{-\infty}^{\infty} f_{XY}(x, y) dy$$

$$f_Y(y) = \int_{-\infty}^{\infty} f_{XY}(x, y) dx$$

Densité bivariée : exemple

Voici la distribution théorique (modélisée à partir d'un échantillon) de la longueur et de la hauteur des becs pour trois espèces de manchots.



Source : <https://seaborn.pydata.org/generated/seaborn.jointplot.html>

Définition

Deux variable X et Y sont **indépendantes** ssi :

$$\begin{aligned}\text{Cas discret : } P(X = x_j \text{ et } Y = y_k) &= P(X = x_j)P(Y = y_k) \\ p_{jk} &= p_{j\bullet}p_{\bullet k}\end{aligned}$$

$$\begin{aligned}\text{Cas continu : } P(X \in A \text{ et } Y \in B) &= P(X \in A)P(Y \in B) \\ f_{XY}(x, y) &= f_X(x)f_Y(y)\end{aligned}$$

Définition

Soit deux variables X et Y . Leur **covariance théorique** se définit comme :

$$\text{Cov}(X, Y) := E((X - E(X))(Y - E(Y))) = E(XY) - E(X)E(Y)$$

où :

$$E(XY) := \sum_{j=1}^{m_1} \sum_{k=1}^{m_2} p_{jk} \cdot x_j y_k \quad (\text{cas discret})$$

$$E(XY) := \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{XY}(x, y) \cdot xy \, dx dy \quad (\text{cas continu})$$

Si X et Y sont indépendantes, on a $E(XY) = E(X)E(Y)$ et donc $\text{Cov}(X, Y) = 0$.

Définition

Soit deux variables X et Y avec écart-types théoriques σ_X et σ_Y . Leur **corrélation théorique** se définit comme :

$$\text{Corr}(X, Y) = \rho_{XY} := \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

On a :

- $\text{Cov}(aX + b, cY + d) = ac\text{Cov}(X, Y)$
- $\text{Corr}(aX + b, cY + d) = \pm \text{Corr}(X, Y)$
- $-1 \leq \text{Corr}(X, Y) \leq 1$, avec les valeurs extrêmes impliquant une dépendance linéaire $Y = aX + b$.

Covariance et corrélation théorique : exemple

Reprenons $X = \ll \text{score du plus petit dé} \gg$ et $Y = \ll \text{score du plus grand dé} \gg$:

$X \backslash Y$	1	2	3	
1	$\frac{1}{9}$	$\frac{2}{9}$	$\frac{2}{9}$	$\frac{5}{9}$
2	0	$\frac{1}{9}$	$\frac{2}{9}$	$\frac{3}{9}$
3	0	0	$\frac{1}{9}$	$\frac{1}{9}$
	$\frac{1}{9}$	$\frac{3}{9}$	$\frac{5}{9}$	

$$E(X) = \frac{5}{9} \cdot 1 + \frac{3}{9} \cdot 2 + \frac{1}{9} \cdot 3 = \frac{14}{9} = 1.56 \quad E(X^2) = \frac{5}{9} \cdot 1^2 + \frac{3}{9} \cdot 2^2 + \frac{1}{9} \cdot 3^2 = \frac{26}{9} = 2.89$$

$$\text{Var}(X) = E(X^2) - E(X)^2 = 0.47$$

$$E(Y) = \frac{1}{9} \cdot 1 + \frac{3}{9} \cdot 2 + \frac{5}{9} \cdot 3 = \frac{22}{9} = 2.44 \quad E(Y^2) = \frac{1}{9} \cdot 1^2 + \frac{3}{9} \cdot 2^2 + \frac{5}{9} \cdot 3^2 = \frac{58}{9} = 6.44$$

$$\text{Var}(Y) = E(Y^2) - E(Y)^2 = 0.47$$

$$E(XY) = \frac{1}{9} \cdot 1 \cdot 1 + \frac{2}{9} \cdot 1 \cdot 2 + \frac{2}{9} \cdot 1 \cdot 3 + \frac{1}{9} \cdot 2 \cdot 2 + \frac{2}{9} \cdot 2 \cdot 3 + \frac{1}{9} \cdot 3 \cdot 3 = \frac{36}{9} = 4$$

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 0.1975 \quad \text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = 0.4211$$