

Méthodes Quantitatives I :

9. Théorèmes, lois dérivées et estimations

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 69 - 80

Exercices : 4.10 - 4.13

La loi des grands nombres et le théorème central limite

Calculs d'espérance et variance

Soit X une variable aléatoire, nous avons déjà vu que si on considère **la nouvelle variable aléatoire** suivante :

$$A = aX + b$$

On a alors :

$$E(A) = E(aX + b) = aE(X) + b$$

$$\text{Var}(A) = \text{Var}(aX + b) = a^2 \text{Var}(X)$$

Exemple : Si $X = \ll \text{somme de 2 jets de dés à 3 faces} \gg$ et $A = 2X + 1$, on a

Cas	(1, 1)	(1, 2), (2, 1)	(1, 3), (3, 1), (2, 2)	(2, 3), (3, 2)	(3, 3)
Distribution	$\frac{1}{9}$	$\frac{2}{9}$	$\frac{3}{9}$	$\frac{2}{9}$	$\frac{1}{9}$
Valeurs de X	2	3	4	5	6
Valeurs de A	5	7	9	11	13

On a $E(X) = 4$ et $\text{Var}(X) = 1.33$. En faisant le calcul, on obtient bien $E(A) = 2 \cdot 4 + 1 = 9$ et $\text{Var}(A) = 2^2 \cdot 1.33 = 5.33$.

Calculs d'espérance et variance

Si l'on a deux variables aléatoires X et Y , celle-ci peuvent être liées, c'est-à-dire qu'une **réalisation consiste en un couple de valeurs** (x, y) .

Soit la variable aléatoire $Z = X + Y$, on a alors :

$$E(Z) = E(X + Y) = E(X) + E(Y)$$

$$\text{Var}(Z) = \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

Exemple : Si $X = \ll \text{somme des 2 d3} \gg$, $Y = \ll \text{produit des 2 d3} \gg$, $Z = X + Y$, on a

Cas	(1, 1)	(1, 2), (2, 1)	(1, 3), (3, 1)	(2, 2)	(2, 3), (3, 2)	(3, 3)
Distribution	$\frac{1}{9}$	$\frac{2}{9}$	$\frac{2}{9}$	$\frac{1}{9}$	$\frac{2}{9}$	$\frac{1}{9}$
Valeurs de X	2	3	4	4	5	6
Valeurs de Y	1	2	3	4	6	9
Valeurs de Z	3	5	7	8	11	15

On a $E(X) = 4$, $E(Y) = 4$, $\text{Var}(X) = 1.33$, $\text{Var}(Y) = 5.78$ et $\text{Cov}(X, Y) = 2.67$.

En faisant le calcul, on obtient bien

$$E(Z) = 4 + 4 = 8$$

$$\text{Var}(Z) = 1.33 + 5.78 + 2 \cdot 2.67 = 12.44$$

Calculs d'espérance et variance

Si maintenant, on a n variables aléatoires $X_1, \dots, X_n$, on peut s'intéresser aux deux variables suivantes :

- La **somme des variables** $S_n := \sum_{j=1}^n X_j$
- La **moyenne des variables** $\bar{X}_n := \frac{1}{n} \sum_{j=1}^n X_j$

On aura

$$E(S_n) = \sum_{j=1}^n E(X_j)$$

$$E(\bar{X}_n) = \frac{1}{n} \sum_{j=1}^n E(X_j)$$

$$\text{Var}(S_n) = \sum_{j=1}^n \text{Var}(X_j) + \sum_{i \neq j} \text{Cov}(X_i, X_j)$$

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \left(\sum_{j=1}^n \text{Var}(X_j) + \sum_{i \neq j} \text{Cov}(X_i, X_j) \right)$$

C'est un cas de figure complexe à calculer.

Définition

Soient n variables aléatoires $X_1, \dots, X_n$. On dit que ces dernières sont **indépendantes et identiquement distribuées**, abrégé **i.i.d.**, ssi :

- X_i et X_j sont indépendantes pour tous i, j .
- Elles suivent la même loi, $X_j \sim L$.

Dans ce cas, toutes les variables possèdent la même espérance $E(X_j) = \mu$ et la même variance $\text{Var}(X_j) = \sigma^2$. L'indépendance assure que $\text{Cov}(X_i, X_j) = 0$ pour $i \neq j$.

Une réalisation de ces variables aléatoire $(x_1, \dots, x_n)$ peut être vu comme un **échantillon de taille n** contenant les valeurs d'une variable (une colonne d'un jeu de données) pour n individus.

Calculs d'espérance et variance pour des i.i.d.

Soient n variables aléatoires $X_1, \dots, X_n$ **i.i.d.**, avec $E(X_j) = \mu$ et $\text{Var}(X_j) = \sigma^2$. Les variables aléatoires **somme** S_n et **moyenne** $\bar{X}_n$ ont alors les espérances et variances suivantes :



$$E(S_n) = n\mu \quad E(\bar{X}_n) = \mu \quad \text{Var}(S_n) = n\sigma^2 \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}$$

La dernière égalité montre que la **moyenne d'un échantillon a une variance qui diminue proportionnellement avec la taille de celui-ci.**

En revanche, si l'on considère l'**écart-type de la moyenne** $\sqrt{\text{Var}(\bar{X}_n)}$, ce dernier diminue selon $\frac{1}{\sqrt{n}}$.

Calculs d'espérance et variance pour des i.i.d. : simulations

Soient $X_j = \ll \text{résultat du } j\text{-ème tirage d'un d6} \gg$. En effectuant des simulations, on obtient :



5 simulations pour la somme et moyenne après n tirages.

La précision d'une moyenne

Exemples :

- Un thermomètre a une précision de 1°C pour chaque mesure ; mesurer $n = 100$ fois une même température et prendre la moyenne des mesures permet d'améliorer la précision à $1^{\circ}\text{C}/\sqrt{100} = 0.1^{\circ}\text{C}$.
- Si, dans un sondage d'opinion portant sur $n = 100$ personnes, la précision de l'estimation (d'un vote « oui », p.ex.) était de 10%, alors l'extension du sondage à $n = 1000$ personnes permet de réduire cette marge d'erreur à $10\%/\sqrt{1000/100} = 10\%/\sqrt{10} = 3.2\%$.

En général, l'écart-type d'une moyenne diminue avec la taille n de l'échantillon, mais comme $1/\sqrt{n}$ seulement : il faut quatre fois plus d'observations pour être deux fois plus précis : **l'augmentation de la précision est possible, mais coûteuse.**

Théorème : loi des grands nombres (informel)

Soient $X_1, \dots, X_n$ des **variables i.i.d.**, avec $E(X_j) = \mu$.

Pour $n \rightarrow \infty$, on a :

$$E(\bar{X}_n) \rightarrow \mu$$


$$\text{Var}(\bar{X}_n) \rightarrow 0$$

Ainsi, la **moyenne empirique $\bar{X}_n$ converge vers la moyenne théorique μ .**

Si chaque valeur individuelle X_j peut être difficile à prédire (« micro-description aléatoire »), la moyenne de n valeurs, pour n grand, est à peu près connue d'avance (« macro-description déterministe ») : **bien que les caractéristiques individuelles sont pratiquement impossibles à prédire, leur incidence globale moyenne peut faire l'objet de prédictions.**

- Le taux de mortalité annuelle sur les routes suisses peut être prédit assez précisément d'une année à l'autre, au contraire de l'identité des futures victimes.
- Un casino sait qu'il fera du bénéfice sur une soirée comportant de nombreux joueurs, alors que le gain ou la perte pour chaque joueur individuellement est plus difficile à prévoir.

La loi des grands nombres : simulations



La moyenne empirique des échantillons converge vers 3.5 pour $U_{\{1,2,3,4,5,6\}}$, 5 pour $N(5, 10)$ et $1/2$ pour $\text{Exp}(2)$.

Maintenant, qu'en est-il des lois de S_n et $\bar{X}_n$?

Théorème central limite (informel)

Soient $X_1, \dots, X_n$ des **variables i.i.d de loi quelconque** avec $E(X_j) = \mu$ et $\text{Var}(X_j) = \sigma^2$.







Pour n grand, on a :

$$S_n \sim N(n\mu, n\sigma^2)$$

$$\bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Le théorème central limite

Pour n lancés d'un d6



Le théorème central limite : exemple d'application

Quelle est la probabilité d'obtenir 65 piles ou plus en 100 lancers d'une pièce ?

On peut modéliser le problème avec $X = \ll \text{nombre de piles en 100 lancers} \gg$ et donc $X \sim B(100, 1/2)$. Il faudra alors calculer :

$$P(X \geq 65) = \sum_{k=65}^{100} \binom{100}{k} \frac{1}{2^{100}}$$

ce qui est long...

En revanche, si l'on pose

$$X_j = \begin{cases} 1 & \text{si pile au } j\text{-ème lancer} \\ 0 & \text{sinon} \end{cases}$$

et que l'on note $\bar{X}_{100}$ la moyenne sur les 100 lancés, notre probabilité sera alors :

$$P(X \geq 65) = P(\bar{X}_{100} \geq 0.65)$$

Le théorème central limite : exemple d'application

On peut alors approximer $\bar{X}_{100}$ par une loi normale. Par le théorème central limite, on aura

$$\bar{X}_{100} \sim N\left(0.5, \frac{1/4}{100}\right)$$

car $\text{Var}(X_j) = \frac{1}{2}(1 - \frac{1}{2}) = 1/4$ (Loi de Bernouilli avec $p = 1/2$). On a

$$\begin{aligned}P(\bar{X}_{100} \geq 0.65) &= P\left(\frac{\bar{X}_{100} - 0.5}{0.05} \geq \frac{0.65 - 0.5}{0.05}\right) \\&= P(\bar{X}_{100}^s \geq 3) \\&= 1 - \phi(3) = 0.00135\end{aligned}$$

La valeur exacte est 0.00176 (calcul numérique).

Les lois dérivées de la loi normale

Les lois dérivées de la loi normale : pourquoi ?

La plupart des distributions des **indices statistiques** (moyenne empirique, χ^2 , F-ratio) calculés sur un échantillon sont **des dérivés de la loi normale** (si n grand).

Il s'agira donc de comparer les valeurs obtenues sur l'échantillon avec leur **loi théorique**.

Les lois dérivées de la loi normale : formulation générale

La **formulation générale** de ces lois sera la suivante :

Soient q **variables aléatoires** $X_1, X_2, \dots, X_q$ **i.i.d.** suivant une **loi normale**, i.e.

$$X_j \sim N(\mu, \sigma^2)$$

On va chercher la loi de la variable Y qui est définie avec

$$Y \sim f(X_1, X_2, \dots, X_q)$$

où $f(X_1, X_2, \dots, X_q)$ est une fonction particulière des variables originales.


Définition

Soient q variable indépendantes $X_1, X_2, \dots, X_q$ avec $X_j \sim N(0, 1)$. La variable Y définie comme

$$Y := X_1^2 + X_2^2 + \dots + X_q^2$$

suit une **loi du chi-carré à q degrés de liberté**. On le note $Y \sim \chi^2(q)$.

La loi du chi-carré



Source : https://en.wikipedia.org/wiki/Chi-squared_distribution

- Son espérance est $E(Y) = q$.
- Sa variance théorique est $\text{Var}(Y) = 2q$.

La loi du chi-carré : application

Le **chi2** mesure la différence entre une table de contingence de taille $m_1 \times m_2$ et sa table théorique sous indépendance associée

	A	B	C	
F	5	5	1	11
H	2	4	3	9
	7	9	4	20

← chi2 →

	A	B	C	
F	3.85	4.95	2.2	11
H	3.15	4.05	1.8	9
	7	9	4	20

Sous hypothèse d'indépendance entre lignes et colonnes, on sait que :

$$\text{chi2} \sim \chi^2((m_1 - 1)(m_2 - 1))$$



Définition

Soient $Y_1 \sim \chi^2(q_1)$ et $Y_2 \sim \chi^2(q_2)$ deux variables indépendantes. La variable Z définie comme

$$Z := \frac{Y_1/q_1}{Y_2/q_2}$$

suit une **loi du F** ou **loi de Fisher** à q_1 et q_2 degrés de liberté. On le note $Z \sim F(q_1, q_2)$.

La loi du F



Source : <https://en.wikipedia.org/wiki/F-distribution>

- Son espérance est uniquement définie pour $q_2 > 2$ et est égale à $E(Z) = \frac{q_2}{q_2 - 2}$.
- Sa variance théorique est uniquement définie pour $q_2 > 4$ et est égale à $\text{Var}(Z) = \frac{2n_2^2(n_1 + n_2 - 2)}{n_1(n_2 - 2)^2(n_2 - 4)}$.

Si l'on possède les réalisations d'une variable numérique X et d'une variable catégorielle Y à m modalités sur un échantillon de n personnes, alors le **F-ratio** s'obtient avec

$$F := \frac{\frac{\text{var}_B(x)}{m-1}}{\frac{\text{var}_W(x)}{n-m}}$$

Sous hypothèse d'indépendance entre X et Y , on sait que :

$$F \sim F(m-1, n-m)$$



Définition

Soient $X \sim N(0, 1)$ et $Y \sim \chi^2(q)$ deux variables indépendantes. La variable S définie comme

$$S := \frac{X}{\sqrt{Y/q}}$$

suit une **loi du t** ou **loi de Student à q degrés de liberté**. On le note $S \sim t(q)$.

La loi du t



Source : https://en.wikipedia.org/wiki/Student%27s_t-distribution

- Son espérance est égale à $E(S) = 0$.
- Sa variance théorique est uniquement définie pour $q > 2$ et est égale à $\text{Var}(S) = \frac{q}{q-2}$.
- La loi de Student est utilisée un peu comme la loi normale, mais elle est plus appropriée dans le cas où on a **un petit échantillon** et que **la variance théorique est inconnue**. Elle possède une variance plus élevée.
- Lorsque q devient élevé, elle s'approche de la loi normale centrée réduite.


Estimations ponctuelles et intervalles de confiance

Modèles et observations

En étudiant les lois de probabilité, on se place du côté des **modèles**, en supposant que ceux-ci sont **connus**.


En réalité, seules les **observations** sont connues et le modèle est **inconnu**.

L'enjeu consiste à **inférer le modèle**, c'est-à-dire le caractériser à partir des observations.



Variables aléatoires et échantillon

On peut supposer que notre échantillon $x_1, \dots, x_n$ contient des **réalisations** de variables $X_1, \dots, X_n$ i.i.d. :



On pourrait vouloir **estimer des paramètres théoriques des X_j** , comme leur **espérance μ** ou leur **variance σ^2** , à partir des **données de l'échantillon**.

D'une manière générale, on aimerait définir un **estimateur** $\hat{\theta}$ de la manière suivante :

$$\hat{\theta}(x_1, \dots, x_n) = \ll \text{calcul sur l'échantillon } x_1, \dots, x_n \gg$$

pour **estimer un paramètre théorique θ des X_j** . On appelle cela, l'**estimation ponctuelle**.

Notons que $\hat{\theta}(X_1, \dots, X_n)$ **est une variable aléatoire**.

Une propriété importante de notre estimateur est qu'il devrait vérifier

$$E(\hat{\theta}(X_1, \dots, X_n)) = \theta$$

c'est-à-dire que ce soit un **estimateur sans biais**.

Si l'on prends la **moyenne empirique de l'échantillon** :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

il s'agit d'une **réalisation de la moyenne des variables aléatoires** :

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

On a vu alors que :

$$E(\bar{X}_n) = \mu$$

c'est donc d'un **estimateur sans biais de l'espérance**.

Estimateur de la variance

La **variance empirique de l'échantillon** :

$$\text{var}(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \left(\frac{1}{n} \sum_{i=1}^n x_i \right)^2$$

est **réalisation de la variable aléatoire** V_n , définie par :

$$V_n = \frac{1}{n} \sum_{i=1}^n X_i^2 - \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2$$

On peut calculer que :

$$E(V_n) = \frac{n-1}{n} \sigma^2$$

c'est donc un **estimateur biaisé de la variance théorique** σ^2 (la variance est sous-estimée).

Un **estimateur non-biaisé de la variance théorique** est donc :

$$\widehat{\text{var}}(x) = \frac{n}{n-1} \text{var}(x) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

qui est une réalisation de $\frac{n}{n-1} V_n$. On a alors bien :

$$E \left(\frac{n}{n-1} V_n \right) = \sigma^2$$

La loi des grands nombres nous dit que **la moyenne empirique**

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

est un **bon estimateur** de la moyenne théorique μ , surtout si l'échantillon est grand.

Seulement, en cas d'échantillon de taille limitée, on préférera donner un **intervalle autour de cette moyenne empirique qui contiendra, avec une forte probabilité, la moyenne théorique.**

Grâce au **théorème central limite**, on sait que la **variable aléatoire moyenne**

$$\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i$$


suit une loi normale avec :

$$\bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Supposons, pour commencer, que l'on connaisse σ^2 .

Taille de l'intervalle

D'un point de vue théorique, on peut donc trouver une **distance d** telle qu'il y ait **95% de chances que variable $\bar{X}_n$ soit à d ou plus proche de μ** .



Trouver d , tel que $P(\mu - d < \bar{X}_n < \mu + d) = 95\%$

Il s'agit un **problème de quantiles**. Si $U \sim N(0, 1)$, on a :

$$P(-d^c < U < d^c) = 2\Phi(d^c) - 1 = 0.95$$

$$\Phi(d^c) = 0.975$$

$$d_c = u_{0.975}$$

Cette distance d est donc, sur la loi $N(\mu, \frac{\sigma^2}{n})$:

$$d = \frac{\sigma}{\sqrt{n}} d^c = \frac{\sigma}{\sqrt{n}} u_{0.975}$$

On a donc :

$$P\left(\mu - \frac{\sigma}{\sqrt{n}}u_{0.975} < \bar{X}_n < \mu + \frac{\sigma}{\sqrt{n}}u_{0.975}\right) = 0.95$$

Ce qui veut dire que, par analogie :

$$P\left(\bar{X}_n - \frac{\sigma}{\sqrt{n}}u_{0.975} < \mu < \bar{X}_n + \frac{\sigma}{\sqrt{n}}u_{0.975}\right) = 0.95$$

Définition

Soit un échantillon $x_1, \dots, x_n$ issu de $X_1, \dots, X_n$ i.i.d avec loi inconnue, où μ **inconnu** et σ^2 **connue**. Pour une **erreur** α ($0 < \alpha < 1$), on a :

$$P\left(\bar{x}_n - \frac{\sigma}{\sqrt{n}}u_{(1-\frac{\alpha}{2})} < \mu < \bar{x}_n + \frac{\sigma}{\sqrt{n}}u_{(1-\frac{\alpha}{2})}\right) = 1 - \alpha$$

l'intervalle

$$[\bar{x}_n - d, \bar{x}_n + d] \quad \text{avec} \quad d = \frac{\sigma}{\sqrt{n}}u_{(1-\frac{\alpha}{2})}$$

s'appelle **l'intervalle de confiance $(1 - \alpha)$ pour la moyenne avec variance connue**.

Les intervalles de confiance, variance connue : exemple

On sait que que la taille des femmes en suisse à une écart-type théorique de $\sigma = 7$. Soit notre échantillon avec $n = 10$:

156, 160, 161, 162, 163, 165, 166, 168, 176, 177

avec $\bar{x} = 165.4$.

Pour calculer l'intervalle de confiance 95% sur la moyenne, c'est-à-dire $\alpha = 0.05$. On commence par trouver :

$$u_{(1-\frac{\alpha}{2})} = u_{0.975} = 1.96$$

On aura donc :

$$d = \frac{\sigma}{\sqrt{n}} u_{0.975} = \frac{7}{\sqrt{10}} 1.96 = 4.34$$

Ce qui veut dire que l'intervalle :

$$P(165.4 - 4.34 < \mu < 165.4 + 4.34) = P(161.06 < \mu < 169.74) = 95\%$$

On a 95% de chances de trouver μ dans $[161.06, 169.74]$.

En général, on ne connaît pas σ^2 et on va **l'estimer avec la variance empirique s^2** (biaisée) :

$$s^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \left(\frac{1}{n} \sum_{i=1}^n x_i \right)^2$$

Dans ce cas, on préférera utiliser une **loi de Student avec $(n - 1)$ degrés de liberté**, qui prend en compte le fait que la variance empirique **sous-estime** la variance théorique.

Définition

Soit un échantillon $x_1, \dots, x_n$ issu de $X_1, \dots, X_n$ i.i.d avec loi inconnue, avec μ et σ inconnus. Pour une erreur α ($0 < \alpha < 1$), on a :

$$P\left(\bar{x}_n - \frac{s}{\sqrt{n-1}} t_{(1-\frac{\alpha}{2})}[n-1] < \mu < \bar{x}_n + \frac{s}{\sqrt{n-1}} t_{(1-\frac{\alpha}{2})}[n-1]\right) = 1 - \alpha$$

où s est l'écart-type empirique. L'intervalle

$$[\bar{x}_n - d, \bar{x}_n + d] \quad \text{avec} \quad d = \frac{s}{\sqrt{n-1}} t_{(1-\frac{\alpha}{2})}[n-1]$$

s'appelle **l'intervalle de confiance $(1 - \alpha)$ pour la moyenne avec variance inconnue.**

Les intervalles de confiance, variance inconnue : exemple

On récolte le temps moyen par jour (en h) passé sur internet (durant les loisirs) dans l'échantillon $n = 15$ suivant :

0.1, 1.9, 1.9, 2.5, 2.7, 2.9, 3.1, 3.6, 4.2, 4.7, 4.8, 5.0, 5.4, 6.4, 7.6

avec $\bar{x} = 3.79$ et $s = 3.49$.

Pour calculer l'intervalle de confiance 95% sur la moyenne, c'est-à-dire $\alpha = 0.05$. On commence par trouver :

$$t_{(1-\frac{\alpha}{2})}[n-1] = t_{0.975}[14] = 2.145$$

On aura donc :

$$d = \frac{s}{\sqrt{n-1}} t_{0.975}[14] = \frac{3.49}{\sqrt{14}} 2.145 = 2.00$$

Ce qui veut dire que l'intervalle :

$$P(3.79 - 2 < \mu < 3.79 + 2) = P(1.79 < \mu < 5.79) = 95\%$$

On a 95% de chances de trouver μ dans $[1.79, 5.79]$.

Les intervalles de confiance : proportion

Définition

Soit un échantillon $x_1, \dots, x_n$ issu de $X_1, \dots, X_n$ **variable binaires i.i.d.** avec $P(X_j = 1) = p$ **inconnu**. Pour une **erreur** α ($0 < \alpha < 1$), on a :

$$P \left(f - \sqrt{\frac{f(1-f)}{n}} u_{(1-\frac{\alpha}{2})} < p < f + \sqrt{\frac{f(1-f)}{n}} u_{(1-\frac{\alpha}{2})} \right) = 1 - \alpha$$

où $f = \frac{1}{n} \sum_i x_i$ est la **proportion empirique de 1**. L'intervalle

$$[f - d, f + d] \quad \text{avec} \quad d = \sqrt{\frac{f(1-f)}{n}} u_{(1-\frac{\alpha}{2})}$$

s'appelle **l'intervalle de confiance $(1 - \alpha)$ pour une proportion**.

Les intervalles de confiance, proportion : exemple

On interroge 100 futurs votants d'une certaine initiative fédérale, et 58 personnes se déclarent favorables. On a donc $n = 100$ et $f = 0.58$.

On veut chercher l'intervalle de confiance 99% pour la vraie proportion p , c'est-à-dire avec $\alpha = 0.01$. On commence par trouver :

$$u_{(1-\frac{\alpha}{2})} = u_{0.995} = 2.58$$

On aura donc :

$$d = \sqrt{\frac{f(1-f)}{n}} u_{0.995} = \sqrt{\frac{0.58 \cdot 0.42}{100}} 2.58 = 0.1273$$

Ce qui veut dire que l'intervalle :

$$P(0.58 - 0.1273 < p < 0.58 + 0.1273) = P(0.4527 < p < 0.7073) = 99\%$$

On a 99% de chances de trouver p dans [45.27%, 70.73%].