

Méthodes Quantitatives I :

10. Introduction à l'inférence statistique

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 81 - 97

Exercices : 5.1 - 5.3, 5.5

Formule de Bayes pour l'induction

Un **modèle probabiliste** peut s'écrire de la manière suivante

$$P(D|H)$$

où

- D sont les **données**, c'est-à-dire les observations.
- H est l'**hypothèse**, la **théorie** ou le **modèle**.

$P(D|H)$ s'interprète comme les probabilités d'observer D si l'on suppose H vrai.

Tous les modèles sont **a priori (avant d'observer les données) admissibles** à condition que :

$$P(D|H) \geq 0 \quad \sum_D P(D|H) = 1$$

Les données

Les **données** D constituent ce qu'on observe, cela peut être :

- La distribution des espèces végétales dans un étang.
- Les classes sociales au sein d'un collège.
- Les enregistrements météo d'une région donnée.

En statistique, ce n'est pas forcément les données sur lesquelles porte notre intérêt, pas plus que les données D' :

- La distribution des espèces végétales dans un *autre* étang.
- Les classes sociales au sein d'un *autre* collège.
- Les enregistrements météo d'une *autre* région donnée.

Mais plutôt sur la question de la **généralisation** :

Dans quelle mesure les régularités observées dans l'échantillon D sont susceptibles de se retrouver dans un autre échantillon D' ?

En supposant un **modèle H** , la question précédente peut se reformuler de la manière suivante :

Dans quelle mesure le modèle H décrit correctement l'échantillon D , et peut donc être capable de décrire d'autres échantillons analogues D' ?

L'intérêt porte sur H et non pas sur D .

La question est maintenant la suivante : comment dire quelque chose de H (inobservable) à partir des observations D ?

C'est la question de l'**induction** ou **inférence statistique**.

La règle de Bayes pour l'induction

Le problème de l'**induction** peut s'écrire grâce à la **formule de Bayes**

$$P(H|D) = \frac{P(D|H)P(H)}{P(D)}$$

où

- $P(H)$ est la **probabilité a priori** que H soit vraie.
- $P(D|H)$ est la **probabilité d'observer D en supposant H vraie**.
- $P(D)$ est la **probabilité d'observer D indépendamment du modèle**.
- $P(H|D)$ est la **probabilité a posteriori** que H soit vraie après avoir observé les données.

En toute généralité, ce problème est **difficile** ! En effet :

- Il faut définir une **croyance a priori $P(H)$** dans le modèle.
- On peut écrire $P(D) = \sum_{H'} P(D|H')P(H')$, mais il faut donc considérer **tous les modèles possibles H'** .

On va généralement **restreindre les modèles possibles**.

La règle de Bayes pour l'induction : exemple 1

Une personne se sent fatiguée depuis quelques jours (D). Est-ce le signe d'une maladie cachée (H) ? On a :

$$P(\text{maladie}|\text{fatigue}) = \frac{P(\text{fatigue}|\text{maladie})P(\text{maladie})}{P(\text{fatigue})}$$

La chance que ce soit une maladie est donc :

- Plus élevée si la maladie a des chances d'entraîner la fatigue ($P(\text{fatigue}|\text{maladie})$ élevée).
- Plus élevée si la personne est souvent malade ($P(\text{maladie})$ élevée).
- Plus faible si la personne est souvent fatiguée, peu importe les raisons ($P(\text{fatigue})$ élevée).

La règle de Bayes pour l'induction : exemple 2

La règle de Bayes pour l'induction permet des calculs si l'on **restreint les modèles probabilistes**.

Soit une urne qui contient (de très nombreuses) billes. On suppose les deux hypothèses suivantes :

- H_1 : « toutes les billes sont noires »
- H_2 : « la moitié des billes sont noires, les autres blanches »

H_1 est **déterministe**, alors que H_2 est **probabiliste**.

On tire une seule bille, elle est noire. Que penser de H_1 et H_2 ?

La règle de Bayes pour l'induction : exemple 2

La règle de Bayes exige des **probabilité des modèles à priori** (avant les données). Comme nous n'avons pas de préférence à priori, on va supposer :

$$P(H_1) = P(H_2) = \frac{1}{2}$$

Quelles sont les **probabilités des modèles à posteriori**, après avoir tiré une bille noire ?

$$\begin{aligned} P(H_1|\text{noire}) &= \frac{P(\text{noire}|H_1)P(H_1)}{P(\text{noire}|H_1)P(H_1) + P(\text{noire}|H_2)P(H_2)} \\ &= \frac{1 \cdot \frac{1}{2}}{1 \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{2}} = \frac{0.5}{0.75} = \frac{2}{3} \end{aligned}$$

Et par complémentarité $P(H_2|\text{noire}) = \frac{1}{3}$.

Notre croyance en H_1 s'est renforcée !

La règle de Bayes pour l'induction : exemple 2

Imaginons maintenant que l'on observe D : « n billes noires tirées », comment vont évoluer les croyances en H_1 et H_2 ? On trouve :

$$P(H_1|D) = \frac{P(H_1)}{P(H_1) + \left(\frac{1}{2}\right)^n (1 - P(H_1))}$$
$$P(H_2|D) = \frac{P(H_2)}{2^n(1 - P(H_2)) + P(H_2)}$$

Si nos a priori initiaux $P(H_1)$ et $P(H_2)$ sont dans $]0, 1[$, on aura :


$$\lim_{n \rightarrow \infty} P(H_1|D) = 1$$

$$\lim_{n \rightarrow \infty} P(H_2|D) = 0$$

En revanche, si $P(H_1) = 0$, $P(H_2) = 1$ ou $P(H_1) = 1$, $P(H_2) = 0$, rien ne bouge !

La règle de Bayes pour l'induction : exemple 2

Évolution de $P(H_1|D)$ et $P(H_2|D)$ en fonction de D : « n de billes noires tirées », dans les cas $P(H_1) = 0.5$, $P(H_1) = 0.8$, $P(H_1) = 0.1$ et $P(H_1) = 0$.



La règle de Bayes pour l'induction : exemple 2

La convergence $\lim_{n \rightarrow \infty} P(H_1|D) = 1$ a lieu pour autant que $P(H_1) > 0$.

Si l'on pose $P(H_1) = 0$, alors $P(H_1|D) = 0$ quelle que soit la taille n des observations D . Si quelqu'un n'accorde au départ aucun crédit à une théorie, alors aucun fait ultérieur ne pourra le faire changer d'avis (idem pour $P(H_1) = 1$).

La règle de Bayes permet ainsi de décrire aussi bien :

- Le phénomène de **persuasion raisonnée** (pour $0 < P(H) < 1$)
- Le phénomène de dogmatisme ou **fanatisme épistémologique** (pour $P(H) = 0$ ou $P(H) = 1$).

La règle de Bayes pour l'induction : exemple 2

Si l'on avait observé D' : « on tire une bille blanche », alors, instantanément, $P(H_1|D') = 0$ et $P(H_2|D') = 1$

En résumé :

- Un modèle déterministe peut être réfuté par une seule contre-observation.
- Un modèle probabiliste n'est réfutable au sens strict que par une infinité d'observations.

Un ensemble fini d'observations D ne peut que réduire la croyance a posteriori $P(H|D)$ que l'on peut mettre dans un modèle probabiliste H , sans l'annuler complètement.

Le modèle probabiliste H ne peut que devenir invraisemblable ($P(H|D)$ très petit).

Face à des modèles probabilistes (la règle en science, plutôt que l'exception), on ne peut jamais garantir que l'inférence (i.e. la détermination du « vrai modèle » H à partir des données) sera correcte.

Cependant, des stratégies efficaces, i.e. minimisant le risque d'erreur, ont pu être développées :

- Dans le contexte des **familles de modèles** où il est question d'estimer les paramètres d'une classe de distributions théoriques (typiquement la moyenne μ et/ou la variance σ^2 d'une loi normale $N(\mu, \sigma^2)$).
- Dans le contexte d'une **compétition entre $q \geq 2$ modèles** $H_1, H_2, \dots, H_q$ dont l'un est supposé être le vrai modèle.

La classification

La classification : lien avec modèle et observation

Un cadre où m modèles sont en compétition est celui de la **classification**. On peut alors supposer que chaque observation vient potentiellement d'un modèle différent :

H_1 : l'observation fait partie de la classe 1

H_2 : l'observation fait partie de la classe 2

$\vdots$

H_m : l'observation fait partie de la classe m

La classification se fait à l'aide d'une méthode ou algorithme appelé **classifieur**, qui place les différentes observations dans les groupes 1 à m . Nos données sont donc les résultats du classifieur :

D_1 : l'observation a été classée comme classe 1

D_2 : l'observation a été classée comme classe 2

$\vdots$

D_m : l'observation a été classée comme classe m

Un bon classifieur est celui qui maximise les probabilités $P(D_1|H_1)$, $P(D_2|H_2)$, $\dots$, $P(D_m|H_m)$.

La table de confusion

Souvent, dans le cas de la classification, on connaît les véritables classes des individus. On peut donc définir la table suivante :

Définition

Lors d'une classification de n objets en m classes, la **table ou matrice de confusion** $N = (n_{jk})$ est le tableau où l'on comptabilise :

$n_{jk} :=$ nombre d'objets de véritable classe j classés dans la classe k .

Ainsi, les **marges** contiennent :

- Sur les lignes $n_{j\bullet}$, le nombre d'objets de véritables classes j .
- Sur les colonnes $n_{\bullet k}$, le nombre d'objets classés comme k .

Les effectifs sur la **diagonale** donnent le nombre de catégories correctement identifiées, alors que les éléments **hors-diagonale** sont les attributions incorrectes ou confusions.

La table de confusion : exemple

On a demandé à un certain nombre de personnes de dire quelques phrases sur un ton qui devait évoquer l'une des 5 émotions suivantes : **normal**, **happy**, **angry**, **sad** et **afraid** (Petrushin 1999). Chaque enregistrement a été converti en quelques caractéristiques associées au signal audio. Après avoir entraîné un réseau de neurones (classifieur), on a demandé à ce dernier de classifier la tonalité émotionnelle de 700 nouveaux enregistrements :

stimulus j \ réponse k	normal	happy	angry	sad	afraid
normal	93	4	10	25	8
happy	17	86	14	6	17
angry	15	7	101	8	9
sad	16	1	7	96	20
afraid	17	13	7	34	69

Les lignes sont les stimuli (vraies catégories) et les colonnes les réponses (catégories attribuées).

Définition

Dans une matrice de confusion $N = (n_{jk})$, la **proportion d'accord** p^{accord} mesure le taux global de classification correcte, à savoir :

$$p^{\text{accord}} := \frac{\sum_{j=1}^m n_{jj}}{n_{jk}} = \frac{\sum_{j=1}^m n_{jj}}{n_{\bullet\bullet}}$$

On peut aussi calculer le **taux de classification correcte pour chaque vrai classe j** avec $\frac{n_{jj}}{n_{j\bullet}}$.

Dans notre exemple, on a :

$$p^{\text{accord}} = \frac{445}{700} = 63.6\%$$

Et pour chaque classe :

stimulus j	normal	happy	angry	sad	afraid
taux classification correcte	66.4%	61.4%	72.1%	68.6%	49.3%

La proportion d'objets correctement classés par hasard

Les taux donnés précédemment **surestiment** les performances du classificateur. En effet, on peut également bien classer des objets par hasard.

Définition

L'**effectif théorique de classification aléatoire** associé à une matrice de confusion $N = (n_{jk})$ est donné par :

$$n_{jk}^{\text{theo}} := \frac{n_{j\bullet} \cdot n_{\bullet k}}{n_{\bullet\bullet}}$$

On peut donc calculer la **proportion d'objets correctement classés par hasard** P^{hasard} à l'aide de cette table. On obtient :

$$P^{\text{hasard}} = \frac{\sum_{j=1}^m n_{j\bullet} \cdot n_{\bullet j}}{n_{\bullet\bullet}^2}$$

Dans notre exemple, on trouve :

$$\begin{aligned} P^{\text{hasard}} &= \frac{140 \cdot 158 + 140 \cdot 111 + 140 \cdot 139 + 140 \cdot 169 + 140 \cdot 123}{700^2} \\ &= \frac{98000}{700^2} = 20.0\% \end{aligned}$$

Définition

Le **kappa de Cohen**, noté κ , vise à mesurer la proportion d'attributions correctes non dues au hasard. Il se définit avec

$$\kappa := \frac{p_{\text{accord}} - p_{\text{hasard}}}{1 - p_{\text{hasard}}}$$

Par construction :

- $\kappa > 0$ indique une performance meilleur que le hasard.
- $\kappa \simeq 0$ indique une performance similaire que le hasard.
- $\kappa < 0$ indique une performance pire que le hasard.

La valeur maximale $\kappa = 1$ est obtenue ssi $p_{\text{accord}} = 1$.

Dans notre exemple, $\kappa = \frac{0.636 - 0.2}{1 - 0.2} = 0.545$.

Classification binaire

Le cas de la **classification binaire** est très répandu : tout « organisme sensible » l'effectue sans cesse sur son environnement :

- est-il ou non en sécurité dans la situation actuelle ?
- peut-il faire confiance ou non à telle personne ?
- tel candidat à un examen ou une embauche doit-il être recalé, ou non ?
- le voyant suspect qui apparaît sur un tableau de bord doit-il être pris au sérieux ou non ?
- le document proposé par un moteur de recherche se révélera-t-il pertinent ou non pour la recherche ?
- faut-il déclarer coupable, ou non, un suspect dans une affaire de meurtre ?

Les **situations réelles** peuvent être de deux types :

- Les unes possèdent, réellement, une certaine caractéristique spécifique : **présence** ou **signal**.
- Les autres ne possèdent pas cette caractéristique : **absence** ou **bruit**.

La **perception** d'un signal ou non amène alors à **deux types d'erreurs** :

- Détecter à tort la caractéristique alors qu'elle est absente : c'est l'**erreur de première espèce** ou une **fausse alarme**.
- Ne pas détecter la caractéristique alors qu'elle est présente : c'est l'**erreur de seconde espèce** ou un **manqué**.

Table de confusion binaire

On peut formaliser les états réels et les perceptions dans la **matrice de confusion binaire** suivante :

- $x = \ll \text{état réel} \gg$
 - $x = 0$: signal réellement absent ou **vrai négatif**.
 - $x = 1$: signal réellement présent ou **vrai positif**.
- $y = \ll \text{perception} \gg$
 - $y = 0$: **signal non perçu**.
 - $y = 1$: **signal perçu**.

		y = "perception" ou "décision"		
		y = 0 (bruit)	y = 1 (signal)	
x = "état réel"	x = 0 (bruit)	n_{00} : vrais négatifs	n_{01} : fausses alarmes = faux positifs	$n_{0\bullet}$
	x = 1 (signal)	n_{10} : manqués = faux négatifs	n_{11} : vrais positifs	$n_{1\bullet}$
		$n_{\bullet 0}$	$n_{\bullet 1}$	$n_{\bullet\bullet}$

Définition

Soit une matrice de confusion binaire :

$$N = \begin{array}{|c|c|} \hline n_{00} & n_{01} \\ \hline n_{10} & n_{11} \\ \hline \end{array}$$

La **probabilité de l'erreur de première espèce**, notée α , se calcule avec :

$$\alpha := \frac{n_{01}}{n_{00} + n_{01}} = \frac{\text{faux positifs}}{\text{vrais négatifs} + \text{faux positifs}}$$

La **probabilité de l'erreur de la deuxième espèce**, notée β , se calcule avec :

$$\beta := \frac{n_{10}}{n_{10} + n_{11}} = \frac{\text{faux négatifs}}{\text{vrais positifs} + \text{faux négatifs}}$$

Erreurs de la première et seconde espèce : exemple

Soit une matrice de confusion binaire associée à une recherche parmi 2500 documents :

retourné par le moteur de recherche → statut réel du document ↓	<i>non retourné</i>	<i>retourné</i>	total
<i>non pertinent</i>	$n_{00} = 2300$	$n_{01} = 150$	2450
<i>pertinent</i>	$n_{10} = 10$	$n_{11} = 40$	50
total	2310	190	2500

La probabilité qu'un document non pertinent soit malgré tout retourné par le moteur de recherche (erreur de première espèce) est de $\alpha = 150/2450 = 6.1\%$.

La probabilité qu'un document pertinent ne soit pas retourné (erreur de seconde espèce) est de $\beta = 10/50 = 20\%$.

Erreurs de la première et seconde espèce dans l'inférence

Lorsque l'on fait de l'inférence statistique, on va fréquemment opposer deux hypothèses, dont une seule est vraie :

- H_0 , l'**hypothèse nulle**, décrit une « situation inintéressante » : pas de différences entre les groupes, pas de dépendance entre variables, etc. H_0 est assimilé à du **bruit**.
- H_1 , l'**hypothèse alternative**, décrit une « situation intéressante » : existence de différences entre les groupes, de dépendance entre variables, etc. H_1 est assimilé à du **signal**.

Sur la base des données D , on va rejeter ou non H_0 (i.e on accepte ou non H_1) :

- L'erreur de **première espèce** consiste à rejeter H_0 à tort = « fausse alarme ».
- L'erreur de **seconde espèce** consiste à accepter H_0 à tort = « manqué ».

Règle de décision

La **probabilité d'erreur de première espèce** est notée α :

$$\alpha = P(\text{rejeter } H_0 | H_0 \text{ vrai})$$

La **probabilité d'erreur de deuxième espèce** est notée β :

$$\beta = P(\text{accepter } H_0 | H_0 \text{ faux})$$

Nous le verrons plus tard, mais on utilise une **règle de décision**, qui se base sur les données, pour rejeter ou non H_0 . Elle prend la forme suivante :

- Si $d(D) > d_c$, on rejette H_0 (on accepte H_1).
- Si $d(D) \leq d_c$, on accepte H_0 (on rejette H_1).

où $d(D)$ est la **variable de décision**, qui dépend de données D , et d_c un **seuil critique**, fixé par l'utilisateur.

Règle de décision : exemple

On suspecte une pièce d'être truquée au sens où sa probabilité p d'obtenir pile ne serait pas de $p = 0.5$, mais de $p = 0.9$. On lance 6 fois la pièce, et on décide (arbitrairement) que la pièce est truquée si le nombre de pile vaut 5 ou 6. On a donc :

- $H_0 : p = 0.5$ (pièce normale)
- $H_1 : p = 0.9$ (pièce truquée)
- $d(D)$ = nombre de piles en 6 lancers
- $d_c = 4$ (on rejette H_0 si $d(D) > 4$)

Règle de décision : exemple

On a pour l'erreur de la première espèce :

$$\begin{aligned}\alpha &= P(\text{rejeter } H_0 | H_0 \text{ vrai}) = P(d(D) > 4 | p = 0.5) \\ &= \binom{6}{5} 0.5^6 + \binom{6}{6} 0.5^6 \\ &= 0.109 = 10.9\%\end{aligned}$$

Et pour l'erreur de deuxième espèce :

$$\begin{aligned}\alpha &= P(\text{accepter } H_0 | H_0 \text{ faux}) = P(d(D) \leq 4 | p = 0.9) \\ &= 1 - \binom{6}{5} 0.9^5 \cdot 0.1 + \binom{6}{6} 0.9^6 \\ &= 0.114 = 11.4\%\end{aligned}$$

Erreurs de première et seconde espèce : tableau général

Les erreurs de première et de seconde espèce et leurs probabilités α et β :

		décision (inférence statistique)	
		H_0 vrai	H_1 vrai
état réel	H_0 vrai	OK $1 - \alpha$	erreur de la première espèce $\alpha = P(d(D) > d_c H_0 \text{ vrai})$
	H_0 faux	erreur de la deuxième espèce $\beta = P(d(D) \leq d_c H_0 \text{ faux})$	OK $1 - \beta$