

Méthodes Quantitatives II :

1. Introduction à l'inférence statistique (rappels et suite)

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 97 - 105

Exercices : 5.4, 5.6 - 5.8 (fin de la série 5)

Rappel

Opposer des hypothèses

Lorsque l'on fait de l'inférence statistique, on va fréquemment opposer deux hypothèses, dont une seule est vraie :

- H_0 , l'**hypothèse nulle**, décrit une « situation inintéressante » : pas de différences entre les groupes, pas de dépendance entre variables, etc. H_0 est assimilé à du **bruit**.
- H_1 , l'**hypothèse alternative**, décrit une « situation intéressante » : existence de différences entre les groupes, de dépendance entre variables, etc. H_1 est assimilé à du **signal**.

Sur la base des données D , on va rejeter ou non H_0 (i.e on accepte ou non H_1) :

- L'erreur de **première espèce** consiste à rejeter H_0 à tort = « fausse alarme ».
- L'erreur de **seconde espèce** consiste à accepter H_0 à tort = « manqué ».

Probabilités d'erreur α et β et décision

La **probabilité d'erreur de première espèce** est notée α :

$$\alpha = P(\text{rejeter } H_0 | H_0 \text{ vrai})$$

La **probabilité d'erreur de deuxième espèce** est notée β :

$$\beta = P(\text{accepter } H_0 | H_0 \text{ faux})$$

On utilise une **règle de décision**, qui se base sur les données, pour rejeter ou non H_0 . Elle prend la forme suivante :

- Si $d(D) > d_c$, on rejette H_0 (on accepte H_1).
- Si $d(D) \leq d_c$, on accepte H_0 (on rejette H_1).


où $d(D)$ est la **variable de décision**, qui dépend de données D , et d_c un **seuil critique**, fixé par l'utilisateur.

Tableau général

Les erreurs de première et de seconde espèce et leurs probabilités α et β :

		décision (inférence statistique)	
		H_0 vrai	H_1 vrai
état réel	H_0 vrai	OK $1 - \alpha$	erreur de la première espèce $\alpha = P(d(D) > d_c H_0 \text{ vrai})$
	H_0 faux	erreur de la deuxième espèce $\beta = P(d(D) \leq d_c H_0 \text{ faux})$	OK $1 - \beta$

L'ensemble $W = \{d(D) | d(D) > d_c\}$ est appelée **région de rejet (de H_0)**.



Exemple 1 : pièce truquée, décision

On suspecte une pièce d'être truquée au sens où sa probabilité p d'obtenir pile ne serait pas de $p = 0.5$, mais de $p = 0.9$. On lance 6 fois la pièce, et on décide (arbitrairement) que la pièce est truquée si le nombre de pile vaut 5 ou 6. On a donc :

- $H_0 : p = 0.5$ (pièce normale)
- $H_1 : p = 0.9$ (pièce truquée)
- $d(D)$ = nombre de piles en 6 lancers
- $d_c = 4$ (on rejette H_0 si $d(D) > 4$)

Exemple 1 : calcul des erreurs

On a pour l'erreur de la première espèce :

$$\begin{aligned}\alpha &= P(\text{rejeter } H_0 | H_0 \text{ vrai}) = P(d(D) > 4 | p = 0.5) \\ &= \binom{6}{5} 0.5^6 + \binom{6}{6} 0.5^6 \\ &= 0.109 = 10.9\%\end{aligned}$$

Et pour l'erreur de deuxième espèce :

$$\begin{aligned}\beta &= P(\text{accepter } H_0 | H_0 \text{ faux}) = P(d(D) \leq 4 | p = 0.9) \\ &= 1 - \binom{6}{5} 0.9^5 \cdot 0.1 + \binom{6}{6} 0.9^6 \\ &= 0.114 = 11.4\%\end{aligned}$$

Introduction aux tests : test de comparaison de deux moyennes

Exemple 2 : concentration de zinc dans les harengs

Une étude s'intéresse à la pollution par les métaux dans une pisciculture de Caroline du Sud.

Deux études antérieures ont proposé des valeurs différentes pour la concentration de zinc (en microgrammes par gramme de matière sèche) dans les harengs, à savoir 85 et 105.

Dans les deux cas, l'écart-type de la concentration était estimé à 24 microgrammes par gramme.

Tester deux moyennes : les hypothèses

On va supposer que :

- L'une ou l'autre des valeurs proposées (85 ou 105) est la vraie valeur (supposition extrêmement forte).
- L'écart type théorique (24) est connu (supposition assez artificielle - l'écart type théorique est rarement connu).

Ici, on va utiliser un **test de comparaison de deux moyennes**. Il oppose l'**hypothèse nulle** H_0 et l'**hypothèse alternative** H_1 suivantes :

$$\begin{cases} H_0 : & \mu = \mu_0 \\ H_1 : & \mu = \mu_1 \end{cases}$$

où μ désigne la **moyenne théorique** (la vraie moyenne) et avec $\mu_0 = 85$, $\mu_1 = 105$ et $\sigma = 24$.

Pour trancher entre les deux théories, on va récolter un nouvel échantillon $D = \{x_1, \dots, x_n\}$ composé des mesures de concentrations dans n harengs, dont on calculera la moyenne $\bar{x}$.

Plus $\bar{x}$ est élevé (respectivement bas), plus la plausibilité de H_1 (resp. H_0) sera renforcée par les observations.


La **règle de décision** est la suivante : on fixe un seuil critique x_c tel que :

- Si $\bar{x} > x_c$, on rejette H_0 (et accepte H_1).
- Si $\bar{x} < x_c$, on accepte H_0 (et rejette H_1).

La règle de décision

Comme la règle de décision ne dépend ici que de $\bar{x}$, et non pas des autres détails de l'échantillon D (p.ex., sa variance) on dit que $\bar{x}$ constitue la **variable de décision du test**, notée $d(D)$.

L'intervalle $W := (x_c, \infty)$ est la **région de rejet (de H_0)**, tandis que son complémentaire $W^c = [0, x_c]$ est la **région d'acceptation (de H_0)**.




x_c sous l'hypothèse H_0

Si l'on suppose H_0 vrai, alors on sait que chaque mesure X de concentration suit $X \sim \text{Loi}(\mu_0, \sigma)$, de loi inconnue avec moyenne $\mu_0 = 85$ et écart type $\sigma = 24$.


Le **théorème central limite** nous dit que la moyenne $\bar{X}$ d'un échantillon de taille n suivra :

$$\bar{X} \sim N(\mu_0, \frac{\sigma^2}{n})$$



x_c sous l'hypothèse H_1

À l'inverse si l'on suppose H_1 vrai, alors on sait que $\bar{X} \sim N(\mu_1, \frac{\sigma^2}{n})$ avec $\mu_1 = 105$ (et toujours $\sigma = 24$) :




Cela va nous permettre de calculer, pour un x_c donné, les probabilités d'erreur α et β de type I et de type II.

On a :


$$\begin{aligned}\alpha &= P(\bar{X} > x_c | H_0 \text{ vrai}) = P(\bar{X} > x_c | \mu = \mu_0) \\ &= P\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > \frac{x_c - \mu_0}{\sigma/\sqrt{n}}\right) = P\left(\bar{X}^s > \frac{x_c - \mu_0}{\sigma} \sqrt{n}\right) \\ &= 1 - \phi\left(\frac{x_c - \mu_0}{\sigma} \sqrt{n}\right)\end{aligned}$$

Distribution de $\bar{X}$ sous H_0 ($n = 20$)





De même :

$$\begin{aligned}\beta &= P(\bar{X} \leq x_c | H_1 \text{ vrai}) = P(\bar{X} \leq x_c | \mu = \mu_1) \\ &= P\left(\frac{\bar{X} - \mu_1}{\sigma/\sqrt{n}} \leq \frac{x_c - \mu_1}{\sigma/\sqrt{n}}\right) = P\left(\bar{X}^s \leq \frac{x_c - \mu_1}{\sigma} \sqrt{n}\right) \\ &= \phi\left(\frac{x_c - \mu_1}{\sigma} \sqrt{n}\right)\end{aligned}$$



α et β en fonction de x_c


En faisant varier x_c dans un intervalle suffisamment grand (p.ex. $[40, 150]$), les fonctions $\alpha(x_c)$ et $\beta(x_c)$ parcourent pratiquement l'entièreté des valeurs dans l'intervalle unité $[0, 1]$:




La surface gris foncé vaut α , et la surface gris claire vaut β . On a toujours $\alpha + \beta \leq 1$.

Courbe ROC

Les courbes $1 - \beta(x_c)$ (en ordonnée) en fonction de $\alpha(x_c)$ (en abscisse) selon le seuil critique x_c (pour un n donné), sont appelées « caractéristiques opérationnelles du récepteur » (receiver operating characteristic) ou **courbe ROC**.





Plus n est grand : plus faible est la variance σ^2/n des distributions et plus les courbes associées à H_0 et H_1 sont séparées. La courbe ROC se rapproche du point idéal $\alpha = \beta = 0$ exempt d'erreurs de première et de seconde espèce.

Plus n est petit : plus on s'approche de la bissectrice d'équation $1 - \beta = \alpha$. Cette bissectrice correspond à l'**absence de données ($n=0$)**, où l'on est obligé de choisir au hasard entre H_0 et H_1 .

Exemple 3 : les copies perdues

Un prof. de maths a égaré dans le train des copies d'examen : les données D ont disparu. Il décide d'attribuer aléatoirement à chaque élève un résultat « réussite » avec probabilité p , et « échec » avec probabilité $1 - p$.

En posant H_0 = « réussite » et H_1 = « échec », la probabilité α de rejeter H_0 à tort est celle de faire échouer un élève qui aurait dû réussir, événement qui se produit ici (indépendamment de la performance réelle de l'élève) avec la probabilité $\alpha = 1 - p$.

Par un raisonnement similaire, $\beta = p$. Ainsi, quelle que soit la valeur de p , on a :

$$\alpha + \beta = (1 - p) + p = 1$$

qui est la bissectrice du premier quadrant de la courbe ROC.

Détermination du seuil (retour à l'exemple 2)

Au lieu de déterminer α (ou β) en fonction de x_c , l'usage consiste à **fixer le niveau de signification α** et d'en déduire le seuil critique x_c :

$$\begin{aligned}1 - \alpha &= \Phi\left(\frac{x_c - \mu_0}{\sigma} \sqrt{n}\right) \\ \Leftrightarrow u_{1-\alpha} &= \frac{x_c - \mu_0}{\sigma} \sqrt{n} \\ \Leftrightarrow x_c &= \mu_0 + \frac{\sigma}{\sqrt{n}} u_{1-\alpha}\end{aligned}$$

La **règle de décision** devient :

On rejette H_0 au niveau α si : $\bar{x} > \mu_0 + \frac{\sigma}{\sqrt{n}} u_{1-\alpha}$

ou :

On rejette H_0 au niveau α si : $\frac{\bar{x} - \mu_0}{\sigma} \sqrt{n} > u_{1-\alpha}$

Détermination du seuil : exemple de calcul

Pour un échantillon de $n = 9$ observations, à combien doit-on fixer le seuil critique x_c au niveau de signification $\alpha = 5\%$?

(Rappel : $\mu_0 = 85$ et $\sigma = 24$)

On rejette H_0 au niveau α si $\bar{x} > x_c$, où :

$$x_c = \mu_0 + \frac{\sigma}{\sqrt{n}} u_{1-\alpha} = 85 + \frac{24}{\sqrt{3}} 1.645 = 98.16$$

En d'autres termes, si une personne décide de rejeter l'hypothèse que $\mu = 85$ dès que la moyenne (avec $n = 9$) dépasse 98.16, cette personne est assurée de se tromper (= rejeter H_0 à tort) moins d'une fois sur 20.

Approches de Neyman-Pearson et de Fisher

Dans le cadre de l'exemple 2, supposons maintenant que les deux hypothèses en concurrence soient :

$$\begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu > \mu_0 \end{cases}$$

avec $\mu_0 = 85$ et $\sigma = 24$. Dans ce contexte

- H_0 est toujours bien définie et α peut être calculé. C'est une **hypothèse simple**.
- H_1 devient une **famille d'hypothèses**, et β ne peut plus être calculé. On appelle cela une **hypothèse composite**.

Hypothèses simples et composites : exemples

« X suit une loi normale de moyenne 2 et de variance 3 » (i.e. $X \sim N(2, 3)$) constitue un modèle probabiliste simple.

« X suit une loi normale de moyenne 4 » est un modèle probabiliste composite : la variance étant inconnue, ce modèle est constitué de la famille de tous les modèles $N(4, \sigma^2)$ avec $\sigma^2 > 0$.

« X suit une loi normale » ou « Y suit une loi normale de variance 1 » sont composites.

« Ce dé est équilibré » est un modèle probabiliste simple.

« Ce dé n'est pas équilibré » est un énoncé probabiliste composite : il existe une infinité de distributions possibles non-uniformes.

« Je prendrai le train de 19h02 » est un énoncé déterministe simple.

« Je prendrai le train de 19h02 ou de 20h02 » ou « Je ne prendrai pas le train de 19h02 » sont des énoncés composites.

Deux approches en théorie des tests

L'approche de **Neyman-Pearson** consiste à tester entre deux valeurs possibles θ_0 et θ_1 d'un paramètre théorique θ , i.e. à tester entre **deux hypothèses simples**.

$$\begin{cases} H_0 : & \theta = \theta_0 \\ H_1 : & \theta = \theta_1 \end{cases}$$

L'approche de **Fisher** consiste à tester entre **une hypothèse simple H_0 et une hypothèse composite H_1** . Il en existe en général 3 variantes :

$$\begin{array}{ll} \text{Unilatérale} & : \begin{cases} H_0 : & \theta = \theta_0 \\ H_1 : & \theta > \theta_0 \end{cases} & \text{Unilatérale} & : \begin{cases} H_0 : & \theta = \theta_0 \\ H_1 : & \theta < \theta_0 \end{cases} \\ \text{« à droite »} & & \text{« à gauche »} & \end{array}$$

$$\text{Bilatérale} : \begin{cases} H_0 : & \theta = \theta_0 \\ H_1 : & \theta \neq \theta_0 \end{cases}$$

Tests de Fisher : décision pour test unilatéral à droite

La règle de décision de la variante **unilatérale « à droite »** est :

On rejette H_0 au niveau α si $d(D) > x_{1-\alpha}$

où $d(D)$ est la **variable de décision** et $x_{1-\alpha}$ le **$(1 - \alpha)$ -ème quantile** de la distribution statistique à utiliser dans le test.

Les deux quantités $d(D)$ et $x_{1-\alpha}$ sont spécifiés, pour chaque test usuel, dans les **formulaires statistiques**.

Exemple : Pour le test de la moyenne

$$\begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu > \mu_0 \end{cases}$$

On a vu que $d(D) = \frac{\bar{x} - \mu_0}{\sigma} \sqrt{n}$ et $x_{1-\alpha} = u_{1-\alpha}$ (le $(1 - \alpha)$ -ème quantile de la loi normale centrée réduite).




Tests de Fisher : décisions pour les autres variantes

La règle de décision de la variante **unilatérale « à gauche »** est :

On rejette H_0 au niveau α si $d(D) < -x_{1-\alpha}$

La règle de décision de la **variante bilatérale** est :

On rejette H_0 au niveau α si $|d(D)| > x_{1-\frac{\alpha}{2}}$



Test unilatéral ou bilatéral ?


Lorsqu'un·e chercheur·euse cherche à rejeter H_0 , il doit **généralement appliquer la version bilatérale** du test :

- L'hypothèse alternative $H_1 : \theta \neq \theta_0$ couvre tous les cas complémentaires à H_0 . Alors que dans les versions unilatérales, une des possibilités est simplement exclue dès le départ, et ne pourra ainsi jamais être identifiée si d'aventure elle était vraie.
- Ce n'est que **si l'on a de bonnes raisons de croire que l'une des deux alternatives $\theta > \theta_0$ ou $\theta < \theta_0$ peut être écartée a priori** qu'il est légitime d'utiliser un test unilatéral (p. ex. : test de l'égalité des salaires entre hommes et femmes).

Le cas des variables de décision positives

Il arrive souvent que la variable de décision $d(D)$ soit **positive par construction**. Dans ce cas, il n'y a plus qu'une variante : un test unilatéral « à droite » :

On rejette H_0 au niveau α si $d(D) > x_{1-\alpha}$



La distribution choisie ici est celle du χ^2 à 3 degrés de liberté. Le début des zones grisées correspond au quantiles $x_{0.90}$ ($\alpha = 10\%$), $x_{0.95}$ ($\alpha = 5\%$), et $x_{0.99}$ ($\alpha = 1\%$).



La valeur p

Le test de moyenne de Fisher

Posons un test de moyenne avec **hypothèse H_0 simple et hypothèse H_1 composite (de Fisher)** :

$$\begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu > \mu_0 \end{cases}$$


Pour tester l'hypothèse H_0 , on va poser un seuil α , tirer un échantillon $\{x_1, \dots, x_n\}$ et calculer sa moyenne $\bar{x}$, et comparer cette moyenne avec le seuil $x_{1-\alpha}$:



La p-valeur





La **valeur p (p-value)** est une **probabilité** associée à notre variable de décision $d(D)$. On peut la définir comme :

valeur p = $\ll$ Probabilité d'obtenir des valeurs *plus extrêmes* que $d(D)$ sous H_0 $\gg$




Critère de rejet avec la valeur p

La valeur p **est comparée directement avec un seuil α** . On rejette H_0 si $p < \alpha$ (on travaille avec les aires plutôt que sur l'axe).



La p-valeur avec un test bilatéral

Dans le cadre d'un **test bilatéral**, la valeur p comprends l'aire sous la courbe au delà de notre variable de décision **et son symétrique** :



Exemple 2 : la p-valeur

Revenons à notre exemple de concentration, on aimerait tester :

$$\begin{cases} H_0 : \mu = 85 \\ H_1 : \mu > 85 \end{cases}$$

On tire un échantillon de $n = 9$ observations et on obtient $\bar{x} = 97$ (avec tj $\sigma = 24$). Quelle est notre valeur p ?

$$\begin{aligned} \text{valeur p} &= P(\bar{X} > \bar{x} | H_0 \text{ vrai}) = P(\bar{X} > \bar{x} | \mu = 85) \\ &= P\left(\frac{\bar{X} - 85}{24/\sqrt{9}} > \frac{\bar{x} - 85}{24/\sqrt{9}}\right) = P\left(\bar{X}^s > \frac{97 - 85}{24}\sqrt{9}\right) \\ &= 1 - \phi(1.5) = 1 - 0.93 = 0.07 \end{aligned}$$

Le test est significatif à $\alpha = 10\%$, mais pas à $\alpha = 5\%$.