

Méthodes Quantitatives II :

3. Tests catégoriels et tests du lien entre deux variables

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 110 - 117

Exercices : Fin de la série 6

Tests catégoriels

Lorsque x est une **variable catégorielle à m modalités**, on pourra :

- Comparer la répartition des modalités de x dans l'échantillon à une certaine répartition théorique (test du χ^2 pour une population).
- Comparer la répartition des modalités de x entre deux échantillons (test d'indépendance du χ^2).

Pour $m = 2$, la répartition des modalités de x dans l'échantillon est donnée par une **proportion empirique f** , définie comme la proportion d'individus possédant une des modalités de x (la proportion complémentaire $1 - f$ est associée à la seconde modalité de x) : on utilise alors des **tests de la proportion**.

Test de la proportion pour un échantillon

Un test de la proportion possède les hypothèses suivantes :

$$\begin{cases} H_0 : p = p_0 \\ H_1 : p > p_0 \end{cases} \quad (\text{version unilatérale})$$

où p_0 est une certaine proportion donnée. Si n n'est pas trop petit, on rejette H_0 au niveau α si :

$$\frac{f - p_0}{\sqrt{p_0(1 - p_0)}} \sqrt{n} > u_{1-\alpha}$$

où f est la **proportion empirique**.

(Rappel) Jeu de données : classe de gymnase

identifiant	sexe	lateralite	age	taille	maths	allemand1	allemand2
1	F	D	20	175	10	7	9
2	F	D	17	162	3	4	5
3	M	D	17	160	10	6	6
4	M	G	15	166	10	10	10
5	F	G	19	160	3	7	8
6	F	D	16	168	6	8	10
7	M	D	20	168	7	5	5
8	F	D	17	170	3	5	6
9	F	D	16	173	3	6	7
10	M	G	16	168	9	5	7
11	F	D	18	161	8	6	8
12	F	D	19	176	9	5	8
13	F	D	17	166	9	5	8
14	F	D	16	162	6	5	7
15	F	D	18	158	8	7	8
16	M	D	18	163	9	10	10
17	F	D	15	149	3	5	4
18	M	D	19	176	2	7	8
19	F	D	15	152	4	8	9
20	F	D	15	170	9	9	10

Exemple I : test de la proportion pour un échantillon

La proportion de gauchers dans la classe vaut $f = 3/20 = 15\%$. Cette valeur est-elle significativement différente de la valeur $p_0 = 10\%$ avancée par certains spécialistes ?

Il faut ici utiliser la version bilatérale du test :

$$\frac{0.15 - 0.1}{\sqrt{0.1(1 - 0.1)}} \sqrt{20} = 0.745 \stackrel{?}{>} u_{1-\frac{\alpha}{2}} = 1.96 \quad \text{NON !}$$

Ici, la taille de l'échantillon ($n = 20$) est beaucoup trop petite pour qu'un écart de 5% soit significatif. Ce dernier le serait (pour le test bilatéral avec $\alpha = 5\%$) si la quantité $\sqrt{n}$ était ici multipliée par un facteur d'au moins $1.96/0.745 = 2.63$, i.e. si n était multiplié par un facteur d'au moins $2.63^2 = 6.92$, soit un échantillon d'au moins $20 \cdot 6.92 = 138.6 \simeq 139$ individus.

Exemple II : test de la proportion pour un échantillon

La proportion d'hommes dans la classe vaut $f = 6/20 = 30\%$. Peut-on y voir la marque d'un recrutement masculin inférieur au recrutement féminin, s'agissant d'études post-obligatoires ?

l'hypothèse alternative H_1 est $p < p_0$ où p est la proportion masculine dans la population et $p_0 = 0.5$. C'est ici le test unilatéral « à gauche » qu'il faut utiliser, à savoir

$$-\frac{0.3 - 0.5}{\sqrt{0.5(1 - 0.5)}}\sqrt{20} = 1.79 \stackrel{?}{>} u_{1-\alpha} = 1.65 \quad \text{OUI!}$$

Ainsi, à $\alpha = 5\%$ et en utilisant un test unilatéral, il est correct de considérer que le nombre d'hommes dans la classe est significativement petit (mais tout juste).

Avec R :

```
> n_M = sum(note$sexe == 'M')  
> prop.test(n_M, n=20, p=0.5, alternative='less', correct=F)  
X-squared = 3.2, df = 1, p-value = 0.03682
```


Loi binomiale et approximation normale

Le test de la proportion est, comme les autres tests classiques, basé sur le **théorème central limite**, ce qui suppose n grand.

Si n est petit, on peut procéder à la correction de continuité (non développée ici), ou encore mieux, utiliser la **loi binomiale**. On parle alors du **test binomial** plutôt que du test de la proportion, même si les hypothèses à tester restent inchangées.





Dans l'exemple précédant, la valeur p calculée par le test binomial est simplement la probabilité qu'en 20 lancers, une pièce équilibrée ne produise que 6 pile ou moins, à savoir :

$$p = \sum_{n=1}^6 \binom{20}{n} (0.5)^n (1 - 0.5)^{20-n} = (0.5)^{20} \sum_{n=1}^6 \binom{20}{n} = 0.05766$$

Avec R :

```
> binom.test(n_M, n=20, p=0.5, alternative='less')  
number of successes = 6, number of trials = 20, p-value = 0.05766
```

Loi binomiale pour différentes valeurs de n



Test de la proportion pour deux échantillons indépendants

On souhaite comparer les proportions empiriques f_1 et f_2 observées sur **deux échantillons indépendants** (i.e. non appariés) de tailles respectives n_1 et n_2 . Il s'agit de tester :

$$\begin{cases} H_0 : p_1 = p_2 \\ H_1 : p_1 > p_2 \end{cases} \quad (\text{version unilatérale})$$

Si n_1 et n_2 ne sont pas trop petits, l'approximation normale est valide, et on rejette H_0 au niveau α si :

$$\frac{f_2 - f_1}{\sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right) \bar{f}(1 - \bar{f})}} > u_{1-\alpha} \quad \text{avec } \bar{f} = \frac{n_1 f_1 + n_2 f_2}{n_1 + n_2}$$

La proportion moyenne $\bar{f}$ est la **proportion empirique observée dans la totalité de l'échantillon de taille $n_1 + n_2$** .

Exemple III : test de la proportion pour un échantillon

La proportion de gauchers chez les hommes $f_M = 2/6 = 0.333$ est-elle significativement différente de la proportion de gauchères chez les femmes $f_F = 1/14 = 0.071$?

La version bilatérale du test à $\alpha = 5\%$ donne

$$\bar{f} = \frac{6 \cdot \frac{2}{6} + 14 \cdot \frac{1}{14}}{6 + 14} = \frac{3}{20} = 0.15$$

et

$$\frac{|0.333 - 0.071|}{\sqrt{\left(\frac{1}{6} + \frac{1}{14}\right) 0.15(1 - 0.15)}} = 1.50 \stackrel{?}{>} u_{0.975} = 1.96 \quad \text{NON !}$$

Avec R :

```
> n.F = sum(note$sexe == 'F')
> n.M = sum(note$sexe == 'M')
> n.F_g = sum(notes$sexe == 'F' & notes$lateralite == 'G')
> n.M_g = sum(notes$sexe == 'M' & notes$lateralite == 'G')
> prop.test(c(n.F_g, n.M_g), n=c(n.F, n.M), correct=F)
X-squared = 2.2596, df = 1, p-value = 0.1328
```

Test du chi2 pour une variable catégorielle

Lorsque le nombre m de modalités de la variable catégorielle dépasse 2, les tests de proportion ne s'appliquent plus.

Le **test du chi2 pour une variable catégorielle** permet de comparer la **distribution empirique** $f = (f_1, \dots, f_m)$ à une certaine **distribution théorique** $p^0 = (p_1^0, \dots, p_m^0)$ spécifiée. Par construction, on a :

$$f_j \geq 0 \quad \sum_{j=1}^m f_j = 1 \quad p_j^0 \geq 0 \quad \sum_{j=1}^m p_j^0 = 1$$

Les hypothèses nulle et alternative du test sont :

$$\begin{cases} H_0 : p = p^0 & (\text{i.e. } p_1 = p_1^0, \dots, p_m = p_m^0) \\ H_1 : p \neq p^0 & (\text{i.e. } H_0 \text{ est fausse}) \end{cases}$$

Test du chi2 pour une variable catégorielle

La **variable de décision** est le **chi-carré pour une variable catégorielle**, défini comme :

$$\text{chi2} = n \cdot \sum_{j=1}^m \frac{(f_j - p_j^0)^2}{p_j^0} = \sum_{j=1}^m \frac{(n_j - n_j^{\text{th}})^2}{n_j^{\text{th}}}$$

où les n_j sont les **effectifs observés dans l'échantillon de taille n** (i.e. $n_j = n \cdot f_j$), et les n_j^{th} sont les **effectifs théoriques ou attendus** correspondants, i.e. tels que $n_j^{\text{th}} = n \cdot p_j^0$.

La règle de décision est de rejeter H_0 au niveau α si

$$\text{chi2} > \chi_{1-\alpha}^2[m-1]$$

où $\chi_{1-\alpha}^2[m-1]$ est le $(1 - \alpha)$ -ème quantile de la **distribution du χ^2** à $m - 1$ degrés de liberté.

Exemple IV : test du chi2 pour une variable catégorielle

le test du chi2 pour une variable catégorielle peut s'appliquer à n'importe quel profil théorique. Cependant, le cas du profil théorique **uniforme** $p_1^0 = p_2^0 = \dots = p_m^0 = \frac{1}{m}$ est fréquemment rencontré.

Le nombre de victoires selon les 8 pistes d'un hippodrome (données réelles) est :

Numéro de piste	1	2	3	4	5	6	7	8	total
Nombre de victoires	29	19	18	25	17	10	15	11	144

L'attribution d'une piste plutôt qu'une autre influence-t-elle significativement les chances de gagner ?

Exemple IV (suite)



Il faut ici comparer le profil observé au profil théorique uniforme, pour lequel $n_j^{\text{th}} = 144/8 = 18$ victoires sont attendues sur chaque piste.

Le chi2 vaut :

$$\begin{aligned}\text{chi2} &= \sum_{j=1}^m \frac{(n_j - n_j^{\text{th}})^2}{n_j^{\text{th}}} \\ &= \frac{(29 - 18)^2 + (19 - 18)^2 + (18 - 18)^2 + (25 - 18)^2 + (17 - 18)^2 + (10 - 18)^2 + (15 - 18)^2 + (11 - 18)^2}{18} \\ &= 16.3\end{aligned}$$

Comme $\chi_{0.95}^2[7] = 14.07$ et $\chi_{0.99}^2[7] = 18.48$, on trouve une influence de piste significative à 5%, mais non à 1%.

Exemple IV (suite)



Exemple V : loi de Zipf

Dans sa formulation la plus simple la **loi de Zipf** appliquée à la variété textuelle dit que le mot le plus fréquent dans un texte est deux fois plus fréquent que le second mot le plus fréquent, trois fois plus fréquent que le troisième mot le plus fréquent, etc.

En se limitant aux quatre noms les plus fréquents de la Déclaration universelle des droits de l'homme (1948) on trouve droit(s) (63 occurrences), suivi de personne, liberté(s) et homme, avec 23, 19 et 10 occurrences, soit un total de $n = 115$ occurrences.

La loi de Zipf dit que :

$$p_1^0 = \frac{12}{25}, \quad p_2^0 = \frac{6}{25}, \quad p_3^0 = \frac{4}{25}, \quad p_4^0 = \frac{3}{25}$$

ou

$$n_1^{\text{th}} = 55.2, \quad n_2^{\text{th}} = 27.6, \quad n_3^{\text{th}} = 18.4, \quad n_4^{\text{th}} = 13.8$$

à comparer avec les effectifs empiriques.

Exemple V (suite)

On peut résumer les effectifs empirique et théorique dans le tableau suivant :

terme	droit(s)	personne	liberté(s)	homme	total
effectif observé	63	23	19	10	115
effectif théorique	55.2	27.6	18.4	13.8	115

La variable de décision (le χ^2) vaut :

$$\chi^2 = \frac{(63 - 55.2)^2}{55.2} + \frac{(23 - 27.6)^2}{27.6} + \frac{(19 - 18.4)^2}{18.4} + \frac{(10 - 13.8)^2}{13.8} = 2.93$$

ce qui est bien inférieur au seuil $\chi^2_{(1-0.05)}[3] = 7.81$. Sur ce petit exemple, le document semble suivre la loi de Zipf.

Avec R :

```
> chisq.test(c(63,23,19,10), p=c(12,6,4,3)/25, correct=F)  
X-squared = 2.9348, df = 3, p-value = 0.4018
```

Tests du lien entre deux variables

Nous allons maintenant aborder les tests qui s'intéressent au **lien entre deux variables**.

On aura :

- numérique vs numérique → **Test de la corrélation**
- catégorielle vs catégorielle → **Test du χ^2**
- numérique vs catégorielle → **Test du F**
- (ordinaire vs ordinaire → **Test de la corrélation de rang**)

Test de la corrélation

Pour tester le **lien entre deux variables numériques x et y** , on utilise le **test de la corrélation**.

Ce dernier teste si la **corrélation théorique ρ est nulle ou non**. Pour y répondre, nous allons calculer la **corrélation empirique $r = \text{corr}(x, y)$** .

Dans la version unilatérale « à droite », il s'agit de tester :

$$\begin{cases} H_0 : \rho = 0 \\ H_1 : \rho > 0 \end{cases} \quad (\text{version unilatérale})$$

On rejette H_0 au niveau α si :

$$\frac{r}{\sqrt{1-r^2}} \sqrt{n-2} > t_{1-\alpha}[n-2]$$

(il faut que $n \geq 3$ au moins)

Exemple VI : test de la corrélation

Est-ce qu'il y a un lien positif entre age et taille. En d'autres termes, est-ce que la corrélation empirique $r = \text{corr}(\text{age}, \text{taille})$ est-elle significativement supérieure à 0 ?

On calcule $r = 0.403$ et en posant $\alpha = 0.05$:

$$\frac{0.403}{\sqrt{1 - 0.403^2}} \sqrt{18} = 1.87 \stackrel{?}{>} t_{0.95}[18] = 1.734 \quad \text{OUI!}$$

Par contre, la corrélation ne serait pas significative dans la version bilatérale du test ($t_{0.975}[18] = 2.101$).

Avec R :

```
> cor.test(notes$age, notes$taille, alternative='greater')  
t = 1.8692, df = 18, p-value = 0.03898
```

Test du chi2 : table de contingence

Pour tester le lien entre **deux variables catégorielles**, on utilise le **test du chi2**.

Avec deux variables catégorielles x et y , avec m_1 et m_2 modalités, les données sont contenues dans une **table de contingence** n_{jk} , donnant le nombre d'individus dans la catégorie j de x et k de y .

		yeux				
		brown	blue	hazel	green	
cheveux	black	68	20	15	5	108
	brown	119	84	54	29	286
	red	26	17	14	14	71
	blond	7	94	10	16	127
		220	215	93	64	592

Tableau croisés (Snee 1974) de $x = \ll \text{couleur des cheveux} \gg$ vs $y = \ll \text{couleur des yeux} \gg$.

Table des effectifs théoriques sous hypothèse d'indépendance

Pour rappel, à partir de la table de contingence, on peut construire la **table des effectifs théoriques sous hypothèse d'indépendance** avec :

$$n_{jk}^{\text{th}} = \frac{n_{j\bullet} n_{\bullet k}}{n_{\bullet\bullet}}$$

		yeux				
		brown	blue	hazel	green	
cheveux	black	40.1	39.2	17.0	11.7	108
	brown	106.3	103.9	44.9	30.9	286
	red	26.4	25.8	11.1	7.7	71
	blond	47.2	46.1	20.0	13.7	127
		220	215	93	64	592

Test d'indépendance du chi2

La mesure standard de liaison entre x et y est donné par le **chi2**, qui mesure « l'éloignement » de la table empirique à la table théorique :

$$\text{chi2} = \sum_{j=1}^{m_1} \sum_{k=1}^{m_2} \frac{(n_{jk} - n_{jk}^{\text{th}})^2}{n_{jk}^{\text{th}}}$$

Les hypothèses du **test d'indépendance du chi2** sont :

$$\begin{cases} H_0 : & X \text{ et } Y \text{ sont indépendants} \\ H_1 : & X \text{ et } Y \text{ sont dépendants} \end{cases}$$

On rejette H_0 au niveau α si :

$$\text{chi2} > \chi_{1-\alpha}^2[(m_1 - 1)(m_2 - 1)]$$

Exemple VII : test du chi2

Dans notre exemple, on a :

		yeux				
		brown	blue	hazel	green	
cheveux	black	68	20	15	5	108
	brown	119	84	54	29	286
	red	26	17	14	14	71
	blond	7	94	10	16	127
		220	215	93	64	592

↔

		yeux				
		brown	blue	hazel	green	
cheveux	black	40.1	39.2	17.0	11.7	108
	brown	106.3	103.9	44.9	30.9	286
	red	26.4	25.8	11.1	7.7	71
	blond	47.2	46.1	20.0	13.7	127
		220	215	93	64	592

La variable de décision vaut $\chi^2 = 138.29$, qui est très grand par rapport au seuil $\chi^2_{1-0.05}[(4-1)(4-1)] = \chi^2_{1-0.05}[9] = 16.9$.

Avec R :

```
> chisq.test(hair_eye, correct=F)
```

```
X-squared = 138.29, df = 9, p-value < 2.2e-16
```


Si chacun des effectifs observés avait été 10 fois plus petit, la variable de décision aurait également été divisée par 10, avec la valeur résultante $\chi^2 = 13.829$, qui ne serait alors plus significative à $\alpha = 5\%$.

Test du F : décomposition de la variance

Pour tester le lien entre **une variable numérique x et une variable catégorielle y** , on utilise le **test du F** .

Rappel : Les m modalités de y constituent **m groupes**, et la variance empirique (totale) de x se décompose exactement en variance inter-groupe et variance intra-groupe comme :

$$\text{var}(x) = \text{var}_B(x) + \text{var}_W(x)$$




Le F -ratio


Le F ou F -ratio se calcule avec :

$$F = \frac{\frac{\text{var}_B(x)}{m-1}}{\frac{\text{var}_W(x)}{n-m}}$$

Un F faible indique que $\text{var}_B(x)$ est faible et que les moyennes empiriques $\bar{x}_j$ dans chaque groupe sont proches :



A l'inverse, un F élevé signale que les moyennes des groupes $\bar{x}_j$ diffèrent fortement :



Test du F : décomposition de la variance

Les hypothèses du **test du F** sont les suivantes :

$$\begin{cases} H_0 : \mu_1 = \mu_2 = \dots = \mu_m \\ H_1 : H_0 \text{ est fausse} \end{cases}$$

où $\mu_1, \mu_2, \dots, \mu_m$ sont les moyennes de chaque groupe défini par les modalités de y . H_1 dit qu'au moins deux moyennes théoriques μ_j et μ_k diffèrent.

On rejette H_0 au niveau α si :

$$F = \frac{\frac{\text{var}_B(x)}{m-1}}{\frac{\text{var}_W(x)}{n-m}} > F_{1-\alpha}[m-1, n-m]$$

où $F_{1-\alpha}[m-1, n-m]$ désigne le **($1-\alpha$)-ème quantile de la loi du F à $\text{df}_B = m-1$ et $\text{df}_W = n-m$ degrés de liberté** (ordre important).

Exemple VIII : test du F

Le questionnaire adressé aux membres de l'UNIL (2016) contenait les variables x =age (en années) et y =statut ($m = 6$ modalités). Les effectifs, âges moyens et écarts-types de l'âge, sont les suivants :

statut	contient	effectif n_j	âge moyen $\bar{x}_j$	écart-type s_j
Etu	étudiants	695	22.98	4.79
ProfMer	professeurs et MER	128	51.53	9.96
PostDoc	premiers assist., MA	52	37.46	6.30
Ass	assistants doctorants	145	29.68	4.30
PAT	PAT	304	42.36	10.08
Autre	autres statuts	41	43.00	14.69
total		1365	31.84	12.65

Exemple VIII (suite)

Pour rappel, les variances inter- et intra-groupe sont définies comme :

$$\begin{aligned}\text{var}_B(x) &= \sum_{j=1}^m \frac{n_j}{n} (\bar{x}_j - \bar{x})^2 & \text{var}_W(x) &= \sum_{j=1}^m \frac{n_j}{n} s_j^2 \\ n &= \sum_{j=1}^m n_j & \bar{x}_j &= \frac{1}{n_j} \sum_{i \in j} x_i & \bar{x} &= \sum_{j=1}^m \frac{n_j}{n} \bar{x}_j\end{aligned}$$

Et on trouve ici :

$$\begin{aligned}\text{var}(x) &= 159.95 & \text{var}_B(x) &= 106.39 & \text{var}_W(x) &= 53.56 \\ F &= 539.9\end{aligned}$$

ce qui est extrêmement élevé par rapport à

$$F_{0.95}[6 - 1, 1365 - 6] = 2.22. \text{ (avec R, on obtient } p < 2 \cdot 10^{-16})$$