

Méthodes Quantitatives II :

4. Corrélation de rangs et corrélation partielle

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 118 - 123

Exercices : 7.1, 7.2

Le coefficient de corrélation de rangs (Spearman)

Une variable est **ordinaire** ssi ses scores peuvent être ordonnés par la relation « plus grand ou égal que » (ou, de façon équivalente, « plus petit ou égal que »).

Par exemple, les réponses fermées à une question « buvez-vous un café en début de journée ? » peuvent comporter les champs :

- Toujours
- Habituellement
- Souvent
- Quelquefois
- Parfois
- Rarement
- Jamais

Les variables ordinales : recodage

On peut alors classer les modalités comme :

Toujours $\geq$ Habituellement $\geq \dots \geq$ Jamais

On peut alors chercher à **recoder ces variables** avec des valeurs numériques, par exemple :

$$12 > 10 > 8 > \dots > 2 > 0$$

mais, pour ce recodage particulier, cela implique que « Toujours » est 2 fois plus grand que « Quelquefois » et 6 fois plus grand que « Rarement », ce qui peut être discutable.

Calculer la moyenne, la variance, ou la corrélation entre deux variables ordinales recodées doit avoir du sens.

Le rang

La bonne manière de recoder les variables ordinales est d'utiliser les **rangs**, notés **$\text{rang}(x_i)$** . On les construit en attribuant :

- Le rang 1 à l'individu i dont x_i est le plus élevé.
- Le rang 2 à l'individu i dont le score x_i est le deuxième plus élevé.
- etc.

Arbitrairement, et par construction, les rangs ainsi construits sont **décroissants**.

Par exemple, soient les scores :

$$x = (2, 8, 5, 1, 0, 3)$$

alors les rangs de cette variable sont :

$$\text{rang}(x) = (4, 1, 2, 5, 6, 3)$$

Le rang : cas des ex-aequos

En cas d'**ex-aequos**, on attribue à ces individus le **rang moyen de leur groupe**.

En posant cette condition, la **moyenne des rangs** reste la moyenne des nombres de 1 à n :

$$\overline{\text{rang}(x)} = \frac{1}{n} \sum_{i=1}^n \text{rang}(x_i) = \frac{n+1}{2}$$

Exemples :

- Si A est premier, suivi de B et C égalité, suivi ensuite de D , on aura :

$$\text{rang}(A) = 1, \quad \text{rang}(B) = \text{rang}(C) = \frac{2+3}{2} = 2.5, \quad \text{rang}(D) = 4$$

- Si A est premier, suivi de B , C et D à égalité, on aura :

$$\text{rang}(A) = 1, \quad \text{rang}(B) = \text{rang}(C) = \text{rang}(D) = \frac{2+3+4}{3} = 3$$

Exemple I : deux variables numériques

Soient les deux variables numériques x et y et leurs rangs associés :

individu	1	2	3	4	5	6	7	8	9	10
x	60	80	55	85	70	100	60	50	70	70
$\text{rang}(x)$	7.5	3	9	2	5	1	7.5	10	5	5
y	50	70	40	80	30	90	70	55	50	65
$\text{rang}(y)$	7.5	3.5	9	2	10	1	3.5	6	7.5	5

On voit qu'un nombre impair d'ex-aequos génère un rang entier, et un nombre pair d'ex-aequos génère un rang demi-entier.

La corrélation de rangs (corrélation de Spearman)

Soient x et y ordinales. On ne peut calculer leur corrélation directement, mais on peut calculer la corrélation entre leurs rangs.

Le coefficient résultant, noté $r_S(x, y)$ ou r_{xy}^S est la **corrélation de rangs** ou **corrélation de Spearman** (la corrélation ordinaire se nomme aussi corrélation de Pearson) :

$$r_{xy}^S := \text{corr}(\text{rang}(x), \text{rang}(y))$$

Dans l'exemple précédent, on trouve que $r_{xy}^S = \text{corr}(\text{rang}(x), \text{rang}(y)) = 0.61$.
Si l'on avait calculé la corrélation ordinaire (de Pearson) entre x et y , on aurait obtenu $r_{xy} = \text{corr}(x, y) = 0.68$.

La corrélation de rangs : croissants ou décroissants

On a adopté la convention de déterminer les rangs de façon **décroissante**.

La convention inverse (rangs croissants), notées ici $\text{rang}^c(x)$, est bien sûr possible, et ne change rien à la valeur de la corrélation de rangs **pourvu que la même convention soit utilisée pour les deux variables** :

$$r_{xy}^S := \text{corr}(\text{rang}(x), \text{rang}(y)) = \text{corr}(\text{rang}^c(x), \text{rang}^c(y))$$

La corrélation de rangs : propriétés

Quelle que soit la convention (décroissante ou croissante) adoptée, la **moyenne des rangs** dans un échantillon de n individus est :

$$\overline{\text{rang}(x)} = \frac{n+1}{2}$$

et la **variance des rangs** vaut :

$$\text{var}(\text{rang}(x)) = \frac{n^2 - 1}{12}$$

Cependant, pour cette dernière, la formule est valable **seulement s'il n'y a pas d'ex-aequo**. Dans le cas d'ex-aequo, il faut calculer la variance au cas par cas.

Test de la corrélation de rangs

Pour **tester la significativité d'un coefficient de corrélation de rangs**, on pose :

$$\begin{cases} H_0 : \rho_{xy}^S = 0 \\ H_1 : \rho_{xy}^S > 0 \end{cases} \quad (\text{version unilatérale})$$

où ρ_{xy}^S , noté aussi $\rho_S(x, y)$, est le coefficient de corrélation de rangs théorique.

On rejette H_0 au niveau α si :

$$r_{xy}^S > r_c(n, \alpha)$$

Les **valeurs critiques** $r_c(n, \alpha)$ font l'objet (pour n petit) d'une table particulière.

Exemple I (suite)

Pour l'exemple précédant, au niveau $\alpha = 5\%$ et dans le cas unilatéral, on trouve :

$$r_{xy}^S = 0.61 \stackrel{?}{>} r_c(10, 0.05) = 0.564 \quad \text{OUI !}$$

En revanche, si on avait effectué un test bilatéral avec $\alpha = 5\%$, on aurait du comparer :

$$r_{xy}^S = 0.61 \stackrel{?}{>} r_c(10, 0.025) = 0.648 \quad \text{NON !}$$

Exemple II : anglicismes

Soient deux questions (Margot 2022) :

- x = « Les anglicismes constituent une menace pour la langue française ».
- y = « Nous utilisons des anglicismes par effet de mode »

avec 5 niveaux d'accord. On a les résultats suivants :

	1	2	3	4	5	6
x	Plutôt d'accord	Tout à fait d'accord	Plutôt d'accord	Neutre	Tout à fait d'accord	Plutôt d'accord
y	Plutôt d'accord	Tout à fait d'accord	Plutôt en désaccord	Plutôt d'accord	Plutôt d'accord	Plutôt d'accord

	7	8	9	10	11	12
x	Plutôt en désaccord	Plutôt d'accord	En désaccord total	Plutôt en désaccord	Neutre	Plutôt en désaccord
y	Neutre	Plutôt d'accord	Tout à fait d'accord	Plutôt en désaccord	Neutre	Tout à fait d'accord

Exemple II : anglicismes

Cela nous donne les rangs suivants :

	1	2	3	4	5	6
x	Plutôt d'accord	Tout à fait d'accord	Plutôt d'accord	Neutre	Tout à fait d'accord	Plutôt d'accord
rang(x)	8.5	11.5	8.5	5.5	11.5	8.5
y	Plutôt d'accord	Tout à fait d'accord	Plutôt en désaccord	Plutôt d'accord	Plutôt d'accord	Plutôt d'accord
rang(y)	7	11	1.5	7	7	7

	7	8	9	10	11	12
x	Plutôt en désaccord	Plutôt d'accord	En désaccord total	Plutôt en désaccord	Neutre	Plutôt en désaccord
rang(x)	3	8.5	1	3	5.5	3
y	Neutre	Plutôt d'accord	Tout à fait d'accord	Plutôt en désaccord	Neutre	Tout à fait d'accord
rang(y)	3.5	7	11	1.5	3.5	11

On calcule alors :

$$\text{var}(\text{rang}(x)) = 11.25 \quad \text{var}(\text{rang}(y)) = 10.833 \quad \text{cov}(\text{rang}(x), \text{rang}(y)) = 0.667$$

Ce qui nous donne :

$$r_{xy}^S = \text{corr}(\text{rang}(x), \text{rang}(y)) = \frac{\text{cov}(\text{rang}(x), \text{rang}(y))}{\sqrt{\text{var}(\text{rang}(x))\text{var}(\text{rang}(y))}} = 0.0604$$

$$r_{xy}^S = 0.0604 \stackrel{?}{>} r_c(12, 0.05) = 0.503 \quad \text{NON ! } (p = 0.8521)$$

Le coefficient de corrélation partielle

Sur un échantillon de n individus, on mesure deux variables x et y , de scores x_i et y_i . La mesure classique de liaison entre x et y est donnée par :

1. La **corrélation** $r_{xy} = \text{corr}(x, y)$ pour x et y numériques.
2. Le **chi2** pour x et y catégorielles.
3. Le **F-ratio** pour x numérique et y catégorielle (ou l'inverse).
4. La **corrélation de rang** pour x et y ordinales.

On a vu comment calculer chacun de ces coefficients et comment tester leur significativité.

Matrice de corrélation

En présence de **trois variables numériques** x , y et z , on peut calculer trois coefficients de corrélation bivariés, soit :

- La corrélation $r_{xy} = r_{yx} = \text{corr}(x, y)$.
- La corrélation $r_{xz} = r_{zx} = \text{corr}(x, z)$.
- La corrélation $r_{yz} = r_{zy} = \text{corr}(y, z)$.

Ces coefficients peuvent être disposés dans la **matrice de corrélation $\mathbf{R}$** de type 3×3 (i.e. à trois lignes et trois colonnes) :

$$\mathbf{R} = \begin{pmatrix} r_{xx} & r_{xy} & r_{xz} \\ r_{yx} & r_{yy} & r_{yz} \\ r_{zx} & r_{zy} & r_{zz} \end{pmatrix} = \begin{pmatrix} 1 & r_{xy} & r_{xz} \\ r_{yx} & 1 & r_{yz} \\ r_{zx} & r_{zy} & 1 \end{pmatrix}$$

qui est symétrique.

Si :

- x est lié à z .
- y est lié à z .

alors on s'attend à ce que x et y soient à leur tour liées entre elles. Par exemple :

- Dans les études au secondaire 2, la note de chimie des élèves est très (positivement) corrélée à celle de physique, laquelle est très (positivement) corrélée avec celle de maths : on s'attend à ce que « chimie » et « maths » soient à leur tour (positivement) corrélées.
- Plus une région est riche, plus grande est l'espérance de vie et plus grand est le taux d'alphabétisation. On observe en effet que l'espérance de vie est corrélée positivement au taux d'alphabétisation.
- Le nombre d'homicides annuels dans une commune est très corrélé avec le nombre de lampadaires de la commune (trivial).

On voit bien la nécessité de disposer d'un
« instrument » permettant de mesurer :


- La part de la corrélation entre x et y qui serait
« expliquée » par leurs corrélations avec z .
- Ou la part de la corrélation « authentique » entre x et y
qui n'est pas due aux corrélations avec z .

Le **coefficient de corrélation partielle** permet de mesurer cette
deuxième quantité.

Le coefficient de corrélation partielle

Le **coefficient de corrélation partielle** entre x et y sachant z se note **corr**($x, y|z$) ou $r_{xy|z}$ et se calcule avec :

$$\text{corr}(x, y|z) = r_{xy|z} := \frac{r_{xy} - r_{xz}r_{yz}}{\sqrt{(1 - r_{xz}^2)(1 - r_{yz}^2)}}$$



Le coefficient de corrélation partielle $r_{xy|z}$ « soustrait » de la corrélation ordinaire r_{xy} la partie « générée » par r_{xz} et r_{yz} .

Exemple III : QI, poids et âge de jeunes enfants

Dans un échantillon fictif de $n = 100$ enfants de 6 à 10 ans, on mesure :

1. $x = \text{QI}$ (ici le même « test de QI » pour tous les enfants).
2. $y = \text{poids en kilogrammes}$.
3. $z = \text{âge en années}$.

avec une matrice de corrélation résultante :

$$\mathbf{R} = \begin{pmatrix} r_{xx} & r_{xy} & r_{xz} \\ r_{yx} & r_{yy} & r_{yz} \\ r_{zx} & r_{zy} & r_{zz} \end{pmatrix} = \begin{pmatrix} 1 & 0.6 & 0.7 \\ 0.6 & 1 & 0.89 \\ 0.7 & 0.89 & 1 \end{pmatrix}$$

Exemple III (suite) : QI, poids et âge de jeunes enfants

Le coefficient de corrélation partielle entre QI et poids pour un âge donné $\text{corr}(\text{QI}, \text{poids} | \text{âge}) = r_{xy|z}$ vaut alors :

$$r_{xy|z} = \frac{0.6 - 0.7 \times 0.89}{\sqrt{(1 - 0.7^2)(1 - 0.89^2)}} = -0.068$$

En résumé, la corrélation entre QI et poids vaut $r_{xy} = 0.6$, mais la corrélation partielle entre QI et poids si l'âge des enfants avait été constant vaut $r_{xy|z} = -0.068$.

En général, **il n'y a pas de relation systématique entre r_{xy} et $r_{xy|z}$** (tout dépend de r_{xz} et r_{yz}) :

- r_{xy} et $r_{xy|z}$ peuvent être de même signe (positif ou négatif), ou pas.
- r_{xy} et $r_{xy|z}$ peuvent être chacun grand ou petit en valeur absolue, indépendamment de l'autre.

On a aussi, comme il se doit :

$$r_{xx|z} = 1 \quad r_{xy|x} = \frac{0}{0} = \text{indéterminé}$$

Test de la corrélation partielle

Le **test de la corrélation partielle** suppose les hypothèses suivantes :

$$\begin{cases} H_0 : \rho_{xy|z} = 0 \\ H_1 : \rho_{xy|z} > 0 \end{cases} \quad (\text{version unilatérale})$$

où $\rho_{xy|z}$ est le coefficient de corrélation partielle théorique.

On rejette H_0 au niveau α si :

$$\frac{r_{xy|z}}{\sqrt{1 - r_{xy|z}^2}} \sqrt{n-3} > t_{1-\alpha}[n-3]$$

(il faut que $n \geq 4$ au moins)

Exemple III (suite) : QI, poids et âge de jeunes enfants

Au niveau $\alpha = 5\%$, on trouve, pour le test bilatéral pour l'exemple précédent :

$$\frac{|-0.068|}{1 - 0.068^2} \sqrt{97} = 0.67 \stackrel{?}{>} t_{0.975}[97] = 1.985 \quad \text{NON !}$$

Ainsi, la corrélation partielle négative $r_{xy|z} = -0.068$ entre QI et poids pour un âge donné n'est pas significative, et de très loin : sa valeur p bilatérale est de $p = 0.50$.

Par contraste, la corrélation simple $r_{xy} = 0.6$ est extrêmement significative, avec une valeur p bilatérale de $p = 4.2 \cdot 10^{-11}$.

Exemple III (suite) : QI, poids et âge de jeunes enfants

Au niveau $\alpha = 5\%$, on trouve, pour le test bilatéral pour l'exemple précédent :

$$\frac{|-0.068|}{1 - 0.068^2} \sqrt{97} = 0.67 \stackrel{?}{>} t_{0.975}[97] = 1.985 \quad \text{NON !}$$

Ainsi, la corrélation partielle négative $r_{xy|z} = -0.068$ entre QI et poids pour un âge donné n'est pas significative, et de très loin : sa valeur p bilatérale est de $p = 0.50$.

Par contraste, la corrélation simple $r_{xy} = 0.6$ est extrêmement significative, avec une valeur p bilatérale de $p = 4.2 \cdot 10^{-11}$.

La corrélation partielle : explications (*)

Pour **comprendre la formule de la corrélation partielle**, nous allons passer par le **calcul de la covariance sur les résidus**.



Supposons x , y et z , et les deux **régressions** suivantes :

$$\hat{x}_i = az_i + b \quad a = \frac{\text{cov}(x, z)}{\text{var}(z)}, \quad b = \bar{x} - a\bar{z}$$

$$\hat{y}_i = cz_i + d \quad c = \frac{\text{cov}(y, z)}{\text{var}(z)}, \quad d = \bar{y} - c\bar{z}$$

Les **résidus** se définissent alors comme :

$$e_i^x = x_i - \hat{x}_i \quad e_i^y = y_i - \hat{y}_i$$



La corrélation partielle : explications (*)

On peut définir la **covariance partielle**, $\text{cov}(x, y|z) = s_{xy|z}$ comme :

$$s_{xy|z} := \text{cov}(e^x, e^y)$$

On trouve alors :

$$s_{xy|z} = s_x s_y (r_{xy} - r_{xz} r_{zy})$$

Grâce à cette formule, les **variances partielles** sont :

$$s_{xx|z} = s_x^2 (1 - r_{xz}^2) \quad s_{yy|z} = s_y^2 (1 - r_{yz}^2)$$

Et en posant :

$$r_{xy|z} := \frac{s_{xy|z}}{\sqrt{s_{xx|z} s_{yy|z}}}$$

on obtient notre résultat $r_{xy|z} = \frac{r_{xy} - r_{xz} r_{yz}}{\sqrt{(1 - r_{xz}^2)(1 - r_{yz}^2)}}$.