

Méthodes Quantitatives II :

5. Corrélations inter- et intragroupes et le concept d'entropie

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 123 - 131

Exercices : 7.3, 8.1

Corrélations inter- et intragroupes

Décomposition de la variance (rappel)

En présence d'**une variable numérique x** et d'**une variable catégorielle z** (à m modalités), on a la décomposition :

$$\underbrace{\text{var}(x)}_{\text{variance totale}} = \underbrace{\text{var}_B(x)}_{\text{variance intergroupe}} + \underbrace{\text{var}_W(x)}_{\text{variance intragroupe}}$$

Les $g = 1, \dots, m$ modalités de z définissent m groupes, de **poids relatif** :

$$\rho_g = \frac{n_g}{n} \quad \text{avec} \quad \sum_{g=1}^m \rho_g = 1$$

où n_g est le nombre d'individus appartenant au groupe g , et n la taille de l'échantillon.

Les **moyennes par groupe** et la **moyenne totale** sont :

$$\bar{x}_g = \frac{1}{n_g} \sum_{i \in g} x_i \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \sum_{g=1}^m \rho_g \bar{x}_g$$

Décomposition de la variance (rappel)

La **variance intergroupe** :

$$\text{var}_B(x) = \sum_{g=1}^m \rho_g (\bar{x}_g - \bar{x})^2$$


mesure la fluctuation des moyennes des groupes $\bar{x}_g$ par rapport à la moyenne totale $\bar{x}$.

La **variance intragroupe** :

$$\text{var}_W(x) = \sum_{g=1}^m \rho_g \text{var}_g(x) \quad \text{avec } \text{var}_g(x) = \frac{1}{n_g} \sum_{i \in g} (x_i - \bar{x}_g)^2$$

mesure la fluctuation moyenne des scores dans chacun des groupes.

Décomposition de la variance (rappel)



Deux variables numériques, une catégorielle

La même décomposition a lieu pour toute autre variable numérique y :

$$\text{var}(y) = \text{var}_B(y) + \text{var}_W(y)$$

Mais, chose inédite, on peut également **décomposer la covariance** :

$$\text{cov}(x, y) = \text{cov}_B(x, y) + \text{cov}_W(x, y)$$

où la **covariance intergroupe** est définie par :

$$\text{cov}_B(x, y) = \sum_{g=1}^m \rho_g (\bar{x}_g - \bar{x})(\bar{y}_g - \bar{y})$$

et la **covariance intragroupe** par :

$$\text{cov}_W(x, y) = \sum_{g=1}^m \rho_g \text{cov}_g(x, y)$$

$$\text{avec} \quad \text{cov}_g(x, y) = \frac{1}{n_g} \sum_{i \in g} (x_i - \bar{x}_g)(y_i - \bar{y}_g)$$

Pour gagner en concision, on introduit les notations :

$$s_{xy} := \text{cov}(x, y) \quad s_{xy}^B := \text{cov}_B(x, y) \quad s_{xy}^W := \text{cov}_W(x, y)$$

Ainsi, $s_{xx} = \text{var}(x) = s_x^2$, $s_{xx}^B = \text{var}_B(x)$ et $s_{xx}^W = \text{var}_W(x)$.

On peut disposer ces éléments dans la **matrice de variance-covariance totale** :

$$\mathbf{S} = \begin{pmatrix} s_{xx} & s_{xy} \\ s_{yx} & s_{yy} \end{pmatrix} = \begin{pmatrix} \text{var}(x) & \text{cov}(x, y) \\ \text{cov}(y, x) & \text{var}(y) \end{pmatrix}$$

Et noter cela symboliquement comme :

$$\mathbf{S} = (s_{xy})$$

De même, on note

$$\mathbf{S}^B = \begin{pmatrix} s_{xx}^B & s_{xy}^B \\ s_{yx}^B & s_{yy}^B \end{pmatrix} \quad \mathbf{S}^W = \begin{pmatrix} s_{xx}^W & s_{xy}^W \\ s_{yx}^W & s_{yy}^W \end{pmatrix}$$

et les règles de **décomposition des variances et des covariances** s'écrivent alors simplement comme :

$$\mathbf{S} = \mathbf{S}^B + \mathbf{S}^W$$

où le signe « + » dénote ici l'addition matricielle obtenue par l'addition (ordinaire) des composantes des matrices.

Corrélations : totales, inter- et intragroupes

Pour rappel, les **corrélations ordinaires** (appelées aussi totales dans ce contexte) s'obtiennent à partir des covariances comme :

$$r_{xy} = \frac{\text{cov}(x, y)}{\sqrt{\text{var}(x)\text{var}(y)}} = \frac{s_{xy}}{\sqrt{s_{xx}s_{yy}}}$$

De même, les **corrélations inter- et intragroupes** sont définies par :

$$r_{xy}^B = \frac{s_{xy}^B}{\sqrt{s_{xx}^B s_{yy}^B}} \quad r_{xy}^W = \frac{s_{xy}^W}{\sqrt{s_{xx}^W s_{yy}^W}}$$

On peut bien sûr disposer ces corrélations en tant que composantes des matrices de corrélation (totale, inter- et intragroupe) :

$$\mathbf{R} = (r_{xy}) \quad \mathbf{R}^B = (r_{xy}^B) \quad \mathbf{R}^W = (r_{xy}^W)$$

lesquelles ne sont toutefois pas additives en général, au sens que :

$$\mathbf{R} \neq \mathbf{R}^B + \mathbf{R}^W$$

Exemple I : notes du gymnase (rappel)

identifiant	sexe	lateralite	age	taille	maths	allemand1	allemand2
1	F	D	20	175	10	7	9
2	F	D	17	162	3	4	5
3	M	D	17	160	10	6	6
4	M	G	15	166	10	10	10
5	F	G	19	160	3	7	8
6	F	D	16	168	6	8	10
7	M	D	20	168	7	5	5
8	F	D	17	170	3	5	6
9	F	D	16	173	3	6	7
10	M	G	16	168	9	5	7
11	F	D	18	161	8	6	8
12	F	D	19	176	9	5	8
13	F	D	17	166	9	5	8
14	F	D	16	162	6	5	7
15	F	D	18	158	8	7	8
16	M	D	18	163	9	10	10
17	F	D	15	149	3	5	4
18	M	D	19	176	2	7	8
19	F	D	15	152	4	8	9
20	F	D	15	170	9	9	10

Exemple I : notes du gymnase

On considère la corrélation entre $x = \ll \text{age} \gg$, $y = \ll \text{taille} \gg$, sachant $z = \ll \text{sexe} \gg$. On a par groupe :

sexe	n	age	taille
F	14	17	164
M	6	17.5	167

$$\underbrace{\begin{pmatrix} 2.628 & 4.728 \\ 4.728 & 52.328 \end{pmatrix}}_S = \underbrace{\begin{pmatrix} 0.053 & 0.253 \\ 0.253 & 1.214 \end{pmatrix}}_{s^B} + \frac{14}{20} \underbrace{\begin{pmatrix} 2.429 & 5.071 \\ 5.071 & 62.388 \end{pmatrix}}_{s^f} + \frac{6}{20} \underbrace{\begin{pmatrix} 2.917 & 3.083 \\ 3.083 & 24.806 \end{pmatrix}}_{s^m}$$
$$= \underbrace{\begin{pmatrix} 0.053 & 0.253 \\ 0.253 & 1.214 \end{pmatrix}}_{s^B} + \underbrace{\begin{pmatrix} 2.575 & 4.475 \\ 4.475 & 51.114 \end{pmatrix}}_{s^W}$$

Exemple I : notes du gymnase

Avec :

$$\mathbf{S} = \begin{pmatrix} 2.628 & 4.728 \\ 4.728 & 52.328 \end{pmatrix} \quad \mathbf{S}^B = \begin{pmatrix} 0.053 & 0.253 \\ 0.253 & 1.214 \end{pmatrix} \quad \mathbf{S}^W = \begin{pmatrix} 2.575 & 4.475 \\ 4.475 & 51.114 \end{pmatrix}$$

En utilisant la formule $r_{xy} = \frac{s_{xy}}{\sqrt{s_{xx}s_{yy}}}$, on trouve :

$$\mathbf{R} = \begin{pmatrix} 1 & 0.403 \\ 0.403 & 1 \end{pmatrix} \quad \mathbf{R}^B = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \quad \mathbf{R}^W = \begin{pmatrix} 1 & 0.390 \\ 0.390 & 1 \end{pmatrix}$$

Exemple I : notes du gymnase

On sait que lors d'une régression, la pente $a = r_{xy} \frac{s_y}{s_x}$




Figure 1 : la droite de régression totale (r_{xy}) et en noire, Les droites de régression pour les femmes et les hommes sont de la même couleur que les groupes (r_{xy}^W), et la droite de régression en vert est celle entre les groupes (r_{xy}^B).

Exemple II : données fictives

Dans l'exemple précédent, les pentes des droites de régression sont toutes positives, ce qui implique que $r > 0$, $r^W > 0$ et $r^B > 0$: âge et taille sont positivement corrélés dans l'échantillon en général, dans chacun des deux groupes, et entre les deux groupes. Il n'en va pas nécessairement toujours ainsi :




Figure 2 : Données fictives illustrant $r < 0$ et $r^B < 0$ mais $r^W > 0$.

L'exemple II (avec $r < 0$ et $r^W > 0$, ou l'inverse) est une illustration du **paradoxe d'inversion** ou **paradoxe de Simpson**, qui sera étudié plus loin : la corrélation entre x et y peut être négative dans tout l'échantillon, alors qu'elle peut être positive dans chacun des groupes.

La significativité des coefficients de corrélation intergroupe r^B et intragroupe r^W peut être **testée** (mais pas vu ici).

Les matrices de covariance **S** et de corrélation **R** peuvent naturellement être **étendues à plus de 2 variables numériques**.

Tableau résumé

	z numérique	z catégorielle
x	$\text{var}(x) = \text{var}(\hat{x}) + \text{var}(e)$	$\text{var}(x) = \text{var}_B(x) + \text{var}_W(x)$
x et y	$\text{var}(x) = \text{var}(\hat{x}) + \text{var}(e^x)$ $\text{var}(y) = \text{var}(\hat{y}) + \text{var}(e^y)$ $\text{cov}(x, y z) = \text{cov}(e^x, e^y)$	$\text{var}(x) = \text{var}_B(x) + \text{var}_W(x)$ $\text{var}(y) = \text{var}_B(y) + \text{var}_W(y)$ $\mathbf{S} = \mathbf{S}^B + \mathbf{S}^W$

Le concept d'entropie

Lorsque l'on a une variable numérique x , mesurer la variation des différents scores (autours de la moyenne) passe par le calcul de la **variance** :

$$\text{var}(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Qu'en est-il d'une **variable catégorielle** ? Peut-on créer une mesure similaire ?

Sur une variable catégorielle, on va utiliser les concepts de **variété** et d'**entropie**.

Variable catégorielle : effectifs et fréquences relatives

On dispose de n observations, parmi lesquelles n_1 observations sont de type 1, n_2 sont de type 2,... et finalement n_m sont de type m .

Les **effectifs** n_j et les **fréquences relatives** ou **proportions** $f_j = \frac{n_j}{n}$ vérifient :

$$n_j \geq 0 \quad \sum_{j=1}^m n_j = n \quad f_j = \frac{n_j}{n} \geq 0 \quad \sum_{j=1}^m f_j = 1$$

Il faut distinguer les mesures **relatives** de la variété des mesures **absolues** : les mesures relatives, étudiées ici, ne dépendent que des proportions f , tandis que les secondes dépendent (aussi) de la taille n de l'échantillon.

La variété (simple)

La mesure relative la plus simple, simplement appelée **variété**, consiste à compter le nombre de types j distincts qui apparaissent effectivement, i.e. pour lesquels $f_j > 0$. Formellement :

$$v(f) := \sum_{j=1}^m \mathbf{1}(f_j > 0)$$

où $\mathbf{1}(A)$ est la fonction indicatrice de l'événement A , valant 1 si A est vrai et 0 sinon.

La variété (simple) : défaut

La variété $v(f)$ souffre d'un défaut majeur : **elle ne tient pas compte des valeurs des f_j** , mais distingue seulement les cas $f_j > 0$ et $f_j = 0$.

Prenons un exemple :

- La cafétéria A sert : des pâtes (25% du temps), du riz (25%), de la polenta (25%) ou des patates (25%).
- La cafétéria B sert : des pâtes (97% du temps), du riz (1%), de la polenta (1%) ou des patates (1%).

La variété alimentaire de la cafétéria A est clairement supérieure à celle de la cafétéria B. Cependant, la variété est identique.

On peut aussi dire que le menu de la cafétéria B est plus **prévisible**.

Si l'on possède des fréquences relatives $f = (f_1, \dots, f_m)$, on peut définir l'**incertitude** ou l'**information** du type j avec :

$$h(j) = -\log(f_j)$$

où le logarithme $\log(x) \equiv \log_a(x)$ est défini selon une certaine base a .

L'expression $\log_a(x)$ désigne le **logarithme en base $a > 1$** de $x > 0$, à savoir l'exposant y auquel il faut élever a pour obtenir x :

$$y = \log_a(x) \quad \Leftrightarrow \quad a^y = x$$

Par exemple, $\log_2(32) = 5$ car $2^5 = 32$.

Rappels sur le logarithme

$$\lim_{x \rightarrow 0} \log_a(x) = -\infty$$

$$\log_a(1) = 0$$


$$\log_a(a) = 1$$

$$\lim_{x \rightarrow \infty} \log_a(x) = \infty$$

On a aussi :

$$\lim_{x \rightarrow 0} x \log_a(x) = 0$$

$$0 \log_a(0) = 1 \log_a(1) = 0$$



Finalement peu importe la base a , on a :

$$\log_a(xy) = \log_a(x) + \log_a(y)$$


$$\log_a\left(\frac{x}{y}\right) = \log_a(x) - \log_a(y)$$

$$\log_a(x^y) = y \log_a(x)$$

L'incertitude ou l'information (retour)

L'incertitude ou
l'information du type
 j est :

$$h(j) = -\log_a(f_j)$$



Exemple des cafétérias (en base e) :

- Dans la cafétéria A : tous les plats ont une incertitude de $-\log(0.25) = 1.386$.
- Dans la cafétéria B : les pâtes ont une incertitude de $-\log(0.97) = 0.030$, et les autres plats une incertitude de $-\log(0.01) = 4.605$.

Une bonne mesure de variété relative devrait mesurer l'**incertitude moyenne** sur la catégorie qui va apparaître.

Parmi les nombreuses propositions émises, la mieux justifiée mathématiquement (et de loin) est l'**entropie de Shannon** (1948).

Définition


L'**entropie** d'une variable catégorielle X à m modalités et de distribution f (théorique ou empirique), en base a , est la quantité :

$$H(X) = H(f) := - \sum_{j=1}^m f_j \log_a(f_j)$$

Bornes de l'entropie

Selon la forme de f , la prévision de la valeur de X sera plus ou moins difficile ou incertaine : c'est ce que mesure l'entropie $H(f)$.


- L'entropie est **maximale** lorsque f est uniforme, i.e. $f_j = \frac{1}{m}$ et vaut alors $H(f) = \log_a(m)$.
- L'entropie est **minimale** lorsque f est concentrée sur une catégorie (i.e. déterministe) et vaut alors $H(f) = 0$.



Gauche : $H(f) = \log_a(6)$; Milieu : $0 < H(f) < \log_a(6)$; Droite : $H(f) = 0$

Entropie pour une variable binaire

Soit X une **variable binaire**, avec $f_1 = f$ et $f_2 = 1 - f$. On a alors (en base 2) :



Les bases de l'entropie

Les **bases de a les plus fréquentes** de l'entropie sont :

- $a = 2$, l'entropie a une unité appelée **bits**
- $a = e$, l'entropie a une unité appelée **nats**
- $a = 10$, l'entropie a une unité appelée **digits**

Changer de base revient à **multiplier le logarithme par une constante** (comme pour un changement d'unités en physique) :

$$\log_b(x) = \log_b(a) \log_a(x)$$

Ainsi :

- $1 \text{ digit} = 2.30 \text{ nat} = 3.32 \text{ bit}$
- $1 \text{ nat} = 0.43 \text{ digit} = 1.44 \text{ bit}$
- $1 \text{ bit} = 0.30 \text{ digit} = 0.69 \text{ nat}$

L'écriture $\ln(x)$ ou $\log(x)$ réfère à $\log_e(x)$: logarithme népérien ou naturel.

Exemple I : trois dés

On considère trois dés à 6 faces :

1. Un dé équilibré, où $f_j = \frac{1}{6} = 0.167$. Alors :

$$H(f) = - \sum_{j=1}^6 \frac{1}{6} \log \left(\frac{1}{6} \right) = \log \left(\frac{1}{6} \right) = \log(6) = 1.79 \text{ nats}$$

2. Un dé où $f_5 = \frac{1}{2}$ et les autres faces ont $f_j = \frac{1}{10}$. Alors :

$$H(f) = -\frac{1}{2} \log \left(\frac{1}{2} \right) - 5 \cdot \frac{1}{10} \log \left(\frac{1}{10} \right) = 1.5 \text{ nats}$$

3. Un dé ne faisant que des « 2 ». Alors :

$$H(f) = -1 \log(1) - 5 \log(0) = 0 \text{ nats}$$

Exemple II : « est-il toujours vivant depuis hier ? »

Le taux brut de mortalité correspond au rapport du nombre total de décès enregistrés au cours de l'année à la population résidente permanente moyenne. Il est d'environ 0.8% en Suisse en 2015 (source : OFS). Le taux brut quotidien de mortalité est donc d'environ $0.8\%/65.25 = 0.000022$ (~ 22 morts/million).

L'annonce du décès subit d'un résident, encore en vie la veille mais dont on ignore à peu près tout (l'âge, les comportements, l'état de santé etc.), contient beaucoup d'information, soit environ :

$$-\log_2(0.000022) = 15.47 \text{ bits}$$

contrastant avec l'annonce de sa survie, peu surprenante :

$$-\log_2(1 - 0.000022) = 0.000032 \text{ bits}$$

En moyenne, la question « est-il toujours vivant depuis hier ? » **apporte peu d'information**, environ :

$$0.000022 \cdot 15.47 + (1 - 0.000022) \cdot 0.000032 = 0.00037 \text{ bits}$$

et on la pose rarement.

Exemple III : questions médianes

A l'inverse, les questions dont la réponse apporte **le plus d'information sont celles susceptibles de récolter à peu près une moitié de oui, et une moitié de non.**

Telle serait peut-être (en Suisse en 2018) la question :

- « Êtes-vous pour la légalisation de la consommation de cannabis pour les adultes ? »

par contraste avec les questions :

- « Êtes-vous pour la peine de mort pour les consommateurs de cannabis ? »
- « Êtes-vous pour un accès illimité au cannabis pour les enfants en bas âge ? »

qui ne récolteront que des « non », ou presque.

De même, l'information sur le résultat « pile ou face » du lancer d'une pièce est maximale lorsque la pièce est équilibrée, et vaut 1 bit. Avec une pièce biaisée en faveur de « pile » ou de « face », l'information diminue et vaut moins de 1 bit.

Exemple IV : la fausse pièce d'or

A l'instar d'une énergie, d'une masse ou d'une somme d'argent, l'**information se comporte de façon additive** : **on peut l'additionner ou la soustraire pour établir un bilan.**

Exemple : un tas de 25 pièces d'or contient une "fausse pièce", plus légère que les autres. La différence, imperceptible sans instrument, peut être détectée à l'aide d'une balance à plateaux. Peut-on identifier la fausse pièce en trois pesées ?

Solution : chaque pesée apporte trois réponses possibles : « équilibre », « penche à gauche » ou « penche à droite », soit une information maximale de $\log_3(3) = 1$ « ternits » (en base 3), soit, en trois pesées, 3 ternits.

L'incertitude initiale de sélectionner un pièce (la fausse, précisément) parmi 25 candidats a priori équiprobables vaut $\log_3(25) = 2.93$ ternits. Comme le bilan :

$$\text{information max. acquise} - \text{incertitude initiale} = 3 - 2.93 > 0$$

est positif, il semble possible de répondre par « oui » à la question posée, à condition de s'y prendre astucieusement (reste à trouver la manière).

- L'**incertitude** ou l'**information** d'un événement de probabilité f_j se mesure avec $h(f_j) = -\log_a(f_j)$.
- La mesure classique de la **variété relative** associée à un variable catégorielle à m modalités est donnée par l'**entropie**
 $H(f) = -\sum_j f_j \log_a(f_j)$.
- L'entropie est **maximale** et vaut $\log_a(m)$ lorsque les m catégories sont **équiprobables**.
- L'entropie est **minimale** et vaut 0 lorsqu'**une seule catégorie est possible**.
- L'entropie mesure l'**incertitude a priori** (= avant de connaître la catégorie qui va apparaître) ou, de façon équivalente, l'**information moyenne a posteriori** (= après avoir pris connaissance de la catégorie).
- L'entropie se comporte de façon **additive** (bilan d'entropie), à l'instar d'une énergie, d'une masse ou d'une somme d'argent.