

Méthodes Quantitatives II :

6. Entropie pour deux variables catégorielles

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 131-136

Exercices : 8.2, 8.3

Rappels sur l'entropie pour une variable catégorielle

Introduite comme une **mesure de variété relative pour une variable catégorielle X** , l'entropie $H(X)$ possède également les interprétations équivalentes :

- $H(X)$ = mesure l'**incertitude a priori** sur la catégorie de X .
- $H(X)$ = mesure l'**information moyenne a posteriori** apportée par la connaissance de la catégorie de X .

Formule de l'entropie

En présence d'une variable catégorielle X à m modalités, de fréquences relatives $f_j \geq 0$ avec $\sum_{j=1}^m f_j = 1$, l'**entropie** $H(X)$ de X (ou l'entropie $H(f)$ de sa distribution f) est :

$$H(X) \equiv H(f) = - \sum_{j=1}^m f_j \log f_j$$

Pour le moment, f peut désigner :

- soit la **distribution empirique** (fréquences relatives $f_j = \frac{n_j}{n}$), auquel cas $H(X)$ est l'entropie empirique des scores de la variable X .
- soit la **distribution théorique** (probabilités $f_j = P(X = j)$), auquel cas $H(X)$ est l'entropie théorique de la variable X .

Cela sera précisé selon le contexte.

Maximum et minimum de l'entropie

Pour une variable catégorielle X à m modalités, les **bornes de l'entropie** (en base a) sont :

$$0 \leq H(X) \leq \log_a(m)$$

- Si $H(X) = 0$, le résultat est **déterministe**.
- Si $H(X) = \log_a(m)$, la distribution est **uniforme** sur toutes les catégories.

Les **bases a** les plus utilisées pour l'entropie sont :

- $a = 2$, l'entropie s'exprime en **bits**.
- $a = e$, l'entropie s'exprime en **nats**.
- $a = 10$, l'entropie s'exprime en **digits**.

Exemple I : 2 forêts

On compte le nombre d'arbres de différentes espèces dans 2 forêts, et on obtient :

	Chênes	Pins	Hêtres	Érables	Bouleaux	Total
Forêt A (Nombre)	60	50	40	30	20	200
Forêt A (Proportions)	30%	25%	20%	15%	10%	100%
Forêt B (Nombre)	200	150	100	25	25	500
Forêt B (Proportions)	40%	30%	20%	5%	5%	100%

L'entropie est alors :

$$\begin{aligned}H(\text{Forêt}_A) &= -(0.30 \log_2(0.30) + 0.25 \log_2(0.25) + 0.20 \log_2(0.20) \\&\quad + 0.15 \log_2(0.15) + 0.10 \log_2(0.10)) \\&= 0.521 + 0.500 + 0.464 + 0.410 + 0.332 = 2.227 \text{ bits}\end{aligned}$$

$$\begin{aligned}H(\text{Forêt}_B) &= -(0.40 \log_2(0.40) + 0.30 \log_2(0.30) + 0.20 \log_2(0.20) \\&\quad + 0.05 \log_2(0.05) + 0.05 \log_2(0.05)) \\&= 0.529 + 0.521 + 0.464 + 0.216 + 0.216 = 1.946 \text{ bits}\end{aligned}$$

D'après l'entropie, il y a plus de variété (relative) dans la forêt A.

Exemple II : nouveau né

Un couple d'amis vient d'avoir un nouveau né. Imaginons 2 questions :

1. « C'est une fille ou un garçon ? »
2. « Combien de bras a ton enfant ? »

1. Le résultat X peut prendre deux résultats (fille ou garçon) avec chacun à peu près 50% de chance. L'entropie est donc :

$$H(X) = -\frac{1}{2} \log_2 \left(\frac{1}{2} \right) - \frac{1}{2} \log_2 \left(\frac{1}{2} \right) = \log_2 (2) = 1 \text{ bits}$$

L'entropie est maximal pour 2 catégories : on a beaucoup d'incertitude a priori sur la réponse et l'information moyenne gagnée a posteriori sera grande.

2. Ici, on simplifiera le résultat X avec deux catégories : « 2 bras », avec probabilité 99.99%, ou « n'importe quel autre nombre de bras », avec probabilité 0.01%.

L'entropie est donc :

$$\begin{aligned} H(X) &= -0.9999 \log_2 (0.9999) - 0.0001 \log_2 (0.0001) \\ &= 0.9999 \cdot 0.00014 + 0.0001 \cdot 13.2877 = 0.0015 \text{ bits} \end{aligned}$$

L'entropie est faible : on a peu d'incertitude a priori sur la réponse et l'information moyenne gagnée a posteriori sera faible.

Exemple III : Le roi et les tonneaux

Un roi possède 1000 tonneaux de vin pour un banquet qui a lieu demain. On l'informe qu'un tonneau est empoisonné. Le poison est mortel et agit en exactement 24 heures. Le roi dispose de goûteurs pour tester le vin.

Quel est le nombre minimum de goûteurs nécessaire pour trouver le tonneau empoisonné à temps pour le banquet de demain ?

Exemple III : Le roi et les tonneaux (réponse avec l'entropie)

L'incertitude initiale : il y a 1000 tonneaux suspects, l'incertitude est donc de $H(X) = \log_2(1000) \simeq 9.96$ bits.

L'information d'un goûteur : chaque goûteur a deux résultats possibles, soit survivre, soit mourir. Un goûteur nous apporte donc une information de $\log_2(2) = 1$ bit.

Réponse : il nous faudra donc 10 goûteurs car $10 \cdot 1 \text{ bit} > 9.96 \text{ bits}$.

(Mais comment faire ?)

Exemple III : Le roi et les tonneaux (solution)

Pour trouver la solution, on commence par encoder le numéro des tonneaux en **binaire**. Avec 10 positions de 0 ou 1, on a $2^{10} = 1024$ possibilités, donc suffisamment pour encoder chaque tonneau.

On attribue une position binaire à chaque goûteur (goûteur 1 $\rightarrow$ position 1, goûteur 2 $\rightarrow$ position 2, etc.).

Chaque goûteur doit goûter tous les tonneaux qui possèdent un 1 sur leur position attribuée.

Après 24h, les goûteurs décédés nous donnent alors le code binaire du tonneau. Par exemple, si les goûteurs 2, 4, 6, 9 et 10 sont décédés :

$$0101010011 \rightarrow 340$$

Il s'agit du tonneau 340.

L'entropie pour deux variables catégorielles

L'entropie jointe (bivariée)

On considère maintenant **deux variables catégorielles** X et Y , de modalités $j = 1, \dots, m_1$, respectivement $k = 1, \dots, m_2$.

Définitions

Soit n_{jk} le nombre d'individus dans l'échantillon possédant la modalité j de X et la modalité k de Y . Ces effectifs croisés (qui forment la table de contingence $X \times Y$), définissent, après normalisation, les **proportions jointes** :

$$f_{jk} := \frac{n_{jk}}{n} \geq 0 \quad \text{avec} \quad \sum_{j=1}^{m_1} \sum_{k=1}^{m_2} f_{jk} = 1$$

On définit alors l'**entropie jointe** (empirique) de X et Y par :

$$H(X, Y) := - \sum_{jk} f_{jk} \log f_{jk}$$

L'entropie jointe (bivariée)

Selon ce tableau, les **entropies de X et Y** valent respectivement :

$$H(X) = - \sum_j f_{j\bullet} \log f_{j\bullet}$$

$$H(Y) = - \sum_k f_{\bullet k} \log f_{\bullet k}$$

où

- $f_{j\bullet} = \sum_k f_{jk}$ représente le poids relatif de la catégorie j de X ,
- $f_{\bullet k} = \sum_j f_{jk}$ représente le poids relatif de la catégorie k de Y .

(Naturellement, $\sum_j f_{j\bullet} = 1$ et $\sum_k f_{\bullet k} = 1$)

Quelle est la relation entre $H(X, Y)$ d'une part, et $H(X)$ et $H(Y)$ d'autre part ?

(I) L'entropie jointe est bornée inférieurement par chacune des entropies univariées :

$$H(X) \leq H(X, Y) \quad \text{et} \quad H(Y) \leq H(X, Y)$$

(II) L'entropie jointe est bornée supérieurement par la somme des entropies univariées :

$$H(X, Y) \leq H(X) + H(Y)$$

- (I) dit que l'information apportée par deux variables ne peut jamais être inférieure à l'information apportée par chacune des variables.
- (II) dit que l'information simultanément apportée par deux variables ne peut jamais être supérieure à la somme des informations apportées par chacune des deux variables prises séparément.

Exemple IV : choix d'enseignement selon le genre

Soient $n = 20$ étudiant.e.s de genre $X = \{F, M\}$, qui ont choisi l'un des deux enseignements à option $Y = \{A, B\}$. Les effectifs croisés, les proportions correspondantes et leurs marges sont :

$X \backslash Y$	A	B	
F	5	5	10
M	10	0	10
	15	5	20

$X \backslash Y$	A	B	
F	0.25	0.25	0.5
M	0.5	0	0.5
	0.75	0.25	1

Table 1 : Effectifs croisés n_{jk} et proportions correspondantes f_{jk}

L'entropie jointe ainsi que les entropies univariées valent (en bits) :

- $H(X, Y) = -\frac{1}{4} \log_2 \frac{1}{4} - \frac{1}{4} \log_2 \frac{1}{4} - \frac{1}{2} \log_2 \frac{1}{2} - 0 \log_2 0 = 1.5$
- $H(X) = -\frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{2} \log_2 \frac{1}{2} = 1$
- $H(Y) = -\frac{3}{4} \log_2 \frac{3}{4} - \frac{1}{4} \log_2 \frac{1}{4} = 0.81$

Exemple IV : choix d'enseignement selon le genre (suite)

Concernant les inégalités :

- Les inégalités (I) ($1.5 \geq 1$ et $1.5 \geq 0.81$) sont vérifiées.
- L'inégalité (II) ($1.5 \leq 1 + 0.81 = 1.81$) est vérifiée.

On peut s'intéresser à l'**entropie conditionnelle ponctuelle** (pour une modalité posée) :

- Pour $X = F$, la distribution de Y est $(0.5, 0.5)$, avec une entropie conditionnelle ponctuelle de $H(Y|X = F) = 1$ bit.
- Pour $X = M$, la distribution de Y est $(1, 0)$, avec une entropie conditionnelle ponctuelle de $H(Y|X = M) = 0$.

La moyenne de ces quantités vaut :

$$f_{F\bullet}H(Y|X = F) + f_{M\bullet}H(Y|X = M) = 0.5 \cdot 1 + 0.5 \cdot 0 = 0.5 \text{ bit}$$

et définit l'entropie conditionnelle de Y connaissant X , notée $H(Y|X)$.

Il se trouve que $H(Y|X) = H(X, Y) - H(X) = 1.5 - 1 = 0.5$ bits. Il s'agit d'un résultat général, que l'on peut adopter comme définition.

Définition

L'**entropie conditionnelle** $H(Y|X)$ de Y pour X donné est donnée par l'entropie jointe $H(X, Y)$ soustraite de l'entropie $H(X)$:

$$H(Y|X) := H(X, Y) - H(X)$$

Les inégalités (I) et (II) entraînent immédiatement que :

$$0 \leq H(Y|X) = H(X, Y) - H(X) \leq H(Y)$$

Naturellement, on a aussi (en échangeant X et Y) :

$$0 \leq H(X|Y) = H(X, Y) - H(Y) \leq H(X)$$

Définition

L'**information mutuelle**, qui est symétrique, se définit comme :

$$I(X : Y) = H(X) + H(Y) - H(X, Y)$$

Là aussi, les inégalités (I) et (II) entraînent que :

$$0 \leq I(X : Y) \leq H(X) \quad \text{et} \quad 0 \leq I(X : Y) \leq H(Y)$$

On commence à disposer de plusieurs quantités dérivées, qu'il s'agit :

- De bien **interpréter**.
- De bien **identifier** et **calculer**.

Par construction :

$$H(Y) = I(X : Y) + H(Y|X)$$

(variété de Y = variété expliquée par X + variété résiduelle)

Le diagramme de Venn de la Théorie de l'Information




Figure 1 : Relations entre les quantités précédentes. Attention : l'extérieur du diagramme n'a aucune signification.

Exemple IV : choix d'enseignement selon le genre (suite)

$X \backslash Y$	A	B	
F	0.25	0.25	0.5
M	0.5	0	0.5
	0.75	0.25	1

On a (en bits) :

$$H(X, Y) = -\frac{1}{4} \log_2 \frac{1}{4} - \frac{1}{4} \log_2 \frac{1}{4} - \frac{1}{2} \log_2 \frac{1}{2} - 0 \log_2 0 = 1.5$$

$$H(X) = -\frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{2} \log_2 \frac{1}{2} = 1$$

$$H(Y) = -\frac{3}{4} \log_2 \frac{3}{4} - \frac{1}{4} \log_2 \frac{1}{4} = 0.81$$

Et donc :

$$H(X|Y) = H(X, Y) - H(X) = 0.5$$

$$H(Y|X) = H(X, Y) - H(Y) = 0.69$$

$$I(X : Y) = H(X) + H(Y) - H(X, Y) = 1.81 - 1.5 = 0.31$$

Deux définitions de base : $X \perp Y$ et $X \succeq Y$

La notation $X \perp Y$, qui dit que les variables X et Y sont **indépendantes**, signifie selon le contexte que :

- (contexte théorique) $P(X = j \text{ et } Y = k) = P(X = j)P(Y = k)$ (indépendance au sens propre).
- (contexte empirique) $f_{jk} \simeq f_{j\bullet}f_{\bullet k}$ (absence de liaison).

La notation $X \succeq Y$ dit que X **détermine fonctionnellement** Y , i.e. que la connaissance de chaque catégorie j de X détermine la catégorie k de Y . On dit encore que :

- Y **dépend fonctionnellement** de X .
- X est **plus fin** que Y .
- Y est **plus grossier** que X .
- X est **emboîté** dans Y .
- les catégories de Y résultent d'une **agrégation** des cat. de X .

Le cas particulier $X \perp Y$




Figure 2 : Les « ensembles » correspondant à X et Y sont ici disjoints, ce qui rend l'information mutuelle $I(X : Y)$ nulle.

Le cas particulier $X \succeq Y$




Figure 3 : X est ici plus fin que Y ($X \succeq Y$), i.e. Y est connu si X l'est.

Exemple V : enseigne et couleur d'une carte

Soit X l'*enseigne* d'une carte (pique, trèfle, cœur ou carreau) et Y la *couleur* d'une carte (noir ou rouge) :

$Y \backslash X$	pique	trèfle	cœur	carreau	
noir	0.25	0.25	0	0	0.5
rouge	0	0	0.25	0.25	0.5
	0.25	0.25	0.25	0.25	

On a (en bits) :

$$H(X) = 2 \quad H(Y) = 1 \quad H(X, Y) = 2$$

Et donc :

$$H(X|Y) = H(X, Y) - H(Y) = 1$$

$$H(Y|X) = H(X, Y) - H(X) = 0$$

$$I(X : Y) = H(X) + H(Y) - H(X, Y) = 1$$

L'entropie conditionnelle $H(Y|X)$ mesure **l'incertitude sur Y connaissant X** . Elle satisfait :

$$0 \leq H(Y|X) \leq H(Y)$$

- La **borne supérieure** $H(Y)$ est atteinte ssi $X \perp Y$.
- La **borne inférieure** 0 est atteinte ssi $X \succeq Y$.

L'information mutuelle :

$$I(X : Y) = H(X) + H(Y) - H(X, Y)$$

mesure **la dépendance entre X et Y** : on a toujours $I(X : Y) \geq 0$, avec $I(X : Y) = 0$ ssi $X \perp Y$.

Dans le contexte empirique, le coefficient du chi2 possédait exactement la même propriété. En fait, on peut prouver que, approximativement :

$$\text{chi2} \simeq 2n \cdot I(X : Y)$$

où n est la taille de l'échantillon et où $I(X : Y)$ est mesuré en nats.
Ainsi, chaque fois qu'on utilise un test du chi2, on peut utiliser la variable de décision $2n \cdot I(X : Y)$ à la place (et réciproquement).

Quelques cas particuliers :

- $H(X, X) = H(X)$
- $H(X|X) = 0$
- $I(X : X) = H(X)$

L'entropie conditionnelle $H(Y|X)$ ne peut jamais dépasser $H(Y)$. La connaissance de X ne peut qu'améliorer celle de Y .

Plus généralement, une quantité telle que $H(XZ|YW)$ désigne l'incertitude conditionnelle sur les modalités prises par les deux variables X et Z , connaissant les deux modalités des deux variables Y et W .

Dans l'expression $H(.|.)$

Ainsi :

- La partie **avant** le symbole $\ll | \gg$ désigne ce que l'**on ne connaît pas**.
- La partie **après** le symbole $\ll | \gg$ désigne ce que l'**on connaît**.
- Plus il y a de variables avant $\ll | \gg$, plus grande est $H(.|.)$.
- Plus il y a de variables après $\ll | \gg$, plus petite est $H(.|.)$.

Par exemple, on a toujours :

$$\begin{aligned}H(UXZ|YW) &\geq H(XZ|YW) \geq H(X|YW) \\ H(XZ|YW) &\leq H(XZ|Y) \leq H(XZ)\end{aligned}$$

et ainsi de suite.

Exemple VI : analyse de flux

Un flux est caractérisé par le nombre d'unités n_{jk} (personnes, matière, biens, argent...) qui se trouvent dans la région j à un moment donné, puis dans la région k à un certain temps $T > 0$ ultérieur.

En présence de m régions :

- La variable « origine » X possède m modalités.
- la variable « destination » Y possède également m modalités.

et les effectifs n_{jk} forment une table de contingence de taille $m \times m$ associée aux variables X et Y .

- $H(X)$ est l'incertitude associée à la question : « d'où vient-elle ? »
- $H(Y)$ est l'incertitude associée à la question : « où va-t-elle ? »
- $H(Y|X)$ est l'incertitude associée à la question : « où va-t-elle, sachant d'où elle vient ? »
- $H(X|Y)$ est l'incertitude associée à la question : « d'où vient-elle, sachant où elle est allée ? »

Exemple VI (a) : flux de migrants dans l'ouest des US

Flux de migrants (ayant changé de domicile) entre 2006 et 2010 parmi $m = 237$ comtés (counties) de l'ouest étasunien (Washington, Oregon, Idaho, California, Nevada, Utah et Arizona). [Bavaud, F., Kordi, M., and Kaiser, C. (2018). *Flow autocorrelation : a dyadic approach. The Annals of Regional Science*, 61(1), 95-111.]




Figure 4 : carte des comtés US (source : wikipedia)

En notant par X l'origine et Y la destination des migrants, on obtient (en nats)
 $H(X) = 4.20$, $H(Y) = 4.36$ et $H(X, Y) = 7.47$. D'où l'on déduit que $H(X|Y) = 3.11$,
 $H(Y|X) = 3.24$ et $I(X : Y) = 1.12$

L'inégalité $H(X|Y) < H(Y|X)$ signifie qu'il est plus difficile de savoir où va un migrant (sachant d'où il part) que de savoir d'où il vient (sachant qu'il est arrivé là.).

Exemple VI (b) : flux pendulaires en Suisse romande

Flux de pendulaires entre communes de domicile et communes de travail, pour les $m = 895$ communes de Suisse romande en 2000.



Figure 5 : Communes de Suisse (source : bfs.admin.ch)

En notant par X l'origine et Y la destination des pendulaires, on obtient (en nats)
 $H(X) = 6.61$, $H(Y) = 6.35$ et $H(X, Y) = 12.33$. D'où l'on déduit que
 $H(X|Y) = 5.98$, $H(Y|X) = 5.72$ et $I(X : Y) = 0.63$.

L'inégalité $H(X|Y) > H(Y|X)$ signifie qu'il est plus facile de savoir où va travailler quelqu'un (sachant où il habite) que de savoir où il habite (sachant où il travaille).

De façon équivalente, $H(X) > H(Y)$: la variété des destinations est moindre que celle des origines.