

Méthodes Quantitatives II :

7. Dépendances et entropies pour trois variables catégorielles

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 136 - 144

Exercices : 8.4 - 8.6

Rappels sur l'entropie

Entropie avec une variable

En présence d'une variable catégorielle X à m modalités, de fréquences relatives $f_j \geq 0$ avec $\sum_{j=1}^m f_j = 1$, l'**entropie** $H(X)$ de X est :

$$H(X) \equiv H(f) = - \sum_{j=1}^m f_j \log_a(f_j)$$

On a :

$$0 \leq H(X) \leq \log_a(m)$$

- Si $H(X) = 0$, le résultat est **déterministe**.
- Si $H(X) = \log_a(m)$, la distribution est **uniforme** sur toutes les catégories.

Puisque l'entropie vérifie $0 \leq H(X) \leq \log_a(m)$, il nous est possible de construire la **variété effective**, notée $\text{eff}(X)$ de la manière suivante :

$$\text{eff}(X) := a^{H(X)}$$

Par construction, $1 \leq \text{eff}(X) \leq m$, ce qui rend cette quantité plus aisée à interpréter que l'entropie.

La variété effective*

Prenons quatre distributions sur des dés à 6 faces :

	1	2	3	4	5	6
Dé 1	1/6	1/6	1/6	1/6	1/6	1/6
Dé 2	1/2	1/10	1/10	1/10	1/10	1/10
Dé 3	1/2	1/2	0	0	0	0
Dé 4	1	0	0	0	0	0

On a :

$$H(\text{Dé 1}) = 1.79 \text{ nats}$$

$$H(\text{Dé 2}) = 1.50 \text{ nats}$$

$$H(\text{Dé 3}) = 0.69 \text{ nats}$$

$$H(\text{Dé 4}) = 0 \text{ nats}$$

Avec la variété effective :

$$\text{eff}(\text{Dé 1}) = \exp(1.79) = 6$$

$$\text{eff}(\text{Dé 2}) = \exp(1.50) = 4.47$$

$$\text{eff}(\text{Dé 3}) = \exp(0.73) = 2$$

$$\text{eff}(\text{Dé 4}) = \exp(0) = 1$$

Soit n_{jk} le nombre d'individus dans l'échantillon possédant la modalité j de X et la modalité k de Y . Ces effectifs croisés définissent, après normalisation, les **proportions jointes** :

$$f_{jk} := \frac{n_{jk}}{n} \geq 0 \quad \text{avec} \quad \sum_{j=1}^{m_1} \sum_{k=1}^{m_2} f_{jk} = 1$$

On définit alors l'**entropie jointe** (empirique) de X et Y par :

$$H(X, Y) := - \sum_{jk} f_{jk} \log f_{jk}$$

Elle vérifie les propriétés suivantes :

$$H(X) \leq H(X, Y) \quad H(Y) \leq H(X, Y) \quad H(X, Y) \leq H(X) + H(Y)$$

L'**entropie conditionnelle** $H(Y|X)$ de Y sachant X est donnée par :

$$H(Y|X) := H(X, Y) - H(X)$$

On a :

$$0 \leq H(Y|X) \leq H(Y) \quad 0 \leq H(X|Y) \leq H(X)$$


L'**information mutuelle**, qui est symétrique, se définit comme :

$$I(X : Y) = H(X) + H(Y) - H(X, Y)$$

Avec :

$$0 \leq I(X : Y) \leq H(X) \quad \text{et} \quad 0 \leq I(X : Y) \leq H(Y)$$

Le diagramme de Venn de la Théorie de l'Information



Relations entre les quantités précédentes. Attention : l'extérieur du diagramme n'a aucune signification.

Exemple I : patients

Il y a 100 patients dans une salle d'attente d'un hôpital :

$X \backslash Y$	Pas de taches	Taches rouges	
Sain	60	5	65
Malade	15	20	35
	75	25	100

On calcule :

$$H(X) = -0.65 \log_2(0.65) - 0.35 \log_2(0.35) = 0.93 \text{ bits}$$

$$H(Y) = -0.75 \log_2(0.75) - 0.25 \log_2(0.25) = 0.81 \text{ bits}$$

$$H(X, Y) = -0.6 \log_2(0.6) - 0.05 \log_2(0.05) - 0.15 \log_2(0.15) - 0.2 \log_2(0.2) = 1.53 \text{ bits}$$

Ce qui nous donne :

$$H(X|Y) = H(X, Y) - H(Y) = 1.53 - 0.81 = 0.72 \text{ bits}$$

$$H(Y|X) = H(X, Y) - H(X) = 1.53 - 0.93 = 0.60 \text{ bits}$$



$$I(X : Y) = H(X) + H(Y) - H(X, Y) = 0.93 + 0.81 - 1.53 = 0.21 \text{ bits}$$

Indépendance et dépendance fonctionnelle

La notation $X \perp Y$, qui dit que les variables X et Y sont **indépendantes**, signifie selon le contexte que :

- (contexte théorique) $P(X = j \text{ et } Y = k) = P(X = j)P(Y = k)$ (indépendance au sens propre).
- (contexte empirique) $f_{jk} = f_{j\bullet}f_{\bullet k}$ (absence de liaison).

La notation $X \succeq Y$ dit que Y **dépend fonctionnellement** de X , i.e. la connaissance de chaque catégorie j de X détermine la catégorie k de Y .



Trois variables catégorielles

Avec **trois variables** X , Y et Z , plusieurs relations d'**indépendance** apparaissent :

- **Indépendance complète** : $X \perp Y \perp Z$.
- **Indépendance 2 à 2** : $X \perp Y$, $X \perp Z$, $Y \perp Z$.
- **Indépendance d'une variable par rapport aux deux autres**
 $X \perp (Y, Z)$, $Y \perp (X, Z)$, $Z \perp (X, Y)$.
- **Indépendance conditionnelle** : $X \perp Y|Z$, $X \perp Z|Y$,
 $Y \perp Z|X$.

Indépendance complète : $X \perp Y \perp Z$.

L'**indépendance complète** $X \perp Y \perp Z$ signifie que, pour toutes les catégories possibles j de X , k de Y et l de Z , on a :

Contexte théorique :

$$P(X = j \text{ et } X = k \text{ et } Z = l) = P(X = j)P(Y = k)P(Z = l)$$

Contexte empirique :

$$f_{jkl} = f_{j\bullet\bullet}f_{\bullet k\bullet}f_{\bullet\bullet l}$$

De façon équivalente :

$$H(X, Y, Z) = H(X) + H(Y) + H(Z)$$

Indépendance entre une variable et les deux autres variables : $X \perp (Y, Z)$

L'**indépendance** $X \perp (Y, Z)$ signifie que, pour toutes les catégories possibles j de X , k de Y et l de Z , on a :

Contexte théorique :

$$P(X = j | Y = k \text{ et } Z = l) = P(X = j)$$

Contexte empirique :

$$f_{jkl} = f_{j\bullet\bullet} f_{\bullet kl}$$

De façon équivalente :

$$H(X, Y, Z) = H(X) + H(Y, Z)$$

Indépendance de deux variables conditionnellement à une autre : $X \perp Y|Z$

L'**indépendance** $X \perp Y|Z$ signifie que, pour toutes les catégories possibles j de X , k de Y et l de Z , on a :

Contexte théorique :

$$P(X = j \text{ et } Y = k | Z = l) = P(X = j | Z = l)P(Y = k | Z = l)$$

Contexte empirique :

$$f_{jkl} = \frac{f_{j\bullet l} f_{\bullet k l}}{f_{\bullet\bullet l}}$$

De façon équivalente :

$$H(X, Y|Z) = H(X|Z) + H(Y|Z)$$

Les différentes relations d'indépendance ont différentes implications entre elles :

- $X \perp Y$ **n'implique pas** la relation d'indépendance conditionnelle $X \perp Y|Z$, **ni inversement**.
- $X \perp Y \perp Z$ **implique** $X \perp Y$, $X \perp Z$ et $Y \perp Z$.
- $X \perp Y$, $X \perp Z$ et $Y \perp Z$ **n'implique pas** $X \perp Y \perp Z$.
- $X \perp (Y, Z)$ **si et seulement si** $X \perp Y|Z$ et $X \perp Z$
- La relation $X \perp (Y, Z)$ est **plus contraignante** que chacune des relations $X \perp Y|Z$ et $X \perp Z|Y$.

Exemple II : performances scolaires

L'énoncé :

« performance scolaire » $\perp$ (« revenu parents », « formation parents »)

dit que la performance scolaire ne dépend ni du revenu, ni de la formation des parents (généralement tenu pour faux).

On a vu que cet énoncé est équivalent à :

« performance scolaire » $\perp$ « revenu parents » | « formation parents »

(généralement tenu pour vrai) et :

« performance scolaire » $\perp$ « formation parents »

(généralement tenu pour faux).

Exemple III : pièces de monnaie

On considère trois pièces de monnaie pouvant chacune prendre les valeurs pile ou face, respectivement codées comme $X = 0, 1$, $Y = 0, 1$ et $Z = 0, 1$.

Cependant, ces pièces ne sont pas indépendantes : au lieu d'y trouver les 8 possibilités équiprobables $(0,0,0)$, $(1,0,0)$, $(0,1,0)$, $(1,1,0)$, $(0,0,1)$, $(1,0,1)$, $(0,1,1)$ et $(1,1,1)$ du cas indépendant, il n'y a ici que 4 possibilités équiprobables pour (X, Y, Z) , à savoir

$$(X, Y, Z) = (1, 1, 1), (1, 0, 0), (0, 1, 0) \text{ et } (0, 0, 1).$$

- Ici, chaque variable prend les valeurs 1 et 0 avec la même fréquence 50%, et ainsi $H(X) = H(Y) = H(Z) = 1$ bit
- aussi, chaque paire de variables contient les profils $(1,1)$, $(1,0)$, $(0,1)$ et $(0,0)$ avec la même fréquence 25%, et ainsi $H(X, Y) = H(X, Z) = H(Y, Z) = 2$ bits
- enfin, chacun des 4 profils trivariés possibles est de fréquence 25%, d'où $H(X, Y, Z) = 2$ bits.

Exemple III : pièces de monnaie (suite)

En conclusion :

- les trois variables sont indépendantes deux à deux : $X \perp Y$, car $I(X : Y) = H(X) + H(Y) - H(X, Y) = 1 + 1 - 2 = 0$ (ainsi que $Y \perp Z$ et $X \perp Z$).
- par contre, les trois variables ne sont pas complètement indépendantes : il est faux que $X \perp Y \perp Z$, car $H(X, Y, Z) = 2 < H(X) + H(Y) + H(Z) = 3$.

Ici, la connaissance de deux variables entraîne celle de la troisième variable : on a que :

$$H(X|Y, Z) = H(X, Y, Z) - H(Y, Z) = 2 - 2 = 0$$

De même, $H(Y|X, Z) = 0$ et $H(Z|X, Y) = 0$

Définition

L'**information mutuelle conditionnelle** $I(X : Y|Z)$ entre X et Y pour Z donné, se définit par :

$$I(X : Y|Z) := H(X|Z) + H(Y|Z) - H(X, Y|Z)$$

De façon équivalente :

$$I(X : Y|Z) = H(X, Z) + H(Y, Z) - H(X, Y, Z) - H(Z)$$

L'information mutuelle conditionnelle $I(X : Y|Z)$ mesure la dépendance entre X et Y pour Z donné. Elle est non négative, avec :

$$I(X : Y|Z) = 0 \quad \Leftrightarrow \quad X \perp Y|Z$$

Exemple IV : magasins

La table de contingence $X \times Y \times Z$ ci-après, de taille $2 \times 2 \times 2$ illustre le cas $X \perp Y|Z$ et $X \not\perp Y$:

		Z : lieu d'achat			
		épicerie		supermarché	
		Y : paiement		Y : paiement	
		carte	espèces	carte	espèce
X : catégorie d'articles	boissons	6	12	2	3
	snacks	4	8	6	9

Pour $Z = \ll \text{épicerie} \gg$, les effectifs croisés $X \times Y$ observés de la table 2×2 coïncident exactement avec les effectifs théoriques sous l'hypothèse d'indépendance. Il en est de même pour $Z = \ll \text{supermarché} \gg$.

En clair, $X \perp Y|Z$.

Exemple IV : magasins (suite)

Est-ce que $X \perp Y$? Pour le savoir, on agrège les données du tableau selon les deux modalités $Z = \ll \text{épicerie} \gg$ et $Z = \ll \text{supermarché} \gg$, qui donne alors le tableau :

		Y : paiement	
		carte	espèce
X : catégorie d'articles	boissons	15	8
	snacks	10	17

dans lequel les effectifs observés ne coïncident pas avec les effectifs attendus sous indépendance $X \perp Y$, qui sont :

		Y : paiement	
		carte	espèce
X : catégorie d'articles	boissons	8.28	14.72
	snacks	9.72	17.28

Ainsi, $X \not\perp Y$ d'un point de vue empirique (même si le χ^2 associé à la table $X \times Y$ ci-dessus n'est pas significatif).

La possibilité que $X \not\perp Y$ alors que $X \perp Y|Z$ est assez intuitive :

P1 : « il est troublant de constater à quel point certaines formes de criminalité en Suisse sont liées à la nationalité des criminels »

P2 : « oui, mais cela s'explique entièrement par les différences de revenu / de précarité / de statut légal / de support social etc. entre les populations impliquées »

Du point de vue de la modélisation quantitative, on peut essayer d'« expliquer » tout pattern de dépendance entre X et Y en construisant une nouvelle variable Z dite **latente** (= inobservée), telle que $X \perp Y|Z$: ce sont les **modèles à variables latentes**.

Exemple V : médicaments

La table de contingence $X \times Y \times Z$ ci-après, de taille $2 \times 2 \times 2$ illustre, à l'inverse, le cas $X \not\perp Y|Z$ et $X \perp Y$:

		Z : sexe			
		masculin		féminin	
		Y : guérison		Y : guérison	
		oui	non	oui	non
X : médicament	avec	80	40	20	10
	sans	100	80	100	20

- La proportion de guérisons chez les hommes passe de $80/120 = 0.66$ avec médicament à $100/180 = 0.56$ sans médicament.
- Pour les femmes, elle passe de $20/30 = 0.66$ avec médicament à $100/120 = 0.83$ sans médicament.

Pour chaque sexe pris séparément, il y a dépendance entre « guérison » et « prise de médicament » : bénéfique chez les hommes, le médicament se révèle nocif pour les femmes. En clair, $X \not\perp Y|Z$.

Exemple V : médicaments (suite)

En ne prenant pas en compte le sexe du patient, i.e. en agrégeant les données selon Z , on obtient le tableau :

		Y : guérison	
		oui	non
X : médicament	avec	100	50
	sans	200	100

où les effectifs empiriques coïncident avec les effectifs attendus sous indépendance : ainsi, $X \perp Y$.

Ici, les valeurs des données font que les bénéfices de la prise de médicament chez les hommes compensent exactement les méfaits de la prise de médicament chez les femmes, ce qui rend le médicament neutre au niveau de la population générale (i.e. sans distinction de sexe).

Le fait de ne pas désagréger peut amener à des résultats étranges, comme le montre l'exemple suivant.

Exemple VI : taux de réussite au baccalauréat

On considère les effectifs croisés (fictifs) des résultats aux examens de baccalauréat dans deux écoles A et B d'une certaine ville :

		Z : école			
		A		B	
		Y : résultat		Y : résultat	
		réussite	échec	réussite	échec
X : genre	femme	15	35	9	1
	homme	1	9	35	15

- Dans l'école A, le taux de réussite est de $\frac{15}{15+35} = 30\%$ chez les femmes, $\frac{1}{1+9} = 10\%$ chez les hommes.
- Dans l'école B, le taux de réussite est de $\frac{9}{9+1} = 90\%$ chez les femmes, $\frac{35}{35+15} = 70\%$ chez les hommes.

Exemple VI : taux de réussite au baccalauréat (suite)

Si l'on agrège les résultats des deux écoles, on obtient :

		Y : résultat	
		réussite	échec
X : genre	femme	24	36
	homme	36	24

soit un taux de réussite global de :

- $\frac{24}{24+36} = 40\%$ chez les femmes.
- $\frac{36}{36+24} = 60\%$ chez les hommes.

En résumé :

- Dans l'école A, les femmes réussissent mieux que les hommes.
- Dans l'école B, les femmes réussissent mieux que les hommes.
- Mais, dans l'ensemble des écoles $A \cup B$, les hommes réussissent mieux que les femmes !

Paradoxe d'inversion (paradoxe de Simpson)

L'exemple V (taux de réussite au baccalauréat) illustre le **paradoxe d'inversion** ou **paradoxe de Simpson** :


- Le **Tout** (niveau « agrégé », ou « global ») peut être **inversé par rapport à chacune des Parties** (niveau « trié » selon les valeurs de Z , ou « désagrégé », ou encore « local ») qui le constituent.
- Dans l'exemple du taux de réussite au baccalauréat :
l'« explication » du paradoxe tient au fait que la plupart des femmes fréquentent l'école A, dont les taux moyens de réussite sont nettement inférieurs à ceux de l'école B, laquelle est fréquentée en majorité par les hommes.

Paradoxe d'inversion (suite)

- Autre exemple célèbre (P.J. Bickel, E.A. Hammel et J.W. O'Connell (1975) « Sex Bias in Graduate Admissions : Data From Berkeley » *Science* 187 (4175) pp. 398-404) : le taux d'admission global aux études postgrades de l'Université de Californie à Berkeley, tous programmes confondus, était dans les années 70 nettement plus faible pour les femmes que pour les hommes.
- Cependant, programme par programme (niveau désagrégé), le taux d'admission des femmes était chaque fois supérieur à celui des hommes..
- Explication : les femmes, effectivement meilleures (ou mieux préparées, ou favorisées, ou pour toute autre raison) choisissaient préférentiellement des études plus sélectives que les hommes, pour lesquelles il y avait davantage de compétition entre postulant.e.s, et pour lesquelles le taux d'acceptation était par conséquent plus faible.

Paradoxe d'inversion (suite)

Autre exemple fictif : la corrélation totale entre le salaire mensuel (des économistes US dans les années 90) et les années de formation est négative.



Trié par employeur (secteur privé=cercles ; secteur public=carrés ; université=triangles), la **corrélation intragroupe est positive**, comme attendu.

Dans l'exemple du taux de réussite au baccalauréat : il est, au sens strictement logique, correct de dire que :

1. « Les hommes sont meilleures que les femmes » (en considérant les données agrégées).
2. « Les femmes sont meilleurs que les hommes » (en considérant chaque école).

Cela étant, l'énoncé 2 est probablement moins trompeur que l'énoncé 1 : il prend en compte le contexte (l'école) qui semble être un facteur important dans le taux de réussite.

Paradoxe d'inversion (en guise de conclusion)

En général :

- Si une « variable de tri » Z existe, **il est recommandé de reporter les résultats conditionnellement aux modalités Z** (et non pas seulement globalement)
- **Cela n'empêche nullement l'existence d'une « autre variable de tri » W** (disponible dans les données ou non) dont le conditionnement pourrait à nouveau inverser les choses.
- En présence du paradoxe d'inversion (toujours possible a priori), l'expérience montre que mêmes les personnes les plus expérimentées peuvent se faire piéger ; ce qui reflète l'aspect très **contre-intuitif** du paradoxe.