

Méthodes Quantitatives II :

8. Distributions empiriques et théoriques : l'entropie relative

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 145 - 154

Exercices : Série 9

L'entropie relative

Dans notre contexte de variables catégorielle, Il est temps de distinguer les contextes **empiriques** et **théoriques**, c'est-à-dire de confronter les données et les modèles (la base de l'inférence).

Pour cela, la mesure adéquate est l'**entropie relative** $K(f||g)$ entre deux distributions f et g . C'est une nouvelle quantité, que l'on va :

- Définir.
- Examiner quelques unes des propriétés formelles.
- Discuter ses implications épistémologiques et statistiques.

Soient f et g **deux distributions sur les mêmes m modalités** :

- $f_j \geq 0, \sum_{j=1}^m f_j = 1$
- $g_j \geq 0, \sum_{j=1}^m g_j = 1$

Définition

L'**entropie relative** ou **divergence de Kullback-Leibler** entre f et g , notée $K(f||g)$ est la quantité :

$$K(f||g) := \sum_{j=1}^m f_j \log \left(\frac{f_j}{g_j} \right)$$

Rappel : $K(f||g) := \sum_{j=1}^m f_j \log \left(\frac{f_j}{g_j} \right)$

Aussi, pour $a > 0$: $a \log \left(\frac{a}{0} \right) = \infty$, $0 \log \left(\frac{0}{a} \right) = 0$, $0 \log \left(\frac{0}{0} \right) = 0$

- $K(f||g) \geq 0$
- $K(f||g) = 0 \iff f \equiv g$
- $K(f||g) \neq K(g||f)$ en général
- $K(f||g) = \infty$ ss'il existe une modalité j telle que $f_j > 0$ et $g_j = 0$
- Si $g_j > 0$, alors $K(f||g) < \infty$.

Approximation par le chi-carré

Si f et g sont proches, alors, approximativement, pour autant que l'entropie relative **soit mesurée en nats** (log naturel) :

$$K(f||g) \cong \frac{1}{2n} \text{chi2}(f||g) \quad \text{où} \quad \text{chi2}(f||g) = n \sum_{j=1}^m \frac{(f_j - g_j)^2}{g_j}$$

Le chi2 divisé par n , c'est-à-dire la quantité :

$$\text{phi2} := \frac{1}{n} \text{chi2} = \sum_{j=1}^m \frac{(f_j - g_j)^2}{g_j}$$

est appelée **phi-carré**. Par construction, $K(f||g) \cong \frac{1}{2} \text{phi2}(f||g)$.

Exemple I : distributions trimodales

Avec les distributions trimodales $f^A = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ et $f^B = (\frac{1}{5}, \frac{1}{5}, \frac{3}{5})$, on obtient (en nats) :

$$K(f^A || f^B) = \frac{1}{3} \ln \frac{1/3}{1/5} + \frac{1}{3} \ln \frac{1/3}{1/5} + \frac{1}{3} \ln \frac{1/3}{3/5} = 0.145$$

$$K(f^B || f^A) = \frac{1}{5} \ln \frac{1/5}{1/3} + \frac{1}{5} \ln \frac{1/5}{1/3} + \frac{3}{5} \ln \frac{3/5}{1/3} = 0.148$$

dont l'approximation donne :

$$\frac{1}{2} \text{phi2}(f^A || f^B) = 0.148$$

$$\frac{1}{2} \text{phi2}(f^B || f^A) = 0.160$$

Exemple I : distributions trimodales, suite

Avec $f^A = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$, $f^B = (\frac{1}{5}, \frac{1}{5}, \frac{3}{5})$ et $f^C = (1, 0, 0)$, on obtient (en nats) :

$$K(f^A||f^C) = \frac{1}{3} \ln \frac{1/3}{1} + \frac{1}{3} \ln \frac{1/3}{0} + \frac{1}{3} \ln \frac{1/3}{0} = \infty$$

$$K(f^B||f^C) = \infty$$

à cause de $a \log \frac{a}{0} = \infty$ pour $a > 0$.

En revanche, pour f^C par rapport à f^A et f^B :

$$K(f^C||f^A) = 1 \ln \frac{1}{1/3} + 0 \ln \frac{0}{1/3} + 0 \ln \frac{0}{1/3} = \ln 3 = 1.099$$

$$K(f^C||f^B) = 1 \ln \frac{1}{1/5} + 0 \ln \frac{0}{1/5} + 0 \ln \frac{0}{3/5} = \ln 5 = 1.609$$

Distribution multinomiale et entropie relative

Soit X une variable catégorielle aux modalités $j = 1, \dots, m$. Soit $p_j \geq 0$ (avec $\sum_{j=1}^m p_j = 1$) la probabilité que $X = j$.

Rappel : la probabilité d'observer n_j fois la modalité j (avec $\sum_{j=1}^m n_j = n$) est donnée par la **distribution multinomiale** :

$$P(n_1, \dots, n_m) = \frac{n!}{n_1! n_2! \dots n_m!} p_1^{n_1} p_2^{n_2} \dots p_m^{n_m}$$

On observe ensuite une **réalisation**, $n_1, \dots, n_m$, on aura alors 2 distributions :

- La **distribution théorique** de composantes $f_j^M = p_j$
- la **distribution empirique** de composantes $f_j^D = \frac{n_j}{n}$.

Théorème

Pour n grand, on peut **réécrire la loi multinomiale** comme :

$$P(f^D|f^M) \doteq \exp(-nK(f^D||f^M))$$

Le signe $\doteq$ dénote l'**égalité asymptotique**, et peut être en gros lu comme égal dans la limite $n \rightarrow \infty$.

Ce théorème dit que le comportement asymptotique (= pour n grand) de $P(f^D|f^M)$ est déterminé par l'entropie relative $K(f^D||f^M)$ (mesurée en nats), ainsi que la taille de l'échantillon n .

Distribution multinomiale et entropie relative (suite)

On peut penser à un dé (pas forcément équilibré) à m faces, aux probabilités f^M . L'équation

$$P(f^D | f^M) \doteq \exp(-nK(f^D || f^M))$$

implique que, **la distribution empirique f^D des proportions des faces observées va fluctuer autour de la distribution théorique f^M .**







Ces fluctuations sont d'autant moins probables que :

- $K(f^D || f^M)$ est grand
- n est grand.

Ceci permettra de construire des **tests statistiques** basés sur l'entropie relative.

Distribution multinomiale et entropie relative (suite)

Soit $f^M = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$. On fixe $n_3 = \frac{1}{3}n$, et on regarde la distribution en faisant varier n_1 (donc $n_2 = \frac{1}{3}n - n_1$). En bleu, $P(f^D|f^M)$, en rouge, $\exp(-nK(f^D||f^M))$:



La relation :

$$P(f^D|f^M) \doteq \exp(-nK(f^D||f^M))$$

implique :

$$P(f^D|f^M) = 0 \quad \text{si} \quad K(f^D||f^M) = \infty$$

Cela se produit ssi $f_j^D > 0$ alors que $f_j^M = 0$ pour un j .

Le modèle dit que la catégorie j n'apparaît jamais, mais elle apparaît dans les données !

Le **modèle doit alors être immédiatement réfuté** (quel que soit n , réfutation déterministe au sens de Popper).

Asymétrie de l'entropie relative et réfutation déterministe (suite)

Par contre, si $f_j^M > 0$ mais $f_j^D = 0$:

$$K(f^D || f^M) < \infty$$

Il est très possible qu'un modèle de dé prédise que le 5 sortira 20% du temps, et que l'on observe toujours pas de 5 au bout de $n = 10$ lancers.

En revanche, si n devient grand, on va commencer à **douter** du modèle. C'est une **réfutation probabiliste au sens de la théorie des tests**.

L'asymétrie de $K(f||g) \neq K(g||f)$ reflète l'asymétrie entre modèles et données.

Tests basés sur l'entropie relative

Tests statistiques avec l'entropie relative

Si $K(f^D || f_0^M)$ et n sont suffisamment grands, il devient invraisemblable que les données aient été générées selon la distribution théorique particulière f_0^M .

On peut construire un **test** avec :

$$\begin{cases} H_0 : & f^M = f_0^M \\ H_1 : & f^M \neq f_0^M \end{cases}$$

On rejette H_0 au niveau α si :

$$2nK(f^D || f_0^M) > \chi^2_{1-\alpha}[m-1] \quad (\text{K doit être en nats})$$

La quantité $2nK(f^D || f_0^M)$ est parfois appelée **chi2 de vraisemblance** (log-likelihood chi square), et également notée LL (ou L^2 ou G^2).

Exemple II : répartition des genres dans un master

70% des étudiants d'une Faculté sont des étudiantes. Parmi les nombreux masters qu'offre cette faculté, le master *Méthodes computationnelles et entropie pour les SHS* n'attire que 20% d'étudiantes.

Faut-il y voir là une différence de choix genré significative ?

On pose $f_0^M = (0.7, 0.3)$ et $f^D = (0.2, 0.8)$. L'entropie relative vaut

$$K(f^D || f_0^M) = 0.2 \ln \frac{0.2}{0.7} + 0.8 \ln \frac{0.8}{0.3} = 0.534 \text{ nats}$$

Le seuil critique à $\alpha = 5\%$ est $\chi_{0.95}^2[1] = 3.84$. Supposons qu'il y ait $n = 5$ étudiant(e)s dans le master (i.e. 1 femme et 4 hommes).

Comme $2 \times 5 \times 0.534 = 5.34 > 3.84$, la différence est significative.

Exemple II : répartition des genres dans un master (suite)

On obtient le même résultat avec le test basé sur le chi2 ordinaire (avec les effectifs attendus sous H_0 de 3.5 femmes et 1.5 hommes) :

$$\text{chi2} = \frac{(1 - 3.5)^2}{3.5} + \frac{(4 - 1.5)^2}{1.5} = 5.95 > 3.84$$

Note (*) : le nombre de femmes sur 5 personnes ne peut être que discret (i.e. 0,1,2,3,4,5), et l'approximation continue sur laquelle est basée les deux versions du test précédent peut être médiocre.

Pour que cette approximation d'un problème discret par un traitement continu soit à peu près acceptable, il est généralement recommandé que tous les effectifs attendus (ou au moins 80%) soient supérieurs à 5.

Exemple II : répartition des genres dans un master (suite *)

Si les effectifs attendus sont petits (comme ici), on peut alors procéder à la **correction dite de continuité** (censée améliorer l'approximation) qui consiste à remplacer le χ^2 par l'expression

$$\text{chi2} = \sum_{j=1}^m \frac{(n_j - n_j^{\text{theo}})^2}{n_j^{\text{theo}}} \rightarrow \text{chi2}_{\text{corrigé}} = \sum_{j=1}^m \frac{(|n_j - n_j^{\text{theo}}| - 0.5)^2}{n_j^{\text{theo}}}$$

qui donne ici $\text{chi2}_{\text{corrigé}} = 3.80 < 3.84$, qui n'est donc plus significatif à $\alpha = 5\%$.

On peut aussi calculer la probabilité exacte qu'une étudiante ou moins participe au master, soit

$$\binom{5}{0} 0.7^0 \cdot 0.3^5 + \binom{5}{1} 0.7^1 \cdot 0.3^4 = 0.0308$$

qui est exactement la valeur p du test dit **binomial exact**.

Comme $p < \alpha = 0.05$, la différence est alors significative dans cette approche (ici, la meilleure).

Exemple III : courses de chevaux

Lors d'une course de chevaux, l'assignement d'une piste plutôt qu'une autre influence-t-elle significativement les chances de gagner ?

Les résultats des 144 courses du premier mois de 1955 d'un certain hippodrome étatsunien (New York Post du 30 août 1955, p. 42) sont :

Numéro de piste	1	2	3	4	5	6	7	8	total
Nombre de victoires	29	19	18	25	17	10	15	11	144

L'hypothèse nulle H_0 est que le numéro de la piste n'influence pas les chances de gagner, i.e. que la distribution théorique est uniforme $f_j^M = \frac{1}{8}$, ce qui donne une valeur attendue de $144/8 = 18$ victoires par piste.

L'hypothèse alternative H_1 dit que H_0 est fausse.

(dans le cours 3, testé avec le chi2)

Exemple III : courses de chevaux (suite)

L'entropie relative et le chi2 de vraisemblance valent ici

$$K = \frac{1}{144} \left(29 \ln \frac{29}{18} + 19 \ln \frac{19}{18} + \dots + 11 \ln \frac{11}{18} \right) = 0.056 \text{ nats}$$

$$2nK = 2 \cdot 144 \cdot 0.056 = 16.138$$

à comparer avec le seuil critique (à 5%) de $\chi^2_{0.95}[8 - 1] = 14.067$:
on rejette l'hypothèse H_0 que le numéro de la piste n'influence pas les chances de gagner.

Dans la version du chi2 ordinaire, on trouve

$$\text{chi2} = \frac{(29 - 18)^2}{18} + \frac{(19 - 18)^2}{18} + \dots + \frac{(11 - 18)^2}{18} = 16.333$$

et on aboutit aux mêmes conclusions.

Le test d'indépendance et l'information mutuelle

On considère à nouveau les **effectifs croisés** n_{jk} (table de contingence) associés aux modalités $j = 1, \dots, m_1$ de X et $k = 1, \dots, m_2$ de Y .

Sous l'hypothèse H_0 d'indépendance, les **effectifs théoriques** sont :

$$n_{jk}^{theo} = \frac{n_{j\bullet} n_{\bullet k}}{n_{\bullet\bullet}}$$

En termes de fréquences relatives, les **distributions empiriques et théoriques** sont :

$$f_{jk}^D = \frac{n_{jk}}{n_{\bullet\bullet}} \quad f_{jk}^M = \frac{n_{j\bullet} n_{\bullet k}}{n_{\bullet\bullet}^2} = f_{j\bullet}^D f_{\bullet k}^D$$

et l'**entropie relative** vaut :

$$\begin{aligned} K(f^D || f^M) &= \sum_{jk} f_{jk}^D \ln \frac{f_{jk}^D}{f_{jk}^M} = \sum_{jk} f_{jk}^D \ln \frac{f_{jk}^D}{f_{j\bullet}^D f_{\bullet k}^D} \\ &= \sum_{jk} f_{jk}^D \ln f_{jk}^D - \sum_{jk} f_{jk}^D \ln f_{j\bullet}^D - \sum_{jk} f_{jk}^D \ln f_{\bullet k}^D \\ &= -H(X, Y) + H(X) + H(Y) = I(X : Y) \end{aligned}$$

Le test d'indépendance et l'information mutuelle (suite)

En résumé, le développement précédent dit que si f_0^M est la distribution sous indépendance issue de la distribution empirique jointe f^D , alors :

$$K(f^D || f_0^M) = I(X : Y)$$

où $I(X : Y) = H(X) + H(Y) - H(X, Y)$ est l'information mutuelle entre les distributions (empiriques) de X et de Y .

On a vu que $X \perp Y$ (au sens empirique) ssi $I(X : Y) = 0$.

On constate maintenant que **$I(X : Y)$ est l'entropie relative entre la distribution empirique et la distribution attendue sous indépendance**. Plus elle est grande, moins les données suggèrent que X et Y sont indépendantes.

Le test d'indépendance et l'information mutuelle (suite)

Ainsi, l'**information mutuelle** $I(X : Y)$ (en nats) peut être **directement utilisée comme variable de décision dans le test d'indépendance** :

$$\begin{cases} H_0 : & X \text{ et } Y \text{ sont indépendantes} \\ H_1 : & X \text{ et } Y \text{ ne sont pas indépendantes} \end{cases}$$

On rejette H_0 au niveau α si :

$$2nl(X : Y) \geq \chi^2_{1-\alpha}[(m_1 - 1)(m_2 - 1)]$$

Ce test du χ^2 de vraisemblance est équivalent au test du χ^2 ordinaire : on rejette H_0 au niveau α si :

$$\chi^2 \geq \chi^2_{1-\alpha}[(m_1 - 1)(m_2 - 1)]$$

(pour rappel, $\chi^2 \cong 2nl(X : Y)$)

Exemple IV (reprise d'un ancien exemple)

$n = 20$ étudiant.e.s de genre $X = \{F, M\}$ ont choisi l'un des deux enseignements à option $Y = \{A, B\}$. Les effectifs observés et les effectifs théoriques sous indépendance sont :

$X \backslash Y$	A	B	
F	5	5	10
M	10	0	10
	15	5	20

$X \backslash Y$	A	B	
F	7.5	2.5	10
M	7.5	2.5	10
	15	5	20

Effectifs croisés n_{jk} (gauche) et théoriques n_{jk}^{theo} (droite)

L'information mutuelle vaut ici (déjà calculée) :

$$I(X : Y) = H(X) + H(Y) - H(X, Y) = 1 + 0.811 - 1.5 = 0.311 \text{ bits}$$

soit $0.311 \times \ln 2 = 0.215$ nats. Le chi2 de vraisemblance vaut donc :

$$2nI(X : Y) = 2 \times 20 \times 0.215 = 8.63 \quad (\text{le chi2 ordinaire vaut } 6.67)$$

qui est significatif au niveau $\alpha = 1\%$ ($\chi_{0.99}^2[1] = 6.63$)

Principe du maximum de vraisemblance

Comment tester une famille de modèles ?

Dans la section qui précède, on teste le modèle f_0^M qui est **un seul modèle particulier** (i.e. H_0 est une hypothèse simple).

Or, dans la pratique, on souhaite tester une **famille de modèles** notée $\mathcal{M}$, plutôt qu'un modèle unique particulier $f_0^M \in \mathcal{M}$.

Or, $\mathcal{M}$ contient en général une infinité de distributions, ce qui donne comme hypothèses :

$$\begin{cases} H_0 : f^M \in \mathcal{M} \\ H_1 : f^M \notin \mathcal{M} \end{cases}$$

avec l'hypothèse H_0 composite. Comment procéder ?

Familles de modèles : quelques exemples (dé)

On considère un dé à $m = 6$ faces, de distribution théorique f^M , avec (naturellement) $f_j^M \geq 0$ et $\sum_{j=1}^m f_j^M = 1$.

Différentes familles de modèles (toutes infinies, et en particulier composites) pourraient être :

- Les faces « petites » sont aussi fréquentes que les faces « grandes » :

$$\mathcal{M} = \{f^M | f_1^M + f_2^M + f_3^M = f_4^M + f_5^M + f_6^M\}$$

- Les faces « impaires » sont aussi fréquentes que les faces « paires » :

$$\mathcal{M} = \{f^M | f_1^M + f_3^M + f_5^M = f_2^M + f_4^M + f_6^M\}$$

- La somme des fréquences des faces « opposées » est constante (et donc de $1/3$) :

$$\mathcal{M} = \{f^M | f_1^M + f_6^M = f_2^M + f_5^M = f_3^M + f_4^M\}$$

- Le « cinq » ne sort jamais :

$$\mathcal{M} = \{f^M | f_5^M = 0\}$$

Le principe du maximum de vraisemblance

Posé de manière très général, la **principe de maximum de vraisemblance** consiste à sélectionner le modèle $\hat{M}$ qui maximise, pour des données D posée, la probabilité $P(D|M)$:

$$P(D|\hat{M}) = \max_{M \in \mathcal{M}} P(D|M) \quad \hat{M} = \arg \max_{M \in \mathcal{M}} P(D|M)$$

dans ce contexte, $P(D|M)$ s'appelle la **vraisemblance** (une fonction de M).

Lorsque les données sont catégorielles (notre cas), ce principe s'exprime avec l'**entropie relative** :

$$\min_{f^M \in \mathcal{M}} K(f^D || f^M) = K(f^D || \hat{f}^{\mathcal{M}}) \quad \hat{f}^{\mathcal{M}} = \arg \min_{f^M \in \mathcal{M}} K(f^D || f^M)$$

La distribution $\hat{f}^{\mathcal{M}}$, généralement unique dans les problèmes standard en modélisation, dépend à la fois de f^D et de $\mathcal{M}$. C'est la **distribution du maximum de vraisemblance**.

Pour la famille $\mathcal{M}$ dite **saturée**, qui dit que n'**importe quelle distribution théorique** f^M **est admissible**, le maximum de vraisemblance devient trivial :

$$\hat{f}_j^{\mathcal{M}} = f_j^D \quad \text{pour tout } j$$

L'estimation du maximum de vraisemblance $\hat{f}^{\mathcal{M}}$ coïncide alors avec la distribution empirique f^D .

En réalité, le maximum de vraisemblance devient pertinent lorsque l'on **restreint les modèles admissibles**.



Exemple V : dé sous contraintes

Un dé à 6 faces a été déformé et on s'attend à ce que la somme des probabilités des faces opposées soit toujours de $1/3$.

Pour cette famille $\mathcal{M}$: « la somme des fréquences des faces opposées est $1/3$ », l'estimation du maximum de vraisemblance est :

$$\begin{aligned}\hat{f}_1^{\mathcal{M}} &= \frac{1}{3} \frac{f_1^D}{f_1^D + f_6^D} & \hat{f}_2^{\mathcal{M}} &= \frac{1}{3} \frac{f_2^D}{f_2^D + f_5^D} & \hat{f}_3^{\mathcal{M}} &= \frac{1}{3} \frac{f_3^D}{f_3^D + f_4^D} \\ \hat{f}_6^{\mathcal{M}} &= \frac{1}{3} \frac{f_6^D}{f_1^D + f_6^D} & \hat{f}_5^{\mathcal{M}} &= \frac{1}{3} \frac{f_5^D}{f_2^D + f_5^D} & \hat{f}_4^{\mathcal{M}} &= \frac{1}{3} \frac{f_4^D}{f_3^D + f_4^D}\end{aligned}$$

Pour un tirage donné, on obtient alors un « meilleur modèle » selon le maximum de vraisemblance :



Exemple VI : table de contingence

Dans une table empirique f_{jk}^D , on peut se demander quel est le modèle du maximum de vraisemblance dans la famille :

$$\mathcal{M} = \{f_{jk}^M | f_{j\bullet}^M = f_{j\bullet}^D \text{ et } f_{\bullet k}^M = f_{\bullet k}^D\}$$

autrement dire, les modèles tels que leurs marges sont égales à la distribution empirique. On trouve alors :

$$f_{jk}^M = f_{j\bullet}^D f_{\bullet k}^D$$

c'est-à-dire le **modèle d'indépendance**.

Tests d'hypothèse pour une famille de modèles

Revenons à la question de tester :

$$\begin{cases} H_0 : f^M \in \mathcal{M} \\ H_1 : f^M \notin \mathcal{M} \end{cases}$$

La solution est la suivante :

1. On détermine, parmi tous les modèles dans $\mathcal{M}$, celui qui est le mieux ajusté aux données, à savoir le **modèle de maximum de vraisemblance** $\hat{f}^{\mathcal{M}}$
2. Le test devient alors : on rejette H_0 au niveau α si :

$$2nK(f^D || \hat{f}^{\mathcal{M}}) \geq \chi^2_{1-\alpha}[\text{df}(\mathcal{M})]$$

Le nombre de degrés de liberté $\text{df}(\mathcal{M})$ du test est le **nombre de contraintes** dans $\mathcal{M}$, i.e. le nombre de conditions supplémentaires, par rapport au modèle saturé, qui définissent $\mathcal{M}$.

Détermination du nombre de degrés de liberté $df(M)$

Dans le **modèle saturé**, on ne précise rien de particulier, et donc $df(\mathcal{M}) = 0$. L'estimateur du maximum de vraisemblance est ici $\hat{f}^{\mathcal{M}} = f^D$, et le test revient à comparer la variable de décision nulle $2nK(f^D || f^D) = 0$ au seuil critique $\chi^2_{1-\alpha}[0]$ indéfini.

A l'inverse, se donner **une seule distribution** théorique possible f_0^M (hypothèse simple) revient à fixer $df(\mathcal{M}) = m - 1$ contraintes supplémentaires par rapport au modèle saturé. On retrouve le test « on rejette H_0 au niveau α » si :

$$2nK(f^D || f_0^M) > \chi^2_{1-\alpha}[m - 1]$$

Détermination du nombre de degrés de liberté $df(M)$ (suite)

Dans le modèle $\mathcal{M}$ **sous contraintes des marges** pour respecter deux variables X à m_1 modalités et Y à m_2 modalités, les conditions $f_{j\bullet}^M = f_{j\bullet}^D$ et $f_{\bullet k}^M = f_{\bullet k}^D$ constituent $df(\mathcal{M}) = (m_1 - 1)(m_2 - 1)$ contraintes supplémentaires par rapport au modèle saturé.

Les programmes statistiques standards (tels R, SPSS, Matlab, Python, etc.) fournissent automatiquement les degrés de liberté à l'utilisateur, ce qui permet souvent de **comprendre les contraintes sous-jacentes posées à la famille de modèles**.