

Méthodes Quantitatives II :

9. Tests de normalité et test de Kolmogorov-Smirnov

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 163 - 173

Exercices : Série 10

Introduction

Rappel : validité des tests statistiques classiques

La grande majorité des tests statistiques classiques sont basés sur la **loi normale**, ou des lois dérivées (lois du χ^2 , t et F). La loi normale elle-même est justifiée par le **théorème central limite** :

$$\overline{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

qui a lieu :

- pour n observations numériques $x_1, \dots, x_n$ i.i.d.
- de variance théorique σ^2 finie.
- et n grand.

Par exemple, Un résultat dérivé est que la variance empirique s^2 est distribuée comme :

$$\frac{ns^2}{\sigma^2} \sim \chi^2[n-1]$$

Pour n petit (p.ex. $n < 10$), le théorème central limite n'a plus lieu d'être, et **le recours à la loi normale n'est plus justifié.**

Comment effectuer des tests sur de petits échantillons ?

Avec n petit, on a alors 3 grandes options :

1. On peut espérer que le test reste valable même si les données ne sont pas distribuées normalement (ou si d'autres hypothèses de travail en principe nécessaires à la bonne application du test ne sont pas réalisées). Le test est alors dit **robuste**.

Par exemple :

- Le test de comparaison de deux moyennes est assez robuste en cas de non normalité, pour autant que l'on n'ait pas simultanément des échantillons de taille et de variance très différentes.
- En revanche le test du χ^2 de comparaison de deux variances n'est *pas* robuste aux violations de normalité.

Comment effectuer des tests sur de petits échantillons ?

2. On peut **transformer ses données** $x_1, \dots, x_n$ au moyen d'une fonction g appropriée telle que les nouveaux scores $y_i := g(x_i)$ aient une distribution plus proche de la distribution normale.
3. On peut recourir à des **tests plus généraux** (moins puissants en général, i.e. moins aptes à rejeter correctement l'hypothèse nulle H_0) qui ne présupposent pas les hypothèses de travail habituelles.

De tels tests sont dits **non paramétriques** (« distribution-free »).

Par opposition, les tests classiques basés sur la loi normale (ou toute autre loi exigée par les hypothèses de travail), sont qualifiés de **paramétriques**.

Pourquoi « paramétrique » ?

La distribution est supposée connue, et la seule incertitude est sur les **paramètres de la distribution**. (e.g. la moyenne et la variance dans le cas normal).

Tests de normalité

Comment s'assurer que la distribution des scores $x_1, \dots, x_n$ est normale (ou pas ?).

Diagnostics visuels :

- Histogramme
- Q-Q plots (et P-P plots)

Diagnostics formels :

- Test de symétrie
- Test d'aplatissement
- Test de Kolmogorov-Smirnov




Figure 1 – Histogramme de $n = 1000$ valeurs $\{x_i\}_{i=1,\dots,n}$ générées par une loi du $\chi^2[5]$, et densité de la distribution normale $\mathcal{N}(\bar{x}, \hat{s}^2)$

Ici, $\hat{s}^2 = \frac{n}{n-1} s^2$ est la variance de l'échantillon et constitue un estimateur sans biais de σ^2 .

Diagnostics visuels : le Q-Q plot

Si les valeurs de l'échantillon $x_1, \dots, x_n$ étaient distribuées normalement, les valeurs standardisées $\frac{x_i - \bar{x}}{\hat{s}}$ devraient suivre une **loi normale** $N(0, 1)$.

Ainsi les quantiles empiriques standardisés $\frac{x_\alpha - \bar{x}}{\hat{s}}$ **devraient à peu près coïncider avec les quantiles** u_α de la loi normale standard.

Autrement dit, si l'on trace les points (u_α, x_α) pour plusieurs α , on devrait observer une **relation linéaire** de la forme :

$$x_\alpha = \bar{x} + \hat{s}u_\alpha$$

appelée **droite de Henry**.

Diagnostics visuels : le Q-Q plot - construction

On construit de **Q-Q plot** de la manière suivante :

- On ordonne les scores dans l'ordre croissant : $x_{[1]} \leq x_{[2]} \leq \dots \leq x_{[n]}$.
- On détermine la fonction de répartition empirique $F(x)$.
- On détermine les valeurs $u_{[i]} := \Phi^{-1}(F(x_{[i]}))$, où $\Phi(u)$ est la fonction de répartition de la loi normale standard $\mathcal{N}(0, 1)$
- On dessine le diagramme de dispersion des n points, d'abscisse $u_{[i]}$ (= quantiles théoriques) et d'ordonnée $x_{[i]}$ (= quantiles empiriques), et on y superpose la droite de Henry.

Si la répartition empirique $F(x)$ est proche de la fonction de répartition d'une loi normale $\mathcal{N}(\mu, \sigma^2)$ (avec μ et σ^2 quelconques), alors les points sont bien alignés le long de la droite de Henry.

Diagnostics visuels : le Q-Q plot - exemple χ^2

Exemple : $n = 1000$ données $x_1, \dots, x_n$ générées par une loi du $\chi^2[5]$:




Figure 2 – Q-Q plot : absence d'alignement le long de la droite de Henry

Diagnostics visuels : le Q-Q plot - exemple normal

Exemple : $n = 1000$ données $x_1, \dots, x_n$ générées par une distribution normale $\mathcal{N}(1, 9)$:




Figure 3 – Q-Q plot : bon alignement le long de la droite de Henry

Une distribution normale $\mathcal{N}(\mu, \sigma^2)$ possède deux paramètres : sa moyenne $\mu = E(X)$ et sa variance $\sigma^2 = E((X - \mu)^2)$.

Avec un loi normale, tous les **autres paramètres susceptibles de décrire la forme d'une distribution** sont fixés une fois que μ et σ^2 le sont.

En particulier, pour une distribution normale,

- Le **moment centré d'ordre trois** $\mu_3 := E((X - \mu)^3)$ vaut toujours zéro.
- Le **moment centré d'ordre quatre** $\mu_4 := E((X - \mu)^4)$ vaut toujours $3\sigma^4$.

Les **versions empiriques** des moments centrés d'ordre trois et quatre sont :

$$m_3 := \overline{(x - \bar{x})^3} \quad \text{et} \quad m_4 := \overline{(x - \bar{x})^4}$$

m_3 (ou μ_3 pour les distributions théoriques) est une mesure d'**asymétrie** :

- $m_3 \cong 0$ si la distribution est symétrique autour de sa moyenne
- $m_3 > 0$ si la distribution décroît plus vite à gauche qu'à droite (existence d'une queue à droite)
- $m_3 < 0$ si la distribution décroît plus vite à droite qu'à gauche (existence d'une queue à gauche)

Diagnostics formels : coefficient d'asymétrie

Le **coefficient d'asymétrie (skewness)** est une mesure standardisée d'asymétrie, ne dépendant pas des unités choisies :


$$\alpha_3 := \frac{\mu_3}{\sigma^3} = \frac{E((X - \mu)^3)}{(E((X - \mu)^2))^{\frac{3}{2}}} \quad \text{coefficient d'asymétrie théorique}$$

$$a_3 := \frac{m_3}{s^3} = \frac{\overline{(x - \bar{x})^3}}{\left(\overline{(x - \bar{x})^2}\right)^{\frac{3}{2}}} \quad \text{coefficient d'asymétrie empirique}$$

Le coefficient d'asymétrie empirique a_3 est un estimateur du coefficient d'asymétrie théorique α_3 .

Si les données sont distribuées normalement, on s'attend à ce que α_3 **distribué normalement** autour de 0 avec une variance d'environ $6/n$.

Diagnostics formels : coefficient d'asymétrie



Source : <https://www.r-bloggers.com/2020/11/skewness-and-kurtosis-in-statistics/>

Diagnostics formels : coefficient d'aplatissement

Le **coefficient d'aplatissement (kurtosis)** est une mesure standardisée d'asymétrie, ne dépendant pas des unités choisies :

$$\alpha_4 := \frac{\mu_4}{\sigma^4} = \frac{E((X - \mu)^4)}{(E((X - \mu)^2))^2} \quad \text{coefficient d'aplatissement théorique}$$


$$a_4 := \frac{m_4}{s^4} = \frac{\overline{(x - \bar{x})^4}}{\left(\overline{(x - \bar{x})^2}\right)^2} \quad \text{coefficient d'aplatissement empirique}$$

Pour une distribution normale, α_4 vaut 3. α_4 peut varier entre 1 et ∞ .

Le coefficient d'aplatissement empirique a_4 est un estimateur du coefficient d'aplatissement théorique α_4 .

Si les données sont distribuées normalement, on s'attend à ce que α_4 soit **distribué normalement** autour de 3 avec une variance d'environ $24/n$.

Diagnostics formels : coefficient d'aplatissement



Source : <https://www.rajivgopinath.com/blogs/statistics-and-data-science-hub/foundations/basic-statistical-concepts/skewness-and-kurtosis-explained>



Mesokurtic : Distribution normale, $a_4 = 3$

Leptokurtic : Queues épaisses et sommet fin, $a_4 > 3$.

Platykurtic : Queues fines et sommet épais, $a_4 < 3$.



Diagnostics formels : asymétrie et aplatissement - exemples

A gauche : loi normale $\mathcal{N}(2, 9)$. A droite : 1000 données générées selon cette loi.





Diagnostics formels : asymétrie et aplatissement - exemples

A gauche : loi uniforme $\mathcal{U}(-2, 6)$. A droite : 1000 données générées selon cette loi.



Diagnostics formels : asymétrie et aplatissement - exemples

A gauche : loi de Gumbel (distribution de « valeurs extrêmes », avec queue persistante à droite) de « paramètre de localisation » $a = 2$ et de « paramètre d'échelle » $b = 3$. A droite : 1000 données générées selon cette loi.



Test d'asymétrie

Si a_3 est trop différent de 0, **l'hypothèse de normalité est à rejeter** :

$$\begin{cases} H_0 : F^{theo}(x) = \text{répartition normale} \\ H_1 : F^{theo}(x) \neq \text{répartition normale} \end{cases}$$

Test (bilatéral) d'asymétrie : on rejette H_0 au niveau α si

$$\frac{|a_3|\sqrt{n}}{\sqrt{6}} \geq u_{1-\frac{\alpha}{2}}$$

Exemple : les $n = 1000$ données produites par une loi du $\chi^2[5]$ ont un coefficient d'asymétrie de $a_3 = 1.19$: l'asymétrie est positive (queue à droite).

La variable de décision vaut $(1.19 \cdot \sqrt{1000})/\sqrt{6} = 15.4$; valeur très élevée en comparaison des quantiles $u_{1-\frac{\alpha}{2}}$ de la loi normale standard : H_0 est à rejeter sans hésitation.

Avec le même $a_3 = 1.19$, mais $n = 15$ seulement, on aurait eu une valeur p bilatérale de 0.06.

Test d'aplatissement

Si a_4 est trop différent de 3, **l'hypothèse de normalité est à rejeter** :

$$\begin{cases} H_0 : F^{theo}(x) = \text{répartition normale} \\ H_1 : F^{theo}(x) \neq \text{répartition normale} \end{cases}$$

Test (bilatéral) d'aplatissement : on rejette H_0 au niveau α si

$$\frac{|a_4 - 3|\sqrt{n}}{\sqrt{24}} \geq u_{1-\frac{\alpha}{2}}$$

Exemple : les $n = 1000$ données produites par une loi du $\chi^2[5]$ ont un coefficient d'aplatissement de $a_4 = 5.00$: présence de valeurs extrêmes (positives) par rapport à la distribution normale (queue à droite).

La variable de décision vaut $(|5.00 - 3|\sqrt{1000})/\sqrt{24} = 12.9$ valeur très significative à nouveau : H_0 est à rejeter sans hésitation.

Avec le même $a_4 = 5.00$, mais $n = 15$, on aurait eu $p = 0.11$.

Test de Jarque-Bera

On peut combiner les deux tests d'asymétrie et d'aplatissement dans un seul test, appelé le **test de Jarque-Bera** :

$$\begin{cases} H_0 : F^{theo}(x) = \text{répartition normale} \\ H_1 : F^{theo}(x) \neq \text{répartition normale} \end{cases}$$

On rejette H_0 au niveau α si :

$$\frac{n}{6} \left[a_3^2 + \frac{1}{4}(a_4 - 3)^2 \right] > \chi^2_{1-\alpha}[2]$$

Exemple : aux $n = 1000$ valeurs simulées selon une loi uniforme $\mathcal{U}(-2, 6)$ correspondent les coefficients d'asymétrie et d'aplatissement de $a_3 = 0.01$ et de $a_4 = 1.76$.

La variable de décision du test de Jarque-Bera vaut $d = 64.1$ (à comparer avec une distribution du $\chi^2[2]$), ce qui est extrêmement significatif.

C'est ici l'aplatissement a_4 , trop éloigné de 3 pour une loi normale, qui est responsable du rejet de H_0 (et non pas l'asymétrie a_3 , proche de la valeur attendue de 0, la distribution uniforme étant symétrique).

Test de Kolmogorov-Smirnov

Le test de Kolmogorov-Smirnov : idée

Le but ici est de **comparer une distribution empirique $F^{obs}(x)$ d'un échantillon de n observations à une distribution théorique $F_0(x)$.**

L'idée est de rejeter l'hypothèse que la distribution théorique est $F_0(x)$ si **la différence entre $F^{obs}(x)$ et $F_0(x)$ est trop élevée.** Cette différence est mesurée par la variable de décision :

$$d := \max_x |F^{obs}(x) - F_0(x)|$$

où la maximisation impliquée par « $\max_x$ » consiste à sélectionner la valeur x telle que la différence entre $F^{obs}(x)$ et $F_0(x)$ (en valeur absolue) soit aussi grande que possible.

Le test de Kolmogorov-Smirnov

Le **test de Kolmogorov-Smirnov** pose donc les hypothèses :

$$\begin{cases} H_0 : F^{theo}(x) = F_0(x) \\ H_1 : F^{theo}(x) \neq F_0(x) \end{cases}$$

et on rejette H_0 au niveau α si

$$d = \max_x |F^{obs}(x) - F_0(x)| > d_c(\alpha, n)$$

où le **seuil critique** $d_c(\alpha, n)$, dépendant du niveau de signification α et de la taille de l'échantillon n , est lu dans une table particulière (celle du test de KS, justement).

Détermination de d

Comment déterminer la variable de décision d ?

La **fonction de répartition empirique** $F^{obs}(x)$ est une fonction croissante en escalier formée de n marches de hauteur $1/n$ chacune (en l'absence d'ex-aequos), avec $F^{obs}(x) = 0$ pour $x < x_{min}$ et $F^{obs}(x) = 1$ pour $x \geq x_{max}$.

La **distribution théorique** $F^{theo}(x)$ est souvent continue. Elle est croissante et vérifie :

$$\lim_{x \rightarrow -\infty} F^{th}(x) = 0 \quad \text{et} \quad \lim_{x \rightarrow \infty} F^{th}(x) = 1$$

En particulier,


$$\lim_{x \rightarrow -\infty} |F^{obs}(x) - F_0(x)| = 0 \quad \text{et} \quad \lim_{x \rightarrow \infty} |F^{obs}(x) - F_0(x)| = 0$$

La valeur x maximisant $|F^{obs}(x) - F_0(x)|$ se trouve quelque part dans $(-\infty, \infty)$.

Exemple : test de KS pour une distribution normale

On génère un échantillon de $n = 1000$ valeurs $x_1, \dots, x_n$ distribuées selon une loi du $\chi^2[5]$ et on construit la fonction de répartition empirique $F^{obs}(x)$ (à mille marches) correspondante.

On prend pour fonction théorique possible $F_0(x)$ la fonction de répartition normale dont la moyenne μ (respectivement la variance σ^2) est prise comme la valeur de la moyenne empirique $\bar{x}$ (respectivement la variance empirique s^2).




$F^{obs}(x)$ et $F_0(x) = \Phi\left(\frac{x-\bar{x}}{s}\right)$: leur différence maximale vaut $d = 0.111$

La différence est très significative, avec une valeur p (déterminée par un logiciel) de $p = 3.6 \cdot 10^{-11}$.

Exemple : test de KS pour une distribution uniforme

Aline, veilleuse de nuit au service des urgences d'un hôpital, imagine que les admissions se font en début plutôt qu'en fin de nuit : les 5 admissions, la veille, entre 22h00 et 06h00, ont eu lieu à 22h15, 22h45, 23h55, 0h30 et 02h35.

Il faut ici comparer la distribution empirique à la distribution théorique $U(22h00, 06h00)$:



La variable de décision vaut ici $d = 0.488$, qui n'est significative qu'à $\alpha = 20\%$: la table spécifique du test donne $d_c(0.2, n = 5) = 0.44698$

Le test de KS de comparaison de deux échantillons

Le test de Kolmogorov-Smirnov permet également **la comparaison de deux échantillons**, en comparant les distributions empiriques $F_1^{obs}(x)$ (portant sur n_1 observations) et $F_2^{obs}(x)$ (portant sur n_2 observations) au moyen de leur différence maximale

$$d := \max_x |F_1^{obs}(x) - F_2^{obs}(x)|$$

La table des valeurs critiques $d_c(\alpha, n_1, n_2)$ à utiliser ici correspond approximativement à la table usuelle des valeurs critiques $d_c(\alpha, n)$ à condition de prendre


$$n = \frac{n_1 n_2}{n_1 + n_2}$$

On rejette au niveau α l'hypothèse H_0 que les deux échantillons suivent la même loi théorique (non spécifiée) si :

$$d > d_c \left(\alpha, \frac{n_1 n_2}{n_1 + n_2} \right)$$

Exemple : test de KS de comparaison de deux échantillons

Barnabé est également veilleur de nuit dans le même service, mais le week-end seulement. Entre 22h00 et 06h00, il y a eu 10 admissions : à 22h45, 1h00, 2h15, 2h35, 3h15, 3h55, 4h00, 4h45, 5h30 et 5h45.



Répartition empirique des observations de Aline (en continu ; $n_1 = 5$) et Barnabé (en pointillé ; $n_2 = 10$). La différence maximale vaut $d = 0.7$ atteinte pour $x \in (0h30, 1h00) = (24.5, 25)$

Calcul de la valeur critique : on détermine $n = (10 \times 5)/(10 + 5) = 3.33$; on observe ensuite (tables) que, pour $n = 3$ la différence $d = 0.7$ est significative à $\alpha = 0.1$ ($d_c(0.1, 3) = 0.63604$), mais pas à $\alpha = 0.05$ ($d_c(0.05, 3) = 0.70760$).

La valeur p du test indiquée par les logiciels se trouve être de $p = 0.076$.