

Méthodes Quantitatives II :

10. Données pondérées et agrégation

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 179 - 190

Exercices : Série 11

Introduction : les unités d'observation

Les unités d'observation : « atomes » ou « agrégats » ?

La plupart des méthodes d'analyse statistique sont adaptées au cas de n **observations individuelles** chaque observation est caractérisée par un profil d'une ou plusieurs variables numériques ou catégorielles :

- n **élèves**, caractérisés par leurs notes lors d'une ou plusieurs épreuves
- n **prélèvements** localisés de forage, caractérisés par leur composition physico-chimique
- n **auteurs** de science-fiction, caractérisés par leur profil bio- et bibliographique.

Les unités d'observation (suite)

Par contraste, certaines méthodes d'analyse statistique portent sur des **collectifs** ou **agrégats**, réunissant plusieurs unités ou observations individuelles :

- n **communes**, caractérisées par leur taux de chômage, d'étrangers, d'imposition, etc.
- n **hautes écoles**, caractérisées par l'âge moyen des étudiants ou des enseignants
- n **livres** de science-fiction, caractérisés par la distribution du lexique, des lieux, des personnages..

Dans le cas de collectifs, les unités d'observations peuvent être **fusionnées ou agrégées** : deux communes, deux hautes écoles, deux livres (vol. I et II) peuvent fusionner, ou être divisés.

Par contre, deux élèves, deux prélèvements, deux auteurs **ne peuvent pas** être fusionnés.

Il faut ainsi distinguer deux types d'observations ou individus statistiques :

- les « véritables » individus, qui ne sont ni agréables ni sécables, qu'on peut qualifier ici d'**individus atomiques** ou **atomes** (terminologie non standard)
- les individus collectifs, agréables ou sécables (conceptuellement et dans la pratique), qui sont des **individus agrégés** ou **agrégats**.

Le traitement quantitatif des deux cas diffère, raison pour laquelle on introduit ici cette distinction.

Mesures pondérées

Moyennes uniformes et pondérées

La **moyenne** de la note d'histoire dans une classe de n élèves est :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

où x_i = note d'histoire de l'élève i .

Par contre, la **proportion moyenne** d'étrangers dans le canton de Vaud, formé de n communes, est :

$$\bar{x} = \sum_{i=1}^n f_i x_i$$

où x_i = proportion d'étrangers dans la commune i et

$$f_i = \frac{n_i}{n_{\bullet}} = \text{taille relative de la commune } i$$

Ici n_i est le nombre d'habitants dans la commune i , et $n_{\bullet}$ est le nombre total d'habitants du canton.

Moyennes uniformes et pondérées (suite)

Les deux expressions pour la moyenne :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{et} \quad \sum_{i=1}^n f_i x_i$$

définissent la **moyenne uniforme**, resp. la **moyenne pondérée**.

La **taille relative** ou **poids relatif** f satisfait à :

$$f_i > 0 \quad \text{et} \quad \sum_{i=1}^n f_i = 1$$

f_i est une mesure de l'importance relative, du poids relatif de l'individu-agrégat i parmi un échantillon de n individus-agrégats.

Le vecteur $f = (f_i)$ des poids définit un **système de pondération**.

La **pondération uniforme** est le cas particulier $f_i = \frac{1}{n}$.

Comportement des variables numériques sous agrégation

Supposons que les communes i et j fusionnent en une nouvelle entité notée $[i \cup j]$. Si x est une variable telle que « proportion d'étrangers », « nombre de vélos par habitant », « surface habitable par habitant », etc. alors le nouveau score après fusion vaut

$$x_{[i \cup j]} = \frac{f_i x_i + f_j x_j}{f_i + f_j}$$

On dit que x est une **variable de densité**.

Par contraste, si y est une variable telle que « nombre d'étrangers », « nombre de vélos », « nombre d'hectares en zone urbaine », etc. alors le nouveau score après fusion vaut



$$y_{[i \cup j]} = y_i + y_j$$

On dit que y est une **variable de taille**.

Variables de densité et de taille : exemples

1) En physique, les variables de densité sont dites **intensives** (pression, température, concentration) et les variables de taille sont dites **extensives** (masse, énergie, volume).

2) A gauche : $x = \ll \text{taux de suicide} \gg$ (dans les départements français dans les années 1830) est une variable de densité. A droite : $y = \ll \text{nombre annuel de naissances} \gg$ est une variable de taille.



(Source : A.-M. Guerry (1833) $\ll$ Essai sur la Statistique Morale de la France $\gg$)

Variance pondérée

La **variance pondérée** d'une variable x (de densité) est :

$$\text{var}(x) = \sum_{i=1}^n f_i (x_i - \bar{x})^2 = \overline{x^2} - \bar{x}^2$$

où $\bar{x}$ et $\overline{x^2}$ sont les moyennes (pondérées) de x et x^2 .

La variance mesure la moyenne (pondérée) du carré des écarts à la moyenne (pondérée). Elle mesure également la demi-moyenne (pondérée) du carré des différences entre **toutes les paires d'observations** :

$$\text{var}(x) = \frac{1}{2} \sum_{i,j=1}^n f_i f_j (x_i - x_j)^2$$

$$\begin{aligned} \text{(Preuve (*)) : } \frac{1}{2} \sum_{i,j=1}^n f_i f_j (x_i - x_j)^2 &= \frac{1}{2} \sum_{i,j=1}^n f_i f_j (x_i^2 + x_j^2 - 2x_i x_j) = \\ &= \sum_i f_i x_i^2 - (\sum_i f_i x_i)(\sum_j f_j x_j) = \overline{x^2} - \bar{x}^2 = \text{var}(x) \end{aligned}$$

(*) La variance intrinsèque (intra-agrégat)

Les valeurs d'une variable numérique x sont données par leurs **scores** x_i sur les individus (atomiques) $i = 1, \dots, n$.

Les agrégats peuvent être caractérisés par leur **valeur (moyenne)** x_i mais aussi par leur **variance intrinsèque** ou intra-agrégat s_i^2 , mesurant la variabilité entre les unités plus petites dont les agrégats sont formés.

Par exemple :

- $x_i = \ll \text{revenu moyen des personnes actives dans la commune } i \gg$, et $s_i^2 = \ll \text{variance du moyen revenu entre les personnes actives dans la commune } i \gg$
- $x_i = \ll \text{taux de chômage dans le canton } i \gg$, et $s_i^2 = \ll \text{variance intrinsèque} \gg$ du taux de chômage entre les communes du canton.

(*) Comportement de la variance intrinsèque sous agrégation

Si s_i^2 et s_j^2 représentent les variances intrinsèques dans les agrégats i et j , la variance intrinsèque dans l'agrégat $[i \cup j]$, issu de la fusion de i et j , vaut

$$s_{[i \cup j]}^2 = \frac{f_i s_i^2 + f_j s_j^2}{f_i + f_j} + \frac{f_i (x_i - x_{[i \cup j]})^2 + f_j (x_j - x_{[i \cup j]})^2}{f_i + f_j}$$

Le premier terme du membre du droite, qui se transforme sous agrégation comme une variable de densité, correspond à la **variance intra-groupe** dans la décomposition de la variance.

Le second terme, qui s'écrit aussi $\frac{f_i f_j}{(f_i + f_j)^2} (x_i - x_j)^2$, correspond à la **variance inter-groupe** dans la décomposition de la variance.

On voit que, sous agrégation, les variances intrinsèques ne se transforment ni comme une variable de densité, ni comme une variable de taille, mais comme un troisième type qu'on pourrait appeler « dispersif ».

Covariance et corrélation pondérées

La **covariance pondérée** de deux variables x et y (de densité) est :

$$\text{cov}(x, y) = \sum_{i=1}^n f_i (x_i - \bar{x})(y_i - \bar{y}) = \overline{xy} - \bar{x}\bar{y}$$

L'expression équivalente :

$$\text{cov}(x, y) = \frac{1}{2} \sum_{i,j=1}^n f_i f_j (x_i - x_j)(y_i - y_j)$$

est également valide.

Finalement, la **corrélation pondérée** s'obtient de façon habituelle comme :

$$r_{xy} = \text{corr}(x, y) = \frac{\text{cov}(x, y)}{\sqrt{\text{var}(x)}\sqrt{\text{var}(y)}}$$

où **toutes les quantités sont calculées de façon pondérée.** **Unil.**

Exemple : diplômés et personnes sans religion

Les cantons suisses constituent $n = 26$ individus (agrégats), avec un poids f proportionnel à leur population (en 2018; données OFS <https://www.bfs.admin.ch/bfs/fr/home.html>).

Le poids maximum $f_{max} = 0.177 = 17.7\%$ est atteint pour Zurich (ZH); le poids minimum $f_{min} = 0.0019 = 0.19\%$ est atteint pour Appenzell Rhodes Intérieures (AI), presque cent fois (93.8) moins peuplé que ZH.

On considère, dans la population de plus de 15 ans, les deux variables de densité :

- $x = \ll \text{proportion de diplômés de troisième cycle} \gg$ (universités et hautes écoles), avec un maximum $x_{max} = 40\%$ pour BS, et un minimum $x_{min} = 19\%$ pour AI, avec une moyenne de $\bar{x} = 31.1\%$
- $y = \ll \text{proportion de personnes sans religion} \gg$, avec un maximum $y_{max} = 51\%$ pour BS, et un minimum $y_{min} = 9\%$ pour AI, avec une moyenne de $\bar{y} = 28.2\%$.

Exemple : diplômés et personnes sans religion (suite)

Les écarts-types et covariances (pondérés) sont :

- $s_x = \sqrt{\text{var}(x)} = 5.5\%$ écart-type du pourc. de diplômé.e.s
- $s_y = \sqrt{\text{var}(y)} = 8.2\%$ écart-type du pourc. de personnes sans religion
- $s_{xy} = \text{cov}(x, y) = 0.00309$ covariance correspondante

La corrélation (pondérée) entre x et y vaut ainsi

$$r_{xy} = \text{corr}(x, y) = \frac{0.00309}{0.055 \times 0.082} = 0.691$$

qui représente une valeur plutôt élevée ($0.691^2 = 47.7\%$ de variance expliquée).

Mais est-elle **significative** ?

Règle générale : dans le cas pondéré, les tests usuels restent valides (comparaison de moyennes, corrélation, etc.).

Par exemple :

$r = 0.691$ sur $n = 26$ agrégats est *très significatif* : en comparant la variable de décision bilatérale $\frac{|r|}{\sqrt{1-r^2}} \sqrt{n-2} = 4.68$ à un seuil critique $t_{1-\frac{\alpha}{2}}[n-2]$, on trouve $p = 0.000093$.

Régression linéaire pondérée

En présence d'un prédicteur x de y , il s'agit d'**ajuster une droite de régression** :

$$y_i^* = ax_i + b$$

de sorte à minimiser les **moindres carrés pondérés** (weighted least squares ; WLS).

$$\sum_{i=1}^n f_i (y_i^* - y_i)^2$$

Ici, les erreurs sur les grands agrégats coûtent plus cher.

La solution se trouve être toujours la même que dans le cas uniforme, à savoir :

$$a = \frac{\text{cov}(x, y)}{\text{var}(x)} \quad b = \bar{y} - a\bar{x}$$

étant entendu que toutes les quantités ci-dessus sont **calculées de façon pondérée**.

Exemple : diplômés et personnes sans religion (suite)




Diagramme de dispersion x - y , avec la droite de régression pondérée $y^* = ax + b$. La surface des points (triangles) représentatifs des cantons est proportionnelle à leur poids relatif f (population résidente de plus de 15 ans).

Les systèmes de poids

Différents systèmes de poids selon les disciplines

Les variables x et y dont on a calculé les moyennes, variances, covariance, corrélation doivent impérativement être des variables de densité **relativement à une certaine pondération f** :

- en **géographie humaine**, le poids f des régions est proportionnel au nombre d'habitants, et les variables de densité x doivent être de la forme :

$$x_i = \frac{\text{score de taille de la region } i}{\text{nombre d'habitants dans la region } i}$$

(cf. « proportion d'étrangers », « nombre de vélos par habitant » etc.)

Différents systèmes de poids selon les disciplines (suite)

- en **géographie physique**, le poids g des régions est proportionnel à leur superficie, et les variables de densité x doivent être de la forme :

$$x_i = \frac{\text{score de taille de la region } i}{\text{superficie de la region } i}$$

(cf. « proportion de surfaces boisées », « densité de population », etc.)


- en **géographie économique**, le poids h des régions est proportionnel à leur « richesse » telle que mesurée par leur PIB, et les variables de densité x doivent être de la forme :

$$x_i = \frac{\text{score de taille de la region } i}{\text{« richesse » de la region } i}$$

(cf. « part des dépenses alimentaires dans le budget des ménages », etc.)

Exemple : géographie physique

Le poids g_i de chaque pays est proportionnel à sa **surface** :




Projection de Gall-Peters, préservant les surfaces.

Source : <https://originalmap.fr/produit/carte-monde-gall-peters/>

Exemple : géographie humaine

Le poids f_i de chaque pays est proportionnel à sa **population** :




La taille de chaque pays est proportionnelle au poids f donné par sa population relative (ici population estimée en 2050, avec les couleurs représentant l'accroissement estimé de population).

Source : <https://www.ined.fr/>

Exemple : géographie économique

Le poids h_i de chaque pays est proportionnel au **PIB** :



La taille des pays est proportionnelle au poids h déterminé par son PIB (avec couleurs représentant l'indice de développement humain (IDH)).

Source : <https://etab.ac-reunion.fr/clg-la-chatoire/anamorphose-inegalites-richeesse-2015/>

Exemple :

En 2018, le poids relatif de la Suisse dans le monde est d'environ :

- $f_{CH} = 0.11\%$ (poids de la population)
- $g_{CH} = 0.030\%$ (poids de la superficie)
- $h_{CH} = 0.85\%$ (poids du PIB total)

Ainsi :

- La richesse par habitant est d'environ $0.85/0.11 = 7.7$ fois plus grande qu'en moyenne dans le monde.
- La densité de population est d'environ $0.11/0.030 = 3.7$ fois plus grande qu'en moyenne dans le monde.

(*) Rapport de deux pondérations :

Une pondération, telle que f, g ou h , est elle-même une **variable de taille** :

$$f_{[i \cup j]} = f_i + f_j$$

$$g_{[i \cup j]} = g_i + g_j$$

$$h_{[i \cup j]} = h_i + h_j$$

Aussi, un **rapport de deux pondérations**, tel que $x_i = \frac{g_i}{f_i}$ est **une variable de densité compatible avec la pondération f** (celle du dénominateur). En effet :

$$x_{[i \cup j]} = \frac{g_{[i \cup j]}}{f_{[i \cup j]}} = \frac{g_i + g_j}{f_i + f_j} = \frac{f_i \frac{g_i}{f_i} + f_j \frac{g_j}{f_j}}{f_i + f_j} = \frac{f_i x_i + f_j x_j}{f_i + f_j}$$

En particulier, avec $g = \ll \text{poids en surface} \gg$ et $f = \ll \text{poids en population} \gg$, la variable x_i est proportionnelle à la surface par habitant, et c'est la « bonne densité » à utiliser en géographie humaine (munie des poids « canoniques » $f = \text{population relative}$).

Rapport de deux pondérations (suite)

Par contraste, la variable $y_i = \frac{f_i}{g_i}$ (c'est l'inverse de la surface par habitant) est **proportionnelle à la densité de population**, et constitue la « bonne densité » à utiliser en géographie physique (munie des poids canoniques $\mathbf{g}$ = surface relative).

La moyenne de $x_i := \frac{g_i}{f_i}$ vaut toujours 1. ($\bar{x} = \sum_{i=1}^n f_i \frac{g_i}{f_i} = \sum_i g_i = 1.$)

La variance de $\mathbf{x}$:

$$\text{var}(\mathbf{x}) = \sum_{i=1}^n f_i (x_i - 1)^2 = \frac{1}{2} \sum_{i,j=1}^n f_i f_j (x_i - x_j)^2$$

mesure la variabilité (ici de la surface par habitant) d'une région à l'autre.

(*) Indice de Gini

Une mesure alternative de variabilité est constituée par l'**indice de Gini** :

$$G := \frac{1}{2} \sum_{i,j=1}^n f_i f_j |x_i - x_j|$$

dont les valeurs sont comprises entre 0 et 1.

L'indice de Gini est populaire en sciences économiques, dans le contexte où $x_i = \frac{h_i}{f_i}$ mesure la part de richesse par habitant dans la région i .

La valeur minimale $G = 0$ dénote une égalité parfaite de distribution des revenus ($h_i = f_i$ pour tout i).

La limite $G \rightarrow 1$ décrit le cas le plus inégalitaire, où l'agrégat i_0 de plus petite taille $f_{i_0} = f_{min}$ s'accapare toutes les richesses ($h_{i_0} = 1$).

(*) Comment indiquer la pondération dans un logiciel

Les logiciels statistiques standard (tels que SPSS, ou certains packages R, etc.) possèdent souvent (mais pas toujours) une option de la forme :

$$\text{weight} = \mathbf{w}$$

où $\mathbf{w} = (w_i)$ est un vecteur de n composantes positives (autant de composantes que le nombre n d'individus) qui a pour effet de « dupliquer » la i -ème ligne du tableau de données w_i fois.

Par exemple, $w_2 = 3$ signifie que le 2ème individu est compté trois fois à l'identique ; des poids $w_i > 0$ non entiers sont aussi possibles.

C'est à partir de ce vecteur de poids $\mathbf{w}$ que le logiciel calcule (en principe) la taille N de l'échantillon comme $N = \sum_{i=1}^n w_i$, et c'est ce N qu'il va utiliser dans ses calculs de significativité.

Il faut **absolument** que $N = n$, sans quoi les valeurs p des tests statistiques seront fausses.

(*) Comment indiquer la pondération dans un logiciel (suite)

Le cas « non pondéré » (ou plutôt uniformément pondéré) correspond à la valeur par défaut, $w_i = 1$ pour chaque individu : on a bien que $\sum_{i=1}^n w_i = n$, comme il se doit.

Dans le cas pondéré, le poids relatif f s'obtient généralement comme $f_i = \frac{n_i}{n_{\bullet}}$, comme dans $n_i =$ « nombre d'habitants du canton i » et $n_{\bullet} = \sum_{i=1}^n n_i =$ « nombre d'habitants de toute la Suisse ».

- Poser alors $w_i = f_i$ **ne fonctionne pas** : cela revient à indiquer au logiciel un échantillon de taille $N = 1$ (puisque $\sum_i f_i = 1$).
- Poser $w_i = n_i$ **ne fonctionne pas non plus** : cela reviendrait à fixer la taille de l'échantillon à $N = n_{\bullet}$ plutôt que n (i.e. 8'544'527 en 2018 plutôt que 26 dans l'exemple $n_i =$ nombre d'habitants du canton i).

La déclaration correcte est :

$$w_i = n f_i$$

(car $\sum_i w_i = n$ ici)

(*) Comment indiquer la pondération dans un logiciel (suite)

Les quantités nf_i peuvent être appelées **poids effectifs** : ils mesurent la taille de l'agrégat i rapportée à la taille moyenne des agrégats.

Par exemple $nf_{ZH} = 5.31$, $nf_{VD} = 2.76$ et $nf_{AI} = 0.057$: ZH est 5.31 fois plus peuplé qu'un canton moyen, VD l'est 2.76 fois plus et AI environ 18 fois moins.

A noter que les poids problématiques $w_i = f_i$ et $w_i = n_i$ fourniront les valeurs correctes des moyennes, variances, corrélations etc. (ces derniers sont en effet proportionnels aux poids effectifs) ; ils engendreront par contre des erreurs systématiques dans les tests statistiques.