

Méthodes quantitatives III : analyse des données multivariées

François Bavaud, Université de Lausanne

automne 2018

Table des matières

1	Introduction au calcul matriciel	7
1.1	Matrices et vecteurs	7
1.1.1	Addition de deux matrices	8
1.1.2	Multiplication de deux matrices	8
1.1.3	Multiplication d'une matrice par un scalaire	8
1.1.4	Matrice identité	9
1.1.5	Inversion d'une matrice	9
1.1.6	Transposée d'une matrice	10
1.1.7	Matrices symétriques et orthogonales	10
1.1.8	Produit scalaire	10
1.1.9	Norme et dissimilarité euclidienne	11
1.1.10	Angle entre deux vecteurs	11
1.1.11	Caractérisation des matrices orthogonales	12
1.2	Application linéaire et projection	12
1.2.1	Le concept d'application linéaire	12
1.2.2	Caractérisation géométrique des matrices diagonales et orthogonales	12
1.2.3	Parallélisme, combinaisons linéaires et indépendance linéaire	13
1.2.4	Rang d'une matrice	14
1.2.5	Matrice de projection	14
1.3	Décomposition spectrale d'une matrice	16
1.3.1	Valeurs et vecteurs propres	16
1.3.2	Déterminant et trace	17
1.3.3	Le théorème spectral	17
1.3.4	(*) Projections propres et fonctions de matrices	18
1.3.5	(*) Théorème de décomposition singulière	19
1.4	Exercices et corrigés	20
2	Statistique multivariée et géométrie	25
2.1	La matrice des données multivariées : l'espace des individus et des variables	25
2.2	Correspondances entre géométrie et statistique	25
2.2.1	Moyenne	25
2.2.2	Variance, covariance et corrélation	27
2.2.3	Matrices de variance-covariance et de corrélation	29
2.2.4	Un exemple	29
2.3	La régression multiple	31
2.4	Le coefficient de corrélation partielle	32
2.4.1	(*) Coefficients de corrélation partielle d'ordre supérieur	33
2.4.2	(*) Une vue unifiée des différents coefficients de corrélation	33
2.5	Résumé	34

2.6	Exercices et corrigés	34
3	La régression multiple (suite)	38
3.1	Coefficients de régression et corrélation multiple	38
3.1.1	Rappel	38
3.1.2	Exemple	39
3.1.3	Corrélations simples et collinéarité	40
3.2	Modèle probabiliste	40
3.2.1	Estimation des paramètres	41
3.2.2	Tests et intervalles de confiance	41
3.2.3	Combien de prédicteurs retenir, et lesquels	43
3.3	Tester les hypothèses de travail	44
3.3.1	(*) Violation du modèle par autocorrélation des résidus	46
3.3.2	(*) Transformation des variables	46
3.3.3	(*) Identification des observations influentes	47
3.4	(*) Diagnostics de collinéarité	48
3.5	Résumé (très)	49
3.6	Exercices et corrigés	49
4	L'analyse en composantes principales	54
4.1	Présentation générale	54
4.2	Les bases de l'ACP	56
4.2.1	L'algorithme	56
4.2.2	Un exemple	57
4.2.3	Combien de facteurs faut-il retenir ?	59
4.2.4	(*) Exemple : ACP sur deux variables	60
4.2.5	L'ACP avec SPSS	61
4.3	(*) ACP sur la matrice de variance-covariance	62
4.3.1	(*) Exemple (suite)	64
4.4	Les rotations	65
4.5	Approche géométrique à l'ACP	66
4.6	(*) ACP, analyse factorielle, et "SEM"	68
4.6.1	Un autre exemple : ACP avec SPSS (figures 4.13 et 4.14)	68
4.7	Résumé	68
4.8	Exercices et corrigés	68
5	Dissimilarités	74
5.1	Introduction	74
5.2	Dissimilarités : définitions générales	74
5.2.1	Scores numériques	75
5.2.2	Scores standardisés et dissimilarité de Mahalanobis	76
5.3	Dissimilarités métriques	77
5.4	Dendrogrammes et dissimilarités ultramétriques	77
5.5	Dissimilarités d'arbre	79
5.5.1	(*) Algorithme de Fitch-Margoliash (FM) pour la construction d'arbres	80
5.6	Dissimilarités de Minkowski(q) ou de type L_q	83
5.7	Dissimilarités euclidiennes ou de type L_2	83
5.8	Dissimilarités de type L_∞ ou métriques	83
5.9	Dissimilarités de type L_1 ou de bloc	84
5.9.1	(*) Distance quasi-hypermétrique ou distance cond. définie négative	85

5.10	Inclusions entre dissimilarités	85
5.11	Autres dissimilarités	86
5.11.1	Distance du plus court chemin	86
5.11.2	Distance d'édition	86
5.12	Scores catégoriels binaires	87
5.13	(*) Dissimilarités entre distributions	88
5.13.1	Dissimilarité du χ^2	88
5.13.2	(*) Le cas catégoriel univarié	89
5.13.3	(*) (Dis)similarité du cosinus	89
5.14	Exercices et corrigés	90
6	Dissimilarités euclidiennes et MDS	96
6.1	Introduction	96
6.1.1	Exemple 1 : distances entre 12 villes britanniques	97
6.2	MDS uniforme	97
6.2.1	Exemple 2 : application du MDS classique	99
6.2.2	(*) Le cas L_2 approximatif : MDS non-métrique	100
6.2.3	Si B n'est pas définie positive - que faire ?	101
6.2.4	Exemple 1 (suite) : distances entre villes britanniques	101
6.3	MDS pondéré	103
6.3.1	Propriétés des distances euclidiennes : centre de gravité et dispersion	103
6.3.2	Produits scalaires et distances	103
6.3.3	MDS pondéré : décomposition spectrale des produits scalaires pondérés	104
6.3.4	Exemple 3 : collaborations scientifiques de l'Inde	104
6.4	Autres propriétés et applications du MDS pondéré	106
6.4.1	(*) Le MDS comme fondement de l'ACP	106
6.4.2	(**) Deux distributions f et g : autres propriétés des distances euclidiennes	107
6.4.3	(**) Noyaux isotropes et transformations de Schoenberg	107
6.4.4	(*) Dissimilarité discrète uniforme et pondérée, dissimilarité en étoile	107
6.5	Exercices et corrigés	109
6.6	Références pour les chapitres 5 et 6	111
7	L'analyse des correspondances	112
7.1	Quotients d'indépendance	112
7.2	Géométrie de l'analyse des correspondances	113
7.2.1	Buts de l'analyse des correspondances	113
7.2.2	Distance du chi-carré	113
7.2.3	L'extraction des facteurs	114
7.2.4	Contributions	115
7.2.5	(*) La dualité lignes-colonnes	116
7.2.6	Le biplot et son interprétation	117
7.3	Analyse des correspondances d'une matrice termes-documents	118
7.4	Exercices et corrigés	120
8	La classification hiérarchique ascendante	123
8.1	Introduction : classification supervisée et non supervisée	123
8.1.1	Ingrédients d'une classification non supervisée (clustering)	124
8.1.2	Principales familles de clustering	124
8.2	(*) Partitions	124
8.3	La constitution des groupes (CAH)	125

8.3.1	La méthode de Ward	128
8.3.2	Classification ascendante hiérarchique dans R avec hclust()	130
8.4	Exercices et corrigés	130
9	Formulaire	136
9.1	Calcul matriciel	136
9.2	Dissimilarités	137

Introduction

Deux objets (textes, régions, personnes) se ressemblent ou diffèrent entre eux de plusieurs façons, selon différentes dimensions, en fonction de diverses caractéristiques. La Statistique multivariée et l'Analyse des Données, qui sont l'objet du cours, proposent des points de vue et algorithmes basés sur ces considérations : *les profils* (ou variables) caractérisent les *objets* (ou individus), et vice-versa ; les *corrélations* entre variables reflètent les *(dis)similarités* entre objets, et vice-versa.

Cette **dualité** objets-profiles (ou individus-variables) est parfaitement capturée par la dualité ligne-colonne dans la représentation des données, dont le calcul matriciel (chapitre 1) permet le **traitement formel**. On insiste parfois sur le fait que les objets sont, bien souvent, des *agrégats*, auxquels sont alors associés des **poids** variables.

Ce cours contient tellement d'expressions mathématiques qu'il fera mal aux yeux à nombre de ses lecteurs forcés, et pourra attester auprès de ses proches, unis dans une même indignation incrédule, des mauvais traitements subis durant les études. Plus sérieusement, on ne sera pas surpris de trouver des expressions mathématiques dans un cours de méthodes quantitatives, lesquelles visent à standardiser et à automatiser des procédures courantes dans le traitement des données, une fois ces dernières organisées dans une table lignes-colonnes.

Ce passage par les méthodes quantitatives joue un rôle somme toute modeste (mais hélas pétrifiant pour une grande partie des lettrés, probablement une majorité) dans l'activité en sciences humaines, sociales ou naturelles : c'est au praticien que revient *l'ouverture initiale* (opérationnalisation de la problématique et collecte des données) ainsi que *le dernier mot* (interprétation des résultats des traitements quantitatifs).

La question du traitement quantitatif d'une question de recherche, initialement exprimée dans le langage naturel de la chercheuse, est de nature linguistique : elle suppose de pouvoir transformer

- 1) une expression française en expression mathématique (l'équivalent du "thème latin")
- 2) une expression mathématique en une autre
- 3) une expression mathématique en français (la "version latine").

Les opérations 1) et 3) sont de nature *sémantique*, tandis que 2), la seule composante mathématique au sens strict, est de nature *syntactique*. Contrairement aux apparences, cette dernière n'est pas particulièrement élaborée dans ce cours, les opérations de base se réduisant, grosso modo, à des additions et multiplications sur des *tableaux de nombres* (plutôt que des nombres individuels), lesquels sont si possible représentés collectivement par *un seul symbole* : c'est l'objet du *calcul matriciel* (chapitre 1), dont l'apprentissage demande avant tout de maîtriser l'art de manipuler des symboles un peu plus généraux et abstraits qu'à l'accoutumée ; le plus souvent, la difficulté face à une formule mathématique réside davantage dans la lecture de la formule, que dans la compréhension de son contenu mathématique :

इस सूत्र का मतलब कुछ भी नहीं है

Le coût d'entrée de l'acquisition d'une nouvelle langue, hindi ou mathématiques, est assurément considérable, mais ses bénéfices récompenseront les efforts requis au centuple. On peut certes tenter une approche moins exigeante, en n'utilisant presque exclusivement que le langage naturel dans la description du traitement des données : bonjour alors l'imprécision, l'incapacité de communiquer les choix méthodologiques, adieu la reproductibilité scientifique et la généralisabilité ! (à notre humble avis...)

Ami lecteur, sois ainsi assuré que l'insistance sur le formalisme mathématique n'a pas pour but de t'incommoder, ou pire. C'est pour ton édification, pour ton bien, ton *empowerment* : commettras-tu le suicide intellectuel consistant à t'en remettre *a priori et exclusivement* à la langue naturelle, si souvent peu adaptée pour décrire précisément les procédures et résultats, rendant par là nombre de discours académiques, aussi inspirés soient-ils, équivoques et non reproductibles ? Es-tu assez désespéré pour céder au rejet radical et facile du formalisme mathématique, sous le prétexte fallacieux et obscur que "le comportement humain ne saurait être capté par des formules" ? Voudrais-tu d'un diplôme universitaire qui t'aurait laissé dans l'ignorance de l'idée de *décomposition spectrale*, et de sa pratique ? Non, non, mille fois non - nous sommes bien d'accord là-dessus.



Le chapitre 2 donne l'occasion d'étudier un autre sous-système de traduction, à savoir celui permettant (cette fois en demeurant à l'intérieur du langage mathématique) de transformer des concepts algébriques en concepts géométriques, et vice-versa. L'objectif visé est la possibilité de décrire la Statistique multivariée et l'Analyse des Données en termes algébriques ou géométriques, ou les deux à la fois - une circonstance fort utile à la description des méthodes et à l'interprétation des résultats : *régression multiple* (chapitre 3), *analyse en composantes principales* (chapitre 4).

Au contraire des chapitres 3 et 4, *centrés sur les relations entre variables*, les chapitres 5 et 6 sont *centrés sur les relations entre objets* : le concept fondamental est celui de *dissimilarité* entre paires d'objets, dont les propriétés détaillées (trop peu développées dans les exposés traditionnels) conditionnent les traitements possibles et la visualisation des données : par un arbre, par un dendrogramme, ou par un nuage de points dans un espace euclidien.

Le cas particulier des *distances euclidiennes entre objets pondérés* (chapitre 6) résume à lui tout seul la quintessence et la puissance des approches multivariées. Muni de ce précieux viatique, l'impétrant saura alors naviguer dans les eaux étincelantes de l'*analyse des correspondances*, exemplaire dans la dualité de son formalisme (chapitre 7), des méthodes de classification du chapitre 8), ou des *plongements isométriques* (chapitre 6), ouvrant la voie aux *méthodes à noyau* du "Machine learning".

Longue est la route, jugée particulièrement ardue par la plupart de nos contemporains. Raison de plus pour s'y lancer, ne serait-ce qu'au moins à moitié : cyniquement parlant, la modestie de la culture quantitative et de sa pratique, attestée dans des pans entiers de la société des puissants et des lettrés, fournit aux détenteurs de compétences formelles et computationnelles, mêmes modestes, de solides avantages comparatifs, en termes d'employabilité, d'efficacité intellectuelle, de production et de reproduction d'idées, voire de reproduction tout court : au royaume des aveugles, les borgnes sont rois - et le bien-voyant ne sera jamais que le borgne d'un mieux-voyant que lui.



Chapitre 1

Introduction au calcul matriciel

La pratique de l'analyse multivariée nécessite la manipulation globale de tableaux de nombres ou *matrices*. Les opérations que l'on effectue sur les matrices généralisent les opérations $+$, $-$, $\times$ ou $\div$ de l'arithmétique ordinaire. La nouveauté contenue dans le calcul matriciel réside plutôt dans la saisie *simultanée* de toutes les composantes de la matrice, auxquelles les mêmes opérations sont systématiquement appliquées.

Cette visée globale se reflète dans l'écriture de la matrice, que l'on représente par un seul symbole. Cette convention, qui nécessite un petit apprentissage et familiarisation avec le formalisme, permet de représenter de façon plus succincte et élégante les définitions, relations et algorithmes en statistique multivariée, et en mathématiques appliquées en général.

1.1 Matrices et vecteurs

Une **matrice de type** $(n \times m)$ est un tableau de nombres à n lignes et m colonnes, que l'on note :

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1m} \\ a_{21} & a_{22} & \dots & a_{2m} \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & a_{nm} \end{pmatrix} \quad (1.1)$$

a_{ij} représente le nombre ou **composante** situé dans la i -ème ligne ($i = 1, \dots, n$) et la j -ème colonne ($j = 1, \dots, m$) de la matrice A . Il est utile d'utiliser la notation $A = (a_{ij})$, qui dit simplement que les composantes de la matrice A sont désignées par a_{ij} .

On considère ici des matrices *réelles* (par contraste avec les matrices *complexes* ou *binaires*, par exemple) dont les composantes sont des nombres réels. La notation $A \in \mathbb{R}^{n \times m}$ indique que A est une matrice réelle de type (on dit aussi "taille") $(n \times m)$. Si $n = m$, on parle de **matrice carrée**. Les composantes $a_{11}, a_{22}, \dots, a_{nn}$ d'une matrice carrée forment sa **diagonale principale**. Si toutes les composantes hors de la diagonale principale d'une matrice carrée sont nulles, cette matrice est dite **diagonale**.

Un **vecteur colonne** v à n **composantes** est une matrice $(n \times 1)$:

$$v = \begin{pmatrix} v_1 \\ v_2 \\ \dots \\ v_n \end{pmatrix} \in \mathbb{R}^{n \times 1} \quad (\text{ou noté simplement } v \in \mathbb{R}^n) \quad (1.2)$$

Le *vecteur nul* $\mathbf{0}$ est le vecteur $(n \times 1)$ dont toutes les composantes sont nulles. Le *vecteur constant unité* $\mathbf{1}$

est le vecteur $(n \times 1)$ dont toutes les composantes sont égales à 1 :

$$\mathbf{0} := \begin{pmatrix} 0 \\ 0 \\ \dots \\ 0 \end{pmatrix} \quad \mathbf{1} := \begin{pmatrix} 1 \\ 1 \\ \dots \\ 1 \end{pmatrix} \quad (1.3)$$

Un **vecteur ligne** w à m **composantes** est une matrice $(1 \times m)$:

$$w = (w_1, w_2, \dots, w_m) \in \mathbb{R}^{1 \times m} \quad (1.4)$$

Sauf spécification contraire, les vecteurs considérés par la suite seront des vecteurs colonne.

Un **scalaire** est une matrice (1×1) : c'est donc un nombre ordinaire.

1.1.1 Addition de deux matrices

A deux matrices $A = (a_{ij})$ et $B = (b_{ij})$ de même type $(n \times m)$ on peut faire correspondre la matrice $C = A + B$ de type $(n \times m)$ dont les composantes $C = (c_{ij})$ sont définies par :

$$c_{ij} = a_{ij} + b_{ij} \quad (1.5)$$

1.1.2 Multiplication de deux matrices

A deux matrices $A = (a_{ik})$ de type $(n \times l)$ et $B = (b_{kj})$ de type $(l \times m)$ on peut faire correspondre la matrice $C = AB$ de type $(n \times m)$ dont les composantes $C = (c_{ij})$ sont définies par :

$$c_{ij} = \sum_{k=1}^l a_{ik} b_{kj} \quad (1.6)$$

Pour calculer c_{ij} , il faut donc multiplier le premier élément de la ligne i de A avec le premier élément de la colonne j de B , puis multiplier le deuxième élément de la ligne i de A avec le deuxième élément de la colonne j de B , ... , et enfin additionner le tout.

Par construction, le produit AB de $A \in \mathbb{R}^{n \times l}$ par $B \in \mathbb{R}^{\tilde{l} \times m}$ n'est défini que si $\tilde{l} = l$, i.e. que si le nombre de lignes de B est égal au nombre de colonnes de A .

1.1.3 Multiplication d'une matrice par un scalaire

Au scalaire λ et à la matrice $A = (a_{ij})$ de type $(n \times m)$ on peut faire correspondre la matrice $C = \lambda A$ de type $(n \times m)$, dont les composantes $C = (c_{ij})$ sont définies par :

$$c_{ij} = \lambda a_{ij} \quad (1.7)$$

Exemples : soient

$$A = \begin{pmatrix} 2 & 3 \\ 1 & 2 \end{pmatrix} \quad B = \begin{pmatrix} 1 & -1 \\ 1 & 0 \end{pmatrix} \quad C = \begin{pmatrix} 2 & 0 & -1 \\ -2 & 0 & 1 \end{pmatrix} \quad D = \begin{pmatrix} 2 & 2 \\ -1 & 0 \\ 4 & 1 \end{pmatrix} \quad (1.8)$$

Alors :

$$A + B = \begin{pmatrix} 3 & 2 \\ 2 & 2 \end{pmatrix} \quad AB = \begin{pmatrix} 5 & -2 \\ 3 & -1 \end{pmatrix} \quad BA = \begin{pmatrix} 1 & 1 \\ 2 & 3 \end{pmatrix} \quad (1.9)$$

$$AC = \begin{pmatrix} -2 & 0 & 1 \\ -2 & 0 & 1 \end{pmatrix} \quad DA = \begin{pmatrix} 6 & 10 \\ -2 & -3 \\ 9 & 14 \end{pmatrix} \quad 3D = \begin{pmatrix} 6 & 6 \\ -3 & 0 \\ 12 & 3 \end{pmatrix} \quad (1.10)$$

A et B sont des matrices carrées. On remarque que $AB \neq BA$: la multiplication matricielle n'est généralement pas commutative. Les produits CA , CB , AD , BD ne sont pas définis : ils ne correspondent pas à des types de la forme $(n \times l)$ fois $(l \times m)$. CD est une matrice de type (2×2) et DC est une matrice de type (3×3) .

1.1.4 Matrice identité

La matrice diagonale $(n \times n)$

$$I_n = \begin{pmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 1 \end{pmatrix} \quad (1.11)$$

comportant des 1 dans la diagonale principale (et des 0 ailleurs) a la propriété

$$AI_n = I_n A = A \quad (1.12)$$

quelle que soit la matrice carrée $(n \times n)$ A . On l'appelle **matrice identité** (de taille n), et la note souvent simplement par I plutôt que I_n . Si B est une matrice rectangulaire de type $(n \times m)$, on a aussi que $I_n B = BI_m = B$.

Les composantes de la matrice identité I_n ne sont généralement pas notées comme (i_{ij}) (peu lisible et inconfortable), mais par le symbole dit de *Kronecker* $I = (\delta_{ij})$, défini par

$$\delta_{ij} = \chi(i = j) = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{si } i \neq j \end{cases}.$$

où $\chi(E)$ est la *fonction caractéristique* de l'événement E , qui vaut $\chi(E) = 1$ si E est vrai, et $\chi(E) = 0$ sinon.

1.1.5 Inversion d'une matrice

On appelle **matrice inverse** de A $(n \times n)$ et on note A^{-1} la matrice $(n \times n)$ qui (si elle existe) satisfait :

$$AA^{-1} = A^{-1}A = I \quad (1.13)$$

Lorsque A possède un inverse, elle est dite **inversible**. Il existe, dans des cas particuliers, des formules simples pour calculer les inverses de certaines matrices : par exemple, lorsque A est une matrice (2×2) , on a

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \quad A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix} \quad (1.14)$$

pour autant que $ad - bc \neq 0$. Ou bien, lorsque A est une matrice diagonale d'ordre n , on a


$$D = \begin{pmatrix} d_1 & 0 & \dots & 0 \\ 0 & d_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & d_n \end{pmatrix} \quad D^{-1} = \begin{pmatrix} \frac{1}{d_1} & 0 & \dots & 0 \\ 0 & \frac{1}{d_2} & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \frac{1}{d_n} \end{pmatrix} \quad (1.15)$$

pour autant que tous les éléments diagonaux $d_1, d_2, \dots, d_n$ soient non nuls. Ce résultat se généralise aux matrices **diagonales en bloc**

$$A = \begin{pmatrix} F & 0 & \dots & 0 \\ 0 & G & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & H \end{pmatrix} \quad A^{-1} = \begin{pmatrix} F^{-1} & 0 & \dots & 0 \\ 0 & G^{-1} & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & H^{-1} \end{pmatrix} \quad (1.16)$$

où les blocs $F, G, \dots, H$ constituent eux-mêmes des matrices carrées (de taille quelconque) disposés sur la diagonale de A .

Dans le cas général, le nombre d'opérations nécessaires à inverser une matrice $(n \times n)$ croît, à une constante multiplicative près, comme le *cube* n^3 de la taille de la matrice à inverser : pour n même modeste, le recours à une routine numérique devient vite indispensable.

FIGURE 1.1 – représentations des vecteurs x et y dans le repère orthonormé à 3 dimensions

1.1.6 Transposée d'une matrice

On appelle **matrice transposée** de la matrice A ($n \times m$) et on note A^T ou A' la matrice ($m \times n$) obtenue à partir de A en échangeant lignes et colonnes

$$A' = \begin{pmatrix} a_{11} & a_{21} & \dots & a_{n1} \\ a_{12} & a_{22} & \dots & a_{n2} \\ \dots & \dots & \dots & \dots \\ a_{1m} & a_{2m} & \dots & a_{nm} \end{pmatrix} \quad (1.17)$$

1.1.7 Matrices symétriques et orthogonales

Une matrice carrée A est dite **symétrique** si $A' = A$.

Les matrices inverses et transposées satisfont à :

$$(A')^{-1} = (A^{-1})' \quad (AB)^{-1} = B^{-1}A^{-1} \quad (AB)' = B'A' \quad (1.18)$$

Une matrice carrée A est dite **orthogonale** si sa transposée est égale à son inverse :

$$A' = A^{-1} \quad \Leftrightarrow \quad A'A = AA' = I \quad (1.19)$$

1.1.8 Produit scalaire

Deux vecteurs colonne de type $(n \times 1)$

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{pmatrix} \quad \text{et} \quad y = \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{pmatrix} \quad (1.20)$$

peuvent être visualisés comme deux points dans un espace à n dimensions, ce dernier étant muni d'un repère orthonormé formé de n axes perpendiculaires identiquement gradués, i.e. munis d'une origine commune et d'une unité de même longueur (voir figure 1.1). Sur ce repère orthonormé ou *base* orthonormale, le vecteur x est alors repéré par la coordonnée x_1 sur le premier axe, x_2 sur le second, etc... (voir figure 1.1). Le *vecteur nul* $\mathbf{0}$ dont les n composantes sont toutes nulles est représenté par le point à l'origine.

Le **produit scalaire** entre x et y est noté (x, y) et défini par :

$$(x, y) = (y, x) := x'y = y'x = \sum_{i=1}^n x_i y_i \quad (1.21)$$




FIGURE 1.2 – théorème de Pythagore : le carré de la longueur d'un vecteur x est égal à la somme des carrés de ses composantes : $\|x\|^2 = x_1^2 + x_2^2 + \dots + x_n^2$

Deux vecteurs x et y sont dits **orthogonaux** (noté $x \perp y$) si $(x, y) = 0$.

La définition (1.21) montre que le produit scalaire (x, y) , obtenu en multipliant (dans cet ordre) un premier vecteur ligne avec un second vecteur colonne, est un cas particulier de la multiplication matricielle, dont le résultat $x'y = y'x$ est un scalaire. Par contraste, les expressions xy' et yx' sont de type $(n \times 1) \cdot (1 \times n) = (n \times n)$, et constituent des matrices carrées de taille n , transposées l'une de l'autre.

1.1.9 Norme et dissimilarité euclidienne

La racine carrée du produit scalaire d'un vecteur x avec lui-même est appelée **norme** (euclidienne) x , et notée $\|x\|$. En vertu du théorème de Pythagore, la norme (euclidienne) $\|x\|$ du vecteur x s'interprète alors comme la longueur (ordinaire) de x (figure 1.2) :

$$\|x\| := \sqrt{(x, x)} = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2} \quad (1.22)$$

Un vecteur x est **normé** si $\|x\| = 1$. *Normaliser* (ou *normer*) un vecteur, c'est le diviser par sa norme de sorte que le vecteur résultant soit de norme 1. Par exemple, le vecteur $x = \begin{pmatrix} 4 \\ 3 \end{pmatrix}$ est de norme $\|x\| = \sqrt{3^2 + 4^2} = \sqrt{25} = 5$; sa normalisation $\frac{1}{5} \begin{pmatrix} 4 \\ 3 \end{pmatrix} = \begin{pmatrix} 4/5 \\ 3/5 \end{pmatrix}$ produit un vecteur de longueur $\sqrt{(3/5)^2 + (4/5)^2} = \sqrt{25/25} = 1$.

La **distance euclidienne** $d(x, y)$ entre deux vecteurs x et y de n composantes chacun est définie comme la norme euclidienne de leur différence :

$$d(x, y) := \|x - y\| = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2} \quad (1.23)$$

La quantité $d(x, y)$ constitue une mesure de dissimilarité entre x et y : il est d'autant plus grand que les composantes de x et de y diffèrent entre elles. Cette dissimilarité possède les propriétés suivantes :

- (i) $d(x, y) \geq 0$ (non-négativité)
- (ii) $d(x, y) = d(y, x)$ (symétrie)
- (iii) $d(x, x) = 0$ (diagonale nulle)
- (iv) $d(x, y) = 0$ ssi $x = y$ (dissimilarité "propre")
- (v) $d(x, y) + d(y, z) \geq d(x, z)$ (inégalité triangulaire)

Les propriétés (i), (ii) et (iii) définissent une *dissimilarité* en général. Si l'on y ajoute la propriété (v), on parle d'une *dissimilarité métrique* ou *distance*.

1.1.10 Angle entre deux vecteurs

Le produit scalaire (1.21) entre deux vecteurs x et y dont les directions mesurées depuis l'origine diffèrent d'un angle α (voir figure 1.1) peut aussi se calculer par

$$(x, y) = \|x\| \|y\| \cos \alpha \quad (1.24)$$

Deux vecteurs non nuls x et y sont ainsi orthogonaux (i.e. $(x, y) = 0$) ssi $\cos \alpha = 0$, i.e. ssi $\alpha = \pm 90^\circ$, i.e. ssi x et y sont perpendiculaires.

Quels que soient les deux vecteurs x et y , il est toujours vrai que $-\|x\|\|y\| \leq (x, y) \leq \|x\|\|y\|$. Cette inégalité, dite de *Cauchy-Schwartz*, montre que le cosinus d'un angle ne peut excéder 1 en valeur absolue : en posant $(x, y) = \|x\| \|y\| \cos \alpha$ et en divisant l'inégalité précédente par $\|x\| \|y\|$, il vient immédiatement que $-1 \leq \cos \alpha \leq 1$. Pour mémoire, $\cos(0^\circ) = 1$, $\cos(90^\circ) = 0$, $\cos(180^\circ) = -1$ et $\cos(270^\circ) = 0$.

1.1.11 Caractérisation des matrices orthogonales

Les matrices orthogonales A tirent leur nom de la caractérisation suivante : *une matrice $A = (A_1|A_2|\dots|A_n)$ de type $(n \times n)$ est orthogonale ssi tous ses vecteurs colonne $A_1, A_2, \dots, A_n$ sont orthogonaux entre eux, i.e. si*

$$(A_i, A_j) = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{sinon} \end{cases} = \delta_{ij} \quad (1.25)$$

Cette équation exprime que chaque vecteur est de norme unité ($\|A_i\|^2 = (A_i, A_i) = 1$), ainsi qu'orthogonal aux autres vecteurs ($A_i \perp A_j$ pour $i \neq j$). On dit que les vecteurs $A_1, \dots, A_n$ sont *orthonormaux*. On montre facilement que la propriété (1.25) est équivalente à la propriété d'orthogonalité $AA' = I$, et qu'un résultat analogue s'applique aux vecteurs ligne de A .

1.2 Application linéaire et projection

1.2.1 Le concept d'application linéaire

Si A est une matrice $(m \times n)$, l'application $y = Ax$ transforme le vecteur x à n composantes en le vecteur y à m composantes. Cette application $x \mapsto y := Ax$ est **linéaire**, i.e. possède les propriétés

$$\text{si } x_1 \mapsto y_1 \text{ et } x_2 \mapsto y_2 \text{ alors } \alpha x_1 \mapsto \alpha y_1 \text{ et } x_1 + x_2 \mapsto y_1 + y_2 \quad (1.26)$$

c'est-à-dire que si l'"entrée" x est multipliée par un nombre α positif ou négatif, la "sortie" y sera multipliée par la même quantité. Aussi, la sortie d'une somme est la somme des sorties. Inversement, toute application *linéaire* transformant un vecteur x à n composantes en vecteur y à m composantes est de la forme $y = Ax$, où A est une matrice $(m \times n)$.

L'équivalence entre matrices et applications linéaires rend les appellations *algèbre linéaire* et *calcul matriciel* largement synonymes.

L'opération $y = x + b$ de translation par un vecteur constant b n'est, au sens strict, pas linéaire : elle ne peut être représentée par une transformation de type $y = Ax$ (qui doit, contrairement à la translation, transformer le vecteur nul $\mathbf{0}$ en $\mathbf{0}$, c'est-à-dire laisser l'origine invariante). Il est cependant courant (en statistique en particulier) de qualifier de *linéaire* au sens large toute transformation de type général $y = Ax + b$ (qualifiée plus strictement d'*affine* en mathématiques).

1.2.2 Caractérisation géométrique des matrices diagonales et orthogonales

La matrice diagonale associée au vecteur $d \in \mathbb{R}^n$

$$D = \text{diag}(d) = \begin{pmatrix} d_1 & 0 & \dots & 0 \\ 0 & d_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & d_n \end{pmatrix} \quad (1.27)$$




FIGURE 1.3 – transformation diagonale : dilatation de 200% de la première composante et inversion par rapport à la seconde composante




FIGURE 1.4 – rotation de 45° dans le plan Oxy par la matrice (1.29)

a, dans l'application $y = Dx$, pour effet de multiplier x_1 par d_1 , x_2 par d_2 , etc... : il s'agit donc, géométriquement, d'une **dilatation** dans chacune des directions, accompagnée éventuellement d'une **inversion par rapport à l'axe i** si d_i est négatif. La figure 1.3 illustre le cas bidimensionnel avec $d_1 = 2$ et $d_2 = -1$.

Une matrice orthogonale U a la propriété de laisser les longueurs (et les angles) invariants. En effet, si $y = Ux$, alors :

$$\|y\|^2 = y'y = (Ux)'(Ux) = x'U'Ux = x'x = \|x\|^2 \quad (1.28)$$

d'où “norme de y ” = “norme de x ”. Une matrice orthogonale agit donc comme une **rotation**, avec présence possible d'une **inversion par rapport à l'origine** (par la suite, la présence possible d'une inversion accompagnant une rotation ou une dilatation sera sous-entendue). Par exemple, à deux dimensions, la matrice orthogonale

$$U = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \quad (1.29)$$

appliquée à x fait tourner x autour de l'origine dans le sens trigonométrique (= inverse des aiguilles d'une montre) d'un angle de 45° (voir figure 1.4). (rappel : $\sin(45^\circ) = \cos(45^\circ) = \frac{1}{\sqrt{2}}$). Plus généralement, la matrice orthogonale

$$U = \begin{pmatrix} \cos \alpha & -\sin \alpha \\ \sin \alpha & \cos \alpha \end{pmatrix} \quad (1.30)$$

est la matrice de rotation d'angle α . dans le plan, mesuré dans le sens trigonométrique.

1.2.3 Parallélisme, combinaisons linéaires et indépendance linéaire

Un vecteur $y \in \mathbb{R}^n$ de la forme $y = \alpha x$ (où $\alpha \in \mathbb{R}$ est un scalaire quelconque) est dit *parallèle* au vecteur $x \in \mathbb{R}^n$.

Soit $\{x_1, \dots, x_k\}$ une liste de k vecteurs, chacun à n composantes. Une expression de la forme $\alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_k x_k = \sum_{j=1}^k \alpha_j x_j$, où chaque $\alpha_j \in \mathbb{R}$, est appelée *combinaison linéaire* de la liste initiale. Toute combinaison linéaire définit un vecteur à n composantes également. En attribuant à chacun des coefficients

α_j toutes les valeurs réelles possibles, on génère un ensemble infini de vecteurs appelé *hyperplan engendré* par $\{x_1, \dots, x_k\}$ et noté $M(x_1, \dots, x_k)$ ou simplement M s'il n'y a pas de confusion possible. Cet hyperplan contient le vecteur nul $\mathbf{0}$ (puisque $\mathbf{0} = 0x_1 + 0x_2 + \dots + 0x_k$); de plus, l'hyperplan M possède les propriétés suivantes :

- si $x \in M$ alors $\lambda x \in M$ pour tout scalaire λ
- si $x \in M$ et $y \in M$ alors $x + y \in M$

qui font de M un *espace vectoriel*.

Exemple : l'hyperplan $M(x_1)$ engendré par le seul vecteur x_1 consiste en tous les vecteurs parallèles à x_1 .

L'ensemble $\{x_1, \dots, x_k\}$ est dit **(linéairement) indépendant** si aucun vecteur de la liste n'appartient à l'hyperplan formé par les autres vecteurs. Par exemple, si

$$x_1 = \begin{pmatrix} 1 \\ 2 \\ 0 \\ 1 \end{pmatrix} \quad x_2 = \begin{pmatrix} 2 \\ -1 \\ 1 \\ 3 \end{pmatrix} \quad x_3 = \begin{pmatrix} 4 \\ 3 \\ 1 \\ 5 \end{pmatrix} \quad x_4 = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} \quad (1.31)$$

alors les ensembles $\{x_1, x_2, x_4\}$, $\{x_1, x_3, x_4\}$ ou $\{x_2, x_3, x_4\}$ sont linéairement indépendants. Par contre, $\{x_1, x_2, x_3\}$ ne l'est pas car $x_3 = 2x_1 + x_2$.

Une liste $\{x_1, \dots, x_k\}$ de vecteurs linéairement indépendants est appelée **base** de l'hyperplan $M(x_1, \dots, x_k)$. Si les vecteurs possèdent n composantes, un ensemble de vecteurs indépendants contient au plus n éléments.

Attention : l'indépendance en question est une notion purement *géométrique*, tout-à-fait distincte du concept de l'indépendance *statistique* qui qualifie une relation possible entre événements ou variables, pour une distribution de probabilité donnée.

1.2.4 Rang d'une matrice

Le **rang** d'une matrice A ($n \times m$), noté $\text{rang}(A)$ ou $\text{rg}(A)$, est le nombre de vecteurs colonne indépendants contenus dans A , ou, ce qui revient au même (il s'agit là d'un théorème dont la preuve n'est pas si immédiate), le nombre de vecteurs ligne indépendants contenus dans A . Par définition, $\text{rang}(A) \leq \min(n, m)$. Dans l'exemple suivant


$$A = \begin{pmatrix} 1 & 0 & 3 \\ 0 & 2 & 1 \\ -1 & 0 & -3 \end{pmatrix} \quad B = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{pmatrix} \quad C = \begin{pmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 3 & 0 & -3 \end{pmatrix} \quad (1.32)$$

on a $\text{rang}(A) = 2$, $\text{rang}(B) = 3$ et $\text{rang}(C) = 1$.

1.2.5 Matrice de projection

Soit $\{x_1, \dots, x_k\}$ un ensemble de k vecteurs linéairement indépendants de n composantes chacun. Ces vecteurs forment une base de l'hyperplan $M(x_1, \dots, x_k)$. On note $X := (x_1 | x_2 | \dots | x_k) \in \mathbb{R}^{n \times k}$ la matrice ($n \times k$) formée des composantes de la base. Soit y un vecteur à n composantes n'appartenant pas à l'hyperplan $M \equiv M(x_1, \dots, x_k)$. On cherche à déterminer le vecteur y^* de M le plus similaire à y au sens où la distance euclidienne $\|y - y^*\|$ (1.23) est minimale. Ce vecteur y^* est appelé *projection de y sur M* (figure 1.5). Il est facile de voir que la correspondance entre y et y^* est *linéaire* : par exemple, si l'on remplace y par $3y$, alors sa projection y^* deviendra $3y^*$. Ceci implique que la relation est de la forme $y^* = Py$ où P est une matrice ($n \times n$), appelée **matrice de projection**. Cette matrice dépend uniquement de M , ou, de façon équivalente, uniquement de la matrice X des composantes de la base de M . On peut montrer (ce que nous ne ferons pas) que la relation cherchée est $P = X(X'X)^{-1}X'$. En résumé

$$\text{si } \min_{z \in M} \|y - z\| = \|y - y^*\| \quad \text{alors } y^* = Py \quad \text{où } P := X(X'X)^{-1}X' \quad \text{et } X := (x_1 | x_2 | \dots | x_k) \quad (1.33)$$

FIGURE 1.5 – projection $y^* = Py$ de y sur l'hyperplan M engendré par x_1 et x_2

P s'obtient donc au moyen d'une expression impliquant l'inversion d'une matrice $(k \times k)$, impliquant des calculs conséquents lorsque k est grand.

On a $d(y, y^*) = \|e\|$, où $e := y - y^*$ (voir figure 1.5). On peut montrer que l'angle entre e et M doit être droit (sans quoi la longueur e ne serait pas minimale). Ainsi, le vecteur y se décompose en deux vecteurs perpendiculaires entre eux $y = y^* + e$ pour lesquels s'applique le théorème de Pythagore $\|y\|^2 = \|y^*\|^2 + \|e\|^2$. En notant par α l'angle entre y et M (voir figure 1.5), on a $\|Py\| = \|y^*\| = \|y\| \cos \alpha$ (une projection raccourcit les longueurs) et $\|e\| = \|y\| \sin \alpha$.

Par construction, y^* est sa propre projection sur M (c'est le vecteur de M le plus proche de lui-même). Ainsi, $P^2y = P(Py) = Py^* = y^* = Py$ quel que soit y , et donc $\boxed{P^2 = P}$ pour toute matrice de projection. Cette propriété dite d'*idempotence* peut être démontrée directement à partir de (1.33). On montre aussi que $\boxed{P' = P}$, i.e. que toute projection est symétrique. Enfin, on peut établir que $\text{rang}(P) = k$. Inversement, toute matrice A de taille $(n \times n)$, de rang $\text{rang}(A) = k$, idempotente et symétrique est une matrice de projection sur un hyperplan M de dimension k plongé dans un espace de dimension n .

Deux cas particuliers extrêmes sont instructifs :

- si $k = 1$, i.e. si l'hyperplan M est engendré par un seul vecteur x_1 , alors on peut montrer que la matrice de projection P devient $P = \frac{1}{\|x_1\|^2} x_1 x_1'$, de rang $\text{rang}(P) = 1$.
- si $k = n$, i.e. si l'hyperplan M se confond avec l'espace entier à n dimensions (puisque les vecteurs $x_1, \dots, x_n$ à n dimensions et linéairement indépendants par hypothèse forment une base de cet espace), alors la matrice de projection P devient $P = I$, la matrice identité, de rang $\text{rang}(P) = n$. Ce résultat est évident : si M se confond avec l'espace tout entier, tout vecteur y appartient à M et le vecteur $y^* \in M$ qui lui est le moins dissimilaire n'est autre que y lui-même, d'où $y^* = y = Iy$, et finalement $P = I$.

Exemple : les vecteurs tridimensionnels

$$x_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \quad x_2 = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \quad (1.34)$$

engendrent un hyperplan $M(x_1, x_2)$ qui se trouve être un plan ordinaire (i.e. à deux dimensions, puisqu'engendré par deux vecteurs indépendants). Pour déterminer l'opérateur de projection P sur ce plan M , on forme successivement les matrices

$$X = \begin{pmatrix} 1 & 1 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} \quad X' = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \end{pmatrix} \quad X'X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix} \quad (X'X)^{-1} = \begin{pmatrix} 2 & -1 \\ -1 & 1 \end{pmatrix} \quad (1.35)$$

où l'on a utilisé (1.14) dans le dernier calcul. La matrice de projection recherchée est alors

$$P = X(X'X)^{-1}X' = \begin{pmatrix} 1 & 1 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 2 & -1 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} \quad (1.36)$$

dont on peut vérifier qu'elle est symétrique et idempotente. Tout vecteur $y' = (y_1, y_2, y_3)$ se transforme donc en $y^* := Py$ par projection, où $y^* = (y_1, y_2, 0)$: dans cet exemple, projeter un vecteur revient simplement à annuler sa troisième composante, ce que l'on aurait pu deviner à l'avance en observant que les valeurs particulières (1.34) des vecteurs x_1 et x_2 font que le plan $M(x_1, x_2)$ engendré par ces derniers est simplement le plan d'équation $y_3 = 0$ ¹.

1.3 Décomposition spectrale d'une matrice

1.3.1 Valeurs et vecteurs propres

En général, deux vecteurs x et y de même dimension reliés par une application linéaire $y = Ax$ ne sont pas parallèles. Si ceci était néanmoins le cas, i.e. s'il existait un scalaire λ tel que $y = \lambda x$, x serait appelé vecteur propre de A pour la valeur propre associée λ :

Définition : soit $A \in \mathbb{R}^{(n \times n)}$ une matrice carrée, et $x \in \mathbb{R}^n$ un vecteur colonne satisfaisant la relation

$$Ax = \lambda x \quad (1.37)$$

où $\lambda \in \mathbb{R}$ est un scalaire. On dit alors que x est **vecteur propre (ve.p.)** (eigenvector) de A pour la **valeur propre (va.p.)** (eigenvalue) λ .

L'ensemble des valeurs propres d'une matrice A constitue son *spectre*. Dans tout ce qui suit, on se limitera au cas "simple" des matrices *A réelles et symétriques* (i.e. $A \in \mathbb{R}^{n \times n}$ avec $A = A'$), suffisamment riche néanmoins pour aborder les problèmes de base en analyse de données et statistique multivariée. Une matrice réelle symétrique possède n va.p., distinctes ou non, $\lambda_1, \dots, \lambda_n$, avec des ve.p. associés $x_1, \dots, x_n$, satisfaisant :

$$Ax_\alpha = \lambda_\alpha x_\alpha \quad \alpha = 1, 2, \dots, n \quad (1.38)$$

Il s'avère utile (ce que nous ferons) d'utiliser des indices grecs ($\alpha, \beta \dots$) pour numéroter les valeurs et vecteurs propres d'une matrice A . Telle quelle, cette numérotation est arbitraire ; on choisit généralement d'ordonner les indices par valeurs décroissantes des valeurs propres, i.e. de poser $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_\alpha \geq \lambda_n$.

Une matrice symétrique pour laquelle $\lambda_\alpha > 0$ pour tout α est dite *définie positive* (d.p.). Si $\lambda_\alpha \geq 0$ pour tout α , elle est dite *semi-définie positive* (s.d.p.). On peut prouver qu'une matrice A de type $(n \times n)$ est semi-définie positive ssi elle peut s'écrire comme $A = CC'$ où C est une matrice de type $(n \times m)$ (avec m quelconque, qui peut toujours être choisi comme $m \leq n$). C'est ainsi que l'on peut montrer que les matrices de corrélation ou de variance-covariance (chapitre 2) sont s.d.p.

Il est facile de voir que si x est ve.p. de A pour la va.p. μ , alors n'importe quel vecteur y parallèle à x est également ve.p. de A pour la même va.p. : les vecteurs propres d'une matrice sont donc définis à un facteur multiplicatif près, et définissent ainsi des *directions* particulières de l'espace (précisément celles qui restent invariantes après transformation). Pour assurer l'unicité des ve.p., on choisit généralement de les normer : si x est ve.p. de A , alors $u := x/\|x\|$ est également ve.p. et satisfait de plus $\|u\| = 1$. Cependant, l'unicité n'est assurée qu'au *sens* près : si u est un ve.p. normé, alors $-u$ est aussi un ve.p. normé tout aussi "légitime" que ne l'est u : en jouant sur les mots, le sens d'un vecteur propre n'a pas de sens donné ou privilégié.

1. attention : il y a en général, et ici en particulier, ambiguïté de notation au sens où z_i peut, selon le contexte, soit représenter le i -ème vecteur d'une liste, soit la i -ème composante du vecteur z .

1.3.2 Déterminant et trace

Le **déterminant** d'une matrice carrée A ($n \times n$), noté **det**(A), est le produit des valeurs propres de A :

$$\det(A) = \prod_{\alpha=1}^n \lambda_{\alpha} \quad (1.39)$$

Il suffit qu'une des va.p. soit nulle pour que $\det(A) = 0$. On peut montrer que le rang de A est égal au nombre de ses valeurs propres non nulles, et que

$$A^{-1} \text{ existe} \Leftrightarrow \det(A) \neq 0 \Leftrightarrow \text{rang}(A) = n \quad (1.40)$$

En général, $\det(AB) = \det(A) \det(B)$; de plus, $\det(A^{-1}) = (\det(A))^{-1}$ et $\det(A') = \det(A)$.

Cas particuliers :

- le déterminant d'une matrice diagonale A est égale au produit de ses éléments diagonaux : $\det(A) = a_{11}a_{22} \dots a_{nn}$. Cette propriété *n'est pas réalisée* si A n'est pas diagonale.
- le déterminant d'une matrice orthogonale vaut toujours +1 ou -1.
- lorsque A est une matrice (2×2) :

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \quad \det(A) = ad - bc \quad (1.41)$$

La **trace** d'une matrice carrée A ($n \times n$), notée **trace**(A) ou **tr**(A), est la somme de ses éléments diagonaux :

$$\text{trace}(A) = a_{11} + a_{22} + \dots + a_{nn} \quad (1.42)$$

On peut montrer qu'en général $\text{trace}(AB) = \text{trace}(BA)$, et que $\text{trace}(A) = \lambda_1 + \dots + \lambda_n$: la trace d'une matrice est toujours égale à la somme de ses va.p.

1.3.3 Le théorème spectral

A bien des égards, les matrices orthogonales et diagonales se comportent comme des matrices élémentaires permettant de reconstruire toute matrice carrée de même type. Le *théorème spectral* (donné sans preuve) constitue la formulation précise de cet énoncé.

Théorème spectral : toute matrice symétrique A de type ($n \times n$) peut s'écrire de façon (presque²) unique comme :

$$A = U\Lambda U' \quad \text{avec} \quad U = (u_1 | \dots | u_{\alpha} | \dots | u_n) \quad UU' = I \quad \Lambda = \text{diag}(\lambda) \quad (1.43)$$

où $U = (u_{i\alpha})$ est une matrice orthogonale dont les colonnes sont formées par les vecteurs propres normés de A , et $\Lambda = \text{diag}(\lambda) = (\delta_{\alpha\beta} \lambda_{\alpha})$ est une matrice diagonale dont les composantes non nulles sont formées des valeurs propres de A .

En termes de vecteurs propres, ainsi qu'en composantes, la décomposition spectrale (1.43) de $A = (a_{ij})$ s'écrit de façon équivalente comme (à vérifier !)

$$A = \sum_{\alpha=1}^n \lambda_{\alpha} u_{\alpha} u'_{\alpha} \quad a_{ij} = \sum_{\alpha=1}^n \lambda_{\alpha} u_{i\alpha} u_{j\alpha} \quad (1.44)$$

Déterminer les va.p. et ve.p. d'une matrice A symétrique, ou déterminer les matrices U et Λ intervenant dans la décomposition spectrale (1.43) de A sont donc deux opérations équivalentes, que l'on appelle encore **diagonalisation** ou **décomposition spectrale** de A . Cette opération est à la base des méthodes dites *factorielles* (ACP, MDS, AFC, analyse discriminante, etc.) en analyse de données.

2. presque : le choix de la numérotation $\alpha = 1, \dots, n$ des va.p. de A et des ve.p. associés, ainsi que du sens de ces derniers reste arbitraire ; cf. section 1.3.1

Exemple : on considère la matrice réelle symétrique

$$A = \begin{pmatrix} -1 & \sqrt{2} \\ \sqrt{2} & 0 \end{pmatrix} \quad \text{dont les ve.p. normalisés sont}$$

$$u_1 = \begin{pmatrix} \frac{1}{\sqrt{3}} \\ \sqrt{\frac{2}{3}} \end{pmatrix} \quad \text{et} \quad u_2 = \begin{pmatrix} -\sqrt{\frac{2}{3}} \\ \frac{1}{\sqrt{3}} \end{pmatrix}$$

avec les va. p. associées $\lambda_1 = 1$, $\lambda_2 = -2$ (à vérifier!).

La matrice $U := (u_1|u_2) = \begin{pmatrix} \sqrt{\frac{1}{3}} & \sqrt{\frac{2}{3}} \\ -\sqrt{\frac{2}{3}} & \sqrt{\frac{1}{3}} \end{pmatrix}$ constitue bien une matrice orthogonale. On vérifie alors que l'application du théorème spectral permet de reconstituer A :

$$\lambda_1 u_1 u_1' + \lambda_2 u_2 u_2' = 1 \begin{pmatrix} \frac{1}{3} & \frac{\sqrt{2}}{3} \\ \frac{\sqrt{2}}{3} & \frac{2}{3} \end{pmatrix} - 2 \begin{pmatrix} \frac{2}{3} & -\frac{\sqrt{2}}{3} \\ -\frac{\sqrt{2}}{3} & \frac{1}{3} \end{pmatrix} = \begin{pmatrix} -1 & \sqrt{2} \\ \sqrt{2} & 0 \end{pmatrix} = A$$

1.3.4 (*) Projections propres et fonctions de matrices

Considérons la matrice $P_\alpha := u_\alpha u_\alpha' \in \mathbb{R}^{n \times n}$ apparaissant dans (1.44), de composantes $p_{\alpha ij} := u_{i\alpha} u_{j\alpha}$. Comme u_α est un vecteur normé, on a que $P_\alpha^2 = u_\alpha \underbrace{u_\alpha' u_\alpha}_{=1} u_\alpha' = u_\alpha u_\alpha' = P_\alpha$. Aussi, $P_\alpha' = (u_\alpha u_\alpha')' = P_\alpha$.

P_α est idempotente et symétrique : c'est une matrice de *projection propre*, i.e. projetant tout vecteur sur le sous-espace engendré par le α -ème vecteur propre u_α . Les projecteurs associés à des ve.p. distinctes sont orthogonaux : l'orthogonalité de u_α et u_β pour $\alpha \neq \beta$ entraîne que $P_\alpha P_\beta = u_\alpha \underbrace{u_\alpha' u_\beta}_{=0} u_\beta' = 0$.

Ainsi, A se réécrit comme $A = U \Lambda U' \sum_{\alpha=1}^n \lambda_\alpha P_\alpha$, et il est facile de montrer que son carré ou son inverse, par exemple, s'obtiennent comme

$$A^2 = U \Lambda^2 U' = \sum_{\alpha=1}^n \lambda_\alpha^2 P_\alpha \quad A^{-1} = U \Lambda^{-1} U' = \sum_{\alpha=1}^n \frac{1}{\lambda_\alpha} P_\alpha \quad (1.45)$$

la dernière identité présupposant qu'aucune va.p. de A n'est nulle, i.e. que A est bien inversible. Plus généralement, toute *fonction de matrice* $f(A)$ (où $f(x)$ est une fonction suffisamment régulière, telle que $\sqrt{x}$, $\exp(x)$, $\ln(x)$, $\sin(x)$, ...) peut s'écrire comme

$$f(A) = U f(\Lambda) U' = \sum_{\alpha=1}^n f(\lambda_\alpha) P_\alpha$$

où $f(\Lambda)$ est la matrice diagonale obtenue en appliquant la fonction $f(x)$ sur chaque composante diagonale λ_α de Λ . Ainsi, la matrice symétrique $f(A) \in \mathbb{R}^{n \times n}$ possède les mêmes ve.p. que la matrice symétrique $A \in \mathbb{R}^{n \times n}$, et ses va.p. s'obtiennent simplement à partir des va.p. λ_α de A comme $f(\lambda_\alpha)$. En particulier, la connaissance de la décomposition spectrale $A = U \Lambda U'$ d'une matrice A permet de l'inverser facilement par $A^{-1} = U \Lambda^{-1} U'$, ce qui montre au passage que le calcul de la décomposition spectrale d'une matrice est une opération au moins aussi laborieuse que le calcul de son inverse. On peut vérifier directement que $A^{-1} A = U \Lambda^{-1} U' U \Lambda U' = U \Lambda^{-1} \Lambda U' = U U' = I$, comme il se doit (car $U' U = U U' = I$).

Par exemple, l'inverse et l'exponentielle de la matrice de l'exemple précédent valent

$$A^{-1} = \frac{1}{\lambda_1} u_1 u_1' + \frac{1}{\lambda_2} u_2 u_2' = \frac{1}{1} \begin{pmatrix} \frac{1}{3} & \frac{\sqrt{2}}{3} \\ \frac{\sqrt{2}}{3} & \frac{2}{3} \end{pmatrix} - \frac{1}{2} \begin{pmatrix} \frac{2}{3} & -\frac{\sqrt{2}}{3} \\ -\frac{\sqrt{2}}{3} & \frac{1}{3} \end{pmatrix} = \begin{pmatrix} 0 & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{2} \end{pmatrix}$$

$$\exp(A) = \exp(\lambda_1) u_1 u_1' + \exp(\lambda_2) u_2 u_2' = \exp(1) \begin{pmatrix} \frac{1}{3} & \frac{\sqrt{2}}{3} \\ \frac{\sqrt{2}}{3} & \frac{2}{3} \end{pmatrix} + \exp(-2) \begin{pmatrix} \frac{2}{3} & -\frac{\sqrt{2}}{3} \\ -\frac{\sqrt{2}}{3} & \frac{1}{3} \end{pmatrix} = \begin{pmatrix} 0.996 & 1.218 \\ 1.218 & 1.857 \end{pmatrix}$$

1.3.5 (*) Théorème de décomposition singulière

Il existe une forme de généralisation du théorème de décomposition spectrale pour les matrices non symétriques ou même rectangulaires de type $n \times m$, appelée *théorème de décomposition singulière*. La voici :

Théorème de décomposition singulière : toute matrice réelle $A \in \mathbb{R}^{n \times m}$ de rang r peut s'écrire comme :

$$A = U\Lambda V' \quad (1.46)$$

où U est une matrice $(n \times r)$ dont les r colonnes u_α ($\alpha = 1, \dots, r$) sont orthonormales ($U'U = I_r$), V est une matrice $(m \times r)$ dont les r colonnes v_α ($\alpha = 1, \dots, r$) sont orthonormales ($V'V = I_r$) et Λ est une matrice diagonale $(r \times r)$ de composantes $\lambda_\alpha > 0$ strictement positives, appelées valeurs singulières.

Exemples : les exemples ci-dessous illustrent trois décompositions singulières, donc on peut vérifier (si on y tient) qu'elles reconstituent effectivement la matrice de départ. On peut bien sûr déterminer "à la calculatrice" ces décompositions singulières – un exercice par ailleurs fastidieux qui n'est guère pratiqué; tout praticien aura recours à des routines numériques, telles `svd()` pour la décomposition singulière dans R, et `eigen()` pour la décomposition spectrale.

(1) la décomposition singulière de $B = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}$ est $B = U\Lambda V'$ avec

$$U = \begin{pmatrix} -0.386 & -0.922 \\ -0.922 & 0.386 \end{pmatrix} \quad \Lambda = \begin{pmatrix} 9.508 & 0 \\ 0 & 0.773 \end{pmatrix} \quad V = \begin{pmatrix} -0.429 & 0.806 \\ -0.566 & 0.112 \\ -0.704 & -0.581 \end{pmatrix}$$

(2) La décomposition singulière de $C = \begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix}$ est $C = U\Lambda V'$ avec

$$U = \begin{pmatrix} 0.788 & -0.615 \\ 0.615 & 0.788 \end{pmatrix} \quad \Lambda = \begin{pmatrix} 2.562 & 0 \\ 0 & 1.562 \end{pmatrix} \quad V = \begin{pmatrix} 0.615 & -0.788 \\ 0.788 & 0.615 \end{pmatrix}$$

(3) La décomposition singulière de la matrice $A = \begin{pmatrix} -1 & \sqrt{2} \\ \sqrt{2} & 0 \end{pmatrix}$, déjà considérée dans l'exemple ci-dessus, est $A = U\Lambda V'$ avec

$$U = \begin{pmatrix} -\sqrt{\frac{2}{3}} & \sqrt{\frac{1}{3}} \\ \sqrt{\frac{1}{3}} & \sqrt{\frac{2}{3}} \end{pmatrix} \quad \Lambda = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix} \quad V = \begin{pmatrix} \sqrt{\frac{2}{3}} & \sqrt{\frac{1}{3}} \\ -\sqrt{\frac{1}{3}} & \sqrt{\frac{2}{3}} \end{pmatrix}$$

que l'on peut comparer avec sa décomposition spectrale $A = \tilde{U}\tilde{\Lambda}\tilde{U}'$ qui était

$$\tilde{U} = \begin{pmatrix} \sqrt{\frac{1}{3}} & \sqrt{\frac{2}{3}} \\ -\sqrt{\frac{2}{3}} & \sqrt{\frac{1}{3}} \end{pmatrix} \quad \tilde{\Lambda} = \begin{pmatrix} 1 & 0 \\ 0 & -2 \end{pmatrix}$$

Ainsi, et de façon générale, l'utilisation de deux matrices orthogonales U et V permet la décomposition singulière d'une matrice A quelconque, avec une matrice diagonale associée Λ dont les composantes sont positives (ce sont les valeurs singulières), tandis que l'utilisation d'une seule matrice orthogonale U ne garantit en général que la décomposition de matrices A carrées symétriques, avec des composantes diagonales (ce sont les valeurs propres) qui peuvent être positives ou négatives.

Aussi, on déduit du théorème de décomposition singulière de $A \in \mathbb{R}^{n \times m}$ les identités $AA' = U\Lambda^2U'$ et $A'A = V\Lambda^2V'$, qui sont deux cas particuliers du théorème spectral (les matrices $AA' \in \mathbb{R}^{n \times n}$ et $A'A \in \mathbb{R}^{m \times m}$ étant symétriques, et par ailleurs semi-définies positives). Ainsi, les valeurs singulières (composantes de Λ) sont la *racine carrée des valeurs propres non nulles* (et strictement positives : composantes de Λ^2) de AA' , ou de $A'A$ (ce sont les mêmes).

Enfin, on établit facilement les formules dites de *transition* $U = AV\Lambda^{-1}$ et $V = A'U\Lambda^{-1}$. Ainsi, une façon de calculer la décomposition singulière de A est de déterminer U et Λ par la décomposition spectrale $AA' = U\Lambda^2U$, puis de calculer V par $A'U\Lambda^{-1}$.

1.4 Exercices et corrigés

Exercice 1.1

1. Soit $A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$, $B = \begin{pmatrix} 1 & 0 \\ 2 & 3 \\ 4 & 5 \end{pmatrix}$ et $C = \begin{pmatrix} 0 & 1 \\ -1 & 3 \end{pmatrix}$
calculer (si elles existent) $A + C$, AC , CA , AB , A' , B' et vérifier que $(BA)' = B'A'$.
2. Vérifier que si $A = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & -1 & 1 \end{pmatrix}$ alors $A^{-1} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{2} & -\frac{1}{2} \\ 0 & \frac{1}{2} & \frac{1}{2} \end{pmatrix}$
3. Soit $B = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 1 \end{pmatrix}$ et $C = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$. Déterminer B^{-1} et C^{-1} .
4. Vérifier que $B = \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix}$ et $E = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{-1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}$ sont orthonormales.
5. Soit $x = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$ et $y = \begin{pmatrix} 3 \\ 4 \end{pmatrix}$. Calculer $\|x\|$, $\|y\|$, $(x, y) = x'y$, xy' , et l'angle entre les vecteurs x et y .
6. Soit

$$A = \begin{pmatrix} 4 & 1 & -8 & 4 \\ 2 & 5 & -4 & 20 \\ -1 & 3 & 2 & 12 \\ 53 & -2 & -6 & -8 \end{pmatrix}$$

Calculer son rang et sa trace. Peut-on calculer A^{-1} ?

7. (*) Soit $A = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 2\sqrt{3} \\ 0 & 2\sqrt{3} & 3 \end{pmatrix}$
 - (a) Calculer ses valeurs propres λ_α et ses vecteurs propres normés u_α .
 - (b) Vérifier que la matrice U formée des vecteurs propres normés de A est orthogonale.
 - (c) Vérifier la validité de l'identité $A = \sum_\alpha \lambda_\alpha u_\alpha u'_\alpha$, qui n'est autre que l'écriture vecteur propre par vecteur propre de l'identité matricielle $A = U\Lambda U'$.
8. (*) Soit C une matrice orthogonale. Montrer que $\det(C) = 1$ ou bien $\det(C) = -1$. (Indications : utiliser les relations $CC' = I$, $\det(AB) = \det(A)\det(B)$ et $\det(A') = \det(A)$.)
9. Montrer algébriquement que la matrice de projection $P := X(X'X)^{-1}X'$ est symétrique et idempotente.
10. (*) Soit u un vecteur colonne de norme 1. Montrer que $P := uu'$ est la matrice $(n \times n)$ de projection sur la droite $M(u)$ engendrée par u .

Exercice 1.2

Soient les matrices

$$A = \begin{pmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \end{pmatrix} \quad B = \begin{pmatrix} 0 & 0 \\ 1 & 1 \end{pmatrix} \quad C = \begin{pmatrix} -1 & 2 & 0 \\ 0 & -1 & 2 \\ 2 & 0 & -1 \end{pmatrix} \quad \text{et} \quad D = \begin{pmatrix} 1 & -2 \\ -3 & 4 \end{pmatrix}$$

1. effectuer AB , $B'A$, AC , BC' , CA' , BD et DB lorsque c'est possible.
2. sans calculer leur déterminant, déterminer quelles matrices sont inversibles.
3. calculer l'inverse des matrices lorsque c'est possible.

Exercice 1.3

Simplifier l'expression suivante : $(X'Y'ZX)'(YX)^{-1}$.

Exercice 1.4 1. parmi les matrices suivantes, lesquelles sont

- symétriques ?
- orthogonales ?
- des matrices de projection ?

$$E = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} & 0 \\ -1/\sqrt{2} & 1/\sqrt{2} & 0 \\ 0 & 0 & 1 \end{pmatrix}, F = \begin{pmatrix} 0 & 0 & 1 \\ 0 & 2 & 0 \\ 3 & 0 & 0 \end{pmatrix}, G = \begin{pmatrix} 2/3 & -2/3 & 1/3 \\ 1/3 & 2/3 & 2/3 \\ 2/3 & 1/3 & -2/3 \end{pmatrix},$$

$$H = \begin{pmatrix} 3/4 & -1/4 & -1/4 & -1/4 \\ -1/4 & 3/4 & -1/4 & -1/4 \\ -1/4 & -1/4 & 3/4 & -1/4 \\ -1/4 & -1/4 & -1/4 & 3/4 \end{pmatrix}, I = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

2. effectuer le produit scalaire de toutes les paires de colonnes des matrices orthogonales. Qu'avez-vous vérifié ?

Exercice 1.5

On considère la matrice $U = \begin{pmatrix} a & c \\ b & d \end{pmatrix}$.

1. quelles sont les conditions sur a, b, c et d pour que U soit orthogonale ?
2. l'un des coefficients peut-il être supérieur à 1 ? Si non, pourquoi ?
3. pouvez-vous déterminer la valeur de b, c et d si l'on donne $a = \frac{1}{\sqrt{5}}$?

Exercice 1.6

Les affirmations suivantes (à propos de matrices carrées A et B de type $(n \times n)$) sont-elles **vraies** ou **fausses** ? Si l'affirmation est vraie, efforcez-vous de la démontrer. Si l'affirmation est fausse, donnez un contre-exemple.

1. Si A et B sont diagonales, la matrice AB l'est également.
2. Si A et B sont inversibles, la matrice AB l'est également.
3. Si A et B sont orthogonales, la matrice AB l'est également.
4. Si A et B sont symétriques, la matrice AB l'est également.
5. [optionnel car difficile] Si A et B sont des matrices de projection, la matrice AB l'est également.

Exercice 1.7

En effectuant une rotation d'angle β autour de l'origine (dans le sens trigonométrique, i.e. inverse des aiguilles d'une montre), on peut démontrer que le vecteur $x := \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ se transforme en un vecteur donné par $y = Rx$,

avec $R = \begin{pmatrix} \cos \beta & \sin \beta \\ -\sin \beta & \cos \beta \end{pmatrix}$

1. Que valent les composantes $\begin{pmatrix} y_1 \\ y_2 \end{pmatrix}$ de y ?
2. Montrer que la norme de y est égale à celle de x (comme il se doit pour une rotation ; une telle transformation conservant les longueurs est dite *isométrique*). Rappel : $\cos^2 \beta + \sin^2 \beta = 1$.
3. Montrer que R est une matrice orthogonale.

Exercice 1.8

Soit x un vecteur $(n \times 1)$, et soit $M := \{v \mid v = ax \text{ avec } a \in \mathbb{R}\}$ l'hyperplan engendré par x (ici la droite passant par l'origine de direction x).

1. montrer que la projection y^* sur M d'un vecteur y quelconque (de type $(n \times 1)$) est donnée par $y^* = \frac{(x,y)}{\|x\|^2} x$
2. en particulier, montrer que $y^* = y$ si $y \parallel x$ (où “ $\parallel$ ” dénote la relation “est parallèle à”).

Corrigé de la série 1

Exercice 1.1 1. $A + C = \begin{pmatrix} 1 & 3 \\ 2 & 7 \end{pmatrix}$ $AC = \begin{pmatrix} -2 & 7 \\ -4 & 15 \end{pmatrix}$ et $CA = \begin{pmatrix} 3 & 4 \\ 8 & 10 \end{pmatrix}$. La matrice AB n'est pas définie.

$$BA = \begin{pmatrix} 1 & 2 \\ 11 & 16 \\ 19 & 28 \end{pmatrix}, A' = \begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix}, B' = \begin{pmatrix} 1 & 2 & 4 \\ 0 & 3 & 5 \end{pmatrix}, (BA') = A'B' = \begin{pmatrix} 1 & 11 & 19 \\ 2 & 16 & 28 \end{pmatrix}.$$

$$2. AA^{-1} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = I = \text{matrice identité.}$$

$$3. B^{-1} = \begin{pmatrix} \frac{1}{2} & 0 & 0 \\ 0 & \frac{1}{3} & 0 \\ 0 & 0 & 1 \end{pmatrix} \text{ et } C^{-1} = \begin{pmatrix} -2 & 1 \\ \frac{3}{2} & \frac{-1}{2} \end{pmatrix}$$

$$4. BB' = EE' = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I.$$

$$5. \|x\| = \sqrt{(x, x)} = \sqrt{1^2 + (-1)^2} = \sqrt{2} \text{ et } \|y\| = \sqrt{(y, y)} = \sqrt{3^2 + 4^2} = 5.$$

$$(x, y) = 1.3 + (-1).4 = -1 \text{ et } xy' = \begin{pmatrix} 3 & 4 \\ -3 & -4 \end{pmatrix}.$$

Soit $\alpha = \angle(x, y)$. Alors $\cos \alpha = \frac{(x, y)}{\|x\|\|y\|} = \frac{-1}{5\sqrt{2}} \cong -0.14$. A l'aide d'une calculatrice, on trouve $\alpha = 98.13$ degrés.

6. Soit A_2 et A_4 les vecteurs colonne 2 et 4 de A . On constate que $A_2 = \frac{1}{4}A_4$. Les trois autres colonnes sont linéairement indépendantes : on peut le vérifier en essayant sans succès de résoudre $\alpha A_1 + \beta A_2 = A_3$. Par conséquent $\text{rg}(A) = 3$. Aussi, $\text{tr}(A) = 4 + 5 + 2 - 8 = 3$. Comme $\text{rg}(A) = 3 < 4$, on déduit de (1.40) que A n'est pas inversible.

7. (a) En posant $Ax = \lambda x$, on obtient le système d'équations suivant :

$$\begin{aligned} x_1 &= \lambda x_1 \\ 2x_2 + 2\sqrt{3}x_3 &= \lambda x_2 \\ 2\sqrt{3}x_2 + 3x_3 &= \lambda x_3 \end{aligned}$$

Résolution (un cheminement parmi d'autres possibilités) :

i. Posons $x_1 \neq 0$. Par la première équation du système, on obtient $\lambda = 1$. Les deuxième et troisième équations donnent $x_2 = x_3 = 0$. x_1 est défini à un facteur multiplicatif près (rappel : tout multiple d'un vecteur propre est aussi un vecteur propre avec la même valeur propre). On peut donc poser

$$x_1 = 1. \text{ En définitive, } u_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \text{ est un vecteur propre normé de } A \text{ pour la valeur propre}$$

$$\lambda_1 = 1.$$

ii. Posons $x_1 = 0$. Par la même remarque qu'en i), on peut poser $x_2 = 1$. En éliminant x_3 , on trouve $\lambda^2 - 5\lambda - 6 = (\lambda - 6)(\lambda + 1) = 0$, dont les solutions sont $\lambda_2 = 6$ et $\lambda_3 = -1$, et les vecteurs

$$\text{propres associés (non normés) sont } v_2 = \begin{pmatrix} 0 \\ 1 \\ \frac{2}{\sqrt{3}} \end{pmatrix} \text{ et } v_3 = \begin{pmatrix} 0 \\ 1 \\ -\frac{\sqrt{3}}{2} \end{pmatrix}, \text{ soit } u_2 = \begin{pmatrix} 0 \\ \sqrt{\frac{3}{7}} \\ \sqrt{\frac{4}{7}} \end{pmatrix} \text{ et}$$

$$u_3 = \begin{pmatrix} 0 \\ \sqrt{\frac{4}{7}} \\ -\sqrt{\frac{3}{7}} \end{pmatrix} \text{ après normalisation. Par construction, } U := (u_1 | u_2 | u_3) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & \sqrt{\frac{3}{7}} & \sqrt{\frac{4}{7}} \\ 0 & \sqrt{\frac{4}{7}} & -\sqrt{\frac{3}{7}} \end{pmatrix}.$$

(b) On peut démontrer que U est orthogonale en vérifiant qu'elle est composée de trois vecteurs colonne normés perpendiculaires entre eux. On peut aussi vérifier directement que $UU' = I$.

$$(c) \quad u_1 u'_1 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \quad u_2 u'_2 = \begin{pmatrix} 0 & 0 & 0 \\ 0 & \frac{3}{7} & \frac{2}{7}\sqrt{3} \\ 0 & \frac{2}{7}\sqrt{3} & \frac{4}{7} \end{pmatrix} \quad u_3 u'_3 = \begin{pmatrix} 0 & 0 & 0 \\ 0 & \frac{4}{7} & -\frac{2}{7}\sqrt{3} \\ 0 & -\frac{2}{7}\sqrt{3} & \frac{3}{7} \end{pmatrix}$$

$$\text{donc } \sum_{\alpha=1}^3 \lambda_{\alpha} u_{\alpha} u'_{\alpha} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 2\sqrt{3} \\ 0 & 2\sqrt{3} & 3 \end{pmatrix} = A$$

8. $CC' = I \Rightarrow \det(CC') = \det(C) \det(C') = \det(I) = 1$. Comme $\det(C') = \det(C)$, alors $(\det(C))^2 = 1$ et donc $\det(C) = 1$ ou bien $\det(C) = -1$.

9. Si $P = X(X'X)^{-1}X'$, alors

$$P' = (X(X'X)^{-1}X')' = X''(X'X)^{-1'}X' = X(X'X)^{-1}X' = X(X'X)^{-1}X' = P \quad (1.47)$$

donc P est symétrique (on a utilisé $(ABC)' = C'B'A'$, $(AB)' = B'A'$, $A'' = A$ et $A'^{-1} = A^{-1'}$). De même,

$$P^2 = (X(X'X)^{-1}X')(X(X'X)^{-1}X') = X(X'X)^{-1}(X'X)(X'X)^{-1}X' = X(X'X)^{-1}X' = P \quad (1.48)$$

donc P est idempotente (on a utilisé $(AB)(CD) = A(BC)D$ et $A^{-1}A = I$).

10. $P := uu'$ est symétrique (car $P' = (uu')' = u'u' = uu' = P$) et idempotente (car $P^2 = uu'uu' = u(\|u\|^2)u' = uu'$, en utilisant le fait que u est de norme $\|u\| = 1$) : c'est donc une matrice de projection. Comme $Pu = uu'u = u(\|u\|^2) = u$, u reste invariant par projection : P est donc la projection sur la droite $M(u)$ engendrée par u .

Exercice 1.2

$$1. \quad B'A = \begin{pmatrix} 2 & 4 & 6 \\ 2 & 4 & 6 \end{pmatrix}, \quad AC = \begin{pmatrix} 9 & -1 & 1 \\ 10 & 0 & 2 \end{pmatrix}, \quad CA' = \begin{pmatrix} 5 & 6 \\ 7 & 8 \\ -3 & -2 \end{pmatrix},$$

$$BD = \begin{pmatrix} 0 & 0 \\ -2 & 2 \end{pmatrix}, \quad DB = \begin{pmatrix} -2 & -2 \\ 4 & 4 \end{pmatrix}.$$

2. A n'est pas inversible, car elle n'est pas carrée. B n'est pas inversible, car elle est de rang 1. C et D sont inversibles car elles sont respectivement de rang 3 et 2.

$$3. \quad C^{-1} = \frac{1}{7} \begin{pmatrix} 1 & 2 & 4 \\ 4 & 1 & 2 \\ 2 & 4 & 1 \end{pmatrix} \quad (\text{vous n'êtes pas censé savoir calculer cet inverse, mais vous pouvez vérifier que } CC^{-1} = C^{-1}C = I),$$

$$D^{-1} = \begin{pmatrix} -2 & -1 \\ -3/2 & -1/2 \end{pmatrix}.$$

Exercice 1.3

$$(X'Y'ZX)'(YX)^{-1} = X'Z'$$

Exercice 1.4

1. E est non symétrique, orthogonale et n'est pas une matrice de projection. F n'est ni symétrique, ni orthogonale, ni une matrice de projection. G est non symétrique, orthogonale, n'est pas une matrice de projection. H est symétrique, non orthogonale, de projection. I est symétrique, orthogonale, de projection.
2. Si v_i et v_j sont deux colonnes d'une matrice orthogonale, (v_i, v_j) vaut 1 si $i = j$, et sinon. En d'autres termes, ces colonnes sont orthogonales entre elles, et leur norme est égale à 1 (elles forment un système de vecteurs orthonormés).

Exercice 1.5

1. En posant $U'U = I$, on obtient $a^2 + b^2 = 1$ (la première colonne est normée), $ac + bd = 0$ (les deux colonnes sont orthogonales) et $c^2 + d^2 = 1$ (la deuxième colonne est normée).

- Aucun coefficient ne peut être supérieur à 1, car ceci entraînerait que la norme de la colonne correspondante serait supérieure à 1, ce qui est impossible pour une matrice orthogonale. L'impossibilité peut aussi être montrée à l'aide des conditions précédentes.
- On obtient 4 solutions :

$$\frac{1}{\sqrt{5}} \begin{pmatrix} 1 & 2 \\ -2 & 1 \end{pmatrix}, \frac{1}{\sqrt{5}} \begin{pmatrix} 1 & -2 \\ -2 & -1 \end{pmatrix}, \frac{1}{\sqrt{5}} \begin{pmatrix} 1 & -2 \\ 2 & 1 \end{pmatrix}, \text{ et } \frac{1}{\sqrt{5}} \begin{pmatrix} 1 & 2 \\ 2 & -1 \end{pmatrix}$$

Exercice 1.6

- Vrai** : si A est la matrice diagonale dont la j -ème composante (sur la diagonale) est a_j et si B est la matrice diagonale dont la j -ème composante est b_j , alors AB est la matrice diagonale dont la j -ème composante est $a_j b_j$.
- Vrai** : Si A^{-1} et B^{-1} existent, l'inverse de AB existe aussi ; il est donné par $(AB)^{-1} = B^{-1}A^{-1}$.
- Vrai** : si $A' = A^{-1}$ et $B' = B^{-1}$ alors $(AB)' = B'A' = B^{-1}A^{-1} = (AB)^{-1}$, i.e. AB est orthogonale.
- Faux** en général, comme le montre le contre-exemple $A = \begin{pmatrix} 1 & 2 \\ 2 & 3 \end{pmatrix} = A'$, $B = \begin{pmatrix} -1 & 0 \\ 0 & 1 \end{pmatrix} = B'$ et $AB = \begin{pmatrix} -1 & 2 \\ -2 & 3 \end{pmatrix} \neq (AB)'$
- Faux** en général : une matrice P est une matrice de projection ssi $P^2 = P$ (idempotence) et $P' = P$ (symétrie). Tel est bien le cas de $P_1 = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$ (projection sur l'axe $y = 0$ dans le repère $0xy$) et de $P_2 = \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}$ (projection sur l'axe $x = y$ dans le repère $0xy$) ; on trouve cependant que $P_1 P_2 = \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ 0 & 0 \end{pmatrix}$ n'est pas symétrique (et non idempotente également), et donc ne représente pas une matrice de projection.

Exercice 1.7

- $y_1 = \cos \beta x_1 + \sin \beta x_2$ et $y_2 = -\sin \beta x_1 + \cos \beta x_2$.
- $\|y\|^2 = y_1^2 + y_2^2 = (\cos \beta x_1 + \sin \beta x_2)^2 + (-\sin \beta x_1 + \cos \beta x_2)^2 = (\cos^2 \beta + \sin^2 \beta)(x_1^2 + x_2^2) = x_1^2 + x_2^2 = \|x\|^2$.
- $R R' = \begin{pmatrix} \cos \beta & \sin \beta \\ -\sin \beta & \cos \beta \end{pmatrix} \begin{pmatrix} \cos \beta & -\sin \beta \\ \sin \beta & \cos \beta \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I$

Exercice 1.8

- soit P la matrice de projection sur M . On a $P = X(X'X)^{-1}X'$ avec $X = x$ dans ce cas particulier. On a $X'X = x'x = (x, x) = \|x\|^2$, et donc $(X'X)^{-1} = \|x\|^{-2}$, qui est un scalaire dans ce cas particulier (car l'hyperplan M est engendré par un seul vecteur x). Donc $P = \|x\|^{-2}xx'$, d'où $y^* = Py = \|x\|^{-2}xx'y = \frac{(x, y)}{\|x\|^2} x$ (puisque $(x, y) = x'y$).
- $y \setminus x$ ssi $y = b x$ pour un certain $b \in \mathbb{R}$. Dans ce cas, $(x, y) = b(x, x) = b \|x\|^2$ et l'on a (en fonction du résultat précédent) que $y^* = \frac{b \|x\|^2}{\|x\|^2} x = b x = y$, comme il se doit : dire que $y \setminus x$ revient à dire que $y \in M$ et donc que $y^* = Py = y$.

Chapitre 2

Statistique multivariée et géométrie

2.1 La matrice des données multivariées : l'espace des individus et des variables

Les données `huit_notes` de la figure 2.1 constituent les notes de 50 élèves sur 8 branches : elle constituent une matrice $X = (x_{ij})$ de type 50×8 . Un fichier de données se présente (ou devrait se présenter) toujours sous la forme d'un *tableau comportant n lignes et p colonnes*. Chaque ligne représente un *individu* (personnes, communes, textes, etc...), et chaque colonne une *variable*. La composante x_{ij} située à l'intersection de la i -ème ligne et de la j -ème colonne représente le *score obtenu par l'individu i à la variable j* . Dans ce chapitre, on considère des scores numériques, associés à des variables X_j quantitatives.

La matrice des $(n \times p)$ données peut se décomposer en p colonnes, chaque colonne étant un vecteur x_j de type $(n \times 1)$. La représentation dans l'**espace des variables** consiste à placer p points dans un espace à n dimensions, chaque point représentant les scores $(x_{1j}, x_{2j}, \dots, x_{nj})$ associés à une variable x_j ($j = 1, \dots, p$) et chaque axe un individu.

La même matrice peut aussi se décomposer en n lignes, chaque ligne étant un vecteur de type $(1 \times p)$ représentant le profil d'un individu. La représentation dans l'**espace des individus** consiste à placer n points dans un espace à p dimensions, chaque point représentant le *profil* $(x_{i1}, x_{i2}, \dots, x_{ip})$ d'un individu i ($i = 1, \dots, n$) et chaque axe une variable.

Par exemple, la régression simple $y = y^* + e$ (où $y^* = ax + b = ax + b\mathbf{1}$ est la variable prédite par x , x et y sont les variables observées, a et b les coefficients de régression, $\mathbf{1}$ le vecteur unité et $e = y - y^*$ le vecteur des résidus) est généralement représentée dans l'espace des individus par le diagramme de dispersion de la figure 2.2 (gauche). Lorsque le nombre de prédicteurs augmente (régression multiple), il n'est plus possible de procéder ainsi et l'on choisira alors la représentation dans l'espace des variables (figure 2.2, droite).

2.2 Correspondances entre géométrie et statistique

2.2.1 Moyenne

Parmi les indicateurs de tendance centrale, la moyenne $\bar{x} := \frac{1}{n} \sum_i x_i$ est celui qui minimise le carré des résidus : si l'on devait approximer toute la série numérique $x_1, \dots, x_n$ par un seul nombre a , il faudrait prendre $a = \bar{x}$, au vu de la propriété

$$\sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + (n-1)(\bar{x} - a)^2 \quad (2.1)$$

français	géographie	physique	chimie	histoire	mathématiques	philosophie	allemand
7	6	5	6	2	7	9	2
5	5	3	7	4	4	6	6
5	7	8	9	5	6	5	9
5	4	5	3	5	5	5	6
6	5	3	7	2	6	4	4
7	8	4	5	5	7	8	6
4	5	3	5	1	5	4	3
5	5	6	6	4	7	5	4
3	6	3	3	2	4	5	2
7	6	5	7	4	7	6	4
5	7	5	7	5	8	10	4
8	7	7	9	7	10	8	7
9	8	4	8	7	7	9	7
5	7	4	6	8	6	5	8
4	8	10	10	10	10	6	5
3	4	6	5	1	5	4	3
3	7	4	4	4	7	5	3
4	4	7	6	3	4	5	7
9	5	5	8	10	7	6	7
6	3	3	3	3	8	6	2
4	6	5	5	7	4	5	6
7	4	4	4	1	8	8	2
6	7	4	6	5	7	5	6
4	6	6	7	6	7	7	5
6	7	7	6	5	9	8	7
8	5	6	6	5	8	5	9
5	8	4	6	4	8	9	5
5	4	5	6	5	4	7	4
4	3	6	6	7	5	8	3
5	2	4	6	3	5	9	4
5	6	7	7	5	8	7	5
3	2	2	3	1	6	4	3
7	5	7	7	10	7	5	8
5	9	6	8	4	8	5	8
3	2	3	4	3	6	5	3
6	7	4	7	6	5	7	8
6	5	3	4	4	4	8	1
5	8	5	6	7	7	4	7
5	10	8	9	7	10	8	9
6	7	7	7	4	9	7	8
5	7	3	3	7	4	7	2
3	5	2	2	2	4	4	3
7	5	5	3	2	6	8	1
3	6	5	5	3	7	5	5
8	6	7	7	4	9	4	7
4	6	4	7	2	9	6	1
4	6	3	5	3	6	5	5
8	6	6	7	6	8	7	7
6	10	4	8	8	9	7	7
8	8	7	8	8	7	8	8

FIGURE 2.1 – Données `huit.notes` : un fichier de données de n individus sur p variables se présente sous la forme d'une matrice $X = (x_{ij})$ de type $(n \times p)$, où x_{ij} est le score de l'individu i sur la variable j .




FIGURE 2.2 – Représentation de la régression simple dans l’espace des individus (gauche) et dans l’espace des variables (droite)




FIGURE 2.3 – La moyenne $x^* = Px = \bar{x}\mathbf{1}$ est le meilleur indicateur de tendance centrale au sens de la projection sur la droite des constantes. Le vecteur centré $x^c := x - \bar{x}\mathbf{1}$, de composantes $x_i^c = x_i - \bar{x}$, est le résidu e de x par rapport à la projection.

qui montre que le terme de gauche est minimal pour $a = \bar{x}$.

La propriété algébrique (2.1) (dite *principe de Huygens*) s’énonce aussi géométriquement (figure 2.3) : soit x le vecteur des n données et soit $\mathbf{1}$ le vecteur unité à n composantes, dont les combinaisons linéaires $a\mathbf{1}$ (avec $a \in \mathbb{R}$) constituent la *droite des constantes* $M(\mathbf{1})$. Alors le projecteur P sur $M(\mathbf{1})$ est donné par $P = \mathbf{1}(\mathbf{1}'\mathbf{1})^{-1}\mathbf{1}' = \frac{1}{n}\mathbf{1}\mathbf{1}'$. La projection est donnée par le vecteur moyenne constant $x^* := Px = \bar{x}\mathbf{1}$, et le résidu $e = x - x^*$ est le vecteur des *valeurs centrées* $x_i^c = x_i - \bar{x}$.

Remarque importante : on se limite ici, suivant la tradition, aux moyennes *uniformes*, où le poids de chacun des n individus est identique et égal à $1/n$. Très souvent, cependant, le poids des individus n’est pas identique (ex : ensemble de n villes dont le poids relatif est proportionnel à leur population ; ensemble de n textes dont le poids relatif est proportionnel à leur taille ; etc.), ce qui nécessite l’usage d’un *formalisme pondéré*, où la moyenne d’une variable x (dite de densité, i.e. caractérisant l’individu indépendamment de sa taille) est alors $\bar{x} = \sum_{i=1}^n f_i x_i = f'x$, où f est le vecteur des *poids relatifs* des individus, obéissant à $f_i > 0$ et $\sum_{i=1}^n f_i = 1$, et généralisant le cas de la pondération uniforme, laquelle s’obtient comme le cas particulier $f_i = 1/n$. Le cas pondéré général sera abordé plus loin, en particulier au chapitre 6.

2.2.2 Variance, covariance et corrélation

Les scores (x_i, y_i) des deux variables x et y mesurées sur un échantillon de n individus constituent deux vecteurs colonne x et y . Centrer les scores revient à définir les nouveaux vecteurs $x^c = x - \bar{x}\mathbf{1}$ et $y^c = y - \bar{y}\mathbf{1}$.




FIGURE 2.4 – Le produit scalaire x^c, y^c entre les variables centrées x^c et y^c s'exprime comme $(x^c, y^c) = \|x^c\| \|y^c\| \cos \alpha$. La quantité $\|x^c\| \cos \alpha$ est la longueur de la projection de x^c sur y^c , et $\|y^c\| \cos \alpha$ est la longueur de la projection de y^c sur x^c .

La covariance empirique s'écrit :

$$\text{cov}(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n} \sum_{i=1}^n x_i^c y_i^c = \frac{1}{n} (X^c, Y^c) \quad (2.2)$$

A un facteur $\frac{1}{n}$ près, la *covariance* entre deux variables est donc le *produit scalaire* entre les vecteurs centrés correspondants, dans l'espace des individus. On a d'autre part (figure 2.4) :

$$(x^c, y^c) = \|x^c\| \|y^c\| \cos \alpha \quad (2.3)$$

où α est l'angle entre les vecteurs x^c et y^c , et $\|x^c\|$ dénote la norme de x^c . De même, la variance empirique s'écrit :


$$\text{var}(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n (x_i^c)^2 = \frac{1}{n} \|x^c\|^2 \quad (2.4)$$

A un facteur $\frac{1}{n}$ près, la *variance* d'une variable est le *carré de la norme* du vecteur centré correspondant (et son écart-type sa norme). Finalement, la corrélation s'écrit :

$$r_{xy} = \text{corr}(x, y) = \frac{\text{cov}(x, y)}{\sqrt{\text{var}(x)} \sqrt{\text{var}(y)}} = \frac{\frac{1}{n} \|x^c\| \|y^c\| \cos \alpha}{\frac{1}{n} \|x^c\| \|y^c\|} = \cos \alpha \quad (2.5)$$

La *corrélation* entre deux variables est le *cosinus de l'angle* entre les deux vecteurs centrés correspondants (figure 2.4). Avec cette interprétation, il est alors évident que $-1 \leq r_{xy} \leq 1$; de même, $r_{xy} = 1$ ssi $\alpha = 0$, ce qui signifie que x^c et y^c sont proportionnels, i.e. $y^c = ax^c$ (avec $a > 0$), ou encore $y = ax + b$ avec $b = \bar{y} - a\bar{x}$: on retrouve le résultat qu'un nuage de points possède une corrélation de 1 ssi tous les points (x_i, y_i) sont alignés selon une droite $y = ax + b$ (avec $a > 0$). Finalement, les deux variables sont *décorrélées* ($r_{xy} = 0$) ssi $\alpha = 90^\circ$, i.e. ssi x^c et y^c sont perpendiculaires ou orthogonaux.

En conclusion, les opérations usuelles sur les variables quantitatives, telles que la détermination de leur variances, covariances ou corrélations peuvent être traduites en opérations géométriques sur des vecteurs correspondants dans l'espace des variables. Cette circonstance permet d'exprimer un problème statistique en termes géométriques, d'y trouver une solution géométrique, et de la retranscrire en termes statistiques. Le détour qui en résulte n'est qu'apparent, au vu de l'excellence des capacités de visualisation (et de la médiocrité des talents algébriques...) au sein de notre espèce.



Au facteur $\frac{1}{n}$ près, les correspondances principales entre statistique et géométrie sont :

Statistique (variables x, y)	Géométrie (vecteurs x, y)
variable x à n scores	vecteur x à n composantes
vecteur centré $x^c = x - \bar{x}$	résidu de la projection de x sur la droite des constantes
variance de x	carré de la norme de x^c
écart-type de x	norme de x^c
standardiser x	normer x^c
covariance de x et y	produit scalaire de x^c et y^c
corrélation de x et y	cosinus de l'angle entre x^c et y^c
$r_{xy} = \pm 1$	x^c et y^c parallèles ($y = ax + b$)
$r_{xy} = 0$	x^c et y^c perpendiculaires

2.2.3 Matrices de variance-covariance et de corrélation

Notons par $s_{jk} := \text{cov}(x_j, x_k) = \frac{1}{n}(x_j^c, x_k^c)$ la covariance entre la j -ème et la k -ème variable. Par construction, $s_{jk} = s_{kj}$ et $s_{jj} = \text{var}(x_j)$. Ainsi, en présence de p variables, la matrice $S = (s_{jk})$ est de type $(p \times p)$, sa diagonale contient les variances et ses composantes non-diagonales les covariances entre variables distinctes. On l'appelle matrice de *variance-covariance* ou simplement matrice des covariances ; elle est souvent désignée par $\Sigma = (\sigma_{jk})$ au lieu de $S = (s_{jk})$, ou encore par la notation hybride $\Sigma = (s_{jk})$ ¹.

De même, on note $R = (r_{jk})$ la matrice $(p \times p)$ des corrélations, définie par

$$r_{ij} = \text{corr}(x_j, x_k) = \frac{\text{cov}(x_j, x_k)}{\sqrt{\text{var}(x_j)\text{var}(x_k)}} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}} = \frac{s_{jk}}{s_j s_k} \quad (2.6)$$

où $s_j := \sqrt{s_{jj}}$ désigne l'écart type de la variable x_j . La matrice R est symétrique, et toutes ses valeurs diagonales valent 1.

Soit $x_j^s := (x_j - \bar{x}_j)/s_j$ la variable standardisée obtenue à partir de la variable brute x_j . Par construction, $\bar{x}_j^s = 0$ et $\text{var}(x_j^s) = 1$. On peut également vérifier que $\text{cov}(x_j^s, x_k^s) = \text{corr}(x_j^s, x_k^s) = \text{corr}(x_j, x_k) = r_{jk}$.

2.2.4 Un exemple

Au lieu de manipuler des vecteurs colonne $x_1, \dots, x_p$, dans l'espace des variables, il est souvent plus direct et avantageux de manipuler directement l'entièreté de la matrice des données $X = (x_1, \dots, x_p)$ de taille $n \times p$, comme on l'illustre sur l'exemple suivant² : $n = 109$ étudiant(e)s en psychologie de l'Université de Lausanne ont répondu à un questionnaire de motivation, indiquant (sur une échelle de 1 = "pas du tout d'accord" à 7 = "tout à fait d'accord") leur degré d'accord sur certains énoncés, en réponse à la question "**pourquoi faites-vous des études de psychologie ?**". Certains des énoncés (retenus ici) étaient :

- x_1 "Parce qu'il est difficile de trouver un emploi avec un baccalauréat seulement en poche."
- x_2 "Parce que j'éprouve du plaisir et de la satisfaction à apprendre de nouvelles choses."
- x_3 "Pour me prouver à moi-même que je suis capable de terminer ce que j'ai entrepris."
- x_4 "Pour les moments intenses que je vis lorsque je suis en train de communiquer mes propres idées aux autres."
- x_5 "Honnêtement, je ne le sais pas ; j'ai vraiment l'impression de perdre mon temps à l'université."
- x_6 "Pour le plaisir que je ressens à me surpasser dans mes études."
- x_7 "Parce que le psychologue est souvent appelé à aider autrui."

Le tableau de données (109×7) se présente sous la forme :

1. ici, l'usage de l'alphabet grec n'indique pas le caractère théorique d'une quantité ; on pourra utiliser Σ^{theo} si nécessaire.
 2. Données `motiv_psycho` fournies par le Dr. J.-P. Antonietti, SSP-UNIL

$$X = \begin{pmatrix} x_{11} & x_{12} & x_{13} & x_{14} & x_{15} & x_{16} & x_{17} \\ x_{21} & x_{22} & x_{23} & x_{24} & x_{25} & x_{26} & x_{27} \\ x_{31} & x_{32} & x_{33} & x_{34} & x_{35} & x_{36} & x_{37} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ x_{109;1} & x_{109;2} & x_{109;3} & x_{109;4} & x_{109;5} & x_{109;6} & x_{109;7} \end{pmatrix} = \begin{pmatrix} 2 & 7 & 1 & 5 & 1 & 5 & 7 \\ 1 & 5 & 2 & 2 & 1 & 1 & 4 \\ 1 & 7 & 7 & 6 & 1 & 4 & 6 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 1 & 6 & 5 & 4 & 1 & 4 & 6 \end{pmatrix} \quad (2.7)$$

La matrice X^c des données *centrées* s'obtient en soustrayant à chaque score le score moyen (de colonne) qui est respectivement de $\bar{x}_1 = 1.90$, $\bar{x}_2 = 5.87$, $\bar{x}_3 = 3.50$, $\bar{x}_4 = 3.26$, $\bar{x}_5 = 1.39$, $\bar{x}_6 = 3.34$, $\bar{x}_7 = 5.64$:

$$X^c = \begin{pmatrix} 0.10 & 1.13 & -2.50 & 1.74 & -0.39 & 1.66 & 1.36 \\ -0.90 & -0.87 & -0.50 & -1.26 & -0.39 & -2.34 & -1.64 \\ -0.90 & 1.13 & 3.50 & 2.74 & -0.39 & 0.66 & 0.34 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ -0.90 & 0.13 & 1.50 & 0.74 & -0.39 & 0.66 & 0.34 \end{pmatrix} \quad (2.8)$$

Si l'on *réduit* encore, i.e. divise les scores centrés par l'écart-type correspondant (à savoir : $s_1 = 1.47$, $s_2 = 0.99$, $s_3 = 1.92$, $s_4 = 1.65$, $s_5 = 0.84$, $s_6 = 1.65$, $s_7 = 1.44$), on obtient la matrice X^s des scores centrés-réduits ou *standardisés* :

$$X^s = \begin{pmatrix} 0.07 & 1.13 & -1.30 & 1.06 & -0.46 & 1.01 & 0.94 \\ -0.61 & -0.88 & -0.78 & -0.77 & -0.46 & -1.42 & -1.14 \\ -0.61 & 1.14 & 1.83 & 1.67 & -0.46 & 0.40 & 0.25 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ -0.61 & 0.13 & 0.78 & 0.45 & -0.46 & 0.40 & 0.25 \end{pmatrix} \quad (2.9)$$

Le produit $(X^c)'X^c$ donne une matrice de taille $(p \times p)$; on peut montrer (par exemple à l'aide de la correspondance vectorielle établie à la section précédente) que cette matrice symétrique, après division par n , est la matrice de *variance-covariance* $\Sigma := \frac{1}{n}(X^c)'X^c$. Cette dernière contient les covariances ordinaires $s_{jk} = \text{cov}(x_j, x_k) = s_{kj}$ hors de la diagonale principale, et les variances $s_{jj} = \text{cov}(x_j, x_j) = \text{var}(x_j) =: s_j^2$ dans la diagonale principale :

$$\Sigma = \frac{1}{n}(X^c)'X^c = \begin{pmatrix} 2.18 & -0.05 & 0.18 & 0.01 & 0.21 & 0.42 & -0.05 \\ -0.05 & 0.99 & 0.47 & 0.27 & -0.03 & 0.54 & -0.08 \\ 0.18 & 0.47 & 3.69 & 1.14 & 0.33 & 1.25 & 0.10 \\ 0.01 & 0.27 & 1.14 & 2.72 & -0.15 & 0.95 & 0.39 \\ 0.21 & -0.03 & 0.33 & -0.15 & 0.59 & 0.05 & -0.21 \\ 0.42 & 0.54 & 1.25 & 0.95 & 0.05 & 2.72 & -0.15 \\ -0.05 & -0.08 & 0.10 & 0.39 & -0.21 & -0.15 & 2.17 \end{pmatrix} \quad (2.10)$$

Le même traitement, effectué à partir de la matrice des scores standardisés X^s , conduit à la matrice symétrique R de corrélation, de taille $(p \times p)$, de composantes $r_{jk} = \text{corr}(x_j, x_k)$, avec des 1 dans la diagonale principale :

$$R = \frac{1}{n}(X^s)'X^s = \begin{pmatrix} 1.00 & -0.03 & 0.06 & 0.007 & 0.17 & 0.17 & -0.02 \\ -0.03 & 1.00 & 0.25 & 0.16 & -0.03 & 0.33 & -0.05 \\ 0.06 & 0.25 & 1.00 & 0.36 & 0.23 & 0.40 & 0.04 \\ 0.007 & 0.16 & 0.36 & 1.00 & -0.11 & 0.35 & 0.18 \\ 0.17 & -0.03 & 0.23 & -0.11 & 1.00 & 0.04 & -0.08 \\ 0.17 & 0.33 & 0.40 & 0.35 & 0.04 & 1.00 & -0.06 \\ -0.02 & -0.05 & 0.04 & 0.16 & -0.08 & -0.06 & 1.00 \end{pmatrix} \quad (2.11)$$




FIGURE 2.5 – effectuer une régression multiple revient à effectuer une projection $y^* = Py$ dans l'espace des variables

2.3 La régression multiple

Il d'agit d'essayer de reconstituer la valeur d'une variable y (appelée “variable dépendante” ou “critère”) en fonction de p autres variables $x_1, \dots, x_p$ (appelées “variables indépendantes” ou “prédicteurs”³). On se limite aux reconstitutions les plus simples, à savoir linéaires, de la forme

$$y = y^* + e \qquad y^* = b_0 + b_1 x_1 + b_2 x_2 + \dots + b_p x_p \qquad (2.12)$$

où y^* est la variable *prédite*, $e = y - y^*$ est le *résidu*, et $b_0, \dots, b_p$ sont des *coefficients de régression* qu'il s'agit de choisir au mieux, i.e. de façon à minimiser la somme des carrés des résidus $\sum_i e_i^2$ (critère des moindres carrés).

Par exemple (données *huit_notes*), on voudrait déterminer y = “note de géographie” en fonction des $p = 7$ autres branches pour chacun des $n = 50$ élèves. Les variables entrant dans l'équation (2.12) sont des vecteurs à n composantes, et les identités entre ces derniers constituent n équations sur leurs composantes. Idéalement, on aimerait que le résidu soit nul (i.e. $e_i = 0$ pour tout $i = 1, \dots, n$), ce qui serait le cas si l'on pourrait trouver des coefficients tels que $y = b_0 + b_1 x_1 + b_2 x_2 + \dots + b_p x_p$, qui constitue un système de n équations à $p + 1$ inconnues $b_0, \dots, b_p$. Dans l'exemple, on aurait 50 équations à 8 inconnues, qui n'ont généralement pas de solution (davantage de contraintes que de degrés de liberté). Ainsi, si $n \gg p$, (ce qui sera toujours le cas dans les applications de la régression multiple), on doit poser $e \neq 0$, i.e. $y^* \neq y$ (reconstitution approximative).

En faisant varier toutes les valeurs des composantes $b_0, \dots, b_p$, l'ensemble des vecteurs y^* générés par (2.12) constitue précisément l'hyperplan $M \equiv M(\mathbf{1}, x_1, \dots, x_p)$ engendré par les vecteurs $\mathbf{1}, x_1, \dots, x_p$. L'apparition du vecteur unité $\mathbf{1}$ (contenant n fois la composante 1) provient du terme b_0 , qui doit être interprété comme $b_0 \mathbf{1}$.

Ainsi posé, le problème revient à déterminer (figure 2.5) le vecteur $y^* \in M$ le plus proche du vecteur $y \notin M$ au sens où $\|y - y^*\|^2 = \|e\|^2$ est minimum (critère des moindres carrés). On sait que la solution est donnée par la projection $y^* = Py$ où $P = X(X'X)^{-1}X'$ et $X = (\mathbf{1} | x_1 | \dots | x_p)$: ici, la matrice X de type $(n \times (p+1))$ est simplement obtenue à partir de la matrice des données initiales (telle que celle de la figure 2.1) en lui ajoutant une colonne ne contenant que des 1.

Les correspondances entre Géométrie et Statistique établies précédemment permettent de tirer plusieurs conséquences de la figure 2.5. D'abord, le vecteur des résidus e est perpendiculaire à $\mathbf{1}, x_1, \dots, x_p$ et y^* , d'où :

$$\text{cov}(e, \mathbf{1}) = 0 \quad (\text{i.e. } \bar{e} = 0) \qquad \text{corr}(e, X_i) = 0 \quad \text{pour } i = 1, \dots, p \qquad \text{corr}(e, y^*) = 0 \qquad (2.13)$$

Ensuite, le triangle formé de y, y^* et e est rectangle, avec y comme hypoténuse. Le théorème de Pythagore

3. **Attention !** il s'agit de l'indépendance du point de vue fonctionnel, et non pas statistique : en général, les prédicteurs sont corrélés entre eux.




FIGURE 2.6 – visualisation géométrique du coefficient de corrélation partielle

s'énonce alors :

$$\begin{array}{rclcl} \text{var}(y) & = & \text{var}(y^*) & + & \text{var}(e) \\ \text{variance totale} & = & \text{variance expliquée} & + & \text{variance résiduelle} \end{array} \quad (2.14)$$

Enfin, il est naturel de définir le *coefficient de corrélation multiple* R comme le cosinus de l'angle entre Y et l'hyperplan $M(\mathbf{1}, X_1, X_2, \dots, X_p)$ engendré par les prédicteurs. Ainsi :

$$R = \cos \alpha = \text{corr}(y, y^*) \quad R^2 = \frac{\text{var}(y^*)}{\text{var}(y)} = \frac{\text{variance expliquée}}{\text{variance totale}} = \text{prop. variance expliquée} \quad (2.15)$$

En présence d'un seul prédicteur ($p = 1$), on retrouve la situation de régression simple $y = b_0 \mathbf{1} + b_1 x_1 \equiv b + ax$ illustrée en figure 2.2. Le coefficient de corrélation multiple se réduit alors à $R = \text{corr}(y^*, y) = \text{corr}(ax + b, y) = \text{corr}(x, y) = r_{xy}$.

En absence de tout prédicteur ($p = 0$), il s'agit d'approximer y par le vecteur constant le plus proche. On sait (section 2.2.1) que ce dernier est le vecteur constant $y^* = \bar{y} \mathbf{1}$ dont les composantes sont égales à la moyenne $\bar{y}$ (figure 2.3).

2.4 Le coefficient de corrélation partielle

Rappelons que le coefficient de corrélation est invariant par rapport aux transformations linéaires, c'est-à-dire :

$$\text{corr}(x, y) = \text{corr}(ax + b, cy + d) \quad (2.16)$$

quels que soient x et y , où a, b, c, d sont des constantes (telles que $ac > 0$; lorsque $ac < 0$, le signe de la corrélation est inversé). Comme la corrélation entre variables est le cosinus de l'angle des variables centrées, on pourra toujours, dans les problèmes de corrélation, considérer les variables x et y comme *standardisées*, i.e. centrées ($\bar{x} = 0$) et réduites ($\text{var}(x) = 1$). Soient trois variables standardisées x, y et z . En se référant à la figure 2.6, on a :

$$\text{corr}(x, y) = \cos \gamma \quad \text{corr}(x, z) = \cos \alpha \quad \text{corr}(y, z) = \cos \beta \quad (2.17)$$

x^{**} et y^{**} sont les projections de x et y perpendiculaires à Z , c'est-à-dire les parties **résiduelles** de x et y , "non expliquées" par z . La corrélation entre ces parties résiduelles est appelée **corrélation partielle de x et y pour z donné**, et notée $\text{corr}(x, y|z)$ ou $r_{x,y|z}$. On a $r_{x,y|z} = \cos \delta$.

D'autre part, on peut montrer (par la trigonométrie sphérique) que

$$\cos \delta = \frac{\cos \gamma - \cos \alpha \cos \beta}{\sqrt{1 - \cos^2 \alpha} \sqrt{1 - \cos^2 \beta}} \quad (2.18)$$

c'est-à-dire :

$$r_{x,y|z} = \frac{r_{xy} - r_{xz} r_{yz}}{\sqrt{1 - r_{xz}^2} \sqrt{1 - r_{yz}^2}} \quad (2.19)$$

$r_{xy|z}$ peut aussi s'interpréter comme corrélation entre les deux plans définis par x, z d'une part et y, z d'autre part.

2.4.1 (*) Coefficients de corrélation partielle d'ordre supérieur

On peut poursuivre le raisonnement et définir le coefficient de corrélation partielle d'ordre 2 $\text{corr}(x, y|z, w) = r_{x,y|z,w}$ comme la corrélation entre les résidus x^{**} et y^{**} de la régression de x et y par les prédicteurs z et w . Sa valeur peut s'obtenir en itérant l'équation (2.19) :

$$r_{x,y|z,w} = \frac{r_{xy|z} - r_{xw|z} r_{yw|z}}{\sqrt{1 - r_{xw|z}^2} \sqrt{1 - r_{yw|z}^2}} \quad (2.20)$$

En continuant ainsi, on peut calculer des coefficients de corrélation partielle d'ordre 3 (de la forme $\text{corr}(x, y|z, w, u)$), d'ordre 4 (de la forme $\text{corr}(x, y|z, w, u, v)$) et ainsi de suite.

Le coefficient de corrélation multiple est relié aux coefficients de corrélation partiels des différents ordres par l'identité :

$$1 - R_{y,(x_1 x_2 \dots x_p)}^2 = (1 - r_{y,x_1}^2)(1 - r_{y,x_2|x_1}^2)(1 - r_{y,x_3|x_1 x_2}^2) \dots (1 - r_{y,x_p|x_1 x_2 \dots x_{p-1}}^2) \quad (2.21)$$

2.4.2 (*) Une vue unifiée des différents coefficients de corrélation

En notant $M_{123\dots}$ l'hyperplan engendré par les vecteurs $x_0 := \mathbf{1}, x_1, x_2, x_3 \dots$ et $\angle(M, N)$ l'angle entre deux hyperplans M et N , les divers coefficients de corrélation peuvent être définis de la façon suivante :

- Corrélation simple entre x_1 et x_2 :

$$r_{12} = \text{corr}(x_1, x_2) = \cos \angle(M_1, M_2) \quad (2.22)$$

- Corrélation partielle entre x_1 et x_2 à x_3 "fixé" :

$$r_{12|3} = \text{corr}(x_1, x_2|x_3) = \cos \angle(M_{13}, M_{23}) \quad (2.23)$$

- Corrélation partielle entre x_1 et x_2 à x_3 et x_4 "fixés" :

$$r_{12|34} = \text{corr}(x_1, x_2|x_3, x_4) = \cos \angle(M_{134}, M_{234}) \quad (2.24)$$

- Corrélation multiple entre x_1 (critère) et $\{x_2, x_3, x_4, x_5\}$ (prédicteurs) :

$$R_{1,(2345)} = \cos \angle(M_1, M_{2345}) \quad (2.25)$$

- Corrélation dite *canonique* entre le sous-espace engendré par $\{x_1, x_2, x_3\}$ et celui engendré par $\{x_4, x_5\}$; le coefficient de corrélation canonique est utilisé pour déterminer dans quelle mesure les "questionnaires $\{x_1, x_2, x_3\}$ et $\{x_4, x_5\}$ mesurent quelque chose en commun" :

$$R_{(123),(45)} := \cos \angle(M_{123}, M_{45}) \quad (2.26)$$

2.5 Résumé

Dans l'espace des variables :

- centrer une variable revient à prendre son résidu sur la droite des constantes
- la covariance entre deux variables est leur produit scalaire (après centration, à $\frac{1}{n}$ près)
- la variance d'une variable est le carré de sa norme (après centration, à $\frac{1}{n}$ près)
- la corrélation de deux variables est le cosinus de leur angle (après centration)
- de façon générale, tout coefficient de corrélation (simple, multiple, partiel, canonique) est le cosinus de l'angle entre les hyperplans correspondants.

Faire une régression multiple, c'est projeter (dans l'espace des individus) le critère y sur l'hyperplan engendré par les prédictors $x_1, \dots, x_p$ et le vecteur constant $\mathbf{1}$. Cette projection permet de déterminer les coefficients de la régression. Le vecteur y^* obtenu contient les scores prédits. Les résidus sont $e = y - y^*$. On a toujours $\text{var}(y) = \text{var}(y^*) + \text{var}(e)$ et $R^2 = \text{var}(y^*)/\text{var}(y)$.

2.6 Exercices et corrigés

Exercice 2.1

On considère le tableau de données suivant :

i	x	y	z
1	1	-2	2
2	3	4	0

1. Calculer les variables centrées x^c , y^c et z^c .
2. Représenter graphiquement les variables x , y , z , x^c , y^c et z^c dans l'espace des variables.
3. Vérifier que les vecteurs x^c , y^c et z^c sont les projections de x , y et z sur la droite passant par l'origine et dont la direction est donnée par $\begin{pmatrix} 1 \\ -1 \end{pmatrix}$ (ces projections sont les résidus des projections des vecteurs sur la droite des constantes, passant par l'origine et dont la direction est donnée par $\begin{pmatrix} 1 \\ 1 \end{pmatrix}$). On vérifie également que les projections des vecteurs sur la droite des constantes ont pour composantes la moyenne des variables correspondantes. Par exemple, la projection de X sur la droite des constantes vaut $\bar{x} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \end{pmatrix}$.
4. Par l'observation de votre graphique uniquement, déterminer s_x , $\text{cov}(x, y)$ et r_{yz} . Vérifier vos résultats par un calcul direct.

Exercice 2.2

Déterminer, pour chacune des questions ci-dessous, l'unique réponse correcte :

1. Une des correspondances suivantes (à propos de variables centrées) est fausse :
 - (a) la corrélation entre deux variables est l'angle entre les deux vecteurs correspondants
 - (b) à un facteur $\frac{1}{n}$ près, la covariance de deux variables centrées est le produit scalaire des deux vecteurs correspondants
 - (c) si le coefficient de corrélation de deux variables vaut ± 1 , alors les vecteurs centrés correspondants sont parfaitement collinéaires
 - (d) si une variable est standardisée, alors la norme du vecteur correspondant est égale à $\sqrt{n}$.

2. Soit la matrice $B = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 1 & 0 \\ 3 & 0 & 1 \end{pmatrix}$

et 4 vecteurs : $v_1 = \begin{pmatrix} 0 \\ \frac{2}{3} \\ -1 \end{pmatrix}$, $v_2 = \begin{pmatrix} \sqrt{13} \\ 2 \\ 3 \end{pmatrix}$, $v_3 = \begin{pmatrix} 1 \\ -\frac{2}{\sqrt{13}} \\ -\frac{3}{\sqrt{13}} \end{pmatrix}$, $v_4 = \begin{pmatrix} 0 \\ 1 \\ -\frac{2}{3} \end{pmatrix}$.

Un des vecteurs proposés n'est pas un vecteur propre de B :

- (a) v_1 avec la valeur propre -1
- (b) v_2 avec la valeur propre $\lambda = 1 + \sqrt{13}$
- (c) v_3 avec la valeur propre $\lambda = 1 - \sqrt{13}$
- (d) v_4 avec la valeur propre +1

Exercice 2.3

La matrice de corrélation entre deux variables vaut $R = \begin{pmatrix} 1 & r \\ r & 1 \end{pmatrix}$, où $r \in [-1, 1]$ est le coefficient de corrélation entre les deux variables. Calculer la trace et le déterminant de R , et déterminez ses deux valeurs propres λ_1 et λ_2 . Montrer que R est *semi-définie positive*, i.e. que toutes ses va.p. sont non-négatives.

Exercice 2.4

Soit $\Sigma = \begin{pmatrix} 4 & 2 & 2 \\ 2 & 3 & 0 \\ 2 & 0 & 2 \end{pmatrix}$ une matrice de variance-covariance pour trois variables x , y et z . On peut montrer

que son inverse est donné par $\Sigma^{-1} = \begin{pmatrix} \frac{3}{2} & -1 & -\frac{3}{2} \\ -1 & 1 & 1 \\ -\frac{3}{2} & 1 & 2 \end{pmatrix}$.

- 1. que valent $\text{var}(z)$, $\text{cov}(z, y)$ et $\text{cov}(y, y)$?
- 2. que valent $\text{corr}(x, y)$, $\text{corr}(x, z)$ et $\text{corr}(y, y)$?
- 3. que vaut $\text{corr}(x, y|z)$?

Exercice 2.5 (*)

On considère le cas de la régression simple de $y \in \mathbb{R}^n$ sur $x \in \mathbb{R}^n$

- 1. Calculer la matrice $(X'X)^{-1} \in \mathbb{R}^{2 \times 2}$ intervenant dans la matrice $(n \times n)$ de projection $P = X(X'X)^{-1}X'$, où $X = (\mathbf{1}|x)$. En particulier, montrer que la matrice $(X'X)$ est inversible ssi $\text{var}(x) > 0$.
- 2. Les composantes de la matrice de projection $P = (p_{ij})$ sont égales à $p_{ij} = \frac{1}{n}(1 + \frac{(x_i - \bar{x})(x_j - \bar{x})}{\text{var}(x)})$, dont on constate qu'elles sont symétriques (i.e. $p_{ij} = p_{ji}$). Montrer que $P\mathbf{1} = \mathbf{1}$, i.e. montrer que $\sum_j p_{ij} = 1$.
- 3. Démontrer la propriété d'idempotence $P^2 = P$ de la projection, i.e. montrer que $\sum_k p_{ik}p_{kj} = p_{ij}$.


Corrigé de la série 2

Exercice 2.1

- 1. Comme $\bar{x} = 2$, $\bar{y} = 1$ et $\bar{z} = 1$, on obtient

i	x^c	y^c	z^c
1	-1	-3	1
2	1	3	-1

- 2.



3.

4. (a) L'écart-type s_x de x est lié à la norme de x^c de la manière suivante : $s_x = \sqrt{\text{var}(x)} = \sqrt{\text{cov}(x, x)} = \sqrt{\frac{1}{n}(x^c, x^c)} = \frac{1}{\sqrt{n}}\|x^c\|$. Comme, d'après le graphique, $\|x^c\| = \sqrt{2}$, on a $s_x = 1$.
- (b) $\text{cov}(x, y) = \frac{1}{n}(x^c, y^c) = \frac{1}{n}\|x^c\|\|y^c\|\cos\alpha = \frac{1}{2}\sqrt{18}\sqrt{2} = 3$ ($\alpha = 0$ car x^c et y^c sont parallèles et de même sens).
- (c) $r_{yz} = \cos\alpha$, où α est l'angle entre les vecteurs y^c et z^c . Comme $\alpha = 180^\circ$, $r_{yz} = -1$. Remarque : comme l'échantillon ne compte que deux individus, les corrélations entre toutes les paires de variables (non nulles) ne peuvent valoir que ± 1 .

Exercice 2.2

1. a) Faux : la corrélation entre deux variables *n'est pas* l'angle entre les deux vecteurs correspondants (mais constitue le *cosinus* de cet angle).
- b) Vrai, puisque $\text{cov}(x, y) = \left(\frac{1}{n} \sum x_i y_i\right) - \bar{x}\bar{y} = \frac{1}{n}(x^c, y^c)$.
- c) Vrai, puisque $\text{corr}(x, y) = \cos(\alpha)$, et que $\cos(\alpha) = 1$ si $\alpha = 0^\circ$, et $\cos(\alpha) = -1$ si $\alpha = 180^\circ$ (où α est l'angle entre x^c et y^c).
- d) Vrai, puisque une variable standardisée x a été centrée ($\bar{x} = 0$) et réduite ($s_x = 1$). Ainsi, $1 = \text{var}(x) = \frac{1}{n} \sum x_i^2 = \frac{1}{n} \|x\|^2$ qui implique $\|x\|^2 = n$, et donc $\|x\| = \sqrt{n}$.
2. Pour les valeurs propres proposées :
 - a) v_1 n'est pas un vecteur propre de B puisque (par calcul direct) $B v_1 \neq -1 \cdot v_1$.
 - b) v_2 est un vecteur propre de B puisque (par calcul direct) $B v_2 = (1 + \sqrt{13}) \cdot v_2 = \begin{pmatrix} 13 + \sqrt{13} \\ 2(1 + \sqrt{13}) \\ 3(1 + \sqrt{13}) \end{pmatrix}$.
 - c) v_3 est un vecteur propre de B puisque (par calcul direct) $B v_3 = (1 - \sqrt{13}) \cdot v_3 = \begin{pmatrix} 1 - \sqrt{13} \\ 2(1 - \sqrt{13}) \\ 3(1 - \sqrt{13}) \end{pmatrix}$.

d) v_4 est un vecteur propre de B puisque (par calcul direct) $B v_4 = 1 \cdot v_4 = \begin{pmatrix} 0 \\ 1 \\ -\frac{2}{3} \end{pmatrix}$.

Exercice 2.3

On a $\text{trace}(R) = 1 + 1 = 2$, et $\det(R) = 1 \cdot 1 - r \cdot r = 1 - r^2$. Par ailleurs, les deux va.p. λ_1 et λ_2 de R satisfont $\lambda_1 + \lambda_2 = \text{trace}(R) = 2$, et $\lambda_1 \cdot \lambda_2 = \det(R) = 1 - r^2$: ce système de deux équations à deux inconnues peut être résolu en substituant $\lambda_2 = (1 - r^2)/\lambda_1$ dans la première équation, d'où $\lambda_1 + (1 - r^2)/\lambda_1 = 2$, d'où l'équation du second degré $\lambda_1^2 - 2\lambda_1 + (1 - r^2) = 0$, qui possède les deux solutions

$$\lambda_{\pm} = 1 \pm \sqrt{r^2} = 1 \pm |r| \quad \text{ou encore} \quad \lambda_1 = 1 + r \quad \text{et} \quad \lambda_2 = 1 - r$$

Ainsi, les deux va.p. de R sont non-négatives (et même strictement positives si $r \neq \pm 1$), ce qui démontre la caractère *semi-positif* de R .

Exercice 2.4

1. $\text{var}(z) = 2$, $\text{cov}(z, y) = 0$ et $\text{cov}(y, y) = \text{var}(y) = 3$.
2. $\text{corr}(x, y) = \frac{\text{cov}(x, y)}{\sqrt{\text{var}(x) \text{var}(y)}} = \frac{2}{\sqrt{4 \cdot 3}} = \frac{1}{\sqrt{3}} = 0.58$.
 $\text{corr}(x, z) = \frac{\text{cov}(x, z)}{\sqrt{\text{var}(x) \text{var}(z)}} = \frac{2}{\sqrt{4 \cdot 2}} = \frac{1}{\sqrt{2}} = 0.71$.
 $\text{corr}(y, y) = \frac{\text{cov}(y, y)}{\sqrt{\text{var}(y) \text{var}(y)}} = 1$ (toujours vrai, par construction).
3. $\text{corr}(x, y|z) = \frac{\text{corr}(x, y) - \text{corr}(x, z) \text{corr}(y, z)}{\sqrt{(1 - \text{corr}^2(x, z))(1 - \text{corr}^2(y, z))}} = \frac{0.58 - 0.71 \cdot 0}{\sqrt{(1 - 0.71^2)(1 - 0^2)}} = 0.82$.

Exercice 2.5

1. Comme $X = (\mathbf{1}|x)$, on a $X'X = \begin{pmatrix} n & \sum_j x_j \\ \sum_j x_j & \sum_j x_j^2 \end{pmatrix} =: \begin{pmatrix} e & f \\ g & h \end{pmatrix}$. Son inverse est

$$(X'X)^{-1} = \begin{pmatrix} e & f \\ g & h \end{pmatrix}^{-1} = \frac{1}{eh - fg} \begin{pmatrix} h & -f \\ -g & e \end{pmatrix} = \frac{1}{n \sum_j x_j^2 - (\sum_j x_j)^2} \begin{pmatrix} \sum_j x_j^2 & -\sum_j x_j \\ -\sum_j x_j & n \end{pmatrix}$$

Or, le dénominateur du premier terme, qui est le déterminant de $X'X$, s'écrit aussi comme $n^2[\frac{1}{n} \sum_j x_j^2 - (\frac{1}{n} \sum_j x_j)^2] = n^2(\overline{x^2} - \bar{x}^2) = n^2 \text{var}(x)$: ainsi, $X'X$ est inversible ssi $\text{var}(x) > 0$.

2. De la même façon, on peut montrer que les composantes de la matrice de projection $X(X'X)^{-1}X' = P = (p_{ij})$ sont égales à $p_{ij} = \frac{1}{n}(1 + \frac{(x_i - \bar{x})(x_j - \bar{x})}{\text{var}(x)})$. On a que

$$\sum_j p_{ij} = \frac{1}{n} \sum_j (1 + \frac{(x_i - \bar{x})(x_j - \bar{x})}{\text{var}(x)}) = \frac{1}{n} \sum_j 1 + \frac{1}{n} \frac{(x_i - \bar{x})}{\text{var}(x)} \sum_j (x_j - \bar{x}) = \frac{n}{n} + 0 = 1$$

On a utilisé $\sum_j (x_j - \bar{x}) = 0$, et mis en facteur devant le signe somme $\sum_j \dots$ les termes qui ne dépendent pas de j .

3. Par définition, en procédant mécaniquement,

$$\begin{aligned} \sum_{k=1}^n p_{ik} p_{kj} &= \frac{1}{n^2} \sum_{k=1}^n [1 + \frac{(x_i - \bar{x})(x_k - \bar{x})}{\text{var}(x)}] [1 + \frac{(x_k - \bar{x})(x_j - \bar{x})}{\text{var}(x)}] = \frac{1}{n^2} \sum_{k=1}^n 1 + \frac{1}{n^2} \sum_{k=1}^n \frac{(x_i - \bar{x})(x_j - \bar{x})}{\text{var}(x)} \\ &+ \frac{1}{n^2} \sum_{k=1}^n \frac{(x_i - \bar{x})(x_k - \bar{x})}{\text{var}(x)} + \frac{1}{n^2} \sum_{k=1}^n \frac{(x_i - \bar{x})(x_k - \bar{x})}{\text{var}(x)} \frac{(x_k - \bar{x})(x_j - \bar{x})}{\text{var}(x)} \\ &= \frac{1}{n} + 0 + 0 + \frac{1}{n^2} \frac{(x_i - \bar{x})(x_j - \bar{x})}{\text{var}^2(x)} \sum_{k=1}^n (x_k - \bar{x})(x_k - \bar{x}) = \frac{1}{n} + \frac{1}{n^2} \frac{(x_i - \bar{x})(x_j - \bar{x})}{\text{var}^2(x)} n \text{var}(x) \\ &= \frac{1}{n} [1 + \frac{(x_i - \bar{x})(x_j - \bar{x})}{\text{var}(x)}] = p_{ij} \end{aligned}$$

ce qui démontre l'idempotence de P .

Chapitre 3

La régression multiple (suite)

3.1 Coefficients de régression et corrélation multiple

3.1.1 Rappel

Effectuer une régression (linéaire) multiple du critère y sur les p prédicteurs $x_1, \dots, x_p$ consiste à approximer au mieux (au sens des moindres carrés) y par la variable des scores prédits y^*

$$y^* = b_0 + b_1 x_1 + \dots + b_p x_p = \sum_{j=0}^p b_j x_j = Xb \quad (3.1)$$

où $X = (x_0 | x_1 | \dots | x_p)$ est la matrice $n \times (p+1)$ des scores des prédicteurs (auxquels on a rajouté la colonne $x_0 = \mathbf{1}$) et b est le vecteur $(p+1) \times 1$ des coefficients de régression. Ces derniers sont donnés (en vertu de $y^* = Xb$ et $y^* = Py = X(X'X)^{-1}X'y$) par

$$b = \begin{pmatrix} b_0 \\ b_1 \\ \dots \\ b_p \end{pmatrix} = (X'X)^{-1}X'y \quad (3.2)$$

Le coefficient de corrélation multiple R est égal à la corrélation entre Y et l'hyperplan $M \equiv M(\mathbf{1}, x_1, \dots, x_p)$ engendré par les prédicteurs, ou, de façon équivalente, à la corrélation entre le critère y et sa reconstitution y^* . Son carré est la proportion de variance de y expliquée par les prédicteurs

$$R = \cos \angle(y, M) = \text{corr}(y^*, y) \quad R^2 = \frac{\text{var}(y^*)}{\text{var}(y)} \quad (3.3)$$

Une analogie culinaire peut aider à saisir le sens intuitif de l'équation (3.1) : supposons qu'un cuisinier ne dispose pas d'un certain condiment ou d'une certaine épice y : peut-il en recréer approximativement le goût et la saveur à l'aide d'autres condiments ou épices $x_1, x_2, \dots, x_p$ disponibles ? En utilisant tout son Art, le cuisinier va créer un mélange (ou synthèse) y^* , constitué d'une proportion de b_1 de l'épice x_1 , d'une proportion de b_2 de l'épice x_2 , etc... , qu'il espère le plus similaire possible à l'ingrédient manquant Y . Parfois la tâche sera relativement aisée, et les convives ne percevront pas la différence entre y et y^* . Parfois la tâche sera si difficile (comme de synthétiser un ersatz de sucre à partir de sel, de poivre et de gingembre) que la démarche sera vouée d'avance à l'échec ; ainsi en va-t-il de la régression multiple : la création d'un ersatz y^* est toujours possible, mais parfois peu ressemblant à l'original y visé¹.

1. dans cette métaphore (c'est sa limitation majeure), les proportions de mélange b_j des ingrédients disponibles doivent être non négatives, contrairement aux b_j de l'équation (3.1) qui peuvent prendre des valeurs quelconques.

Beta Coefficient Table					
Variable:	Coefficient:	Std. Err.:	Std. Coeff.:	t-Value:	Probability:
INTERCEPT	1.239				
français	-.247	.158	-.221	1.563	.1255
physique	-.283	.174	-.262	1.623	.1121
chimie	.189	.19	.187	.994	.326
histoire	.169	.118	.216	1.43	.16
mathématiques	.405	.153	.384	2.645	.0115
philosophie	.21	.151	.187	1.39	.1718
allemand	.286	.138	.36	2.068	.0448

FIGURE 3.1 – les valeurs des coefficients de régression b_j figurent dans la colonne “Coefficient”

Count:	R:	R-squared:	Adj. R-squared:	RMS Residual:
50	.688	.473	.385	1.463

Analysis of Variance Table				
Source	DF:	Sum Squares:	Mean Square:	F-test:
REGRESSION	7	80.623	11.518	5.382
RESIDUAL	42	89.877	2.14	p = .0002
TOTAL	49	170.5		

FIGURE 3.2 – coefficient de corrélation multiple $R = .688$ pour $n = 50$ individus. La table d’“analyse de variance” donne les valeurs de la décomposition $n \text{ var}(y) = n \text{ var}(y^*) + n \text{ var}(e)$, les termes de la forme $n \text{ var}(\cdot)$ étant appelés *somme des carrés*.

3.1.2 Exemple

Dans les données `huit_notes` du chapitre 2 constituées des notes obtenues par $n = 50$ élèves, on veut prédire $y = \text{“(note de) géographie”}$ en fonction des sept prédicteurs “(note de) français”, “physique”, “chimie”, “histoire”, “mathématiques”, “philosophie”, et “allemand”. La figure 3.1 donne les valeurs des coefficients de régression b_j , et la figure 3.2 donne la valeur $R = .688$ du coefficient de corrélation et de son carré $R^2 = .473$. Ainsi, 47.3% de la variabilité des notes de géographie (d’un élève à l’autre) peut être expliquée par la variabilité constatée sur les autres notes, ce qui revient à dire que 52.7% de la variance des notes de géographie ne s’expliquent pas par les résultats obtenus dans les autres disciplines².

Par exemple, le score prédit en géographie de quelqu’un qui aurait huit en français et en histoire et sept partout ailleurs serait de

$$y^* = 1.239 - .247 \times 8 - .283 \times 7 + .189 \times 7 + .169 \times 8 + .405 \times 7 + .21 \times 7 + .286 \times 7 = 6.26$$

La colonne “Std.Coeff.” de la figure 3.1 contient les *poids bêta* β_j qui sont les coefficients de régression *standardisés*, c’est-à-dire obtenus après standardisation des variables indépendantes $x_1, \dots, x_p \rightarrow x_1^s, \dots, x_p^s$ et dépendante $y \rightarrow y^s$

$$\beta_0 := 0 \quad \beta_j := \frac{\sqrt{\text{var}(x_j)}}{\sqrt{\text{var}(y)}} b_j = \frac{s_j}{s_y} b_j \quad j = 1, \dots, p \quad (3.4)$$

Par rapport aux coefficients de régression bruts b_j , les poids bêta β_j ont l’avantage de ne pas dépendre du système d’unités choisis. Par exemple, si “géographie” était exprimée sur une échelle de 100 (au lieu de 10) et que “mathématiques” était exprimée sur une échelle de 20 (au lieu de 10), les autres variables étant inchangées, on aurait la transformation $b_j \rightarrow 10 b_j$ pour tous les prédicteurs (y compris $j = 0$) sauf $b_{\text{mathématiques}} \rightarrow 5 b_{\text{mathématiques}}$, tandis que tous les poids bêta β_j resteraient inchangés.

2. cette notion de variance du critère expliquée par la variance du prédicteur est assez intuitive : typiquement, les notes de physique et de mathématiques sont fortement et positivement corrélées dans une classe, et la variation du niveau de mathématiques d’un étudiant à l’autre s’accompagne le plus souvent d’une variation correspondant du niveau de physique.

Correlation Matrix for Variables: X1 ... Xg

	français	physique	chimie	histoire	mathém...	philosop...	allemand	géograp...
français	1							
physique	.222	1						
chimie	.387	.67	1					
histoire	.373	.472	.563	1				
mathéma...	.379	.512	.555	.263	1			
philosophie	.401	.129	.234	.198	.251	1		
allemand	.378	.533	.637	.589	.33	-.06	1	
géographie	.23	.328	.533	.465	.492	.226	.497	1

FIGURE 3.3 – matrice des corrélations entre les 8 variables. Le coefficient de corrélation multiple $R = .688$ entre “géographie” et l’ensemble des autres prédicteurs est au moins égal à la plus grande corrélation simple entre $y = \text{“géographie”}$ et chacune des autres notes $x_1, \dots, x_p$. Il y a collinéarité : les prédicteurs $x_1, \dots, x_p$ sont corrélés entre eux.

De façon générale, le poids bêta β_j mesure l’importance du prédicteur x_j dans la qualité de l’ajustement R^2 des valeurs de y par tous les prédicteurs $x_1, \dots, x_p$.

3.1.3 Corrélations simples et collinéarité

Chercher à prédire une variable y ne fait sens que si cette dernière est liée aux prédicteurs $x_1, \dots, x_p$. Comme R constitue la valeur maximale de la corrélation entre y et une combinaison linéaire quelconque des prédicteurs, on en déduit (figure 3.3) que R est supérieur ou égal à chacun des coefficients de corrélation simple $r_{x_1 y} = \text{corr}(x_1, y), \dots, r_{x_p y} = \text{corr}(x_p, y)$.

En général, les prédicteurs sont liés entre eux, i.e. $\text{corr}(x_j, x_k) \neq 0$ comme le montre la figure 3.3). Cette situation est appelée *collinéarité* (au sens large), et complique considérablement l’interprétation des résultats d’une régression multiple : la question “les notes en géographies sont-elles à mettre en relation avec les notes en mathématiques ou bien en chimie ?” est en effet sans objet si les variables “mathématiques” et “chimie” sont corrélées.

À l’extrême (collinéarité au sens strict), un des prédicteurs serait lui-même une combinaison linéaire exacte des autres prédicteurs. Alors la matrice $X'X$ serait non inversible (car de rang inférieur à $p+1$), et l’équation (3.2) non définie. Dans ce cas, il suffirait d’ôter autant de prédicteurs qu’il le faut pour obtenir une liste (largement arbitraire...) de prédicteurs linéairement indépendants et procéder alors à une régression multiple³.

3.2 Modèle probabiliste

Jusqu’à présent, la régression multiple n’a été abordée que sous l’angle restreint de la question de l’ajustement (fit) d’un critère y à une série de prédicteurs $x_1, \dots, x_p$ au sein d’un échantillon de taille n . Dès que l’on aborde la question de la généralisabilité des résultats obtenus à un autre échantillon de même nature (par exemple aux notes obtenues par un autre groupe d’élèves), il est nécessaire de faire intervenir un *modèle probabiliste* permettant de pratiquer l’*inférence* (de l’échantillon vers la population infinie dont l’échantillon est supposé issu) et les test statistiques en particulier.

Ce modèle probabiliste dit que, pour des valeurs des prédicteurs $x_1, \dots, x_p$ fixées, le critère Y est une *variable aléatoire* constituée d’une *partie déterministe* Y^* et d’une *partie aléatoire* ϵ (terme d’erreur, de moyenne nulle

3. Une façon radicale de contourner les difficultés dues à la collinéarité consiste à transformer le jeu de prédicteurs corrélés en un jeu de combinaisons linéaires de ces derniers, non corrélés entre eux, typiquement au moyen d’une analyse en composantes principales (chapitre suivant). Cependant, la difficulté subsiste au sens où chaque nouveau prédicteur sera en général constitué d’une combinaison de tous les prédicteurs de départ...

et de variance constante), telle que

$$Y = Y^* + \epsilon \quad Y^* = \sum_{j=0} b_j^{\text{th}} x_j = Xb^{\text{th}} = E(Y|x_1, \dots, x_p) \quad E(\epsilon) = 0 \quad \text{Var}(\epsilon) = \sigma^2 \quad (3.5)$$

où les b_j^{th} sont les coefficients de corrélation théoriques et σ^2 la variance d'erreur.

3.2.1 Estimation des paramètres

Les estimateurs classiques des paramètres théoriques (qui ne sont pas directement observables) b_j^{th} et σ^2 du modèle (3.5), ainsi que de la corrélation multiple théorique associée $(R^{\text{th}})^2$ sont donnés par

$$\hat{b}_j^{\text{th}} := b_j \quad \hat{\sigma}^2 := \frac{\sum_{i=1}^n e_i^2}{n - p - 1} \quad \hat{R}^2 := \frac{(n - 1)R^2 - p}{n - p - 1} \quad (3.6)$$

Ces estimateurs sont *sans biais*, i.e. leur moyenne (théorique) est égale aux paramètres théoriques correspondants, sans sur- ni sous-estimation systématique⁴. La figure 3.2 indique (sous “RMS Residual”) la valeur $\hat{\sigma} = 1.463$, ce qui signifie que l'écart typique entre la note de géographie y et sa prédiction y^* est importante, de l'ordre de 1.46.

L'expression (3.6) montre qu'au sein de toute la population (pensée comme la limite d'un échantillon de taille infinie qui révélerait alors le modèle et ses paramètres), le pourcentage de variance expliquée (ou *carré de la corrélation multiple théorique* $(R^{\text{th}})^2$) doit être estimé non pas par R^2 , mais par le “ R^2 ajusté” $\hat{R}^2$. On peut vérifier que ce coefficient ajusté $\hat{R}^2$ est *toujours inférieur* au coefficient de détermination R^2 , la différence devenant négligeable pour n très grand. Dans notre exemple, on trouve $\hat{R}^2 = 0.385$: c'est donc plutôt 38.5% que 47.3% de variance expliquée que les autres notes “expliquent” de la note de géographie à l'intérieur de la population.

3.2.2 Tests et intervalles de confiance

Rappel : saut coïncidence numérique fortuite, les valeurs des coefficients *empiriques* R et b_j sont non nuls. Mais cette circonstance suffit-elle à inférer que, vraisemblablement, les coefficients *théoriques* correspondants R^{theo} et b_j^{theo} sont non nuls ? C'est précisément la question de l'inférence statistique, et *tester la significativité* des coefficients (empiriques) R^2 et b_j consiste à décider si

- (i) leur non-nullité signale vraisemblablement que les valeurs théoriques des paramètres correspondantes sont non nulles à leur tour, les coefficients étant alors qualifiés de *significatifs*
- (ii) ou bien s'il est néanmoins plausible que les paramètres théoriques correspondants soient nuls (les coefficients étant alors dits non significatifs), parce que la faible valeur de R et b_j et/ou le faible nombre d'observations n fait que la non nullité des coefficients empiriques peut être mise sur le compte du hasard, reflétant une simple fluctuation statistique.

Dans le premier (second) cas, on rejette H_0 (H_1) et accepte H_1 (H_0), avec

$$H_0 : “\lambda = 0” \quad H_1 : “\lambda \neq 0”$$

où λ est le paramètre théorique en jeu. Une fois que le chercheur a fixé son *niveau de signification* α , le risque maximal toléré de rejeter H_0 à tort, il peut, *de façon équivalente* :

- rejeter H_0 si $d(D) > x_{1-\alpha}$, où $d(D)$ représente la variable de décision associée au test (calculée par le chercheur) et $x_{1-\alpha}$ (lu dans une table statistique) le $1 - \alpha$ -ème quantile de la distribution de $d(D)$ sous H_0 .
- rejeter H_0 si $p < \alpha$, où la *valeur* p , calculée par un logiciel, est le niveau de signification a posteriori (précisément tel que $d(D) = x_{1-p}$).
- rejeter H_0 si $0 \notin [\lambda_{\min}(\alpha), \lambda_{\max}(\alpha)]$, ce dernier intervalle étant l'*intervalle de confiance* à $1 - \alpha$ (et sous H_0) pour les valeurs possibles de λ : dire que zéro n'appartient pas à cet intervalle revient à dire que la probabilité que $\lambda \neq 0$ est inférieure à α .

4. à quelques corrections près, négligeables pour n grand, en ce qui concerne $\hat{R}^2$.

Confidence Intervals and Partial F Table					
Variable :	95% Lower :	95% Upper :	90% Lower :	90% Upper :	Partial F :
INTERCEPT					
français	-.567	.072	-.514	.019	2.444
physique	-.634	.069	-.576	.01	2.634
chimie	-.194	.571	-.131	.508	.988
histoire	-.069	.407	-.03	.367	2.046
mathématiques	.096	.715	.148	.663	6.994
philosophie	-.095	.514	-.044	.463	1.933
allemand	.007	.566	.053	.519	4.277

FIGURE 3.4 – intervalles de confiance à 95% et 99% pour les coefficients de régression théoriques

Test de la corrélation multiple : on rejette l’hypothèse nulle H_0 : “la corrélation théorique R^{theo} est nulle” au niveau α si

$$\frac{R^2}{1 - R^2} \frac{n - p - 1}{p} > F_{1-\alpha}[p, n - p - 1] \quad (3.7)$$

où n est le nombre de sujets (ici $n = 50$), p le nombre de prédicteurs (ici $p = 7$), et $F_{1-\alpha}[p, n - p - 1]$ est le $1 - \alpha$ -ième centile de la distribution du F à p et $n - p - 1$ degrés de liberté. Dans l’exemple, on peut lire dans la table 3.2 la valeur $F = 5.382$ du “ F observé” (qui est la variable de décision constituée par le membre de gauche de l’équation (3.7)), ainsi que les degrés de liberté (**df** = degrees of freedom) $p = 7$ et $n - p - 1 = 42$.

Alternativement, il suffit, après avoir choisi un niveau α , tel $\alpha = .01$, de lire la valeur p (qui est ici de $p = .002$ dans la table 3.2) pour rejeter H_0 si $p < \alpha$ (ce qui sera ici le cas) : $p = .0002$ veut dire qu’il n’y a que deux chances sur dix mille pour que la corrélation R non-nulle observée ne soit due qu’à une coïncidence fortuite présente dans cet échantillon-ci, sans qu’elle apparaisse dans un autre échantillon⁵.

Il faut préciser que ces seuils critiques (ainsi que les suivants) ne sont valides que sous l’hypothèse supplémentaire que la distribution des résidus modèle (3.5) est *normale*, i.e. que $\epsilon \sim N(0, \sigma^2)$.

Test des coefficients de régression : si

$$\frac{|b_j|}{\hat{\sigma} \sqrt{(X'X)^{-1}_{jj}}} > t_{1-\frac{\alpha}{2}}[n - p - 1] \quad (3.8)$$

on rejette “ $H_0^j : b_j^{\text{theo}} = 0$ ” au niveau α . Il s’agit d’un test bilatéral pour chacun des coefficients de corrélation b_j avec $j = 0, \dots, p$.

Si b_0 est significatif, alors la valeur du critère est significativement différente de zéro lorsque chacun des prédicteurs est nul ; l’intérêt de ce dernier test est souvent secondaire.

Si b_j est significatif pour $j \geq 1$, alors le prédicteur x_j associé influence significativement les valeurs du critère y , étant donnée la présence des autres prédicteurs entrant dans la régression multiple.

Dans l’exemple (table 3.1), la colonne “Probability” donne la valeur p du test correspondant. En travaillant avec $\alpha = .05$, seuls les prédicteurs “mathématiques” et “allemand” influencent significativement la valeur du critère. Aussi, on a $b_{\text{chimie}} = .189$. Ce dernier coefficient n’est pas significatif puisque $p = .326$, et le prédicteur “chimie” pourrait ainsi être omis.

Attention ! dans le cas où l’on supprime ou ajoute un prédicteur, toutes les valeurs des coefficients b_j doivent être **recalculées**, à cause de la collinéarité entre prédicteurs.

La figure 3.4 donne les intervalles de confiance pour les coefficients de régression théoriques b_j^{th} , sur la base de la formule

$$\text{Prob}(b_j - \hat{\sigma} \sqrt{(X'X)^{-1}_{jj}} t_{\frac{1+\alpha}{2}}[n - 1] \leq b_j^{\text{th}} \leq b_j + \hat{\sigma} \sqrt{(X'X)^{-1}_{jj}} t_{\frac{1+\alpha}{2}}[n - 1]) = \alpha \quad (3.9)$$

5. attention, deux quantités complètement différentes sont notées p dans ce paragraphe : le nombre de prédicteurs, et la p -value

Les quantités $\hat{\sigma}\sqrt{(X'X)^{-1}_{jj}}$ dans l'équation (3.9) figurent dans la colonne “Std.Err” de la figure 3.1 : elles mesurent la fluctuation typique des valeurs des b_j d'un échantillon à l'autre, et doivent nous inciter à ne pas sur-interpréter ces dernières : par exemple, la fluctuation typique de $b_{\text{français}} = -.247$ est de .158.

Comme il se doit, seuls les intervalles de confiance à 95% pour “mathématiques” et “allemand” ne contiennent pas le zéro, ce qui revient à dire que seuls les prédictors “mathématiques” et “allemand” influencent significativement (à $\alpha = .05$) la valeur du critère, *étant donnée la présence des autres prédictors*.

3.2.3 Combien de prédictors retenir, et lesquels

Plutôt que de chercher à expliquer y par toutes les p variables explicatives $x_1, \dots, x_p$ à disposition, on peut se restreindre à un ensemble $k < p$ de variables donnant une reconstitution presque aussi bonne de y mais plus économique. En présence de p prédictors, il y a 2^p modèles de régression linéaire possibles, se distinguant entre eux par la présence ou l'absence de chaque prédictor x_j ($j = 1, \dots, p$) dans l'équation de régression $y^* = \sum_{j=0}^p b_j x_j$.

Il n'existe pas de critère unique et général permettant, dans tous les cas, d'évaluer la qualité du modèle : tout dépend des buts recherchés par l'utilisateur (grand R^2 , grand $\hat{R}^2$, parcimonie, absence de collinéarité,...), auquel incombe donc la responsabilité ultime du choix du “meilleur” modèle. Ceci étant, il existe deux grandes familles de critères de choix, l'une basée sur l'*ajustement* (“goodness of fit”) tel que reflété par la proportion de variance expliquée, l'autre basée sur la *significativité* (ou non-significativité) des coefficients.

Maximisation de la corrélation multiple : chercher à maximiser la totalité de la variance expliquée R^2 aboutit invariablement à sélectionner tous les prédictors, même les plus ténus ou opaques : par exemple, la corrélation multiple R entre $y = \text{“géographie”}$ et certains prédictors $x_1, \dots, x_p$ ne peut qu'augmenter (bien que faiblement, selon toute attente) si l'on rajoute la variable $x_{p+1} = \text{“numéro de téléphone portable de l'élève”}$...

On peut alors chercher à maximiser l'estimateur ajusté de la corrélation théorique $\hat{R}^2$ 3.6 (ou, ce qui revient au même, à minimiser $\hat{\sigma}^2$) : contrairement à R^2 , cette quantité peut diminuer lorsque p augmente.

Omettre un seul prédictor : en présence de p prédictors, il faudrait omettre le prédictor dont le β_j est le plus faible (critère d'ajustement), ici “chimie” ou “philosophie” avec $\beta_j = .187$, ou celui dont le coefficient associé est le moins significatif, ici “chimie” avec $p = .326$.

Garder un seul prédictor : si un seul prédictor x_j devait être choisi, il faudrait prendre celui qui explique le plus le critère y , i.e. celui pour lequel $r_{x_j y}^2$ est maximal, ici “chimie” avec $r = .533$ (figure 3.3). Des considérations de significativité aboutissent ici au même choix, puisque, à n donné, une corrélation simple est d'autant plus significative qu'elle est élevée.

Ainsi, et quelque peu paradoxalement, si un seul prédictor de la variable “géographie” devait être choisi, ce serait la variable “chimie”, tandis que, si un seul prédictor devait être éliminé (parmi l'ensemble des $p = 7$ prédictors à disposition), ce serait à nouveau ... la variable “chimie” ! Métaphoriquement parlant, lorsqu'il est question de reconstituer une saveur y , l'ingrédient “chimie”, peu typé, fait -à l'instar de l'“aromat” helvétique- à peu près l'affaire dans une cuisine peu fournie ; mais si d'autres ingrédients plus différenciés étaient à disposition du cuisinier, ces derniers qui seraient alors préférés, et le trop banal “chimie” oublié...

(*) **Itération de modèles :** pour faciliter la sélection d'un “bon” modèle, un certain nombre de procédures automatiques sont disponibles sur la plupart des logiciels. Par exemple, SPSS permet d'utiliser l'une des options suivantes :

- **“Enter”** : c’est la procédure par défaut, demandant à l’utilisateur de déterminer au départ le jeu des prédicteurs qu’il veut voir figurer une fois pour toutes dans le modèle.
- **“Forward”** : une première variable (celle dont la corrélation simple avec le critère est la plus forte, qui est “chimie” dans notre exemple) est introduite dans le modèle. Tous les modèles à deux prédicteurs $y^* = b_0 + b_{\text{chimie}}x_{\text{chimie}} + b_jx_j$ (où x_j est un prédicteur autre que “chimie”) sont alors produits, et la valeur- p p_j des poids bêta correspondants β_j calculée automatiquement. Le prédicteur candidat dont le p_j est le plus faible est alors introduit à son tour, et ainsi de suite, *tant que toutes les valeurs- p des variables candidates à entrer dans le modèle sont inférieures à une valeur seuil p_{IN} fixé par l’utilisateur*. Par exemple, avec $p_{\text{IN}} = 0.10$, ce sont les variables “chimie”, “mathématiques” et “histoire” qui sont introduites successivement. Le modèle obtenu (n’incluant donc pas “allemand”, “français”, “philosophie” et “physique”) explique alors une proportion de $R^2 = 0.39$ de la variance du critère “géographie”. Avec $p_{\text{IN}} = 0.05$, seule “chimie” est incluse dans le modèle, avec $R^2 = 0.28$.
- **“Backward”** : cette procédure est l’inverse de la précédente : toutes les variables sont introduites au départ ; celle dont la valeur- p correspondante est la plus grande (et qui correspond à la plus petite valeur de la colonne “Partial F” de la figure 3.4) est alors éliminée, pour autant que cette valeur soit supérieure à un seuil p_{OUT} fixé par l’utilisateur, et ainsi de suite jusqu’à ce que toutes les valeurs- p des poids bêta du modèle final soient inférieures à p_{OUT} . Avec $p_{\text{IN}} = 0.10$, les variables “chimie”, “physique”, “français”, “philosophie” et “histoire” sont successivement éliminées, laissant seuls les prédicteurs “allemand” et “mathématiques” finalement conservés dans le modèle final, pour lequel $R^2 = 0.37$. Le même modèle est d’ailleurs obtenu avec $p_{\text{IN}} = 0.05$.
- **“Stepwise”** : cette procédure combine les deux procédures précédentes : relativement aux seuils p_{IN} et p_{OUT} fixés par l’utilisateur (avec $p_{\text{IN}} < p_{\text{OUT}}$), les prédicteurs X_j sont successivement introduits dans le modèle (si $p_j < p_{\text{IN}}$) ou retirés (si $p_j > p_{\text{OUT}}$) ; au départ, le modèle ne contient aucun prédicteur. Appliquée à l’exemple, et pour les choix $(p_{\text{IN}}, p_{\text{OUT}}) = (.01, .05)$, $(.05, .10)$ ou $(.01, .15)$ cette procédure sélectionne “chimie” comme seul prédicteur, avec $R^2 = 0.28$. Avec $(p_{\text{IN}}, p_{\text{OUT}}) = (.10, .15)$, la procédure introduit d’abord “chimie”, puis “mathématiques”, puis “histoire”, puis *élimine* “chimie” (car trop collinéaire avec “mathématiques” et “histoire”), puis introduit “allemand”. Le modèle final, retenant donc les prédicteurs “mathématiques”, “histoire” et “allemand”, explique $R^2 = 40\%$ de la variabilité du critère “géographie”.

3.3 Tester les hypothèses de travail

Pour être valide, l’application des tests précédents *présuppose* que soient vérifiées les hypothèses (dites *hypothèses de travail*)

- de **linéarité** entre critère et prédicteurs : dans toute la population dont est extrait l’échantillon, le modèle théorique est :

$$Y = b_0^{\text{th}} + b_1^{\text{th}}X_1 + b_2^{\text{th}}X_2 + \dots + b_p^{\text{th}}X_p + \epsilon \quad (3.10)$$

où le terme d’erreur ϵ est une variable aléatoire indépendante des prédicteurs.

- de **normalité** de la distribution du terme d’erreur : $\epsilon \sim N(0, \sigma^2)$, ce qui implique entre autres la nullité de la moyenne ($E(\epsilon) = 0$), et la constance de la variance ($\text{Var}(\epsilon) = \sigma^2$). On parle d’**homoscédasticité** (= variance constante) lorsque cette dernière hypothèse particulière est vérifiée, d’**hétéroscédasticité** sinon. Un cas typique d’hétéroscédasticité est la situation où $\text{Var}(\epsilon)$ dépend de façon monotone (croissante ou décroissante) des valeurs de Y ou de celles des $X_1, \dots, X_p$.

En cas de violation sérieuse de ces hypothèses additionnelles, la légitimité et la portée d’une régressions multiple s’en trouve naturellement amoindrie.

En pratique, la violation du modèle (c’est à dire des hypothèses de linéarité, de normalité et d’homoscédasticité) peut être détectée visuellement sur le *diagramme des résidus*, qui consiste en un diagramme de dispersion de n points constitués des résidus e_i (en ordonnée) et des valeurs prédites y_i^* (en abscisse). Cette construction est justifiée par le fait que la corrélation $\text{corr}(e, Y^*)$ est *toujours nulle par construction* (équation 2.13). Cependant, la non-corrélation n’implique pas l’indépendance (c’est le contraire qui est vrai) : l’observation





FIGURE 3.5 – diagnostic visuel par le diagramme des résidus, permettant de rejeter les hypothèses de travail

FIGURE 3.6 – diagramme des résidus : valeurs standardisées des y_i^* (en abscisse) et des e_i (en ordonnée). L'alignement des points selon des droites de pente négative est ici dû au fait que les scores observés y sont entiers.

d'un pattern **autre** qu'un *nuage horizontal* centré sur l'axe horizontal $e = 0$ et *symétriquement raréfié en haut et en bas* à mesure que l'on s'éloigne de l'axe serait le signe que les hypothèses de travail sont prises en défaut (figure 3.5).

Lorsque les hypothèses de travail (linéarité, normalité et homoscedasticité) sont clairement prises en défaut, on peut essayer d'y remédier

1. soit en postulant une nouvelle relation *non linéaire* $Y = f(X_1, X_2, \dots, X_p) + \epsilon$, ou plus généralement $Y = g(X_1, X_2, \dots, X_p, \epsilon)$, entre critère et prédicteurs. Cette approche, qui présuppose une bonne compréhension de la nature non-linéaire des transformations de base (telles que x^m , $\sqrt{x}$, $\exp(x)$ ou $\log(x)$), est connue sous le nom de *régression non-linéaire*. Elle peut déboucher sur des considérations passablement mathématiques et spécifiques à la relation postulée.
2. soit en transformant les variables dépendante et/ou indépendantes de façon à obtenir de nouvelles variables $Y'(Y)$ et /ou $X'_j(X_1, \dots, X_p)$ ($j = 1, \dots, p$) censées mieux satisfaire le modèle, puis à effectuer une régression multiple linéaire sur les données transformées.

De toutes les hypothèses de travail, c'est la normalité qui est la moins cruciale, sauf lorsqu'il s'agit d'estimer des seuils critiques et des intervalles de confiance.

Exemple : retournant à l'exemple, le diagramme des résidus (figure 3.6) ne présente apparemment pas de pathologie infirmant les hypothèses de linéarité, normalité et homoscedasticité. A y voir de plus près, on

constate cependant un effet d'alignement des points. Ce pattern est dû au fait que les notes ont été données en points entiers : $y = y^* + e$ doit en effet être entier. Les biais produits, assez subtils et difficiles à analyser systématiquement, n'invalident toutefois pas sérieusement la méthode ; tout au plus peut-on imaginer que la qualité de la régression (mesurée par exemple par R^2 pour n et p fixés) aurait été *légèrement* meilleure si l'on avait introduit des notes exactes, l'arrondi ayant pour effet de "casser" en partie les corrélations.

3.3.1 (*) Violation du modèle par autocorrélation des résidus

Il existe une cause possible toute différente de violation du modèle, pouvant se produire lorsque les n données sont constituées d'observations successives dans le temps (ou dans l'espace), comme dans le cas hypothétique où l'on voudrait "expliquer" Y_i = "chiffre d'affaire du i -ème mois", par X_i = "nombre de clients du i -ème mois" et par Z_i = "budget publicitaire du i -ème mois". Dans un tel cas, il se peut très bien que le jeu des décalages comptables ou celui de l'effet différé de la publicité rendent les résidus e_i corrélés aux résidus des mois suivants ou précédents. Pour établir la non-corrélation séquentielle des résidus (laquelle n'est pas visualisable dans le diagramme des résidus), on peut employer la variable de décision de Durbin-Watson

$$d := \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2} \quad (3.11)$$

qui doit être proche de 2 si les résidus sont non corrélés (les seuils critiques sont disponibles dans des tables spécialisées). Des valeurs de d fortement supérieures (inférieures) à 2 indiquent une autocorrélation négative (positive) entre résidus voisins⁶.

Dans l'exemple, la variable de décision de Durbin-Watson se trouve être égale à $d = 1.65$, qui non significatif. Le contraire eut été étonnant : comment en effet expliquer l'observation d'autocorrélations entre les résidus relatifs à des élèves qui se trouvent être *voisins relativement à leur numérotation de 1 à 50* ? Si l'on se refuse à attribuer des propriétés magiques particulières aux numéros assignés aux élèves, propriétés influençant leurs notes, il faudrait, le cas échéant, connaître la nature de l'ordre reflété par la numérotation. Il pourrait s'agir d'un ordre spatial (des numéros voisins étant spatialement adjacents) : on aurait alors peut-être affaire à un cas de tricherie, certains élèves copiant leur voisin (autocorrélation positive) ou simplement à un assignement contrôlé par l'enseignant, plaçant par exemple à chaque table un élève "fort" et un élève "faible" (autocorrélation négative). Il pourrait s'agir d'un ordre temporel (les numéros correspondant à l'ordre d'examen oral) : ceci indiquerait peut-être des cycles de performances variables au cours d'une journée, ou bien des cycles de fatigue ou d'humeur de la part des examinateurs. Ou bien encore de données falsifiées de façon suffisamment maladroite pour exhiber une autocorrélation résiduelle trahissant ainsi leur origine.

3.3.2 (*) Transformation des variables


Quel type de transformation doit-on choisir en vue de linéariser le problème (cf. section 3.3) ? Deux situations sont à distinguer :

1. il se peut (c'est l'exception en sciences humaines) que le chercheur dispose d'un modèle théorique *a priori*, lui indiquant alors du même coup quelle transformation est à même de mieux linéariser la situation.

Par exemple, le *modèle gravitaire* en géographie humaine a pour objet la relation entre

- d'une part le *flux normalisé* n_{jk} de la région j vers la région k (tel que le nombre de migrants du pays j vers le pays k , ou le nombre de pendulaires habitant la commune j et travaillant sur la commune k , divisé par les flux totaux sortants de j et entrants dans k)
- d'autre part la *distance effective* d_{jk} entre les régions j et k (prenant en compte la facilité d'accès, la longueur et le coût du voyage).

6. il s'agit de "voisins dans le temps". La problématique de l'autocorrélation spatiale, **centrale** en géosciences, nécessite l'introduction de la notion de "voisins dans l'espace", et généralise la variable de décision de Durbin-Watson à des indices tels que le "I de Moran" ou le "c de Geary" .

FIGURE 3.7 – distance de Cook pour chacun des $n = 50$ individus

Deux modèles gravitaires particulièrement populaires sont (pour $j \neq k$) :

$$n_{jk} = A \exp(-Bd_{jk}) \quad \text{modèle exponentiel} \qquad n_{jk} = \alpha d_{jk}^{-\beta} \quad \text{modèle algébrique} \quad (3.12)$$

où A , B , α , β sont des paramètres positifs à déterminer. La relation entre les n_{jk} et d_{jk} n'est linéaire dans aucun des deux modèles (3.12). On peut cependant la linéariser dans le modèle exponentiel par la transformation $y_i := \ln n_{jk}$ et $x_i := d_{jk}$, ce qui donne la relation *linéaire* $y_i = ax_i + b$ avec $a := -B$ et $b := \ln A$. Cette relation déterministe (concernant des individus $i \equiv (j, k)$ qui sont ici constitués de couples ordonnés de régions) a toutes les chances d'être réfutée à moins de lui ajouter un terme d'erreur e_i . On aboutit alors au modèle familier de régression linéaire simple $y_i = ax_i + b + e_i$ que l'on peut traiter de façon habituelle (même si la normalité de la distribution des e_i est loin d'être garantie). De même, la transformation $y_i := \ln n_{jk}$ et $x_i := \ln d_{jk}$ transforme le modèle algébrique en modèle linéaire $y_i = \tilde{a}x_i + \tilde{b}$ avec $\tilde{a} = -\beta$ et $\tilde{b} = \ln \alpha$, ce qui donne $y_i = \tilde{a}x_i + \tilde{b} + e_i$ avec l'adjonction des résidus. Il est même possible de comparer la qualité de l'ajustement ("goodness of fit") des deux modèles aux données en calculant la variance expliquée par ces derniers. On trouve par exemple $R = 0.55$ pour le modèle exponentiel et $R = 0.75$ pour le modèle algébrique appliqué au cas des flux pendulaires dans les 385 communes du canton de Vaud, après suppression des flux nuls⁷ : le modèle gravitaire algébrique explique donc $(0.75)^2 = 56\%$ de la variance totale des flux, ce qui est assez remarquable au vu de l'aspect rudimentaire du modèle. Après avoir effectué une régression linéaire, la transformation inverse permet d'estimer le paramètre β du modèle algébrique qui vaut environ $\beta = 1.6$: on en déduit qu'en doublant la distance, les flux normalisés n_{jk} décroissent donc d'un facteur d'environ $2^{-1.6} = 0.33$.

2. en l'absence d'a priori théoriques susceptibles d'être formulés par une relation fonctionnelle précise (c'est le cas général en sciences humaines), il ne reste qu'à procéder de façon heuristique pour déterminer la "bonne" transformation, par tâtonnement : par exemple, on pourra considérer la transformation $x'_1 = \sqrt{x_1}$ si l'on suspecte que y dépend linéairement de x_1^2 plutôt que de x_1 , ou l'on utilisera la transformation $y' = y/x_1$, $x'_1 = 1/x_1$ lorsque l'on peut suspecter que $\text{var}(e) \propto x_1^2$.


On peut également tester toute une classe de transformations (par exemple, les transformations en puissance avec un exposant variable, dites transformations de Box-Cox) puis sélectionner la transformation particulière qui semble la mieux ajustée.

Une autre transformation populaire est la transformation logarithmique $y' = \log y$ permettant de "rectifier" un nuage de points trop convexe (parabolique ou exponentiel), accompagnée ou non d'une transformation logarithmique $x' = \log x$ des prédicteurs, comme dans la "loi de Zipf" reliant la taille ou l'effectif (d'une ville, d'un mot, d'une espèce) avec le rang de l'individu.

3.3.3 (*) Identification des observations influentes

Il n'est jamais garanti a priori qu'il existe une "bonne" transformation des variables permettant de satisfaire les hypothèses de travail. En particulier, s'il existe des observations aberrantes ou extrêmes (outliers), ces

7. Sylvie Roman "Régionalisation : différentes analyses de flux" mémoire IGUL/UNIL, 1996

FIGURE 3.8 – valeur de levier pour chacun des $n = 50$ individus

dernières le resteront après transformation. Il est donc désirable de pouvoir identifier les individus particulièrement influents dans la détermination du coefficient de corrélation R et des coefficients de régression b_j , à la suite de quoi il s'agira de décider s'il est désirable ou non de conserver ces observations. Deux mesures d'influence (du i -ème individu) souvent utilisées sont

- la *distance de Cook*, D_i^C , mesurant (le carré de) la distance standardisée entre le vecteur des coefficients de régression b obtenu à partir de toutes les observations et le vecteur des coefficients de régression $b_{[-i]}$ obtenu à partir de toutes les observations sauf la i -ème. Un D_i^C grand (typiquement $D_i^C \geq 1$) indique une influence anormalement élevée de l'individu i sur les paramètres estimés du modèle : si tel est le cas, les coefficients de régression changeront substantiellement si l'individu i est exclu des données.
- la *distance de Mahalanobis* D_i^M , mesurant le carré de la distance euclidienne “multi-standardisée” entre le vecteur des p scores prédictors $(x_{i1}, \dots, x_{ip})$ du i -ème individu et le vecteur des p scores moyens $(\bar{x}_1, \dots, \bar{x}_p)$. Un D_i^M élevé dénote un individu i dont les scores prédictors sont extrêmes (sur une ou plusieurs dimensions), i.e. éloignés du nuage de points formé par les prédictors associés aux autres individus. La *valeur de levier* (leverage value) est définie comme $\frac{1}{n-1} D_i^M$ et constitue une autre mesure d'influence (des prédictors standardisés de l'individu i sur les prédictors standardisés des autres individus) d'usage courant ; sa valeur maximale de $\frac{n}{n-1}$ est atteinte lorsque tous les scores des individus sont identiques pour chaque variable, à l'exception de l'individu i .

3.4 (*) Diagnostics de collinéarité

En plus des difficultés d'interprétation qu'il génère, le phénomène de collinéarité (dont la présence ne viole cependant aucune hypothèse de travail, à strictement parler) aboutit, lorsqu'il est prononcé, à des valeurs instables des b_j (et des β_j) : comme on peut le visualiser sur la figure 2.5, si deux prédictors X_j et X_k sont de directions très proches, la position de l'hyperplan M tout entier tendra à dépendre très fortement du détail de la position relative de X_j et X_k : le changement d'un seul score suffira alors à modifier notablement la position de l'hyperplan M , et partant, la valeur des coefficients de régression b_j . Il s'agit du même type d'instabilité qui rend difficile le contrôle de la position d'un plateau horizontal soutenu par des baguettes horizontales, lorsque ces dernières sont rapprochées et de directions proches. En conclusion, la présence d'une forte collinéarité entre prédictors rend les coefficients de régression b_j fortement dépendants des détails de l'échantillon, d'où de grands intervalles de confiance b_j^{th} dans un tel cas. Toutes choses (n , p , R^2 , α) étant égales par ailleurs, la taille de ces intervalles est proportionnelle à (la racine carrée de) la variance théorique $\text{Var}(b_j^{\text{th}})$, elle-même proportionnelle à $\frac{1}{1-R_j^2}$, où

$$R_j^2 := R_{X_j, (X_1, \dots, X_{j-1}, X_{j+1}, \dots, X_p)}^2 \quad (3.13)$$

est le carré de la corrélation multiple entre X_j et les autres $p-1$ prédictors. Un R_j^2 trop élevé signifie que X_j est trop bien expliqué par les autres prédictors, i.e. que la collinéarité de X_j avec l'ensemble des autres

----- Variables in the Equation -----							
Variable	B	SE B	Beta	Tolerance	VIF	T	Sig T
ALLEMAND	.286233	.138396	.359716	.414902	2.410	2.068	.0448
CHIMIE	.188528	.189703	.186572	.356113	2.808	.994	.3260
FRANCAIS	-.247401	.158248	-.221103	.627498	1.594	-1.563	.1255
HISTOIRE	.168763	.117980	.216300	.548910	1.822	1.430	.1600
MATHEMAT	.405277	.153241	.383765	.596072	1.678	2.645	.0115
PHILOSOP	.209712	.150843	.187035	.693471	1.442	1.390	.1718
PHYSIQUE	-.282715	.174201	-.262492	.479778	2.084	-1.623	.1121
(Constant)	1.239309	1.080225				1.147	.2578

FIGURE 3.9 – poids bêta, tolérance, et facteur d’inflation de la variance

prédicteurs est trop grande. La quantité $\frac{1}{1-R_j^2}$ est appelée *facteur d’inflation de la variance* ou VIF, et son inverse $1 - R_j^2$ *tolérance*.

La table 3.9 permet de comprendre pourquoi la significativité des coefficients de régression est inférieure pour la chimie ($p_{\text{chimie}} = .326$) qu’elle ne l’est pour la philosophie ($p_{\text{philosophie}} = .172$), alors bien même que leurs poids bêta sont sensiblement égaux ($\beta_{\text{chimie}} = \beta_{\text{philosophie}} = .187$) : le facteur d’inflation de la variance est en effet deux fois plus grand pour la chimie $\text{VIF}_{\text{chimie}} = 2.81$ qu’elle ne l’est pour la philosophie $\text{VIF}_{\text{philosophie}} = 1.44$; en clair, cela signifie que “chimie” est plus corrélée avec les autres prédicteurs que ne l’est “philosophie”.

En termes culinaires, il est plus difficile de simuler l’ingrédient “philosophie” que l’ingrédient “chimie” à l’aide des ingrédients restants (les autres prédicteurs), ce qui rend le recours à l’ingrédient “philosophie” d’autant plus incontournable, ce qu’atteste la significativité plus grande de sa “proportion d’usage dans la recette” b_j .

3.5 Résumé (très)

- La régression multiple permet de prédire la valeur y^* (variable dépendante) associée à une nouvelle observation x de profil $x_1, \dots, x_p$ (prédicteurs ou variables indépendantes), au moyen de la relation linéaire $y^* = \sum_{j=0}^p b_j x_j$, où les coefficients de régression b_j ont été calculés ou calibrés sur la base d’un échantillon d’apprentissage comportant n observations des variables dépendante et indépendantes.
- Il s’agit d’une technique d’apprentissage automatique (machine learning) *non supervisée*, i.e. pour laquelle on ignore dans quelle mesure la prédiction des valeurs y^* correspondant aux *nouvelles observations* est proche des valeurs observées ou non.
- Les tests principaux dans une régression multiple sont celui de la nullité de la corrélation théorique, et ceux de la nullité de chacun des coefficients de corrélation théoriques.
- Pour que ces tests soient applicables, il faut que les hypothèses de travail (linéarité, normalité et homoscedasticité) soient à peu près vérifiées, ce que l’on peut contrôler à l’aide d’un diagramme des résidus e en fonction de y^* . Il faut aussi que les résidus soient non auto-corrélés sérialement, ce que l’on peut contrôler à l’aide du test de Durbin-Watson.
- La présence de collinéarité, i.e. de corrélation entre les prédicteurs, peut compliquer considérablement le choix du meilleur modèle et l’interprétation de ses coefficients.
- Décider d’omettre ou d’inclure un prédicteur peut être dicté par des considérations d’ajustement (proportion de variance expliquée) ou de significativité, conditionnellement à la présence des autres prédicteurs.

3.6 Exercices et corrigés

Exercice 3.1

(voir sortie SPSS ci-après) un questionnaire est rempli par $n = 56$ fumeurs ; chaque individu répond à 8 questions dont les scores vont de 1 (=“pas du tout”) à 5 (=“tout à fait”). On essaie de prédire au moyen d’une régression linéaire multiple le score de la variable **CRAVING** = “avez-vous besoin de fumer après 24

heures d'abstinence ?" en fonction des raisons qui, selon l'individu, conduisent à fumer.

ANNEXE 1

**** MULTIPLE REGRESSION ****

CRAVING besoin de fumer après 24 heures d'abstinence
 PSY_SOC fumer pour des raisons psycho-social
 ORAL_GRA fumer pour le plaisir de la bouche
 RELAX fumer pour une relaxation plaisante
 STIMUL fumer pour les effets stimulants
 CALMING fumer pour les effets calmants
 NO_THINK fumer pour ne penser à rien
 REL_CRAV fumer pour satisfaire le besoin de fumer

Correlation Matrix:

	CALMING	CRAVING	NO_THINK	ORAL_GRA	PSY_SOC	REL_CRAV	RELAX	STIMUL
CALMING	1							
CRAVING	.00284	1						
NO_THINK	.24217	-.11110	1					
ORAL_GRA	.16189	-.34634	.15330	1				
PSY_SOC	.02050	-.36723	-.00754	.29704	1			
REL_CRAV	.11946	.56172	.04424	.02368	-.15682	1		
RELAX	.01486	-.04183	-.02770	.13853	-.06358	-.08594	1	
STIMUL	.31073	.03784	.27651	.17352	.04435	.09841	.09228	1

Dependent Variable: CRAVING

Indep. variables: CALMING NO_THINK ORAL_GRA PSY_SOC REL_CRAV RELAX STIMUL

Multiple R .70150
 R Square .49211
 Adjusted R Square .41804
 Standard Error 1.19043

Analysis of Variance

	DF	Sum of Squares	Mean Square
Regression	7	65.90696	9.41528
Residual	48	68.02162	1.41712

F = 6.64397 Signif F = .0000

----- Variables in the Equation -----

Variable	B	SE B	Beta	T	Sig T
CALMING	-.003750	.065621	-.006335	-.057	.9547
NO_THINK	-.088174	.088473	-.109203	-.997	.3239
ORAL_GRA	-.154878	.058154	-.299317	-2.663	.0105
PSY_SOC	-.180981	.101798	-.196473	-1.778	.0818
REL_CRAV	.349883	.068975	.538168	5.073	.0000
RELAX	.018424	.083005	.023491	.222	.8253
STIMUL	.053061	.078926	.075528	.672	.5046
(Constant)	2.655643	.792855		3.349	.0016

1. Que signifient le R , son carré et son carré ajusté ?
2. Quelle est l'interprétation de la colonne "Sum of Squares" dans le tableau "Analysis of Variance" ? Celle de "F" ? Celle de "Signif. F" ?
3. S'il fallait ne conserver qu'un seul prédicteur, lequel choisiriez-vous ?
4. S'il fallait ne supprimer qu'un seul prédicteur, lequel choisiriez-vous ?
5. Un individu a répondu "2" à toutes les questions, **CRAVING** excepté ; quelle valeur prédit-on pour ce dernier score ?
6. Comment définit-on le *diagramme des résidus* ? Quelle devrait être son allure si les hypothèses de travail (en vue d'appliquer une régression linéaire) étaient vérifiées ?

7. Peut-on affirmer à un niveau de signification $\alpha = 0.05$ que le coefficient de la variable ORAL_GRA est différent de zéro ? Et au niveau $\alpha = 0.01$?
8. Sans le calculer, pensez-vous que l'intervalle de confiance de niveau $1 - \alpha = 0.95$ du coefficient de la variable PSY_SOC contient la valeur zéro ?

Exercice 3.2

Vrai ou faux ? :

Soit le modèle linéaire $Y = b_0^{th} + b_1^{th}X_1 + b_2^{th}X_2 + \dots + b_p^{th}X_p + \epsilon$. Une régression linéaire sur les données nous permet d'estimer les coefficients simples $b_1, b_2, \dots, b_p$ qui composent l'équation prédictive $Y^* = b_0 + b_1X_1 + b_2X_2 + \dots + b_pX_p$. Si l'on pose $R = 0$, cela signifie :

- a) qu'aucun des coefficients simples n'est nul
- b) que l'un des coefficients simples est nul
- c) que tous les coefficients simples sont nuls
- d) que la variance résiduelle est nulle .

Exercice 3.3

Vrai ou faux ? : on considère trois variables x_1, x_2 et x_3 représentant des notes, sur une échelle de 0 à 10, obtenues par des étudiantes dans trois matières différentes durant leurs études, et y le premier salaire qu'elles ont obtenu après leurs études. On effectue une régression avec y comme variable dépendante et x_1, x_2 et x_3 comme prédicteurs. Si on change linéairement l'échelle des notes, de sorte qu'elles soient notées de 0 à 100, alors

- a) les coefficients de régression b_j vont diminuer
- b) le R^2 va rester identique
- c) les poids bêta β_j vont augmenter
- d) la covariance entre x_1 et x_2 va augmenter.

Exercice 3.4

On considère, pour chacun des 50 états des Etats-Unis, les statistiques 1973 des fréquences des délits répertoriés (par 100'000 habitants) pour les 7 délits suivants : meurtre, viol, braquage, agression, cambriolage, vol, auto (= vol d'un véhicule automobile). On effectue une régression linéaire multiple de $y = \text{meurtre}$ par les prédicteurs constitués par les autres variables.

Statistiques descriptives

	N	Minimum	Maximum	Moyenne	Ecart type
meurtre	50	.90	15.80	7.4440	3.86677
viol	50	9.00	51.60	25.7340	10.75963
braquage	50	13.30	472.60	124.0920	88.34857
agression	50	43.80	485.30	211.3000	100.25305
cambriolage	50	446.10	2453.10	1291.9040	432.45571
vol	50	1239.90	4467.40	2671.2880	725.90871
auto	50	144.40	1140.10	377.5260	193.39442

Matrice de corrélation

		meurtre	viol	braquage	agression	cambriolage	vol	auto
Corrélation	meurtre	1.000	.601	.484	.649	.386	.102	.069
	viol	.601	1.000	.592	.740	.712	.614	.349
	braquage	.484	.592	1.000	.557	.637	.447	.591
	agression	.649	.740	.557	1.000	.623	.404	.276
	cambriolage	.386	.712	.637	.623	1.000	.792	.558
	vol	.102	.614	.447	.404	.792	1.000	.444
	auto	.069	.349	.591	.276	.558	.444	1.000

Coefficients de régression^a

Modèle		Coefficients non standardisés		Coefficients standardisés	t	Sig.	Intervalle de confiance à 95,0% pour b	
		b	Erreur standard	bêta			Borne inférieure	Borne supérieure
1	(Constante)	5.570	1.474		3.780	.000	2.598	8.542
	viol	.160	.061	.444	2.607	.013	.036	.283
	braquage	.012	.006	.269	1.866	.069	-.001	.024
	agression	.011	.006	.281	1.819	.076	-.001	.023
	cambrilage	.002	.002	.251	1.213	.232	-.001	.006
	vol	-.003	.001	-.496	-2.984	.005	-.004	-.001
	auto	-.005	.003	-.242	-1.898	.064	-.010	.000

a. Variable dépendante : meurtre

ANOVA^a

Modèle		Somme des carrés	ddl	Carré moyen	F	Sig.
1	Régression	446.187	6	74.365	11.163	.000 ^b
	Résidu	286.456	43	6.662		
	Total	732.643	49			

a. Variable dépendante : meurtre
b. Prédicteurs : (Constante), auto, agression, vol, braquage, viol, cambrilage

Corrélation multiple^b

Modèle	R	R carré	R carré ajusté	Erreur standard de l'estimation
1	.780 ^a	.609	.554	2.58104

a. Prédicteurs : (Constante), auto, agression, vol, braquage, viol, cambrilage
b. Variable dépendante : meurtre

- Quel indicateur reflète la *qualité de l'ajustement* de la variable dépendante aux prédicteurs, dans l'échantillon ? Quelle est sa valeur ?
- Quel indicateur reflète la *qualité prédictive globale* du modèle, dans la perspective de l'étendre à d'autres données que celles de l'échantillon ? Quelle est sa valeur ?
- Quelles sont les hypothèses (H_0 et H_1) associées au test de la corrélation multiple ? Cette dernière est-elle significative au niveau $\alpha = 0.01$?
- Quelles sont les hypothèses (H_0 et H_1) associées au test de chacun des coefficients de régression (constante exceptée) ?
- Parmi les coefficients de régression (constante exceptée), le(s)quel(s) est(sont) significatif(s) au niveau $\alpha = 0.01$?
- Une certaine province canadienne compte, par 100'000 habitants, 10 délits annuels dans chacune des catégories **viol**, **braquage**, **agression**, **cambrilage**, **vol**, **auto**. En appliquant à cette province le modèle de régression calibré sur les données américaines, quelle est la fréquence attendue de **meurtre** (par 100'000 habitants) ?
- Et si une autre province canadienne comptait **zéro** délits annuels dans chacune des catégories **viol**, **braquage**, **agression**, **cambrilage**, **vol**, **auto**, vous attendriez-vous à une fréquence de **meurtre** de zéro ?
- Si vous ne deviez conserver qu'un seul prédicteur, lequel choisiriez-vous ?
- Si vous ne deviez supprimer qu'un seul prédicteur, lequel choisiriez-vous ?

Corrigé de la série 3

Exercice 3.1

- $R = \text{corr}(y^*, y) = \cos \alpha$ est le coefficient de corrélation multiple (où α est l'angle entre le vecteur des valeurs observées y et l'hyperplan M engendré par les prédicteurs $1, x_1, \dots, x_7$). $R^2 = \frac{\text{var}(y^*)}{\text{var}(y)}$ est la proportion de variance de y expliquée par les prédicteurs (dans l'échantillon) ; le " R^2 ajusté" est une estimation de cette dernière quantité *dans la population*. On a bien $R_{\text{ajusté}}^2 = \frac{(n-1)R^2 - p}{n-p-1} = \frac{55 \cdot 492 - 7}{56 - 7 - 1} = 0.418$
- La colonne "Sum of Squares" donne la décomposition exacte $n \text{ var}(y) = n \text{ var}(y^*) + n \text{ var}(e)$; F est le rapport $\frac{\frac{\text{var}(y^*)}{p}}{\frac{\text{var}(e)}{n-p-1}} = \frac{R^2}{1-R^2} \frac{n-p-1}{p}$ (plus il est grand, plus R^2 est grand) ; "Signif. F" est la *valeur p* associée au test $H_0 : "R^{\text{theo}} = 0"$.
- Il faudrait conserver **REL_CRAV**, le plus corrélé avec **CRAVING** (.56172)

4. Il faudrait supprimer **CALMING**, dont la valeur absolue du poids beta (= -.006335) est la plus petite (et dont la valeur p de .9547 est la plus élevée).
5. La valeur prédite serait de $2 \times (-.003750 - .88174 + \dots + .053061) + 2.655643 = 2.64$
6. Il s'agit du nuage de $n = 56$ points d'abscisses $y_i^* = \text{"valeur prédite"}$ et d'ordonnées $e_i = y_i - y_i^* = \text{"résidu"}$ (on trouve aussi la variante avec les valeurs prédites et résiduelles *standardisées*). Par construction, $\bar{e} = 0$ et $\text{corr}(y^*, e) = 0$. Si, de plus, les hypothèses de travail en vue d'appliquer une régression linéaire sont vérifiées, alors le nuage ne présente pas de courbure notable ($\rightarrow$ linéarité), pas de dispersion variant fortement avec y^* ($\rightarrow$ homoscedasticité) et des valeurs résiduelles e_i distribuées à peu près normalement autour de $\bar{e} = 0$ ($\rightarrow$ normalité).
7. Oui pour $\alpha = 0.05$. Non pour $\alpha = 0.01$
8. Oui, parce que le coefficient n'est pas significatif à 5%

Exercice 3.2

- a) Faux. Si aucun coefficient $b_1^{th}, \dots, b_p^{th}$ n'est nul, $R \neq 0$.
- b) Faux. Si un coefficient $b_1^{th}, \dots, b_p^{th}$ est nul et que les autres ne sont pas nuls, $R \neq 0$.
- c) Vrai. Si tous les coefficients $b_1^{th}, \dots, b_p^{th}$ sont nuls, $R = 0$.
- d) Faux. Si la variance résiduelle est nulle, $R = 1$.

Exercice 3.3

- a) Vrai : les coefficients de régression b_j vont diminuer d'un facteur 10 (sauf b_0 qui va rester constant)
- b) Vrai : R^2 , à l'instar des corrélations ou corrélations partielles en général, reste invariant par changement d'unité
- c) Faux : les poids bêta β_j restent inchangés (ils correspondent aux coefficients de régression b_j pour des variables standardisées, justement)
- d) Vrai : la covariance entre x_1 et x_2 va augmenter d'un facteur $10 \cdot 10 = 100$.

Exercice 3.4

- a) Il s'agit du R carré $R^2 = 0.609$
- b) Il s'agit du R carré ajusté $\hat{R}^2 = 0.554$
- c) $H_0 : R^{\text{theo}} = 0$ contre $H_1 : R^{\text{theo}} \neq 0$, avec $p = .000 < \alpha = 0.01$ (lu dans le tableau "ANOVA") : on rejette H_0 , i.e. la corrélation multiple est significative
- d) $H_0 : b_j^{\text{theo}} = 0$ contre $H_1 : b_j^{\text{theo}} \neq 0$
- e) Seul le coefficient b_{vo1} est significatif (i.e. significativement non nul), en vertu de $p = .005 < \alpha = 0.01$
- f) La fréquence attendue de **meurtre** (par 100'000 habitants) est de $5.570 + .160 \times 10 + .012 \times 10 + .011 \times 10 + .002 \times 10 - .003 \times 10 - .005 \times 10 = 7.34$
- g) Non, on s'attendrait à fréquence attendue de **meurtre** de $5.570 + .160 \times 0 + .012 \times 0 + .011 \times 0 + .002 \times 0 - .003 \times 0 - .005 \times 0 = 5.570$
- h) Il faudrait conserver **braquage**, qui est le plus corrélé à **meurtre**
- i) En raisonnant sur l'ajustement (grand R^2), il faudrait supprimer **auto**, dont la valeur absolu du poids bêta .242 est la plus faible ; en raisonnant sur la significativité des prédicteurs, il faudrait supprimer **auto**, dont la valeur p .232 est la plus grande.

Chapitre 4

L'analyse en composantes principales

4.1 Présentation générale

Lorsque p variables quantitatives $x_1, \dots, x_p$ sont corrélées entre elles, l'information qu'elles expriment ensemble possède de ce fait un certain degré de redondance. Dans un échantillon d'automobiles, la longueur, la largeur, le prix, la puissance et le poids sont positivement corrélés entre eux, phénomène évident pour quiconque ayant noté l'existence de "grandes" et de "petites" automobiles.

Cette redondance permet de *compresser* l'information initiale contenue dans les p variables au moyen d'un nombre $k < p$ de *facteurs*, qui sont des variables synthétiques *résumant au mieux* les variables de départ : au lieu de décrire entièrement le profil d'une automobile par p caractéristiques connues, on pourra le décrire de façon approchée (mais néanmoins précise, dans les cas favorables) au moyen de $k < p$ nouvelles caractéristiques, dont la signification reste à interpréter ("trouver un nom aux facteurs").

L'*analyse en composantes principales* (ACP) est une procédure multivariée descriptive qui consiste à
(1) transformer p variables corrélées $x_1, \dots, x_j, \dots, x_p$ en p nouvelles variables non corrélées ou *facteurs* $f_1, \dots, f_\alpha, \dots, f_p$. De façon équivalente, la matrice $(n \times p)$ des scores bruts X est transformée en matrice $(n \times p)$ des *scores factoriels* F , où

$$X = (x_1 | \dots | x_j | \dots | x_p) = (x_{ij}) \qquad F = (f_1 | \dots | f_\alpha | \dots | f_p) = (f_{i\alpha})$$

- (2) conserver les $k < p$ premiers facteurs seulement $f_1, \dots, f_k$. Il y a simplification des données (on passe de p variables à k facteurs) mais aussi perte d'information en général.
- (3) *interpréter* les facteurs (qui sont des combinaisons linéaires des variables de départ), i.e. leur donner une signification intuitive, les nommer. L'interprétation des facteurs sera basée
- i) sur les valeurs des scores factoriels $f_{i\alpha}$ des individus
 - ii) sur les valeurs des corrélations variables-facteurs $s_{j\alpha} := \text{corr}(x_j, f_\alpha)$ ou *saturation*s
 - iii) ou bien les deux à la fois.

Note : dans ce chapitre, les individus sont indicés par $i = 1, \dots, n$. Les variables sont indicées par $j = 1, \dots, p$. Les facteurs sont indicés par $\alpha = 1, \dots, k \leq p$.

L'opération (1) ci-dessus, fondée sur la décomposition spectrale, est entièrement automatique. Elle correspond à une *compression sans perte* : les données sont recodées en facteurs, et peuvent être entièrement reconstruites à partir de l'ensemble de ces derniers.

La procédure de sélection (2) est semi-automatique, et dépend ultimement du choix de l'utilisateur ; elle aboutit à une *compression avec perte* : les données ne peuvent plus en général être entièrement reconstituées à partir de $k < p$ facteurs seulement. Un utilisateur pourra privilégier la simplicité et conserver peu de

facteurs, tandis qu'un autre préférera perdre moins d'information et conserver davantage de facteurs – tout dépend du contexte, de l'objectif et du public visés.

L'interprétation (3) repose entièrement sur la clairvoyance et la connaissance du terrain de l'utilisateur. L'idéal, comme toujours, est d'identifier les structures présentes dans les données, sans tomber dans la sur-interprétation – un équilibre délicat à trouver.

Exemple 1 : sciences politiques : le comportement politique d'un individu au cours des p dernières votation peut être mesuré par des scores de type x_{ij} = “force d'adhésion de l'individu i à la proposition j ” ou bien “ $x_{ij} = 1$ si l'individu i vote oui à la votation j ”, et “ $x_{ij} = 0$ sinon”. Cherchant à positionner un échantillon de n individus dans un “espace politique” qui reste à définir, une politologue pourra effectuer une analyse en composantes principales permettant de représenter chaque individu par son score factoriel $f_{i\alpha}$ dans chacun des facteurs $\alpha = 1, \dots, k$ retenus. L'examen des saturations (des variables-votations sur les facteurs) permettra d'affiner l'interprétation de chacun des facteurs et de leur donner un nom, tel que f_1 = “positionnement sur l'axe politique gauche-droite”, f_2 = “conservatisme versus ouverture au changement”, f_3 = “préoccupations locales versus nationales”, etc...

Exemple 2 : psychologie : un psychologue postule l'existence de “capacités cognitives de base”, et voudrait les mettre en évidence à partir d'une batterie de p tests d'intelligence comprenant les variables x_1 = “test (ou sous-test) d'intelligence spatiale”, x_2 = “test d'intelligence numérique”, x_3 = “test d'intelligence verbale”, etc... Les résultats à ces tests sont généralement fortement corrélés. Effectuant une ACP, le psychologue extrait k facteurs $f_1, \dots, f_k$ qu'il pourra peut-être interpréter, le cas échéant, comme f_1 = “facteur d'intelligence générale” (= “facteur G”) (qui pourra expliquer disons 85% de la variabilité des données, dans un sens qui sera défini plus loin), f_2 = “facteur d'opposition spatial-verbal” (qui pourra expliquer 7% de la variabilité des données), etc... En conservant les deux premiers facteurs, $85\% + 7\% = 92\%$ de la variabilité des données sera expliquée (et 8% sera perdue), ce qui représente une excellente compression des données (surtout si p est grand).

Exemple 3 : linguistique : un linguiste cherche à caractériser les différences stylistiques entre n auteurs (ou plutôt entre n textes écrits par ces auteurs). Pour cela, il construit p indicateurs numériques tels que x_1 = “proportion du nombre d'adjectifs au nombre de substantifs”, x_2 = “proportion du nombre de propositions subordonnées au nombre total de propositions”, x_3 = “fluctuation moyenne (en proportion) de la longueur de la phrase”, etc. Suite à une ACP, ce linguiste extrait un premier facteur résumant par exemple 70% de la variabilité totale manifestée par ses indicateurs ; il pourra alors décider de conserver ce seul facteur, décrétant du coup que “les différences stylistiques observées entre auteurs sont représentables par un espace à une seule dimension, à condition de négliger 30% de la variabilité manifestée dans les indicateurs”. Il pourra également déterminer le score factoriel d'un nouvel auteur, et positionner ainsi ce dernier au côté des n auteurs d'origine sur ce continuum uni-dimensionnel.

Exemple 4 : géographie : on dispose de p indicateurs socio-économiques sur les $n = 309$ communes du canton de Vaud, tels que x_1 = “proportion d'actifs”, x_2 = “taux de chômage”, x_3 = “proportion d'étrangers”, x_4 = “proportion de contribuables au revenu imposable supérieur à 100'000.-”, etc.

Un premier facteur f_1 pourra par exemple s'interpréter (en vertu des scores factoriels des individus-communes et des saturations des variables-indicateurs) comme reflétant une opposition entre communes riches et pauvres, ou entre communes urbaines versus rurales. Un second facteur f_2 pourra caractériser la démographie, le logement, l'emploi, etc.

Trouver de bons noms de facteurs est un art difficile : le nom devraient évoquer le contenu des variables de départ tout en s'en distinguant, puisqu'un facteur est, par construction, une combinaison linéaire des variables de départ. On peut partiellement contourner la difficulté en utilisant le fait que les facteurs sont des *axes de différenciation entre individus* (voir section 4.5) en proposant des noms du type f_1 = “opposition entre A et B ”, f_2 = “opposition entre C et D ”, mais il faut que ces oppositions $A - B$ et $C - D$ soient

pensées par leur auteur comme indépendantes l'une de l'autre, puisque les facteurs sont, par construction, non corrélés.

4.2 Les bases de l'ACP

4.2.1 L'algorithme

Toute matrice symétrique carrée, telle que la matrice $(p \times p)$ de corrélation R , se décompose spectralement comme

$$R = U\Lambda U' \text{ où } U = (u_1|u_2|\dots|u_p) \text{ est orthogonale et } \Lambda = \text{diag}(\lambda) = \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \lambda_p \end{pmatrix} \text{ diagonale} \quad (4.1)$$

Si l'on ordonne la diagonale de Λ par valeurs décroissantes, i.e. $\lambda_1 \geq \dots \geq \lambda_\alpha \geq \dots \geq \lambda_p \geq 0$, la décomposition spectrale ci-dessus est alors unique, *au signe près des colonnes de U* : si par exemple $U = (u_1|u_2|\dots|u_p)$ est une solution, alors $\tilde{U} = (u_1|-u_2|\dots|u_p)$ est également une solution. La non-négativité de toutes les valeurs propres λ_α de R est une conséquence du caractère semi-défini positif de $R = \frac{1}{n}X^{s'}X^s$ (voir chapitre 1).

La décomposition spectrale de la matrice des corrélations entre variables constitue le coeur de l'ACP :

- 1) on effectue la décomposition spectrale $R = U\Lambda U'$, où $\Lambda = \text{diag}(\lambda)$ est diagonale et contient les valeurs propres ordonnées de façon décroissante, et $U = (u_{j\alpha})$ est orthogonale et contient les vecteurs propres de R .

- 2) le score factoriel de l'individu i sur le facteur α est défini comme

$$f_{i\alpha} := \sum_j x_{ij}^s u_{j\alpha} \quad \text{i.e.} \quad F = (f_{i\alpha}) = X^s U$$

où $x_{ij}^s = (x_{ij} - \bar{x}_j)/s_j$ est le score standardisé de l'individu i sur la variable j .

- 3) par construction, les scores factoriels sont centrés et non corrélés :

$$\bar{f}_{i\alpha} = 0 \quad \text{corr}(f_\alpha, f_\beta) = 0 \quad \text{si} \quad \alpha \neq \beta \quad \text{var}(f_\alpha) = \lambda_\alpha$$

- 4) la variance totale à expliquer est

$$\sum_{j=1}^p \text{var}(x_j^s) = \sum_{j=1}^p 1 = p = \sum_{\alpha=1}^p \text{var}(f_\alpha) = \sum_{\alpha=1}^p \lambda_\alpha$$

Ainsi, λ_α/p est la proportion de variance totale expliquée par le facteur α .

- 5) la saturation $s_{j\alpha} := \text{corr}(x_j, f_\alpha)$ de la variable j sur le facteur α est $s_{j\alpha} = u_{j\alpha}\sqrt{\lambda_\alpha}$ (i.e. $S = U\sqrt{\Lambda}$) et satisfait

$$\sum_{j=1}^p s_{j\alpha}^2 = \lambda_\alpha \quad \sum_{\alpha=1}^p s_{j\alpha}^2 = 1 \quad \sum_{\alpha=1}^p s_{j\alpha} s_{k\alpha} = r_{jk} \quad \text{i.e.} \quad R = SS'$$

Ainsi, $s_{j\alpha}^2$ est la proportion de variance de x_j expliquée par le facteur α .

- 6) en gardant $k < p$ facteurs, la variance de la variable j expliquée par les k premiers facteurs définit sa *communalité* $h_j^2 := \sum_{\alpha=1}^k s_{j\alpha}^2 \leq 1$.
- 7) on représente l'individu i dans l'espace des premiers facteurs $\alpha = 1, \dots, k$ par ses scores factoriels $f_{i\alpha}$. On représente la variable x_j dans l'espace des k premiers facteurs par ses saturations $s_{j\alpha}$. Par construction, $\sum_{\alpha=1}^k s_{j\alpha}^2 \leq 1$, i.e. les coordonnées des variables sont à l'intérieur du "cercle des corrélations" (de centre 0 et de rayon 1).

4.2.2 Un exemple

Considérons les données `motiv_psycho` du chapitre 2 (“pourquoi faites-vous des études de psychologie ?”). La matrice (7×7) des corrélations R était

$$R = \begin{pmatrix} 1.00 & -0.03 & 0.06 & 0.007 & 0.17 & 0.17 & -0.02 \\ -0.03 & 1.00 & 0.25 & 0.16 & -0.03 & 0.33 & -0.05 \\ 0.06 & 0.25 & 1.00 & 0.36 & 0.23 & 0.40 & 0.04 \\ 0.007 & 0.16 & 0.36 & 1.00 & -0.11 & 0.35 & 0.18 \\ 0.17 & -0.03 & 0.23 & -0.11 & 1.00 & 0.04 & -0.08 \\ 0.17 & 0.33 & 0.40 & 0.35 & 0.04 & 1.00 & -0.06 \\ -0.02 & -0.05 & 0.04 & 0.16 & -0.08 & -0.06 & 1.00 \end{pmatrix} \quad (4.2)$$

Sa décomposition spectrale $R = U\Lambda U'$ donne

$$U = (u_1|u_2|\dots|u_7) = \begin{pmatrix} -.139 & -.501 & .310 & .707 & -.202 & -.191 & -.237 \\ -.398 & .116 & -.464 & -.092 & -.703 & -.331 & -.025 \\ -.537 & -.129 & .123 & -.370 & .169 & .224 & -.682 \\ -.466 & .340 & .236 & .076 & .434 & -.611 & .211 \\ -.095 & -.671 & .222 & -.51 & -.070 & -.175 & .443 \\ -.554 & -.026 & -.143 & .277 & .067 & .601 & .479 \\ -.032 & .391 & .740 & -.110 & -.489 & .198 & .089 \end{pmatrix} \quad (4.3)$$

On peut vérifier que U (dont les colonnes sont les vecteurs propres de R , appelés aussi *composante principales* dans ce contexte) est orthogonale, en utilisant l'un des trois critères équivalents : suivants :

- la transposée U' de U est égale à son inverse U^{-1} , i.e. $UU' = I$.
- les lignes de U sont orthogonales entre elles et de norme unité.
- les colonnes de U sont orthogonales entre elles et de norme unité.

La matrice diagonale Λ contient les valeurs propres ordonnées de façon décroissante, qui sont $\lambda_1 = 1.957$, $\lambda_2 = 1.279$, $\lambda_3 = 1.066$, $\lambda_4 = .922$, $\lambda_5 = .762$, $\lambda_6 = .530$ et $\lambda_7 = .483$. Ces valeurs propres constituent les variances des scores factoriels ($\lambda_\alpha := \text{var}(f_\alpha)$) et leur somme vaut $p = 7$. Ainsi, le premier facteur explique $1.957/7 = .279 = 28\%$ de la variance totale, le second facteur explique $1.279/7 = .183 = 18\%$ de la variance totale, etc.

Pour pouvoir interpréter les facteurs et les nommer, on examine la matrice des saturations $S = (s_{j\alpha})$ entre variables et facteurs, où $s_{j\alpha} := \text{corr}(x_j, f_\alpha)$. Dans l'exemple (et après avoir changé u_1 en $-u_1$ pour faciliter les interprétations à venir)

$$S = \begin{pmatrix} .194 & .567 & .320 & .679 & .177 & .139 & .165 \\ .557 & -.131 & -.480 & -.088 & .613 & .241 & .018 \\ .751 & .146 & .127 & -.355 & -.148 & -.163 & .474 \\ .652 & -.384 & .244 & .073 & -.379 & .445 & -.147 \\ .133 & .758 & .229 & -.490 & .061 & .127 & -.308 \\ .775 & .030 & -.147 & .266 & -.059 & -.438 & -.333 \\ .045 & -.443 & .765 & -.105 & .427 & -.144 & -.062 \end{pmatrix} \quad (4.4)$$

où chaque ligne est associée à une variable et chaque colonne à un facteur. Si l'on retient $k = 2$ facteurs seulement (qui expliquent une proportion de $28\% + 18\% = 46\%$ de variance), on peut représenter les 7 variables dans le cercle des corrélations (figure 4.1). L'équation $\sum_{\alpha=1}^p s_{j\alpha}^2 = 1$ peut s'interpréter comme celle d'une hypersphère de rayon unité et de centre origine à p dimensions, de même que $x^2 + y^2 = 1$ est l'équation du cercle unité à deux dimensions, ou que $x^2 + y^2 + z^2 = 1$ est l'équation de la sphère unité à trois dimensions. Ainsi, la communalité $h_j^2 = \sum_{\alpha=1}^r s_{j\alpha}^2$ est le carré de la distance au centre du point représentant x_j dans les k premières dimensions, et constitue la proportion de variance de x_j expliquée par les k premiers facteurs.

Dans l'exemple ($k = 2$), les communalités valent




FIGURE 4.1 – cercle des corrélations : chaque variable x_j est représentée par ses coordonnées s_{j1} et s_{j2} (saturations)




FIGURE 4.2 – scores factoriels f_1 et f_2 des $n = 109$ individus, normalisés à $\bar{f}_\alpha = 0$ et $\text{var}(f_\alpha) = \lambda_\alpha$

Variable x_j	Communalité h_j^2 (facteurs f_1 et f_2)
x_1	.359
x_2	.327
x_3	.585
x_4	.573
x_5	.592
x_6	.602
x_7	.198

On constate que la variable x_7 est très mal représentée (plus de 80% de variance inexpliquée) et que x_1 et x_2 sont médiocrement représentées par les deux premiers facteurs. Pour interpréter ces derniers, on retiendra seulement les variables dont la communalité n'est pas trop petite. Au vu de la signification des variables x_3 , x_4 et x_6 (chapitre 2), bien corrélées avec le premier facteur f_1 , on pourrait baptiser $f_1 = \text{“motivation consciente en tant que défi lancé à soi-même”}$. Par contraste, le second facteur f_2 , pratiquement corrélé avec x_5 seulement (et légèrement avec x_1), pourrait être nommé *“doute et motivation diffuse dans le choix de la filière d'études”*. Ainsi, les sujets de l'étude se caractériseraient en premier lieu par une motivation personnelle plus ou moins élevée, et en second lieu, et indépendamment (puisque f_1 et f_2 ne sont pas corrélés), par un doute plus ou moins élevé sur leur choix. Cette caractérisation sommaire en $k = 2$ facteurs plutôt qu'en $p = 7$ variables ne conserve que 46% de la variance totale, ce qui est assez médiocre.




FIGURE 4.3 – diagramme des valeurs propres ou “scree graph”

La figure 4.2 donne le diagramme de dispersion des deux premiers scores factoriels : on constate que *le diagramme seul ne permet pas d'interpréter les facteurs*, en l'absence d'une *méta-information* sur les individus, qui fournirait, en plus des scores bruts des variables $x_1, \dots, x_7$ sur lesquelles l'ACP a été effectuée, d'autres indications telles que l'âge, le sexe ou le parcours scolaire des individus.

4.2.3 Combien de facteurs faut-il retenir ?

Retenir tous les p facteurs équivaut à garder toute l'information initiale, sans contribuer à simplifier la structure des liaisons entre variables. Inversement, ne garder qu'un petit nombre de facteurs risque d'aboutir à n'expliquer qu'un pourcentage trop faible de variance totale, et donc à résumer de façon excessive la complexité de la structure des liaisons entre variables à *moins que quelques facteurs seulement suffisent à expliquer une proportion importante de la variance totale* : on a là affaire à un dilemme typique entre les objectifs opposés de “conservation de l'information” et de “nécessité de simplifier l'information”. La résolution du dilemme dépendra des préférences et des besoins de l'utilisateur : c'est ce dernier qui décidera du choix du nombre k des facteurs à retenir. Il peut être aidé dans sa décision par la considération d'un certain nombre de “critères”, parmi lesquels :

- 1) s'arrêter dès que la proportion expliquée cumulée de la variance atteint une proportion fixée, par exemple 90% (“critère” de “Joliffe”).
- 2) ne garder que les valeurs propres $\lambda_1, \dots, \lambda_k$ supérieures à la moyenne $\frac{1}{p}(\lambda_1 + \dots + \lambda_p)$ (“critère” de “Kaiser”). Si l'on travaille avec la matrice des corrélations, cela revient à exclure les valeurs propres inférieures à 1.
- 3) faire un “scree graph” (scree = éboulis) consistant à représenter les λ_α en fonction de α (figure 4.3). Souvent, un “coude” apparaît, marquant un changement de régime dans la décroissance des valeurs propres. Ne garder alors que les valeurs propres apparaissant *avant* l'apparition du coude (“critère” de “Cattell”) : par construction, les valeurs propres suivantes sont d'importance proche (et faible) : il serait ainsi peu justifié d'en conserver certaines mais pas les autres.
- 4) tester l'hypothèse H_0^k : “ $\lambda_{k+1}^{\text{th}} = \lambda_{k+2}^{\text{th}} = \dots = \lambda_p^{\text{th}}$ ” que les $(p-k)$ dernières valeurs propres de la matrice de corrélation théorique R^{th} sont identiques¹ : si tel était le cas, il faudrait les éliminer toutes (ou les conserver toutes), en suivant le même raisonnement qu'en 3).


1. (*) on peut tester successivement H_0^k en posant $k = p-1$, puis $k = p-2$ etc..., et laisser tomber les dernières valeurs propres jusqu'à ce que l'hypothèse soit rejetée. La variable de décision est :

$$d^k = (n - \frac{2p+11}{6})(p-k) \ln(\frac{a_k}{g_k}) \quad (4.5)$$

où a_k et g_k sont les moyennes arithmétiques et géométriques des dernières valeurs propres :

$$a_k = \frac{\lambda_{k+1} + \lambda_{k+2} + \dots + \lambda_p}{p-k} \quad g_k = \sqrt[p-k]{\lambda_{k+1} \lambda_{k+2} \dots \lambda_p} \quad (4.6)$$

L'inégalité dite “arithmétique-géométrique” $g_k \leq a_k$ est toujours vérifiée. Il y a égalité $g_k = a_k$ ssi les dernières valeurs propres sont toutes égales ($\lambda_{k+1} = \lambda_{k+2} = \dots = \lambda_p$). Sous H_0^k , $d^k \sim \chi^2[\frac{1}{2}(p-k)(p-k-1)]$ pour un échantillon suffisamment grand.

FIGURE 4.4 – cercle des corrélations pour $k = p = 2$

Lorsque $k = 0$, H_0 est l'hypothèse que *toutes* les valeurs propres de la matrice sont identiques, ce qui est le cas ssi les corrélations entre variables sont nulles, i.e. ssi $R^{\text{th}} = I$, où I est la matrice identité ($p \times p$). Le test correspondant est appelé *test de sphéricité* (ou test de Bartlett).

4.2.4 (*) Exemple : ACP sur deux variables

Il est rare que l'on effectue une ACP avec moins de $p = 4$ variables, et l'exemple qui suit ($p = 2$) n'est pas réaliste en pratique, mais permet d'expliciter les mécanismes algébriques oeuvrant dans l'ACP. En appliquant une décomposition spectrale à la matrice de corrélation

$$R = \begin{pmatrix} 1 & r \\ r & 1 \end{pmatrix} = U \Lambda U' = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} 1+r & 0 \\ 0 & 1-r \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} \end{pmatrix} \quad (4.7)$$

on trouve les ve.p. $(u_1)' = \frac{1}{\sqrt{2}}(1, 1)$ et $(u_2)' = \frac{1}{\sqrt{2}}(1, -1)$ avec les va.p. associées $\lambda_1 = 1 + r$ et $\lambda_2 = 1 - r$. On a que $\lambda_1 > \lambda_2$ si $r > 0$, ce que nous supposons.

Le premier facteur explique une proportion de $\frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{1}{2}(1 + r)$ de la variance. Cette proportion vaut 100% si $r = 1$: dans ce cas en effet, il existe une relation de la forme $x_2 = ax_1 + b$ avec $a > 0$, autrement dit $x_1^s = x_2^s$: il est donc évident que l'on peut résumer la totalité de l'information par un seul facteur. Au contraire, si $r = 0$, alors chacun des facteurs explique une proportion de 50% de la variance totale.

Les facteurs f_1 et f_2 s'obtiennent comme les colonnes de $F = X^s U$:

$$f_1 = \frac{1}{\sqrt{2}}(x_1^s + x_2^s) \quad f_2 = \frac{1}{\sqrt{2}}(x_1^s - x_2^s) \quad (4.8)$$

Les variables x_1 et x_2 sont parfaitement représentées ($h_1^2 = h_2^2 = 1$) sur le cercle des corrélations dans le plan factoriel par les saturations $S = U \Lambda^{\frac{1}{2}}$ (figure 4.4) :

$$s_{11} = \text{corr}(x_1, f_1) = \sqrt{\frac{1+r}{2}} \quad s_{12} = \text{corr}(x_1, f_2) = \sqrt{\frac{1-r}{2}} \quad (4.9)$$

$$s_{21} = \text{corr}(x_2, f_1) = \sqrt{\frac{1+r}{2}} \quad s_{22} = \text{corr}(x_2, f_2) = -\sqrt{\frac{1-r}{2}} \quad (4.10)$$

Plus r est grand (i.e. plus α est petit), plus les points représentatifs de x_1^s et x_2^s sont rapprochés. Lorsque $r = -1$ (i.e. $\alpha = 180^\circ$), les points sont en opposition.

KMO and Bartlett's Test			Communalities		
Kaiser-Meyer-Olkin Measure of Sampling Adequacy.			Initial	Extraction	
			1.000	.564	
Bartlett's Test of Sphericity			1.000	.488	
Approx. Chi-Square			1.000	.600	
df			1.000	.763	
Sig.			1.000	.555	
			1.000	.507	
			1.000	.815	
			1.000	.746	

Extraction Method: Principal Component Analysis.

Total Variance Explained						
Component	Initial Eigenvalues			Extraction Sums of Squared Loadings		
	Total	% of Variance	Cumulative %	Total	% of Variance	Cumulative %
1	3.825	47.811	47.811	3.825	47.811	47.811
2	1.212	15.156	62.967	1.212	15.156	62.967
3	.822	10.274	73.241			
4	.694	8.669	81.909			
5	.618	7.722	89.632			
6	.354	4.429	94.060			
7	.263	3.292	97.352			
8	.212	2.648	100.000			

Extraction Method: Principal Component Analysis.

FIGURE 4.5 – premières sorties d'une ACP avec SPSS

4.2.5 L'ACP avec SPSS

Une ACP sur la matrice des corrélations des $p = 8$ notes de français, géographie, physique, chimie, histoire, mathématiques, philosophie et allemand sur $n = 50$ élèves (données `huit_notes`) fournit avec SPSS la sortie représentée en figure 4.5, contenant ²

- la valeur du “KMO” (pas abordé ici)
- la significativité (forte) du test de Bartlett, comme c'est presque toujours le cas : les corrélations inter-variables sont significatives, il fait donc sens de procéder à une ACP.
- les valeurs propres λ_α (eigenvalues), la proportion de variance expliquée par ces dernières, et la proportion cumulée. Ici, le critère de Kaiser retient 2 facteurs (appelés “components”), avec les communalités h_j^2 correspondantes (colonne “extraction”). La colonne “initial” rappelle que l'ensemble de tous les facteurs donne par construction une communalité de 100%.

La figure 4.6 fournit les saturations $s_{j\alpha}$ (“component matrix”) sur les deux premiers facteurs, à partir desquelles les communalités $h_j^2 = s_{j1}^2 + s_{j2}^2$ peuvent être calculées. Dans SPSS, les scores factoriels sont par convention standardisés, i.e. définis par $f_\alpha^s := f_\alpha / \sqrt{\lambda_\alpha}$, où $f_{i\alpha} := \sum_j x_{ij}^s u_{j\alpha}$. Les coefficients permettant de transformer les scores standardisés de départ en scores factoriels standardisés sont donc donnés par $u_{j\alpha} / \sqrt{\lambda_\alpha}$ qui constituent la “component score coefficient matrix”. La “component score covariance matrix” rappelle que les scores factoriels sont ici standardisés ($\text{var}(f_\alpha^s) = 1$) et, comme il se doit, non corrélés ($\text{cov}(f_1^s, f_2^s) = 0$).

La figure 4.7 donne le “scree plot”, qui montre que seule la première valeur propre se dégage clairement des

2. Dans le cas de données manquantes, l'option “listwise” de SPSS consiste à calculer les corrélations à partir de toutes les paires disponibles, même si ces paires se rapportent à un individu possédant un score manquant par rapport à une troisième variable. Cette procédure, qui vise à conserver le plus d'information possible sur les corrélations, peut parfois aboutir à une matrice des corrélations qui n'est plus semi-définie positive, avec comme conséquence l'apparition de valeurs propres strictement négatives (mais de valeur absolues généralement petites). Ce phénomène peut affecter les dernières valeurs propres, sans compromettre sérieusement l'interprétation des premiers facteurs retenus.

Il faut également mentionner le cas atypique $n \leq p$, qui aboutit à la nullité des $p - n + 1$ dernières valeurs propres, sans que le caractère semi-défini positif de R , ni la possibilité de pratiquer une ACP ne soient remises en question.




FIGURE 4.6 – La “component matrix” donne les saturations ; la “component score covariance matrix” donne les coefficients transformant les scores standardisés x_i^s en facteurs standardisés f_α^s .




FIGURE 4.7 – “scree plot” et cercle des corrélations. Le premier facteur pourrait s’appeler “performance générale”. Le second facteur exprime une différenciation entre notes - difficile à nommer simplement.

autres. Les saturations de la figure 4.6 donnent les coordonnées des variables sur le cercle des corrélations (qui n’apparaît pas clairement comme tel dans SPSS).

4.3 (*) ACP sur la matrice de variance-covariance

Une variante de l’ACP consiste à décomposer spectralement la matrice de variance-covariance $\Sigma = \frac{1}{n} X^c X^c = (s_{jk})$ plutôt que la matrice de corrélation $R = \frac{1}{n} X^s X^s = (r_{jk})$:

- 1) on effectue la décomposition spectrale $\Sigma = U\Lambda U'$
- 2) le score factoriel de l'individu i sur le facteur α est

$$f_{i\alpha} := \sum_j x_{ij}^c u_{j\alpha} \quad \text{i.e.} \quad F = (f_{i\alpha}) = X^c U$$

où x_{ij}^c est le score centré de l'individu i sur la variable j .

- 3) par construction, les scores factoriels sont centrés et non corrélés :

$$\bar{f}_{i\alpha} = 0 \quad \text{corr}(f_\alpha, f_\beta) = 0 \quad \text{si} \quad \alpha \neq \beta \quad \text{var}(f_\alpha) = \lambda_\alpha$$

- 4) la variance totale à expliquer est

$$\sum_{j=1}^p \text{var}(x_j^c) = \sum_{j=1}^p \text{var}(x_j) = \sum_{\alpha=1}^p \text{var}(f_\alpha) = \sum_{\alpha=1}^p \lambda_\alpha$$

Ainsi, $\lambda_\alpha / (\lambda_1 + \dots + \lambda_p)$ est la proportion de variance totale expliquée par le facteur α .

- 5) la saturation $s_{j\alpha} := \text{corr}(x_j, f_\alpha)$ de la variable j sur le facteur α est $s_{j\alpha} = u_{j\alpha} \sqrt{\lambda_\alpha} / s_j$, où $s_j = \sqrt{\text{var}(x_j)}$ est l'écart-type de la variable x_j . Il satisfait

$$\sum_{j=1}^p \text{var}(x_j) s_{j\alpha}^2 = \lambda_\alpha \quad \sum_{\alpha=1}^p s_{j\alpha}^2 = 1 \quad \sum_{\alpha=1}^p s_{j\alpha} s_{k\alpha} = r_{jk} \quad \text{i.e.} \quad R = SS'$$

Ainsi, $s_{j\alpha}^2$ est la proportion de variance de x_j expliquée par le facteur α .

- 6) en gardant $k < p$ facteurs, la variance de la variable j expliquée par les k premiers facteurs définit sa *communalité* $h_j^2 := \sum_{\alpha=1}^k s_{j\alpha}^2 \leq 1$.
- 7) on représente l'individu i dans l'espace des premiers facteurs $\alpha = 1, \dots, k$ par ses scores factoriels $f_{i\alpha}$. On représente la variable x_j dans l'espace des k premiers facteurs par ses saturations $s_{j\alpha}$. Par construction, $\sum_{\alpha=1}^k s_{j\alpha}^2 \leq 1$, i.e. les coordonnées des variables sont à l'intérieur du "cercle des corrélations" (de centre 0 et de rayon 1).

Ainsi, une ACP sur les variances-covariances donne lieu à des propriétés très analogues à une ACP sur des corrélations, la différence essentielle étant que, dans la première, le poids de la variable x_j vaut $\text{var}(x_j) / (\text{var}(x_1) + \dots + \text{var}(x_p))$, tandis qu'il vaut $1/p$ (poids uniforme) lors d'une ACP ordinaire sur la matrice des corrélations. Aussi, les ve.p. et va.p. obtenus lors d'une ACP sur Σ sont en général complètement *différents* des ve.p. et va.p. obtenus lors d'une ACP ordinaire (sauf quand les variances $\text{var}(x_j)$ sont proches entre elles).

Une ACP sur la matrice de variance-covariance Σ peut faire sens lorsque les variables $x_1, \dots, x_p$ sont mesurées sur la même échelle (comme dans le cas de p notes scolaires, ou de p mesures étalées dans le temps d'une même quantité), et que l'on souhaite que le poids de chaque variable soit proportionnel à sa variance : s'il y a les notes lors d'un certain examen varient davantage que lors d'un autre examen, il peut valoir la peine de chercher à prendre davantage en considération le premier plutôt que le second examen.

Toutefois, une ACP sur la matrice Σ de variance-covariance devient simplement absurde si les variables possèdent des échelles différentes : dans le cas du profil d'une automobile, les poids des variables de longueur deviendraient par exemple 10'000 fois plus petites par rapport aux poids des autres variables si l'on changeait l'unité de mesure de centimètres en mètres (puisque $\text{var}(x[\text{cm}]) = 10'000 \text{var}(x[\text{m}])$). Il faudrait naturellement *standardiser au préalable* les variables dans un tel cas (les transformant ainsi en quantités sans dimension), mais ceci revient précisément à effectuer une ACP sur la matrice R des corrélations, justement.

L'ACP ordinaire sur R résout ce problème, mais il faut garder à l'esprit que la construction des facteurs va forcément refléter la contribution identique de chacune des variables de départ (poids uniforme) : en choisissant les p variables sur lesquelles il va effectuer une ACP ordinaire, l'utilisateur doit être conscient qu'il donne d'entrée de jeu un poids identique à chacune des p variables sélectionnées. Par exemple, une

Component Matrix ^a				
	Raw		Rescaled	
	Component		Component	
	1	2	1	2
FRANCAIS	.884	.655	.531	.393
GEOGRAPHIE	1.285	.259	.689	.139
PHYSIQUE	1.236	-.014	.714	-.008
CHIMIE	1.564	.153	.847	.083
HISTOIRE	1.922	-.376	.804	-.157
MATHEMATIQUES	1.072	.808	.607	.457
PHILOSOPHIE	.428	1.313	.257	.789
ALLEMAND	1.939	-.949	.827	-.405

Extraction Method: Principal Component Analysis.
^a. 2 components extracted.

Communalities				
	Raw		Rescaled	
	Initial	Extraction	Initial	Extraction
FRANCAIS	2.779	1.211	1.000	.436
GEOGRAPHIE	3.480	1.719	1.000	.494
PHYSIQUE	3.000	1.528	1.000	.509
CHIMIE	3.408	2.469	1.000	.725
HISTOIRE	5.716	3.834	1.000	.671
MATHEMATIQUES	3.120	1.801	1.000	.577
PHILOSOPHIE	2.768	1.908	1.000	.690
ALLEMAND	5.496	4.659	1.000	.848

Extraction Method: Principal Component Analysis.

FIGURE 4.8 – saturations (gauche) et communalités (droite) d'une ACP sur Σ

Total Variance Explained							
		Initial Eigenvalues ^a			Extraction Sums of Squared Loadings		
	Component	Total	% of Variance	Cumulative %	Total	% of Variance	Cumulative %
Raw	1	15.191	51.035	51.035	15.191 3.939	51.035 13.235	51.035 64.27
	2	3.939	13.235	64.270			
	3	3.124	10.494	74.764			
	4	2.313	7.772	82.536			
	5	2.161	7.261	89.797			
	6	1.402	4.709	94.506			
	7	.906	3.045	97.551			
	8	.729	2.449	100.000			
Rescaled	1	15.191	51.035	51.035	3.748	46.844	46.844
	2	3.939	13.235	64.270	1.202	15.021	61.86
	3	3.124	10.494	74.764			
	4	2.313	7.772	82.536			
	5	2.161	7.261	89.797			
	6	1.402	4.709	94.506			
	7	.906	3.045	97.551			
	8	.729	2.449	100.000			

Extraction Method: Principal Component Analysis.

^a. When analyzing a covariance matrix, the initial eigenvalues are the same across the raw and rescaled solution.

FIGURE 4.9 – Valeurs propres λ_α de la matrice Σ (“total”) et pourcentage de variance expliquée $\lambda_\alpha/(\lambda_1 + \dots + \lambda_p)$ (“% of variance”). Les sommes $\sum_j \text{var}(x_j) s_{j\alpha}^2 = \lambda_\alpha$ donnent les valeurs propres (“raw sums”), tandis que les “rescaled sums” $\sum_j s_{j\alpha}^2$ (biffées ici) ne possèdent pas d’interprétation statistique directe.

étude des communes jurassiennes par une ACP sur une matrice de corrélation entre 30 variables, dont 10 sont de type géomorphologique et 20 sont de type socio-économique, reflètera forcément le choix implicite de pondérer les descripteurs géographiques physiques versus humains dans une proportion 1/3 versus 2/3.

4.3.1 (*) Exemple (suite)

Pratiquée sur la matrice de variance-covariance Σ , l'ACP produite avec SPSS donne (figure 4.8) les saturations $s_{j\alpha} := \text{corr}(x_j, f_\alpha)$ (“rescaled component matrix”), dont le carré est le pourcentage de variance de x_j expliqué par le facteur f_α . La somme des carrés des quantités $\sqrt{\text{var}(x_j)} s_{j\alpha} = u_{j\alpha} \lambda_\alpha$ (“raw component matrix”) fournit les variances ($\sum_{\alpha=1}^p \text{var}(x_j) s_{j\alpha}^2 = \text{var}(x_j)$) figurant dans le tableau “raw communalities, initial”, et leur somme sur les k premiers facteurs est contenue dans la colonne “raw communalities, extraction”. La figure 4.9 donne de même les sommes des $s_{j\alpha}^2$ (“rescaled”) et des $\text{var}(x_j) s_{j\alpha}^2$ (“raw”) sur les variables $j = 1, \dots, p$.

4.4 Les rotations

Par construction, les facteurs f_α sont des abstractions mathématiques et ne possèdent pas nécessairement de signification intuitive. L'interprétation des facteurs serait facilitée si les $s_{j\alpha}$ étaient soit grandes (i.e. proches de 1 en valeur absolue), soit proches de zéro : on saurait alors à quelle(s) variable(s) correspondrait principalement un facteur donné. Pour cela, on peut effectuer une rotation des facteurs par $\tilde{F} := FG$, où G est une matrice orthonormale. Le problème est que les nouveaux “facteurs” $\tilde{f}_1, \tilde{f}_2, \dots$ sont des combinaisons linéaires des facteurs $f_1, f_2, \dots$ ou, de façon équivalente, $\tilde{F} = X^s \tilde{U}$, avec $\tilde{U} = UG$, et que les colonnes de $\tilde{U}$ ne sont plus vecteurs propres d'une matrice simple telle que Σ ou R . La corrélation des variables de départ avec les nouveaux facteurs définit les composantes $\tilde{s}_{j\alpha} := \text{corr}(x_j, \tilde{f}_\alpha)$ de la nouvelle matrice des saturations $\tilde{S} = SG$.

Il existe différents critères (les plus utilisés portant les noms de *varimax*, *quartimax*, ou *equamax*) pour l'obtention d'une matrice de rotation G telle que $\tilde{S}$ ait des entrées proches soit de 1 (en valeur absolue) soit de 0. On peut montrer que $\tilde{\lambda}_\alpha := (\tilde{S}'\tilde{S})_{\alpha\alpha}$, qui donne (à un facteur $1/p$ près) la proportion de variance portée par le premier facteur, diffère en général de λ_α . En particulier, le premier facteur (après rotation) diffère généralement de la direction maximisant la variance projetée du nuage de points (voir section 4.5). Par contre, si l'on décide (avant rotation) de garder $k < p$ facteurs, et que la rotation G ne porte que sur les k premiers axes, alors la communalité après rotation $\tilde{h}_j^2 := \sum_{\alpha=1}^k \tilde{s}_{j\alpha}^2$ ainsi que la proportion de variance expliquée par les k premiers facteurs restent identiques :

$$\tilde{h}_j^2 = h_j^2 \qquad \sum_{\alpha=1}^k \tilde{\lambda}_\alpha = \sum_{\alpha=1}^k \lambda_\alpha \quad (4.11)$$

Dans l'exemple `motiv_psycho`, la matrice de rotation “varimax” (lorsque les 3 premiers facteurs initiaux sont retenus) vaut :

$$G = \begin{pmatrix} .975 & .188 & .116 & 0 & 0 & 0 & 0 \\ -.115 & .881 & -.459 & 0 & 0 & 0 & 0 \\ -.189 & .434 & .881 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix} \quad (4.12)$$

(exercice : vérifier qu'il s'agit d'une rotation, i.e. que G est orthogonale).

Seules les trois premières colonnes de la matrice de saturation sont alors modifiées par la rotation

$$\tilde{S} = SG = \begin{pmatrix} .064 & .675 & .044 & .679 & .177 & .139 & .165 \\ .649 & -.219 & -.298 & -.088 & .613 & .241 & .018 \\ .691 & .325 & .133 & -.355 & -.148 & -.163 & .474 \\ .634 & -.110 & .467 & .073 & -.379 & .445 & -.147 \\ -.001 & .793 & -.131 & -.49 & .061 & .127 & -.308 \\ .780 & .108 & -.053 & .266 & -.059 & -.438 & -.333 \\ -.049 & -.049 & .882 & -.105 & .427 & -.144 & -.062 \end{pmatrix} \quad (4.13)$$

Par exemple, en conservant les trois premiers facteurs, la communalité de la première variable vaut $\tilde{h}_1^2 = (.064)^2 + (.675)^2 + (.044)^2 = 0.462$, résultat identique à celui obtenu à partir de (4.4) : $h_1^2 = (.194)^2 + (.567)^2 + (.320)^2 = 0.462$. En conservant $k = 2$ facteurs, on obtient de (4.13) les communalités suivantes :




FIGURE 4.10 – cercle des rotations après rotation

Variable x_j	Communalité h_j^2 (facteurs $\tilde{f}_1$ et $\tilde{f}_2$)
x_1	.459
x_2	.469
x_3	.583
x_4	.414
x_5	.629
x_6	.620
x_7	.005

Dans notre exemple, l'effet de la rotation G sur le plan factoriel f_1 f_2 n'est pas très spectaculaire ; en effet, G agit en effet essentiellement sur le plan généré par les facteurs 2 et 3, et a pour effet principal de décorréler x_7 des nouveaux facteurs $\tilde{f}_1$ et $\tilde{f}_2$. L'interprétation de ces derniers reste essentiellement la même.

Une rotation varimax effectuée sur les 2 premiers facteurs seulement produit une matrice G de même structure bloc qu'en (4.13), avec le premier bloc (2×2) donné par $\begin{pmatrix} .922 & .386 \\ -.386 & .922 \end{pmatrix}$. Comme $\cos(-22.71^\circ) = .922$ et $\sin(22.71^\circ) = -.386$, il s'agit d'une rotation des *axes factoriels* de 22.71° dans le sens des aiguilles d'une montre (ou, ce qui revient au même, d'une rotation des *points* de 22.71° dans le sens trigonométrique, i.e. inverse des aiguilles d'une montre).

Le mieux est l'ennemi du bien : certains auteurs vont encore plus loin en considérant des “rotations obliques” des facteurs (G non orthonormale) qui produisent des axes factoriels non perpendiculaires, i.e. interdépendants. Ces méthodes (appelées quartimin, biquartimin et covarimin, et regroupées sous l'appellation “rotations oblimin”), sont à **proscrire** : elles réduisent à néant le bénéfice principal d'une ACP, qui est de produire des facteurs non corrélés.

4.5 Approche géométrique à l'ACP

Les $n \times p$ données peuvent être représentées par un nuage de n points-individus dans l'espace des individus à p dimensions, soit par leurs scores bruts (ACP sur Σ), soit par leurs scores standardisés (ACP sur R). On cherche à déterminer la “meilleure” droite D approximant le nuage de points, au sens où la somme des carrés des distances des points à la droite est minimisée³. Cette droite D passe par le point-individu moyen

3. Pour $p = 2$, la situation est presque analogue à celle de la régression simple de Y sur X , sauf que l'on ne cherche pas dans l'ACP à minimiser la somme des carrés des résidus (qui représentent la distance *verticale* seulement $y_j^* - y_j$ à la




FIGURE 4.11 – la direction du premier facteur est celle qui maximise la variance projetée du nuage des points-individus




FIGURE 4.12 – la direction du plan engendré par les deux premiers facteurs est à nouveau celle qui maximise la variance projetée du nuage des points-individus

$\bar{x} = (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_p)$, dit aussi *centre de gravité*, ce dernier se confondant avec l'origine dans le cas de données standardisées (figure 4.11).

La droite recherchée est aussi celle qui maximise la dispersion projetée (sur la droite) du nuage de points (figure 4.11). Il se trouve que la direction de cette droite D est celle de la première composante principale u_1 , et que la variance des projections orthogonales des points sur la droite est λ_1 , la première valeur propre de Σ (ou de R , selon la version choisie). Par construction, cette variance est la plus *grande* possible parmi toutes les projections possibles sur une droite (en projection, les variances ne peuvent que diminuer).

En résumé, la direction u_1 de D est celle où le nuage est maximalelement étiré ou dispersé, ce qui revient à conserver le plus d'information sur la forme du nuage en passant d'une description à p dimensions à une description à 1 dimension. En d'autres termes, **le premier facteur f_1 est l'axe de différenciation maximale entre individus.**

Au lieu de projeter sur la droite D de dimension 1 de manière à minimiser la variance de la projection du nuage, on aurait pu déterminer le plan M de dimension 2 dont la projection maximise la dispersion totale, ou, de façon équivalente, telle que la somme des carrés des distances des points à M soit *minimale* (figure 4.12). On trouve alors que M est le plan passant par $\bar{x}$ engendré par les deux premières composantes principales u_1 et u_2 , avec une dispersion totale $\lambda_1 + \lambda_2$ (la figure 4.2 donne précisément la position des projections des points-individus sur M). Et ainsi de suite, pour $k = 2, 3, \dots, p$. Pour plus de détails, voir le chapitre 6, consacré à la décomposition spectrale des distances euclidiennes dans l'espace des individus (MDS).

(droite de régression), mais bien à minimiser le carré de la distance totale à la droite, qui, en vertu du théorème de Pythagore $d_j^2 = d_{xj}^2 + d_{yj}^2$, est la somme des distances verticale *et* horizontale des points à cette droite.

4.6 (*) ACP, analyse factorielle, et “SEM”

Il est fréquent de voir les termes “analyse en composantes principales” (ACP) et “analyse factorielle” (AF) utilisés comme synonymes, de façon interchangeable. De fait, l'AF s'est historiquement développée la première sur le plan statistique, au début du XX^{ème} siècle, sous l'impulsion de psychologues tels que Spearman, avec pour but de proposer un modèle de *facteurs latents*, non corrélés et inobservables, dont seules certaines combinaisons linéaires (les variables), corrélées entre elles, seraient observées ; ce **modèle** peut être testé, et en particulier rejeté, au cours d'une AF. Par contraste, l'AFC consiste en une simple décomposition spectrale de la matrice des corrélations : il s'agit donc d'un simple **algorithme** qui possède toujours une solution.

De surcroît, l'algorithme de décomposition spectrale constitue la partie principale d'une AF. La forme originale de l'AF tend à être abandonnée au profit de l'AFC, davantage descriptive que inférentielle.

Les principes de l'AF se retrouvent dans les méthodes de “structural equation modelling” (SEM), qui, en un mot, cherchent à établir des relations entre variables, en s'appuyant sur et généralisant les pratiques de l'AF, l'ACP et la régression multiple.

4.6.1 Un autre exemple : ACP avec SPSS (figures 4.13 et 4.14)

4.7 Résumé

- Une ACP transforme p variables quantitatives corrélées $X_1, \dots, X_p$ en $k \leq p$ facteurs $f_1, \dots, f_k$ non corrélés : il n'y a pas lieu d'entreprendre une ACP si les corrélations entre variables sont trop faibles.
- La variance expliquée par le α -ième facteur f_α est donnée par la valeur propre $\lambda_\alpha = \text{var}(f_\alpha)$ de la matrice de corrélation R (ou de variance-covariance Σ).
- La qualité de la représentation de la j -ième variable par les k premiers facteurs est donnée par la communalité h_j^2 .
- La qualité globale de la représentation des p variables par les k premiers facteurs est donnée par le pourcentage $\frac{\lambda_1 + \lambda_2 + \dots + \lambda_k}{\lambda_1 + \lambda_2 + \dots + \lambda_p}$ de variance expliquée.
- On peut représenter le i -ième individu par un point dans un espace factoriel, de coordonnées $f_{i\alpha}$ (score factoriel) sur le α -ième axe.
- L'interprétation du α -ième facteur est donnée par les saturations (ou par les scores factoriels eux-mêmes, lorsqu'existe de la méta-information sur les individus) : un coefficient $s_{j\alpha}$ grand (en valeur absolue) témoigne d'une forte dépendance entre le facteur f_α et la variable x_j .
- Le cercle des corrélations permet de représenter chaque variable x_j par un point dans un espace factoriel, de coordonnées $s_{j\alpha}$ (saturation) sur le α -ième axe.
- Les rotations permettent d'obtenir des saturations proches de 1, -1 ou 0, ce qui facilite l'interprétation des facteurs obtenus.
- Faire une ACP sur la matrice Σ de variance-covariance plutôt que sur la matrice des corrélations R revient à pondérer l'importance de chaque variable x_j par sa variance $s_j^2 = \text{var}(x_j)$ plutôt que par une pondération uniforme $1/p$.

4.8 Exercices et corrigés

Exercice 4.1

Vrai ou faux ?

1. Dans une ACP sur la matrice de variance-covariance impliquant p variables, la somme des valeurs propres vaut toujours p .
2. Lors d'une ACP, on conserve 3 facteurs, expliquant respectivement 40%, 35% et 10% de la variance, soit un total de 85%. Une rotation permet alors d'augmenter ce total.

Exemple : analyse en composantes principales avec SPSS
(échantillon de n = 406 voitures)

Correlation Matrix							
		Miles per Gallon	Engine Displacement (cu. inches)	Horsepower	Vehicle Weight (lbs.)	Time to Accelerate from 0 to 60 mph (sec)	Model Year (modulo 100)
Correlation	Miles per Gallon	1.000	-.805	-.776	-.831	.431	.577
	Engine Displacement (cu. inches)	-.805	1.000	.898	.934	-.548	-.367
	Horsepower	-.776	.898	1.000	.863	-.701	-.411
	Vehicle Weight (lbs.)	-.831	.934	.863	1.000	-.425	-.303
	Time to Accelerate from 0 to 60 mph (sec)	.431	-.548	-.701	-.425	1.000	.296
	Model Year (modulo 100)	.577	-.367	-.411	-.303	.296	1.000

KMO and Bartlett's Test		
Kaiser-Meyer-Olkin Measure of Sampling Adequacy.		.760
Bartlett's Test of Sphericity	Approx. Chi-Square	2545.338
	df	15
	Sig.	.000

Communalities		
	Initial	Extraction
Miles per Gallon	1.000	.840
Engine Displacement (cu. inches)	1.000	.923
Horsepower	1.000	.928
Vehicle Weight (lbs.)	1.000	.878
Time to Accelerate from 0 to 60 mph (sec)	1.000	.467
Model Year (modulo 100)	1.000	.978

Extraction Method: Principal Component Analysis.

Total Variance Explained						
Component	Initial Eigenvalues			Extraction Sums of Squared Loadings		
	Total	% of Variance	Cumulative %	Total	% of Variance	Cumulative %
1	4.178	69.628	69.628	4.178	69.628	69.628
2	.837	13.942	83.570	.837	13.942	83.570
3	.703	11.715	95.285			
4	.159	2.658	97.942			
5	.077	1.291	99.233			
6	.046	.767	100.000			

Extraction Method: Principal Component Analysis.

FIGURE 4.13 – Matrice de corrélation entre $p = 7$ variables, test de sphéricité, communalités et variances expliquées en gardant $k = 2$ facteurs

3. Lors d'une ACP, la relation "individus-facteurs" est décrite par les saturations, tandis que la relation "variables-facteurs" est décrite par les scores factoriels.
4. Le déterminant d'une matrice A est égal au produit $\alpha_{11} \cdot \alpha_{22} \cdot \dots \cdot \alpha_{nn}$ de ses éléments diagonaux.
5. Soit A une matrice carrée ($n \times n$) de valeurs propres λ_α . Alors $[A^{-1} \text{ existe}] \Leftrightarrow [\det(A) \neq 0] \Leftrightarrow [\lambda_\alpha \neq 0 \text{ pour tout } \alpha] \Leftrightarrow [\text{rang}(A) = n]$.

Exercice 4.2

On dispose d'une série de données permettant d'évaluer la qualité de la vie dans 21 pays (18 européens, plus le Japon, le Canada et les USA) au moyen des quatre variables numériques suivantes (source : *Condensé de l'Annuaire Eurostat*, Office des publications officielles des Communautés européennes, 1998) :

carbone : émission de dioxyde de carbone (CO_2) en kg/habitant en 1995

pib : produit intérieur brut par habitant en écu en 1996 (standardisé en fonction du pouvoir d'achat)

voitures : nombre de voitures particulières pour 1000 habitants en 1996




FIGURE 4.14 – Saturations (“component matrix”), scree graph et cercle des corrélations

vie : espérance de vie des filles à la naissances en 1996.

Les sorties SPSS ci-après donnent les résultats obtenus par une analyse en composantes principales avec le logiciel SPSS sur ces quatre variables, ainsi que les scores standardisés des variables utilisées pour l’analyse.

Indications (les sorties SPSS n’étant pas toujours très claires) : “Component matrix” donne les saturations $s_{i\alpha} = \sqrt{\lambda_\alpha} u_{i\alpha}$ et “Component Score Coefficient Matrix” donne les quantités $u_{i\alpha}/\sqrt{\lambda_\alpha}$, par lesquelles on peut calculer les scores factoriels *standardisés* $f_{i\alpha}^s = f_{i\alpha}/\sqrt{\lambda_\alpha}$, où $f_{i\alpha} = \sum_{j=1}^p x_{ij}^s u_{i\alpha}$ est le score factoriel non standardisé (de l’individu i sur le facteur α), de moyenne nulle et de variance λ_α .

1. D’après les corrélations entre les variables et le test de Bartlett, l’analyse en composantes principales est-elle pertinente sur ce jeu de données ?
2. Combien de composantes ont été retenues dans le modèle présenté ? Combien en auriez-vous retenu avec les différents critères vus au cours ?
3. Calculez la proportion de variance expliquée par la première composante à partir des valeurs propres et vérifiez votre résultat dans le tableau **Total Variance Explained**.
4. Comment calculer les communalités à partir des corrélations entre les variables de départ et les composantes principales ? Quelle variable de départ est la mieux représentée par les composantes retenues ?
5. D’après les saturations, interprétez (donnez un nom) à chacune des composantes.
6. Vérifiez que $\sum_{j=1}^4 s_{j\alpha}^2 = \lambda_\alpha$ pour $\alpha = 1, 2$

Factor Analysis

Correlation Matrix

		émissions de dioxyde de carbone	PIB standardisé en écus par personne en 1996	nombre de voitures particulières pour 1000 habitants	espérance de vie des filles à la naissance
Correlation	émissions de dioxyde de carbone	1.000	.722	.393	-.261
	PIB standardisé en écus par personne en 1996	.722	1.000	.687	.091
	nombre de voitures particulières pour 1000 habitants	.393	.687	1.000	.285
	espérance de vie des filles à la naissance	-.261	.091	.285	1.000

KMO and Bartlett's Test

Kaiser-Meyer-Olkin Measure of Sampling Adequacy.		.549
Bartlett's Test of Sphericity	Approx. Chi-Square	31.087
	df	6
	Sig.	.000

Communalities

	Initial	Extraction
émissions de dioxyde de carbone	1.000	.863
PIB standardisé en écus par personne en 1996	1.000	.894
nombre de voitures particulières pour 1000 habitants	1.000	.794
espérance de vie des filles à la naissance	1.000	.901


Extraction Method: Principal Component Analysis.

Total Variance Explained

Component	Initial Eigenvalues			Extraction Sums of Squared Loadings		
	Total	% of Variance	Cumulative %	Total	% of Variance	Cumulative %
1	2.217	55.414	55.414	2.217	55.414	55.414
2	1.235	30.884	86.298	1.235	30.884	86.298
3	.380	9.497	95.795			
4	.168	4.205	100.000			

Extraction Method: Principal Component Analysis.


Scree Plot

Component Matrix^a

	Component	
	1	2
émissions de dioxyde de carbone	.806	-.462
PIB standardisé en écus par personne en 1996	.946	-.005
nombre de voitures particulières pour 1000 habitants	.816	.359
espérance de vie des filles à la naissance	.090	.945

Extraction Method: Principal Component Analysis.

a. 2 components extracted.



7. Soit $U = \begin{pmatrix} 0.542 & -0.416 & 0.472 & 0.558 \\ 0.636 & -0.004 & 0.161 & -0.755 \\ 0.548 & 0.322 & -0.708 & 0.308 \\ 0.060 & 0.850 & 0.501 & 0.152 \end{pmatrix}$ la matrice des vecteurs propres : on peut l'obtenir en *divisant* chaque colonne des saturations ("Component matrix") par $\sqrt{\lambda_\alpha}$, où $\lambda_1 = 2.217$ et $\lambda_2 = 1.235$, ou, de façon équivalente, en *multipliant* chaque colonne de la "Component Score Coefficient Matrix" par $\sqrt{\lambda_\alpha}$. Vérifiez que $Ru_1 = \lambda_1 u_1$, où R est la matrice des corrélations et λ_1 la première valeur propre.
8. Calculez le score factoriel usuel (i.e. non standardisé) de la Suisse sur les deux premières composantes.

Corrigé de la série 4

Exercice 4.1

- Faux** : dans une ACP sur la matrice de variance-covariance, la somme des valeurs propres est égale à la variance totale $\sum_{j=1}^p \text{var}(x_j)$, qui est la trace $\text{Tr}(\Sigma)$ de la matrice de variance-covariance Σ .
- Faux** : une rotation des 3 facteurs conserve ce total de 85%. Par contre, la proportion de variance expliquée par le premier facteur chutera en-dessous de 40% tandis que la proportion de variance expliquée par les facteurs 2 et 3 dépassera les $35\% + 10\% = 45\%$.
- Faux** : c'est juste le contraire.
- Faux** : le déterminant d'une matrice A est égal au produit $\lambda_1 \cdot \lambda_2 \cdot \dots \cdot \lambda_n$ de ses valeurs propres. (Par contre, la trace d'une matrice A est bien égale à la somme $\alpha_{11} + \alpha_{22} + \dots + \alpha_{nn}$ de ses éléments diagonaux, qui coïncide avec la somme $\lambda_1 + \lambda_2 + \dots + \lambda_n$ de ses valeurs propres).

5. Vrai.

Exercice 4.2

- Oui, les corrélations sont pour la plupart assez élevées, et l'hypothèse de sphéricité (H_0 : toutes les corrélations sont égales à 0) est rejetée (Bartlett's Test).
- 2 composantes principales ont été retenues (Total Variance Explained). On obtient ce résultat si l'on ne retient que les valeurs propres > 1 , si l'on ne retient que les valeurs propres nécessaires pour expliquer au moins 80% de la variance ou si l'on applique le critère du coude dans le Scree Plot.
- Proportion de variance expliquée par la première composante : $\frac{\lambda_1}{\lambda_1 + \lambda_2 + \lambda_3 + \lambda_4} = \frac{2.217}{2.217 + 1.235 + 0.380 + 0.168} = 0.554$. C'est bien la valeur donnée dans le tableau Total Variance Explained.
- La communalité h_j^2 d'une variable (tableau Communalities) est obtenue en additionnant les carrés des saturations $S_{j\alpha}^2$ de cette variable (corrélations entre cette variable et les composantes conservées du modèle, tableau Component Matrix). On a par exemple $h_{\text{carbone}}^2 = 0.806^2 + (-0.462)^2 = 0.863$. La variable la mieux représentée sur les deux premiers facteurs est celle dont la communalité est la plus élevée ; c'est l'espérance de vie des filles à la naissance ($h_{\text{vie}}^2 = 0.901$).
- La première composante est principalement corrélée avec carbone, pib et voitures ; on pourrait par exemple la nommer "industrialisation". La deuxième composante est essentiellement corrélée avec l'espérance de vie des filles à la naissance et ne représente donc que cette variable.
- $0.806^2 + 0.946^2 + 0.816^2 + 0.090^2 = 2.219 \approx \lambda_1$ (erreur d'arrondi) et $(-0.462)^2 + (-0.005)^2 + 0.359^2 + 0.945^2 = 1.235 = \lambda_2$.
- $\lambda_1 = 2.217$ est donnée dans le tableau Total Variance Explained. On a bien

$$\begin{pmatrix} 1.000 & 0.722 & 0.393 & -0.261 \\ 0.722 & 1.000 & 0.687 & 0.091 \\ 0.393 & 0.687 & 1.000 & 0.285 \\ -0.261 & 0.091 & 0.285 & 1.000 \end{pmatrix} \begin{pmatrix} 0.542 \\ 0.636 \\ 0.548 \\ 0.060 \end{pmatrix} = 2.217 \begin{pmatrix} 0.542 \\ 0.636 \\ 0.548 \\ 0.060 \end{pmatrix}.$$

On vérifie aussi que u_1 est bien normé :

$$0.542^2 + 0.636^2 + 0.548^2 + 0.060^2 = 1.$$

- $f_1 = u_{11} \times \text{carbone}^s + u_{21} \times \text{pib}^s + u_{31} \times \text{voitures}^s + u_{41} \times \text{vie}^s$ et $f_2 = u_{12} \times \text{carbone}^s + u_{22} \times \text{pib}^s + u_{32} \times \text{voitures}^s + u_{42} \times \text{vie}^s$.

Pour la Suisse (voir valeurs standardisées ci-dessous) : $f_1(\text{CH}) = 0.542 \times (-0.906) + 0.636 \times 0.799 + 0.548 \times 0.642 + 0.060 \times 1.220 = 0.442$,

$$f_2(\text{CH}) = (-0.416) \times (-0.906) + (-0.004) \times 0.799 + 0.322 \times 0.642 + 0.850 \times 1.220 = 1.617.$$

	pays	zcarbone	zpib	zvoiture	zvie
1	B	.24483	.19480	.15236	.00386
2	DK	.35821	.23960	-.88149	-1.86078
3	D	.11369	.09928	.99032	-.48257
4	EL	-.55178	-1.80721	-2.03505	-.07721
5	E	-.87280	-1.40878	-.37001	.89665
6	F	-.89306	-.17640	.72914	1.21993
7	IRL	-.22758	-.70449	-1.50180	-1.45542
8	I	-.64604	-.28776	1.75210	.65243
9	L	2.61487	2.42796	1.62151	-.48257
10	NL	.26600	-.19397	-.51148	-.15828
11	A	-.65105	.19084	.52237	-.23935
12	P	-1.15625	-1.72554	-1.44739	-1.53650
13	FIN	.26168	-.55774	-.33736	.00386
14	S	-.87234	-.36843	.05441	.81457
15	UK	-.18455	-.45999	-.44619	-.88792
16	IS	-.24511	.46108	.38089	.08493
17	NO	-.11625	.77883	-.28295	.40922
18	CH	-.90649	.79937	.64207	1.21993
19	US	2.26950	1.59943	1.17532	-.88792
20	CA	1.36337	.38461	.38089	.65243
21	JP	-.16884	.51453	-.58786	2.11172

Chapitre 5

Dissimilarités

5.1 Introduction

Le paradigme *statistique* classique met l'accent sur les *variables* et leurs relations : quelle est la distribution de X ou de Y ? Y a-t-il dépendance entre X et Y (et Z , et W , etc.) et si oui, de quelle nature? La démarche scientifique consiste à effectuer n mesures, i.e. à constituer un échantillon “représentatif” de n valeurs $\{x_i, y_i\}$, etc. permettant d'aborder ces questions. Dans cette optique, l'identité des n individus constituant l'échantillon n'a aucune pertinence, à l'instar de n élèves dont on suit le parcours socio-pédagogique, de n patients soignés selon une thérapie donnée, ou de n forages miniers : les caractéristiques de ces individus ne servent qu'à fournir des scores que l'on pourra alors comparer, corrélérer etc., sans que, jamais, l'intérêt ne soit focalisé sur tel individu plutôt que tel autre, les individus demeurant d'ailleurs *anonymes* en général.

Par contraste, les sciences humaines (bien plus que les sciences sociales ou les sciences naturelles) s'attachent à étudier les dissemblances ou ressemblances entre *individus* ou *objets*, lesquels sont alors bien identifiés et *nommés* : quels contrastes ou similarités entre Lausanne, Genève, Marseille, Gênes? entre nécropoles égyptiennes, grecques, romaines? entre plans d'études en Lettres, Géosciences, Biologie? Entre “*Shine On You Crazy Diamond*”, “*The Great Gig In The Sky*” et “*Brain Damage*”? Ici, les variables ou caractéristiques des objets sont à l'arrière-plan, et servent à construire des *dissimilarités* ou *similarités entre objets*, supposément bien adaptées à la problématique en jeu.

Naturellement, toute caractérisation des individus (les lignes du tableau de données) entraîne une caractérisation des variables (des colonnes du tableau de données) : c'est le principe de *dualité* au coeur de l'*analyse des données*, laquelle, en contraste avec la statistique classique, accorde autant voire plus d'importance aux relations entre objets plutôt qu'entre variables, et ce dans un cadre généralement non probabiliste. La compréhension des propriétés des structures formelles de *dissimilarités* entre objets est incontournable pour une analyse avisée – un domaine extrêmement riche aux ramifications étendues, quoiqu'insuffisamment exposé dans la plupart des introductions au sujet.

5.2 Dissimilarités : définitions générales

On considère n **objets** ou individus indicés par $i = 1, \dots, n$, chaque objet étant caractérisé par p **caractéristiques** ou traits (“features”) indicés par $k = 1, \dots, p$. Les données sont ainsi constituées d'une matrice $X = (x_{ik})$ de type $(n \times p)$, où x_{ik} est la valeur (numérique ou catégorielle) de la k -ième caractéristique sur le i -ème objet. Une paire d'objets sera souvent indicée par (i, j) , un triple d'objets par (i, j, k) (attention à la double signification possible de k selon le contexte, qui peut désigner soit une variable, soit un objet).

Définition 1 (Dissimilarité)

Une dissimilarité d entre n objets est une matrice $d = (d_{ij})$ carrée $(n \times n)$ symétrique, non-négative, avec une diagonale nulle.

En d'autres termes, d est une dissimilarité ssi, pour toute paire d'objets i et j , on a

$$d_{ij} \geq 0 \quad d_{ij} = d_{ji} \quad d_{ii} = 0 . \quad (5.1)$$

La dissimilarité (5.1) est dite *propre* (ou “definite”) si $d_{ij} = 0$ entraîne que $i = j$, i.e. si la dissimilarité entre objets distincts est strictement positive ; elle est dite *semi-propre* (ou “even”) si $d_{ij} = 0$ entraîne que $d_{ik} = d_{jk}$ pour tous k , i.e. si deux objets de dissimilarité nulle ont les mêmes dissimilarités avec les autres objets.

5.2.1 Scores numériques

Pour le moment, on se limite au cas où chacun des traits possède un caractère numérique, plutôt que catégoriel. Alors les *profils* des objets i et j sont constitués des vecteurs ligne à p composantes $x_i = (x_{i1}, \dots, x_{ik}, \dots, x_{ip})$ et $x_j = (x_{j1}, \dots, x_{jk}, \dots, x_{jp})$. La *distance euclidienne* entre ces vecteurs définit une mesure particulière de dissimilarité d_{ij} , satisfaisant à toutes les propriétés de la définition 1. Il existe quantité d'autres dissimilarités, non euclidiennes, obéissant également à cette définition.

Définition 2 (Construction de dissimilarités)

A partir des profils numériques $x_i \in \mathbb{R}^{1 \times p}$ et $x_j \in \mathbb{R}^{1 \times p}$ des objets i et j , on peut construire la dissimilarité ¹

$$\text{de type } L_2 \text{ ou euclidienne} \quad d_{ij} := \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2} =: \|x_i - x_j\|_2 \quad (5.2)$$

$$\text{de type } L_2^2 \text{ ou euclidienne carrée} \quad d_{ij} := \sum_{k=1}^p (x_{ik} - x_{jk})^2 =: \|x_i - x_j\|_2^2 \quad (5.3)$$

$$\text{de type } L_1 \text{ ou de bloc (ou de Manhattan)} \quad d_{ij} := \sum_{k=1}^p |x_{ik} - x_{jk}| =: \|x_i - x_j\|_1 \quad (5.4)$$

$$\text{de type } L_\infty \text{ ou de Chebychev} \quad d_{ij} := \max_{k=1}^p |x_{ik} - x_{jk}| =: \|x_i - x_j\|_\infty \quad (5.5)$$

$$\text{de type } L_q \text{ ou de Minkowski}(q) \quad (q \geq 1) \quad d_{ij} := \left(\sum_{k=1}^p |x_{ik} - x_{jk}|^q \right)^{\frac{1}{q}} =: \|x_i - x_j\|_q \quad (5.6)$$

$$\text{de type } L_q^{q/r} \text{ ou général}(q, r) \quad (q, r \geq 1) \quad d_{ij} := \left(\sum_{k=1}^p |x_{ik} - x_{jk}|^q \right)^{\frac{1}{r}} =: \|x_i - x_j\|_q^{q/r} \quad (5.7)$$

La définition de la dissimilarité de générale (q, r) englobe toutes les autres : on retrouve la dissimilarité de Minkowski(q) avec le type (q, q) , et la dissimilarité euclidienne carrée avec le type $(2, 1)$. Aussi, la dissimilarité de Minkowski(q) donne la dissimilarité euclidienne pour $q = 2$, la dissimilarité de bloc pour $q = 1$, et la dissimilarité de Chebychev pour $q \rightarrow \infty$: pour q grand, la caractéristique k sur laquelle les objets i et j diffèrent le plus tend à dominer les autres caractéristiques, jusqu'à constituer la seule contribution à leur dissimilarité pour $q \rightarrow \infty$.

Exemple 1 (Notes scolaires)

On considère des élèves caractérisés par leurs $p = 3$ scores $x_i = (x_{i1}, x_{i2}, x_{i3})$ où x_{i1} = “note de mathématiques de l'élève i ”, x_{i2} = “note de physique” et x_{i3} = “note d'anglais”. Le profil des élèves i et j est de $x_i = (5, 2, 3)$, respectivement $x_j = (6, 3, 1)$. Leur dissimilarité euclidienne au carré est de $(5 - 6)^2 + (2 - 3)^2 + (3 - 1)^2 = 6$, et leur dissimilarité euclidienne de $\sqrt{6} = 2.45$. Leur dissimilarité de bloc est de $|5 - 6| + |2 - 3| + |3 - 1| = 4$. Leur dissimilarité de Minkowski d'ordre $q = 10$ (par exemple) est de $\sqrt[10]{1^{10} + 1^{10} + 2^{10}} = 2.0004$, proche de la valeur de la dissimilarité de Chebychev $\max(1, 1, 2) = 2$.

1. la terminologie utilisée peut varier passablement dans la littérature

5.2.2 Scores standardisés et dissimilarité de Mahalanobis

Supposons, dans l'exemple 1 précédent, que la variance de la note de physique soit supérieure à celle de mathématiques. La dissimilarité entre deux élèves reflètera alors, en moyenne, davantage la différence de leurs performances en physique qu'en mathématiques. Cet état de choses est ici acceptable dans la mesure où les trois variables sont mesurées dans la même unité. Par contre, si l'on voulait obtenir des dissimilarités entre automobiles avec les traits x_{i1} = “nombre de cylindres”, x_{i2} = “vitesse de pointe [km/h]” et x_{i3} = “prix [FrS]”, alors il serait absurde de procéder de même *avec les scores bruts non transformés* : l'écart-type de x_{i1} est de l'ordre de l'unité, celui de x_{i2} de l'ordre de la dizaine et celui de x_{i3} de l'ordre de dix-mille, et la dissimilarité d_{ij} entre deux automobiles i et j dépendrait ainsi presque uniquement de la différence $|x_{i3} - x_{j3}|$ (mais pas de $|x_{i2} - x_{j2}|$, et encore moins de $|x_{i1} - x_{j1}|$).

Standardiser les profils, i.e. utiliser les scores $x_{ik}^s := (x_{ik} - \bar{x}_k)/\sqrt{\text{var}(x_k)}$ plutôt que les scores bruts x_{ik} avant de calculer les dissimilarités d_{ij} résoud le problème en question : par construction, chaque trait, une fois standardisé, possède le même poids, qui ne dépend pas du système d'unités (par exemple [FrS] ou [\$]) utilisé.

“*Multistandardisation*” : les variables étant généralement corrélées, on pourrait objecter à la démarche précédente, garantissant un poids identique pour tous les traits, qu'elle compte plusieurs fois la même chose dans l'expression des dissimilarités : si “mathématiques” et “physique” sont positivement corrélées, calculer des dissimilarités en tenant compte de la différence des performances en mathématiques *et* en physique, revient à compter à double² un même phénomène. Pour contourner cette difficulté, on peut alors remplacer les scores bruts ou standardisés des profils par les *scores factoriels standardisés* $f_{i\alpha}^s$ issus de la décomposition spectrale de la matrice Σ de variance-covariance (voir chapitre 4), tels $f_{i\alpha}^s = 0$ et $\text{var}(f_{i\alpha}^s) = 1$. La dissimilarité euclidienne entre scores factoriels standardisés s'appelle *dissimilarité de Mahalanobis*. Elle constitue une distance euclidienne “multistandardisée” au sens où non seulement l'effet de la différence des variances, mais aussi l'effet de la corrélation entre traits ont été éliminés. On peut montrer (équation 5.10) que la dissimilarité de Mahalanobis s'exprime aussi comme le produit scalaire des différences de profil “dans la métrique Σ^{-1} ” (i.e. en intercalant Σ^{-1} dans le produit scalaire).

$$\text{dissimilarité euclidienne} \quad d_{ij} := \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2} = \sqrt{(x_i - x_j)(x_i - x_j)'} \quad (5.8)$$

$$\text{dissimilarité euclidienne standardisée} \quad d_{ij} := \sqrt{\sum_{k=1}^p (x_{ik}^s - x_{jk}^s)^2} = \sqrt{(x_i - x_j)S^{-1}(x_i - x_j)'} \quad (5.9)$$

$$\text{dissimilarité de Mahalanobis} \quad d_{ij} := \sqrt{\sum_{\alpha=1}^p (f_{i\alpha}^s - f_{j\alpha}^s)^2} = \sqrt{(x_i - x_j)\Sigma^{-1}(x_i - x_j)'} \quad (5.10)$$

Dans (5.9), la matrice S désigne la matrice *diagonale* dont les composantes sont les variances $\text{var}(x_k)$.

Exemple 2 (Notes scolaires, suite)

Supposons que la matrice de variance-covariance empiriques entre “mathématiques”, “physique” et “anglais” soit donnée par

$$\Sigma = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 4 & 0 \\ 0 & 0 & 3 \end{pmatrix} \quad \text{i.e.} \quad \Sigma^{-1} = \begin{pmatrix} \frac{4}{7} & -\frac{1}{7} & 0 \\ -\frac{1}{7} & \frac{2}{7} & 0 \\ 0 & 0 & \frac{1}{3} \end{pmatrix} \quad \text{et} \quad S = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 3 \end{pmatrix} \quad (5.11)$$

La dissimilarité euclidienne standardisée entre $x_i = (5, 2, 3)$ et $x_j = (6, 3, 1)$, de différence $x_i - x_j = (-1, -1, 2)$ vaut alors $d_{ij} = \sqrt{(5-6)^2/2 + (2-3)^2/4 + (3-1)^2/3} = 1.44$. On remarque que seules les *différences* de scores standardisés interviennent dans l'expression, qui ne dépend ainsi pas des moyennes

2. pas tout-à-fait “à double” si la corrélation est inférieure à un




FIGURE 5.1 – Seul le triangle de gauche existe, et définit une dissimilarité métrique

empiriques. La valeur $d_{ij} = 1.44$ obtenue est supérieure à la dissimilarité de Mahalanobis

$$d_{ij} = \sqrt{(-1, -1, 2) \begin{pmatrix} \frac{4}{7} & -\frac{1}{7} & 0 \\ -\frac{1}{7} & \frac{2}{7} & 0 \\ 0 & 0 & \frac{1}{3} \end{pmatrix} \begin{pmatrix} -1 \\ -1 \\ 2 \end{pmatrix}} = \sqrt{\frac{3}{7} + -\frac{1}{7} + \frac{4}{3}} = \sqrt{1.90} = 1.38 \quad (5.12)$$

qui, par construction, “soustrait” l’effet des corrélations dans les dissimilarités.

5.3 Dissimilarités métriques

Peut-on représenter les valeurs des trois dissimilarités d_{ij} , d_{ik} et d_{jk} associées à trois objets i , j et k comme les longueurs des trois côtés d’un triangle ? La réponse est “oui” ssi la longueur de chaque côté n’excède pas la somme des deux autres. Une dissimilarité possédant cette propriété est dite *métrique*. L’emploi du terme **distance** est assez variable, mais recouvre presque toujours une dissimilarité métrique.

Définition 3 (Dissimilarités métriques ou distances)

Une dissimilarité est dite *métrique* ssi

$$d_{ij} \leq d_{ik} + d_{kj} \quad \text{pour tous } i, j, k \quad (5.13)$$

Les dissimilarités de Minkowski(q) (pour $q \geq 1$), en particulier les dissimilarités euclidienne, de bloc et de Chebychev sont métriques. Les dissimilarités euclidiennes standardisées (5.9) ainsi que de Mahalanobis (5.10) sont également métriques. Par contre, la dissimilarité euclidienne au carré n’est *pas* métrique : par exemple, si trois objets i , j et k sont à distance euclidienne de $d_{ij} = 4$, $d_{ik} = 2$ et $d_{jk} = 3$, l’inégalité (5.13) est vérifiée, mais elle ne l’est plus pour les dissimilarités euclidiennes au carré qui sont de $4^2 = 16$, $2^2 = 4$ et $3^2 = 9$ respectivement (figure 5.1).

Selon l’équation (5.13), si, au lieu d’aller de i à j directement, on passe par k , alors la distance parcourue ne peut qu’augmenter, et ne reste constante que si k se trouve sur le trajet de i à j . Le temps de trajet t_{ij} , le coût de trajet c_{ij} etc. ne peuvent aussi qu’augmenter à l’occasion d’un détour : ces quantités constituent d’autres instances de dissimilarité métrique (sous réserve de leur symétrie $t_{ij} = t_{ji}$ etc.).

5.4 Dendrogrammes et dissimilarités ultramétriques

Le **dendrogramme** (figure 5.2) constitue une représentation hiérarchique d’une *partition* des n objets en m *groupes* (voir les développements du chapitre 8) L’axe vertical h est la *hauteur* du dendrogramme et permet de définir m groupes en coupant le dendrogramme à hauteur h (figure 5.2). h est une mesure de l’imprécision ou de la grossièreté de la partition, car plus on coupe haut, plus les distinctions entre individus sont perdues




FIGURE 5.2 – En coupant le dendrogramme à hauteur $h = 2.5$, on obtient les $m = 3$ groupes $[abcd]$, $[e]$ et $[f]$. Pour $h \geq h_{\max} = 4$, tous les objets sont agrégés ($m = 1$).

et moins il y a de groupes : en $h = 0$, on a $m = n$, i.e. autant de groupes que d'objets, alors que pour $h \geq h_{\max}$, il n'y a plus qu'un groupe ($m = 1$).

Sur un dendrogramme, la dissimilarité d_{ij} entre deux objets i et j est définie comme la hauteur h à laquelle les branches issues de i et j se rencontrent. Par exemple, on lit sur la figure 5.2 que $d_{ab} = 1$ et $d_{ae} = d_{be} = 3$. La matrice de dissimilarités complète est

$$d = \begin{pmatrix} & a & b & c & d & e & f \\ \begin{matrix} a \\ b \\ c \\ d \\ e \\ f \end{matrix} & \begin{pmatrix} 0 & 1 & 2 & 2 & 3 & 4 \\ 1 & 0 & 2 & 2 & 3 & 4 \\ 2 & 2 & 0 & 1 & 3 & 4 \\ 2 & 2 & 1 & 0 & 3 & 4 \\ 3 & 3 & 3 & 3 & 0 & 4 \\ 4 & 4 & 4 & 4 & 4 & 0 \end{pmatrix} \end{pmatrix} \quad (5.14)$$

En raisonnant sur les dissimilarités entre trois objets i , j et k représentées sur un dendrogramme, il est facile de montrer que l'on a toujours $d_{ij} \leq \max(d_{ik}, d_{jk})$, i.e. que, des trois nombres d_{ij} , d_{ik} et d_{jk} , deux sont égaux et non inférieurs au troisième. Une dissimilarité possédant cette propriété est dite *ultramétrique* :

Définition 4 (Dissimilarités ultramétriques)

Une dissimilarité est dite ultramétrique ssi

$$d_{ij} \leq \max(d_{ik}, d_{jk}) \quad \text{pour tous } i, j, k \quad (5.15)$$

Dans un monde où les dissimilarités sont ultramétriques, tout triple d'objets sera donc représenté par un triangle isocèle avec une “petite base” (figure 5.3).

Par construction, i et j appartiennent au même groupe ssi $d_{ij} \leq h$. En notant comme “ $i\mathcal{R}j$ ” la relation “ i et j appartiennent au même groupe”, on a que la relation $\mathcal{R}$ est *réflexive* (i.e. $i\mathcal{R}i$ entraîne que $j\mathcal{R}i$), *symétrique* (i.e. $i\mathcal{R}i$ pour tout i), et *transitive* (i.e. $i\mathcal{R}j$ et $j\mathcal{R}k$ entraînent que $i\mathcal{R}k$ ³) : c'est donc une relation d'équivalence, comme il se doit d'une relation partitionnant les n objets en m groupes.

On peut vérifier que l'inégalité ultramétrique (5.15) entraîne l'inégalité triangulaire (5.13) $d_{ij} \leq d_{ik} + d_{jk}$.
Toute dissimilarité ultramétrique est donc métrique.

3. puisque si $d_{ik} \leq h$ et $d_{jk} \leq h$ alors $d_{ij} \leq \max(d_{ik}, d_{jk}) \leq h$




FIGURE 5.3 – Tous les triangles, tels a), b) et c) permettent de visualiser des dissimilarités métriques. Les dissimilarités représentées par a) et b) ne sont pas ultramétriques ($d_{12} > \max(d_{13}, d_{23}) = d_{13}$ et $d_{56} > \max(d_{54}, d_{64}) = d_{54}$). La dissimilarité du triangle isocèle à “petite base” c) est ultramétrique.




FIGURE 5.4 – Les 5 configurations possibles connectant 4 noeuds distincts sur un arbre.

5.5 Dissimilarités d'arbre

Un *graphe* $G = (V, E)$ est composé d'un ensemble de noeuds V (“vertices”) et d'un ensemble d'arrêtes E (“edges”) reliant certains noeuds à d'autres. Le graphe est *valué* si chaque arrête possède une valeur $l(e) \geq 0$ que l'on peut ici interpréter comme sa longueur. La longueur $l(C)$ d'un chemin C formé d'arrêtes consécutives est définie comme $l(C) := \sum_{e \in C} l(e)$, la somme des longueurs des arrêtes formant le chemin.

Un *arbre* est un graphe :

- 1) sans arrête interne (= pas d'arrête reliant un noeud à lui-même)
- 2) simple (= pas d'arrête multiple)
- 3) non orienté (= les arrêtes n'ont pas d'orientation)
- 4) connexe (= il existe un chemin formé d'arrêtes consécutives reliant tout point ou noeud à tout autre)
- 5) sans boucle (= il n'existe pas de chemin circulaire reliant un noeud à lui-même sans utiliser deux fois ou plus la même arrête).

La distance δ_{ij} entre deux noeuds i et j d'un arbre est définie comme la longueur du chemin (unique) reliant i et j . Par construction, $\delta_{ii} = 0$.

Définition 5 (dissimilarité d'arbre)

Une dissimilarité d entre n objets est une *dissimilarité d'arbre* ss'il existe un arbre valué (à $N \geq n$ noeuds) dans lequel chaque objet i est représentable par un noeud i , et tel que $d_{ij} = \delta_{ij}$, où δ_{ij} est la distance sur l'arbre entre les noeuds i et j .




FIGURE 5.5 – Arbre à $N = 7$ noeuds représentant la dissimilarité (5.17) entre $n = 6$ objets, le noeud supplémentaire étant adjacent à a , b et c .

Théorème 1 (inégalité des quatre points)

La dissimilarité d est une dissimilarité d'arbre ssi, pour chaque quadruple d'objets (i, j, k, l) *distincts ou non*, l'inégalité dite *des quatre points*

$$d_{ij} + d_{kl} \leq \max(d_{ik} + d_{jl}, d_{il} + d_{jk}) \quad \text{est vérifiée.} \quad (5.16)$$

Sans prouver ici ce théorème (Buneman, 1974), remarquons que l'inégalité des quatre points est vérifiée sur chacune des configurations de la figure 5.4. L'inégalité des quatre points (5.16) est équivalente à l'énoncé suivant : “*des trois nombres $d_{ij} + d_{kl}$, $d_{ik} + d_{jl}$ et $d_{il} + d_{jk}$, deux sont égaux et non inférieurs au troisième*”. Lorsque deux des objets coïncident, la condition des quatre points (5.16) est équivalente à l'inégalité triangulaire (5.28). **Une dissimilarité d'arbre est donc métrique.**

Exemple 3

A la dissimilarité d'arbre suivante

$$d = \begin{pmatrix} & \begin{matrix} a & b & c & d & e & f \end{matrix} \\ \begin{matrix} a \\ b \\ c \\ d \\ e \\ f \end{matrix} & \begin{pmatrix} 0 & 2 & 2 & 3 & 4 & 5 \\ 2 & 0 & 2 & 3 & 4 & 5 \\ 2 & 2 & 0 & 1 & 2 & 3 \\ 3 & 3 & 1 & 0 & 3 & 4 \\ 4 & 4 & 2 & 3 & 0 & 1 \\ 5 & 5 & 3 & 4 & 1 & 0 \end{pmatrix} \end{pmatrix} \quad (5.17)$$

correspond l'arbre de la figure 5.5.

Enfin, tout dendrogramme peut être considéré comme un arbre induisant une dissimilarité d'arbre, en définissant le poids $l(e_{xy})$ de chaque arrête e_{xy} (où x et y sont deux noeuds du dendrogramme qui peuvent représenter aussi bien des objets initiaux que des noeuds intermédiaires) comme étant égale à $|h_x - h_y|/2$, la moitié de la valeur absolue de la différence entre les hauteurs des extrémités x et y de l'arrête e_{xy} . La dissimilarité d_{ij} entre les objets i et j est alors égale à la distance prise sur le chemin reliant i et j . Par exemple, $d_{ae} = 0.5 + 0.5 + 0.5 + 1.5 = 3$, qui est bien la dissimilarité ultramétrique (5.14).

Ainsi, **toute dissimilarité ultramétrique est une dissimilarité d'arbre**. Inversément, on peut montrer qu'une dissimilarité d'arbre est une dissimilarité ultramétrique ss'il existe un noeud particulier de l'arbre, sa *racine* (“root”), dont la distance à tous les n objets est la même. C'est bien le cas de la figure 5.6, mais non de la figure 5.5.

5.5.1 (*) Algorithme de Fitch-Margoliash (FM) pour la construction d'arbres

Nombreuses sont les situations, particulièrement en biologie, où l'on a de bonnes raisons de penser que les dissimilarités (d_{ij}) sont des dissimilarités d'arbre, de façon exacte, ou le plus souvent approchée. L'algorithme




FIGURE 5.6 – Tout dendrogramme (ici le dendrogramme de la figure 5.2) définit un arbre possédant un noeud particulier (la racine) à distance identique (ici 2) de chaque objet




FIGURE 5.7 – Des identités $d_{ij} = \delta_{i[ij]} + \delta_{j[ij]}$, $d_{ik} = \delta_{i[ij]} + \delta_{k[ij]}$ et $d_{jk} = \delta_{j[ij]} + \delta_{k[ij]}$, on tire la formule (5.18) de la distance triangulaire.

suivant, dit de Fitch-Margoliash, permet de construire un arbre dont les dissimilarités (δ_{ij}) sont proches des dissimilarités d'origine (d_{ij}), avec la propriété que $\delta_{ij} = d_{ij}$ ssi les (d_{ij}) sont des dissimilarités d'arbre.

L'algorithme FM : à partir de la matrice de dissimilarité (d_{ij}), on construit un arbre en joignant la paire la plus proche (i, j) et en la remplaçant par un noeud $[ij]$. La dissimilarité $\delta_{i[ij]}$ entre i et le noeud $[ij]$ peut s'estimer comme

$$\delta_{i[ij]} := \frac{1}{2}(d_{ij} + d_{ik} - d_{jk}) \quad (\text{formule de la distance triangulaire}) \quad (5.18)$$

où k est n'importe quel objet différent de i et j . Si les dissimilarités étaient des dissimilarités d'arbre, la quantité $\delta_{i[ij]}$ dans (5.18) ne dépendrait pas de k . En général ce n'est pas le cas, et l'on estime alors $\delta_{i[ij]}$ en prenant la moyenne sur tous les k possibles :


$$\delta_{i[ij]} := \frac{1}{n-2} \sum_{k; k \neq i, j} \left[\frac{1}{2}(d_{ij} + d_{ik} - d_{jk}) \right] \quad (5.19)$$

(et $\delta_{j[ij]}$ s'obtient comme $\delta_{j[ij]} = d_{ij} - \delta_{i[ij]}$). On estime alors la dissimilarité $\delta_{l[ij]}$ entre le noeud $[ij]$ et un autre objet $l \neq i, j$ comme

$$\delta_{l[ij]} := d_{il} - \delta_{i[ij]} \quad (5.20)$$

On dispose maintenant d'une nouvelle matrice $((n-1) \times (n-1))$ de dissimilarités et l'on recommence le processus jusqu'à aggrégation complète.

Exemple 4

FIGURE 5.8 – Arbre et dissimilarités d'arbre (δ_{ij}) (5.24) approximant les dissimilarités (d_{ij}) de départ (5.21)

A partir de la dissimilarité suivante

$$d = \begin{pmatrix} & a & b & c & d & e \\ a & 0 & 1 & 3 & 5 & 6 \\ b & 1 & 0 & 4 & 4 & 6 \\ c & 3 & 4 & 0 & 2 & 7 \\ d & 5 & 4 & 2 & 0 & 7 \\ e & 6 & 6 & 7 & 7 & 0 \end{pmatrix} \quad (5.21)$$

on agrège d'abord a et b . La dissimilarité $\delta_{a[ab]}$ (formule (5.19)) s'obtient comme moyenne entre $\frac{1}{2}(1+3-4) = 0$ (avec $k = c$), $\frac{1}{2}(1+5-4) = 1$ (avec $k = d$) et $\frac{1}{2}(1+6-6) = \frac{1}{2}$ (avec $k = e$), c'est à dire $\delta_{a[ab]} = \frac{1}{2}$, d'où $\delta_{b[ab]} = 1 - \frac{1}{2} = \frac{1}{2}$. On calcule alors (formule (5.20)) $\delta_{c[ab]} = 3 - \frac{1}{2} = \frac{5}{2}$, $\delta_{d[ab]} = 5 - \frac{1}{2} = \frac{9}{2}$ et $\delta_{e[ab]} = 6 - \frac{1}{2} = \frac{11}{2}$, et l'on obtient la matrice réduite

$$d = \begin{pmatrix} & [ab] & c & d & e \\ [ab] & 0 & \frac{5}{2} & \frac{9}{2} & \frac{11}{2} \\ c & \frac{5}{2} & 0 & 2 & 7 \\ d & \frac{9}{2} & 2 & 0 & 7 \\ e & \frac{11}{2} & 7 & 7 & 0 \end{pmatrix} \quad (5.22)$$

On agrège alors c et d . La dissimilarité $\delta_{c[cd]}$ (formule (5.19)) s'obtient comme moyenne entre $\frac{1}{2}(2+2.5-4.5) = 0$ (avec $k = [ab]$) et $\frac{1}{2}(2+7-7) = 1$ (avec $k = e$), c'est à dire $\delta_{c[cd]} = 0.5$, d'où $\delta_{d[cd]} = 2 - 0.5 = 1.5$. On calcule alors (formule (5.20)) $\delta_{[ab][cd]} = 2.5 - 0.5 = 2$, $\delta_{e[cd]} = 7 - 0.5 = 6.5$ et l'on obtient la matrice réduite

$$d = \begin{pmatrix} & [ab] & [cd] & e \\ [ab] & 0 & 2 & 5.5 \\ [cd] & 2 & 0 & 6.5 \\ e & 5.5 & 6.5 & 0 \end{pmatrix} \quad (5.23)$$

En continuant l'agrégation, on obtient finalement l'arbre de la figure 5.8 correspondant à une matrice de dissimilarité d'arbre δ

$$\delta = \begin{pmatrix} & a & b & c & d & e \\ a & 0 & 1 & 3 & 4 & 7 \\ b & 1 & 0 & 3 & 4 & 7 \\ c & 3 & 3 & 0 & 2 & 7 \\ d & 4 & 4 & 2 & 0 & 8 \\ e & 7 & 7 & 7 & 8 & 0 \end{pmatrix} \quad (5.24)$$

5.6 Dissimilarités de Minkowski(q) ou de type L_q

Visualiser ou *représenter* une dissimilarité d consiste à trouver, pour chaque objet $i = 1, \dots, n$ des nombres $X = (x_{ik})$ (où x_{ik} est la k -ème coordonnée de l'objet i) reconstituant la dissimilarité d comme

$$d_{ij} = \sqrt[p]{\sum_{k=1}^p (x_{ik} - x_{jk})^2} \quad \text{pour tous } i, j \quad (5.25)$$

La condition (5.25) demande que la dissimilarité soit représentable comme *distance euclidienne*. Plus généralement, on définit

Définition 6

Une dissimilarité d entre n objets est *de type L_q* (ou de type Minkowski(q)) s'il existe des coordonnées x_{ik} ($i = 1, \dots, n$; $k = 1, \dots, p$) telles que

$$d_{ij} = \left(\sum_{k=1}^p |x_{ik} - x_{jk}|^q \right)^{\frac{1}{q}} \quad \text{pour tous } i, j \quad (5.26)$$

En particulier, les dissimilarités de type L_2 sont les dissimilarités euclidiennes. Parmi les dissimilarités de type L_q , les plus étudiées sont de type L_2 , L_∞ et L_1 .

5.7 Dissimilarités euclidiennes ou de type L_2

Les dissimilarités euclidiennes (5.25) réalisent les distances de la géométrie classique, où chaque objet $i = 1, \dots, n$ est représenté par un point muni de p coordonnées x_{ik} $k = 1, \dots, p$ tel que

$$d_{ij} = \sqrt{D_{ij}} \quad \text{avec} \quad D_{ij} = \sum_{k=1}^p (x_{ik} - x_{jk})^2 \quad \text{pour tous } i, j \quad (5.27)$$

comme il se doit dans un espace euclidien. Ici et par la suite, $D_{ij} := d_{ij}^2$ représente le *carré* des dissimilarités. Le plus petit p pour lequel une représentation du type (5.27) a lieu est appelé *dimension* de la représentation. On a toujours $p \leq n - 1$ pour des distances euclidiennes : 2 objets peuvent toujours être placés sur une droite, 3 objets dans un plan, etc.

Etant donnée une matrice de dissimilarités (d_{ij}) entre n objets :

- existe-il $(n \times p)$ coordonnées (x_{ik}) capable de reproduire exactement (voire de façon approchée) les dissimilarités par (5.27) ?
- si oui, comment déterminer ces coordonnées ?

Les méthodes de “multidimensional scaling” ou MDS (= “positionnement multidimensionnel”) répondent précisément à ces questions. Le MDS joue un rôle fondamental en analyse des données (le chapitre 6 lui sera consacré).

5.8 Dissimilarités de type L_∞ ou métriques

Une dissimilarité d_{ij} est de type L_∞ (ou de Chebychev) ss'il existe des coordonnées (x_{ik}) telles que $d_{ij} = \max_k |x_{ik} - x_{jk}|$: seul le trait k maximalement différent sur les deux objets contribue à leur dissimilarité. Il se trouve (Frechet, 1910), que l'ensemble des dissimilarités de type L_∞ recouvre exactement celui des dissimilarités métriques :




FIGURE 5.9 – d_{14} est proportionnelle à la surface hachurée. Par construction, $d_{ij} = 0$ ssi A_i et A_j recouvrent exactement la même surface.

Théorème 2 (dissimilarités de type L_∞)

La dissimilarité d_{ij} est de type L_∞ ssi l'inégalité triangulaire

$$d_{ij} + d_{jl} \geq d_{il} \quad (5.28)$$

est vérifiée pour tous les triples d'objets (i, j, l) . Dans ce cas, les coordonnées $x_{ik} := d_{ik}$ ($k = 1, \dots, n$) définissent une représentation de type L_∞ , i.e. telle que $d_{ij} = \max_k |x_{ik} - x_{jk}|$.⁴

5.9 Dissimilarités de type L_1 ou de bloc

Une dissimilarité de type L_1 s'exprime comme $d_{ij} = \sum_k |x_{ik} - x_{jk}|$, à savoir *comme la somme de la différence absolue de leurs valeurs sur l'ensemble de tous les traits*. Dans le cas fréquent où les traits sont binaires et codés comme $x_{ik} = 1$ = “présence du trait k dans l'objet i ”, et $x_{ik} = 0$ = “absence du trait”, la dissimilarité $d_{ij} = \sum_k |x_{ik} - x_{jk}|$ compte le nombre de traits sur lesquels les objets i et j diffèrent.

Dans le cas général, on peut montrer qu'une dissimilarité est de type L_1 ss'il existe une probabilité $P()$, une constante $\mu > 0$ et n événements $A_1, \dots, A_n$ tels que

$$\frac{1}{\mu} d_{ij} = P(A_i \Delta A_j) = P(A_i \cup A_j) - P(A_i \cap A_j) \quad (5.30)$$

où Δ est l'opération de *différence symétrique* (rappel : $A \Delta B := (A \cup B) \setminus (A \cap B)$). Pour cette raison, les dissimilarités de type L_1 sont également appelées dissimilarités de *différence symétrique*. La constante $\mu > 0$ n'a pour seul effet que de changer l'échelle des dissimilarités.

Exemple 5

On considère n surfaces $A_1, \dots, A_n$, et la probabilité $P(A)$ = “probabilité qu'une goutte de pluie tombe dans A ” (figure 5.9). Alors la dissimilarité (5.30) est de type L_1 , et d_{ij} est égale (à un facteur μ près) à l'union des surfaces A_i et A_j , moins leur intersection.

Exemple 6

Dans le cas où les événements sont disjoints (i.e. $A_i \cap A_j = \emptyset$ pour $i \neq j$), alors $P(A_i \cup A_j) - P(A_i \cap A_j) = P(A_i) + P(A_j)$, et la dissimilarité (5.30) s'exprime, pour $i \neq j$, comme $d_{ij} = a_i + a_j$, avec $a_i, a_j \geq 0$.

4. (*) **Preuve** : supposons qu'il existe des coordonnées x_{ik} telles que $d_{ij} = \max_k |x_{ik} - x_{jk}|$. Alors

$$d_{ij} + d_{jl} = \max_k |x_{ik} - x_{jk}| + \max_k |x_{jk} - x_{lk}| \leq \max_k |x_{ik} - x_{lk}| = d_{il} \quad (5.29)$$

Inversément, si l'inégalité triangulaire est vérifiée, on a pour $i \neq j$ et pour tout l , que $d_{li} + d_{ij} \geq d_{lj}$ et $d_{lj} + d_{ji} \geq d_{li}$. Ainsi, $d_{ij} \geq d_{li} - d_{jl} \geq -d_{ij}$, et donc $|d_{li} - d_{jl}| \leq d_{ij}$, l'égalité étant atteinte pour $l = i$ ou $l = j$. En définissant $x_{ik} := d_{ik}$, on obtient finalement $\max_k |x_{ik} - x_{jk}| = \max_k |d_{ik} - d_{jk}| = d_{ij}$. $\square$




FIGURE 5.10 – La dissimilarité d'étoile $d_{ij} = a_i + a_j$ (pour $i \neq j$), de type L_1 , constitue également une dissimilarité d'arbre




FIGURE 5.11 – Inclusions (strictes) entre les diverses classes de dissimilarité étudiées.

Il s'agit d'une dissimilarité particulière, de type L_1 , appelée *dissimilarité en étoile* (figure 5.10), qui constitue également une dissimilarité d'arbre. Cette dissimilarité d_{ij} pourrait modéliser la distance qu'il faut parcourir pour aller du lieu périphérique i vers le lieu périphérique j lorsque toutes les voies de communication passent par un centre commun ou *hub*, représenté par le noeud 0 sur la figure 5.10.

5.9.1 (*) Distance quasi-hypermétrique ou distance cond. définie négative

Une dissimilarité d_{ij} est dite *quasi-hypermétrique* si elle est *conditionnellement négative définie*, i.e. si

$$\sum_{ij} d_{ij} h_i h_j \leq 0 \quad \text{pour tout } h \text{ tel que } \sum_{i=1}^n h_i = 0$$

Il se trouve que d est quasi-hypermétrique ssi elle constitue le *carré d'une distance euclidienne* - une autre propriété remarquable des distances euclidiennes carrées (voir chapitre 6).

5.10 Inclusions entre dissimilarités

On note par

- L_1 l'ensemble des dissimilarités de bloc
- L_2 l'ensemble des dissimilarités euclidiennes
- L_∞ l'ensemble des dissimilarités métriques
- A l'ensemble des dissimilarités d'arbre
- U l'ensemble des dissimilarités ultra-métriques




FIGURE 5.12 – Réseau piéton de Lausanne. Source : Théophile Emmanouilidis, IGD-FGSE-UNIL et Commune de Lausanne

On a déjà pu observer que $U \subset A \subset L_\infty$, ou que $L_2 \subset L_\infty$. On peut prouver (voir par exemple Critchley et Fichet 1994) l'existence d'autres inclusions entre classes, résumées par la figure (5.11). Il apparaît que le type ultra-métrique est le plus restreint, et le type métrique le plus général.

5.11 Autres dissimilarités

5.11.1 Distance du plus court chemin

Un *graphe simple* $G = (V, E)$ est donné par un ensemble V (= “vertices”) de n sommets ou noeuds, reliés (ou non) par des arrêtes (E = “edges”) plus ou moins longues. La *distance du plus court chemin* d_{ij} entre deux noeuds i et j est définie comme la *longueur du plus court chemin reliant i et j* .

Si le graphe est un arbre (i.e. ne contient pas de circuits), la distance du plus court chemin se confond avec la distance d'arbre associée (section 5.5). En général ce n'est pas le cas (figure 5.12), et d_{ij} , bien que très simple à définir et très intuitive dans sa conception, ne possède pas de propriétés formelles évidentes (si ce n'est d'être métrique, évidemment), ce qui la rend *bien difficile à manipuler d'un point de vue mathématique*.

5.11.2 Distance d'édition

Une possibilité d'évaluer la dissimilarité entre deux mots (considérés comme deux chaînes de caractère) est de compter le *nombre minimal de suppressions, d'insertions ou de remplacements* permettant de transformer un mot en un autre. Cette *distance d'édition* (aussi appelée *distance de Levenshtein*) constitue une *distance du plus court chemin*.

La version pondérée de la distance d'édition, consistant à attribuer des coûts différents aux suppressions, d'insertions et remplacements, et à rechercher la transformation de coût minimal, constitue également une distance du plus court chemin.

5.12 Scores catégoriels binaires

Pour p variables **qualitatives**, on se limitera essentiellement au cas fréquent de variables **binaires**, i.e. ne prenant que 2 modalités, exprimant de fait la présence ou l'absence d'un attribut, comme par exemple X_1 = “est retraité”, X_2 = “possède une résidence secondaire”, X_3 = “a des enfants”, etc....

Il est commode d'utiliser le codage binaire $x_{ik} = 1$ si l'objet i possède l'attribut k , et $x_{ik} = 0$ sinon⁵. Aussi, on utilisera la notation

a_{ij} = nombre de co-occurrences

b_{ij} = nombre d'attributs présents chez i et absents chez j

c_{ij} = nombre d'attributs absents chez i et présents chez j

$\bar{d}_{ij}$ = nombre de co-absences (on utilise ici la notation $\bar{d}_{ij}$ pour la distinguer de d_{ij})

Naturellement, $a_{ij} + b_{ij} + c_{ij} + \bar{d}_{ij} = p$. La dissimilarité de type L_1 (section 5.9) $d_{ij} = \sum_{k=1}^p |x_{ik} - x_{jk}|$ vaut alors $b_{ij} + c_{ij}$, le nombre de traits sur lesquels i et j diffèrent. On a aussi $\sum_{k=1}^p (x_{ik} - x_{jk})^2 = b_{ij} + c_{ij}$, ce qui fait de $d_{ij} := \sqrt{b_{ij} + c_{ij}}$ une dissimilarité euclidienne.

Il est courant de rencontrer dans le cas de scores binaires des **indices de similarité** s_{ij} , satisfaisant (ce n'est pas la seule calibration possible, mais la plus courante)

$$s_{ij} \geq 0 \qquad s_{ij} = s_{ji} \qquad s_{ii} = 1 \qquad s_{ij} \leq 1 \qquad (5.31)$$

Une telle similarité s_{ij} peut être alors convertie en dissimilarité par $d_{ij} = 1 - s_{ij}$, tout simplement.

Toute fonction non-négative $f(a_{ij}, b_{ij}, c_{ij}, \bar{d}_{ij})$ définit une similarité s_{ij} possible, pourvu qu'elle satisfasse à $f(a, b, c, \bar{d}) = f(a, c, b, \bar{d})$ (ce qui assure $s_{ij} = s_{ji}$) ainsi qu'à $f(a, 0, 0, \bar{d}) = 1$ (ce qui assure $s_{ii} = 1$), et qu'elle soit décroissante en b et c (ce qui assure $s_{ij} \leq 1$) : il existe une infinité de telles fonctions, et quantité d'indices plus ou moins inspirés et motivés ont été proposés dans la littérature et les logiciels. Les plus courants sont

$$s_{ij} = \frac{a_{ij} + \bar{d}_{ij}}{a_{ij} + b_{ij} + c_{ij} + \bar{d}_{ij}} \quad \text{similarité d'appariement simple (simple matching)} \quad (5.32)$$

$$s_{ij} = \frac{a_{ij}}{a_{ij} + b_{ij} + c_{ij}} \quad \text{similarité de Jaccard} \quad (5.33)$$

$$s_{ij} = \frac{2a_{ij}}{2a_{ij} + b_{ij} + c_{ij}} \quad \text{similarité de Dice-Sørensen} \quad (5.34)$$

On peut montrer que la dissimilarité de Jaccard est métrique⁶, mais que celle de Dice-Sørensen ne l'est pas (voir exercice 5.3).

Au contraire de la similarité d'appariement simple, les similarités de Jaccard et de Dice-Sørensen ne tiennent pas compte des co-absences $\bar{d}_{ij}$. L'idée sous-jacente à ces derniers indices est que la co-présence témoignerait davantage de la similarité entre individus que ne le ferait la co-absence : deux personnes toutes deux titulaires d'un doctorat en physique théorique, par exemple, sont susceptibles d'être plus similaires, toutes choses étant égales par ailleurs, que deux non-titulaires d'un doctorat en physique théorique. Ou que, parmi les habitants de Suisse, deux nationaux islandais seraient a priori plus similaires que ne le sont deux non-nationaux islandais. Cette similarité statistique induite par la co-appartenance peut être formellement justifiée (section 5.13.2) pour autant que la catégorie de co-appartenance soit *rare* (titulaire d'un doctorat en physique théorique ; de nationalité islandaise en Suisse ; etc...) ; elle ne peut pas s'appliquer à des catégories majoritaires telles que “possède deux bras” ou “se sent parfois découragé”...

5. en présence de variables catégorielles à plus de deux modalités, on peut procéder à une *dichotomisation*, transformant une variable catégorielle à m modalités en $m - 1$ variables binaires de présence / absence, aussi appelées “fonctions caractéristiques” ou “dummy variables”.

6. la démonstration n'est pas très difficile, mais pas immédiate non plus ; voir par exemple Späth (1981) ou Kosub (2016)

5.13 (*) Dissimilarités entre distributions

Il est fréquent que les objets $i = 1, \dots, n$ soient constitués d'agrégats d'individus, et que leurs profils représentent des *distributions* f_k^i sur p modalités, telles que $f_k^i \geq 0$ et $\sum_{k=1}^p f_k^i = 1$. Par exemple :

- f_k^i = “proportion d'occurrences du mot k dans le texte i ”
- f_k^i = “proportion d'employés du secteur k dans la région i ”
- f_k^i = “part de consommation de biens de type k par la population de classe socio-économique i ”.

Soit ρ_k la *fréquence relative moyenne* (avec $\sum_k \rho_k = 1$) de la modalité k sur l'ensemble de l'échantillon. Le rapport ou *quotient* $q_{ik} := f_k^i / \rho_k$ entre la proportion de k chez i et sa proportion moyenne indique la sur- ou sous-représentation de k dans i , selon que $q_{ik} > 1$ ou $q_{ik} < 1$. Par construction, la moyenne (pondérée) des quotients vaut un : $\sum_{k=1}^p \rho_k q_{ik} = 1$.

On peut définir des indices de dissimilarité d_{ij} entre les objets i et j comme

$$d_{ij} = \sum_{k=1}^p \rho_k F(q_{ik}, q_{jk}) \quad \text{avec} \quad F(q, q') \geq 0 \quad \text{et} \quad F(q, q) = 0 \quad (5.35)$$

La définition (5.35), très générale, a le mérite de satisfaire automatiquement le *principe d'invariance par agrégation* ou *principe d'équivalence distributionnelle*, qui dit que, si les proportions de deux modalités distinctes $k \neq k'$ étaient en rapport constant à travers l'ensemble des objets⁷, alors, en fusionnant les modalités k et k' en une super-modalité $[k \cup k']$ de poids $\rho_{[k \cup k']} = \rho_k + \rho_{k'}$, les quotients ainsi que la dissimilarité (5.35) resteraient inchangés.

On peut aussi considérer le cas particulier $F(q, q') = (h(q) - h(q'))^2$ et définir le *carré* d'une dissimilarité comme

$$D_{ij} = d_{ij}^2 = \sum_{k=1}^p \rho_k (h(q_{ik}) - h(q_{jk}))^2 \quad \text{où } h(q) \text{ est une fonction croissante} \quad (5.36)$$

Par définition, la dissimilarité d_{ij} définie par (5.36) est *euclydienne*, en plus d'être invariante par agrégation. Le membre principal de cette famille est la dissimilarité du *chi2*, obtenue pour $h(q) = q$, i.e.

$$D_{ij}^X = d_{ij}^2 = \sum_{k=1}^p \rho_k (q_{ik} - q_{jk})^2 = \sum_{k=1}^p \frac{(f_k^i - f_k^j)^2}{\rho_k} = \sum_{k=1}^p \left(\frac{f_k^i}{\sqrt{\rho_k}} - \frac{f_k^j}{\sqrt{\rho_k}} \right)^2 \quad (5.37)$$

Cette dissimilarité est à la base de l'*analyse des correspondances*, et s'obtient (selon 5.37) comme la distance euclydienne carrée entre les profils $f_k^i / \sqrt{\rho_k}$ et $f_k^j / \sqrt{\rho_k}$.

Les choix $h(q) = \ln(q)$, $h(q) = \sqrt{q}$ et $h(q) = q^\beta$, définissent respectivement les dissimilarités de *Hellinger*, *logarithmique* et de *puissance*. La dissimilarité de *présence-absence* s'obtient de $h(q) = I(q > 0)$, valant un si $q > 0$, et zéro sinon. La dissimilarité correspondante D_{ij} donne la somme des poids ρ_k des traits k présents chez i et absents chez j (ou l'inverse) (voir section 5.9).

5.13.1 Dissimilarité du chi2

De toutes les dissimilarités entre distributions, la dissimilarité du chi2 est de loin la plus courante, et on peut reprendre l'exposé général de la section précédente en allant directement au but, à partir d'une *table de contingence* $N = (n_{ik})$ donnant le nombre d'*occurrences* de la catégorie $k = 1, \dots, p$ dans l'objet $i = 1, \dots, n$ (par exemple : nombre d'apparitions du mot k dans le texte i ; nombre de personnes de nationalité k habitant la commune i , etc.).

7. par exemple : la proportion f_k^i de juristes employés par chaque administration régionale $i = 1, \dots, n$ pourrait varier d'une région à l'autre, mais vaudrait toujours le double de la proportion d'économistes $f_{k'}^i$.

La proportion de la catégorie k dans l'objet i est alors $f_k^i = \frac{n_{ik}}{n_{i\bullet}}$ (où l'on utilisé l'écriture $n_{\bullet} := \sum_{k=1}^p n_{ik}$); on peut montrer que $\sum_{k=1}^p f_k^i = 1$, comme il se doit. Aussi, $n_{\bullet\bullet} = \sum_{ik} n_{ik}$ est le nombre total d'occurrences, et $\rho_k = \frac{n_{\bullet k}}{n_{\bullet\bullet}}$ est la proportion de la catégorie k dans l'ensemble des données. Le rapport

$$q_{ik} = \frac{n_{ik}}{n_{ik}^{\text{theo}}} = \frac{n_{ik}}{\frac{n_{i\bullet} n_{\bullet k}}{n_{\bullet\bullet}}} = \frac{n_{ik} n_{\bullet\bullet}}{n_{i\bullet} n_{\bullet k}} = \frac{f_k^i}{\rho_k}$$

est le quotient d'indépendance, supérieur à 1 si la catégorie k est sur-représentée dans l'objet i , et inférieur à 1 si k est sous-représentée dans i (cf. chapitre 7). La dissimilarité du chi2 peut alors s'écrire comme (5.37), ou alternativement comme

$$D_{ij}^{\chi} = \sum_{k=1}^p \rho_k (q_{ik} - q_{jk})^2 = \sum_k \frac{n_{\bullet k}}{n_{\bullet\bullet}} \left(\frac{n_{ik} n_{\bullet\bullet}}{n_{i\bullet} n_{\bullet k}} - \frac{n_{jk} n_{\bullet\bullet}}{n_{j\bullet} n_{\bullet k}} \right)^2 \quad (5.38)$$

C'est une dissimilarité euclidienne carrée, i.e. $D^{\chi} \in L_2^2$.

5.13.2 (*) Le cas catégoriel univarié

En présence d'une seule variable catégorielle à $k = 1, \dots, p$ à modalités, le formalisme de la section 5.13 peut être utilisé pour définir la dissimilarité entre objets i et j différant (ou non) par les catégories respectives auxquelles ils appartiennent, notées $k[i]$ et $k[j]$. En considérant des distributions concentrées dans la catégorie en question (i.e. $f_k^i = \delta_{k, k[i]}$), la dissimilarité du chi2 devient

$$d_{ij} = \begin{cases} \frac{1}{\rho_{k[i]}} + \frac{1}{\rho_{k[j]}} & \text{si } k[i] \neq k[j] \\ 0 & \text{sinon} \end{cases} \quad (5.39)$$

où ρ_k est la proportion d'apparition de la catégorie k dans l'échantillon. Ainsi, deux individus i et j sont d'autant plus dissimilaires qu'ils appartiennent à des catégories (distinctes) *rare*s.

La dissimilarité (5.39) est euclidienne carrée : c'est un cas particulier de la dissimilarité du chi2. C'est aussi une dissimilarité L_1 , ainsi que d'arbre (cf. exemple 6 de la section 5.9).

Une *autre* approche au cas catégoriel univarié consiste à considérer le codage binaire donné par les variables indicatrices, à savoir $x_{ik} = 1$ si l'objet i est dans la catégorie k , et $x_{ik} = 0$ sinon (qui n'est autre que $x_{ik} = f_k^i = \delta_{k, k[i]}$ introduit plus haut). Les indices de co-présence et co-absence valent alors simplement $a_{ij} = 1$, $b_{ij} = c_{ij} = 0$ et $\bar{d}_{ij} = p - 1$ si i et j appartiennent à la même catégorie, et $a_{ij} = 0$, $b_{ij} = c_{ij} = 1$ et $\bar{d}_{ij} = p - 2$ sinon. Si i et j appartiennent à la même catégorie, leur similarité s_{ij} d'appariement simple, de Jaccard et de Dice-Sørensen sont toutes égales à 1, et les dissimilarités correspondantes $d_{ij} = 1 - s_{ij}$ toutes nulles, comme il se doit. Si i et j appartiennent à des catégories différentes, alors $s_{ij} = (p - 2)/p$ (et $d_{ij} = 2/p$) pour l'indice d'appariement simple, tandis que $s_{ij} = 0$ (et $d_{ij} = 1$) pour les indices de Jaccard et de Dice-Sørensen.

5.13.3 (*) (Dis)similarité du cosinus

En recherche documentaire (information retrieval), la similarité de base entre deux documents i et j est souvent quantifiée par la *similarité du cosinus*,

$$s_{ij} := \frac{\sum_{k=1}^p n_{ik} n_{jk}}{\sqrt{\sum_k n_{ik}^2} \sqrt{\sum_k n_{jk}^2}} = \frac{(\vec{n}_i, \vec{n}_j)}{\|\vec{n}_i\|_2 \|\vec{n}_j\|_2} = \frac{\|\vec{n}_i\| \|\vec{n}_j\| \cos \alpha_{ij}}{\|\vec{n}_i\| \|\vec{n}_j\|} = \cos \alpha_{ij} \quad (5.40)$$

où $\vec{n}_i \in \mathbb{R}^p$ est le profil du document i , dont les composantes sont données par n_{ik} , le nombre d'occurrences du terme k dans ce document, et α_{ij} est l'angle entre les vecteurs $\vec{n}_i$ et $\vec{n}_j$. Comme les composantes sont non-négatives, on a $0 \leq \alpha_{ij} \leq \frac{\pi}{2}$, et ainsi $0 \leq s_{ij} \leq 1$. Aussi, $s_{ii} = 1$, et la similarité du cosinus (5.40) obéit au schéma général (5.31). Il est facile de montrer que la dissimilarité correspondante $d_{ij} = 1 - s_{ij} = 1 - \cos \alpha_{ij}$ est de type L_2^2 , i.e. qu'elle constitue une distance euclidienne carrée.

5.14 Exercices et corrigés

Exercice 5.1

Voici les scores de 4 voitures pour $p = 3$ variables x = “nombre de chevaux”, y = “poids en kg” et z = “nombre de cylindres”.

	x	y	z
voiture 1	150	1710	8
voiture 2	230	1403	8
voiture 3	90	1079	4
voiture 4	90	1288	4

1. Calculer la moyenne et l'écart-type de x , y et z (avec une précision de une décimale)
2. Calculer les scores standardisés (avec une précision de 1 décimale).
3. A partir des scores standardisés, produire la matrice de dissimilarité entre voitures en utilisant
 - (a) la distance euclidienne $d_{ij}^{(a)} := \sqrt{\sum_{l=1}^p (x_{il} - x_{jl})^2}$
 - (b) la distance du city-block $d_{ij}^{(b)} := \sum_{l=1}^p |x_{il} - x_{jl}|$.

Exercice 5.2

On cherche à classer 4 écussons selon qu'ils contiennent (code 1) ou non (code 0) divers “meubles” (figures) :

	tourteau	besant	macle	rustre	billette	molette
écusson 1	1	0	0	1	0	1
écusson 2	0	1	0	1	0	1
écusson 3	1	1	0	0	0	0
écusson 4	0	1	1	0	1	0

Produire la matrice de dissimilarité entre écussons en calculant d'abord la similarité d'appariement simple $s^{(a)}$ (5.32) et la la similarité de Jaccard $s^{(b)}$ (5.33), puis en calculant les dissimilarités comme les complément $d_{ij}^{(a)} = 1 - s_{ij}^{(a)}$ et $d_{ij}^{(b)} = 1 - s_{ij}^{(b)}$ de ces similarités.

Exercice 5.3


1. Montrer que la similarité de Dice-Sørensen (5.34), notée δ_{ij} , peut s'obtenir de la similarité de Jaccard (5.33), notée s_{ij} , par la formule $\delta_{ij} = \frac{2s_{ij}}{1+s_{ij}}$
2. Soient p caractéristiques binaires. En notant par I l'ensemble des caractéristiques possédées par l'individu i , par J l'ensemble des caractéristiques possédées par l'individu J , et par $|A|$ le nombre d'éléments de l'ensemble A (i.e. sa *cardinalité*), montrer que la similarité de Jaccard (5.34) et la dissimilarité de Jaccard associée s'écrivent comme

$$s_{ij} = \frac{|I \cap J|}{|I \cup J|} \quad d_{ij} = \frac{|I \Delta J|}{|I \cup J|}$$


3. On considère p caractéristiques binaires, pour lesquelles p est un entier pair. La première moitié de ces caractéristiques est partagée par les individus i et k (mais pas par j), tandis que la seconde moitié de ces caractéristiques est partagée par les individus j et k (mais pas par i). Calculer les similarités et dissimilarités de Jaccard s_{ij} et $d_{ij} = 1 - s_{ij}$ ainsi que de Dice-Sørensen δ_{ij} et $\beta_{ij} = 1 - \delta_{ij}$. Montrer que l'inégalité triangulaire $d_{ij} + d_{jk} \geq d_{ik}$ est ici vérifiée pour la dissimilarité de Jaccard, mais pas pour celle de Dice-Sørensen, qui n'est ainsi pas métrique.

Exercice 5.4

1. Vérifier l'inégalité des quatre points (sur tous les quadruples de points *distincts*) pour la dissimilarité d'arbre induite par les arbres ci-dessous.




a)




b)

2. Que devient l'inégalité des quatre points si deux des points considérés (i.e. deux indices) sont les mêmes ? Et avec trois indices identiques ?
3. Peut-on définir une dissimilarité ultramétrique à partir des arbres ci-dessous ? Si oui, représenter le dendrogramme correspondant. Si non, montrer à l'aide d'un contre-exemple que l'inégalité ultramétrique n'est pas satisfaite.



a)



b)

Exercice 5.5

Spécialiste réputé d'analyse textuelle, Anselme se voit demander de départager deux chercheurs qui ne s'accordent pas sur la paternité d'un mélodrame prestigieux. Le doute subsiste sur qui de Y. Guex ou de G. Rochat l'a écrit. Afin de lui permettre de trancher, on lui fournit deux mélodrames de chacun d'entre eux, de taille à peu près égale ainsi que le texte litigieux.

Anselme décide d'utiliser les dissimilarités entre les textes pour attribuer les oeuvres. Il extrait uniquement la fréquence absolue de 4 verbes caractéristiques du mélodrame, à savoir : **vouloir**, **devoir**, **aimer** et **venger**. Il obtient la table de contingence ci-dessous :

	vouloir	devoir	aimer	venger	total	taille relative
Guex a	338	188	184	139	849	0.186
Rochat a	315	255	249	195	1014	0.222
Guex b	342	177	200	145	864	0.189
Rochat b	301	245	256	180	982	0.215
Texte litigieux	351	163	201	134	849	0.186
Total	1647	1028	1090	793	4558	1

En utilisant la distance du χ^2 , il calcule les dissimilarités suivantes entre les textes :

Questions :

1. Selon la table ci-dessus, quelles sont les paires de textes les plus similaires ?

	Guex a	Rochat a	Guex b	Rochat b	Texte 5
Guex a	0	0.0333	0.00223	0.0369	?
Rochat a	0.0333	0	0.0339	0.0014	?
Guex b	0.00223	0.0339	0	0.0358	?
Rochat b	0.0369	0.0014	0.0358	0	?
Texte litigieux	?	?	?	?	0

- Calculez quelques distance du chi2 entre le texte litigieux et les autres et tentez de déterminer son auteur.
- Admettons qu'un sixième texte, obtenu par la simple agrégation des 5 précédents, soit soumis à l'analyse. Sans effectuer de calcul, quel serait son profil ? De quel auteur serait-il plus proche ?

Exercice 5.6

On sait que les dissimilarités ultramétriques U sont euclidiennes (de type L_2), lesquelles sont des dissimilarités de bloc (de type L_1), lesquelles sont des dissimilarités métriques (de type L_∞), satisfaisant l'inégalité triangulaire : $U \subset L_2 \subset L_1 \subset L_2^2 \subset L_\infty$.

D'autre part, on sait que les dissimilarités de bloc sont des dissimilarités euclidiennes carrées : $L_1 \subset L_2^2$.

A quelle classe (U , L_2 , L_1 , L_2^2 ou L_∞), si possible la plus petite possible, appartiennent les dissimilarités suivantes ?

- d_{ij} = temps minimal pour rentrer de son lieu de travail ou d'étude i à son domicile j
- d_{ij} = coût minimal (en chf) pour se déplacer de son domicile i vers une destination j sur terre
- $d_{ij} = c > 0$ si $i \neq j$ et $d_{ii} = 0$
- $d_{ij} = c_i + c_j$ (avec $c_i \geq 0, c_j \geq 0$) si $i \neq j$ et $d_{ii} = 0$
- d_{ij} = "distance d'édition" ou "distance de Levenshtein" entre deux textes i et j , définie comme le nombre minimal de caractères qu'il faut supprimer, insérer ou remplacer pour transformer un texte en l'autre
- d_{ij} = "distance du chi2" entre deux lignes i et j d'une table de contingence
- d_{ij} = "nombre de catégories bimodales par lesquelles diffèrent les objets i et j "

Corrigé de la série 5

Exercice 5.1

- Les moyennes et les écarts-types valent : $\bar{x} = 140$, $\bar{y} = 1370$, $\bar{z} = 6$, $s_x = 57.4$, $s_y = 228.1$ et $s_z = 2$.
- Scores standardisés :

	x^s	y^s	z^s
voiture 1	.2	1.5	1
voiture 2	1.6	.1	1
voiture 3	-.9	-1.3	-1
voiture 4	-.9	-.4	-1

- Distances euclidiennes et distances du city-block :

$$(d_{ij}^{(a)}) =$$

	1	2	3	4
1	0	2	3.6	3
2	2	0	3.5	3.2
3	3.6	3.5	0	.9
4	3	3.2	.9	0

$$(d_{ij}^{(b)}) =$$

	1	2	3	4
1	0	2.8	5.9	5
2	2.8	0	5.9	5
3	5.9	5.9	0	.9
4	5	5	.9	0

Exercice 5.2

Dissimilarités d'appariement simple et de Jaccard :

$$(d_{ij}^{(a)}) =$$

	1	2	3	4
1	0	.33	.5	1
2	.33	0	.5	.66
3	.5	.5	0	.5
4	1	.66	.5	0

$$(d_{ij}^{(b)}) =$$

	1	2	3	4
1	0	.5	.75	1
2	.5	0	.75	.8
3	.75	.75	0	.75
4	1	.8	.75	0

Exercice 5.3

1. En supprimant les indices ij , on a $s = \frac{a}{a+b+c}$ et $\acute{s} = \frac{2a}{2a+b+c}$. Ainsi

$$\frac{2s}{1+s} = \frac{\frac{2a}{a+b+c}}{1 + \frac{a}{a+b+c}} = \frac{\frac{2a}{a+b+c}}{\frac{a+a+b+c}{a+b+c}} = \frac{2a}{2a+b+c} = \acute{s}$$

2. Par construction, $|I| = a_{ij} + b_{ij}$ est le nombre de caractéristiques partagées par i , $|I \cap J| = a_{ij}$ est le nombre de caractéristiques partagées par i et j , et $|I \cup J| = a_{ij} + b_{ij} + c_{ij}$ est le nombre de caractéristiques partagées par i ou (non exclusif) par j . Ainsi, $|I \cap J|/|I \cup J| = a_{ij}/(a_{ij} + b_{ij} + c_{ij}) = s_{ij}$. D'autre part, $d_{ij} = 1 - s_{ij} = 1 - a_{ij}/(a_{ij} + b_{ij} + c_{ij}) = (b_{ij} + c_{ij})/(a_{ij} + b_{ij} + c_{ij})$. Mais $b_{ij} + c_{ij}$ est le nombre de caractéristiques partagées par i (mais pas par j), additionné du nombre de caractéristiques partagées par j (mais pas par i), soit le nombre d'éléments contenus dans la *différence symétrique* $I \Delta J = (I \cup J) \setminus (I \cap J)$, égal à $|I \Delta J| = |I \cup J| - |I \cap J|$.
3. Par construction, $s_{ij} = 0$, $s_{ik} = \frac{p/2}{p} = \frac{1}{2}$ et $s_{kj} = \frac{1}{2}$, d'où $d_{ij} = 1 - 0 = 1$, $d_{ik} = 1 - \frac{1}{2} = \frac{1}{2}$ et $d_{kj} = \frac{1}{2}$: l'inégalité triangulaire $\frac{1}{2} + \frac{1}{2} \geq 1$ est vérifiée.

Par contre, en utilisant $\acute{s} = \frac{2s}{1+s}$, on trouve $\acute{s}_{ij} = \frac{2 \cdot 0}{1+0} = 0$, $\acute{s}_{ik} = \frac{2 \cdot \frac{1}{2}}{1+\frac{1}{2}} = \frac{2}{3}$ et $\acute{s}_{kj} = \frac{2}{3}$. Ainsi $\acute{d}_{ij} = 1 - 0 = 1$ et $\acute{d}_{ik} = \acute{d}_{jk} = 1 - \frac{2}{3} = \frac{1}{3}$, ce qui viole l'inégalité triangulaire $\frac{1}{3} + \frac{1}{3} \geq \frac{2}{3} \not\geq 1$.

Exercice 5.4

1. (a) Notons tout d'abord que l'inégalité des quatre points

$$d_{ij} + d_{kl} \leq \max(d_{ik} + d_{jl}; d_{il} + d_{jk}) \quad \text{pour tous } i, j, k, l \quad (5.41)$$


reste inchangée si les indices i et j (ou k et l) sont permutés. De même si les deux indices (i, j) sont échangés avec (k, l) . Il n'y a donc que trois quadruples de points à tester :

	i	j	k	l
1)	a	b	c	d
2)	a	c	b	d
3)	a	d	b	c

- 1) on obtient l'inégalité $d_{ab} + d_{cd} \leq \max(d_{ac} + d_{bd}; d_{ad} + d_{bc})$, qui est vraie :
 $1 + 3 \leq \max(3 + 5; 6 + 2) = 8$;
 2) on obtient l'inégalité $d_{ac} + d_{bd} \leq \max(d_{ab} + d_{cd}; d_{ad} + d_{cb})$, qui est vraie :
 $3 + 5 \leq \max(1 + 3; 6 + 2) = 8$;
 3) on obtient l'inégalité $d_{ad} + d_{bc} \leq \max(d_{ab} + d_{dc}; d_{ac} + d_{db})$, qui est vraie :
 $6 + 2 \leq \max(1 + 3; 3 + 5) = 8$.
- (b) les inégalités à tester sont les mêmes pour cet arbre. Numériquement :
- 1) $3 + 3 \leq \max(2 + 6; 5 + 3) = 8$;
 2) $2 + 6 \leq \max(3 + 3; 5 + 3) = 8$;
 3) $5 + 3 \leq \max(3 + 3; 2 + 6) = 8$.
2. (a) Dans le cas où deux indices sont égaux, prenons par exemple $i = j$. L'inégalité des quatre points devient $d_{ii} + d_{kl} \leq \max(d_{ik} + d_{il}; d_{il} + d_{ik})$, soit $d_{kl} \leq d_{ki} + d_{il}$, qui est l'inégalité triangulaire. Ceci

montre que toute dissimilarité d'arbre est métrique. Une inégalité analogue s'obtient dans le cas $k = l$. Par contre, si $i = k$, l'inégalité devient $d_{ij} + d_{il} \leq \max(d_{ii} + d_{jl}; d_{il} + d_{ji})$, soit $d_{ij} + d_{il} \leq \max(d_{jl}; d_{ij} + d_{il})$, qui est toujours vraie. Une inégalité analogue s'obtient si $i = l$, $j = k$ ou $j = l$.

- (b) Dans le cas où trois indices sont égaux, nous avons les quatre possibilités $i = j = k$, $i = j = l$, $i = k = l$ ou $j = k = l$. Dans les quatre cas, on obtient une inégalité qui est toujours vraie. Par exemple, pour $i = j = k$: $d_{ii} + d_{il} \leq \max(d_{ii} + d_{il}; d_{il} + d_{ii})$, soit $d_{il} \leq \max(d_{il}; d_{il}) = d_{il}$.
3. Il s'agit d'essayer de trouver (ou de créer) un nœud sur l'arbre qui se trouve à égale distance de chacun des points. S'il existe, ce nœud devient la racine du dendrogramme correspondant.
- (a) Ce n'est pas possible à partir de cet arbre. L'inégalité ultramétrique n'est pas respectée. En effet, $5 = d_{bc} > \max(d_{ba}; d_{ca}) = 4$.
- (b) Le point se trouvant sur l'arbre à une distance de 4 du point a , donc à une distance de 1 du nœud joignant les branches menant à a et à b , est à égale distance (4) de tous les points. La construction d'un dendrogramme est donc possible :



Les distances indiquées par le dendrogramme (définies ici par la hauteur du nœud joignant les objets ; en les définissant par la longueur du chemin joignant ces nœuds il faudrait diviser la hauteur par 2) sont bien les mêmes que celles que l'on peut lire sur l'arbre

Exercice 5.5

- Les textes de mêmes auteurs sont les plus proches, ce qui nous permet de continuer l'analyse. Les textes de Guex sont reliés par leur dissimilarité minimale (0.00223) et les textes de Rochat également (0.0014).
- Afin de calculer la dissimilarité du texte litigieux $i = 5$ aux autres textes, il faut tout d'abord calculer les distributions des mots f_i^k pour chaque individu (donc en ligne, i.e. normalisées à $\sum_i f_i^k = 1$). La table des fréquences relatives en ligne est la suivante :

	vouloir	devoir	aimer	venger	Total
Guex a	0.398	0.221	0.216	0.163	1
Rochat a	0.310	0.251	0.245	0.192	1
Guex b	0.395	0.204	0.231	0.167	1
Rochat b	0.306	0.249	0.260	0.183	1
Texte litigieux	0.413	0.191	0.236	0.157	1
Moyenne	0.361	0.225	0.239	0.1739	

La ligne "Moyenne" est obtenue en divisant le total en colonne par l'effectif total. Soit ρ_k , la fréquence marginale de la colonne k . Dans le cas de la première colonne, on a $\rho_1 = \frac{1647}{4558} = 0.361$. (Note : cette valeur peut également s'obtenir en effectuant la moyenne pondérée des fréquences relatives de chaque individu. On a alors $\rho_1 = (0.186 * 0.398) + (0.222 * 0.31) + (0.189 * 0.395) + (0.215 * 0.306) + (0.186 * 0.413) = 0.361$).

La table des dissimilarités du chi2 entre les textes qui découle des distributions ci-dessus peut alors être calculée selon la formule $D_{ij}^X = \sum_{k=1}^p (f_k^i - f_k^j)^2 / \rho_k$ de (5.37), qui donne : Au final, le texte peut être

$$D_{ij}^X =$$

	Guex a	Rochat a	Guex b	Rochat b	Texte litigieux
Guex a	0	0.0333	0.00223	0.0369	0.0063
Rochat a	0.0333	0	0.0339	0.0014	0.052
Guex b	0.0022	0.0339	0	0.0358	0.0022
Rochat b	0.0369	0.0014	0.0358	0	0.0524
Texte litigieux	0.0063	0.052	0.0022	0.0524	0

attribué à Guex car sa dissimilarité par rapport à ses autres textes est plus petite (0.0063 et 0.0022) que celles de Rochat (0.052 et 0.0524).

Note : si l'on préfère utiliser la formule équivalente $D_{ij}^X = \sum_{k=1}^p \rho_k (q_{ik} - q_{jk})^2$, il faut d'abord calculer les quotients (rapport entre effectifs observés et effectifs attendus sous indépendance) qui sont ici

$$(q_{ik}) =$$

	vouloir	devoir	aimer	venger
Guex a	1.102	0.982	0.906	0.941
Rochat a	0.860	1.115	1.027	1.105
Guex b	1.095	0.908	0.968	0.965
Rochat b	0.848	1.106	1.09	1.054
Texte litigieux	1.144	0.851	0.990	0.90

3. Son profil serait exactement le profil moyen tel qu'il est calculé au point précédent (avec des quotients tous égaux à 1). Comme les trois textes attribués à Guex représentent 56% (obtenu en sommant les fréquences marginales en ligne : $0.186 + 0.189 + 0.186$) des données totales, ce profil moyen aura tendance à être plus proche des textes de Guex que des textes de Rochat.

Exercice 5.6

1. L_∞ , i.e. de type métrique : passer en plus par un autre lieu k ne peut qu'augmenter la durée du trajet, i.e. $d_{ik} + d_{kj} \geq d_{ij}$ (inégalité triangulaire).
2. L_∞ , pour les mêmes raisons que ci-dessus.
3. U : l'inégalité ultramétrique correspondante $d_{ij} \leq \max_k (d_{ik}, d_{kj})$ est vérifiée
4. L_2^2 (voir cours, "distances en étoile" ; c'est également une dissimilarité d'arbre.)
5. L_∞ , pour les mêmes raisons que pour 1 et 2 ci-dessus.
6. L_2^2 , par construction (voir cours)
7. L_1 : en définissant $x_{ik} = 1$ si l'objet i appartient à la catégorie k , et $x_{ik} = 0$ si l'objet i n'appartient pas à la catégorie k , on a $d_{ij} = \sum_k |x_{ik} - x_{jk}|$.

Chapitre 6

Dissimilarités euclidiennes et MDS

6.1 Introduction

On considère une configuration (f, D) de n objets, munis de poids $f_i > 0$ tels que $\sum_{i=1}^n f_i = 1$, et de dissimilarités euclidiennes carrées D_{ij} , i.e. de la forme

$$D_{ij} = \|x_i - x_j\|^2 = \sum_{k=1}^p (x_{ik} - x_{jk})^2 = d_{ij}^2 \quad (6.1)$$

où la matrice $X = (x_{il})$, de type $n \times p$, représente les *coordonnées* des n objets dans un espace euclidien à p dimensions, et d_{ij} leur distance euclidienne.

La question de base du *multidimensional scaling* (MDS) (ou “positionnement multidimensionnel”) est la suivante :

- (0) étant donnée une dissimilarité $D \in \mathbb{R}^{n \times n}$ (ou bien une dissimilarité $d \in \mathbb{R}^{n \times n}$), existe-t-il des coordonnées $X \in \mathbb{R}^{n \times p}$ telle que D (respectivement d) puisse s’écrire sous la forme (6.1)¹ ? On parle aussi de *plongement isométrique* (isometric embedding) de D dans X .

Et, si oui (cas du MDS *classique* ou *métrique*) :

- (1) combien de coordonnées différentes p , i.e. combien de dimensions p sont alors nécessaires ?
(2) si seules $r < p$ coordonnées sont disponibles, comment les choisir de sorte qu’une proportion maximale de la dispersion totale Δ (laquelle dépend aussi des poids f en jeu ; cf. section 6.3.3) de la configuration soit exprimée ?

Et, si non (cas du MDS *approximatif* ou *non métrique*) :

- (3) comment représenter au mieux la configuration (f, D) par une distance euclidienne carrée $\hat{D}$ approximative, sur r dimensions, minimisant (en un sens restant à définir) les écarts entre D et $\hat{D}$?

La réponse aux questions (0) et (1) ne dépend que des distances entre objets. Par contre, la pondération f des objets intervient dans les questions (2) et (3).

La section 6.2 abordera le cas particulier du MDS non pondéré ou uniforme, où $f_i = 1/n$, limité mais bien plus connu dans la littérature. La section 6.3 abordera le cas général du MDS pondéré, lequel peut à son tour servir de base à toutes les méthodes factorielles, en particulier l’analyse des correspondances du chapitre 7.

1. Naturellement, si de telles coordonnées existent, toute translation $X \rightarrow X + \mathbf{1}a'$, ou toute rotation des coordonnées $X \rightarrow XU$, où U est orthonormale, constitue également une solution admissible générant la même dissimilarité D .

6.1.1 Exemple 1 : distances entre 12 villes britanniques

Les distances routières (en miles) entre 12 villes de Grande-Bretagne sont données par

$$d = \begin{pmatrix} \begin{matrix} \textit{Aberystwyth} & 0 & 244 & 218 & 284 & 197 & 312 & 215 & 469 & 166 & 212 & 253 & 270 \\ \textit{Brighton} & 244 & 0 & 350 & 77 & 167 & 444 & 221 & 583 & 242 & 53 & 325 & 168 \\ \textit{Carlisle} & 218 & 350 & 0 & 369 & 347 & 94 & 150 & 251 & 116 & 298 & 57 & 284 \\ \textit{Dover} & 284 & 77 & 369 & 0 & 242 & 463 & 236 & 598 & 257 & 72 & 340 & 164 \\ \textit{Exeter} & 197 & 167 & 347 & 242 & 0 & 441 & 279 & 598 & 269 & 170 & 359 & 277 \\ \textit{Glasgow} & 312 & 444 & 94 & 463 & 441 & 0 & 245 & 169 & 210 & 392 & 143 & 378 \\ \textit{Hull} & 215 & 221 & 150 & 236 & 279 & 245 & 0 & 380 & 55 & 168 & 117 & 143 \\ \textit>Inverness} & 469 & 583 & 251 & 598 & 598 & 169 & 380 & 0 & 349 & 531 & 264 & 514 \\ \textit>Leeds} & 166 & 242 & 116 & 257 & 269 & 210 & 55 & 349 & 0 & 190 & 91 & 173 \\ \textit>London} & 212 & 53 & 298 & 72 & 170 & 392 & 168 & 531 & 190 & 0 & 273 & 111 \\ \textit>Newcastle} & 253 & 325 & 57 & 340 & 359 & 143 & 117 & 264 & 91 & 273 & 0 & 256 \\ \textit>Norwich} & 270 & 168 & 284 & 164 & 277 & 378 & 143 & 514 & 173 & 111 & 256 & 0 \end{matrix} \end{pmatrix}$$

La matrice d donne les distances du plus court chemin (source : Mardia et al. 1979) ; peuvent-elles être convenablement approximées par des distances à vol d'oiseau, i.e. euclidiennes ? Si oui, on devrait pouvoir *visualiser* la configuration dans un espace de basse dimensionalité, typiquement à deux dimensions vu la planarité de la configuration, de façon à pouvoir y reconstituer le plus exactement possible les distances indiquées.

6.2 MDS uniforme

La question de la reconstitution exacte des distances, qui est l'objet du *MDS classique* (par opposition au MDS approché, appelé aussi *MDS non métrique*), est résolue par le théorème 3 ci-dessous (Schoenberg 1938 ; Young et Householder 1938). Il est basé sur l'introduction d'une matrice auxiliaire symétrique de taille $(n \times n)$, la *matrice des produits scalaires* $B = (B_{ij})$ relatifs à une origine fixée x_0 (figure 6.1).




FIGURE 6.1 – Par le théorème du cosinus $d_{ij}^2 = d_{i0}^2 + d_{j0}^2 - 2d_{i0}d_{j0} \cos \alpha$, le produit scalaire $B_{ij} = d_{i0}d_{j0} \cos \alpha$ entre $x_i - x_0$ et $x_j - x_0$ s'exprime comme $B_{ij} = -\frac{1}{2}(D_{ij} - D_{0i} - D_{0j})$. Lorsque $\alpha = 90^\circ$, on a $\cos \alpha = 0$ et on retrouve le théorème de Pythagore.

Supposons que d_{ij} soit représentable euclidiennement. Il existe alors n vecteurs x_i ($i = 1, \dots, n$) de dimension p tels que $D_{ij} = d_{ij}^2 = \sum_{k=1}^p (x_{ik} - x_{jk})^2$. En choisissant x_0 comme la moyenne (uniforme) ou *centre de gravité*

de la configuration², on a que

$$B_{ij} = \sum_{k=1}^p (x_{ik} - x_{0k})(x_{jk} - x_{0k}) \quad \text{où} \quad x_{0k} := \frac{1}{n} \sum_{i=1}^n x_{ik} . \quad (6.2)$$

Le vecteur x_0 est la moyenne ou *centre de gravité* des points x_i ($i = 1, \dots, n$), et B_{ij} est le produit scalaire centré entre $x_i - x_0$ et $x_j - x_0$ (figure 6.1). Par le théorème du cosinus, on a $D_{ij} = D_{i0} + D_{j0} - 2B_{ij}$. Les quantités D_{i0} et D_{j0} ne sont pas directement données, mais elles peuvent être calculées à l'aide des relations suivantes (principe de Huygens), valables pour des dissimilarités euclidiennes uniquement :

$$\frac{1}{n} \sum_{j=1}^n D_{ij} = D_{i0} + \Delta \quad \Delta = \frac{1}{n} \sum_{i=1}^n D_{i0} = \frac{1}{2} \frac{1}{n^2} \sum_{i,j=1}^n D_{ij} \quad (6.3)$$

où Δ est la dispersion uniforme ou l'*inertie* de la configuration, donnée par la moyenne du carré de la distance des objets à l'origine, ou, de façon équivalente, à la demi-moyenne du carré des distances entre toutes les paires d'objets. On tire des relations précédentes que

$$B_{ij} = -\frac{1}{2} \left(D_{ij} - \frac{1}{n} \sum_k D_{ik} - \frac{1}{n} \sum_k D_{jk} + \frac{1}{n^2} \sum_{kl} D_{kl} \right) \quad \text{i.e.} \quad B = -\frac{1}{2} (I - P) D (I - P)' \quad (6.4)$$

où D est la matrice des dissimilarités au carré, I est la matrice identité et $P = (p_{ij})$ la matrice de projection sur la droite des constantes, de composantes $p_{ij} = 1/n$ (voir chapitre 2). La *matrice de centration* $I - P$ transforme ainsi les scores bruts en scores centrés.

Une fois la matrice B des produits scalaires centrés obtenue, on peut appliquer le théorème suivant :

Théorème 3 (MDS classique non pondéré)

La dissimilarité (d_{ij}) est euclidienne (i.e. de type L_2) ssi B est semi-définie positive, i.e. ssi toutes ses n valeurs propres $(\lambda_1, \dots, \lambda_n)$ sont non négatives.

Dans ce cas, les coordonnées recherchées sont données par $x_{i\alpha} = \sqrt{\lambda_\alpha} u_{i\alpha}$, où $u_{i\alpha}$ est la i -ème composante du α -ème vecteur propre de B . Le nombre $p \leq n - 1$ de valeurs propres strictement positives est la dimension de la représentation³.

Comme d'habitude, on ordonne généralement les n valeurs propres $(\lambda_1, \dots, \lambda_n)$ de façon décroissante. On peut montrer qu'il existe au plus $p = n - 1$ valeurs propres non nulles, i.e. les dissimilarités euclidiennes entre n objets peuvent être représentées dans un espace à $n - 1$ dimensions au plus : par exemple, $n = 3$ objets définissent un triangle représentable dans un espace à $p = 2$ dimensions⁴.

On peut aussi montrer que la somme des valeurs propres est proportionnelle à l'inertie. Conserver $r < p$ dimensions seulement (typiquement $r = 2$) revient à effectuer une reconstruction approximative du nuage de

2. on pourrait choisir en fait n'importe quel point pour x_0 , par exemple un point de la configuration, généralement distinct du centre de gravité : cela n'altérerait pas la validité des théorèmes 3 et 4, ni le caractère euclidien ou non de la configuration ; toutefois, l'inertie correspondante ne serait pas minimale, et la représentation par les $r < p$ premières dimensions ne serait pas optimale du point de vue de la compression de la représentation à basse dimensionalité.

3. (*) Preuve : à partir de B , on obtient D par $D_{ij} = B_{ii} + B_{jj} - B_{ij}$. Les composantes de la décomposition spectrale $B = U \Lambda U'$ sont $B_{ij} = \sum_{\alpha} \lambda_{\alpha} u_{i\alpha} u_{j\alpha}$. Si tous les λ_{α} sont non négatifs, on peut définir $X := U \sqrt{\Lambda}$, c'est à dire $x_{i\alpha} := \sqrt{\lambda_{\alpha}} u_{i\alpha}$. Alors $B_{ij} = (X X')_{ij} = \sum_{\alpha} x_{i\alpha} x_{j\alpha}$ et donc

$$D_{ij} = B_{ii} + B_{jj} - 2B_{ij} = \sum_{\alpha} (x_{i\alpha}^2 + x_{j\alpha}^2 - 2x_{i\alpha} x_{j\alpha}) = \sum_{\alpha} (x_{i\alpha} - x_{j\alpha})^2 \quad (6.5)$$

ce qui montre que (d_{ij}) est euclidienne. Inversement, s'il existe des coordonnées euclidiennes $X = (x_{i\alpha})$, alors toutes les valeurs propres de $B := X X'$ sont non-négatives $\square$.

4. (*) On tire de (6.4) que $\sum_j B_{ij} = 0$, ce qui implique que $\mathbf{1}$ est un vecteur propre de B pour la va.p. dite *triviale* $\lambda_n = 0$, et que le centre de gravité est représenté à l'origine ($x_{0\alpha} = 0$ pour $\alpha = 1, \dots, n - 1$).




FIGURE 6.2 – Reconstruction exacte des dissimilarités (6.6) à deux dimensions

points, dont la qualité est donnée par la proportion d'inertie expliquée par les r premières valeurs propres :

$$\sum_{\alpha=1}^p \lambda_{\alpha} = \text{Tr}(B) = \sum_{i=1}^n B_{ii} = \sum_{\alpha=1}^p \sum_{i=1}^n x_{i\alpha}^2 = \sum_{i=1}^n D_{i0} = n \Delta$$

$$\frac{\sum_{\alpha=1}^r \lambda_{\alpha}}{\sum_{\alpha=1}^p \lambda_{\alpha}} = \text{proportion d'inertie expliquée par les } r \text{ premiers facteurs}$$

En résumé, les résultats du théorème 3 sont utiles à la représentation de configurations *non pondérées*, i.e. dont les objets sont tous de même poids.

6.2.1 Exemple 2 : application du MDS classique

Soient 7 objets de même poids, dont la matrice de dissimilarité d est donnée par :

$$d = \begin{pmatrix} 0 & 1 & \sqrt{3} & 2 & \sqrt{3} & 1 & 1 \\ 1 & 0 & 1 & \sqrt{3} & 2 & \sqrt{3} & 1 \\ \sqrt{3} & 1 & 0 & 1 & \sqrt{3} & 2 & 1 \\ 2 & \sqrt{3} & 1 & 0 & 1 & \sqrt{3} & 1 \\ \sqrt{3} & 2 & \sqrt{3} & 1 & 0 & 1 & 1 \\ 1 & \sqrt{3} & 2 & \sqrt{3} & 1 & 0 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 & 0 \end{pmatrix} \quad \text{donc} \quad D = \begin{pmatrix} 0 & 1 & 3 & 4 & 3 & 1 & 1 \\ 1 & 0 & 1 & 3 & 4 & 3 & 1 \\ 3 & 1 & 0 & 1 & 3 & 4 & 1 \\ 4 & 3 & 1 & 0 & 1 & 3 & 1 \\ 3 & 4 & 3 & 1 & 0 & 1 & 1 \\ 1 & 3 & 4 & 3 & 1 & 0 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 & 0 \end{pmatrix} \quad (6.6)$$

La définition (6.4) des produits scalaires donne

$$B = \frac{1}{2} \begin{pmatrix} 2 & 1 & -1 & -2 & -1 & 1 & 0 \\ 1 & 2 & 1 & -1 & -2 & -1 & 0 \\ -1 & 1 & 2 & 1 & -1 & -2 & 0 \\ -2 & -1 & 1 & 2 & 1 & -1 & 0 \\ -1 & -2 & -1 & 1 & 2 & 1 & 0 \\ 1 & -1 & -2 & -1 & 1 & 2 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} \quad (6.7)$$

Il faut maintenant trouver les valeurs propres et les vecteurs propres de B . Les colonnes de $B = (b_1 | b_2 | \dots | b_7)$ ne sont pas linéairement indépendantes, au vu des relations $b_3 = b_2 - b_1$; $b_4 = -b_1$; $b_5 = -b_2$; $b_6 = b_1 - b_2$; $b_7 = 0$: le rang de B vaut 2, ce qui implique que seules les deux premières valeurs propres sont non nulles. Ce sont $\lambda_1 = \lambda_2 = 3$ (et $\lambda_3 = \lambda_4 = \lambda_5 = \lambda_6 = \lambda_7 = 0$).

Ainsi, on peut représenter les $n = 7$ points dans un espace à $p = 2$ dimensions seulement (configuration planaire), en déterminant les deux premiers vecteurs propres (normés) u_{j1} et u_{j2} , puis en calculant les




FIGURE 6.3 – Reconstruction par SPSS des dissimilarités (d_{ij}) (6.6) à deux dimensions : les points a à g correspondent, dans cet ordre, aux points 1 à 7 précédents. La configuration est identique à celle de la figure (6.2), à une rotation de 90° près.

coordonnées $\sqrt{\lambda_\alpha} u_{j\alpha}$ pour $j = 1, \dots, 7$ et $\alpha = 1, 2$. On trouve finalement :

$$\begin{aligned} \text{point 1 : } \left(\frac{\sqrt{3}}{2}, \frac{1}{2}\right) \quad & \text{point 2 : } \left(\frac{\sqrt{3}}{2}, -\frac{1}{2}\right) \quad & \text{point 3 : } (0, -1) \quad & \text{point 4 : } \left(-\frac{\sqrt{3}}{2}, -\frac{1}{2}\right) \\ \text{point 5 : } \left(-\frac{\sqrt{3}}{2}, \frac{1}{2}\right) \quad & \text{point 6 : } (0, 1) \quad & \text{point 7 : } (0, 0) \end{aligned}$$

Ces 7 points forment les coordonnées d'un hexagone (figure 6.2) où la longueur des arrêtes vaut 1.

(*) MDS classique avec SPSS

A partir du fichier contenant la matrice carrée $(n \times n)$ des dissimilarités (d_{ij}) , (et non pas leurs carrés (D_{ij})), on choisit les options **Analyze** → **Scale** → **Multidimensional Scaling**. Puis on introduit les n colonnes de (d_{ij}) dans la fenêtre **Variables**, avec l'option **Data are distances (square symmetric)**, **Level of Measurement = Interval** et **Scaling Model = Euclidean distance**. Dans **Options**, demander **Group plots** (donnant la configuration proposée) et **Data Matrix** (rappelant les valeurs originales (d_{ij})). La figure (6.3) est un exemple de sortie SPSS sur les données de l'exemple 2.

6.2.2 (*) Le cas L_2 approximatif : MDS non-métrique

Il est fréquent que l'on cherche à positionner géométriquement des objets dont les dissimilarités de départ δ_{ij} ne sont pas euclidiennes. On essaye alors de transformer ces dissimilarités δ_{ij} en *dissimilarités ajustées* $\hat{d}_{ij}$ au moyen d'une fonction croissante $\hat{d}_{ij} := f(\delta_{ij})$, de façon à ce que les dissimilarités ajustées $\hat{d}_{ij}$ soient approximativement euclidiennes, i.e. soient proches de distances $d_{ij}(X)$ associées à une configuration X .

La transformation $f(\delta) \equiv f(\delta|\theta)$ peut dépendre de plusieurs paramètres θ , comme dans la fonction linéaire $f(\delta) := a\delta + b$ (deux paramètres a et b) ou dans la transformation exponentielle $f(\delta) := \exp(c\delta)$ (un paramètre c). On va chercher simultanément, et de façon itérative,

i) à déterminer une configuration X

ii) et à fixer les paramètres θ de sorte que les $\hat{d}_{ij} = f(\delta_{jj'})$ soient aussi proches des distances $d_{ij}(X)$ que possible. Le critère choisi est généralement celui des moindres carrés :

$$\text{déterminer } X_0 \text{ et } \theta_0 \text{ tels que } \min_{\theta, X} \sum_{i,j=1}^n (f(\delta_{ij}|\theta) - d_{ij}(X))^2 = \sum_{i,j=1}^n (f(\delta_{ij}|\theta_0) - d_{ij}(X_0))^2$$

La quantité suivante (indépendante de l'unité de dissimilarité choisie) est appelée *stress* :

$$\sigma := \sqrt{\frac{\sum_{i,j=1}^n (f(\delta_{ij}|\theta_0) - d_{ij}(X_0))^2}{\sum_{i,j=1}^n d_{ij}^2(X_0)}} \quad (6.8)$$

Le stress σ est une mesure de l'écart entre les dissimilarités observées (et transformées au mieux) $f(\delta_{ij}|\theta_0) = \hat{d}_{ij}$ et les distances euclidiennes $d_{ij}(X_0)$ données par la configuration X_0 (choisie au mieux). Par construction, $\sigma \geq 0$, avec $\sigma = 0$ ssi $\hat{d}_{ij} = d_{ij}(X_0)$.

6.2.3 Si B n'est pas définie positive - que faire ?

Lorsque B n'est pas définie positive, le théorème 3 ne s'applique pas, et deux stratégies simples peuvent être invoquées :

- 1) on peut renoncer au caractère euclidien de la visualisation de la configuration, comme dans le MDS non métrique de la section 6.2.2, ou bien, exiger que, dans cette dernière, l'ordre (croissant ou décroissant) des distances euclidiennes lue dans le nuage corresponde - si possible - à l'ordre des dissimilarités initiales (MDS ordinal)
- 2) on peut insister sur le caractère euclidien de la visualisation de la configuration, et modifier les dissimilarités non euclidiennes d_{ij} en dissimilarités euclidiennes δ_{ij} , au moyen de transformations $\delta_{ij} = f(d_{ij})$, dont les plus connues sont

$$\delta_{ij} = d_{ij}^\alpha \quad \text{transformation en puissance} \qquad \delta_{ij} = \begin{cases} d_{ij} + c & i \neq j \\ 0 & i = j \end{cases} \quad \text{expansion} \quad (6.9)$$

où $0 < \alpha < 1$ et $c > 0$. On peut montrer que les nouvelles distances δ_{ij} deviennent euclidiennes si α est suffisamment petit (puissance) ou si c est suffisamment grand : *élever une distance d_{ij} à une puissance suffisamment petite, ou éloigner suffisamment les points, rend la distance résultante forcément euclidienne* (Joly et Le Calvé 1986)⁵.

6.2.4 Exemple 1 (suite) : distances entre villes britanniques

L'application du MDS classique sur les distances entre les 12 villes de Grande-Bretagne est mise en échec par la présence de valeurs propres négatives, quoique faibles dans leur magnitude.

Cette observation n'est surprenante en soi : les distances initiales d_{ij} sont des distances routières (du plus court chemin), dont on sait qu'elles ne sont pas euclidiennes en général (voir chapitre 5). On peut essayer d'éloigner uniformément les villes les unes par rapport aux autres (équation 6.9), et les calculs numériques montrent que cette stratégie fonctionne *dès que cet éloignement est de 61 miles au moins* (figures 6.4 et 6.5)⁶.

5. (*) La valeur maximale de α assurant le caractère euclidien de d_{ij}^α est la *puissance* de d_{ij} . Par définition, $\alpha \geq 1$ si d_{ij} est euclidienne, et $\alpha \geq \frac{1}{2}$ si d_{ij} est euclidienne carrée. Aussi, $\alpha = \infty$ ssi d_{ij} est ultramétrique.

6. attention toutefois : plus les distances sont augmentées, moins la configuration est compressible dans les premières dimensions factorielles : l'éloignement indéfini conduit à la situation maximale incompressible des *dissimilarités discrètes* (section 6.4.4)




FIGURE 6.4 – “scree graph” des valeurs propres de B^h , pour les dissimilarités initiales d (gauche) et pour les dissimilarités transformées δ augmentées de 61 miles (droite)




FIGURE 6.5 – représentation euclidienne, à deux dimensions, des distances augmentées de 61 miles, totalisant 84% d’inertie expliquée dans les deux premières dimensions. Afin de comparer avec la carte géographique habituelle, la coordonnée $-x_2$ a été représentée en abscisse, et la coordonnée $-x_1$ en ordonnée.

6.3 MDS pondéré

6.3.1 Propriétés des distances euclidiennes : centre de gravité et dispersion

Centre de gravité

Les n objets sont munis de poids relatifs f (avec $f_i > 0$ et $\sum_{i=1}^n f_i = 1$) reflétant leur importance, qui peuvent être uniformes ($f_i = 1/n$) ou non. La moyenne pondérée $\bar{x}$ des coordonnées x_i des points (6.1) est

$$\bar{x} = \sum_i f_i x_i . \quad (6.10)$$

$\bar{x}$ est le lieu de référence de la configuration, de son *origine*, *barycentre*, *centre de gravité* ou *centroïde*, et dépend naturellement de la pondération f . Sa distance aux objets peut être notée D_{if} , où

$$D_{if} := D_{i\bar{x}} = \|x_i - \sum_j f_j x_j\|^2 \quad (6.11)$$

et s'exprime par la formule de Huygens

$$D_{if} = \sum_j f_j D_{ij} - \frac{1}{2} \sum_{jk} f_j f_k D_{jk} \quad (6.12)$$

dont le membre de droite *ne dépend que des distances entre objets*, et *non pas de leurs coordonnées*. Cette propriété remarquable caractérise les distances euclidiennes (carrées) : elle n'a pas d'analogue pour des distances non euclidiennes.

Dispersion

La mesure classique de la dispersion des profils individuels est donnée par l'*inertie* Δ , définie comme *la distance carrée moyenne au point de référence*, ou comme *la distance carrée moyenne entre paires d'objets*. Il se trouve (principe faible de Huygens) que ces deux quantités sont égales :

$$\sum_i f_i D_{if} = \frac{1}{2} \sum_{ij} f_i f_j D_{ij} := \Delta \quad (6.13)$$

L'inertie n'est autre que la généralisation multivariée de la variance pondérée, que l'on retrouve pour $p = 1$ (configuration unidimensionnelle).

6.3.2 Produits scalaires et distances

Distances $\rightarrow$ produits scalaires

Le produit scalaire de i et j relativement au centroïde $\bar{x}$ est la matrice $B = (B_{ij})$

$$B_{ij} := (x_i - \bar{x})'(x_j - \bar{x}) \quad (6.14)$$

On peut montrer par (6.1) que

$$B_{ij} = -\frac{1}{2}(D_{ij} - D_{if} - D_{jf}) \quad (6.15)$$

qui est le théorème du cosinus dans le triangle $\bar{x}, x_i, x_j$.

Produits scalaires $\rightarrow$ distances

Par ailleurs, on peut montrer que (6.11) entraîne aussi

$$B_{ij} = -\frac{1}{2}D_{ij} + \frac{1}{2} \sum_k f_k D_{ik} + \frac{1}{2} \sum_k f_k D_{jk} - \frac{1}{2} \sum_{kl} f_k f_l D_{kl} \quad (6.16)$$

qui s'écrit matriciellement comme

$$B = -\frac{1}{2}HDH'$$

où B est la matrice $n \times n$ des produits scalaires relativement à $\bar{x}$, D la matrice $n \times n$ des distance euclidiennes carrées, et $H = (h_{ij}) = I - \mathbf{1}f'$ est la matrice de *centration*, de composantes $h_{ij} = \delta_{ij} - f_j$. Il s'agit d'une matrice de projection, au sens où $H^2 = H$ (voir section 6.4.2; elle n'est toutefois plus symétrique dans le cas pondéré). La propriété $H'f = 0$ montre que $Bf = 0$, i.e. que f est ve.p. de B pour la va.p. zéro.

L'équation (6.16) permet ainsi de calculer les produits scalaires par "*double centration*" du carré des distances euclidiennes (fois $-1/2$), *sans avoir besoin de connaître explicitement les coordonnées*. Inversement, les distances euclidiennes carrées s'obtiennent des produits scalaires comme

$$D_{ij} = B_{ii} + B_{jj} - 2B_{ij} \quad (6.17)$$

6.3.3 MDS pondéré : décomposition spectrale des produits scalaires pondérés

Dans le cas pondéré général, on définit la matrice des *produits scalaires pondérés* par $K_{ij} := \sqrt{f_i f_j} B_{ij}$. Sa trace est égale à l'inertie de la configuration :

$$\text{trace}(K) = \sum_i f_i B_{ii} = \sum_i f_i D_{ii} = \Delta .$$

Il est facile de montrer que K est défini positif ssi B l'est également. On a le

Théorème 4 (MDS pondéré)

La dissimilarité (d_{ij}) est euclidienne (i.e. de type L_2) ssi K est définie positive, i.e. ssi toutes ses n valeurs propres ($\lambda_1, \dots, \lambda_n$) sont non négatives.

Dans ce cas, les coordonnées recherchées sont données par

$$x_{i\alpha} = \frac{\sqrt{\lambda_\alpha}}{\sqrt{f_i}} u_{i\alpha} \quad (6.18)$$

où $u_{i\alpha}$ est la i -ème composante du α -ème vecteur propre de K . Le nombre $p \leq n - 1$ de valeurs propres strictement positives est la dimension de la représentation complète. Les coordonnées du point de référence, l'inertie dans la dimension α ainsi que l'inertie totale valent

$$\bar{x}_\alpha = \sum_i f_i x_{i\alpha} = 0 \quad \sum_i f_i x_{i\alpha}^2 = \lambda_\alpha \quad \sum_{\alpha \geq 1} \lambda_\alpha = \Delta .$$

6.3.4 Exemple 3 : collaborations scientifiques de l'Inde

La table de la figure 6.6 donne le nombre de publications scientifiques $N = (n_{ik})$ (1993-2000) dont les co-auteurs sont des scientifiques indiens et des scientifiques d'autres pays $i = 1, \dots, 29$ (lignes), triés selon les disciplines $k = 1, \dots, 22$ (colonnes) (Anuradha et Urs 2007).

Les disciplines retenues $k = 1, \dots, 22$ sont :

AGD Agricultural Sciences	MBD Molecular Biology & Genetics
ASD Astrophysics	MCD Microbiology
BID Biology & Biochemistry	MSD Materials Science
CHD Chemistry	MTD Mathematics
CLD Clinical Medicine	NED Neuroscience
CSD Computer Science	OTH Multidisciplinary
ECD Economics & Business	PHD Physics
EGD Engineering	PLD Plant and Animal Science
EVD Ecology/Environment	PMD Pharmacology
GED Geosciences	PSD Psychology and Psychiatry
IMD Immunology	SSD Social Science

Country/discipline	AGD	ASD	BID	CHD	CLD	CSD	ECD	EGD	EVD	GED	IMD	LAD	MBD	MCD	MSD	MTD	NED	OTH	PHD	PLD	PMD	PSD	SSD
'ALGERIA'	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	4	0	0	0	0
'AUSTRALIA'	30	66	11	101	128	3	0	28	37	30	6	0	6	6	16	4	5	15	65	29	2	1	1
'AUSTRIA'	5	7	8	15	26	0	0	3	2	5	1	0	3	3	6	1	3	1	34	2	1	0	0
'BELGIUM'	3	22	20	46	23	1	0	11	4	3	3	0	9	9	2	4	0	8	67	29	4	0	0
'BRAZIL'	2	37	12	16	42	0	0	9	3	6	2	0	2	7	7	0	1	7	268	5	0	0	0
'CANADA'	62	23	43	169	114	31	1	118	39	35	6	0	10	14	29	55	17	13	251	50	6	0	0
'DENMARK'	23	23	7	63	19	2	0	6	4	2	2	0	6	2	0	5	0	7	28	5	10	0	0
'ENGLAND'	46	96	149	269	460	7	0	103	28	68	46	0	42	53	45	9	8	35	407	94	15	0	1
'FINLAND'	4	5	8	21	10	0	0	3	0	3	1	0	2	4	2	3	3	2	178	1	1	0	0
'FRANCE'	23	147	72	272	176	2	0	67	15	81	11	0	24	21	60	21	3	35	949	28	6	0	0
'GERMANY'	39	148	139	465	126	16	0	202	42	115	13	0	59	49	94	32	15	49	1560	91	32	0	0
'HONG-KONG'	1	8	2	20	37	1	0	7	4	4	0	0	3	5	2	6	0	0	13	0	1	0	0
'ISRAEL'	5	11	12	31	23	6	0	5	2	2	5	0	6	5	18	7	0	10	21	9	0	0	0
'ITALY'	6	185	49	227	98	2	0	101	3	42	1	0	8	2	63	19	3	35	2597	9	3	0	0
'JAPAN'	89	62	97	281	218	7	0	103	33	77	39	0	24	73	95	8	16	46	496	73	12	0	0
'MALAYSIA'	2	0	3	132	19	0	0	9	1	0	0	0	1	1	5	1	0	8	10	0	2	0	0
'NETHERLANDS'	28	51	11	53	43	5	3	17	15	7	9	0	10	12	5	15	2	7	903	16	4	0	0
'NEW-ZEALAND'	1	5	6	12	25	0	1	4	1	5	1	0	9	2	2	0	0	2	7	4	0	1	0
'NORTH-IRELAND'	1	22	24	4	6	0	0	0	0	0	1	0	0	13	2	0	0	3	37	13	0	0	0
'PEOPLES-R-CHINA'	12	20	11	55	55	0	0	28	2	4	4	0	0	15	8	2	2	7	476	5	1	0	0
'PHILIPPINES'	28	0	5	0	11	0	0	0	12	0	1	0	3	0	0	0	2	2	0	14	0	0	0
'RUSSIA'	3	32	20	68	15	0	0	32	0	38	1	0	4	3	7	2	0	6	697	3	0	0	0
'SCOTLAND'	13	8	26	34	37	0	0	4	16	9	7	0	3	13	4	2	2	3	28	26	3	0	0
'SINGAPORE'	0	0	5	5	11	2	2	39	1	1	0	0	4	2	20	5	3	4	16	3	1	0	0
'SOUTH-KOREA'	2	4	5	30	11	2	0	15	2	5	0	0	1	3	4	1	0	0	399	2	0	0	0
'SPAIN'	2	40	11	85	32	0	0	16	1	12	8	0	7	6	12	6	3	13	406	10	6	0	0
'SWEDEN'	6	18	27	25	53	2	0	15	9	12	10	0	6	8	16	2	6	7	130	3	1	0	0
'SWITZERLAND'	4	9	16	72	110	0	0	29	1	7	6	0	16	4	6	4	0	3	1136	1	0	0	0
'USA'	187	659	610	1205	1397	162	6	578	143	292	155	0	272	139	245	161	123	272	6874	261	95	4	5

FIGURE 6.6 – Nombre de publications co-écrites par des scientifiques indiens et étrangers (1993-2000), par pays et par domaine

Pour rappel, dans le cas d'une table de contingence, la dissimilarité naturelle entre lignes est celle du *chi2* (cf. chapitre 5)

$$D_{ij}^X = \sum_k \rho_k (q_{ik} - q_{jk})^2 = \sum_k \rho_k \left(\frac{n_{ik}n_{\bullet\bullet}}{n_{i\bullet}n_{\bullet k}} - \frac{n_{jk}n_{\bullet\bullet}}{n_{j\bullet}n_{\bullet k}} \right)^2 \quad \rho_k = \frac{n_{\bullet k}}{n_{\bullet\bullet}} \quad q_{ik} = \frac{f_k^i}{\rho_k} \quad f_k^i = \frac{n_{ik}}{n_{i\bullet}} \quad (6.19)$$

où le symbole $\bullet$ dénote une somme sur toutes les valeurs de l'indice correspondant.

f_i est le poids relatif du pays i , proportionnel à sa contribution scientifique cumulée sur tous les domaines $k = 1, \dots, 22$. Par construction, D^X est une distance euclidienne carrée, dont l'inertie associée est proportionnelle au *chi2* de la table de la figure 6.6, mesurant la dépendance entre lignes et colonnes :

$$\Delta(f) = \frac{1}{2} \sum_{ij} f_i f_j D_{ij}^X = \frac{\text{chi2}}{n_{\bullet\bullet}} =: \text{phi2} \quad (6.20)$$

La figure 6.7 donne la meilleure représentation bi-dimensionnelle de la configuration pondérée, exprimant 60% de l'inertie, i.e. 60% de la dépendance lignes-colonnes telle que mesurée par le *chi2*.

Bien évidemment, la même table (figure 6.6) permet de définir des distances $\tilde{D}_{kl}^X$ entre *colonnes*, permettant de représenter, par MDS pondéré, la configuration pondérée des *disciplines*, de poids relatifs ρ_k , et dont l'inertie correspondante totale est toujours égale à (6.20).

Il se trouve que les facteurs associés au MDS pondéré sur les pays correspondent aux facteurs associés au MDS pondéré sur les disciplines, avec des valeurs propres identiques. Cette circonstance permet de représenter *simultanément* les lignes et colonnes dans le *même* espace factoriel, et de visualiser ainsi l'attraction / répulsion entre lignes et colonnes (ici les pays et les disciplines).

La technique de visualisation ainsi définie s'appelle *analyse factorielle des correspondances* (AFC; voir chapitre 7) : elle exploite complètement la dualité lignes-colonnes associée à une table de contingence, et résulte simplement de l'application du MDS pondéré à la distance (6.19) du *chi2*.




FIGURE 6.7 – Configuration des 29 pays obtenue par MDS pondéré sur les distances du χ^2 (6.19), et proportion d’inertie expliquée. La taille des cercles est croissante avec le poids des pays, variant de 0.00014 (Algérie) à 0.38 (USA). Les coordonnées des USA sont proches de l’origine, laquelle représente le centre de gravité pondéré du nuage de points.

6.4 Autres propriétés et applications du MDS pondéré

6.4.1 (*) Le MDS comme fondement de l’ACP

L’analyse en composantes principales (ACP), qui vise à exploiter la corrélation entre variables de façon à en extraire un jeu réduit de facteurs non corrélés (compression avec perte), constitue de fait un cas particulier du MDS, pour des distances euclidiennes judicieusement choisies. Cet état de choses est une illustration de la *dualité individus-variables* (ou objets-traites) en analyse de données, qui, dans le cas d’espèce, aboutit à deux problèmes spectraux équivalents, possédant en particulier des va.p. identiques : l’un des problèmes est construit à partir des liaisons entre variables (ACP), et l’autre à partir des dissimilarités entre individus (MDS).

Explicitement, la matrice $n \times p$ des données $X = (x_{ik})$, munies de poids f (tels que $f_i > 0$ et $\sum_{i=1}^n f_i = 1$) permet de calculer les matrices symétriques $p \times p$ que sont les variances-covariances $\Sigma = (\sigma_{kl})$ et corrélations $R = (r_{kl})$ pondérées comme

$$\sigma_{kl} = \sum_{i=1}^n f_i (x_{ik} - \bar{x}_k)(x_{il} - \bar{x}_l) \quad \bar{x}_k = \sum_{i=1}^n f_i x_{ik} \quad r_{kl} = \frac{\sigma_{kl}}{\sqrt{\sigma_{kk}\sigma_{ll}}}$$

On peut montrer que :

- l’ACP sur $\Sigma = U\Lambda U'$ génère les même va.p. λ_α que le MDS pondéré appliqué aux distances euclidiennes carrés “brutes” $D_{ij} = \sum_k (x_{ik} - x_{jk})^2$. En particulier, $\Delta = \text{trace}(\Sigma) = \sum_{\alpha \geq 1} \lambda_\alpha$.
- l’ACP sur $R = U\Lambda U'$ génère les même va.p. λ_α que le MDS pondéré appliqué aux distances euclidiennes carrés “standardisées” $D_{ij} = \sum_k (x_{ik}^s - x_{jk}^s)^2$, où $x_{ik}^s = (x_{ik} - \bar{x}_k) / \sqrt{\sigma_{kk}}$. En particulier, $\Delta = \text{trace}(R) = \sum_{\alpha \geq 1} \lambda_\alpha = p$.
- au MDS pondéré effectué sur les distances euclidiennes carrés “de Mahalanobis” $D_{ij} = \sum_{kl} (x_{ik} - x_{jk})\sigma^{kl}(x_{il} - x_{jl})$, où $\Sigma^{-1} = (\sigma^{kl})$, correspond une nouvelle forme d’ACP consistant à décomposer spectralement la matrice identité I .

6.4.2 (**) Deux distributions f et g : autres propriétés des distances euclidiennes

Non seulement les poids f , mais toute autre distribution g (telle que $\sum_i g_i = 1$, sans contrainte sur les g_i , dont certaines composantes peuvent être nulles ou même négatives) satisfait également à toutes les propriétés (6.10), (6.11), (6.12) et (6.13) de la section 6.3.1.

Soient $\bar{x}_f$ et $\bar{x}_g$ les centroïdes correspondant aux distributions f et g . On peut alors montrer que

$$D_{fg} = D_{\bar{x}_f \bar{x}_g} = \|\bar{x}_f - \bar{x}_g\|^2 = -\frac{1}{2} \sum_{i,j=1}^n (f_i - g_i)(f_j - g_j) D_{ij} . \quad (6.21)$$

L'équation 6.21 permet ainsi de calculer la distance entre les centroïdes *sans avoir besoin de connaître explicitement les coordonnées*. Elle implique également la propriété dite de *négativité conditionnelle* pour D , à savoir que $\sum_{i,j} h_i h_j D_{ij} \leq 0$ pour tout h tel que $\sum_i h_i = 0$, qui est une condition nécessaire et suffisante pour que D soit une dissimilarité euclidienne carrée (voir section 5.9.1).

6.4.3 (**) Noyaux isotropes et transformations de Schoenberg

Le formalisme euclidien peut encore être étendu en considérant des *transformations de Schoenberg*, qui sont des applications $D_{ij} \rightarrow \tilde{D}_{ij} := \varphi(D_{ij})$ munies des propriétés

$$\varphi(0) = 0 \quad \varphi'(D) \geq 0 \quad \varphi''(D) \leq 0 \quad \varphi'''(D) \geq 0 \quad \text{etc.}$$

où $'$ dénote la dérivée de la fonction. On peut montrer (Schoenberg 1938) que ces fonctions transforment une distance euclidienne carrée D en une autre distance euclidienne carrée $\tilde{D}$ - permettant ainsi l'extension du formalisme, en manipulant les distances mais sans devoir connaître les coordonnées.

Parmi les transformations, on trouve

$$\varphi(D) = D^\alpha \quad 0 < \alpha < 1 \quad \varphi(D) = \ln(1 + D/a) \quad a > 0 \quad \varphi(D) = 1 - \exp(-\lambda D) \quad \lambda > 0$$

Par exemple, pour $\varphi(D) = \sqrt{D}$, la quantité $\sum_j f_j \sqrt{D_{ja}}$ est minimale pour $a =$ “médiane pondérée” de la pondération, laquelle diffère de la “moyenne pondérée” $a = \bar{x}$ qui minimise la la quantité $\sum_j f_j D_{ja}$. Ces transformations de Schoenberg permettent ainsi de générer des estimateurs de tendance centrale plus robustes que ne l'est la moyenne pondérée. Elles permettent aussi de définir des “*noyaux*” (kernels) isotropes, utilisés en “Machine Learning”, générant de nouvelles configurations $(f, \tilde{D})$, toujours euclidiennes, mais reliées de façon non-linéaire à la configuration initiale (f, D) , lesquelles permettent d'étendre avec profit les méthodes de l'Analyse des Données classique, en particulier en analyse discriminante et en clustering.

6.4.4 (*) Dissimilarité discrète uniforme et pondérée, dissimilarité en étoile

La *dissimilarité discrète* entre n objets est définie par $d_{ij} = 1$ si $i \neq j$ et $d_{ij} = 0$ si $i = j$, ce qu'on peut écrire à l'aide des composantes δ_{ij} de la matrice identité comme $d_{ij} = (1 - \delta_{ij})$. En particulier, $D_{ij} = d_{ij}^2 = d_{ij} = (1 - \delta_{ij})$. Cette dissimilarité discrète représente, pour $n = 4$, les distances entre les sommets d'un tétraèdre (figure 6.8).

Plus généralement, étant donné un vecteur $c \in \mathbb{R}^n$ de composantes non négatives, on peut définir la *dissimilarité en étoile* $D_{ij} = c_i + c_j$ pour $i \neq j$ (et $D_{ii} = 0$; voir figure 6.9 et la section 5.9). Il se trouve que cette dissimilarité est le *carré* d'une dissimilarité euclidienne.

Dans le cas de n objets munis de poids $f_i > 0$ avec $\sum_{i=1}^n f_i = 1$, des considérations en analyse des correspondances multiples (Le Roux et Rouanet 2004) ou proches de celles de la section 5.13.2 conduisent à définir les *dissimilarités discrètes pondérées* comme

$$D_{ij} = \begin{cases} \frac{1}{f_i} + \frac{1}{f_j} & \text{si } i \neq j \\ 0 & \text{sinon.} \end{cases} \quad (6.22)$$





FIGURE 6.8 – La distance entre les 4 sommets d'un tétraèdre est donnée par la métrique discrète

FIGURE 6.9 – Dissimilarité en étoile : $c_i + c_j$ représente le *carré* d'une distance euclidienne entre les objets distincts i et j

qui sont un cas particulier des dissimilarités en étoile (exemple 6). Ces dissimilarités discrètes pondérées, déjà rencontrées comme dissimilarité du chi2 dans le cas catégoriel univarié (section 5.13.1) ne dépendent que de la fréquence des catégories i et j auxquelles appartiennent les individus : plus ces dernières sont rares, plus grande est la dissimilarité. Par exemple, au niveau européen, la distance entre un belge (1.5% des habitants) et un suisse (1% des habitants) vaut

$$d(\text{belge}, \text{suisse}) = \frac{1}{0.015} + \frac{1}{0.01} = 166.7$$

tandis que $d(\text{belge}, \text{suisse}) = 1/0.0015 + 1/0.001 = 1666.7$ au niveau mondial.

On peut montrer que les produits scalaires et l'inertie associés à (6.22) sont

$$B_{ij} = \frac{\delta_{ij}}{f_i} - 1 \quad \Delta = \text{trace}(K) = \frac{1}{2} \sum_{ij} f_i f_j D_{ij} = n - 1 .$$

Aussi, les va.p. associées aux produits scalaires pondérés $K_{ij} = \sqrt{f_i f_j} B_{ij}$ sont *toutes égales* (à l'exception de la dernière), à savoir $\lambda_1 = \lambda_2 = \dots = \lambda_{n-1} = 1$ et $\lambda_n = 0$. Cette situation fait de la configuration définie par les dissimilarités discrètes pondérées *la moins compressible possible*, chacune des $n - 1$ premières dimensions exprimant une proportion identique $1/(n - 1)$ d'inertie expliquée.

Par exemple, le tétraèdre ($n = 4$, pondération uniforme) peut être projeté sur un espace unidimensionnel (avec 33.3% d'inertie expliquée), bidimensionnel (66.6% d'inertie expliquée) ou tridimensionnel (100% d'inertie expliquée, comme il se doit) : le tétraèdre ne *possède pas* d'axe principal (ou d'axe secondaire) qui le rapprocherait d'une ellipse ou d'un ellipsoïde, et dont l'existence permettrait de compresser utilement la configuration selon cet axe, en conservant une bonne proportion d'inertie expliquée.

En bref, les dissimilarités discrètes pondérées sont euclidiennes carrées, et leur compressibilité est *aussi mauvaise que possible*, chaque dimension factorielle expliquant $1/(n - 1)$ d'inertie.

Par contraste, les distances euclidiennes carrées *les plus compressibles* sont bien sûr les dissimilarités à une dimension de la forme $D_{ij} = (x_i - x_j)^2$, dont le premier et unique facteur explique 100% de l'inertie.

6.5 Exercices et corrigés

Exercice 6.1

Normer ou *normaliser* un vecteur $a \in \mathbb{R}^n$, c'est le diviser par sa norme $\|a\|_p$ de sorte que la norme résultante soit de 1, i.e. de sorte que $\|\frac{a}{\|a\|_p}\|_p = \frac{\|a\|_p}{\|a\|_p} = 1$. L'expression "vecteur normé" est ainsi ambiguë si p n'est pas défini. Typiquement, on utilise la norme $\|\cdot\|_2$ pour normaliser des vecteurs propres, et la norme $\|\cdot\|_1$ pour normaliser des effectifs (ce qui les transforme en distributions ou poids normalisés, justement).

Soient $a = (1, 2, 3)$ et $b = (3, -4)$. Normaliser a et b selon $\|\cdot\|_2$, $\|\cdot\|_1$ et $\|\cdot\|_\infty$.

Exercice 6.2

Soit $\{x_1, \dots, x_n\}$ un échantillon de n valeurs réelles, munies de poids $\{f_1, \dots, f_n\}$. Il n'y a aucune utilité pratique à effectuer le MDS sur une configuration (f, D) unidimensionnelle ($p = 1$), puisque les valeurs x_i constituent déjà des coordonnées reconstituant les dissimilarités par $D_{ij} = (x_i - x_j)^2$; toutefois, l'exercice permet de mieux assimiler les différentes notions en jeu :

1. que valent les produits scalaires B_{ij} ?
2. que valent les produits scalaires pondérés K_{ij} ?
3. montrer que le vecteur $v \in \mathbb{R}^n$ de composantes $v_i = \sqrt{f_i}(x_i - \bar{x})$ est un vecteur propre de K , et calculer la valeur propre λ associée
4. normaliser v (selon $\|\cdot\|_2$) pour en faire un vecteur propre normé u
5. calculer les coordonnées (6.18) obtenues par MDS.

Exercice 6.3

VRAI OU FAUX ?

1. d_{ij} est une distance euclidienne ssi la matrice obtenue par double centration (= soustraire aux lignes leur moyenne + soustraire aux colonnes leur moyenne) de $-d_{ij}^2$ est semi-définie positive, i.e. ne possède que des va.p. non négatives
2. l'inertie pondérée $\frac{1}{2} \sum_{ij} f_i f_j D_{ij}^x$ correspondant à la dissimilarité du chi2 D^x est égale au chi2, mesurant la dépendance entre lignes et colonnes de la table de contingence
3. (rappel : pour une configuration (f, D) on définit les produits scalaires comme $B^f = -\frac{1}{2} H^f D H^f$ où $H^f := I - \mathbf{1} f'$). Si la matrice B^f des produits scalaires relativement à la distribution f est semi-définie positive, alors $B^g := -\frac{1}{2} H^g D H^g$ (où $H^g := I - \mathbf{1} g'$ et g est une autre distribution normalisée à $\sum_i g_i = 1$) est également semi-définie positive.
4. si d_{ij} est une distance euclidienne satisfaisant à $d_{ik} + d_{kj} = d_{ij}$, alors le point k se trouve sur le segment d'extrémités i et j .
5. si d_{ij} est une distance euclidienne satisfaisant à $d_{ik}^2 + d_{kj}^2 = d_{ij}^2$, alors l'angle entre i et j mesuré depuis le point k est un angle droit.
6. (rappel : un ensemble A est *convexe* si tout segment dont les deux extrémités appartiennent à A est contenu dans A ; l'*enveloppe convexe* d'un ensemble A est le plus petit ensemble convexe qui contienne A).
 - (a) étant donné un échantillon *univarié* de n valeurs réelles $A = \{x_1, \dots, x_n\}$, l'enveloppe convexe de A est le segment $[\min_i x_i, \max_i x_i]$
 - (b) étant donné un échantillon *multivarié* de n points dans un espace à p dimensions $A = \{x_1, \dots, x_n\}$, où $x_i \in \mathbb{R}^p$, l'enveloppe convexe de A est donné par l'ensemble des combinaisons de la forme $\sum_{i=1}^n g_i x_i$ avec $\sum_i g_i = 1$ et $g_i \geq 0$.
 - (c) (*) si $x \in \mathbb{R}^p$ appartient à l'ensemble convexe A , alors λx , où $0 \leq \lambda \leq 1$ appartient également à A

- (d) (*) étant donné un échantillon *multivarié* de n points dans un espace à p dimensions $A = \{x_1, \dots, x_n\}$, où $x_i \in \mathbb{R}^p$, l'hyperplan $M(A)$ engendré par A est donné par l'ensemble des combinaisons de la forme $\sum_{i=1}^n g_i x_i$ avec $\sum_i g_i = 1$ (où les g_i peuvent être négatifs).
- (e) l'intersection de deux ensembles convexes A et B est un ensemble convexe.
- (f) l'union de deux ensembles convexes A et B est un ensemble convexe.

Corrigé de la série 6

Exercice 6.1

$$\|a\|_2 = \sqrt{1^2 + 2^2 + 3^2} = \sqrt{14} = 3.74 \text{ et } \frac{a}{\|a\|_2} = (0.27, 0.53, 0.80)$$

$$\|a\|_1 = |1| + |2| + |3| = 6 \text{ et } \frac{a}{\|a\|_1} = (0.17, 0.33, 0.50)$$

$$\|a\|_\infty = \max(|1|, |2|, |3|) = 3 \text{ et } \frac{a}{\|a\|_\infty} = (0.33, 0.67, 1.00)$$

$$\|b\|_2 = \sqrt{3^2 + (-4)^2} = \sqrt{25} = 5 \text{ et } \frac{b}{\|b\|_2} = (0.6, -0.8)$$

$$\|b\|_1 = |3| + |-4| = 7 \text{ et } \frac{b}{\|b\|_1} = (0.43, -0.57)$$

$$\|b\|_\infty = \max(|3|, |-4|) = 4 \text{ et } \frac{b}{\|b\|_\infty} = (0.75, -1.00) .$$

Exercice 6.2

1. $B_{ij} = (x_i - \bar{x})(x_j - \bar{x})$ où $\bar{x} = \sum_{i=1}^n f_i x_i$
2. $K_{ij} = \sqrt{f_i f_j} B_{ij} = \sqrt{f_i f_j} (x_i - \bar{x})(x_j - \bar{x})$
3. $(Kv)_i = \sum_j K_{ij} v_j = \sum_j \sqrt{f_i f_j} (x_i - \bar{x})(x_j - \bar{x}) \sqrt{f_j} (x_j - \bar{x}) = \sqrt{f_i} (x_i - \bar{x}) \sum_j f_j (x_j - \bar{x})^2 = \text{var}(x) \sqrt{f_i} (x_i - \bar{x}) = \text{var}(x) v_i$. Donc $Kv = \lambda v$ avec $\lambda = \text{var}(x)$.
4. $\|v\|_2 = \sqrt{\sum_i v_i^2} = \sqrt{\sum_i f_i (x_i - \bar{x})^2} = \sqrt{\text{var}(x)} = s_x$, et donc $u_i = \frac{v_i}{\|v\|_2} = \frac{\sqrt{f_i} (x_i - \bar{x})}{s_x}$
5. Les coordonnées du MDS données par l'équation (6.18) pour $p = 1$ (une seule dimension $\alpha = 1$) sont $\frac{\sqrt{\lambda}}{\sqrt{f_i}} u_i = \frac{\sqrt{\text{var}(x)}}{\sqrt{f_i}} \frac{\sqrt{f_i} (x_i - \bar{x})}{s_x} = x_i - \bar{x}$: ce sont ainsi simplement les scores centrées, qui ne diffèrent des scores bruts x_i que par translation de $-\bar{x}$ (qui est l'opération de centration, justement).

Exercice 6.3

1. VRAI : c'est le principe du MDS
2. FAUX (mais presque vrai) : l'inertie pondérée $\frac{1}{2} \sum_{ij} f_i f_j D_{ij}^2$ est égale au phi2, i.e. au chi2 divisé par l'effectif total
3. VRAI : le caractère euclidien ou non euclidien d'une dissimilarité d_{ij} ne dépend pas de la pondération f ou g en jeu : si le critère est satisfait pour une certaine distribution f , il le sera aussi pour une autre distribution g : passer de f à g revient à placer l'origine en $\bar{x}_g = \sum_i g_i x_i$ plutôt qu'en $\bar{x}_f = \sum_i f_i x_i$.
4. VRAI (faire un dessin)
5. VRAI (c'est le théorème de Pythagore)
6. (a) VRAI : l'enveloppe convexe de A contient tous les points des segments de la forme $[x_i, x_j]$ où $x_i, x_j \in A$, i.e. tous les points du plus grand segment $[\min_i x_i, \max_i x_i]$ contenu dans A .
- (b) VRAI : (faire un dessin à $p = 2$ dimensions) : la quantité $\bar{x}_g = \sum_i g_i x_i$ est la moyenne pondérée des points $\{x_i\}_{i=1}^n$. En considérant toutes les distributions g possibles, on va parcourir l'ensemble des positions dans un polyèdre défini par les sommets de A , à savoir son enveloppe convexe ; ainsi, tout point appartenant à l'enveloppe convexe de A peut être obtenu comme moyenne pondérée $\sum_{i=1}^n g_i x_i$, en choisissant judicieusement la pondération g .
- (c) FAUX en général : λx n'appartient pas à A , sauf si le vecteur nul $\mathbf{0}$ appartient à A , ce qui entraîne alors que $\lambda x = (1 - \lambda)\mathbf{0} + \lambda x \in A$ puisque A est convexe.
- (d) FAUX en général, sauf si le vecteur nul $\mathbf{0}$ appartient à A , auquel cas l'ensemble des points de la forme $\sum_{i=1}^n g_i x_i$ (sous la contrainte $\sum_i g_i = 1$, mais sans contrainte sur les signes des g_i) coïncide exactement avec l'ensemble points de la forme $\sum_{i=1}^n \alpha_i x_i$ (sans contrainte sur les α_i), qui est l'hyperplan $M(A)$ engendré par A .

- (e) VRAI. Illustration possible : l'intersection de deux disques est convexe.
- (f) FAUX. Illustration possible : l'union de deux disques n'est pas convexe.

6.6 Références pour les chapitres 5 et 6

- Anuradha, K.T. Urs, S.R. (2007) *Bibliometric indicators of Indian research collaboration patterns : A correspondence analysis*. Scientometrics 71, 179–189
- Bavaud, F. (2011) *On the Schoenberg Transformations in Data Analysis : Theory and Illustrations*. Journal of Classification 28, pp. 297–314
- Borg, I., Groenen, P. J. F. (2005) *Modern Multidimensional Scaling*, Springer
- Buneman, O.P. (1974) *A note on metric properties of trees*, J. Combinatorial Theory, Series B 17, pp. 48–50
- Critchley, F., Fichet, B. (1997) *The partial order by inclusion of the principal classes of dissimilarity on a finite set, and some of their basic properties*, pp. 5–65, in van Cutsem B. (ed.) *Classification and Dissimilarity Analysis, Lecture Notes In Statistics*. Springer
- Deza, M., Deza, E. (2009) *Encyclopedia of Distances*. Springer
- Joly, S., Le Calvé, G. (1986) *Etude des puissances d'une distance*. Statistique et Analyse de Données 11, pp. 30–50
- Kosub, S. (2016) *A note on the triangle inequality for the Jaccard distance*". arXiv :1612.02696[cs.DM]
- Le Roux B., Rouanet H. (2004) *Geometric data analysis : from correspondence analysis to structured data analysis*. Kluwer
- Mardia, K.V., Kent, J.T., Bibby, J.M. (1979) *Multivariate Analysis*. Academic Press
- Schoenberg, I. J. (1938) *Metric Spaces and Completely Monotone Functions*. The Annals of Mathematics 39, 811–841
- Späth, H. (1981) *The minsum location problem for the Jaccard Matrix*. OR Spektrum 3, 91–94
- Young, G., Householder, A. S. (1938) *Discussion of a set of points in terms of their mutual distances*. Psychometrika 3, 19–22

Chapitre 7

L'analyse des correspondances

7.1 Quotients d'indépendance

Soit $N = (n_{ik})$ une table de contingence $(m_1 \times m_2)$, comptant le nombre d'individus n_{ik} dans la catégorie $i = 1, \dots, m_1$ de X et $k = 1, \dots, m_2$ de Y (table 1).

Y = "origine" $k \rightarrow$	Grèce	Turquie	Yougoslavie	Portugal	Espagne	Italie	total	f
X = "destination" $i \downarrow$								
Allemagne	187	133	65	14	183	372	954	.37
France	5	8	20	103	346	340	822	.32
Suisse	7	4	4	1	79	500	595	.23
Pays-Bas	2	6	1	1	6	8	24	.01
Belgique+Luxembourg	8	7	0	2	32	95	144	.06
Autriche	2	5	19	0	2	3	31	.01
Suède	0	0	5	0	0	5	10	.004
total	211	163	114	121	648	1323	2580	1
ρ	.08	.06	.04	.05	.25	.51	1	

Table 1 : flux migratoires de travailleurs des pays européens du sud vers des pays européens du nord en 1965 (source : Magee (1971) "Problems of Economic Development and Migration in Southern Europe", in "Proceedings of the Sixth New Zealand Geography Conference", R.J.Johnson and J.M.Soons Eds., Christchurch N.Z., 179–185)

Comme d'habitude, $n_{i\bullet}$ dénote le profil marginal de la ligne i , et $n_{\bullet k}$ le profil marginal de la colonne k ; aussi, $n := n_{\bullet\bullet}$ est la taille de l'échantillon. On définit les profils moyens $f_i := \frac{n_{i\bullet}}{n}$, qui définissent le poids relatif de la ligne i , satisfaisant $\sum_{i=1}^{m_1} f_i = 1$ (voir table 1), ainsi que $\rho_k := \frac{n_{\bullet k}}{n}$ qui définissent le poids relatif de la colonne k , avec $\sum_{k=1}^{m_2} \rho_k = 1$.

Les flux n_{ik} varient fortement selon la destination i et l'origine k . On s'attend bien sûr à ce que les flux soient proportionnels aux poids f_i et ρ_k : c'est l'*effet de taille*. Cela étant, des flux particulièrement importants tels Pays-Bas-Turquie ou Autriche-Yougoslavie ne s'expliquent pas seulement par les effets de taille : il y a attractivité entre ces modalités, ou plus généralement des *effets de dépendance*.

Pour éliminer les effets de taille, on considère les *quotients d'indépendance* q_{jk} (table 2)

$$q_{ik} := \frac{n_{ik}}{n_{ik}^{\text{theo}}} = \frac{n_{ik} n}{n_{j\bullet} n_{\bullet k}} \quad n_{ik}^{\text{theo}} = \frac{n_{i\bullet} n_{\bullet k}}{n} \quad (7.1)$$

où n_{ik}^{theo} est l'effectif attendu sous l'hypothèse d'indépendance.

origine $k \rightarrow$ destination $i \downarrow$	Grèce	Turquie	Yougoslavie	Portugal	Espagne	Italie	moyenne pondérée
Allemagne	2.40	2.21	1.54	0.31	0.76	0.76	1
France	0.07	0.15	0.55	2.67	1.68	0.81	1
Suisse	0.14	0.11	0.15	0.04	0.53	1.64	1
Pays-Bas	1.02	3.96	0.94	0.89	0.995	0.65	1
Belgique+Lux.	0.68	0.77	0	0.30	0.88	1.29	1
Autriche	0.79	2.55	13.87	0	0.26	0.19	1
Suède	0	0	11.32	0	0	0.98	1
moyenne pondérée	1	1	1	1	1	1	1

Table 2 : quotients d'indépendance q_{ik} associés à la table 1.

Par construction, les q_{ik} sont non-négatifs, et leur moyenne pondérée vaut 1 :

$$\sum_{i=1}^{m_1} f_i q_{ik} = 1 \quad \sum_{k=1}^{m_2} \rho_k q_{ik} = 1 \quad (7.2)$$

Comme leur nom l'indique, les quotients d'indépendance mesurent l'écart à l'indépendance : par construction, $q_{ik} = 1$ ssi $n_{ik} = n_{ik}^{\text{theo}}$. Aussi, deux catégories i et k sont dites

- en attraction mutuelle si $q_{ik} > 1$
- en répulsion mutuelle si $q_{ik} < 1$
- en neutralité mutuelle si $q_{ik} \cong 1$.

Par exemple, “Autriche” et “Yougoslavie” sont en très forte attraction, “Pays-Bas” et “Grèce” en neutralité mutuelle, et “Suède” et “Turquie” en répulsion.

7.2 Géométrie de l'analyse des correspondances

7.2.1 Buts de l'analyse des correspondances

L'analyse factorielle des correspondances (AFC) a pour objectif premier la *visualisation simultanée* des catégories-lignes $i = 1, \dots, m_1$ et des catégories-colonnes $k = 1, \dots, m_2$ de façon à mettre en évidence les écarts à l'indépendance : deux catégories i et k en attraction (répulsion) auront ainsi des représentants proches (lointains). Aussi, deux catégories-lignes i et j (ou deux catégories-colonnes k et l) auront des représentants d'autant plus lointains que leurs profils relatifs (tels que donnés par leurs quotients d'indépendance associés) sont dissemblables. Pour être efficace, la visualisation doit en outre être de basse dimensionalité, typiquement bi-dimensionnelle : l'AFC réalise également une *projection optimale* de l'espace de représentation visuelle dans un plan factoriel bi-dimensionnel (ou un hyper-plan factoriel à 3 dimensions ou plus). Le choix de cette projection sera *optimal* au sens où la mesure totale de dépendance lignes-colonnes (qui est le chi2 en statistique classique) sera exprimée au mieux par les premiers facteurs retenus (sa part associée aux facteurs non retenus dans la visualisation étant alors perdue).

7.2.2 Distance du chi-carré

Pour comparer les profils relatifs de deux catégories i et j , on utilise la *dissimilarité du chi2* définie par la moyenne pondérée des carrés des différences entre quotients d'indépendance associés, à savoir (cf. table 3) :

$$D_{ij} := \sum_{k=1}^{m_2} \rho_k (q_{ik} - q_{jk})^2 \quad (7.3)$$

On peut démontrer les propriétés suivantes (voir chapitre 5) :

- D est une dissimilarité : $D_{ij} \geq 0$, $D_{ij} = D_{ji}$ et $D_{ii} = 0$.

- D est le carré d'une distance euclidienne : ainsi, il sera possible (par MDS) de représenter chaque catégorie $i = 1, \dots, m_1$ par un point dans un espace factoriel, de façon à ce que le carré de la distance entre chaque paire de points i et j soit précisément D_{ij} .
- Pour rappel, l'*inertie de paires* Δ associée au carré d'une distance euclidienne est définie comme la moitié de la moyenne pondérée des (carrés des) distances entre toutes les paires d'objets. De façon équivalente, Δ s'obtient aussi comme l'*inertie centrale*, définie comme la moyenne pondérée des (carrés des) distances entre les objets et le centre de gravité dénoté 0, de profil moyen $q_{0k} = 1$ pour tout k . Le nom de la dissimilarité (7.3) découle de la propriété spécifique

$$\Delta := \frac{1}{2} \sum_{i,j=1}^{m_1} f_i f_j D_{ij} = \sum_{i=1}^{m_1} f_i D_{i0} = \frac{1}{n} \sum_{i=1}^{m_1} \sum_{k=1}^{m_2} \frac{(n_{ij} - n_{ij}^{\text{theo}})^2}{n_{ij}^{\text{theo}}} = \frac{\text{chi2}}{n} =: \phi^2 \quad (7.4)$$

où l'indice du *phi-carré* ϕ^2 est simplement, à $1/n$ près, l'indice du chi2 associé à la table de contingence n_{ij} . Par construction, le phi-carré constitue une mesure de dépendance indépendante de la taille de l'échantillon : si tous les effectifs de la table 1 avaient été doublés, le chi2 aurait été également doublé, mais le phi2 serait resté le même.

- Enfin, D est invariante par agrégation (voir chapitre “Dissimilarités”) : si, par exemple, les quotients associés aux *colonnes* “Grèce” et “Turquie” avaient été les mêmes, il aurait été possible d'agréger ces deux pays en une seule entité (avec des quotients identiques, et un poids relatif constitué de la somme des poids des deux pays) sans que les distances D_{ij} entre *lignes* ne changent.

$$D = d^2 = \begin{pmatrix} 0 & 1.22 & 1.19 & .40 & .62 & 7.17 & 5.17 \\ 1.22 & 0 & 1.02 & 1.27 & .61 & 9.28 & 6.18 \\ 1.19 & 1.02 & 0 & 1.62 & .15 & 9.83 & 5.81 \\ .40 & 1.27 & 1.62 & 0 & .92 & 7.80 & 6.17 \\ .62 & .61 & .15 & .92 & 0 & 9.42 & 5.98 \\ 7.17 & 9.28 & 9.83 & 7.80 & 9.42 & 0 & 1.08 \\ 5.17 & 6.18 & 5.81 & 6.17 & 5.98 & 1.08 & 0 \end{pmatrix} \quad (7.5)$$

Table 3 : distances euclidiennes au carré D (= distances du chi2) entre catégories-lignes $i = 1, \dots, 7$; les distances proprement dites s'obtiennent comme $d_{ij} = \sqrt{D_{ij}}$.

7.2.3 L'extraction des facteurs

Les catégories lignes $i = 1, \dots, m_1$ forment un nuage de m_1 points munis de poids f_i et de distances mutuelles $\sqrt{D_{ij}}$ données par (7.3). Pour représenter au mieux l'inertie pondérée Δ (7.4) dans les basses dimensions, on effectue un MDS pondéré, qui consiste à diagonaliser la matrice $(m_1 \times m_1)$ des produits scalaires pondérés K , obtenue de la matrice des produits scalaires B comme :

$$K_{ij} = \sqrt{f_i f_j} B_{ij} \quad B_{ij} = \sum_{k=1}^{m_2} \rho_k (q_{ik} - 1)(q_{jk} - 1) \quad (7.6)$$

On peut montrer, au vu de la relation

$$K = CC' \quad \text{où} \quad C = (c_{ik}) \quad \text{avec} \quad c_{ik} := \sqrt{f_i \rho_k} (q_{ik} - 1) \quad (7.7)$$

que le rang de K , $r = \text{rang}(K)$, est borné supérieurement par $r \leq \min(m_1, m_2) - 1$: il existe au plus r valeurs propres non nulles.

La décomposition spectrale des produits scalaires pondérés $K = U \Lambda U'$ permet d'obtenir $x_{i\alpha}$, la coordonnée de la modalité i sur le facteur α comme $x_{i\alpha} = \frac{\sqrt{\lambda_\alpha}}{\sqrt{f_i}} u_{i\alpha}$. Par construction,

$$D_{ij} = \sum_{\alpha=1}^r (x_{i\alpha} - x_{j\alpha})^2 \quad \Delta = \sum_{\alpha=1}^r \lambda_\alpha = \text{trace}(K) = \sum_{i=1}^n f_i B_{ii} = \sum_i f_i D_{i0} \quad (7.8)$$

Summary						
Dimension	Singular Value	Inertia	Chi Square	Sig.	Proportion of Inertia	
					Accounted for	Cumulative
1	.495	.245			.511	.511
2	.379	.144			.301	.812
3	.294	.086			.180	.992
4	.060	.004			.007	.999
5	.016	.000			.001	1.000
Total		.479	1235.229	.000 ^a	1.000	1.000

a. 30 degrees of freedom

FIGURE 7.1 – Extraction des facteurs (SPSS) correspondant à l'exemple de la table 1. La colonne “Inertia” contient les va.p. λ_α et la colonne “Singular value” contient les $\sqrt{\lambda_\alpha}$ correspondants. Il y a $r = \min(7, 6) - 1 = 5$ va.p. non nulles, dont les deux premières expliquent une proportion de 81.2% d'inertie. L'inertie totale vaut $\phi^2 = .479$, et le rapport $n = \text{chi}2/\phi^2 = 1235.299/.479 = 2'580$ permet de retrouver la taille totale de l'échantillon. La valeur du $\text{chi}2$, à comparer avec une table du χ^2 à $(7 - 1)(6 - 1) = 30$ degrés de liberté, est très significative ($p < .0005$) : le pays d'origine dépend fortement du pays de destination et vice-versa.

où D_{i0} , le carré de la distance de la catégorie i au centre 0, vaut

$$D_{i0} = \sum_{\alpha=1}^r x_{i\alpha}^2 = \sum_{k=1}^{m_2} \rho_k (q_{ik} - 1)^2 \quad (7.9)$$

et constitue une mesure de l'*atypicité* de la modalité i , i.e. de son écart au profil moyen.

Comme d'habitude, on ordonne les va.p. de façon décroissante : $\lambda_1 \geq \lambda_2 \geq \dots \lambda_r \geq 0$. On peut aussi montrer (théorème de Perron-Frobenius) que $\lambda_1 \leq 1$.

7.2.4 Contributions

L'équation (7.8) montre que

$$\frac{\lambda_\alpha}{\Delta} = \frac{\lambda_\alpha}{\sum_{\alpha=1}^r \lambda_\alpha} = \text{proportion d'inertie expliquée par le facteur } \alpha$$

$$\frac{\sum_{\alpha=1}^K \lambda_\alpha}{\sum_{\alpha=1}^r \lambda_\alpha} = \text{proportion d'inertie expliquée par les } K \text{ premiers facteurs}$$

Ainsi, la mesure totale de dépendance $\text{chi}2 = n \Delta$ entre les variables X et Y se décompose additivement sur chacune des dimensions $\alpha = 1, \dots, r$, par ordre d'importance décroissante.

Au vu de l'orthogonalité des ve.p., et du fait que $u_i := \sqrt{f_i}$ est un ve.p. normé de K pour la va.p. triviale $\lambda = 0$ ¹, il est facile de démontrer les relations

$$\sum_i f_i x_{i\alpha} = 0 \quad \sum_i f_i x_{i\alpha}^2 = \lambda_\alpha \quad (7.10)$$

Ainsi, la moyenne (pondérée) des coordonnées des différentes modalités est nulle, sur chaque facteur : le profil moyen est représenté à l'origine. De plus, la variance (pondérée) des coordonnées, sur chaque facteur, est égale à la va.p. associée : la dispersion du nuage des points-modalités est proportionnelle à l'inertie expliquée par la dimension correspondante.

1. la variante *non centrée* de l'ACP consiste à diagonaliser la matrice non centrée $\sqrt{f_i f_j} \sum_k \rho_k q_{ik} q_{jk}$. Toutes les propriétés de l'ACP restent valides, sauf que la va.p. triviale associée à $\sqrt{f_i}$ devient alors $\lambda = 1$.

Overview Row Points^a

		Score in Dimension			Contribution				
					Of Point to Inertia of Dimension		Of Dimension to Inertia of Point		
					1	2	1	2	Total
pays de destination	Mass	1	2	Inertia	1	2	1	2	Total
Allemagne	.370	−1.100	.043	.122	.447	.001	.896	.001	.897
France	.319	.912	−1.135	.124	.265	.411	.523	.477	1.000
Suisse	.231	.672	1.458	.104	.104	.490	.245	.679	.924
Pays-Bas	.009	−.880	−.393	.006	.007	.001	.307	.036	.344
Belgique + Lux.	.056	.357	.774	.007	.007	.033	.250	.691	.941
Autriche	.012	−3.589	−2.257	.096	.155	.061	.394	.092	.486
Suede	.004	−1.942	−.764	.020	.015	.002	.179	.016	.196
Active Total	1.000			.479	1.000	1.000			

^a. Column Principal normalization

FIGURE 7.2 – Scores factoriels des catégories-lignes (“Score in dimension”) sur les deux premiers facteurs $\alpha = 1$ et $\alpha = 2$ (SPSS). La colonne “Mass” donne les poids relatifs f_i . La colonne “Inertia” donne les valeurs de $f_i D_{i0}$, dont le total (7.8) est le ϕ^2 . “Contribution Of Points to Inertia of Dimension” donne les proportions (7.11) pour $\alpha = 1, 2$, tandis que “Contribution Of Dimension to Inertia of Points” (parfois appelés “cosinus carrés” dans la littérature francophone) donne le carré des saturations (7.12) $\alpha = 1, 2$, dont le total sur les $K = 2 < r = 5$ premières dimensions fournit la communalité.

La quantité

$$\frac{f_i x_{i\alpha}^2}{\lambda_\alpha} = u_{i\alpha}^2 \quad \left(\text{avec} \quad \sum_{i=1}^{m_1} u_{i\alpha}^2 = 1 \right) \quad (7.11)$$

est la *contribution de la modalité i au facteur α* , i.e. la proportion d’inertie du facteur α expliquée ou créée par la modalité i .

De même, en vertu de (7.8), la quantité

$$s_{i\alpha}^2 := \frac{x_{i\alpha}^2}{D_{i0}} \quad \left(\text{avec} \quad \sum_{\alpha=1}^r s_{i\alpha}^2 = 1 \right) \quad (7.12)$$

est la *contribution du facteur α à la modalité i* , i.e. la part du carré de la distance à l’origine D_{i0} expliquée par le facteur α . La quantité $s_{i\alpha}$ représente le cosinus de l’angle entre le vecteur représentant la modalité i (dans toutes les r dimensions) et l’axe α , et joue un rôle parfaitement identique à celui de la *saturation* dans l’ACP. La *communalité* correspondante $h_i^2 := \sum_{\alpha=1}^K s_{i\alpha}^2$ représente la proportion de distance (carrée) à l’origine D_{i0} expliquée par les $K < r$ premières dimensions.

7.2.5 (*) La dualité lignes-colonnes

Bien évidemment, toute la construction précédente sur les catégories-lignes $i = 1, \dots, m_1$ aurait aussi pu se construire sur les catégories-colonnes $k = 1, \dots, m_2$ (voir figure 7.3). Il faudrait alors dans ce cas décomposer spectralement la matrice symétrique $\tilde{K} = C'C = V\tilde{\Lambda}V'$ (équation (7.7)), où $V = (v_{k\alpha})$ est la matrice orthogonale des vecteurs propres de $\tilde{K}$, et $\tilde{\Lambda}$ est la matrice diagonale des valeurs propres associées. Par le théorème de décomposition singulière (section 1.3.5), cette décomposition est reliée à la décomposition $K = U\Lambda U'$ (7.7) par

$$\tilde{\Lambda} = \Lambda \quad V = C'U\Lambda^{-\frac{1}{2}} \quad U = CV\Lambda^{-\frac{1}{2}} \quad (7.13)$$

Aussi, les coordonnées factorielles $y_{k\alpha}$ de la modalité-colonne k dans la dimension α est reliée aux coordonnées-lignes (et inversement) par les formules dites de *transition*

Overview Column Points ^a									
pays d'origine	Mass	Score in Dimension		Inertia	Contribution				
		1	2		Of Point to Inertia of Dimension		Of Dimension to Inertia of Point		
					1	2	1	2	Total
Grece	.082	-.960	.064	.096	.308	.002	.784	.003	.788
Turquie	.063	-.963	-.035	.067	.240	.001	.869	.001	.870
Yougoslavie	.044	-1.134	-.537	.124	.232	.088	.460	.103	.563
Portugal	.047	.654	-.940	.062	.082	.288	.323	.668	.990
Espagne	.251	.257	-.389	.057	.068	.264	.288	.660	.949
Italie	.513	.184	.317	.072	.071	.357	.240	.712	.952
Active Total	1.000			.479	1.000	1.000			

^a. Column Principal normalization

FIGURE 7.3 – Scores factoriels des $m_2 = 6$ catégories-colonnes sur les facteurs $\alpha = 1$ et $\alpha = 2$, de lecture analogue (mutatis mutandis) à la figure 7.2.

$$\begin{cases} y_{k\alpha} = \frac{\sqrt{\lambda_\alpha}}{\sqrt{\rho_k}} v_{k\alpha} = \frac{1}{\sqrt{\lambda_\alpha}} \sum_{i=1}^{m_1} f_i q_{ik} x_{i\alpha} \\ x_{i\alpha} = \frac{\sqrt{\lambda_\alpha}}{\sqrt{f_i}} u_{j\alpha} = \frac{1}{\sqrt{\lambda_\alpha}} \sum_{k=1}^{m_2} \rho_k q_{ik} y_{k\alpha} \end{cases} \quad (\text{formules de transition}) \quad (7.14)$$

7.2.6 Le biplot et son interprétation




FIGURE 7.4 – Biplot de l'analyse des correspondances, permettant une représentation simultanée des modalités-lignes i et les modalités-colonnes k . Les distances euclidiennes (au carré) entre lignes ou colonnes du biplot sont par construction les distances du chi2 (7.3)

L'équation (7.14) montre que, à un facteur $\frac{1}{\sqrt{\lambda_\alpha}}$ près, les coordonnées des colonnes sont les moyennes pondérées (cf. équation (7.1)) des coordonnées des lignes, et vice-versa (une autre manifestation du principe de dualité lignes-colonnes en Analyse de Données). Cette circonstance permet de représenter *simultanément* sur le même espace factoriel les lignes i et les colonnes k de la table de contingence de la table 1. Le graphique correspondant - le *biplot* (figure 7.4) - possède l'interprétation suivante :




FIGURE 7.5 – L’attraction q_{ik} entre la modalité-ligne i et la modalité-colonne k est proportionnelle au produit scalaire entre les vecteurs des coordonnées, i.e. au produit des distances à l’origine multiplié par le cosinus de l’angle entre les vecteurs. (I) : forte attractivité entre i et k . (II) : attractivité *encore plus forte* : le produit scalaire a augmenté, bien que la proximité entre les coordonnées de i et k ait diminué. (III) : neutralité mutuelle. (IV) : forte répulsivité entre i et k .

- le carré de la distance à l’origine D_{i0} d’une catégorie-ligne i (ou catégorie-colonne k) est d’autant plus grand que la catégorie est atypique.
- le profil moyen 0 de ligne (et de colonne) est représenté à l’origine.
- deux catégories-ligne i et j (ou deux catégories-colonnes k et l) dont les coordonnées sont *proches* ont des profils d’attraction-répulsion *similaires*. Deux catégories i et j aux coordonnées identiques pourraient être fusionnées en une seule catégorie $[i \cup j]$ sans modifier la position des autres catégories-lignes ou catégories-colonnes.
- deux catégories-ligne i et j (ou deux catégories-colonnes k et l qui s’opposent de part et d’autre d’un facteur possèdent des profils d’attraction-répulsion opposés (pour la dimension en jeu). Cette circonstance permet d’interpréter et de tenter de nommer le facteur en question.
- l’attraction entre une modalité-ligne i et une modalité-colonne k est proportionnelle au *produit scalaire entre leurs coordonnées*, plutôt qu’à la proximité entre leurs coordonnées (figure 7.5).

Au sens strict, l’interprétation précédente n’est justifiée que dans l’*espace factoriel complet* à r dimensions, restituant toute l’inertie de la configuration : le biplot n’est qu’une projection bidimensionnelle du nuage de points, certes optimale, mais dont la proportion d’inertie expliquée par les deux premières dimensions ne devrait pas être trop faible. En particulier, il faut s’assurer que l’interprétation d’un facteur est basée sur les modalités i “suffisamment expliquées” (au sens des cosinus carrés $s_{i\alpha}^2$ suffisamment grands) par le facteur α en question.

7.3 Analyse des correspondances d’une matrice termes-documents

En statistique textuelle, la table de contingence n_{ik} comptant le nombre de fois que le mot i apparaît dans le texte k est appelée *matrice terme-documents*, et son analyse, en particulier par l’AFC, y joue un rôle majeur.

On considère ici l’exemple de taille très réduite constitué par la brochure “La Suisse vote en couleur”, édité par la Chancellerie fédérale à l’occasion de l’élection du Conseil national du 21 octobre 2007 : chacun des $p = 14$ partis représentés au Conseil national, à savoir **akz**, **ds**, **glp**, **lega**, **pcs**, **pdc**, **pev**, **pls**, **prd**, **pss**, **pst**, **udc**, **udf** et **verts**, avait été invité à produire un bref texte de présentation. Après élimination des mots grammaticaux (“de”, “le”...), identification des formes masculines/féminines ou singulières/plurielles, réduction des formes verbales conjuguées à l’infinitif, et sélection des termes apparaissant au moins quatre fois dans le corpus, on aboutit aux $n = 80$ termes suivants :

sécurité, liberté, bénéficier, condition, solution, droit, tessin, développement, public, égalité, UE, domaine, social, action, formation, vie, énergie, entreprise, lutter, salaire, solidarité, enfant, vert, famille, permettre, pays, vivre, créer, homme, état, responsabilité, valeur, assurer, jeune, suisse, exiger, démocratique, travail, équilibre, canton, faveur, paix, respect, démocrate, environnement, garantir, par-




FIGURE 7.6 – Biplot (gauche), et détail des coordonnées des colonnes (=partis=documents) à droite. Le premier facteur indique une opposition politique gauche-droite, qui se retrouve avec la même orientation sur le plot. Le second facteur semble opposer, en partie, des partis religieux (en bas) à des partis nationalistes (en haut). Les lexiques du *pss* et du *prd* apparaissent comme les plus consensuels, du moins pour les deux premiers facteurs.

lement, taxe, monde, parti, national, économique, protection, emploi, avs, engager, fédéral, femme, politique, viser, société, service, conseil, ouvrir, avenir, humain, chrétien, travailler, indépendance, système, présent, préserver, libéral, rester, défendre, chance, fiscal, populaire, niveau, économie

	eigenvalue	percentage of variance	cumulative percentage of variance		Dim 1	Dim 2	Dim 3	Dim 4	Dim 5
dim 1	0.32925746	13.801379	13.80138	akz	-0.644106981	0.2608676	-0.355698318	0.084971301	-0.12525172
dim 2	0.31394585	13.159567	26.96095	ds	0.003938656	0.9400900	0.405338774	-1.143753271	0.23228139
dim 3	0.27370190	11.472674	38.43362	glp	-0.247418675	-0.2540650	0.006388778	0.169407812	1.57292281
dim 4	0.24078147	10.092759	48.52638	lega	1.202085388	0.9150609	-0.066999082	1.193102955	0.22643721
dim 5	0.21562766	9.038395	57.56477	pcs	-0.297971675	-0.3316098	0.920501686	0.372103779	-0.38992511
dim 6	0.18895720	7.920458	65.48523	pdv	0.419049816	-0.7936285	0.196762563	-0.175143757	-0.09344557
dim 7	0.18522356	7.763956	73.24919	pdc	0.306755999	-0.9138601	-0.740330417	-0.375457855	0.16633792
dim 8	0.15475175	6.486679	79.73587	pls	0.048803027	-0.6954354	-0.014823744	-0.043666961	0.13813444
dim 9	0.12654676	5.304420	85.04029	prd	0.225625794	0.1360458	0.092065256	-0.257498657	-0.37488569
dim 10	0.10747505	4.504997	89.54528	pss	-0.016647264	0.1390859	-0.026449053	0.022145069	-0.38468688
dim 11	0.09821724	4.116940	93.66222	pst	-0.583393181	-0.1717371	1.176287033	0.444973717	-0.09715027
dim 12	0.08612886	3.610235	97.27246	udc	0.412623933	0.7417104	0.091406257	-0.501468602	0.18280471
dim 13	0.06507058	2.727542	100.00000	udf	0.631925878	-0.1846004	-0.674006010	0.006687673	-0.41744556
				verts	-1.127975398	0.3161377	-0.743462621	0.293530152	-0.13321207

FIGURE 7.7 – Valeurs propres λ_α et proportion de variance expliquée λ_α/Δ (gauche); coordonnées factorielles $y_{k\alpha} = \frac{\sqrt{\lambda_\alpha} v_{k\alpha}}{\sqrt{\lambda_\alpha}}$ des colonnes (droite)

Cette table n_{ik} de taille 80×15 comporte seulement $n_{\bullet\bullet} = 565$ mots, et son analyse des correspondances est résumée dans les figures 7.6, 7.7 et 7.8, produites avec le package *FactoMineR* de R (les longues sorties équivalentes pour les $n = 80$ lignes-termes ont été omises). Les poids relatifs ρ_k de chaque document, sont, au vu des consignes reçues, comparables, et vont de 0.05 pour *udc* à 0.10 pour *pdv*.

Il y a en tout $r = \min(80 - 1, 14 - 1) = 13$ facteurs, chacun exprimant une proportion λ_α/Δ de l'inertie, qui vaut $\Delta = \phi^2 = \frac{\text{chi}^2}{n_{\bullet\bullet}} = 2.39$. Les deux premiers facteurs expriment seulement 27% d'inertie, un résultat

	Dim 1	Dim 2	Dim 3	Dim 4	Dim 5
akz	9.143570e+00	1.5729721	3.354449e+00	0.217598992	0.5279567
ds	3.335586e-04	19.9294666	4.249815e+00	38.463887520	1.7714786
glp	1.151725e+00	1.2736626	9.237989e-04	0.738351902	71.0771396
lega	2.718658e+01	16.5220853	1.015967e-01	36.622869879	1.4730271
pcs	1.527270e+00	1.9838166	1.753367e+01	3.256916508	3.9935531
pdz	5.097309e+00	19.1745447	1.351925e+00	1.217619427	0.3870421
pev	1.568064e+00	14.5954658	1.098719e+01	3.212273913	0.7040303
pls	5.121173e-02	10.9061231	5.683941e-03	0.056065335	0.6264855
prd	1.395608e+00	0.5321536	2.795345e-01	2.485699345	5.8832185
pss	7.746491e-03	0.5671086	2.352325e-02	0.018745019	6.3163352
pst	6.586294e+00	0.5985877	3.221090e+01	5.239618989	0.2788930
udc	2.562612e+00	8.6840753	1.512807e-01	5.175758567	0.7680330
udf	8.157025e+00	0.7300382	1.116310e+01	0.001249287	5.4353858
verts	3.556465e+01	2.9298999	1.858640e+01	3.293345317	0.7574215

	Dim 1	Dim 2	Dim 3	Dim 4	Dim 5
akz	2.267349e-01	0.037191413	6.914582e-02	3.945907e-03	0.008573728
ds	5.512039e-06	0.314018297	5.837842e-02	4.648157e-01	0.019171006
glp	1.960143e-02	0.020668661	1.306948e-05	9.189453e-03	0.792205074
lega	3.627777e-01	0.210218051	1.126958e-03	3.573764e-01	0.012872580
pcs	2.680709e-02	0.033201254	2.558285e-01	4.180497e-02	0.045905227
pdz	1.154659e-01	0.414149344	2.545701e-02	2.017027e-02	0.005741692
pev	3.060966e-02	0.271663867	1.782886e-01	4.585586e-02	0.009000258
pls	1.061211e-03	0.215487388	9.790933e-05	8.495994e-04	0.008501826
prd	3.380534e-02	0.012290734	5.628586e-03	4.403091e-02	0.093326611
pss	2.347889e-04	0.016389205	5.926688e-04	4.154760e-04	0.125373737
pst	1.033334e-01	0.008954608	4.200923e-01	6.011556e-02	0.002865538
udc	6.357900e-02	0.205434605	3.120015e-03	9.390578e-02	0.012478995
udf	1.793306e-01	0.015303374	2.040091e-01	2.008501e-05	0.078256736
verts	5.420176e-01	0.042576189	2.354683e-01	3.670452e-02	0.007599644

FIGURE 7.8 – A gauche : contribution $\frac{\rho_k y_{k\alpha}^2}{\lambda_\alpha} = v_{k\alpha}^2$ de chaque parti k au facteur α , en pourcents ; le total en colonne vaut 100% pour chaque dimension α . A droite : “cosinus carrés” $\frac{\tilde{y}_{k\alpha}^2}{\tilde{D}_{k0}}$, donnant la contribution de chaque facteur α l'excentricité $\tilde{D}_{k0}$ de chaque parti, et dont le total en ligne (sur tous les $r = 13$ facteurs) vaut 1.

bien décevant. Le $\chi^2 = 1347.9$ ($df = (80-1) \cdot (14-1) = 1027$) est extrêmement significatif ($p = 4.95e-11$).

Les excentricités des partis $\tilde{D}_{k0} = \sum_{\alpha=1}^{13} y_{k\alpha}^2$, mesurant le carré de leur distance totale au centre, vont de 1.18 pour **pss** (lexique le moins atypique) à 3.98 pour **lega** (lexique le plus atypique). Les parts d'inertie de chaque parti $\rho_k \tilde{D}_{k0}$ vont de 0.11 pour **pss** à 0.25 pour **lega**. Par construction, $\sum_k \rho_k \tilde{D}_{k0} = \sum_\alpha \lambda_\alpha = \phi^2$.

7.4 Exercices et corrigés

Exercice 7.1

A propos de l'exemple du cours "flux migratoires de travailleurs en Europe" :

1. quelle ligne (= pays d'immigration) contribue le plus à la création du facteur 1 ? du facteur 2 ?
2. quelle colonne (= pays d'émigration) contribue le plus à la création du facteur 1 ? du facteur 2 ?
3. quel est le pays d'immigration le mieux représenté par les deux premières dimensions ? le pays d'immigration le moins bien représenté ?
4. en moyenne, les deux premières dimensions représentent-elles mieux les pays d'immigration ou d'émigration ?


Exercice 7.2

La table de contingence ci-dessous donne les effectifs d'étudiants selon leur domaine d'études j et leur pratique k de la photographie. Les quatre domaines d'études considérés sont : sciences humaines (scHum), sciences politiques (scPo), droit et biologie (bio). Les étudiants peuvent pratiquer la photographie de manière quotidienne (quot), hebdomadaire (hebd), mensuelle (mens), annuelle (annuel) ou ne jamais faire de photographie (jms).

Les marges des lignes et colonnes sont données par "total", ρ représente le poids des colonnes et f celui des lignes.

	$k = 1$ (quot)	$k = 2$ (hebd)	$k = 3$ (mens)	$k = 4$ (annuel)	$k = 5$ (jms)	total	f
$j = 1$ (scHum)	7	21	12	13	4	57	0.27
$j = 2$ (scPo)	8	10	4	6	10	38	0.18
$j = 3$ (droit)	2	4	21	22	8	57	0.27
$j = 4$ (bio)	4	8	11	27	11	61	0.28
total	21	43	48	68	33	213	1
ρ	0.10	0.20	0.23	0.32	0.15	1	

Les résultats de l'analyse des correspondances (AFC) effectuée avec R sont reproduits ci-dessous :



1. Que vaut l'inertie ?
2. Que vaut le chi2 ?
3. (a) Que vaut la proportion d'inertie expliquée par le premier facteur ?
(b) Comment peut-on la calculer ?
4. (a) Que vaut le quotient d'indépendance entre "droit" et "annuel" ?
(b) Que peut-on en déduire ? Cocher la bonne réponse.
 - ☐ "droit" et "annuel" sont en répulsion mutuelle
 - ☐ "droit" et "annuel" sont en neutralité mutuelle
 - ☐ "droit" et "annuel" sont en attraction mutuelle
5. (a) Quelle est la pratique qui semble être la plus atypique ? Cocher la bonne réponse.
 - ☐ pratique quotidienne
 - ☐ pratique hebdomadaire
 - ☐ pratique mensuelle
 - ☐ pratique annuelle
 - ☐ pas de pratique
 (b) Pourquoi ? Cocher la seule réponse **incorrecte**.
 - ☐ le profil de ses quotients est éloigné du profil centré
 - ☐ sa distance au centroïde est grande
 - ☐ sa première coordonnée est négative
 - ☐ sur le biplot, il s'agit du point-colonne (rond) le plus éloigné du centre
6. Que représente la quantité $s_{j\alpha}^2 = \frac{x_{j\alpha}^2}{D_{j0}}$? Cocher la bonne réponse.
 - ☐ la contribution du facteur α à la modalité j
 - ☐ la distance de la modalité j au centroïde
 - ☐ la contribution de la modalité j au facteur α

□ la distance du facteur α au centroïde

7. Les affirmations ci-après sont elles vraies ou fausses ?

- (a) Sur le biplot, une modalité-ligne et une modalité-colonne sont en forte attraction si elles sont très proches.
- (b) L'origine du biplot représente le profil moyen des lignes et colonnes.
- (c) Si la taille de l'échantillon double, l'indice du ϕ^2 double également
- (d) Dans le MDS pondéré, les coordonnées des objets sont données par $x_{i\alpha} = \frac{\sqrt{\lambda_\alpha}}{\sqrt{f_i}} u_{i\alpha}$. On a alors $\sum_i f_i x_{i\alpha} = 1$.

Corrigé de la série 7

Exercice 7.1

1. l'Allemagne (qui explique 44.7% du facteur 1) ; la Suisse (qui explique 49.0% du facteur 2)
2. la Grèce (qui explique 30.8% du facteur 1) ; l'Italie (qui explique 35.7% du facteur 2)
3. la France (expliquée à 100%) ; la Suède (expliquée à 19.6%)
4. en moyenne, les deux premières dimensions représentent aussi bien (ou aussi mal) les pays d'immigration que d'émigration, à savoir à $51.1\% + 30.1\% = 81.2\%$ d'inertie expliquée.

Exercice 7.2

1. l'inertie vaut $\Delta = \phi^2 = \lambda_1 + \lambda_2 + \lambda_3 = 0.145935 + 0.050548 + 0.016989 = 0.213$
2. le chi2 vaut $n_{\bullet\bullet} \phi^2 = 213 \times 0.213 = 45.47$
3. (a) La proportion d'inertie expliquée par le premier facteur vaut 68.36%
(b) On pourrait l'obtenir comme $\lambda_1 / \Delta = 0.145935 / 0.213 = 0.68$
4. (a) Le quotient d'indépendance entre "droit" et "annuel" vaut $\frac{22 \times 213}{57 \times 68} = 1.21$
(b) On peut en déduire que "droit" et "annuel" sont en attraction mutuelle (car $1.21 > 1$)
5. (a)(b) La pratique qui semble être la plus atypique est la pratique quotidienne : le profil de ses quotients est éloigné du profil centré, le (carré de) sa distance au centroïde **ChiDist**=0.623897 est grande, et sur le biplot, il s'agit du point-colonne (rond) le plus éloigné du centre. Le fait que sa première coordonnée soit négative n'est pas pertinent.
6. $s_{j\alpha}^2 = \frac{x_{j\alpha}^2}{D_{j0}}$ est la contribution du facteur α à la modalité j
7. Les affirmations ci-après sont elles vraies ou fausses ?
(a) FAUX : sur le biplot, une modalité-ligne et une modalité-colonne sont en forte attraction si leur produit scalaire depuis l'origine est grand
(b) VRAI
(c) FAUX : si la taille de l'échantillon double, le chi2 double, mais le ϕ^2 reste le même.
(d) FAUX : $\sum_i f_i x_{i\alpha} = 0$.

Chapitre 8

La classification hiérarchique ascendante

8.1 Introduction : classification supervisée et non supervisée

Classer des objets, c'est les regrouper en différentes classes, groupes ou blocs. Par exemple :

- les papiers contenus dans un bureau sont regroupés dans différents dossiers
- les communes d'un canton sont réunies en différents districts
- les élèves d'un camp de ski sont répartis en différentes classes.

L'ensemble des groupes constitue une *partition* de l'ensemble des objets (section 8.2).

En Analyse des Données, les objets sont décrits par leurs profils x_i multivariés ou, comme adopté dans ce chapitre, par les *dissimilarités* induites entre paires d'objets $d_{ij} = d(x_i, x_j)$. Les groupes sont dits *homogènes* s'ils sont constitués d'objets similaires entre eux, et la question de l'homogénéité est au coeur des questions de classification. Il faut bien distinguer entre :

- (A) la **classification supervisée** ("classification" en anglais), où les groupes existent a priori et la tâche consiste à attribuer un nouvel objet au "bon" groupe (phase de test), en se basant sur l'expérience préalable (phase d'apprentissage) acquise sur un échantillon d'objets dont les profils ainsi que le groupe auquel ils appartiennent sont connus. Par exemple :
- une banque décide d'accorder ou non un prêt à un nouveau client, sur la base du profil de ce client, ainsi que des profils des clients précédents et de leur catégorisation en "bons" ou "mauvais" payeurs
 - un expert humain fournit à un moteur de recherche un ensemble de documents qu'il sait pertinents pour un sujet donné, ainsi qu'un autre ensemble de documents non pertinents. Sur la base de cette information, le moteur de recherche doit alors décider si un nouveau document est ou n'est pas pertinent pour le sujet donné.
 - un joueur de poker utilise toute son expérience pour décider si, dans telle situation, il doit relancer (et de combien), suivre ou passer.
- (B) la **classification non supervisée** ("clustering" en anglais), où il n'existe pas de groupes a priori : les objets similaires entre eux sont regroupés dans des mêmes classes (homogénéité intra-groupe) et des objets dissimilaires entre eux sont regroupés dans des classes différentes (hétérogénéité inter-groupe). On parle aussi de *partitionnement*, de *typologie*, d'*analyse en clusters* ou de *taxonomie* (ou taxinomie). Par exemple :
- un biologiste classe différents spécimens d'insectes en divers groupes selon les caractéristiques morphologiques de chaque spécimen
 - un psychologue tente d'établir divers types de personnalité auxquels chaque sujet est censé appartenir

- un géographe établit une typologie des communes de Suisse en plusieurs types, selon les caractéristiques socio-économiques et géomorphologiques de chaque commune.

Chaque fois que nous *catégorisons* un ensemble d'objets (des livres pour réorganiser thématiquement notre bibliothèque; des impressions visuelles catégorisées en noms de couleurs; des types de réponses à un questionnaire sur la perception d'une rivière, etc.), nous effectuons un clustering plus ou moins spontané, i.e. nous créons une *variable catégorielle dont les modalités sont les groupes d'objets*, que nous en ayons conscience ou non.

8.1.1 Ingrédients d'une classification non supervisée (clustering)

Seule la classification supervisée ou *clustering* est abordée dans ce chapitre, principalement dans le cadre non pondéré. Pour l'effectuer, il faut

- 1) décider quelles caractéristiques seront retenues pour comparer les n objets entre eux, et de l'importance relative que l'on va attribuer à chaque caractéristique
- 2) définir, sur la base de ces caractéristiques, une mesure de *similarité* s_{ij} ou de *dissimilarité* d_{ij} entre chaque paire d'objets i et j
- 3) décider de la *finesse* (ou *granularité*) de la classification, c'est-à-dire du nombre de groupes $m \leq n$ formant la partition. À un extrême (partition maximale), tous les objets sont regroupés en une seule classe ($m = 1$); à l'autre extrême (partition minimale), chaque objet forme une classe à lui tout seul ($m = n$).

8.1.2 Principales familles de clustering

La recherche de méthodes efficaces et novatrices de clustering sont centrales en Analyse de Données, et occupent une grande partie de la communauté. On peut distinguer quelques grandes familles de clustering :

- 1) La classification ascendante hiérarchique (CAH), développée dans la suite du chapitre, construit une suite de partitions emboîtées aussi homogènes que possible, en partant de la partition minimale et en aboutissant à la partition maximale.
- 2) La classification descendante hiérarchique procède à l'opposé, en partant de la partition maximale, que l'on raffine successivement pour aboutir à la partition minimale.
- 3) Le *density-based spatial clustering* (DBSCAN), cherchant à générer des groupes de taille minimale en regroupant itérativement les objets suffisamment similaires ou voisins.
- 4) Le K-means et ses variantes (dont la classification floue associée aux *modèles de mélanges*) est une méthode *itérative*, calculant alternativement les centroïdes des groupes puis les nouveaux groupes associés, en augmentant à chaque étape l'homogénéité de la partition.
- 5) Les méthodes de *partitionnement de réseau*, parmi lesquelles le *spectral clustering* et la *modularity maximization*, cherchant à partitionner un réseau de n noeuds tout en évitant de couper en deux ses arêtes les plus importantes, arêtes dont les valeurs représentent des similarités ou affinités entre noeuds.

8.2 (*) Partitions

Définition 7 (Partitions et relation d'emboîtement d'ordre partiel)

Soit $\Omega = \{1, \dots, n\}$ un ensemble de n objets. Une *partition* $\mathcal{A}$ de Ω est un ensemble de m sous-ensembles, *blocs* ou *groupes* $\mathcal{A} = \{A_1, \dots, A_m\}$ de Ω , non vides, disjoints deux à deux, et recouvrant Ω , i.e. tel que

$$A_g \subset \Omega \quad A_g \neq \emptyset \quad A_g \cap A_h \text{ si } g \neq h \quad \bigcup_{g=1}^m A_g = \Omega$$

La partition $\mathcal{A}$ est *plus fine* (finer) que la partition $\mathcal{B}$, noté $\mathcal{A} \preceq \mathcal{B}$, si chaque bloc A de $\mathcal{A}$ est contenu dans un bloc B de $\mathcal{B}$. On dit aussi $\mathcal{A}$ est *emboîté* (nested) dans $\mathcal{B}$.

La relation d'emboîtement “ $\preceq$ ” est une relation d'ordre *partiel* entre partitions d'un ensemble Ω : elle est *réflexive* car $\mathcal{A} \preceq \mathcal{A}$, elle est *transitive* car $\mathcal{A} \preceq \mathcal{B}$ et $\mathcal{B} \preceq \mathcal{C}$ entraînent que $\mathcal{A} \preceq \mathcal{C}$, et elle est *anti-symétrique* car $\mathcal{A} \preceq \mathcal{B}$ et $\mathcal{A} \succeq \mathcal{B}$ entraînent que $\mathcal{A} = \mathcal{B}$. Par contre, deux partitions ne sont pas *comparables* en général : il se peut que $\mathcal{A} \not\preceq \mathcal{B}$ et $\mathcal{B} \not\preceq \mathcal{A}$ (d'où le qualificatif d'ordre *partiel*).

Si $\mathcal{A} \preceq \mathcal{B}$, on dit aussi que $\mathcal{B}$ est *plus grossier* (coarser) que $\mathcal{A}$, noté $\mathcal{B} \succeq \mathcal{A}$.

L'*infimum* ou *meet* de deux partitions $\mathcal{A}$ et $\mathcal{B}$ est la partition, notée $\mathcal{A} \wedge \mathcal{B}$, qui, de toutes les partitions plus fines que $\mathcal{A}$ et que $\mathcal{B}$, est la moins fine possible : $\mathcal{A} \wedge \mathcal{B} \preceq \mathcal{A}$ et $\mathcal{A} \wedge \mathcal{B} \preceq \mathcal{B}$. Aussi, si $\mathcal{C} \preceq \mathcal{A}$ et $\mathcal{C} \preceq \mathcal{B}$, alors $\mathcal{C} \preceq \mathcal{A} \wedge \mathcal{B}$. Les groupes de $\mathcal{A} \wedge \mathcal{B}$ s'obtiennent en considérant les intersections non vides des blocs de $\mathcal{A}$ et de ceux de $\mathcal{B}$. La *partition minimale* est la plus fine de toutes les partitions : elle est constituée de n blocs contenant chacun un élément, i.e. $\mathcal{A}_{\min} = \{\{1\}, \{2\}, \dots, \{n\}\}$.

Le *supremum* ou *join* de deux partitions $\mathcal{A}$ et $\mathcal{B}$ est la partition, notée $\mathcal{A} \vee \mathcal{B}$, qui, de toutes les partitions moins fines que $\mathcal{A}$ et que $\mathcal{B}$, est la plus fine possible : $\mathcal{A} \preceq \mathcal{A} \vee \mathcal{B}$ et $\mathcal{B} \preceq \mathcal{A} \vee \mathcal{B}$. Aussi, si $\mathcal{A} \preceq \mathcal{C}$ et $\mathcal{B} \preceq \mathcal{C}$, alors $\mathcal{A} \vee \mathcal{B} \preceq \mathcal{C}$. La *partition maximale* $\mathcal{A}_{\max}$ est la moins fine de toutes les partitions : elle est constituée d'un seul bloc contenant tous les éléments, i.e. $\mathcal{A}_{\max} = \{\{1, \dots, n\}\} = \{\Omega\}$.

Exemple 7

Soit $\Omega = \{1, 2, 3, 4, 5\}$. Alors $\mathcal{A}_1 = \{\{1, 2\}, \{3, 5\}, \{4\}\}$, $\mathcal{A}_2 = \{\{1\}, \{2\}, \{3, 5\}, \{4\}\}$, $\mathcal{A}_3 = \{\{1, 2\}, \{3\}, \{4, 5\}\}$ et $\mathcal{A}_4 = \{\{1\}, \{2\}, \{3\}, \{4\}, \{5\}\}$ constituent quatre partitions, qu'il est plus simple de noter comme $\mathcal{A}_1 = (12|35|4)$, $\mathcal{A}_2 = (1|2|35|4)$, $\mathcal{A}_3 = (12|3|45)$ et $\mathcal{A}_4 = (1|2|3|4|5)$.

On a par exemple $\mathcal{A}_4 \preceq \mathcal{A}_2 \preceq \mathcal{A}_1$. Les partitions $\mathcal{A}_1$ et $\mathcal{A}_3$ sont incomparables : aucune n'est plus fine que l'autre. On a $\mathcal{A}_1 \wedge \mathcal{A}_3 = (12|3|4|5)$ et $\mathcal{A}_1 \vee \mathcal{A}_3 = (12|345)$. Aussi, $\mathcal{A}_{\min} = (1|2|3|4|5)$ et $\mathcal{A}_{\max} = (12345)$.

Aussi, $\mathcal{A}_1 \wedge \mathcal{A}_2 = \mathcal{A}_2$ et $\mathcal{A}_1 \vee \mathcal{A}_2 = \mathcal{A}_1$, qui illustre la propriété générale “ si $\mathcal{A} \preceq \mathcal{B}$, alors $\mathcal{A} \wedge \mathcal{B} = \mathcal{A}$ et $\mathcal{A} \vee \mathcal{B} = \mathcal{B}$ ”.

8.3 La constitution des groupes (CAH)

Agrégation hiérarchique des groupes et recalcul de leurs dissimilarités

Etant donné un ensemble d_{ij} de dissimilarités entre objets, il s'agit de construire une partition dont les m classes ou groupes sont aussi homogènes que possibles. La **classification ascendante hiérarchique** (CAH) consiste, à partir de la partition minimale où les n objets sont distincts, à regrouper les deux objets les plus proches, et à réitérer le processus jusqu'au regroupement complet :

- (1) dans $\mathcal{A}_n := \mathcal{A}_{\min}$, contenant n groupes formés d'un seul objet, on agrège deux groupes, disons $\{a\}$ et $\{b\}$, et on obtient la partition $\mathcal{A}_{n-1}$ qui contient $n - 1$ groupes ($n - 2$ groupes formés d'un seul élément et le groupe $a \cup b$, que l'on peut aussi noter $[ab]$).
- (2) dans $\mathcal{A}_{n-1}$, on agrège deux groupes, (dont l'un peut être $[ab]$ ou pas), et on obtient la partition $\mathcal{A}_{n-2}$ à $n - 2$ groupes
- (3) ... dans $\mathcal{A}_q$, à q groupes, on agrège deux groupes et on obtient la partition $\mathcal{A}_{q-1}$ à $q - 1$ groupes, etc ...
- (4) finalement, les deux groupes de $\mathcal{A}_2$ sont agrégés, produisant le groupe à un élément $\mathcal{A}_1 = \mathcal{A}_{\max}$.

Ce processus définit une suite de n partitions emboîtées $\mathcal{A}_n \preceq \mathcal{A}_{n-1} \preceq \mathcal{A}_{n-2} \preceq \dots \preceq \mathcal{A}_{\max}$. Il se peut que la séquence soit plus courte, si plus de deux groupes sont agrégés à une étape donnée (cf. infra).

A chaque étape, le choix des deux groupes à agréger dépend de la matrice $q \times q$ des dissimilarités d entre les q groupes, qui générera une nouvelle matrice $(q - 1) \times (q - 1)$ de dissimilarité, notée $\tilde{d}$, après agrégation. Deux points restent à régler :

- (1) **comment choisir les deux groupes à agréger ?**

On choisira *toujours* les deux groupes distincts a et b les *plus proches*, i.e. tels que $d_{ab} < d_{gh}$ pour toutes paires $a \neq b$ et $g \neq h$

- (2) **comment calculer les nouvelles dissimilarités $\tilde{d}$ à partir des anciennes d ?**

Il n'y a rien à changer pour les groupes qui n'ont pas participé à l'agrégation, i.e. $\tilde{d}_{gh} = d_{gh}$ si $\{g, h\} \neq$

$\{a, b\}$. Aussi, la dissimilarité du nouveau groupe avec lui-même est bien sûr nulle, i.e. $\tilde{d}_{[ab],[ab]} = 0$. Restent à déterminer les nouvelles dissimilarités entre le nouveau groupe et les groupes qui n'ont pas participé à l'agrégation, i.e. à décider d'une règle de calcul pour $\tilde{d}_{g,[ab]} = \tilde{d}_{[ab],g}$ lorsque $g \neq a, b$. *Plusieurs possibilités existent à ce stade*, les principales étant :

- le *saut minimal* (single linkage) : les distances entre le nouveau groupe $[ab]$ et les autres groupes g sont définies par

$$\tilde{d}_{g,[ab]} = \min(d_{ga}, d_{gb}) \quad (8.1)$$

- le *saut maximal* (complete linkage) : les distances entre le nouveau groupe $[ab]$ et les autres groupes g sont définies par

$$\tilde{d}_{g,[ab]} = \max(d_{ga}, d_{gb}) \quad (8.2)$$

- le *saut moyen* (average linkage) : les distances entre le nouveau groupe $[ab]$ et les autres groupes g sont définies par

$$\tilde{d}_{g,[ab]} = \frac{N_a d_{ga} + N_b d_{gb}}{N_a + N_b} \quad (8.3)$$

où N_a et N_b sont les effectifs des groupes a et b . On peut aussi partir d'une situation pondérée où les poids f_i des objets diffèrent, auquel cas N_a et N_b sont proportionnels aux poids ρ_a et ρ_b des groupes a et b (l'algorithme standard `hclust()` de R permet ce type de traitement pondéré).

Ex-aequos et agrégation de plus de deux groupes

On a supposé jusqu'ici que chaque étape agrège les deux groupes les plus proches. Or, il se peut que la présence d'ex-aequos implique l'agrégation de trois groupes ou plus. Par exemple, si $d_{ab} = 1$, $d_{ac} = 1$ et $d_{bc} = 2$ pour trois groupes distincts a, b, c , toutes les autres dissimilarités entre paires distinctes étant strictement supérieures à 1, il faudrait alors fusionner en un seul coup a , b et c en un nouveau groupe $[abc]$, et recalculer les dissimilarités comme

$$\tilde{d}_{g,[abc]} = \min(d_{ga}, d_{gb}, d_{gc}) \quad \tilde{d}_{g,[abc]} = \max(d_{ga}, d_{gb}, d_{gc}) \quad \tilde{d}_{g,[abc]} = \frac{N_a d_{ga} + N_b d_{gb} + N_c d_{gc}}{N_a + N_b + N_c}$$

pour le saut minimal, maximal et moyen, respectivement.

Construction du dendrogramme associé et obtention de distances ultramétriques

Lors de l'agrégation $a, b \rightarrow [ab]$, la hauteur h_{ab} sur le dendrogramme à laquelle les branches associées seront fusionnées est définie par la dissimilarité associée $h_{ab} = d_{ab}$, ce qui achève sa construction. La hauteur maximale $h_{\max}$ dans le dendrogramme, i.e. celle de sa racine, est ainsi égale à la dissimilarité entre les deux derniers groupes à être agrégés.

On a vu (section 5.4) comment tout dendrogramme génère une *dissimilarité ultramétrique* d_{ij}^U , définie comme la hauteur $h = h_{ab}$ à laquelle les individus i et j sont regroupés la première fois, lors d'une agrégation de la forme $a, b \rightarrow [ab]$ où $i \in a$ et $j \in b$.

En général, la dissimilarité initiale d n'est pas ultramétrique. Or, les distances d^U lues sur le dendrogramme sont ultramétriques¹. Ainsi, la transformation $d \rightarrow d^U$ induit une distorsion des données initiales, que l'on peut mesurer (dans le cas pondéré général) par le "coefficient de corrélation cophénétique"

$$r^2(d, d^U) = 1 - \frac{\sum_{ij} f_i f_j (d_{ij} - d_{ij}^U)^2}{\sum_{ij} f_i f_j d_{ij}^2} \quad (8.4)$$

Plus r^2 est proche de 1, meilleure sera la représentation des données par le dendrogramme.

1. En particulier, la règle du saut minimal a la particularité de générer l'*ultramétrique sous-dominante* d^U , qui est, parmi toutes les dissimilarités ultramétriques inférieures à la dissimilarité initiale d (i.e. $d_{ij}^U \leq d_{ij}$), celle dont les valeurs sont les plus grandes possibles.

Si la dissimilarité initiale d était déjà ultramétrique, on peut montrer qu'elle coïnciderait avec la dissimilarité ultramétrique d^U générée par le dendrogramme, comme il se doit, et ce quel que soit l'algorithme utilisé (saut minimal, saut maximal ou saut moyen)².

Obtention d'un clustering (coupe du dendrogramme)

En coupant le dendrogramme à hauteur h , on obtient une partition des n objets en m groupes. Prendre h élevé revient à privilégier la simplicité (peu de groupes, perte importante d'information en général : forte granularité) tandis que h petit permet de conserver davantage d'information (finesse accrue), au prix d'un accroissement du nombre de groupes. La problématique est tout-à-fait comparable au choix du nombre de facteurs dans une analyse factorielle, et, si des critères de décision ont pu être proposés dans les deux cas, le choix final incombe à l'utilisateur, selon le contexte et ses besoins.

Exemple 8

Le jeu de données **USArrests** disponible dans R contient, pour chacun de $n = 50$ états USA, les $p = 4$ numériques variables suivantes : **murder** = arrestations pour meurtre (pour 100'000 habitants); **assault** = arrestations pour agression (pour 100'000 habitants); **urbapop** = proportion de résidents urbains; **rape** = arrestations pour viol (pour 100'000 habitants).

Après standardisation des variables, on considère la CAH sur les distances euclidiennes d_{ij} , ainsi que sur les distances euclidiennes carrées³ $D_{ij} = d_{ij}^2$, selon trois critères : saut minimum (figure 8.1), saut maximum (figure 8.2) et saut moyen (figure 8.3).




FIGURE 8.1 – Saut minimum sur les distances euclidiennes (gauche) et les distances euclidiennes carrées (droite). La méthode du saut minimum produit souvent, comme ici, un phénomène de *chaînage*, créant de proche en proche des groupes contenant certaines paires d'objets possiblement fort éloignés, ce qui génère des dendrogrammes d'aspect peu équilibré.

2. en effet, comme a et b sont par hypothèse les plus proches, on aurait $d_{ab} \leq d_{ga} = d_{gb}$, et ainsi $\tilde{d}_{g,[ab]} = d_{ga} = d_{gb}$ dans (8.1), (8.2) et (8.3).

3. attention : l'expression "distances euclidiennes carrées", synonyme de "carrés de distances euclidiennes", pourrait suggérer, à tort, que les carrés de distances euclidiennes sont des distances : c'est *faux*, ces dernières ne satisfont généralement pas l'inégalité triangulaire (cf. figure 5.1) ; on lui préfère souvent, pour cette raison, l'expression "dissimilarités euclidiennes carrées". De même, la désignation courante de D^x comme "distance du chi2" constitue un abus de langage : on peut l'utiliser à condition d'être bien conscient que D^x , qui peut violer l'inégalité triangulaire, n'est pas une distance...mais le carré d'une distance.




FIGURE 8.2 – Saut maximum sur les distances euclidiennes (gauche) et les distances euclidiennes carrées (droite). Les dendrogrammes résultants ont meilleure allure, et permettent de définir plus distinctement une partition à m groupes en coupant le dendrogramme à une hauteur donnée. En présence d'individus de poids différents, la version pondérée de l'algorithme donne exactement le même dendrogramme : en CAH, le poids de individus ou des groupes n'intervient jamais dans la méthode du saut maximal (ni dans celle du saut minimal de la figure 8.1).




FIGURE 8.3 – On compare ici le saut moyen sur les distances euclidiennes dans le cas uniforme (à gauche), où le poids de chaque état est le même, et dans le cas pondéré (à droite), où le poids de chaque état est proportionnel à sa population résidente : les valeurs calculées par (8.3) diffèrent, et les dendrogrammes résultants diffèrent également, de toute évidence.

8.3.1 La méthode de Ward

En présence de m groupes, l'inertie totale Δ (qui est la généralisation de la variance dans le cas multivarié) se décompose en inertie inter-groupes Δ_B et inertie intra-groupes Δ_W . Dans le formalisme pondéré général,

$$\Delta = \frac{1}{2} \sum_{i,j=1}^n f_i f_j D_{ij} = \Delta_B + \Delta_W \quad \Delta_B = \sum_{g=1}^m \rho_g D_{g0} \quad \Delta_W = \sum_{g=1}^m \rho_g \Delta_g$$




FIGURE 8.4 – dendrogramme produit par la méthode de Ward standard, dans les cas uniforme (gauche) et pondéré (droite)

où f_i est le poids de l'objet i , et D_{ij} une dissimilarité euclidienne carrée entre objets. La quantité $\rho_g = \sum_{i \in g} f_i$ est le poids du groupe g , D_{g0} est la dissimilarité entre le centre de gravité du groupe g et le centre de gravité général 0 (i.e. de toute la configuration), et Δ_g est l'inertie du groupe g .

Au fur et à mesure que l'on s'élève dans le dendrogramme (hauteur h croissante), le nombre de groupes diminue. L'inertie inter-groupes Δ_B diminue, l'inertie intra-groupes Δ_W augmente, leur total Δ demeurant constant. En agrégeant les groupes a et b , l'inertie inter-groupes Δ_B diminue de

$$\rho_a D_{a0} + \rho_b D_{b0} - (\rho_a + \rho_b) D_{[ab]0} = \frac{\rho_a \rho_b}{\rho_a + \rho_b} D_{ab} \quad (8.5)$$

où D_{ab} est la dissimilarité euclidienne carrée entre les centres de gravité des groupes a et b , la dernière identité découlant du principe de Huygens.

Agréger deux groupes a et b diminue le nombre de groupes (ce qui simplifie la description des données), mais diminue l'homogénéité des clusters (ce qui les rend moins compacts). Il est naturel de s'efforcer de limiter au maximum cette *perte d'inertie interclasse* (ou, de façon équivalente, cette augmentation d'inertie intraclasse) : c'est le principe de la *méthode de Ward* qui, de toutes les agrégations possibles à une étape donnée, va déterminer la paire a, b dont la fusion $a, b \rightarrow [a, b]$ minimise la quantité (8.5)

De façon équivalente, la méthode de Ward consiste à appliquer la CAH non pas aux dissimilarités euclidiennes carrées D_{ij} initiales, mais aux dissimilarités entre objets d_{ij}

$$d_{ij} = \frac{f_i f_j}{f_i + f_j} D_{ij} \quad \text{ou plus généralement} \quad d_{ab} = \frac{\rho_a \rho_b}{\rho_a + \rho_b} D_{ab} \quad \text{diss. entre groupes } a \text{ et } b \quad (8.6)$$

Après agrégation $a, b \rightarrow [a, b]$, la dissimilarité avec un autre groupe g devient alors, par Huygens,

$$\tilde{d}_{g,[ab]} = \frac{\rho_g(\rho_a + \rho_b)}{\rho_g + \rho_a + \rho_b} D_{g,[ab]} = \frac{(\rho_g + \rho_a)d_{ga} + (\rho_g + \rho_b)d_{gb} - \rho_g d_{ab}}{\rho_g + \rho_a + \rho_b} \quad (8.7)$$

Pour conclure, on peut observer que les règles d'agrégation du saut minimum, maximum, moyen, et de la méthode de Ward peuvent s'écrire sous la forme générale, dite de Lance-Williams

$$\tilde{d}_{g,[ab]} = \alpha_a d_{ga} + \alpha_b d_{gb} + \beta d_{ab} + \gamma |d_{ga} - d_{gb}| \quad (8.8)$$

où le choix des coefficients α_a , β et γ spécifie la règle en question.

8.3.2 Classification ascendante hiérarchique dans R avec `hclust()`

Les dendrogrammes de ce chapitre ont été créés avec le package `hclust` de R. En désignant par `Xs` la matrice 50×4 des scores standardisés (x_{ij}^s), et par `pop77` le nombre d'habitants dans chacun des états, i.e. leur poids absolu (le poids relatif étant $f = \text{pop77} / \text{sum}(\text{pop77})$), on a utilisé

<code>hclust(dist(Xs), "single")</code>	figure (8.1) gauche
<code>hclust(dist(Xs)^2, "single")</code>	figure (8.1) droite
<code>hclust(dist(Xs), "complete")</code>	figure (8.2) gauche
<code>hclust(dist(Xs)^2, "complete")</code>	figure (8.2) droite
<code>hclust(dist(Xs), "ave")</code>	figure (8.3) gauche
<code>hclust(dist(Xs), "ave", members=pop77)</code>	figure (8.3) droite
<code>hclust(dist(Xs), "ward.D2", members=pop77)</code>	figure (8.4) gauche
<code>hclust(dist(Xs), "ward.D2", members=pop77)</code>	figure (8.4) droite

La fonction `dist(Xs)` génère les distances euclidiennes d_{ij} sur les scores standardisés, tandis que `dist(Xs)^2` génère les distances euclidiennes carrées $D_{ij} = d_{ij}^2$. L'option `dist(Xs), "ward.D2"` correspond à la méthode de Ward décrite ici, tandis que l'option `dist(Xs), "ward.D"` revient à remplacer les distances euclidiennes carrées par les distances euclidiennes tout court, lesquelles ont également la propriété d'être ... des distances euclidiennes carrées ! (cf. section 6.2.3). Autrement dit, l'option standard `dist(Xs), "ward.D2"` est équivalente à `dist(Xs)^2, "ward.D"`.

8.4 Exercices et corrigés

Exercice 8.1

On souhaite classer 6 tombes mérovingiennes selon 8 variables $x_1, \dots, x_8$ qui représentent l'absence $x_k = 0$ ou la présence $x_k = 1$ d'un certain élément k (nourriture, décoration, bijoux, etc...). Les données récoltées sont les suivantes :

Tombe	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
1	1	0	0	1	0	0	0	0
2	0	0	1	0	0	0	1	0
3	0	1	0	1	1	0	0	0
4	1	0	0	0	1	0	1	0
5	1	1	0	1	1	0	1	1
6	1	0	0	0	1	1	1	0

1. Calculer la matrice de *similarité d'appariement simple*
2. Calculer la matrice de *similarité de Jaccard*
3. Construire, à partir de la dissimilarité d'appariement simple, le dendrogramme par la méthode du saut minimal
4. Construire, à partir de la dissimilarité d'appariement simple, le dendrogramme par la méthode du saut maximal.

Exercice 8.2

Déterminer les coefficients α_a , β et γ de la formule de Lance-Williams (8.8) dans le cas des règles d'agrégation

- 1) du saut minimal (8.1)
- 2) du saut maximal (8.2)
- 3) du saut moyen (8.3)
- 4) de la méthode de Ward (8.7).

Aide : pour tous $x, y \in \mathbb{R}$, on a $\min(x, y) = \frac{x+y}{2} - \frac{|x-y|}{2}$, et $\max(x, y) = \frac{x+y}{2} + \frac{|x-y|}{2}$.

Exercice 8.3

Soit une matrice de dissimilarité entre 6 individus :

	1	2	3	4	5	6
1	0	1	2	0	3	5
2	1	0	4	4	3	2
3	2	4	0	5	1	6
4	0	4	5	0	3	3
5	3	3	3	1	0	4
6	5	2	6	3	4	0

1. Construire le dendrogramme obtenu avec la méthode du saut maximal
2. Faire de même avec la méthode du saut minimal.

Exercice 8.4

On a effectué une classification hiérarchique ascendante avec SPSS (figure 8.4).

Cluster

Proximity Matrix						
Case	Squared Euclidean Distance					
	1	2	3	4	5	6
1	.000	11.000	7.000	1.000	5.000	14.000
2	11.000	.000	14.000	10.000	4.000	13.000
3	7.000	14.000	.000	10.000	8.000	3.000
4	1.000	10.000	10.000	.000	6.000	17.000
5	5.000	4.000	8.000	6.000	.000	11.000
6	14.000	13.000	3.000	17.000	11.000	.000

This is a dissimilarity matrix

Single Linkage

Agglomeration Schedule						
Stage	Cluster Combined		Coefficients	Stage Cluster First Appears		
	Cluster 1	Cluster 2		Cluster 1	Cluster 2	Next Stage
1	1	4	1.000	0	0	4
2	3	6	3.000	0	0	5
3	2	5	4.000	0	0	4
4	1	2	5.000	1	3	5
5	1	3	7.000	4	2	0

Dendrogram

***** HIERARCHICAL CLUSTER ANALYSIS *****

Dendrogram using Single Linkage




FIGURE 8.5 – sortie SPSS pour l'exercice 8.4

1. Quelle est la distance euclidienne carrée entre les individus 2 et 4 ?
2. Quels sont les deux individus les plus semblables ? les plus dissemblables ?
3. Construisez à la main le dendrogramme produit par le saut minimal sur les distances euclidiennes carrées, et comparez-le avec l'arbre produit par SPSS.
4. Les dissimilarités lues sur le dendrogramme sont-elles ultramétriques ? métriques ? euclidiennes ? euclidiennes carrées ?

Corrigé de la série 8

Exercice 8.1

Entre les tombes 1 et 2, on a $a_{12} = 0$, $b_{12} = 2$, $c_{12} = 2$ et $d_{12} = 4$. Pour l'appariement simple, $s_{12} = \frac{4}{8} = 0.5$, tandis que $s_{12} = \frac{0}{8} = 0$ pour la similarité de Jaccard.

On obtient finalement, pour l'ensemble des tombes, les matrices suivantes :

1. similarité d'appariement simple :

	1	2	3	4	5	6
1	1	0.5	0.625	0.625	0.5	0.5
2	0.5	1	0.375	0.625	0.25	0.5
3	0.625	0.375	1	0.5	0.625	0.375
4	0.625	0.625	0.5	1	0.625	0.875
5	0.5	0.25	0.625	0.625	1	0.5
6	0.5	0.5	0.375	0.875	0.5	1

2. similarité de Jaccard :

	1	2	3	4	5	6
1	1	0	0.25	0.25	0.333	0.2
2	0	1	0	0.25	0.143	0.2
3	0.25	0	1	0.2	0.5	0.166
4	0.25	0.25	0.2	1	0.5	0.75
5	0.333	0.143	0.5	0.5	1	0.429
6	0.2	0.2	0.166	0.75	0.429	1

Les dissimilarités correspondantes $d_{ij} = 1 - s_{ij}$ sont les suivantes :

dissimilarité d'appariement simple :

	1	2	3	4	5	6
1	0	0.5	0.375	0.375	0.5	0.5
2	0.5	0	0.625	0.375	0.75	0.5
3	0.375	0.625	0	0.5	0.375	0.625
4	0.375	0.375	0.5	0	0.375	0.125
5	0.5	0.75	0.375	0.375	0	0.5
6	0.5	0.5	0.625	0.125	0.5	0


dissimilarité de Jaccard :

	1	2	3	4	5	6
1	0	1	0.75	0.75	0.666	0.8
2	1	0	1	0.75	0.857	0.8
3	0.75	1	0	0.8	0.5	0.833
4	0.75	0.75	0.8	0	0.5	0.25
5	0.666	0.857	0.5	0.5	0	0.581
6	0.8	0.8	0.833	0.25	0.581	0

3. *Saut minimal sur la dissimilarité d'appariement simple* : on agrège tout d'abord les tombes 4 et 6 à hauteur 0.125. La nouvelle matrice de dissimilarité est de :

	1	2	3	[46]	5
1	0	0.5	0.375	0.375	0.5
2	0.5	0	0.625	0.375	0.75
3	0.375	0.625	0	0.5	0.375
[46]	0.375	0.375	0.5	0	0.375
5	0.5	0.75	0.375	0.375	0

A hauteur 0.375, on doit agréger simultanément 1 et 3 et [46], 2 et [46], 3 et 5, ainsi que [46] et 5, ce qui aboutit à la formation d'un seul cluster :



4. *Saut maximal sur la dissimilarité d'appariement simple* : on agrège tout d'abord les tombes 4 et 6 à hauteur 0.125. La nouvelle matrice de dissimilarité est de :

	1	2	3	[46]	5
1	0	0.5	0.375	0.5	0.5
2	0.5	0	0.625	0.5	0.75
3	0.375	0.625	0	0.5	0.375
[46]	0.5	0.5	0.5	0	0.5
5	0.5	0.75	0.375	0.5	0


A hauteur 0.375, on doit agréger simultanément 1 et 3, et 3 et 5, d'où :

	[135]	2	[46]
[135]	0	0.75	0.5
2	0.75	0	0.5
[46]	0.5	0.5	0

Puis à hauteur 0.5, on obtient

	[351]	[246]
[351]	0	0.75
[246]	0.75	0

d'où finalement le dendrogramme suivant :



Exercice 8.2

- 1) saut minimal : $\tilde{d}_{g,[ab]} = \min(d_{ga}, d_{gb}) = \frac{d_{ga} + d_{gb}}{2} - \frac{|d_{ga} - d_{gb}|}{2}$, et donc $\alpha_a = \alpha_b = \frac{1}{2}$, $\beta = 0$, $\gamma = -\frac{1}{2}$
- 2) saut maximal : $\tilde{d}_{g,[ab]} = \min(d_{ga}, d_{gb}) = \frac{d_{ga} + d_{gb}}{2} + \frac{|d_{ga} - d_{gb}|}{2}$, et donc $\alpha_a = \alpha_b = \frac{1}{2}$, $\beta = 0$, $\gamma = \frac{1}{2}$
- 3) saut moyen : $\alpha_a = \frac{N_a}{N_a + N_b} = \frac{\rho_a}{\rho_a + \rho_b}$, $\alpha_b = \frac{N_b}{N_a + N_b} = \frac{\rho_b}{\rho_a + \rho_b}$, $\beta = 0$, $\gamma = 0$
- 4) méthode de Ward : $\alpha_a = \frac{\rho_g + \rho_a}{\rho_g + \rho_a + \rho_b}$, $\alpha_b = \frac{\rho_g + \rho_a b}{\rho_g + \rho_a + \rho_b}$, $\beta = -\frac{\rho_g}{\rho_g + \rho_a + \rho_b}$, $\gamma = 0$.

Exercice 8.3

1. Saut maximal :

Etape 1

	[14]	2	3	5	6
[14]	0	4	5	3	5
2	4	0	4	3	2
3	5	4	0	1	6
5	3	3	1	0	4
6	5	2	6	4	0

Etape 2


	[14]	2	[35]	6
[14]	0	4	5	5
2	4	0	4	2
[35]	5	4	0	6
6	5	2	6	0

Etape 3

	[14]	[26]	[35]
[14]	0	5	5
[26]	5	0	6
[35]	5	6	0


Dendrogramme (lu horizontalement) :

0---1---2---3---4---5---6




2. En procédant de même, le dendrogramme résultant par saut minimal est :

0---1---2---3



Exercice 8.4

1. Le résultat se lit dans la matrice de dissimilarité (“Proximity Matrix”) : $d_{24} = 10$.
2. Dans le même tableau, on a $d_{min} = d_{14} = 1$ et $d_{max} = d_{46} = 17$.
3. On obtient le dendrogramme



En fouillant la documentation SPSS, on apprend que ce logiciel crée une échelle de hauteur où la première agrégation est positionnée à 1, et la dernière à 25 (pourquoi 25 ? mystère), les rapports de hauteur entre les pas successifs étant préservés. Ainsi dans l'exercice les hauteurs à chaque étape, à savoir 1, 3, 4, 5 et 7 sont transformées en 1, 9, 13, 17 et 25 par la transformation $(d - 1) \cdot \frac{24}{6} + 1$.

4. OUI, chaque fois : toute dissimilarité induite par un dendrogramme est ultramétrique, et donc métrique, euclidienne et euclidienne carrée en vertu des inclusions $U \subset L_2 \subset L_2^2$ et $U \subset L_2 \subset L_\infty$ entre classes de dissimilarités (chapitre 5).

Chapitre 9

Formulaire

9.1 Calcul matriciel

Matrices Une table de nombres $A = (a_{ij})$ contenant n lignes ($i = 1 \dots, n$) et m colonnes ($j = 1 \dots, m$) est une *matrice de type* $n \times m$. A est *carrée* si $m = n$. A est *diagonale* si carrée avec $a_{ij} = 0$ pour $i \neq j$.

Un *vecteur* (colonne) est de type $n \times 1$; un *vecteur ligne* est de type $1 \times m$; un *scalaire* est de type 1×1 .

Si A et B sont de type $n \times m$, alors $C = A + B$ l'est aussi, avec $c_{ij} = a_{ij} + b_{ij}$.

Si A est de type $n \times l$ et B de type $l \times m$, alors $C = AB$ est de type $n \times m$ avec $c_{ij} = \sum_{k=1}^l a_{ik}b_{kj}$.

Si A est de type $n \times m$ et λ est un scalaire, alors λA est de type $n \times m$, de composantes λa_{ij} .

Transposée et inverse La *transposée* d'une matrice $A = (a_{ij})$ de type $n \times m$ est la matrice $A' \equiv A^T = (a_{ji})$ de type $m \times n$. A est *symétrique* si $A = A'$.

La *matrice identité* de type n , notée I_n ou I est la matrice diagonale $n \times n$ de composantes δ_{ij} avec $\delta_{ij} = 1$ si $i = j$ et $\delta_{ij} = 0$ si $i \neq j$. Elle satisfait (en ajustant son type) à $AI = IA = A$ pour tout A .

L'*inverse* d'une matrice carrée A , lorsqu'il existe, est la matrice (unique) A^{-1} satisfaisant à $AA^{-1} = A^{-1}A = I$. A est *orthogonale* si $A' = A^{-1}$.

En général, $AB \neq BA$ et $A(BC) = (AB)C$. Aussi, $(AB)' = B'A'$ et $(AB)^{-1} = B^{-1}A^{-1}$.

Produit scalaire, norme et distance euclidienne Le *produit scalaire* de deux vecteurs (colonne) x et y de dimensions n est le scalaire $(x, y) := x'y = y'x = \sum_{i=1}^n x_i y_i$. Deux vecteurs x et y sont orthogonaux, noté $x \perp y$, si $(x, y) = 0$.

La *norme* de x est $\|x\| = \sqrt{(x, x)} = \sqrt{\sum_i x_i^2}$. Le vecteur x est *normé* si $\|x\| = 1$. On a $(x, y) = \|x\| \|y\| \cos \alpha$ où α est l'angle entre x et y mesuré à l'origine. $\|x - y\|$ est la *distance euclidienne* entre les vecteurs x et y .

Rang Soit $X = (x_1 | x_2 | \dots | x_p)$ un ensemble de p vecteurs (colonne) de dimension n . L'*espace engendré par* X est l'ensemble $M(X) = \{\sum_{j=1}^p \alpha_j x_j \mid \alpha \in \mathbb{R}^p\}$ des *combinaisons linéaires* des vecteurs. Les vecteurs de X sont *linéairement indépendants* si aucun des vecteurs n'appartient à l'espace généré par les autres vecteurs. Le *rang* de X , noté $\text{rg}(X)$, est le nombre maximal de vecteurs colonne de X (ou de vecteurs ligne de X) linéairement indépendants. On a $\text{rg}(X) \leq \min(n, p)$ lorsque X est de type $n \times p$.

Projection Soit $X = (x_1|x_2|\dots|x_p)$ une matrice de type $n \times p$ et de rang p , soit $M(X)$ l'espace engendré par X , et soit $y \notin M(X)$ un vecteur de dimension n . Le vecteur $y^* \in M(X)$ dont la distance à y est minimale, i.e. $y^* = \arg \min_{z \in M(X)} \|y - z\|$, est la *projection de y sur $M(X)$* . Il s'obtient comme $y^* = Py$ où $P := X(X'X)^{-1}X'$ est la *matrice de projection*, qui satisfait $P^2 = P$ (idempotence) et $P' = P$ (symétrie).

Valeurs propres et vecteurs propres Etant donné une matrice symétrique A de taille $n \times n$, le vecteur x (de type $n \times 1$) est un *vecteur propre (ve.p.) de A pour la valeur propre (va.p.) λ* (un scalaire) si $Ax = \lambda x$.

En général, A possède n va.p. λ_α ($\alpha = 1, \dots, n$) et n ve.p. propres associés, que l'on peut choisir normés et noter u_α (définis au signe près). Ces ve.p. sont orthogonales entre elles. La matrice $U := (u_1|\dots|u_\alpha|\dots|u_n)$ est orthogonale. Soit $\Lambda := \text{diag}(\lambda)$ la matrice diagonale engendrée par les ve.p. Alors $A = U\Lambda U'$ (théorème de décomposition spectrale). La matrice A est *semi-définie positive* si toutes ses va.p. sont non-négatives; elle est *définie positive* si toutes ses va.p. sont strictement positives.

Déterminant et trace Le *déterminant* d'une matrice carrée A de type $n \times n$ et de va.p. λ est $\det(A) := \prod_\alpha \lambda_\alpha$; sa *trace* est $\text{tr}(A) = \sum_\alpha \lambda_\alpha$. On a $\det(A') = \det(A)$ et $\det(AB) = \det(A)\det(B)$; aussi A est *inversible* ssi $\det(A) \neq 0$ ssi $\text{rg}(A) = n$. On a également $\text{tr}(A) = \sum_i a_{ii} = \text{tr}(A')$ et $\text{tr}(AB) = \text{tr}(BA)$.

9.2 Dissimilarités

Objets $i = 1, \dots, n$. Poids $f_i \geq 0$ avec $\sum_{i=1}^n f_i = 1$. Caractéristiques ou coordonnées $X = (x_{il})$ de type $n \times p$.

Rappel notations : $\exists x = \text{il existe } x$ $\forall x = \text{pour tout } x$

Dissimilarité $n \times n$: matrice (d_{ij}) symétrique $d_{ij} = d_{ji}$, à diagonale nulle $d_{ii} = 0$ et non négative $d_{ij} \geq 0$.

Dissimilarité métrique ou distance : telle que l'inégalité triangulaire $d_{ij} \leq d_{ik} + d_{kj}$ est vérifiée $\forall k$.

(*) **Dissimilarité propre** : telle que $d_{ij} = 0$ implique $i = j$.

(*) **Dissimilarité semi-propre** : telle que $d_{ij} = 0$ implique, $\forall k$, $d_{ik} = d_{jk}$.

Dissimilarité ultramétrique (U) : telle que, $\forall k$, $d_{ij} \leq \max(d_{ik}, d_{jk})$.

Dissimilarité d'arbre (A) : telle que $d_{ij} + d_{kl} \leq \max(d_{ik} + d_{jl}, d_{il} + d_{jk})$.

(*) **Dissimilarité conditionnellement définie négative (cdn)** : telle que $\sum_{ij} h_i h_j d_{ij} \leq 0$, $\forall h$ tel que $\sum_i h_i = 0$.

Dissimilarités euclidiennes ou L_2 : $\exists X = (x_{il})$ telles que $d_{ij} = \sqrt{\sum_{l=1}^p (x_{il} - x_{jl})^2} =: \|x_i - x_j\|_2$

Dissimilarités euclidiennes carrées ou L_2^2 : $\exists X$ tel que $d_{ij} = \sum_{l=1}^p (x_{il} - x_{jl})^2 =: \|x_i - x_j\|_2^2$

Dissimilarités de bloc (Manhattan) L_1 : $\exists X$ tel que $d_{ij} = \sum_{l=1}^p |x_{il} - x_{jl}| =: \|x_i - x_j\|_1$

Dissimilarités L_p ($p \geq 1$) : $\exists X$ tel que $d_{ij} = (\sum_{l=1}^p |x_{il} - x_{jl}|^p)^{\frac{1}{p}} =: \|x_i - x_j\|_p$

Dissimilarités L_∞ : $\exists X$ tel que $d_{ij} = \max_l |x_{il} - x_{jl}| =: \|x_i - x_j\|_\infty$


Equivalences : “métrique” $\Leftrightarrow L_\infty$

“ultramétrique” $\Leftrightarrow$ “arbre enraciné”

(*) “cdn” $\Leftrightarrow$ “euclidienne carrée” (L_2^2)

(*) “propre” $\Rightarrow$ “semi-propre”

(*) “métrique” $\Rightarrow$ “semi-propre”



Distances euclidiennes $d \in L_2$ - **distances euclidiennes carrées** $D = d^2 \in L_2^2$:

x_k est *intermédiaire* entre x_i et x_j ssi $d_{ik} + d_{kj} = d_{ij}$.

Le triangle $x_i x_j x_k$ est droit en k ssi $d_{ik}^2 + d_{kj}^2 = d_{ij}^2$ (Pythagore)

Centroïde $\bar{x}_f = \sum_j f_j x_j$. Distance carrée au centroïde $D_{if} = \|x_i - \bar{x}_f\|^2$

Inertie $\Delta(f) = \frac{1}{2} \sum_{jk} f_j f_k D_{jk}$.

Huygens faible : $\sum_j f_j D_{jf} = \frac{1}{2} \sum_{jk} f_j f_k D_{jk}$ Huygens fort : $\sum_j f_j D_{jf} = D_{ff} + \frac{1}{2} \sum_{jk} f_j f_k D_{jk}$.

Produits scalaires $B_{ij}^f = (x_i - \bar{x}_f)'(x_j - \bar{x}_f) = -\frac{1}{2}(D_{ij} - D_{if} - D_{jf})$ ($= -\frac{1}{2}D_{ij}$ double-centré).

Produits scalaires pondérés $K_{ij}^f = \sqrt{f_i f_j} B_{ij}^f$. $\text{trace}(K^f) = \sum_i f_i D_{if} = \Delta(f)$.

D est euclidien carré $\Leftrightarrow B^f$ est définie positive $\Leftrightarrow K^f$ est définie positive

MDS : les coordonnées s'obtiennent comme $x_{i\alpha} = \sqrt{\lambda_\alpha} u_{i\alpha}$ où $B^f = U \Lambda U'$, $U = (u_{i\alpha})$ et $\Lambda = \text{diag}(\lambda_\alpha)$

MDS pondéré : les coord. s'obtiennent comme $x_{i\alpha} = \sqrt{\lambda_\alpha} u_{i\alpha} / \sqrt{f_i}$ où $K^f = U \Lambda U'$, $U = (u_{i\alpha})$ et $\Lambda = \text{diag}(\lambda_\alpha)$

$\Delta(f) = \sum_\alpha \lambda_\alpha$ $\lambda_\alpha / \Delta(f) =$ "proportion d'inertie exprimée par le α -ème facteur"

(*) Configurations incompressibles (valeurs propres constantes) : $D_{ij} = c$, $\forall i \neq j$ (cas non pondéré).
 $D_{ij} = \frac{1}{f_i} + \frac{1}{f_j}$, $\forall i \neq j$ (cas pondéré).

Table contingence $N = (n_{jk})$: poids lignes $f_j = \frac{n_{j\bullet}}{n_{\bullet\bullet}}$; poids colonnes $\rho_k = \frac{n_{\bullet k}}{n_{\bullet\bullet}}$; quotients $q_{jk} = \frac{n_{jk}}{n_{j\bullet}} = \frac{n_{jk} n_{\bullet\bullet}}{n_{j\bullet} n_{\bullet k}}$

Dist. du chi2 entre lignes : $D_{ij}^X = \sum_k \frac{n_{\bullet k}}{n_{\bullet\bullet}} \left(\frac{n_{ik} n_{\bullet\bullet}}{n_{i\bullet} n_{\bullet k}} - \frac{n_{jk} n_{\bullet\bullet}}{n_{j\bullet} n_{\bullet k}} \right)^2 = \sum_k \rho_k (q_{ik} - q_{jk})^2$.

Inertie $\Delta(f) = \text{chi2} / n_{\bullet\bullet} =: \text{phi2}$.

Analyse des correspondances (AFC) : s'obtient comme MDS pondéré sur les lignes de $N = (n_{ik})$ (ou sur les colonnes de N : les va.p. λ_α sont identiques).

(*) ACP sur la matrice de variance-covariance Σ : mêmes va.p. (dualité) que le MDS pondéré avec $D_{ij} = \sum_{l=1}^p (x_{il} - x_{jl})^2$ et $\Delta = \sum_l \sigma_{ll}$, où $X = (x_{il})$ est la matrice des scores

(*) ACP sur la matrice de corrélation R : mêmes va.p. (dualité) que le MDS pondéré avec $D_{ij} = \sum_{l=1}^p (x_{il}^s - x_{jl}^s)^2$. Ici, $\Delta = p$.