

Méthodes Quantitatives III :

3. Statistiques multivariées et géométrie

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 25 - 34

Exercices : toute la série 2

Tableau de données

français	géographie	physique	chimie	histoire	maths	philosophie	allemand
7	6	5	6	2	7	9	2
5	5	3	7	4	4	6	6
5	7	8	9	5	6	5	9
5	4	5	3	5	5	5	6
6	5	3	7	2	6	4	4
7	8	4	5	5	7	8	6
4	5	3	5	1	5	4	3
5	5	6	6	4	7	5	4
3	6	3	3	2	4	5	2
7	6	5	7	4	7	6	4
5	7	5	7	5	8	10	4
8	7	7	9	7	10	8	7
9	8	4	8	7	7	9	7
5	7	4	6	8	6	5	8
4	8	10	10	10	10	6	5
3	4	6	5	1	5	4	3
3	7	4	4	4	7	5	3
4	4	7	6	3	4	5	7
9	5	5	8	10	7	6	7
6	3	3	3	3	8	6	2
4	6	5	5	7	4	5	6
7	4	4	4	1	8	8	2
6	7	4	6	5	7	5	6
4	6	6	7	6	7	7	5
6	7	7	6	5	9	8	7
8	5	6	6	5	8	5	9
5	8	4	6	4	8	9	5
5	4	5	6	5	4	7	4
4	3	6	6	7	5	8	3
5	2	4	6	3	5	9	4
5	6	7	7	5	8	7	5
3	2	2	3	1	6	4	3
7	5	7	7	10	7	5	8
5	9	6	8	4	8	5	8
3	2	3	4	3	6	5	3
6	7	4	7	6	5	7	8
6	5	3	4	4	4	8	1
5	8	5	6	7	7	4	7
5	10	8	9	7	10	8	9
6	7	7	7	4	9	7	8
5	7	3	2	7	4	7	2
3	5	2	2	2	4	4	3
7	5	5	3	2	6	8	1
3	6	5	5	3	7	5	5
8	6	7	7	4	9	4	7
4	6	4	7	2	9	6	1
4	6	3	5	3	6	5	5
8	6	6	7	6	8	7	7
6	10	4	8	8	9	7	7
8	8	7	8	8	7	8	8

Un tableau de données numériques peut être représenté par une **matrice** $\mathbf{X} = (x_{ij})$ de dimensions $(n \times p)$.

Chaque ligne représente un **individu**, chaque colonne une **variable**, et les cases contiennent les **scores** x_{ij} .



Ici, il s'agit d'un tableau de notes (fictives) de $n = 50$ élèves sur $p = 8$ branches.

Espace des individus, espace des variables


Cette matrice $\mathbf{X}$ peut se décomposer en :

- n **vecteurs-lignes**, représentant n vecteurs dans $\mathbb{R}^p$. C'est l'espace des **individus**.
- p **vecteurs-colonnes**, représentant p vecteurs dans $\mathbb{R}^n$. C'est l'espace des **variables**.

$$\mathbf{X} = \begin{pmatrix} 3 & -4 \\ -3 & 2 \\ 2 & 1 \end{pmatrix}$$





On peut donc, pour résoudre un problème de statistiques multivariées, le **traduire en problème géométrique**.



Problème dans l'espace des individus ou espace des variables

On travaillera **parfois dans l'espace des individus, parfois dans l'espace des variables.**

Par exemple, la régression simple $y^* = ax + b$ peut se voir comme :



La moyenne : solution algébrique

Problème : si on a une variable $\mathbf{x} = \{x_1, \dots, x_n\}$, comment faire pour la **résumer au mieux en un seul chiffre** ?

Précision : « au mieux » n'est pas clair, il faut définir un critère précis. On veut la valeur a qui **minimise**

$$\sum_{i=1}^n (x_i - a)^2$$

(Il y a une raison à ce critère, c'est celui du maximum de vraisemblance)

Solution algébrique : par le **principe de Huygens**, on a

$$\sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + (\bar{x} - a)^2 \quad \text{où} \quad \bar{x} := \frac{1}{n} \sum_{i=1}^n x_i$$

On voit donc que cette quantité est minimale pour $a = \bar{x}$.

La moyenne : traduction géométrique

Traduction géométrique : Trouver a qui minimise $\sum_{i=1}^n (x_i - a)^2$ revient à dire qu'il faut trouver un **vecteur dans l'espace des variables** de la forme :


$$a\mathbf{1}_n = a \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}$$

tel que

$$d^2(\mathbf{x}, a\mathbf{1}_n) = \|\mathbf{x} - a\mathbf{1}_n\|^2 = \left\| \begin{pmatrix} x_1 - a \\ \vdots \\ x_n - a \end{pmatrix} \right\|^2 = \sum_{i=1}^n (x_i - a)^2$$

soit minimal. Il s'agit donc de **trouver le vecteur sur l'hyperplan $M(\mathbf{1}_n)$ le plus proche de $\mathbf{x}$.**

La moyenne : traduction géométrique



La moyenne : solution géométrique

Solution géométrique : Le vecteur le plus proche est la **projection de $\mathbf{x}$ sur $M(\mathbf{1}_n)$** . On calcule la matrice de projection :

$$\mathbf{P} = \mathbf{1}_n \underbrace{(\mathbf{1}_n' \mathbf{1}_n)^{-1}}_{=n} \mathbf{1}_n' = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n'$$

Avec

$$\mathbf{J}_n := \mathbf{1}_n \mathbf{1}_n' = \begin{pmatrix} 1 & \cdots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \cdots & 1 \end{pmatrix}$$

La matrice de projection s'écrit $\mathbf{P} = \frac{1}{n} \mathbf{J}_n$. On a donc :

$$\mathbf{x}^* = \mathbf{P}\mathbf{x} = \mathbf{1}_n \underbrace{\left(\frac{1}{n} \mathbf{1}_n' \mathbf{x} \right)}_{=\bar{x}} = \bar{x} \mathbf{1}_n$$


On tombe bien sur la même solution, $a = \bar{x}$.

La variable centrée

Centrer une variable x revient à chercher :

$$\mathbf{x}^c := \mathbf{x} - \bar{x}\mathbf{1}_n = \mathbf{x} - \mathbf{x}^* = \mathbf{x} - \mathbf{P}\mathbf{x}$$

La variable centrée est donc le **résidu** $\mathbf{e} := \mathbf{x} - \mathbf{x}^*$ de la projection sur $M(\mathbf{1}_n)$:




Il s'agit aussi de la **projection sur l'hyperplan orthogonal à $\mathbf{1}_n$** :

$$\mathbf{x}^c = \mathbf{H}\mathbf{x} = \left(\mathbf{I} - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n'\right)\mathbf{x}$$

La matrice $\mathbf{H} := \mathbf{I} - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n'$ s'appelle la **matrice de centration**.

La variable centrée



La **variance empirique** se définit comme :

$$\text{var}(\mathbf{x}) := \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

D'un point de vue géométrique :

$$\text{var}(\mathbf{x}) := \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \left\| \begin{pmatrix} x_1 - \bar{x} \\ \vdots \\ x_n - \bar{x} \end{pmatrix} \right\|^2 = \frac{1}{n} \|\mathbf{x} - \bar{\mathbf{x}}\|^2 = \frac{1}{n} \|\mathbf{x}^c\|^2$$

Il s'agit donc du **carré de la norme du vecteur centré** (divisé par n).

Soient deux variables, $\mathbf{x}$ et $\mathbf{y}$. La **covariance** se définit comme :

$$\text{cov}(\mathbf{x}, \mathbf{y}) := \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

D'un point de vue géométrique :

$$\text{cov}(\mathbf{x}, \mathbf{y}) := \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n} \sum_{i=1}^n x_i^c y_i^c = \frac{1}{n} (\mathbf{x}^c)' (\mathbf{y}^c) = \frac{1}{n} (\mathbf{x}^c, \mathbf{y}^c)$$

Il s'agit donc du **produit scalaire entre les deux vecteurs centrés $\mathbf{x}^c$ et $\mathbf{y}^c$** (divisé par n). On a donc :

$$\text{cov}(\mathbf{x}, \mathbf{y}) = \frac{1}{n} \|\mathbf{x}^c\| \|\mathbf{y}^c\| \cos(\alpha)$$

avec α l'angle entre les deux vecteurs centrés $\mathbf{x}^c$ et $\mathbf{y}^c$.

Soient deux variables, $\mathbf{x}$ et $\mathbf{y}$. La **corrélation** se définit comme :


$$r_{xy} = \text{corr}(\mathbf{x}, \mathbf{y}) := \frac{\text{cov}(\mathbf{x}, \mathbf{y})}{\sqrt{\text{var}(\mathbf{x})\text{var}(\mathbf{y})}}$$

D'un point de vue géométrique :

$$r_{xy} = \frac{\text{cov}(\mathbf{x}, \mathbf{y})}{\sqrt{\text{var}(\mathbf{x})\text{var}(\mathbf{y})}} = \frac{\frac{1}{n} \|\mathbf{x}^c\| \|\mathbf{x}^c\| \cos(\alpha)}{\frac{1}{n} \|\mathbf{x}^c\| \|\mathbf{y}^c\|} = \cos(\alpha)$$

La corrélation est donc le **cosinus de l'angle formé par les vecteurs centrés $\mathbf{x}^c$ et $\mathbf{y}^c$** .

La corrélation



La corrélation : interprétation

En sachant que $r_{xy} = \cos(\alpha)$, on voit bien que.

- La corrélation est toujours dans $[-1, 1]$.
- $r_{xy} = 0$ ssi $\alpha = 90^\circ$, c'est-à-dire que les vecteurs $\mathbf{x}^c$ et $\mathbf{y}^c$ sont perpendiculaires.
- $r_{xy} = 1$ ssi $\alpha = 0$, c'est-à-dire que les vecteurs $\mathbf{x}^c$ et $\mathbf{y}^c$ sont dans la même direction.
- $r_{xy} = -1$ ssi $\alpha = 180^\circ$, c'est-à-dire que les vecteurs $\mathbf{x}^c$ et $\mathbf{y}^c$ sont dans des directions opposées.
- $r_{xy} = \pm 1$ ssi $\mathbf{y}^c = a\mathbf{x}^c$ ssi $\mathbf{y} = a\mathbf{x} + b$ (avec $a > 0$ ssi $r_{xy} = 1$ et $a < 0$ ssi $r_{xy} = -1$).

Statistiques multivariée et géométrie : résumé

Statistique (variables $\mathbf{x}$, $\mathbf{y}$)	Géométrie (vecteurs $\mathbf{x}$, $\mathbf{y}$)
variable $\mathbf{x}$ à n scores	vecteur $\mathbf{x}$ à n composantes
vecteur centré $\mathbf{x}^c = \mathbf{x} - \bar{\mathbf{x}}$	résidu de la projection de $\mathbf{x}$ sur la droite des constantes
variance de $\mathbf{x}$	carré de la norme de $\mathbf{x}^c$
écart-type de $\mathbf{x}$	norme de $\mathbf{x}^c$
standardiser $\mathbf{x}$	normer $\mathbf{x}^c$
covariance de $\mathbf{x}$ et $\mathbf{y}$	produit scalaire de $\mathbf{x}^c$ et $\mathbf{y}^c$
correlation de $\mathbf{x}$ et $\mathbf{y}$	cosinus de l'angle entre $\mathbf{x}^c$ et $\mathbf{y}^c$
$r_{xy} = \pm 1$	$\mathbf{x}^c$ et $\mathbf{y}^c$ parallèles ($\mathbf{y} = a\mathbf{x} + b$)
$r_{xy} = 0$	$\mathbf{x}^c$ et $\mathbf{y}^c$ perpendiculaires

La matrice de variance-covariance

Définition

Soient p variables $\mathbf{x}_1, \dots, \mathbf{x}_p$ dans $\mathbb{R}^n$. La **matrice de variance-covariance**, notée $\Sigma = (s_{kl})$, est la matrice $p \times p$ définie par :

$$s_{kl} := \text{cov}(\mathbf{x}_k, \mathbf{x}_l) \quad s_{kk} = \text{var}(\mathbf{x}_k) = s_k^2$$

où $s_k = \sqrt{\text{var}(\mathbf{x}_k)}$ désigne l'écart-type de $\mathbf{x}_k$.

Si l'on utilise la **matrice des données centrées**, i.e.

$$\mathbf{X}^c = \left(\begin{array}{c|c|c|c} \mathbf{x}_1^c & \mathbf{x}_2^c & \cdots & \mathbf{x}_p^c \end{array} \right)$$

on a :

$$\Sigma := \frac{1}{n}(\mathbf{X}^c)'(\mathbf{X}^c)$$

Définition

Soient p variables $\mathbf{x}_1, \dots, \mathbf{x}_p$ dans $\mathbb{R}^n$. La **matrice de corrélation**, notée $\mathbf{R} = (r_{kl})$, est la matrice $p \times p$ définie par :

$$r_{kl} := \text{corr}(\mathbf{x}_k, \mathbf{x}_l) = \frac{s_{jk}}{s_j s_k}$$

Si l'on utilise la **matrice des données standardisées**, i.e.

$$\mathbf{X}^s = \left(\begin{array}{c|c|c|c} \mathbf{x}_1^s & \mathbf{x}_2^s & \cdots & \mathbf{x}_p^s \end{array} \right)$$

On a :

$$\mathbf{R} := \frac{1}{n} (\mathbf{X}^s)' (\mathbf{X}^s)$$

Σ et $\mathbf{R}$ sont **symétriques** et **positives semi-définies**.

Matrice de covariance et corrélation : exemple

Pour le jeu de données des notes, on a la matrice de covariance :

	fran.	geo.	phys.	chim.	hist.	math.	philo.	all.
français	2.72	0.70	0.63	1.17	1.46	1.09	1.09	1.45
géographie	0.70	3.41	1.04	1.80	2.03	1.59	0.69	2.13
physique	0.63	1.04	2.94	2.10	1.91	1.53	0.37	2.12
chimie	1.17	1.80	2.10	3.34	2.43	1.77	0.71	2.70
histoire	1.46	2.03	1.91	2.43	5.60	1.09	0.77	3.23
mathématiques	1.09	1.59	1.53	1.77	1.09	3.06	0.72	1.34
philosophie	1.09	0.69	0.37	0.71	0.77	0.72	2.71	-0.23
allemand	1.45	2.13	2.12	2.70	3.23	1.34	-0.23	5.39

et de corrélation :

	fran.	geo.	phys.	chim.	hist.	math.	philo.	all.
français	1.00	0.23	0.22	0.39	0.37	0.38	0.40	0.38
géographie	0.23	1.00	0.33	0.53	0.46	0.49	0.23	0.50
physique	0.22	0.33	1.00	0.67	0.47	0.51	0.13	0.53
chimie	0.39	0.53	0.67	1.00	0.56	0.56	0.23	0.64
histoire	0.37	0.46	0.47	0.56	1.00	0.26	0.20	0.59
mathématiques	0.38	0.49	0.51	0.56	0.26	1.00	0.25	0.33
philosophie	0.40	0.23	0.13	0.23	0.20	0.25	1.00	-0.06
allemand	0.38	0.50	0.53	0.64	0.59	0.33	-0.06	1.00

La régression multiple

Problème : Soient la variable $\mathbf{y}$ et les variables $\mathbf{x}_1, \dots, \mathbf{x}_p$ dans $\mathbb{R}^n$. Le but est de trouver les $b_0, b_1, \dots, b_p$ tels que $\mathbf{y}^* = b_0 + b_1\mathbf{x}_1 + \dots + b_p\mathbf{x}_p$ soit le plus proche de $\mathbf{y}$.

Précision : « le plus proche » est mal défini. Il s'agit de minimiser les moindres carrés ou la somme des résidus e_i au carré

$$\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - y_i^*)^2 \quad \text{avec} \quad y_i^* = b_0 + b_1x_{i1} + \dots + b_px_{ip}$$

Traduction géométrique : $\mathbf{y}^*$ est une combinaison linéaire de $\mathbf{1}_n, \mathbf{x}_1, \dots, \mathbf{x}_p$ et fait donc partie de l'hyperplan $M(\mathbf{1}_n, \mathbf{x}_1, \dots, \mathbf{x}_p)$. Il faut donc trouver le vecteur de cet hyperplan tel que :

$$\sum_{i=1}^n (y_i - y_i^*)^2 = \|\mathbf{y} - \mathbf{y}^*\|^2 = \|\mathbf{e}\|^2$$

soit minimal. Il s'agit du plus proche vecteur de l'hyperplan $M(\mathbf{1}_n, \mathbf{x}_1, \dots, \mathbf{x}_p)$.

La régression multiple : solution

Solution géométrique : En posant la matrice :

$$\mathbf{X} := \left(\begin{array}{c|c|c|c|c} \mathbf{1}_n & \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_p \end{array} \right)$$

La **matrice de projection sur l'hyperplan** est :

$$\mathbf{P} := \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$$


On a donc :

$$\mathbf{y}^* = \mathbf{P}\mathbf{y} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

Soit $\mathbf{b} = (b_i)$ le vecteur contenant les **coefficients de régression**. On a alors :

$$\mathbf{y}^* = \mathbf{X}\mathbf{b} \Rightarrow \boxed{\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}}$$

La régression multiple : géométrie



- e est orthogonal à tous les prédicteurs, donc $\bar{e} = 0$, $\text{corr}(e, x_k) = 0$ et $\text{corr}(e, y^*)$.
- Le triangle de sommets $\bar{y}$, y^* et y est rectangle en y^* . On a donc :

$$\begin{aligned} \|y^c\|^2 &= \|(y^*)^c\|^2 + \|e\|^2 \\ \text{var}(y) &= \text{var}(y^*) + \text{var}(e) \\ \text{variance totale} &= \text{variance expliquée} + \text{variance résiduelle} \end{aligned}$$

- Le coefficient de corrélation multiple R peut se définir comme :

$$R := \cos(\alpha) = \text{corr}(y, y^*)$$

$$\text{On a } R^2 = \frac{\text{var}(y^*)}{\text{var}(y)} = \frac{\text{variance expliquée}}{\text{variance totale}} = \text{prop. variance expliquée}$$

Le coefficient de corrélation partielle

Problème : Soient trois variables $\mathbf{x}$, $\mathbf{y}$ et $\mathbf{z}$ de $\mathbb{R}^n$. On aimerait un indice de **corrélation entre $\mathbf{x}$ et $\mathbf{y}$ tel que l'effet de $\mathbf{z}$ n'est pas pris en compte**.

Précision : qu'est-ce que « l'effet de $\mathbf{z}$ ». On peut se placer dans le cadre de la régression. Les **parties expliquées par $\mathbf{z}$ de $\mathbf{x}$ et $\mathbf{y}$** sont respectivement


$$\mathbf{x}^* = a_x \mathbf{z} + b_x \quad \mathbf{y}^* = a_y \mathbf{z} + b_y$$

On cherche donc à calculer :

$$\text{corr}(\mathbf{x} - \mathbf{x}^*, \mathbf{y} - \mathbf{y}^*)$$

Notez que comme $\text{corr}(\mathbf{x}, \mathbf{y}) = \text{corr}(a\mathbf{x} + b, c\mathbf{y} + d)$, les b_x et b_y ne sont pas nécessaires et on peut travailler avec les variables standardisées.

Le coefficient de corrélation partielle : résolution géométrie



- $\text{corr}(x, y) = \cos(\gamma)$ $\text{corr}(x, z) = \cos(\alpha)$ $\text{corr}(y, z) = \cos(\beta)$.
- x^{**} et y^{**} sont les **parties résiduelles**, non-expliquées par z .
- Le **coefficient de corrélation partielle** est

$$r_{x,y|z} = \text{corr}(x, y|z) := \text{corr}(x^{**}, y^{**}) = \cos(\delta)$$

- On trouve (géométrie sphérique)

$$r_{x,y|z} = \frac{\cos(\gamma) - \cos(\alpha)\cos(\beta)}{\sqrt{1 - \cos^2(\alpha)}\sqrt{1 - \cos^2(\beta)}} = \frac{r_{xy} - r_{xz}r_{yz}}{\sqrt{1 - r_{xz}^2}\sqrt{1 - r_{yz}^2}}$$

- $r_{x,y|z}$ est le cosinus entre $M(x, z)$ et $M(y, z)$.

La généralisation du coefficient de corrélation

Plus généralement, si l'on note M_{123} l'hyperplan engendré par $\mathbf{1}_n, \mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3$ et $\angle(M, N)$ l'angle entre deux hyperplans M et N , on a :

- La **corrélation simple** : $r_{12} = \cos(\angle(M_1, M_2))$.
- La **corrélation partielle** : $r_{12|3} = \cos(\angle(M_{13}, M_{23}))$.
- La **corrélation partielle vs 2 variables** : $r_{12|34} = \cos(\angle(M_{134}, M_{234}))$.
- La **corrélation multiple, 1 critère vs multiples prédicteurs** :
 $r_{1|234} = \cos(\angle(M_1, M_{234}))$.
- La **corrélation canonique de multiples variables vs multiples variables**
qui s'interprète comme « dans quelle mesure les deux jeux de données mesurent des choses similaires » : $r_{123|456} = \cos(\angle(M_{123}, M_{456}))$.