

Méthodes Quantitatives III :

4. Régression multiple

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 38 - 49

Exercices : toute la série 3

Régression multiple : motivations

français	géographie	physique	chimie	histoire	maths	philosophie	allemand
7	6	5	6	2	7	9	2
5	5	3	7	4	4	6	6
5	7	8	9	5	6	5	9
5	4	5	3	5	5	5	6
6	5	3	7	2	6	4	4
7	8	4	5	5	7	8	6
4	5	3	5	1	5	4	3
5	5	6	6	4	7	5	4
3	6	3	3	2	4	5	2
7	6	5	7	4	7	6	4
5	7	5	7	5	8	10	4
8	7	7	9	7	10	8	7
9	8	4	8	7	7	9	7
5	7	4	6	8	6	5	8
4	8	10	10	10	10	6	5
3	4	6	5	1	5	4	3
3	7	4	4	4	7	5	3
4	4	7	6	3	4	5	7
9	5	5	8	10	7	6	7
6	3	3	3	3	8	6	2
4	6	5	5	7	4	5	6
7	4	4	4	1	8	8	2
6	7	4	6	5	7	5	6
4	6	6	7	6	7	7	5
6	7	7	6	5	9	8	7
8	5	6	6	5	8	5	9
5	8	4	6	4	8	9	5
5	4	5	6	5	4	7	4
4	3	6	6	7	5	8	3
5	2	4	6	3	5	9	4
5	6	7	7	5	8	7	5
3	2	2	3	1	6	4	3
7	5	7	7	10	7	5	8
5	9	6	8	4	8	5	8
3	2	3	4	3	6	5	3
6	7	4	7	6	5	7	8
6	5	3	4	4	4	8	1
5	8	5	6	7	7	4	7
5	10	8	9	7	10	8	9
6	7	7	7	4	9	7	8
5	7	3	2	7	4	7	2
3	5	2	2	2	4	4	3
7	5	5	3	2	6	8	1
3	6	5	5	3	7	5	5
8	6	7	7	4	9	4	7
4	6	4	7	2	9	6	1
4	6	3	5	3	6	5	5
8	6	6	7	6	8	7	7
6	10	4	8	8	9	7	7
8	8	7	8	8	7	8	8

Nous allons retravailler ici avec le tableau des notes

$\mathbf{X} = (x_{ij})$ de dimensions (50×8) .

Question : en se basant sur ce tableau, si l'on possède toutes les notes d'un nouvel élève sauf celle de géographie, peut-on la prédire ?

C'est l'un des buts de la **régression multiple** (mais pas uniquement).

Régression multiple : sorties (SPSS)

Les **sorties** d'une régression multiples sont nombreuses. Il s'agira ici de les comprendre.

Corrélations

	français	géographie	physique	chimie	histoire	maths	philosophie	allemand
français	1	,230	,222	,387	,373	,379	,401	,378
géographie	,230	1	,328	,533	,465	,492	,226	,497
physique	,222	,328	1	,670	,472	,512	,129	,533
chimie	,387	,533	,670	1	,563	,555	,234	,637
histoire	,373	,465	,472	,563	1	,263	,198	,589
maths	,379	,492	,512	,555	,263	1	,251	,330
philosophie	,401	,226	,129	,234	,198	,251	1	-,060
allemand	,378	,497	,533	,637	,589	,330	-,060	1

ANOVA^a

	Somme des carrés	ddl	Carré moyen	F	Sig.
Régression	80,623	7	11,518	5,382	,000 ^b
Résiduel	89,877	42	2,140		
Total	170,500	49			


a. Variable dépendante : géographie

b. Prédicteurs : (Constante), allemand, philosophie, mathématiques, français, histoire, physique, chimie

Modèle	Coefficients non standardisés		Coefficients standardisés		Sig.	Intervalle de confiance à 95,0% pour B		Statistiques de colinéarité	
	B	Erreur standard	Bêta	t		Borne inférieure	Borne supérieure	Tolérance	VIF
1									
(Constante)	1,239	1,080		1,147	,258	-,941	3,419		
français	-,247	,158	-,221	-1,563	,125	-,567	,072	,627	1,594
physique	-,283	,174	-,262	-1,623	,112	-,634	,069	,480	2,084
chimie	,189	,190	,187	,994	,326	-,194	,571	,356	2,808
histoire	,169	,118	,216	1,430	,160	-,069	,407	,549	1,822
mathématiques	,405	,153	,384	2,645	,011	,096	,715	,596	1,678
philosophie	,210	,151	,187	1,390	,172	-,095	,514	,693	1,442
allemand	,286	,138	,360	2,068	,045	,007	,566	,415	2,410

R	R-deux	R-deux ajusté	Erreur standard de l'estimation
,688 ^a	,473	,385	1,463

a. Prédicteurs : (Constante), allemand, philosophie, mathématiques, français, histoire, physique, chimie



Définitions

Effectuer une **régression linéaire multiple** du **critère** y avec les p **prédicteurs** $x_1, \dots, x_p$ consiste à :

Trouver les meilleurs **coefficients de régression** $b_0, b_1, \dots, b_p$ tels que les **prédictions** y^* définies par

$$y^* := b_0 + b_1 x_1 + \dots + b_p x_p$$

approximent *au mieux* y .



Au mieux signifie que la somme des carrés des **résidus** $e := y - y^*$ doit être minimale, i.e.

$$\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - y_i^*)^2$$

C'est le **critère des moindres carrés**.

Régression simple : espace des individus

Dans la **régression simple**, on cherche uniquement à prédire y avec x via les prédictions : $y^* = b_0 + b_1x$. Dans l'espace des individus, les points (x_i, y_i^*) sont alignés sur une **droite** :




Le critère des moindres carrés consiste à trouver la droite la plus ajustée.

À gauche : $\sum_{i=1}^n e_i^2 = 13781.32$. À droite : $\sum_{i=1}^n e_i^2 = 58761.98$.

Régression multiple : espace des individus

Pour la régression multiple dans l'espace des individus, les points de coordonnées $(x_{i1}, \dots, x_{ip}, y_i^*)$ avec $y_i^* := b_0 + b_1x_{i1} + \dots + b_px_{ip}$ sont alignés sur un **hyperplan** :



La solution

En construisant la matrice

$$\mathbf{X} = \left(\begin{array}{c|c|c|c} \mathbf{1}_n & \mathbf{x}_1 & \cdots & \mathbf{x}_p \end{array} \right)$$

Les prédictions s'écrivent alors $\mathbf{y}^*$ comme :

$$\mathbf{y}^* = \mathbf{P}\mathbf{y} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$


où $\mathbf{P}$ est la **matrice de projection sur le plan** $M(\mathbf{1}_n, \mathbf{x}_1, \dots, \mathbf{x}_p)$.

Sachant la relation linéaire $\mathbf{y}^* = \mathbf{X}\mathbf{b}$, on trouve les **coefficients** avec :

$$\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

La solution : espace des variables

Dans l'espace des variables, trouver $\mathbf{y}^*$ consiste à faire la projection de $\mathbf{y}$ sur $M(\mathbf{1}_n, \mathbf{x}_1, \dots, \mathbf{x}_p)$.



Les coefficients : un exemple

Dans notre tableau de notes, prédire la note de géographie avec les autres notes nous donne les coefficients suivants :

	B
(Constante)	1,239
français	-,247
physique	-,283
chimie	,189
histoire	,169
mathématiques	,405
philosophie	,210
allemand	,286

Le score prédit en géographie de quelqu'un qui aurait 8 en français et en histoire, et 7 partout ailleurs serait de

$$y^* = 1.239 - 0.247 \cdot 8 - 0.283 \cdot 7 + 0.189 \cdot 7 + 0.169 \cdot 8 + 0.405 \cdot 7 + 0.21 \cdot 7 + 0.286 \cdot 7 = 6.26$$

On peut voir qu'avoir une bonne note en français et physique diminue le score prédit de géographie, alors qu'il augmente pour les autres branches.

Définitions

Soit un modèle de régression multiple $y^* := b_0 + b_1x_1 + \dots + b_px_p$. On appelle **coefficients de régression standardisés** les $\beta_0, \beta_1, \dots, \beta_p$ définis par :


$$\beta_0 := 0 \quad \beta_j := \frac{\sqrt{\text{var}(x_j)}}{\sqrt{\text{var}(y)}} b_j = \frac{s_{x_j}}{s_y} b_j$$

Il s'agit des coefficients de régression que l'on obtiendrait en effectuant la régression sur les **variables standardisées** $y^s, x_1^s, \dots, x_p^s$.

Ces coefficients β_j ne dépendent pas du système d'unités choisis. Si la valeur du prédicteur x_j augmente de s_{x_j} , alors y^* augmente de $\beta_j s_y$.

Les variances

Si l'on observe le triangle $\mathbf{y}$, $\mathbf{y}^*$ et $\mathbf{e}$ ainsi que sa projection sur la plan orthogonal à $\mathbf{1}_n$, on observe qu'ils sont **rectangles** :



On a alors :

$$\|\mathbf{y}^c\|^2 = \|(\mathbf{y}^*)^c\|^2 + \|\mathbf{e}\|^2$$

$$\text{var}(\mathbf{y}) = \text{var}(\mathbf{y}^*) + \text{var}(\mathbf{e})$$

$$\cos(\alpha) = \text{corr}(\mathbf{y}, \mathbf{y}^*) \quad \cos^2(\alpha) = \frac{\|(\mathbf{y}^*)^c\|^2}{\|\mathbf{y}^c\|^2} = \frac{\text{var}(\mathbf{y}^*)}{\text{var}(\mathbf{y})}$$

Les variances

La **variance totale de y** se décompose donc entre la **variance expliquée** et la **variance inexpliquée**.

$$\underbrace{\text{var}(\mathbf{y})}_{\text{variance totale}} = \underbrace{\text{var}(\mathbf{y}^*)}_{\text{variance expliquée}} + \underbrace{\text{var}(\mathbf{e})}_{\text{variance inexpliquée}}$$

Définition

le **coefficient de corrélation multiple**, noté R , se définit comme :

$$R := \text{corr}(\mathbf{y}, \mathbf{y}^*)$$

En fait, on utilise plus généralement le R^2 , qui nous donne :

$$R^2 = \frac{\text{var}(\mathbf{y}^*)}{\text{var}(\mathbf{y})}$$

c'est-à-dire la **proportion de variance expliquée**.

Pour le moment, la régression a purement été présentée sous un prisme empirique. Si l'on désire avoir accès à des **tests statistiques**, il faut poser un **modèle théorique**.

On suppose que

$$Y = Y^* + \epsilon$$

avec

$$Y = b_0^{\text{theo}} + b_1^{\text{theo}} X_1 + \dots + b_p^{\text{theo}} X_p$$
$$\epsilon \sim \mathcal{N}(0, \sigma^2)$$

Y^* est la **partie déterministe** et ϵ la **partie aléatoire** ou **erreur**. Cette dernière suit une loi normale centrée de variance inconnue σ^2 .

Grâce au **maximum de vraisemblance**, il nous est possible de trouver des **estimateurs** de ces quantités théoriques.

Définitions

Sous le modèle théorique, les estimateurs :

$$\hat{b}_j^{\text{theo}} := b_j \quad (\text{où } b_j \text{ vient de } \mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y})$$

$$\hat{\sigma}^2 := \frac{\sum_{i=1}^n e_i^2}{n - p - 1}$$

$$\hat{R}^2 := \frac{(n - 1)R^2 - p}{n - p - 1}$$

sont tous **non-biaisés**. $\hat{\sigma}$ s'appelle l'**erreur standard** et $\hat{R}^2$ le **R-carré ajusté**.

On voit que $\hat{R}^2$ est inférieur R^2 . Ce dernier est basé uniquement sur l'échantillon et est trop optimiste concernant l'évaluation de la **véritable variance expliquée**.

Estimateurs : exemple

	R	R-deux	R-deux ajusté	Erreur standard de l'estimation
	,688 ^a	,473	,385	1,463

a. Prédicteurs : (Constante), allemand, philosophie, mathématiques, français, histoire, physique, chimie

- La valeur de la **corrélation multiple** vaut $R = \text{corr}(\mathbf{y}, \mathbf{y}^*) = 0.688$
- Dans l'échantillon, la **proportion de variance expliquée** par les prédicteurs vaut $R^2 = 0.473 = 47.3\%$.
- La **proportion théorique de variance expliquée** vaut plutôt $\hat{R}^2 = 38.5\%$.
- L'**erreur standard** vaut $\hat{\sigma} = 1.463$, ce qui veut dire que l'écart typique théorique entre la note de géographie et sa prédiction est de l'ordre de 1.46.

Définition

Sous le modèle théorique présenté, on peut également calculer l'**erreur standard de b_k** ou l'**écart-type de b_k** , noté **err_k**, avec :

$$\text{err}_k := \hat{\sigma} \sqrt{(\mathbf{X}'\mathbf{X})_{kk}^{-1}}$$

Ce dernier mesure la fluctuation typique de b_k en fonction de l'échantillonnage.

Cette erreur permet de construire :

- Un **test d'hypothèse** : $H_0 : b_k^{\text{theo}} = 0$ vs $H_1 : b_k^{\text{theo}} \neq 0$
- Un **intervalle de confiance** :

$$P(b_k - \epsilon_k(\alpha) < b_k^{\text{theo}} < b_k + \epsilon_k(\alpha)) = 1 - \alpha$$

Tests et intervalles de confiance des coefficients : exemple

Modèle		Coefficients non standardisés		Coefficients standardisés		Sig.	Intervalle de confiance à 95,0% pour B	
		B	Erreur standard	Bêta	t		Borne inférieure	Borne supérieure
1	(Constante)	1,239	1,080		1,147	,258	-,941	3,419
	français	-,247	,158	-,221	-1,563	,125	-,567	,072
	physique	-,283	,174	-,262	-1,623	,112	-,634	,069
	chimie	,189	,190	,187	,994	,326	-,194	,571
	histoire	,169	,118	,216	1,430	,160	-,069	,407
	mathématiques	,405	,153	,384	2,645	,011	,096	,715
	philosophie	,210	,151	,187	1,390	,172	-,095	,514
	allemand	,286	,138	,360	2,068	,045	,007	,566

Test de la corrélation multiple

On peut également construire un **test sur la corrélation multiple**. Ce résultat se trouve dans le **tableau ANOVA** :

ANOVA ^a					
	Somme des carrés	ddl	Carré moyen	F	Sig.
Régression	80,623	7	11,518	5,382	,000 ^b
Résiduel	89,877	42	2,140		
Total	170,500	49			

a. Variable dépendante : géographie

b. Prédicteurs : (Constante), allemand, philosophie, mathématiques, français, histoire, physique, chimie

On y trouve :

- La **somme de carrés totale** $= n \cdot \text{var}(\mathbf{y})$
- La **somme de carrés de régression** $= n \cdot \text{var}(\mathbf{y}^*)$
- La **somme de carrés de résiduelle** $= n \cdot \text{var}(\mathbf{e})$
- Les **degrés de liberté** p (expliqué), $n - p - 1$ (résiduel) et $n - 1$ (total).

Le **test** $H_0 : R^{\text{theo}} = 0$ vs $H_1 : R^{\text{theo}} \neq 0$ se fait avec la statistique :



$$F := \frac{\frac{n \cdot \text{var}(\mathbf{y}^*)}{p}}{\frac{n \cdot \text{var}(\mathbf{e})}{n - p - 1}} \stackrel{?}{>} F[p, n - p - 1]$$

Le modèle théorique s'appuie néanmoins sur **3 hypothèses** qu'il faudra vérifier :

- **Linéarité** : il y a bien une relation linéaire entre le critère et les prédicteurs.
- **Normalité** : les erreurs sont distribuée selon une loi Normale.
- **Homoscédasticité** : la variance des erreurs est constante.

Tester les hypothèses de travail





Ces tests s'effectuent d'une manière visuelle avec le **diagramme des résidus** : il s'agit des points (y_i^*, e_i) :



Comme, par construction, $\text{corr}(\mathbf{e}, \mathbf{y}^*) = 0$, les résidus sont toujours répartis autour de 0.


Tester les hypothèses de travail

La vérification se fait de manière visuelle :



Tester les hypothèses de travail : exemple

Dans notre exemple, les hypothèses semblent se tenir



Si ce n'était pas le cas, une solution pourrait être d'effectuer des changements de variables : $\tilde{\mathbf{y}} = f_y(\mathbf{y}), \tilde{\mathbf{x}}_1 = f_1(\mathbf{x}_1), \dots, \tilde{\mathbf{x}}_p = f_p(\mathbf{x}_p)$

La colinéarité des prédicteurs et facteur d'inflation

Si les prédicteurs sont fortement corrélés entre eux, on parle de **colinéarité**.

Les hypothèses de travail ne sont pas violées, mais cela peut poser des **problèmes d'interprétation des coefficients**.

On peut calculer :

R_k^2 := « la proportion de variance du prédicteur x_k expliquée par les autres prédicteurs »

et deux quantités dérivées :

- La **tolérance** : $TOL_k := 1 - R_k^2$
- Le **facteur d'inflation de variance** : $VIF_k := \frac{1}{TOL_k}$

Si $VIF_k > 5$, le **prédicteur k est fortement expliqué par les autres**.

La colinéarité des prédicteurs et facteur d'inflation : exemple

Coefficients non standardisés				Coefficients standardisés		Intervalle de confiance à 95,0% pour B		Statistiques de colinéarité		
Modèle	B	Erreur standard	Bêta	t	Sig.	Borne inférieure	Borne supérieure	Tolérance	VIF	
1	(Constante)	1,239	1,080		1,147	,258	-,941	3,419		
	français	-,247	,158	-,221	-1,563	,125	-,567	,072	,627	1,594
	physique	-,283	,174	-,262	-1,623	,112	-,634	,069	,480	2,084
	chimie	,189	,190	,187	,994	,326	-,194	,571	,356	2,808
	histoire	,169	,118	,216	1,430	,160	-,069	,407	,549	1,822
	mathématiques	,405	,153	,384	2,645	,011	,096	,715	,596	1,678
	philosophie	,210	,151	,187	1,390	,172	-,095	,514	,693	1,442
	allemand	,286	,138	,360	2,068	,045	,007	,566	,415	2,410

Ici, le facteur d'inflation de la variance est deux fois plus grand pour **chimie** ($VIF_{chimie} = 2.81$) que pour **philosophie** ($VIF_{philosophie} = 1.44$) : **chimie** est plus corrélé avec les autres prédicteurs que ne l'est **philosophie**.

Cela veut dire que l'explication de la note de **chimie** est un peu « distillée » dans toutes les autres matières. Ce ne sera pas forcément un prédicteur important à garder pour expliquer la note de **géographie** si on garde les autres prédicteurs (nous le verrons plus tard).

Si l'on a le choix entre plusieurs modèles de régression, comment opter pour le « meilleur » :

- On peut retenir celui qui **maximise le R-carré ajusté $\hat{R}^2$** .
- Si on veut supprimer un seul prédicteur, on **supprimera celui avec la plus grande p-valeur** (ou le plus petit β_k).
- Si l'on veut garder un seul prédicteur, on **gardera celui avec la plus grande corrélation avec le critère $\text{corr}(\mathbf{x}_k, \mathbf{y})$** .

Une procédure standard peut-être :

1. Faire le modèle avec tous les prédicteurs.
2. Supprimer celui avec la plus grande p-valeur. Recommencer en 2.
3. Garder le modèle une fois que tous le prédicteurs sont significatifs ou si $\hat{R}^2$ n'augmente plus.

Sélections de modèles : exemple

		Coefficients non standardisés		Coefficients standardisés				Intervalle de confiance à 95,0% pour B		Statistiques de colinéarité	
Modèle		B	Erreur standard	Bêta	t	Sig.	Borne inférieure	Borne supérieure	Tolérance	VIF	
1	(Constante)	1,239	1,080		1,147	,258	-,941	3,419			
	français	-,247	,158	-,221	-1,563	,125	-,567	,072	,627	1,594	
	physique	-,283	,174	-,262	-1,623	,112	-,634	,069	,480	2,084	
	chimie	,189	,190	,187	,994	,326	-,194	,571	,356	2,808	
	histoire	,169	,118	,216	1,430	,160	-,069	,407	,549	1,822	
	mathématiques	,405	,153	,384	2,645	,011	,096	,715	,596	1,678	
	philosophie	,210	,151	,187	1,390	,172	-,095	,514	,693	1,442	
	allemand	,286	,138	,360	2,068	,045	,007	,566	,415	2,410	

Corrélations

	français	géographie	physique	chimie	histoire	maths	philosophie	allemand
français	1	,230	,222	,387	,373	,379	,401	,378
géographie	,230	1	,328	,533	,465	,492	,226	,497
physique	,222	,328	1	,670	,472	,512	,129	,533
chimie	,387	,533	,670	1	,563	,555	,234	,637
histoire	,373	,465	,472	,563	1	,263	,198	,589
maths	,379	,492	,512	,555	,263	1	,251	,330
philosophie	,401	,226	,129	,234	,198	,251	1	-,060
allemand	,378	,497	,533	,637	,589	,330	-,060	1

Curieusement, s'il ne fallait enlever qu'un prédicteur, ce serait **chimie**, et s'il fallait n'en garder qu'un, ce serait **chimie** également.

Comme nous l'avons vu, les performances en chimie peuvent être expliquées par les autres matières. **C'est un bon indicateur de performance générale, mais utiliser plusieurs autres prédicteurs plus fins permet de meilleures prédictions.**

Démo R