

Méthodes Quantitatives III :

5. L'analyse en composantes principales

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 54 - 68

Exercices : toute la série 4

Principe général

Objectifs de l'ACP

Soit un jeu de données avec **p variables quantitatives** $x_1, \dots, x_p$.

Fréquemment, ces variables sont **corrélées** entre elles, c'est-à-dire que l'information exprimée dans **le jeu de données possède un certain degré de redondance**.

Exemple : Soit un jeu de données « USArrests » sur les crimes violents par états aux États-Unis en 1973 :

	Name	Murder	Assault	UrbanPop	Rape
1	Alabama	13.2	236	58	21.2
2	Alaska	10.0	263	48	44.5
3	Arizona	8.1	294	80	31.0
4	Arkansas	8.8	190	50	19.5
5	California	9.0	276	91	40.6
6	Colorado	7.9	204	78	38.7
7	Connecticut	3.3	110	77	11.1
8	Delaware	5.9	238	72	15.8
9	Florida	15.4	335	80	31.9
10	Georgia	17.4	211	60	25.8

Objectifs de l'ACP

Cette redondance permet de **compresser l'information** contenue dans les p variables.

L'**analyse en composante principale (ACP)** se donne comme but de trouver $k < p$ nouvelles variables, appelées **facteurs**, qui

- Sont **non-corrélées** entre elles.
- Contiennent le **maximum d'information possible** du jeu de données initial.

Un des résultats intéressants de l'ACP est de poser $k = 2$ et de **représenter au mieux notre jeu de données sous forme de graphique**.

Principes de l'ACP

L'**Analyse en composante principale (ACP)** est une procédure multivariée qui consiste à :

- 1.a Transformer p variables corrélées $\mathbf{x}_1, \dots, \mathbf{x}_p$ en p nouvelles variables **non-corrélées** $\mathbf{f}_1, \dots, \mathbf{f}_p$, appelées **facteurs**.
- 1.b **Concentrer l'information des variables initiales sur les premiers facteurs**. Elle se présentera alors de manière **décroissante** dans les facteurs.
- 2 Conserver les $k < p$ premiers facteurs, afin de **compresser l'information**.
- 3 **Interpréter les facteurs**.

L'opération 1. (a et b) est automatique et se base sur la **décomposition spectrale**.

La conservation des $k < p$ premiers facteurs relève du **choix de l'utilisateur**, mais qui peut se baser sur certains critères.




L'interprétation des facteurs repose principalement sur la connaissance des données et reste assez libre. On peut s'appuyer sur 2 quantités :

- Les **scores factoriels**, c'est-à-dire les scores des individus sur chacun des facteurs $\mathbf{f}_1, \dots, \mathbf{f}_p$.
- Les **saturation**s, c'est-à-dire les corrélations entre variables et facteurs, i.e. $\text{corr}(\mathbf{x}_j, \mathbf{f}_\alpha)$.

Notations :

- Les individus sont indicés par $i = 1, \dots, n$
- Les variables sont indicées par $j = 1, \dots, p$
- Les facteurs sont indicés par $\alpha = 1, \dots, k \leq p$

Exemples de sorties



Problème et solution


L'ACP sur les covariances et sur les corrélations

L'ACP nécessite que l'on parte de **données centrées**. Deux cas de figures possibles :

- Les données ne sont **pas réduites**, on parle alors d'**ACP sur la matrice de variance-covariance**.
- Les données sont **réduites** (donc standardisées), on parle alors d'**ACP sur la matrice de corrélation**.

L'ACP sur la matrice de corrélation est le cas le plus largement répandu, mais il s'agit d'un **cas particulier** de l'ACP sur la matrice de variance-covariance, c'est pourquoi nous allons voir en premier lieu le cas général.

Supposons un **jeu de données centré** $\mathbf{X}^c$ de taille $n \times p$. Si les variables sont corrélées et que l'on regarde l'espace des individus, on aura un nuage de points de la sorte




où chaque point est un vecteur-ligne $\mathbf{v}_i^c$ de $\mathbf{X}^c$.

Trouver les facteurs : premier axe


Si l'on devait résumer ces individus avec **une seule variable qui conserve un maximum l'information** comment pourrait-on la construire ?

Solution : on choisit l'axe où il y a la **variance maximale**, car avoir un maximum de variance permet de **facilement différencier les individus** (maximum d'information).



Trouver les facteurs : deuxième axe


Dans un deuxième temps, on construit un autre axe, **orthogonal au premier**, contenant le **maximum de variance résiduelle**.



Et ainsi de suite...

Trouver les facteurs : résultat recherché

Le résultat est un nombre p de **facteurs**, représentant l'information d'une manière décroissante.





Trouver les facteurs : formulation dans l'espace des individus

Le but est donc de trouver une **application linéaire A**, qui, appliquée aux vecteur-lignes $\mathbf{v}_i$ avec :

$$\mathbf{A}\mathbf{v}_i = \mathbf{w}_i$$

donne de nouveau vecteurs-lignes $\mathbf{w}_i$ dont les coordonnées sont non-corrélées et présentent une variance décroissante.



Trouver les facteurs : formulation dans l'espace des variables

Matriciellement, la transformation s'écrit :

$$\mathbf{A}(\mathbf{X}^c)' = \mathbf{F}' \quad \text{où} \quad \mathbf{X}^c = \begin{pmatrix} - & \mathbf{v}_1 & - \\ & \vdots & \\ - & \mathbf{v}_n & - \end{pmatrix} \quad \text{et} \quad \mathbf{F} = \begin{pmatrix} - & \mathbf{w}_1 & - \\ & \vdots & \\ - & \mathbf{w}_n & - \end{pmatrix}$$

Si on écrit cela en termes de **variables** et **facteurs**, cela donne

$$\mathbf{X}^c \mathbf{A}' = \mathbf{F} \quad \text{où} \quad \mathbf{X}^c = \begin{pmatrix} | & & | \\ \mathbf{x}_1 & \cdots & \mathbf{x}_p \\ | & & | \end{pmatrix} \quad \text{et} \quad \mathbf{F} = \begin{pmatrix} | & & | \\ \mathbf{f}_1 & \cdots & \mathbf{f}_p \\ | & & | \end{pmatrix}$$

Trouver les facteurs : matrice de covariance résultante

Si l'on calcule la **matrice de covariance** du nouveau jeu de données, Σ_F , on a

$$\begin{aligned}\Sigma_F &= \frac{1}{n} \mathbf{F}' \mathbf{F} = \frac{1}{n} (\mathbf{X}^c \mathbf{A}')' (\mathbf{X}^c \mathbf{A}') \\ &= \frac{1}{n} \mathbf{A} (\mathbf{X}^c)' (\mathbf{X}^c) \mathbf{A}' = \mathbf{A} \frac{1}{n} (\mathbf{X}^c)' (\mathbf{X}^c) \mathbf{A}' \\ &= \mathbf{A} \Sigma_X \mathbf{A}'\end{aligned}$$

où Σ_X est la matrice de covariance du jeu de donnée initial.

Le but est donc trouver $\mathbf{A}$, tel que $\Sigma_F = \mathbf{A} \Sigma_X \mathbf{A}'$ soit diagonale avec des variances décroissantes sur sa diagonale.

Trouver les facteurs : décomposition de la matrice de covariance initiale

La matrice Σ_X est **symétrique**, le **théorème spectral** nous dit donc que Σ_X peut s'écrire comme

$$\Sigma_X = U \Lambda U'$$

Avec U une **matrice orthogonale** ($UU' = I$) et Λ une **matrice diagonale avec les vecteurs propres classés par ordre décroissant sur la diagonale** (cette décomposition est unique).

De plus, on sait que Σ_X est **semi-définie positive**, c'est-à-dire que ses valeurs propres sont toutes plus grandes ou égales à zéro, i.e. $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$.

Trouver les facteurs : solution

En posant $\mathbf{A}' = \mathbf{U}$, on a :

$$\Sigma_F = \mathbf{A}\Sigma_X\mathbf{A}' = \mathbf{A}\mathbf{U}\mathbf{\Lambda}\mathbf{U}'\mathbf{A}' = \mathbf{U}'\mathbf{U}\mathbf{\Lambda}\mathbf{U}'\mathbf{U} = \mathbf{\Lambda}$$

C'est-à-dire que :

$$\text{cov}(\mathbf{f}_\alpha, \mathbf{f}_\beta) = 0 \quad \text{pour} \quad \alpha \neq \beta$$

$$\text{var}(\mathbf{f}_1) = \lambda_1 \geq \text{var}(\mathbf{f}_2) = \lambda_2 \geq \dots \geq \text{var}(\mathbf{f}_p) = \lambda_p \geq 0$$


Les colonnes $\mathbf{f}_1, \dots, \mathbf{f}_p$ de $\mathbf{F}$ ne seront pas corrélées et leurs variances seront décroissantes.

Notre solution est donc :

$$\mathbf{F} = \mathbf{X}^c \mathbf{U}$$

L'ACP avec la matrices de corrélations

L'ACP en utilisant **uniquement des données centrées** peut donner certaines aberrations, principalement à cause de l'unité de mesure des variables.



En utilisant $\mathbf{X}^s$ à la place de $\mathbf{X}^c$, la décomposition spectrale se fera non plus sur la matrice de covariance, mais sur la **matrice de corrélation**

$$\Sigma_{\mathbf{X}} = \frac{1}{n}(\mathbf{X}^c)'(\mathbf{X}^c) \quad \longrightarrow \quad \mathbf{R} = \frac{1}{n}(\mathbf{X}^s)'(\mathbf{X}^s)$$

Les facteurs s'obtiennent alors avec :

$$\mathbf{F} = \mathbf{X}^s \mathbf{U}$$

L'ACP

ACP : les facteurs

Soit une matrice de données standardisées $\mathbf{X}^s$ et sa matrice de corrélation correspondante $\mathbf{R}$:

$$\mathbf{R} = \frac{1}{n}(\mathbf{X}^s)'(\mathbf{X}^s)$$

La **matrice des facteurs**, notée $\mathbf{F}$, s'obtient avec

$$\mathbf{F} = \mathbf{X}^s \mathbf{U} \quad \text{ou} \quad f_{i\alpha} = \sum_{j=1}^p x_{ij}^s u_{j\alpha}$$

où $\mathbf{U}$ est le résultat de la **décomposition spectrale** de la matrice de corrélation $\mathbf{R}$. i.e.


$$\mathbf{R} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}'$$

Par construction, les scores factoriels sont **centrés** et **non-corrélés** :

$$\overline{\mathbf{f}}_{\alpha} = 0, \quad \text{corr}(\mathbf{f}_{\alpha}, \mathbf{f}_{\beta}) = 0 \quad \text{si} \quad \alpha \neq \beta$$

Les facteurs : exemple

Dans notre exemple, les facteurs f_1 et f_2 permettent de représenter la **carte factorielle** des états :



La proportion de variance expliquée

Remarquons que la **trace** (somme de la diagonale) d'une matrice est invariante à toute opération du type $\mathbf{A}^{-1}\mathbf{X}\mathbf{A}$, on a donc $\text{tr}(\mathbf{X}^s) = \text{tr}(\mathbf{R}) = \text{tr}(\mathbf{\Lambda})$ et

$$p = \sum_{j=1}^p \text{var}(\mathbf{x}_j^s) = \sum_{\alpha=1}^p \text{var}(\mathbf{f}_{\alpha}) = \sum_{\alpha=1}^p \lambda_{\alpha}$$

ACP-covariance : la variance

Sur les variables initiales et les facteurs, le **total de variance est identique** :

$$\sum_{j=1}^p \text{var}(\mathbf{x}_j^s) = \sum_{\alpha=1}^p \text{var}(\mathbf{f}_{\alpha}) = p$$

De plus on a :


$$\text{var}(\mathbf{f}_{\alpha}) = \lambda_{\alpha}$$

La **proportion de variance expliquée par le facteur α** s'exprime donc avec :

$$\text{propvar}_{\alpha} := \frac{\lambda_{\alpha}}{p}.$$

Le scree graph

On peut représenter ces proportions de variance avec le **diagramme des valeurs propres** ou **scree graph**. Dans notre exemple, les proportions de variance sur les 4 facteurs sont respectivement de 62.0%, 24.7%, 8.9% et 4.4%



Le nombre de facteurs à retenir

Les proportions des variances peuvent nous aider à **choisir le nombre facteurs à retenir**. Plusieurs critères existent :

- S'arrêter quand la variance expliquée cumulée atteint un certain seuil, e.g. 90% (critère de Joliffe).
- Ne garder que les valeurs propres supérieures à la moyenne $\frac{1}{p}(\lambda_1 + \dots + \lambda_p) = 1$ (critère de Kaiser).
- Chercher un « coude » (changement de régime) sur le scree graph (« critère de Cattell »).
- Faire un test sur les valeurs propres restantes pour voir si elles sont toutes égales, i.e. $H_0^k : \lambda_{k+1} = \lambda_{k+2} = \dots = \lambda_p$.


Le test de Barlette

Ce dernier critère appliqué à **toutes valeurs propres**, i.e. tester :

$$H_0 : \lambda_1 = \lambda_2 = \dots = \lambda_p$$

s'appelle le **test de sphéricité** ou **test de Barlette**. Rejeter H_0 permet de valider la pertinence de notre ACP.

Exemple de nuage de points « inadéquat » pour l'ACP :



Définition

La **saturation** entre la variable x_j et le facteur f_α , notée $s_{j\alpha}$ est la **corrélation entre ces deux variables**, i.e

$$s_{j\alpha} = \text{corr}(x_j, f_\alpha)$$

Elle s'obtient grâce à la formule suivante :

$$s_{j\alpha} = \sqrt{\lambda_\alpha} u_{j\alpha} \quad \text{ou} \quad \mathbf{S} = \mathbf{U} \sqrt{\Lambda}$$

De plus, $s_{j\alpha}^2$ exprime la **proportion de variance de la variable j expliquée par le facteur α** .

Les saturations vérifient les propriétés suivantes :

1. $\sum_{j=1}^p s_{j\alpha}^2 = \lambda_\alpha$
2. $\sum_{\alpha=1}^p s_{j\alpha}^2 = 1$
3. $\sum_{\alpha=1}^p s_{j\alpha} s_{k\alpha} = r_{jk}$

Grâce au point 2, on voit que le vecteur $\mathbf{s}_j = (s_{j1}, \dots, s_{jp})'$ est sur une **hypersphère de rayon 1**.


Le cercle des corrélations

Dans l'exemple, les saturations et leur carrés sur les 4 facteurs sont

$s_{j\alpha}$	fact 1	fact 2	fact 3	fact 4
Murder	0.84	-0.42	0.20	0.27
Assault	0.92	-0.19	0.16	-0.31
UrbanPop	0.44	0.87	0.23	0.06
Rape	0.86	0.17	-0.49	0.04



$s_{j\alpha}^2$	fact 1	fact 2	fact 3	fact 4
Murder	0.71	0.17	0.04	0.07
Assault	0.84	0.03	0.03	0.10
UrbanPop	0.19	0.75	0.05	0.00
Rape	0.73	0.03	0.24	0.00

En représentant les (s_{j1}, s_{j2}) , on a le **cercle des corrélations** :



Interprétation des facteurs

L'interprétation des scores factoriels et des facteurs se fait à l'aide de la carte factorielle et du cercle des corrélations, mais surtout à l'aide d'une bonne connaissance des données.



Ici, on pourrait interpréter f_1 comme la « criminalité générale » et f_2 comme l'« urbanité » des états.

Définition

Lorsque l'on ne retient que $k < p$ facteurs, la **communalité** de la variable x_j , notée h_j^2 est :

$$h_j^2 := \sum_{\alpha=1}^k s_{j\alpha}^2 \leq 1$$

Elle représente la **proportion de variance de x_j expliquée par ces k facteurs.**

Les communalités : exemple

Avec la tableau de nos saturations au carré :

$s_{j\alpha}^2$	fact 1	fact 2	fact 3	fact 4
Murder	0.71	0.17	0.04	0.07
Assault	0.84	0.03	0.03	0.10
UrbanPop	0.19	0.75	0.05	0.00
Rape	0.73	0.03	0.24	0.00

On peut voir que qu'avec $k = 2$ on a :

$$h_{\text{Murder}}^2 = 0.88 \quad h_{\text{Assault}}^2 = 0.87 \quad h_{\text{UrbanPop}}^2 = 0.94 \quad h_{\text{Rape}}^2 = 0.76$$

La variable la mieux représentée sur les deux premiers axes est « UrbanPop » avec 94% de variance expliquée, et la moins bien représentée est « Rape » avec 76% de variance expliquée.

En résumé, si l'on ne garde que $k < p$ facteurs :

- Un **individu i** est représenté par ses **scores factoriels**, $f_{i1}, \dots, f_{ik}$.
- Une **variable j** est représentée par ses **saturation**s, $s_{j1}, \dots, s_{jk}$.
- La **variance expliquée sur chaque facteur α** s'exprime avec $\frac{\lambda_\alpha}{p}$.
- la **proportion de variance de la variable j sur le facteur α** s'exprime avec $s_{j\alpha}^2$.
- La **proportion de variance expliquée de la variable j sur les k facteurs** est représentée par la **communalité** $h_j^2 = \sum_{\alpha=1}^k s_{j\alpha}^2$.

Parfois, on peut être amené à faire une **ACP sur la matrice des covariance**. Les changements sont les suivants :

- C'est la **matrice de covariance qui est décomposée**
$$\Sigma = \frac{1}{n}(\mathbf{X}^c)'(\mathbf{X}^c) = \mathbf{U}\mathbf{\Lambda}\mathbf{U}'$$
- Les **scores factoriels** s'obtiennent avec $\mathbf{F} = \mathbf{X}^c\mathbf{U}$.
- Les **saturation**s s'obtiennent avec $s_{j\alpha} = \frac{\sqrt{\lambda_\alpha}}{\sqrt{\text{var}(\mathbf{x}_j)}} u_{j\alpha}$.
- La **variance expliquée sur chaque facteur** α s'exprime avec $\frac{\lambda_\alpha}{\sum_{\alpha=1}^p \lambda_\alpha}$ et le **total de variance** est $\sum_{\alpha=1}^p \lambda_\alpha$.

ACP sur la matrice de covariance

