

Méthodes Quantitatives III :

7. Les dissimilarités

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 74 - 86

Exercices : 5.1, 5.4, 5.6

Introduction : variables et individus

Soit une matrice de données $\mathbf{X}$ ($n \times p$) suivante :

$$\mathbf{X} = (x_{ik}) = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

L'analyse peut se faire :

- Sur le p colonnes, qui sont les **variables**.
- Sur les n lignes, qui sont les **individus**.

Variables vs individus

Dans l'analyse centrées sur les **variables**, on cherche à étudier les **colonnes**, qui sont des vecteurs à n dimensions. On travaille dans l'**espace des variables** (ce qu'on a fait jusqu'à maintenant) :

$$\mathbf{X} = \left(\begin{array}{c|c|c|c} | & | & & | \\ \mathbf{x}_1 & \mathbf{x}_1 & \cdots & \mathbf{x}_p \\ | & | & & | \end{array} \right) = \left(\begin{array}{c|c|c|c} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{array} \right)$$

Par contraste, une analyse centrée sur les **individus**, ce sont les **lignes**, vecteurs à p dimensions, qui sont étudiées. On travaille dans l'**espace des individus** :

$$\mathbf{X} = \left(\begin{array}{ccc} - & \mathbf{x}'_1 & - \\ - & \mathbf{x}'_2 & - \\ & \vdots & \\ - & \mathbf{x}'_n & - \end{array} \right) = \left(\begin{array}{cccc} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{array} \right)$$

L'analyse centrée sur les **variables** cherche à comprendre les **liens entre les variables**. Les individus sont utilisés uniquement comme différentes observations pour comprendre ces liens.

Exemple : une régression linéaire sur le prix d'un logement en fonction de la surface, nombre de pièces, âge du bâtiment et de l'emplacement.

L'analyse centrée sur les **individus** cherche au contraire à **caractériser ces individus**, c'est-à-dire trouver des ressemblances/contrastes et éventuellement former des groupes. Les variables ne servent qu'à quantifier ces ressemblances/contrastes.

Exemple : une classification des communes de Suisse en 4 ou 5 grands groupes socio-économiques distincts.

Les matrices de covariance et corrélation

Les analyses centrées sur les variables se basent fréquemment sur les matrices de **covariance** ou de **corrélation**, de dimension $p \times p$.

$$\left(\begin{array}{c|c|c|c} | & | & & | \\ \mathbf{x}_1 & \mathbf{x}_1 & \cdots & \mathbf{x}_p \\ | & | & & | \end{array} \right) \longrightarrow \left(\begin{array}{cccc} \text{var}(\mathbf{x}_1) & \text{cov}(\mathbf{x}_1, \mathbf{x}_2) & \cdots & \text{cov}(\mathbf{x}_1, \mathbf{x}_p) \\ \text{cov}(\mathbf{x}_2, \mathbf{x}_1) & \text{var}(\mathbf{x}_2) & \cdots & \text{cov}(\mathbf{x}_2, \mathbf{x}_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(\mathbf{x}_p, \mathbf{x}_1) & \text{cov}(\mathbf{x}_p, \mathbf{x}_2) & \cdots & \text{var}(\mathbf{x}_p) \end{array} \right)$$

Ces dernières servent à caractériser les ressemblances/contrastes entre variables.

L'analyse centrée sur les individus est basée sur la **quantification de la différence** entre les profils des n lignes.

Définition

Soit n individus. Une mesure de **dissimilarité** d_{ij} entre i et j est une quantité :

- **Symétrique** : $d_{ij} = d_{ji}$
- **Non-négative** : $d_{ij} \geq 0$
- **Nulle entre un individu et lui-même** : $d_{ii} = 0$

L'ensemble des paires de dissimilarités forme une matrice $n \times n$

$$\mathbf{D} = (d_{ij}) = \begin{pmatrix} d_{11} & d_{12} & \cdots & d_{1n} \\ d_{21} & d_{22} & \cdots & d_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ d_{n1} & d_{n2} & \cdots & d_{nn} \end{pmatrix}$$

qui est symétrique, non-négative et de diagonale nulle.

Les dissimilarités

Soient deux lignes $\mathbf{x}'_i$ et $\mathbf{x}'_j$, de taille p , comment définir une dissimilarité associée :

$$d_{ij} = d(\mathbf{x}_i, \mathbf{x}_j)$$
$$\begin{pmatrix} - & \mathbf{x}'_1 & - \\ - & \mathbf{x}'_2 & - \\ & \vdots & \\ - & \mathbf{x}'_n & - \end{pmatrix} \xrightarrow{?} \begin{pmatrix} d_{11} & d_{12} & \cdots & d_{1n} \\ d_{21} & d_{22} & \cdots & d_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ d_{n1} & d_{n2} & \cdots & d_{nn} \end{pmatrix}$$

La principale responsabilité de l'analyste de données dans ce cadre est de **choisir une mesure judicieuse de dissimilarité entre les individus**.

Les dissimilarités


Définition

Soient des individus $\mathbf{x}_1, \dots, \mathbf{x}_n$. La dissimilarité de **type L_2** , ou dissimilarité **euclidienne** est définie par :

$$d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|_2 := \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2}$$

C'est la plus « intuitive » des dissimilarités, elle correspond à la distance usuelle.

La dissimilarité L_2 ou euclidienne : courbes équidistantes




Définition

Soient des individus $\mathbf{x}_1, \dots, \mathbf{x}_n$. La dissimilarité de **type L_2^2** , ou dissimilarité **euclidienne carrée** est définie par :

$$d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|_2^2 := \sum_{k=1}^p (x_{ik} - x_{jk})^2$$

- Bien que cette dissimilarité ressemble à la dissimilarité euclidienne classique, elle n'a pas tout à fait les mêmes propriétés.
- Ce type de dissimilarité est utilisée dans de nombreuses méthodes statistiques.

La dissimilarité L_2^2 ou euclidienne carrée : courbes équidistantes




Définition

Soient des individus $\mathbf{x}_1, \dots, \mathbf{x}_n$. La dissimilarité de **type L_1** , ou dissimilarité **de bloc** ou **de Manhattan** est définie par :

$$d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|_1 := \sum_{k=1}^p |x_{ik} - x_{jk}|$$

- Cette dissimilarité prend son nom du fait que c'est la distance que l'on parcourt en se déplaçant dans une ville « à blocs » (comme à Manhattan).
- L'utilisation de cette dissimilarité dans des méthodes statistiques donne généralement des résultats plus « robustes », c'est-à-dire moins sensible aux valeurs extrêmes.

La dissimilarité L_1 : courbes équidistantes




Définition

Soient des individus $\mathbf{x}_1, \dots, \mathbf{x}_n$. La dissimilarité de **type L_∞** , ou dissimilarité **de Chebychev** est définie par :

$$d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|_\infty := \max_{k=1}^p |x_{ik} - x_{jk}|$$

On le verra plus tard, mais ce type de dissimilarité couvre exactement celle des **dissimilarités métriques** (voir définition plus loin).

La dissimilarité L_∞ : courbes équidistantes



Définition


Soient des individus $\mathbf{x}_1, \dots, \mathbf{x}_n$. La dissimilarité de **type L_q** , ($q \geq 1$), ou dissimilarité **de Minkowski(q)** est définie par :

$$d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|_q := \left(\sum_{k=1}^p |x_{ik} - x_{jk}|^q \right)^{\frac{1}{q}}$$

Cette dissimilarité généralise les dissimilarités de types L_1 , L_2 et L_∞ .

La dissimilarité L_q : courbes équidistantes

Exemple : $L_{1.5}$ et L_4



Définition


Soient des individus $\mathbf{x}_1, \dots, \mathbf{x}_n$. La dissimilarité de **type** $L_q^{q/r}$, ($q, r \geq 1$), ou dissimilarité **générale**(q, r) est définie par :

$$d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|_q^{q/r} := \left(\sum_{k=1}^p |x_{ik} - x_{jk}|^q \right)^{\frac{1}{r}}$$

Cette dissimilarité généralise toutes celles vues précédemment.

La dissimilarité $L_q^{q/r}$: courbes équidistantes

Exemple : $L_4^{4/6}$ et $L_4^{4/2}$



Les dissimilarités : exemple

Soient n élèves caractérisés par leurs 3 scores $\mathbf{x}_i = (x_{i1}, x_{i2}, x_{i3})$ avec :

- x_{i1} = « note de mathématique »
- x_{i2} = « note de physique »
- x_{i3} = « note d'anglais »

Le profile de deux élèves i et j est $\mathbf{x}_i = (5, 2, 3)$ et $\mathbf{x}_j = (6, 3, 1)$:

- La dissimilarité euclidienne carrée est :
 $(5 - 6)^2 + (2 - 3)^2 + (3 - 1)^2 = 6$
- La dissimilarité euclidienne est : $\sqrt{6} = 2.45$
- La dissimilarité de bloc est : $|5 - 6| + |2 - 3| + |3 - 1| = 4$
- La dissimilarité de Minkowski(10) est : $\sqrt[10]{1^{10} + 1^{10} + 2^{10}} = 2.0004$
- La dissimilarité de Chebychev est : $\max(1, 1, 2) = 2$

Standardisation des profils

Dans la grande majorité des cas, les profils sont d'abord **standardisés**, i.e. centrés-réduits :

$$x_{ik} \longrightarrow x_{ik}^s = \frac{x_{ik} - \hat{\mu}_k}{\hat{\sigma}_k}$$

avant de calculer les dissimilarités, qui ne **dépendent alors plus de l'échelle numérique utilisée**.

La standardisation est obligatoire avec par exemple des modèles automobiles dont les profils contiendraient « nombre de cylindres », « vitesse de pointe [km/h] », « prix [chf] ». Sans standardisation, les dissimilarités dépendraient fortement des variables avec la plus grande variance.

Dans l'exemple des notes scolaires :

- La non standardisation est défendable (mêmes unités) ; la contribution de chaque branche dans les dissimilarités est d'autant plus forte que la variance de la branche est importante.
- Par contre, dans la version standardisée, également défendable, la contribution de chaque branche est identique.

En revanche, dans l'exemple des notes, on peut argumenter que comme la note de mathématique et la note de physique risquent d'être fortement corrélées, on **attribue plus de poids à une caractéristique redondante**.

On pourrait construire une dissimilarité qui porte sur les **scores factoriels standardisés** $f_{i\alpha}^s$ issus de la décomposition de la matrice de covariance Σ (par construction non corrélés).

Définition

Soient des individus $\mathbf{x}_1, \dots, \mathbf{x}_n$. Le **carré de la dissimilarité de Mahalanobis** est définie par :

$$d_{ij}^2 := \sum_{\alpha=1}^p (f_{i\alpha}^s - f_{j\alpha}^s)^2 = (\mathbf{x}_i - \mathbf{x}_j)' \Sigma^{-1} (\mathbf{x}_i - \mathbf{x}_j)$$

où $f_{i\alpha}^s$ sont les **scores factoriels standardisés** issus de la décomposition de la matrice de covariance Σ .

Cette dissimilarité « soustrait » les corrélations entre les variables par rapport à la distance euclidienne.

Dissimilarité de Mahalanobis : exemple

Avec nos trois notes, on trouve la matrice de covariance et son inverse :

$$\Sigma = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 4 & 0 \\ 0 & 0 & 3 \end{pmatrix} \quad \Sigma^{-1} = \begin{pmatrix} \frac{4}{7} & -\frac{1}{7} & 0 \\ -\frac{1}{7} & \frac{2}{7} & 0 \\ 0 & 0 & \frac{1}{3} \end{pmatrix}$$

La **dissimilarité euclidienne standardisée** entre $\mathbf{x}_i = (5, 2, 3)$ et $\mathbf{x}_j = (6, 3, 1)$ est :

$$d_{ij} = \sqrt{\frac{(5-6)^2}{2} + \frac{(2-3)^2}{4} + \frac{(3-1)^2}{3}} = 1.44$$

En calculant $(\mathbf{x}_i - \mathbf{x}_j) = (-1, -1, 2)$, La **dissimilarité de Mahalanobis** est :

$$d_{ij} = \sqrt{(-1, -1, 2) \begin{pmatrix} \frac{4}{7} & -\frac{1}{7} & 0 \\ -\frac{1}{7} & \frac{2}{7} & 0 \\ 0 & 0 & \frac{1}{3} \end{pmatrix} \begin{pmatrix} -1 \\ -1 \\ 2 \end{pmatrix}} = \sqrt{\frac{3}{7} - \frac{1}{7} + \frac{4}{3}} = 1.38$$

Les dissimilarités métriques ou distances

Peut-on représenter les valeurs des trois dissimilarités d_{ij} , d_{ik} et d_{jk} associées à trois objets i , j et k comme les longueurs des trois côtés d'un triangle ?

La réponse est « oui » ssi la longueur de chaque côté n'excède pas la somme des deux autres. Une telle dissimilarité est dite **métrique** et on parle alors de **distance**.



Définition

Une dissimilarité d_{ij} est dite **métrique**, que l'on peut alors appeler **distance**, ssi elle vérifie aussi l'**inégalité triangulaire** :

$$d_{ij} \leq d_{ik} + d_{kj} \quad \text{pour tous } i, j, k$$

Les dissimilarités métriques ou distances

- Les dissimilarités de **Minkowski(q)** L_q , en particulier de Chebychev L_∞ , euclidiennes L_2 et de bloc L_1 , sont toutes **métriques**.
- Toutes dissimilarité métrique **correspond a une dissimilarité de Chebychev L_∞** (on peut trouver des coordonnées qui permettent de la calculer).
- En revanche, la dissimilarité euclidienne carrée **n'est pas métrique**.



Les dissimilarités ultramétriques


Définition

Une dissimilarité est dite **ultramétrique**, ssi elle vérifie l'**inégalité ultramétrique** :

$$d_{ij} \leq \max(d_{ik}, d_{jk}) \quad \text{pour tous } i, j, k$$

Une dissimilarité ultramétrique est **nécessairement métrique**.

Dans un monde où les dissimilarités sont ultramétriques, tous triplets d'objets sera représenté par un « triangle isocèle avec une petite base » (seul le triangle (c) représente une dissimilarité ultramétrique).



Dissimilarités entre objets divers

Pour l'instant, les distances que nous avons vues s'obtiennent **à partir de coordonnées de points dans l'espace**.

Cependant, d'autres **objets**, c'est-à-dire d'autres **abstractions mathématiques**, nous permettent de calculer des dissimilarités.

Nous allons en voir trois :

- Les graphes
- Les arbres
- Les dendrogrammes

Définitions

Un **graphe** $G = (V, E)$ est composé d'un ensemble de **noeuds** V et d'un ensemble d'**arêtes** E reliant certains noeuds entre eux.

Le graphe est **valué** ou **pondéré** si chaque arête possède une valeur $l(e) \geq 0$ que l'on peut interpréter comme sa longueur.



Les graphes : exemple

Réseau piéton de Lausanne. Source : Théophile Emmanouilidis.




G	
n: Number of nodes	27'219
m: Number of edges	31'482
l: Total length (km)	734

La distance du plus court chemin

Définitions

Sur un graphe, on peut définir la **distance du plus court chemin** d_{ij} comme la longueur minimale qu'il faut parcourir sur les arêtes pour aller de i à j (potentiellement pondéré par le poids des arêtes).

Comme son nom l'indique, cette distance est **métrique**. En revanche, c'est sa seule propriété (elle est en général ni euclidienne, ni euclidienne carrée), ce qui la rend difficile à utiliser.




Définition

Un **arbre** est un graphe :

1. Sans arête interne (= pas d'arête reliant un noeud à lui-même)
2. Simple (= pas d'arête multiple)
3. Non orienté (= les arêtes n'ont pas d'orientation)
4. Connexe (= il existe un chemin reliant toutes paires de noeud du graphe)
5. Sans boucle (= il n'existe pas de chemin circulaire)

Les arbres : exemples



Source : <https://yulab-smu.top/treedata-book/chapter4.html>

Définition

Une dissimilarité d_{ij} entre n objets est une **dissimilarité d'arbre** ssi il existe un arbre valué (à $N \geq n$ noeuds) dans lequel chaque objet i est représentable par un noeud i , et tel que $d_{ij} = \delta_{ij}$, où δ_{ij} est la **distance sur l'arbre**, c'est-à-dire la **longueur de l'unique chemin** reliant i à j .

Théorème

La dissimilarité d_{ij} est une dissimilarité d'arbre ssi, pour chaque quadruple d'objets (i, j, k, l) distincts ou non, l'**inégalité des quatre points**, i.e.

$$d_{ij} + d_{kl} \leq \max(d_{ik} + d_{jl}, d_{il} + d_{jk})$$


est vérifiée.

Avec l'inégalité des quatre points, on voit que **toute dissimilarité d'arbre est métrique** (on retrouve l'inégalité triangulaire si deux indices coïncident).

Toute **dissimilarité ultramétrique est une dissimilarité d'arbre**.

La dissimilarité d'arbre : exemple

Arbre à $N = 7$ noeuds représentant une dissimilarité d'arbre entre $n = 6$ objets. Le noeud supplémentaire étant adjacent à a , b et c :




avec la dissimilarité d'arbre

$$\mathbf{D} = \begin{pmatrix} & a & b & c & d & e & f \\ a & 0 & 2 & 2 & 3 & 4 & 5 \\ b & 2 & 0 & 2 & 3 & 4 & 5 \\ c & 2 & 2 & 0 & 1 & 2 & 3 \\ d & 3 & 3 & 1 & 0 & 3 & 4 \\ e & 4 & 4 & 2 & 3 & 0 & 1 \\ f & 5 & 5 & 3 & 4 & 1 & 0 \end{pmatrix}$$


Définition

Un **dendrogramme** constitue une représentation hiérarchique d'une **partition** de n objets en m groupes. L'axe vertical h est la **hauteur** du dendrogramme et permet de définir la **granularité** de la partition (i.e., le nombre de groupes m).



Les dendrogrammes : dissimilarités

Sur un dendrogramme, on peut définir une **dissimilarité d_{ij}** entre deux objets i et j comme la **hauteur h à laquelle les branches issues de i et j se rencontrent**.




$$D = \begin{pmatrix} & a & b & c & d & e & f \\ a & 0 & 1 & 2 & 2 & 3 & 4 \\ b & 1 & 0 & 2 & 2 & 3 & 4 \\ c & 2 & 2 & 0 & 1 & 3 & 4 \\ d & 2 & 2 & 1 & 0 & 3 & 4 \\ e & 3 & 3 & 3 & 3 & 0 & 4 \\ f & 4 & 4 & 4 & 4 & 4 & 0 \end{pmatrix}$$

Cette dissimilarité est **ultramétrique**. En fait, **toute dissimilarité ultramétrique peut être représentée sous la forme d'un dendrogramme**.

Dendrogrammes et arbres enracinés


La représentation en dendrogramme n'est pas si éloignée de la représentation par un arbre. En réalité, tout **arbre enraciné**, c'est-à-dire un arbre dans lequel on peut construire un **noeud équidistant à tous les autres noeuds (une racine)**, correspond à un dendrogramme.




Ainsi, **toute dissimilarité ultramétrique est une dissimilarité d'arbre**, mais l'inverse n'est vrai que si l'arbre est **enraciné**.

Dendrogrammes et arbres enracinés : exemple

La dissimilarité d'arbre suivante est-elle ultramétrique ?



Oui : en plaçant un nouveau noeud racine 0 comme indiqué en rouge, tous les noeuds sont à une distance 5 de ce dernier.



Résumé

- U les dissimilarités ultramétriques
- A les dissimilarités d'arbres
- L_1 les dissimilarités de bloc
- L_2 les dissimilarités euclidiennes
- L_2^2 les dissimilarités euclidiennes carrées
- L_∞ les dissimilarités métriques ou distances.

