

Méthodes Quantitatives III :

8. Dissimilarités (suite) et dissimilarités euclidiennes

Guillaume Guex guillaume.guex@unil.ch

Pages du polycopié : 86 - 98

Exercices : série 5 (tout), 6.1

Dissimilarités (suite)

Initialement, nous avons défini plusieurs dissimilarités à partir d'une matrice de données $\mathbf{X} = (x_{ji})$, de la manière suivante :

$$d_{ij} = f(\mathbf{x}_i - \mathbf{x}_j)$$

où $\mathbf{x}_i$ et $\mathbf{x}_j$ sont les profils des individus i et j .

Dans un deuxième temps, nous avons montré comment construire des dissimilarités à partir d'**autres objets** (graphes, arbres, dendrogrammes).

Il n'y a donc pas forcément de matrice de données $\mathbf{X}$ pré-existante à la matrice de dissimilarité $\mathbf{D}$.

Définition

Soit $\mathbf{D} = (d_{ij})$ une matrice $n \times n$ contenant de dissimilarités. On a :

- $\mathbf{D}$ est de **type** $L_q^{q/r}$ ssi il existe une matrice $\mathbf{X}$ de taille $n \times p$ telle que :

$$d_{ij} = \left(\sum_{k=1}^p |x_{ik} - x_{jk}|^q \right)^{\frac{1}{r}}$$

- $\mathbf{D}$ est **métrique**, appelée alors **distance**, ssi, pour tous (i, j, k) :

$$d_{ij} \leq d_{ik} + d_{kj}$$

- $\mathbf{D}$ est une dissimilarité d'**arbre** ssi, pour tous (i, j, k, l) :

$$d_{ij} + d_{kl} \leq \max(d_{ik} + d_{jl}, d_{il} + d_{jk})$$

- $\mathbf{D}$ est **ultramétrique** ssi, pour tous (i, j, k) :

$$d_{ij} \leq \max(d_{ik}, d_{jk})$$

Distance d'édition

On considère deux mots (chaînes de caractères ou *string*) de longueur égale ou non, tels que

$$s_i = \text{CHIENS} \quad \text{et} \quad s_j = \text{NICHE}$$

La **distance d'édition** est le **nombre minimal de transformations** qu'il faut pour effectuer pour transformer s_i en s_j au moyen des opérations élémentaires suivantes :


- substituer un caractère par un autre.
- insérer un caractère.
- supprimer un caractère.

Ici, $d(\text{CHIENS}, \text{NICHE}) = 5$.

C'est une **dissimilarité métrique**.

Distance géodésique

Soit les points sur une sphère :



La **distance géodésique** (la plus courte sur la sphère) se définit comme :

$$d_{ij} = R\theta_{ij}$$

où R est le rayon de la sphère et θ_{ij} l'angle en radians entre i et j , mesuré depuis le centre de la sphère.

On peut montrer que c'est une **distance** L_1 . Si $R \rightarrow \infty$, elle devient L_2 .

Individus définis par des variables catégorielles

Nous avons vu qu'une variable catégorielle $\mathbf{v}$ avec m modalités peut être **recodée avec $m - 1$ variables binaires**, $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_{m-1}$, contenant dans leurs composantes :

$$v_{ik} = \begin{cases} 1 & \text{si l'individu } i \text{ a la modalité } k \\ 0 & \text{sinon} \end{cases}$$

Exemple : $\mathbf{v} = \ll \text{Couleur des yeux} \gg$ avec modalités $\ll \text{brun} \gg$, $\ll \text{vert} \gg$, $\ll \text{bleu} \gg$, alors

$$\mathbf{v} = \begin{pmatrix} \ll \text{Bleu} \gg \\ \ll \text{Brun} \gg \\ \ll \text{Vert} \gg \\ \ll \text{Brun} \gg \end{pmatrix} \longrightarrow \mathbf{v}_1 = \begin{pmatrix} 0 \\ 1 \\ 0 \\ 1 \end{pmatrix}, \mathbf{v}_2 = \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \end{pmatrix}$$

avec $\mathbf{v}_1 := \ll \text{A les yeux bruns} \gg$ et $\mathbf{v}_2 := \ll \text{A les yeux verts} \gg$.

Construire des **dissimilarités** entre des individus définis uniquement par des variables catégorielles revient donc à définir des dissimilarité entre des individus avec **variables binaires**.

$$X = \begin{pmatrix} 1 & 0 & \cdots & 1 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 0 \end{pmatrix} \longrightarrow D$$

Co-occurrences, co-absences

Le profil $\mathbf{x}_i$ d'un individu n'est donc qu'un vecteur de taille p indiquant la présence ou l'absence de p caractéristiques, notées respectivement avec 1 et 0 :

$$\mathbf{x}'_1 = (1, 0, 1, 0, \dots, 0, 1)$$

$$\mathbf{x}'_2 = (0, 0, 1, 1, \dots, 1, 1)$$

$$\vdots$$

Si toutes ces caractéristiques ont la même importance, une dissimilarité entre deux individus i et j peut être construite à partir de quantités suivantes :

- $a_{ij} :=$ le **nombre de co-occurrences**.
- $b_{ij} :=$ le **nombre d'attributs présents chez i mais absents chez j** .
- $c_{ij} :=$ le **nombre d'attributs absents chez i mais présents chez j** .
- $d_{ij} :=$ le **nombre de co-absences**.

On a $a_{ij} + b_{ij} + c_{ij} + d_{ij} = p$.

Co-occurrences, co-absences : exemple

Soient deux profils avec $p = 15$ caractéristiques :

$$\mathbf{x}'_1 = (1, 0, 1, 0, 0, 1, 1, 0, 1, 0, 1, 0, 1, 1, 1)$$

$$\mathbf{x}'_2 = (0, 0, 1, 1, 1, 1, 1, 0, 1, 1, 0, 0, 0, 1, 0)$$

Alors on a :

- Le nombre de co-occurrences : $a_{12} = 5$
- Présences chez $\mathbf{x}_1$ et absences chez $\mathbf{x}_2$: $b_{12} = 4$
- Absences chez $\mathbf{x}_1$ et présences chez $\mathbf{x}_2$: $c_{12} = 3$
- Le nombre de co-absences : $d_{ij} = 3$

Il y a plusieurs manière de construire des dissimilarités avec ces quantités. Le choix de la dissimilarité va dépendre de :

- L'importance relative des co-occurrences par rapport aux co-absences.
- L'**empan** désiré de la dissimilarité (l'intervalle possible de ses valeurs).
- Le **type de dissimilarité** que l'on veut obtenir (L_∞ , L_2^2 , A , U , etc.).

Dissimilarité L_1 et L_2 entre les profils

Les choix les plus simples sont de considérer les variables comme des variables numériques et de calculer la dissimilarité L_1 ou L_2 .

Pour L_1 :

$$d_{ij}^1 = \|\mathbf{x}_i - \mathbf{x}_j\|_1 = \|\mathbf{x}_i - \mathbf{x}_j\|_2^2 = b_{ij} + c_{ij}$$

C'est le **nombre de traits qui distinguent i et j** , dont le maximum est p .

Pour L_2 :

$$d_{ij}^2 = \|\mathbf{x}_i - \mathbf{x}_j\|_2 = \sqrt{b_{ij} + c_{ij}}$$

dont la valeur maximale est $\sqrt{p}$.

Notons que la **proportion de traits distinguant i et j** , définie par d_{ij}^1/p prend comme valeur maximale 1.

Avec des scores binaires, il est courant de passer par des **similarités** avant de construire des dissimilarités.

Définition

Un **indice de similarité** s_{ij} défini entre deux individus i et j est une quantité qui doit vérifier :

- Symétrique : $s_{ij} = s_{ji}$
- Non-négative : $s_{ij} \geq 0$
- Avec diagonale 1 : $s_{ii} = 1$

Convertir une similarité en dissimilarité peut alors se faire tout simplement avec :

$$d_{ij} = 1 - s_{ij}$$

Définition

Soit n profils binaires. La **similarité d'appariement simple** est la similarité s_{ij} définie par :

$$s_{ij} = \frac{a_{ij} + d_{ij}}{a_{ij} + b_{ij} + c_{ij} + d_{ij}}$$

Son empan est $[0, 1]$.

Cette similarité correspond à la **proportion de caractéristiques identiques entre les individus**. Elle donne autant d'importance aux co-occurrences qu'aux co-absences.

Définition

Soit n profils binaires. La **similarité de Jaccard** est la similarité s_{ij} définie par :

$$s_{ij} = \frac{a_{ij}}{a_{ij} + b_{ij} + c_{ij}}$$

Son empan est $[0, 1]$.

Cette similarité correspond à la **proportion de co-occurrences parmi les caractéristiques présentes chez au moins l'un des deux individus**.

Elle donne **plus d'importance aux co-occurrences qu'aux co-absences**.

Sa dissimilarité associée est **métrique**.

Définition

Soit n profils binaires. La **similarité de Dice-Sørensen** est la similarité s_{ij} définie par :

$$s_{ij} = \frac{2a_{ij}}{2a_{ij} + b_{ij} + c_{ij}}$$

Son empan est $[0, 1]$.

Cette similarité donne **encore plus d'importance aux co-occurrences qu'aux co-absences**. Elle est utilisée en écologie et elle est souvent plus robuste que la similarité de Jaccard.

En revanche, sa dissimilarité associée n'est **pas métrique**.

Similarités et dissimilarités associées : exemple

Soient deux profils avec $p = 15$ caractéristiques :

$$\mathbf{x}'_1 = (1, 0, 1, 0, 0, 1, 1, 0, 1, 0, 1, 0, 1, 1, 1)$$

$$\mathbf{x}'_2 = (0, 0, 1, 1, 1, 1, 1, 0, 1, 1, 0, 0, 0, 1, 0)$$

On a $a_{12} = 5$, $b_{12} = 4$, $c_{12} = 3$, $d_{ij} = 3$.

- La similarité d'appariement simple est $s_{12} = \frac{5+3}{15} = 0.53$ et sa dissimilarité associée $d_{12} = 0.47$.
- La similarité de Jaccard est $s_{12} = \frac{5}{5+3+4} = 0.42$ et sa dissimilarité associée $d_{12} = 0.58$.
- La similarité de Dice-Sørensen est $s_{12} = \frac{2 \cdot 5}{2 \cdot 5 + 3 + 4} = 0.59$ et sa dissimilarité associée $d_{12} = 0.41$.

Individus définis par une distribution

Il nous arrive d'avoir des individus i définis par une **distribution** :

$$\mathbf{x}'_i = (f_1^i, f_2^i, \dots, f_p^i)$$

avec $f_k^i \geq 0$ et $\sum_{k=1}^p f_k^i = 1$.

Il s'agit souvent de données où les individus sont des **agrégats**. Les f_k^i rendent alors compte des proportions de p modalités exclusives dans cet agrégat.

Exemples :

- f_k^i = proportion d'occurrences du mot k dans le texte i .
- f_k^i = proportion d'employés du secteur k dans la région i .
- f_k^i = part de consommation de biens de type k par la classe socio-économique i .

La fréquence relative moyenne et quotients

Si l'on possède n profils de fréquences f_k^i sur k modalités, la **fréquence relative moyenne** de la modalité k est :

$$\rho_k := \frac{1}{n} \sum_{i=1}^n f_k^i$$

qui vérifie $\sum_{k=1}^p \rho_k = 1$.

De cette quantité, on peut calculer les **quotients** q_{ik} :

$$q_{ik} := \frac{f_k^i}{\rho_k}$$

Ces derniers indiquent :

- Une **sur-représentation** de k dans i si $q_{ik} > 1$.
- Une **sous-représentation** de k dans i si $q_{ik} < 1$.

Définition

Soient n profils de fréquences f_k^i sur p modalités. La **dissimilarité du chi2** entre i et j , notée D_{ij}^χ , se définit avec :

$$D_{ij}^\chi := \sum_{k=1}^p \rho_k (q_{ik} - q_{jk})^2 = \sum_{k=1}^p \frac{(f_k^i - f_k^j)^2}{\rho_k}$$

avec $\rho_k := \frac{1}{n} \sum_{i=1}^n f_k^i$ et $q_{ik} := \frac{f_k^i}{\rho_k}$.

Cette dissimilarité est de type L_2^2 .

Elle est à la base d'une méthode appelée l'**analyse des correspondances** (que nous verrons plus tard).

Fréquemment, il nous est donné une **table de contingence**

$\mathbf{N} = (n_{ik})$ où :

$n_{ik} = \ll \text{nombre de modalités } k \text{ dans l'individu } i \gg$

Par exemple :

- $n_{ik} = \text{nombre de mots du type } k \text{ dans le livre } i.$
- $n_{ik} = \text{nombre d'étudiant en discipline } k \text{ de l'université } i.$
- $n_{ik} = \text{nombre de résidents de nationalité } k \text{ dans la commune } i.$

Table de contingence : calculs des quantités

Les **fréquences par individus** se calculent alors avec :

$$f_k^i = \frac{n_{ik}}{n_{i\bullet}}$$

Et la **fréquence relative moyenne** comme :

$$\rho_k = \frac{n_{\bullet k}}{n_{\bullet\bullet}}$$

On peut voir cette dernière quantité comme le **poids des modalités**.

D'ailleurs on peut aussi calculer le **poids des individus** avec :

$$f_i = \frac{n_{i\bullet}}{n_{\bullet\bullet}}$$

Table de contingence : la dissimilarité du chi2

Les **quotients d'indépendance** peuvent s'écrire comme :

$$q_{ik} = \frac{n_{ik}}{n_{ik}^{\text{theo}}} \quad n_{ik}^{\text{theo}} = \frac{n_{i\bullet} n_{\bullet k}}{n_{\bullet\bullet}}$$

où n_{ik}^{theo} sont les **effectifs théoriques sous indépendance**.

La **dissimilarité du chi2** s'obtient de la même manière, ce qui correspond à :

$$D_{ij}^{\chi} := \sum_{k=1}^p \rho_k (q_{ik} - q_{jk})^2 = \sum_{k=1}^p \frac{n_{\bullet k}}{n_{\bullet\bullet}} \left(\frac{n_{ik} n_{\bullet\bullet}}{n_{i\bullet} n_{\bullet k}} - \frac{n_{jk} n_{\bullet\bullet}}{n_{j\bullet} n_{\bullet k}} \right)^2$$

Table de contingence : liens avec le chi2

Le nom « **dissimilarité du chi2** » vient de la propriété :

$$\frac{1}{2} \sum_{i,j=1}^n f_i f_j D_{ij}^{\chi} = \frac{\text{chi2}}{n_{\bullet\bullet}} = \text{phi2}$$

où

$$\text{chi2} = \sum_{i=1}^n \sum_{k=1}^p \frac{(n_{ik} - n_{ik}^{\text{theo}})^2}{n_{ik}^{\text{theo}}}$$

est la **mesure classique de dépendance entre lignes et colonnes de la table contingence**, et le phi2 la même mesure mais en termes relatifs (indépendamment de l'effectif total $n_{\bullet\bullet}$).

Ainsi, $\text{chi2} = 0$ ssi $D_{ij}^{\chi} = 0$ partout. Cela arrive ssi $n_{ik} = n_{ik}^{\text{theo}}$ ou ssi $q_{ik} = 1$ partout.

La dissimilarité du chi2 : exemple

	Étudiant-es	Assistant-es	PostDocs	Profs/MER	
FGSE	111	29	7	21	168
Lettres	140	31	12	47	230
SSP	207	36	15	25	283
	458	96	34	93	681

On a $\rho_1 = \frac{458}{681} = 0.672$, $\rho_2 = \frac{96}{681} = 0.141$, $\rho_3 = \frac{34}{681} = 0.050$, $\rho_4 = \frac{93}{681} = 0.137$.

La table des effectifs théoriques et des quotients est :

n_{ij}^{theo}	Étudiant-es	Assistant-es	PostDocs	Profs/MER	
FGSE	112.97	23.68	8.39	22.94	168
Lettres	154.68	32.42	11.48	31.41	230
SSP	190.33	39.89	14.13	38.65	283
	458	96	34	93	681

	Étudiant-es	Assistant-es	PostDocs	Profs/MER	
FGSE	0.98	1.22	0.83	0.92	1
Lettres	0.91	0.96	1.05	1.50	1
SSP	1.09	0.90	1.06	0.64	1
	1	1	1	1	1

On a alors :

$$D_{\text{FGSE, Lettres}}^{\chi} = 0.672 \cdot (0.98 - 0.91)^2 + 0.141 \cdot (1.22 - 0.96)^2 + 0.05 \cdot (0.83 - 1.05)^2 + 0.137 \cdot (0.92 - 1.5)^2 = 0.062$$

Le chi2 est de 17.554, ce qui correspond à la moyenne (pondérée) des dissimilarités du chi2 entre toutes les paires multipliée par toutes les paires.

Les dissimilarités euclidiennes

Dans ce chapitre, nous allons supposer que :

- d_{ij} désigne une **dissimilarité euclidienne** L_2 .
- $D_{ij} = d_{ij}^2$ désigne une **dissimilarité euclidienne carrée** L_2^2 .

On sait alors qu'il existe $\mathbf{X} = (x_{ij})$, une matrice de donnée $n \times p$ telle que :

$$D_{ij} = d_{ij}^2 = \sum_{k=1}^p (x_{ik} - x_{jk})^2$$


Trouver ces coordonnées $\mathbf{X}$ est le but du **Multidimensional scaling (MDS)**.

Le théorème du cosinus

Avec une dissimilarité euclidienne d_{ij} , le **théorème du cosinus** se vérifie. Ce qui veut dire que pour deux profils i et j , on a :

$$d_{ij}^2 = d_{0i}^2 + d_{0j}^2 - 2d_{0i}d_{0j} \cos(\alpha)$$

où d_{0i} est la distance entre i et un **repère quelconque**, noté 0. α mesure alors l'angle entre i et j depuis ce point 0.



Notons que :

$$B_{ij} := d_{0i}d_{0j} \cos(\alpha)$$

correspond au **produit scalaire entre i et j depuis 0**. La formule du cosinus s'écrit alors

$$B_{ij} = -\frac{1}{2}(d_{ij}^2 - d_{0i}^2 - d_{0j}^2) = -\frac{1}{2}(D_{ij} - D_{0i} - D_{0j})$$

Si l'on connaît D_{0i} et D_{0j} , on pourrait donc calculer les produits scalaires B_{ij} entre tous les vecteurs à partir des dissimilarités.

Le principe de Huygens

Principe de Huygens

Soit n individus donnés par leurs **dissimilarités euclidiennes carrées** $\mathbf{D} = (D_{ij})$. Posons 0 le **centre de gravité** de la configuration (le profil moyen). On a alors :

$$\frac{1}{n} \sum_{j=1}^n D_{ij} = D_{i0} + \Delta \quad (\text{Huygens fort})$$

où Δ est l'**inertie** de la configuration. De plus

$$\Delta := \frac{1}{2} \frac{1}{n^2} \sum_{i,j=1}^n D_{ij} = \frac{1}{n} \sum_{i=1}^n D_{i0} \quad (\text{Huygens faible})$$

Si l'on place notre référentiel sur le centre de gravité, les D_{i0} s'obtiennent uniquement avec les D_{ij} .

En **combinant le théorème du cosinus avec le principe de Huygens**, on a :

$$B_{ij} = -\frac{1}{2} \left(D_{ij} - \frac{1}{n} \sum_{k=1}^n D_{ik} - \frac{1}{n} \sum_{k=1}^n D_{jk} + \frac{1}{n^2} \sum_{k,l=1}^n D_{kl} \right)$$

où B_{ij} désigne le **produit scalaire entre i et j depuis le centre de gravité de la configuration**.

Cette formule s'exprime plus élégamment avec des matrices.

Matrice de produits scalaires

Soit n individus donnés par leurs **distances euclidiennes carrées** $\mathbf{D} = (D_{ij})$. La **matrice de centration** $\mathbf{H}$ se définit comme :

$$\mathbf{H} = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n'$$

où $\mathbf{I}_n$ est la matrice identité et $\mathbf{1}_n$ le vecteur de 1 de taille n .

La **matrice de produit scalaire** $\mathbf{B} = (B_{ij})$ depuis le centre de la configuration s'écrit alors comme :

$$\mathbf{B} = -\frac{1}{2} \mathbf{H} \mathbf{D} \mathbf{H}$$

Le théorème du cosinus nous donne également que (pour aller dans l'autre sens) :

$$D_{ij} = B_{ii} + B_{jj} - 2B_{ij}$$

Au chapitre sur l'ACP, on a vu que l'on pouvait trouver les « coordonnées des variables » (les saturations) à partir d'une matrice de variance-covariance Σ .

$$\Sigma (p \times p) \longrightarrow \mathbf{U} (p \times p)$$

La matrice Σ peut être construite comme la **matrice des produits scalaires entre variables centrées**.

Le **Multidimensional scaling (MDS)** reprend le même principe, mais sur la **matrice des produits scalaires entre individus (centrés) obtenue à partir d'une matrice de dissimilarités**.

$$\begin{array}{ccccc} \mathbf{D} (n \times n) & \longrightarrow & \mathbf{B} (n \times n) & \longrightarrow & \mathbf{X} (n \times n) \\ \text{(matrice de dissimilarités } L_2^2) & & \text{(matrice de produits scalaires)} & & \text{coordonnées} \end{array}$$

On peut donc **reconstituer les coordonnées des individus à partir de dissimilarités euclidiennes carrées** (via les produits scalaires).