

Exercices 6 : Le calcul matriciel, l'aléatoire et les tests statistiques

Essayez de faire ces exercices de manière indépendante. Inscrivez vos réponses dans un fichier script R (avec l'extension ".r" ou ".R") en essayant de bien structurer (et dans l'idéal commenter) votre code.

1 Le calcul matriciel

- Créez la matrice suivante :

$$A = \begin{pmatrix} 2 & 1 & 6 & 7 \\ 1 & -2 & 4 & -6 \\ 6 & 4 & 8 & 11 \\ 7 & -6 & 11 & 14 \end{pmatrix}$$

- Déterminez les valeurs propres et vecteurs propres de A et conservez la matrice des vecteurs propres nommée U et les valeurs propres dans une matrice diagonale nommée L .
- Vérifiez que la matrice U est bien orthogonale.
- Calculez le déterminant de U .
- Calculez la matrice $A_2 = ULU'$ et vérifiez que $A_2 = A$ (avec l'aide de la fonction `round()` pour éliminer les erreurs numériques).
- Créez les vecteurs nommés a et b suivants, et calculez $B = ba'$:

$$a = \begin{pmatrix} 3 \\ 5 \\ 4 \\ 9 \end{pmatrix} \quad b = \begin{pmatrix} 4 \\ 12 \\ 7 \\ 8 \end{pmatrix}$$

2 L'aléatoire

Le but de cet exercice est de créer un graphique de densité pour la loi normale standardisée.

1. Pour commencer, générez 100 nombres aléatoires allant de -4.5 à 4.5 suivant la loi uniforme et stockez-les dans un vecteur.
2. Triez ce vecteur dans l'ordre croissant.
3. Créez un nouveau vecteur qui stockera les densités (selon la loi normale standardisée) des valeurs du premier vecteur.
4. Affichez dans un graphique de type `geom_line`, avec comme coordonnées x le premier vecteur et comme coordonnées y le vecteur de densité.

3 Les tests statistiques

3.1 Préparation des données : sociolinguistique.xlsx

- Chargez les librairies `tidyverse` et `readxl`.

- Chargez le jeu de données `sociolinguistique.xlsx`.
- Renommez les variables suivantes avec la fonction `rename`, (les éléments entre <> sont à remplacer adéquatement) :

```
<nouveau jeu de données> = <ancien jeu de données> %>%
  rename(annee=<nom de la variable année de naissance>,
         genre=<nom de la variable du genre>,
         q1_cat='«?Les anglicismes enrichissent la langue française?»',
         q2_cat='«?Les anglicismes constituent une menace pour la langue française?»')
```
- Créez des variables numériques `q1` et `q2`, contenant les réponses aux questions recodées selon le modèle :

```
<nouveau jeu de données> = <ancien jeu de données> %>%
  mutate(q1=case_when(q1_cat=="En désaccord total" ~ -2,
                     q1_cat=="Plutôt en désaccord" ~ -1,
                     q1_cat=="Neutre" ~ 0,
                     q1_cat=="Plutôt d'accord" ~ 1,
                     q1_cat=="Tout à fait d'accord" ~ 2))
```
- Créez la variable `generation` avec :

```
<nouveau jeu de données> = <ancien jeu de données> %>%
  mutate(generation=case_when(annee %in% 0:1983 ~ "X",
                              annee %in% 1984:1995 ~ "Y",
                              annee %in% 1995:3000 ~ "Z"))
```

3.2 Tests de moyenne groupes non-appariés

- Extrayez les vecteurs `q1_f` et `q1_h`, i.e. les réponses numériques à la question 1 pour les femmes et les hommes.
- Effectuez un test de moyenne entre ces deux vecteurs.
- Refaites cette procédure pour la question 2.
- Est-ce que les résultats sont significatifs au seuil $\alpha = 5\%$? Et au seuil $\alpha = 10\%$? Comment peuvent-ils s'interpréter (sens de l'effet)?

3.3 Tests bi-variés

- Effectuez un test de corrélation entre les réponses numériques à la question 1 et la question 2. Interprétez brièvement.
- Effectuez un test du F-ratio entre les réponses numériques à la question 1 et les générations. Refaites le même test pour la question 2 et les générations.
- Pour vous aider à interpréter les résultats précédants, faites des boxplots multiples entre génération et réponses numériques aux questions. Interprétez les résultats des tests et les boxplots.
- Créez une table de contingence entre les réponses catégorielles de la question 1 et les générations. Effectuez un test du χ^2 sur cette table de contingence. Est-ce que les résultats diffèrent par rapport au test du F-ratio? Expliquez brièvement.