

Exercices 7 : La régression multiple

Essayez de faire ces exercices de manière indépendante. Inscrivez vos réponses dans un fichier script R (avec l'extension ".r" ou ".R") en essayant de bien structurer (et dans l'idéal commenter) votre code.

1 Chargement et pré-traitements des données

- Chargez les packages `tidyverse`, `janitor`, `MuMIn` et `broom`.
- Chargez le fichier de données `SeoulBikeData.csv` qui se trouve dans le dossier `data`.
- Utilisez la fonction `clean_names()` du package `janitor` pour transformer les noms des variables dans une version compatible avec R.
- Enlevez les lignes où le service de vélo n'est pas fonctionnel, c'est-à-dire où la variable `functioning_day` n'est pas "Yes".
- Retirez les variables `date`, `hour` et `functioning_day`.
- Transformez les variables `holiday` et `seasons` en facteurs.

2 Modèles de régression

- Construisez le modèle de régression "complet" pour prédire la variable `rented_bike_count` à l'aide de toutes les autres. Affichez-le. Quel est le pourcentage de variance expliquée par ce modèle ?
- Effectuez une sélection de modèles exhaustive avec `dredge()` selon le critère BIC.
- Affichez les 5 premiers modèles retenus. Quelle est la valeur maximale obtenue du BIC ?
- Stockez le meilleur modèle dans une variable, affichez-le, et comparez son R^2 -ajusté avec celui d'avant.
- Donnez les modalités qui ont le plus d'impact positif ou négatif sur la location de vélo.
- Construisez le jeu de données "augmenté", contenant les valeurs prédites et les résidus.
- Avec le jeu de données construit ci-dessus, tracez le diagramme des résidus. Est-ce que les hypothèses de travail sont respectées ? Commentez.