

Exercices 9 : le clustering

1 Préparation et jeu de données

- Chargez les packages `tidyverse`, `FactoMineR`, `factoextra`, `aricode`.
- Vous allez effectuer des clusterings sur le jeu de données `swiss`, contenu dans R. Examinez-le et lisez l'aide à son sujet.
- À partir de ce jeu de données, créez un jeu de données dérivé qui contient une variable catégorielle bimodale `Religion`, avec les modalités `Catholic` et `Protestant`. Construisez cette dernière à partir de la variable numérique `Catholic` et gardez uniquement la variable catégorielle.
- Construisez le jeu de données qui va servir au clustering, avec uniquement les variables `Fertility`, `Agriculture`, `Examination` et `Education`. N'oubliez pas de standardiser les variables.
- Visualisez le jeu de données qui va servir au clustering avec une ACP. Affichez les trois graphiques principaux et essayez d'interpréter les résultats.

2 Le k-means

- Déterminez le nombre de clusters optimal avec le critère de la silhouette.
- Effectuez le k-means avec ce nombre de clusters et assez d'essais.
- Affichez les résultats du k-means dans le plan factoriel principal.
- Ajoutez la variable contenant l'appartenance aux clusters dans le jeu de données complet.
- Examinez la force des liens entre les variables ayant servi au clustering et l'appartenance aux clusters. Quelle variable a le plus servi dans la discrimination ? Et laquelle a le moins servi ?
- Examinez la significativité des liens entre les variables `Infant.Mortality`, `Religion` et les clusters.
- Caractérisez les profils des clusters avec les variables significatives.

3 La CAH

- Construisez la matrice des distances euclidiennes à partir du jeu de données contenant les variables sur lequel le k-means a été effectué.
- Effectuez la CAH avec la méthode de Ward. Affichez le dendrogramme.
- Déterminez le nombre de clusters avec méthode du "Gap". *Attention : sélectionnez la montée significative après avoir atteint le minimum.*
- Affichez le dendrogramme avec la coupe retenue.
- Sauvegardez le résultat de ce clustering dans le jeu de données complet.
- Examinez la significativité des liens entre les clusters obtenus et toutes les variables du jeu de données.
- Caractérisez les profils des clusters avec les variables significatives.
- Construisez la table de contingence entre les groupes obtenus avec le k-means et la CAH. Examinez-la et calculez le χ^2 et le AMI associé.