

Exercices 11 : kNN et cross-validation

Script pour commencer

Pour faire cette série d'exercices (qui est longue), vous devez vous baser sur le script `ex11_start.r`. Ce dernier contient les packages que vous devez utiliser, ainsi que deux fonctions :

- La fonction `create_spiral()` qui permet de créer des données artificielles contenant deux classes formant une spirale. Un graphique d'exemple vous est donné pour que vous vous rendiez compte des données. Utilisez les données créées ainsi dans la suite de l'exercice, mais n'hésitez pas à changer les paramètres de création pour voir d'autres résultats.
- La fonction `knn_dpov_classif()` qui effectue une classification selon la **méthode des k plus proches voisins (kNN)** (https://fr.wikipedia.org/wiki/Methode_des_k_plus_proches_voisins) avec une **distance de Minkowski de paramètre p** . Il s'agira donc d'optimiser **deux hyperparamètres** : p , le degré de la distance de Minkowski, et k , le nombre de voisins pris en compte.

Avant de commencer, étudiez ces deux fonctions pour comprendre comment elles marchent.

1 Préparation des jeux d'entraînement-validation et test

- Standardisez les coordonnées des points.
- Créez les jeux d'entraînement-validation et test, en stratifiant selon la classe.
- Vérifiez les tailles des jeux de données et les proportions des classes.

2 Test du k-NN

- Testez la fonction du k-NN avec des valeurs de p et k quelconques, en prenant comme référence le jeu d'entraînement et en prédisant les classes du jeu de test.
- Calculez l'exactitude, la précision, le rappel et le F1 pour le jeu de test.

3 Cross-validation

- Créez 4 folds sur votre jeu d'entraînement-validation de manière stratifiée.
- Créez des valeurs à tester pour p et k (attention, il vaut mieux choisir des nombres impairs de voisins, pour ne pas avoir d'égalités dans les "votes").
- Créez une matrice vide pouvant contenir les résultats, avec sur les lignes les valeurs à tester pour les p et sur les colonnes les valeurs à tester pour les k .

- Faites une triple boucle pour la cross-validation (sur les p , les k et sur les folds), et effectuez-la. Attention, il vaut mieux calculer les moyennes sur les folds avant de les stocker dans la matrice de résultats créée au point précédent.
- Affichez les moyennes des exactitudes, précisions, rappels et des F1 pour toutes les valeurs de p et k sous forme graphique (aidez-vous de `plot.matrix()`).

4 Le "meilleur modèle"

- Récupérez les meilleurs paramètres de p et k pour l'exactitude. En cas d'égalité, prenez un couple au hasard.
- Calculez les labels sur le jeu de test à partir du jeu d'entraînement-validation au complet, en utilisant les paramètres optimaux.
- Calculez les différentes mesures sur ces labels.
- (BONUS) Pour finir, créez une grille de points entre les valeurs minimale et maximale de x et y (voir `expand.grid()`), et prédisez les labels de tous ces points. Affichez la spirale initiale et les frontières de décision avec cette grille (voir `geom_raster()`).